



YAYASAN PRIMA AGUS TEKNIK

# DSS

(Decision Support Systems)

# Sistem Pendukung Keputusan

**Penulis :**

**Dr. Joseph Teguh Santoso, S.Kom, M.Kom  
Budi Hartono. M.Kom**

# **DSS (Decision Support Systems) Sistem Pendukung Keputusan**

## **Penulis :**

Dr. Joseph Teguh Santoso, S.Kom., M.Kom.  
Budi Hartono, M.Kom.

## **ISBN :**

## **Editor :**

Muhammad Sholikhan, M.Kom

## **Penyunting :**

Dr. Mars Caroline Wibowo. S.T., M.Mm.Tech

## **Desain Sampul dan Tata Letak :**

Irdha Yunianto, S.Ds., M.Kom.

## **Penerbit :**

Yayasan Prima Agus Teknik Bekerja sama dengan  
Universitas Sains & Teknologi Komputer (Universitas STEKOM)

## **Redaksi :**

Jl. Majapahit no 605 Semarang  
Telp. (024) 6723456  
Fax. 024-6710144  
Email : [penerbit\\_ypat@stekom.ac.id](mailto:penerbit_ypat@stekom.ac.id)

## **Distributor Tunggal :**

### **Universitas STEKOM**

Jl. Majapahit no 605 Semarang  
Telp. (024) 6723456  
Fax. 024-6710144  
Email : [info@stekom.ac.id](mailto:info@stekom.ac.id)

Hak cipta dilindungi undang-undang  
Dilarang memperbanyak karya tulis ini dalam bentuk dan dengan cara  
apapun tanpa ijin dari penulis

## KATA PENGANTAR

Puji syukur kami panjatkan Tuhan YME atas terselesaikannya buku yang berjudul **“Sistem Pendukung Keputusan”** dengan baik. Pengambilan keputusan muncul ketika kita ingin memilih tindakan terbaik dari serangkaian alternatif. Dengan kemajuan teknologi digital, mudah, dan hampir seketika, untuk mengumpulkan sejumlah besar informasi dan/atau data yang berkaitan dengan masalah yang ingin kita pecahkan. Misalnya, web di seluruh dunia mungkin merupakan sumber utama informasi dan/atau data yang sering kita gunakan ketika kita menghadapi masalah pengambilan keputusan. Namun, informasi dan/atau data yang kita peroleh dari dunia nyata seringkali kompleks, dan terdiri dari berbagai macam noise. Selain itu, informasi dan/atau data dunia nyata seringkali tidak lengkap dan ambigu, karena ketidakpastian lingkungan. Semua ini membuat pengambilan keputusan menjadi tugas yang menantang. Untuk mengatasi tantangan pengambilan keputusan, peneliti telah merancang dan mengembangkan berbagai sistem pendukung keputusan untuk memberikan bantuan dalam proses pengambilan keputusan manusia.

Tujuan utama buku ini adalah untuk menyediakan kumpulan kecil teknik yang berasal dari kecerdasan buatan, serta metodologi pelengkap lainnya, yang berguna untuk desain dan pengembangan sistem pendukung keputusan cerdas. Contoh aplikasi tentang bagaimana sistem pendukung keputusan cerdas ini dapat digunakan untuk membantu mengatasi berbagai masalah dunia nyata dalam domain yang berbeda, mis. bisnis, manajemen, manufaktur, transportasi dan industri makanan, dan biomedis, juga disajikan. Sebanyak dua puluh bab, yang secara garis besar dapat dibagi menjadi dua bagian, yaitu, (i) teknik pemodelan dan desain untuk sistem pendukung keputusan cerdas; dan (ii) ulasan dan aplikasi sistem pendukung keputusan cerdas, termasuk dalam buku ini. Ringkasan dari setiap bab adalah sebagai berikut. Bagian I Teknik Pemodelan dan Desain untuk Sistem Pendukung Keputusan Cerdas, Ikhtisar pengambilan keputusan cerdas disajikan dalam Bab 1. Aspek umum pengambilan keputusan, kualitas keputusan, dan jenis sistem pendukung keputusan dijelaskan. Sejumlah teknik cerdas yang berasal dari kecerdasan buatan yang berguna untuk desain dan pengembangan sistem pendukung keputusan cerdas dijelaskan. Contoh aplikasi dari teknik cerdas ini, serta model hibridanya, juga disorot. Dalam Bab 2, metodologi rekayasa sistem pendukung keputusan cerdas untuk merancang dan membangun sistem pendukung keputusan cerdas dijelaskan. Metodologi yang diusulkan terdiri dari empat fase: inisiasi proyek, desain sistem, pembangunan dan evaluasi sistem, dan penerimaan definitif pengguna. Kegunaan metodologi yang diusulkan dinilai dalam pengaturan akademik dengan studi kasus yang realistik, dan hasil yang memuaskan dilaporkan. Implikasi dari metodologi yang diusulkan dalam menyediakan proses berorientasi rekayasa perangkat lunak yang sistematis bagi pengguna untuk mengembangkan sistem pendukung pengambilan keputusan yang cerdas dibahas. Di pasar yang sangat kompetitif, desain produk menjadi tugas yang menantang karena kebutuhan pelanggan yang beragam dan kompleksitas teknologi. Dalam Bab 3, kerangka kerja yang menjelaskan hubungan masalah desain produk, proses desain produk,

proses desain bentuk, metode dan alat desain bentuk dengan pertimbangan fungsional, ergonomis, emosional, dan persyaratan manufaktur, disajikan. Sebuah sistem pendukung keputusan untuk membantu desainer dalam merancang bentuk produk dikembangkan. Studi kasus pada desain bentuk skuter dilakukan. Penerapan sistem pendukung keputusan untuk merencanakan proses desain bentuk dan membuat bentuk skuter mengikuti proses yang direncanakan ditunjukkan.

Sistem Inferensi Fuzzy Neural Berbasis Pohon (TNFIS) untuk masalah perumusan model dalam peramalan deret waktu, identifikasi sistem, serta masalah klasifikasi disarankan di Bab 4. Pendekatan yang diusulkan mengambil sifat yang tidak tepat dari penilaian pengambil keputusan pada tacit yang berbeda model menjadi pertimbangan. Algoritma pembelajaran TNFIS terdiri dari dua fase: fase pembelajaran struktural berbasis tindakan Piaget, dan fase penyetelan parameter. Pengetahuan dalam bentuk aturan fuzzy dibuat menggunakan TNFIS, dan teknik visualisasi diusulkan agar pengambil keputusan dapat lebih memahami model yang dirumuskan. Efektivitas TNFIS ditunjukkan dengan menggunakan masalah benchmark.

Pendekatan umum untuk pengambilan keputusan dalam sistem yang kompleks dengan menggunakan sistem pendukung keputusan berbasis agen dijelaskan dalam Bab 5. Pendekatan ini berkontribusi pada desentralisasi dan pengambilan keputusan lokal dalam alur kerja standar. Sebuah struktur berlapis diadopsi untuk mengatasi masalah yang melibatkan (i) pengambilan data, fusi, dan pra-pemrosesan; (ii) penggalian dan evaluasi data; dan (iii) pembuatan keputusan, peringatan, solusi dan prediksi. Sistem pendukung keputusan berbasis agen diterapkan untuk mengevaluasi dampak parameter lingkungan terhadap kesehatan manusia di wilayah Spanyol. Ditemukan bahwa sistem mampu menyediakan semua langkah yang diperlukan untuk pengambilan keputusan dengan menggunakan agen komputasi. Dalam Bab 6, analisis keputusan dengan satu kriteria dan beberapa kriteria untuk kebijakan dan perencanaan energi pedesaan yang berkelanjutan dijelaskan. Sejumlah sistem pendukung keputusan energi kriteria tunggal dan banyak kriteria dianalisis, dengan kekuatan dan keterbatasannya dibahas. Sebuah sistem pendukung keputusan energi pedesaan yang berkelanjutan, yang menggabungkan kriteria kuantitatif dan kualitatif dan memungkinkan prioritas sekelompok calon pengguna untuk dipertimbangkan dalam analisis keputusan, dijelaskan. Kebaruan sistem pendukung keputusan terletak pada kemampuannya untuk menyesuaikan kebutuhan masyarakat pedesaan di negara berkembang dengan teknologi energi yang sesuai, sehingga meningkatkan mata pencaharian dan keberlanjutan. Sebuah studi tentang penggunaan sistem pendukung keputusan untuk analisis energi dan perencanaan komunitas terpencil di Kolombia disajikan.

Dikatakan bahwa pengambilan keputusan adalah jembatan antara sensasi dan tindakan, yaitu jembatan antara pemrosesan input stimulus dan pembangkitan output motorik. Dalam Bab 7, model pengambilan keputusan yang dikenal sebagai sistem pengambilan keputusan komplementer diusulkan. Model ini didasarkan pada pembelajaran komplementer yang secara fungsional memodelkan penghambatan lateral dan mekanisme segregasi yang diamati dalam proses pengambilan keputusan manusia, yaitu, dalam basis saraf lobus prefrontal dan parietal dalam pengambilan keputusan. Aturan fuzzy dibuat untuk

memberi tahu pengguna seberapa yakin sistem dalam prediksinya. Untuk menilai kinerja model yang diusulkan, sejumlah set data medis benchmark digunakan. Hasilnya lebih baik dibandingkan dengan metode pembelajaran mesin lainnya. Berbagai teknik peramalan digunakan oleh banyak perusahaan besar untuk memprediksi masa depan yang tidak pasti dalam upaya untuk membuat keputusan yang lebih baik yang mempengaruhi masa depan organisasi. Dalam Bab 8, sistem pendukung peramalan berdasarkan skema pemulusan eksponensial untuk peramalan data deret waktu disajikan. Isu-isu yang berkaitan dengan estimasi parameter dan pemilihan model dibahas. Sistem pendukung peramalan Bayesian, yaitu, SIOPRED-Bayes, dijelaskan. Sistem ini menggabungkan model pemulusan eksponensial univariat yang ada serta beberapa generalisasi dari model ini untuk menangani fitur yang muncul dalam adegan ekonomi dan industri. Penerapannya untuk peramalan konsumsi air ditunjukkan. Proses keputusan Markov yang dapat diamati sebagian memberikan kerangka matematika yang berguna untuk perencanaan agen di bawah lingkungan yang dapat diamati secara stokastik dan sebagian. Dalam Bab 9, algoritma pembelajaran penguatan berbasis memori yang dikenal sebagai U-Tree berbasis penguatan dijelaskan. Ia mampu mempelajari transisi status dari pengalaman dan membangun model status dengan sendirinya berdasarkan input sensor mentah. Modifikasi prosedur pembangkitan keadaan U-Tree untuk meningkatkan efektivitas model keadaan juga diusulkan. Kinerjanya dievaluasi menggunakan tugas mengemudi mobil. Selain itu, modifikasi pada uji statistik untuk estimasi imbalan disarankan, yang memungkinkan algoritme untuk dijadikan tolok ukur terhadap beberapa pendekatan berbasis model dengan masalah yang terkenal dalam proses keputusan Markov yang dapat diamati sebagian. Fuzzy Inference System (FIS) telah terbukti menjadi model yang berguna dalam melakukan berbagai penilaian dan masalah pengambilan keputusan. Dalam Bab 10, pentingnya sifat monotonisitas dari model penilaian berbasis FIS diselidiki. Secara khusus, kondisi yang cukup untuk model penilaian berbasis FIS untuk memenuhi sifat monotonisitas diturunkan. Selain itu, kerangka kerja Mode Kegagalan dan Analisis Efektif (FMEA) dengan model Nomor Prioritas Risiko (RPN) berbasis FIS diperiksa. Sebuah studi kasus penerapan kerangka FMEA untuk proses manufaktur semikonduktor dilakukan. Hasil yang diperoleh menunjukkan pentingnya sifat monotonisitas model RPN berbasis FIS dalam mengatasi masalah penilaian dan pengambilan keputusan. Bagian II Tinjauan dan Aplikasi Sistem Pendukung Keputusan Cerdas, sebuah studi menyeluruh tentang penggunaan sistem pendukung keputusan dalam industri transportasi disajikan dalam Bab 11. Taksonomi untuk mengklasifikasikan sistem pendukung keputusan transportasi dijelaskan. Kegunaan sistem pendukung keputusan transportasi dalam memecahkan berbagai jenis masalah keputusan diperiksa. Metodologi pengambilan keputusan serta teknologi informasi yang berguna untuk mengembangkan sistem pendukung keputusan transportasi juga dibahas. Sebuah tinjauan yang berguna pada berbagai macam sistem pendukung keputusan yang diterapkan pada sektor transportasi yang berbeda, yang mencakup transportasi jalan, perkotaan, udara, kereta api, dan angkutan laut, disertakan.

Penerapan sistem pendukung keputusan untuk industri makanan, dan khususnya industri makanan laut, disajikan dalam Bab 12. Industri makanan berbeda dengan banyak industri lainnya, karena sifat produk dan bahan dapat berubah secara dramatis seiring waktu.

Ketertelusuran penting untuk mengetahui sejarah produk dan/atau bahan yang diminati. Dengan memanfaatkan ketertelusuran produk, aliran data dapat digunakan untuk pendukung keputusan. Hal ini menunjukkan bahwa sistem pendukung keputusan bermanfaat bagi sejumlah bidang dalam pengolahan makanan, yang meliputi menurunkan dampak lingkungan dari pengolahan makanan, manajemen keselamatan, manajemen pengolahan, dan manajemen stok. Kegunaan sistem pendukung keputusan untuk industri daging, produsen makanan, manajemen persediaan dan pengisian untuk pengecer juga dijelaskan. Desain kota kreatif adalah masalah multi-aspek yang melibatkan berbagai pengetahuan dan database yang beragam. Berdasarkan perangkat kasar, sistem pendukung keputusan yang mampu membantu pengambil keputusan memanfaatkan sumber daya dengan teknologi informasi untuk desain kota kreatif disajikan pada Bab 13. Aturan desain pengembangan kota kreatif oleh para ahli desain perkotaan juga dijelaskan. Teori himpunan kasar diterapkan untuk memilih aturan keputusan dan mengukur status kota-kota Jepang saat ini. Sebuah prototipe, yaitu, Sistem Inovator Perkotaan, untuk menunjukkan kegunaan pendekatan dalam membangun model kolaboratif kota kreatif dengan partisipasi publik dibahas. Aspek utama dari pengambilan keputusan adalah dalam membuat keputusan pembelian dan penjualan. Di Bab 14, dijelaskan mekanisme lelang kombinatorial di mana bidder dapat mengajukan beberapa harga (nilai pesimistik, ideal, dan optimistik) dalam satu paket. Sebuah operasionalisasi baru pada hubungan juru lelang-penawar berdasarkan jenis penawaran atau distribusi kemungkinan segitiga diusulkan. Pendekatan yang diusulkan dievaluasi dengan masalah uji dalam lingkungan lelang fuzzy. Analisis mengungkapkan bahwa interval solusi fuzzy memberikan kemampuan negosiasi dan penilaian risiko bagi juru lelang.

Kebakaran gedung yang tidak disengaja menyebabkan banyak korban jiwa dan kerugian harta benda bagi masyarakat. Jaringan syaraf tiruan telah terbukti menjadi model pengambilan keputusan yang efisien dan efektif dalam aplikasi keselamatan kebakaran. Dalam Bab 15, model jaringan saraf hibrida yang menggabungkan Fuzzy ART dan Jaringan Saraf Regresi Umum diusulkan. Serangkaian percobaan menggunakan kumpulan data benchmark untuk menguji kegunaan jaringan dalam mengatasi masalah regresi data umum pertama kali dilakukan. Sebuah aplikasi baru dari jaringan hybrid yang diusulkan untuk memprediksi waktu evakuasi selama bencana kebakaran dijelaskan. Hasil menunjukkan kemanjuran jaringan yang diusulkan dalam melakukan masalah rekayasa keselamatan kebakaran. Dalam Bab 16, penggunaan desain jalur-konvergensi, yang merupakan pendekatan nonparametrik, untuk pengambilan keputusan dalam strategi migrasi optimal dalam perencanaan kota diperiksa. Sebuah studi untuk mengidentifikasi aglomerasi penduduk yang ada untuk kota-kota kecil, menengah, dan besar dari perspektif regional dan perkotaan dan untuk mengevaluasi efisiensi aglomerasi penduduk yang ada dalam perencanaan kota pertama kali dilakukan. Identifikasi berdasarkan desain jalur-konvergen mengungkapkan inefisiensi dalam aglomerasi populasi yang ada di Cina. Berdasarkan aglomerasi populasi yang teridentifikasi dan inefisiensi aglomerasi, sejumlah keputusan migrasi populasi untuk menghilangkan inefisiensi alokasi populasi dibahas. Dalam Bab 17, penggunaan sejumlah jaringan saraf fuzzy untuk gambar termal superfisial terhadap suhu tubuh internal yang sebenarnya dijelaskan. Perbandingan antara memori semantik global dan lokal serta model jaringan saraf fuzzy Mamdani dan

Takagi-Sugeno-Kang disajikan. Serangkaian studi eksperimental menggunakan data nyata dari skrining pasien SARS potensial dilakukan. Hasil eksperimen klasifikasi suhu berdasarkan citra termal dianalisis. Perbandingan antara berbagai jaringan pembelajaran global dan lokal disajikan. Hasil menunjukkan potensi jaringan saraf kabur sebagai alat pendukung keputusan medis cerdas untuk analisis termal, dengan kemampuan menghasilkan interpretasi semantik yang masuk akal dari prediksi sistem untuk pengguna domain. Elektroensefalogram (EEG) adalah salah satu sumber informasi terpenting dalam terapi epilepsi, dan para peneliti telah membahas masalah penggunaan alat pendukung keputusan untuk sumber data semacam itu. Dalam Bab 18, penerapan sistem logika fuzzy baru yang diimplementasikan dalam kerangka jaringan saraf untuk klasifikasi sinyal EEG disajikan. Jaringan yang diusulkan membangun aturan awalnya dengan pengelompokan sedangkan dasar aturan fuzzy akhir ditentukan oleh pembelajaran kompetitif. Baik teknik estimasi backpropagation error dan kuadrat terkecil rekursif digunakan untuk menyetel parameter premis dan konsekuensi jaringan. Penerapan jaringan untuk klasifikasi sinyal EEG ditunjukkan.

Dalam Bab 19, sistem penalaran dasar kasus untuk diferensiasi berdasarkan kontrol yang diubah dari gerakan mata saccadic pada subjek Attention-Deficit Hyperactivity Disorder (ADHD) dan kelompok kontrol dijelaskan. Sistem TA3, sistem pendukung keputusan cerdas yang menggabungkan penalaran berbasis kasus ke dalam kerangka kerjanya, digunakan untuk mengambil dan menerapkan kasus diagnostik ADHD sebelumnya ke masalah baru berdasarkan data kinerja saccade. Hasilnya menunjukkan bahwa sistem yang diusulkan mampu membedakan ADHD dari subjek kontrol normal, berdasarkan kinerja saccade, dengan akurasi yang meningkat. Dalam Bab 20, penggunaan model memori pembelajaran berbasis otak yang diilhami oleh otak yang dikenal sebagai pengontrol artikulasi model serebelar yang berkembang sendiri semu untuk memodelkan proses pengambilan keputusan otonom dalam lingkungan yang dinamis dan kompleks dijelaskan. Model ini mengadopsi skema manajemen memori yang digerakkan oleh pengalaman, yang telah terbukti lebih efisien dalam menangkap karakteristik bawaan dari domain masalah untuk pengambilan keputusan yang efektif. Penerapan model dievaluasi menggunakan dinamika mekanisme regulasi insulin metabolismik orang sehat ketika terganggu oleh asupan makanan. Model ini berguna untuk menangkap hubungan interaksi yang kompleks dari tingkat glukosa darah, asupan makanan, dan konsentrasi insulin darah yang dibutuhkan untuk homeostasis metabolismik.

Tim Penulis  
Dr Joseph Teguh Santoso, M.Kom  
Budi Hartono, M.Kom.

## DAFTAR ISI

<b>Halaman Judul .....</b>	<b>i</b>
<b>Kata Pengantar .....</b>	<b>iv</b>
<b>Daftar Isi .....</b>	<b>ix</b>
<b>BAGIAN I TEKNIK PEMODELAN DAN DESAIN SISTEM PENDUKUNG KEPUTUSAN</b>	
<b>BAB 1 KEMAJUAN DALAM PENGAMBILAN KEPUTUSAN YANG CERDAS .....</b>	<b>1</b>
1.1 Pendahuluan .....	1
1.2 Aspek Umum Pengambilan Keputusan .....	2
1.3 Teknik untuk Pengambilan Keputusan yang Cerdas .....	6
1.4 Contoh Aplikasi .....	18
1.5 Kesimpulan .....	21
<b>BAB 2 IDSSE-M: METODOLOGI REKAYASA SISTEM PENDUKUNG KEPUTUSAN .....</b>	<b>22</b>
2.1 Pendahuluan .....	22
2.2 Ikhtisar Metodologi DMSS .....	26
2.3 IDSSE-M .....	28
2.4 IDSSE-M: Ilustrasi .....	32
2.5 Kesimpulan .....	40
<b>BAB 3 DESAIN BENTUK PRODUK BERDASARKAN SISTEM PENDUKUNG KEPUTUSAN ....</b>	<b>44</b>
3.1 Pendahuluan .....	44
3.2 Kerangka Proses Desain Produk .....	48
3.3 Metode dan Alat untuk Desain Bentuk .....	54
3.4 DSS untuk Perencanaan Proses Desain .....	54
3.5 Studi Kasus .....	58
3.6 Kesimpulan .....	65
<b>BAB 4 PENINGKATAN SISTEM PENDUKUNG KEPUTUSAN DENGAN MODEL NEURAL FUZZY DAN VISUALISASI MODEL SEDERHANA .....</b>	
4.1 Pendahuluan .....	70
4.2 Pekerjaan Terkait .....	75
4.3 TNFIS: Model Komputasi yang Terinspirasi dari Pengembangan Kognitif .....	77
4.4 Percobaan Numerik .....	83
4.5 Kesimpulan .....	95
<b>BAB 5 AGEN KOMPUTASI DALAM SISTEM PENDUKUNG KEPUTUSAN KOMPLEKS .....</b>	<b>97</b>
5.1 Pendahuluan .....	97
5.2 Sistem Pendukung Keputusan untuk Studi Sistem Kompleks .....	98
5.3 Sistem Pendukung Keputusan dan Karakteristiknya .....	100
5.4 Pendekatan Umum untuk Pembuatan Sistem Multi-Agen .....	109
5.5 Deskripsi Agen dalam MAS .....	114
5.6 Hasil .....	117
5.7 Kesimpulan .....	120

<b>BAB 6 PENDEKATAN DUKUNGAN KEPUTUSAN MULTI-KRITERIA UNTUK ENERGI</b>	
<b>PEDESAAN BERKELANJUTAN DI NEGARA BERKEMBANG .....</b>	<b>121</b>
6.1 Pendahuluan .....	121
6.2 Membandingkan Sistem Pendukung Keputusan Energi Single dan Multi-Kriteria .....	123
6.3 Jangkauan dan Keterbatasan Energi Multi-Kriteria DSS .....	126
6.4 SURE-DSS: Pendekatan dan Aplikasi Multi-Kriteria yang Komprehensif .....	129
6.5 Solusi Energi Jangka Panjang .....	135
6.6 Kesimpulan .....	136
<b>BAB 7 SISTEM PENGAMBILAN KEPUTUSAN MENURUT PEMBELAJARAN PELENGKAP ...</b>	<b>138</b>
7.1 Pendahuluan .....	138
7.2 Sistem Pengambilan Keputusan Pelengkap .....	139
7.3 Aplikasi .....	150
7.4 Kesimpulan .....	153
<b>BAB 8 SISTEM PENDUKUNG PERAMALAN MENURUT EXPONENTIAL SMOOTHING .....</b>	<b>154</b>
8.1 Pendahuluan .....	154
8.2 Prosedur Pemulusan Eksponensial .....	156
8.3 Estimasi Parameter dan Pemasangan Model .....	159
8.4 Strategi Pemilihan Model .....	166
8.5 Prosedur Peramalan .....	167
8.6 SIOPRED-Bayes .....	171
8.7 Kesimpulan .....	174
<b>BAB 9 U-TREE BERBASIS PENGUATAN: PENDEKATAN BARU MENGATASI POMDP .....</b>	<b>175</b>
9.1 Pendahuluan .....	175
9.2 Proses Keputusan Markov .....	177
9.3 U-Tree dan U-Tree yang Dimodifikasi .....	184
9.4 Detail Algoritma .....	189
9.5 Eksperimen dan Hasil .....	192
9.6 Diskusi .....	198
9.7 Kesimpulan .....	200
<b>BAB 10 TENTANG PENGGUNAAN SISTEM INFERENSI FUZZY UNTUK MASALAH</b>	
<b>PENILAIAN DAN PENGAMBILAN KEPUTUSAN .....</b>	<b>201</b>
10.1 Pendahuluan .....	201
10.2 Tinjauan Sistem Inferensi Fuzzy dan Kondisi yang Memadai .....	203
10.3 Model Angka Prioritas Risiko Berbasis Sistem Inferensi Fuzzy .....	205
10.4 Kerangka FMEA yang Diusulkan dengan Model RPN Berbasis FIS .....	207
10.5 Studi Kasus .....	209
10.6 Kesimpulan .....	212
<b>BAGIAN II ULASAN DAN APLIKASI SISTEM PENDUKUNG KEPUTUSAN CERDAS</b>	
<b>BAB 11 SISTEM PENDUKUNG KEPUTUSAN DALAM TRANSPORTASI .....</b>	<b>213</b>
11.1 Pendahuluan .....	213
11.2 Klasifikasi Transportasi – Berorientasi DSS-S .....	215
11.3 Kategori Utama Masalah Keputusan yang Dipecahkan oleh Transportasi DSS-S ..	218

11.4 Metode Utama Proses Keputusan dan Teknologi Informasi Transportasi DSS-S....	220
11.5 Review Transportasi Terpilih – Berorientasi DSS-S .....	224
11.6 Transportasi – DSS-S Diterapkan di Berbagai Industri dan DSS-S Multimodal .....	247
11.7 Kesimpulan .....	255
<b>BAB 12 SISTEM PENDUKUNG KEPUTUSAN UNTUK INDUSTRI MAKANAN .....</b>	<b>257</b>
12.1 Pendahuluan .....	257
12.2 Kualitas dan Ketelusuran Data.....	259
12.3 Sistem Pendukung Keputusan dalam Rantai Pasokan Daging .....	267
12.4 Kesimpulan .....	274
<b>BAB 13 MEMBANGUN SISTEM PENDUKUNG KEPUTUSAN DESAIN PERKOTAAN BERBASIS KONSEP KOTA KREATIF .....</b>	<b>276</b>
13.1 Pendahuluan .....	276
13.2 Kota Kreatif .....	278
13.3 Teori Himpunan Kasar .....	285
13.4 Pengambilan Sampel yang Efisien Berdasarkan Uji Statistik .....	288
13.5 Simulasi .....	290
13.6 Sistem Pendukung Keputusan .....	290
13.7 Sistem Informasi Geografis .....	292
13.8 Desain Penelitian .....	293
13.9 Prototipe Sistem Pendukung Keputusan .....	295
13.10 Kesimpulan .....	298
<b>BAB 14 HARGA FUZZY DALAM LELANG KOMBINASI .....</b>	<b>300</b>
14.1 Pendahuluan .....	300
14.2 Lelang Kombinasi dan Soal Penentuan Pemenang .....	302
14.3 Kombinasi Lelang dan Penentuan Pemenang dalam Lingkungan Fuzzy .....	303
14.4 Formula Model .....	306
14.5 Interpretasi Harga yang Diajukan .....	307
14.6 Tes Generasi Masalah .....	310
14.7 Diskusi .....	315
14.8 Kesimpulan .....	316
<b>BAB 15 PENERAPAN JARINGAN SYARAF TIRUAN PADA TEKNIK KESELAMATAN KEBAKARAN .....</b>	<b>317</b>
15.1 Pendahuluan .....	317
15.2 Arsitektur Model GRNN dan FA .....	318
15.3 Penggabungan GRNN dan FA .....	322
15.4 Studi Eksperimental .....	325
15.5 Aplikasi untuk Rekayasa Keselamatan Kebakaran .....	331
15.6 Kesimpulan .....	337
<b>BAB 16 PENGAMBILAN KEPUTUSAN STRATEGI OPTIMAL AGLOMERASI PENDUDUK DALAM PERENCANAAN KOTA DENGAN PATH-CONVERGED DESIGN .....</b>	<b>339</b>
16.1 Pendahuluan .....	339
16.2 Desain Konverfensi Jalur .....	340

16.3	Identifikasi Aglomerasi Populasi .....	346
16.4	Pengambilan Keputusan tentang Strategi Migrasi Optimal .....	355
16.5	Kesimpulan .....	361
<b>BAB 17</b>	<b>INTERPRETASI KOGNITIF GAMBAR TERMOGRAFI MENGGUNAKAN MEMORI SEMANTIK PEMBELAJARAN FUZZY NOVEL .....</b>	<b>363</b>
17.1	Pendahuluan .....	363
17.2	Pemrosesan Gambar .....	365
17.3	Pilihan Input: Metode Penilaian Korelasi .....	369
17.4	Jaringan Saraf Fuzzy .....	370
17.5	Hasil Eksperimen dan Analisis .....	380
17.6	Analisis Aturan Fuzzy .....	381
17.7	Kesimpulan .....	385
<b>BAB 18</b>	<b>SISTEM JARINGAN SARAF INFERENSI FUZZY ADAPTIF UNTUK KLASIFIKASI SINYAL EEG .....</b>	<b>387</b>
18.1	Pendahuluan .....	387
18.2	Pemilihan dan Perekaman Data .....	389
18.3	Analisis Spektral Menggunakan Transformasi Wavelet Diskrit .....	390
18.4	Arsitektur AFINN .....	394
18.5	Diskusi Hasil .....	401
18.6	Kesimpulan .....	404
<b>BAB 19</b>	<b>PENDEKATAN SISTEMATIS UNTUK DESAIN SISTEM PENALARAN BERBASIS KASUS UNTUK GANGGUAN PEMUSATAN PERHATIAN-DEFISIT .....</b>	<b>405</b>
19.1	Pendahuluan .....	405
19.2	TA3 .....	407
19.3	Metode dan Bahan .....	410
19.4	Percobaan dan Hasil .....	414
19.5	Diskusi .....	421
19.6	Kesimpulan .....	422
<b>BAB 20</b>	<b>PENDEKATAN NEUROKOGNITIF UNTUK PENGAMBILAN KEPUTUSAN UNTUK REKONTRUKSI PROFIL INSULIN METABOLIK ORANG SEHAT .....</b>	<b>424</b>
20.1	Pendahuluan .....	425
20.2	Cerebellum dan Sistem Memori Prosedural Manusia .....	429
20.3	PSECMAC: Model Memori Pembelajaran Cerebellar Multi-Resolusi .....	433
20.4	Diabetes sebagai Penyakit .....	443
20.5	Metabolisme Glukosa: Studi Dinamika Insulin untuk Nornoglikemia .....	446
20.6	Kesimpulan .....	452
<b>Daftar Pustaka .....</b>	<b>454</b>	

**BAGIAN I**

**TEKNIK PEMODELAN DAN DESAIN SISTEM PENDUKUNG KEPUTUSAN**

**BAB 1**

**KEMAJUAN DALAM PENGAMBILAN KEPUTUSAN YANG CERDAS**

Dalam bab ini, ikhtisar teknik dan aplikasi yang terkait dengan pengambilan keputusan cerdas disajikan. Proses pengambilan keputusan dan elemen kualitas keputusan dibahas. Sebuah taksonomi sistem pendukung keputusan dijelaskan. Teknik yang berasal dari kecerdasan buatan yang berguna untuk merancang dan mengembangkan sistem pendukung keputusan cerdas dijelaskan. Penerapan sistem pendukung keputusan cerdas ke berbagai domain disorot. Ringkasan dari kesimpulan disajikan di akhir bab ini.

### **1.1 PENDAHULUAN**

Sistem pendukung keputusan, secara umum, adalah kelas khusus dari sistem informasi terkomputerisasi yang mendukung kegiatan pengambilan keputusan di berbagai domain, mis. pertanian, bioteknologi, keuangan, perbankan, manufaktur, kesehatan, pendidikan, dan pemerintah. Deskripsi singkat tentang sistem pendukung keputusan disediakan dalam [pp.25, 1], seperti dikutip:

“Sistem pendukung keputusan adalah teknologi yang membantu mendapatkan pengetahuan yang tepat kepada pengambil keputusan yang tepat pada waktu yang tepat dalam representasi yang tepat dengan biaya yang tepat.”

Memang, kita menghadapi berbagai tugas pengambilan keputusan dalam kehidupan kita sehari-hari. Kita disajikan dengan banyak informasi dan/atau data dalam aktivitas sehari-hari, dan kita, baik secara sadar maupun tidak sadar, harus mengambil keputusan berdasarkan informasi dan/atau data yang diterima. Situasi ini diperburuk oleh world-wide-web sebagai sumber informasi dan berbagi pengetahuan dan penggunaan kembali. Meskipun ada banyak informasi dan/atau sumber data yang heterogen di world-wide-web, mulai dari dokumen teks hingga gambar multi-media; dari file audio ke aliran video, informasi dan/atau data sering kali kompleks dan multi-segi, dan terdiri dari berbagai jenis gangguan. Dengan demikian, kita harus membuat keputusan tentang kemungkinan tindakan terbaik (atau serangkaian tindakan yang dioptimalkan) dari alternatif yang tersedia. Namun, membuat keputusan yang baik dan akurat adalah tugas yang menantang. Hal ini karena konflik dan pengorbanan sering terjadi karena berbagai tujuan dan sasaran yang harus dipenuhi secara bersamaan oleh pembuat keputusan. Oleh karena itu, bermanfaat jika beberapa sistem pendukung keputusan yang cerdas dapat digunakan untuk membantu kita dalam membuat keputusan yang cepat dan tepat.

Menurut [2], konsep pendukung keputusan berasal dari dua bidang penelitian utama: (i) studi teoritis pengambilan keputusan organisasi di Institut Teknologi Carnegie pada akhir 1950-an/awal 1960-an; (ii) pengembangan teknis sistem komputer interaktif terutama di Massachusetts Institute of Technology pada 1960-an. Namun demikian, munculnya teknologi

digital dan teknik pemrosesan informasi untuk mendukung pemecahan masalah dan tugas pengambilan keputusan lebih lanjut mengakibatkan munculnya sistem pendukung keputusan cerdas. Memang, sistem pendukung keputusan telah berkembang secara substansial dan banyak teknik baru seperti gudang data, OLAP, penambangan data dan teknologi web telah dimasukkan ke dalam desain dan pengembangan sistem pendukung keputusan sejak awal 1970-an [3]. Seperti dijelaskan dalam [4], sistem teknologi informasi berdasarkan perangkat lunak spreadsheet telah digunakan untuk mendukung kegiatan pengambilan keputusan pada 1970-an. Pada 1980-an, model optimasi dari riset operasi dan riset ilmu manajemen telah dimasukkan untuk merancang sistem pendukung keputusan. Pada 1990-an, teknik dari kecerdasan buatan dan statistik telah lebih meningkatkan desain dan penerapan sistem pendukung keputusan.

Lalu apa yang membentuk sistem pendukung keputusan cerdas yang sukses? Enam atribut yang mewakili karakteristik tingkat tinggi dari sistem pendukung keputusan yang sukses dibahas dalam [5]. Mereka adalah (i) interaktivitas: sistem pendukung keputusan bekerja dengan baik dengan orang lain, yang mencakup database lain serta pengguna manusia; (ii) deteksi peristiwa dan perubahan: sistem pendukung keputusan memantau dan mengenali perubahan dan peristiwa penting; (iii) bantuan representasi: sistem pendukung keputusan mewakili dan mengomunikasikan informasi secara efektif dengan cara yang berpusat pada manusia; (iv) deteksi dan pemulihan kesalahan: sistem pendukung keputusan memeriksa kesalahan yang dibuat oleh pengguna, dan, pada saat yang sama, mengetahui keterbatasannya sendiri; (v) informasi dari data: sistem pendukung keputusan menggunakan teknik cerdas untuk mengekstrak informasi yang berguna dari data yang banyak dan untuk menangani outlier serta ambiguitas lain dalam sumber data; (vi) kemampuan prediktif: sistem pendukung keputusan menilai efek perubahan dan memprediksi dampak pada kinerja masa depan, baik dalam jangka pendek (prediksi taktis) atau jangka panjang (prediksi strategis).

Organisasi bab ini adalah sebagai berikut. Pada bagian dua, beberapa aspek umum yang berkaitan dengan proses pengambilan keputusan, elemen yang berguna untuk mengukur kualitas keputusan, dan taksonomi sistem pendukung keputusan dijelaskan. Pada bagian tiga, sejumlah teknik berbasis kecerdasan buatan yang berguna untuk desain dan pengembangan sistem pendukung keputusan cerdas disajikan. Penerapan sistem pendukung keputusan cerdas ini ke berbagai domain yang berbeda dibahas di bagian empat. Ringkasan dari catatan penutup diberikan di bagian lima.

## 1.2 ASPEK UMUM PENGAMBILAN KEPUTUSAN

Pada bagian ini diuraikan aspek-aspek umum yang berkaitan dengan proses pengambilan keputusan, kualitas keputusan, dan jenis-jenis sistem pendukung keputusan, sebagai berikut.

### Proses Pengambilan Keputusan

Selama bertahun-tahun, sejumlah paradigma untuk menggambarkan proses pengambilan keputusan manusia telah diusulkan. Diantaranya, paradigma yang dikemukakan oleh Simon (peraih Nobel) [6] diuji dan digunakan secara luas [7, 8]. Ini terdiri dari tiga fase, yaitu, kecerdasan, desain, dan pilihan. Kemudian, fase implementasi lain untuk paradigma Simon ditambahkan, seperti yang ditunjukkan pada Gambar 1 [9, 10]. Pada fase intelijen,

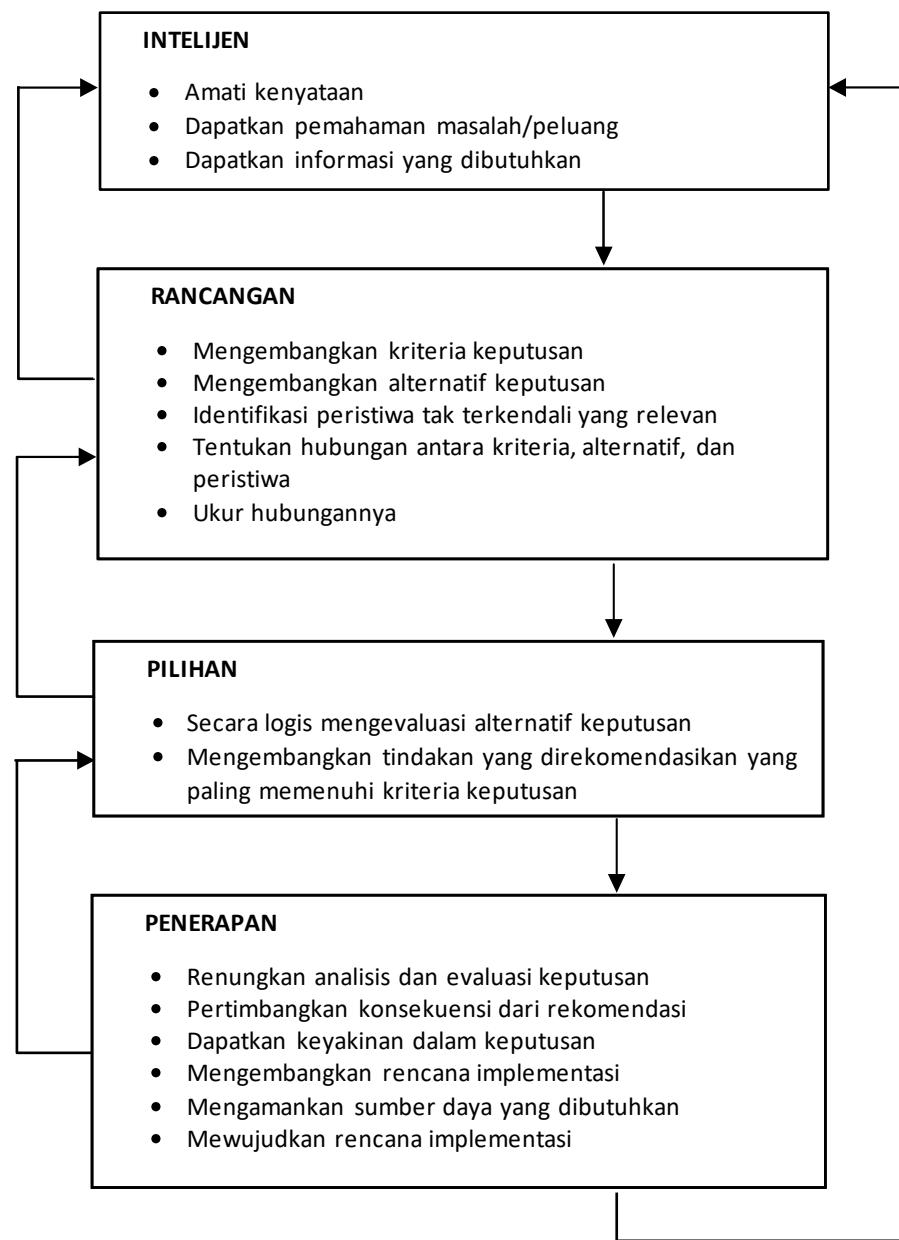
pembuat keputusan mengamati realitas, dan menetapkan pemahaman tentang domain masalah dan peluang yang terkait. Informasi yang diperlukan berkaitan dengan semua aspek masalah yang diteliti juga dikumpulkan. Pada tahap desain, kriteria keputusan dan alternatif dikembangkan dengan menggunakan model tertentu, dengan peristiwa tak terkendali yang relevan diidentifikasi. Hubungan antara keputusan, alternatif, dan peristiwa harus ditentukan dan diukur dengan jelas. Hal ini memungkinkan alternatif keputusan untuk dievaluasi secara logis pada fase berikutnya, yaitu fase pilihan. Selain itu, tindakan yang paling memenuhi kriteria keputusan dirumuskan. Pada tahap implementasi, pengambil keputusan perlu mempertimbangkan kembali analisis dan evaluasi keputusan, serta mempertimbangkan konsekuensi dari rekomendasi. Rencana implementasi kemudian dikembangkan, dengan sumber daya yang diperlukan diamankan. Sekarang siap untuk menerapkan rencana implementasi ke dalam tindakan.

Perhatikan bahwa proses pengambilan keputusan adalah proses yang berkelanjutan dalam lingkaran umpan balik. Ini berarti bahwa pengambil keputusan harus terus-menerus mempertimbangkan kembali dan mengevaluasi kembali realitas dan perubahan dalam domain masalah. Setelah memperoleh informasi baru, perlu untuk mengunjungi kembali satu atau lebih, jika tidak semua, dari empat fase yang terlibat. Proses umpan balik memungkinkan perubahan dan perbaikan pada keputusan sebelumnya untuk diselesaikan, sehingga dapat memenuhi kebutuhan dan tuntutan domain masalah saat ini.

### **Kualitas Keputusan**

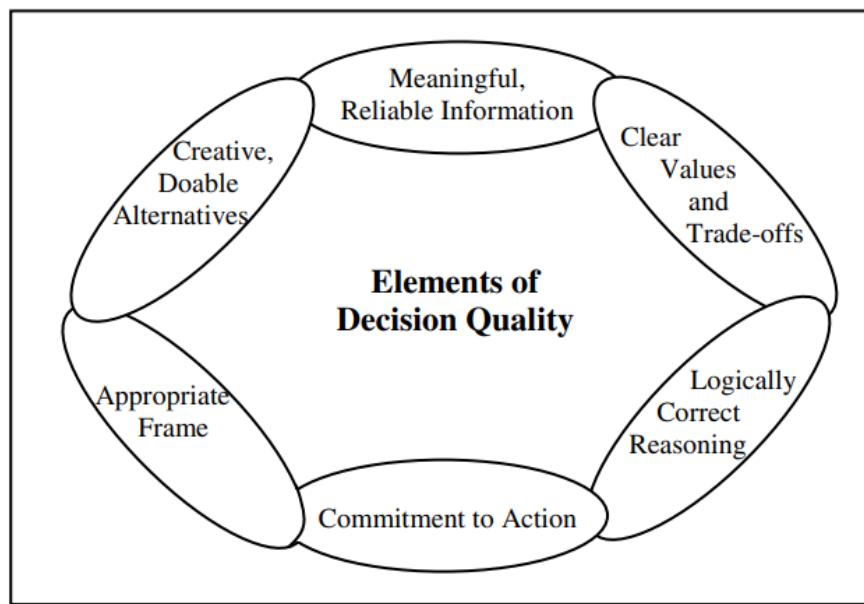
Sesuai dengan [11], jenis keputusan secara garis besar dapat dikategorikan menjadi dua, yaitu keputusan operasional dan keputusan strategis. Keputusan operasional berkaitan dengan pengelolaan operasi, yang berfokus pada hasil dalam jangka pendek. Hasil dari keputusan operasional, yaitu apakah keputusan itu baik atau tidak, diketahui dengan cukup cepat. Proses pengambilan keputusan juga memperhatikan detail dan biasanya mengabaikan ketidakpastian dan menghindari alternatif baru [11].

Di sisi lain, keputusan strategis melibatkan prediksi yang berkaitan dengan isu-isu penting secara jangka panjang. Proses pengambilan keputusan mempertimbangkan ketidakpastian, dan memilih di antara alternatif yang berbeda secara signifikan. Sementara kualitas keputusan operasional dapat dinilai dari hasil jangka pendek, keputusan strategis biasanya melibatkan hasil jauh ke masa depan.



**Gambar 1.1** Proses pengambilan keputusan (Sumber: [9])

Dengan kata lain, sulit untuk menilai kualitas keputusan strategis berdasarkan hasil, yang melibatkan ketidakpastian dalam cakrawala waktu yang lama. Dengan demikian, seperangkat ukuran kualitas keputusan diperkenalkan di [11], seperti yang ditunjukkan pada Gambar 1.2. Ada enam elemen kualitas keputusan, yaitu, (i) kerangka yang sesuai; (ii) alternatif yang kreatif dan dapat dilakukan; (iii) informasi yang bermakna dan andal; (iv) nilai dan pertukaran yang jelas; (v) penalaran yang benar secara logis; dan (vi) komitmen untuk bertindak. Setiap elemen dari kualitas keputusan dibahas sebagai berikut, dan rinciannya tersedia di [11].



**Gambar 1.2** Elemen kualitas keputusan (sumber: [11])

- (i) Kerangka yang tepat: Karena keputusan strategis biasanya menghasilkan konsekuensi jangka panjang yang besar, tim pembuat keputusan dari latar belakang yang berbeda diperlukan dalam proses pengambilan keputusan. Akibatnya, kerangka yang tepat harus ditetapkan, dengan tujuan yang jelas, perspektif yang sadar, dan ruang lingkup yang ditentukan.
- (ii) Alternatif yang kreatif dan dapat dilakukan: Karena sifat ketidakpastian, membuat keputusan strategis perlu mempertimbangkan banyak alternatif. Oleh karena itu, sangat penting untuk mengeksplorasi semua kemungkinan dan untuk memahami sepenuhnya berbagai alternatif yang tersedia sebelum membuat keputusan. Kualitas dicapai ketika sejumlah alternatif inovatif dan dapat direalisasikan yang berbeda ditetapkan untuk dipertimbangkan.
- (iii) Informasi yang bermakna dan andal: Kualitas informasi sangat penting dalam mempengaruhi keputusan strategis. Tim pengambil keputusan harus menyusun informasi yang benar dan eksplisit berdasarkan fakta yang sesuai. Ketidakpastian yang terlibat kemudian dapat dinyatakan dalam bentuk penilaian probabilistik.
- (iv) Nilai dan trade-off yang jelas: Keputusan strategis perlu mempertimbangkan berbagai trade-off, yang mencakup trade-off antara pengembalian sekarang dan masa depan, trade-off antara risiko dan kepastian, serta trade-off di antara kriteria yang berbeda. Dengan demikian, pernyataan eksplisit tentang nilai-nilai fundamental perlu ditetapkan.
- (v) Penalaran yang benar secara logis: Karena keputusan strategis bersifat kompleks, konsekuensi dari setiap alternatif pada ukuran nilai harus dievaluasi secara komprehensif. Dalam hal ini, pilihan kerangka, alternatif, informasi, dan nilai yang jelas diperlukan agar penalaran logis dapat dilakukan.

- (vi) Komitmen untuk bertindak: Dalam setiap proses pengambilan keputusan, komitmen penuh untuk menerapkan rencana tindakan merupakan faktor penting untuk memastikan keberhasilan. Tanpa komitmen dari semua pihak yang terlibat, tidak mungkin mendapatkan hasil yang berguna dan bermanfaat, bahkan dengan rencana aksi yang paling canggih dan komprehensif di tangan.

### **Taksonomi Sistem Pendukung Keputusan**

Dalam [12, 13] lima jenis sistem pendukung keputusan yang berbeda, yaitu, komunikasi-driven, data-driven, dokumen-driven, pengetahuan-driven, dan model-driven, diusulkan. Uraian singkat masing-masing jenis sistem pendukung keputusan adalah sebagai berikut.

- (i) Sistem pendukung keputusan yang digerakkan oleh komunikasi: kelompok sasaran dari sistem pendukung keputusan ini adalah tim internal, yang mencakup mitra, dalam suatu organisasi untuk membangun kolaborasi yang efisien, mis. pertemuan yang sukses. Web atau server klien adalah teknologi paling umum yang digunakan untuk menyebarkan sistem pendukung keputusan ini.
- (ii) sistem pendukung keputusan berbasis data: sistem ini berguna untuk menanyakan database atau gudang data untuk mencari jawaban spesifik untuk tujuan tertentu. Mereka dapat digunakan menggunakan sistem mainframe, tautan klien/server, atau melalui web.
- (iii) sistem pendukung keputusan berbasis dokumen: sistem ini digunakan untuk mencari halaman web dan menemukan dokumen pada sekumpulan kata kunci atau istilah pencarian tertentu. Mereka dapat diimplementasikan melalui web atau sistem klien/server;
- (iv) sistem pendukung keputusan berbasis pengetahuan: ini mencakup berbagai paradigma dalam kecerdasan buatan untuk membantu membuat keputusan dari domain yang berbeda. Berbagai teknik penambangan data, yang meliputi jaringan saraf, logika fuzzy, algoritma evolusioner, penalaran berbasis kasus, dapat digunakan untuk mengembangkan sistem ini guna menyediakan keahlian dan informasi khusus untuk melakukan masalah pengambilan keputusan tertentu. Mereka dapat digunakan menggunakan sistem klien/server, web, atau perangkat lunak yang berjalan pada komputer yang berdiri sendiri;
- (v) sistem pendukung keputusan berbasis model: ini adalah sistem kompleks yang dikembangkan berdasarkan beberapa model (misalnya model matematis dan analitis) untuk membantu menganalisis keputusan atau memilih di antara alternatif yang berbeda. Mereka dapat digunakan melalui perangkat lunak/perangkat keras di komputer yang berdiri sendiri, sistem klien/server, atau web.

### **1.3 TEKNIK UNTUK PENGAMBILAN KEPUTUSAN YANG CERDAS**

Jenis sistem pendukung keputusan yang tercakup dalam buku ini terutama terdiri dari sistem berbasis pengetahuan dan sistem berbasis model. Dengan demikian, sejumlah paradigma yang berguna di bawah payung kecerdasan buatan yang telah banyak digunakan untuk merancang dan mengembangkan sistem pendukung keputusan cerdas dijelaskan di

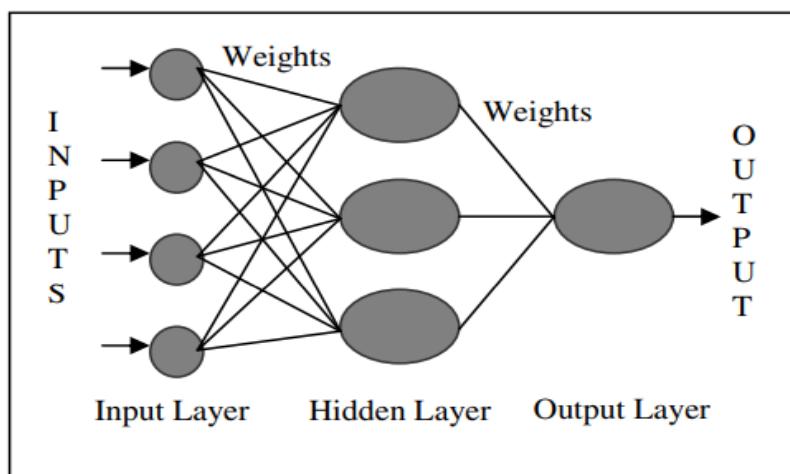
bagian ini. Ini termasuk jaringan saraf tiruan, komputasi evolusioner, sistem fuzzy, penalaran berbasis kasus, dan sistem berbasis agen.

### **Jaringan Syaraf Tiruan**

Jaringan saraf tiruan, cabang dari kecerdasan buatan, berasal dari penelitian dalam pemodelan sistem saraf di otak manusia. McCulloch dan Pitts [14] adalah pelopor yang memprakarsai pemodelan matematika neuron buatan. Jaringan syaraf tiruan sekarang muncul dalam bentuk model komputasi paralel masif dengan sejumlah besar elemen pemrosesan sederhana yang saling berhubungan (dikenal sebagai neuron) yang mampu menyesuaikan diri dengan sampel data. Secara umum, jaringan saraf tiruan dikategorikan menjadi dua: jaringan terawasi dan tidak terawasi. Jaringan yang diawasi menerima dan menggunakan sampel data input dan sampel data output target untuk pembelajaran. Sampel data target bertindak sebagai sinyal pengawasan untuk mengoreksi prediksi jaringan selama siklus pelatihan. Di antara jaringan terawasi yang populer termasuk jaringan perceptron multi-layer [15] dan jaringan fungsi basis radial [16]. Di sisi lain, jaringan tanpa pengawasan hanya menerima dan menggunakan sampel data input tanpa sinyal pengawasan untuk pembelajaran. Peta yang mengatur diri sendiri [17] dan model teori resonansi adaptif [18] adalah di antara beberapa jaringan tanpa pengawasan yang populer. Dua contoh, satu jaringan yang diawasi dan jaringan yang tidak diawasi, dijelaskan sebagai berikut.

#### **Jaringan Perceptron Multi-layer**

Jaringan multi-layer perceptron adalah jaringan feedforward. Strukturnya terdiri dari sekumpulan neuron yang tersusun menjadi dua atau lebih lapisan. Ini memiliki lapisan input, satu atau beberapa lapisan tersembunyi, dan lapisan output. Lapisan input adalah lapisan hipotetis di mana output dari neuron sama dengan inputnya. Dengan kata lain, lapisan input digunakan untuk menyebarkan input yang diterimanya dari lingkungan ke lapisan tersembunyi tanpa ada pemrosesan informasi yang dilakukan pada input. Biasanya ada satu atau lebih lapisan tersembunyi yang diapit di antara lapisan input dan output. Lapisan keluaran menghasilkan hasil kembali ke lingkungan. Perceptron multi-layer adalah jaringan feedforward karena informasi mengalir dalam satu arah hanya dalam jaringan, yaitu, input disajikan pada lapisan input, dan kemudian disebarluaskan melalui lapisan tersembunyi, dan output dihasilkan pada lapisan output. . Gambar 1.3 menggambarkan contoh struktur jaringan perceptron multi-layer dengan tiga lapisan.



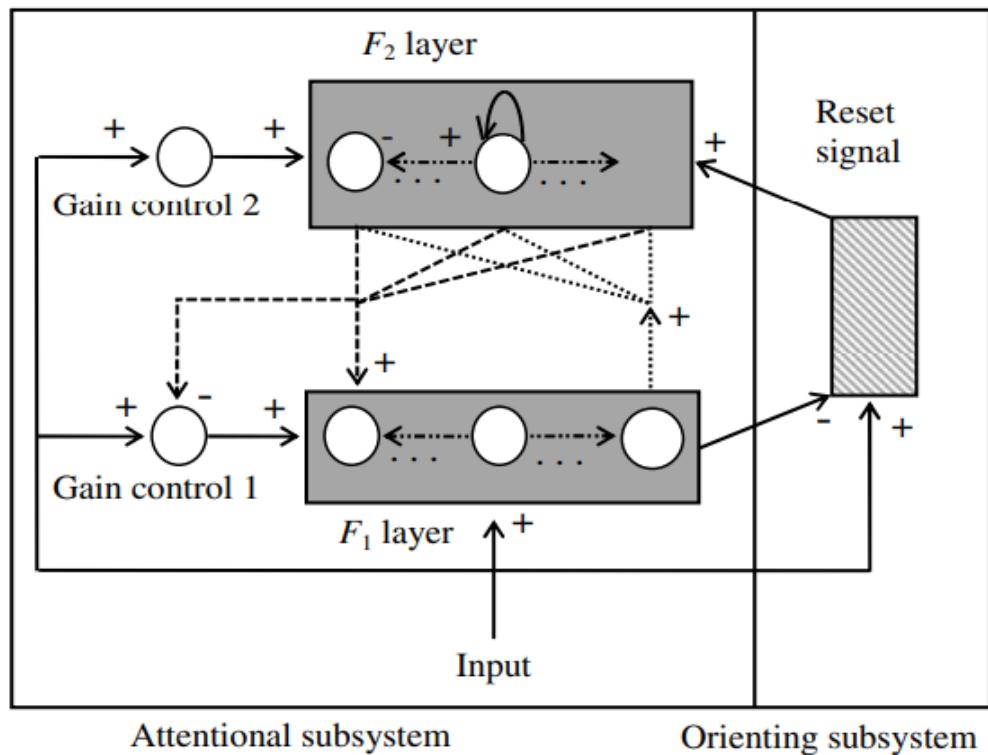
**Gambar 1.3** Contoh perceptron multi-layer

Setiap lingkaran pada Gambar 1.3 mewakili neuron. Jaringan ini disebut sebagai jaringan 4-3-1, karena ada empat neuron input di lapisan input, tiga neuron tersembunyi di lapisan tersembunyi, dan satu neuron output di lapisan output. Hubungan antara neuron dalam dua lapisan berturut-turut dikenal sebagai bobot. Setiap neuron menerima input dari lapisan sebelumnya dan, melalui bobot, menghasilkan output ke lapisan berikutnya. Biasanya, bobot dalam jaringan saraf tiruan mewakili pengetahuan yang dipelajari dari sampel data input, dan menentukan perilaku jaringan. Jaringan memodifikasi bobotnya menggunakan beberapa algoritma pembelajaran selama fase pelatihan.

Algoritma backpropagation adalah algoritma pelatihan yang paling populer untuk multi-layer perceptron [15]. Ini adalah algoritma pembelajaran berdasarkan aturan koreksi kesalahan, dan kesalahan kuadrat rata-rata biasanya digunakan sebagai ukuran kesalahan. Pembelajaran menggunakan algoritma back-propagation terdiri dari dua fase. Dalam lintasan maju, input disebarluaskan ke depan melalui bobot untuk mencapai lapisan keluaran dan menghasilkan keluaran yang diprediksi. Kesalahan antara output yang diprediksi dan output target dihitung. Dalam lintasan mundur, kesalahan pada lapisan keluaran dipropagasi mundur ke lapisan masukan, dengan turunan parsial dari kesalahan total sehubungan dengan bobot di setiap lapisan muncul di sepanjang jalan [19]. Kesalahan tersebut kemudian digunakan untuk memperbarui bobot. Alasannya adalah untuk meminimalkan ukuran kesalahan total melalui proses pembelajaran yang berulang. Proses pembelajaran berhenti ketika kriteria berhenti tercapai, mis. ukuran kesalahan total lebih rendah dari ambang batas, atau jumlah periode pembelajaran yang telah ditentukan sebelumnya tercapai.

### **Teori Resonansi Adaptif**

Teori resonansi adaptif, yang berasal dari penelitian Grossberg [20-22], mencoba untuk mengatasi masalah yang berkaitan dengan proses kognitif manusia, dan merancang metode komputasi yang meniru aktivitas belajar otak. Sejak awal pertama dari jaringan yang dikenal sebagai ART1 [18], sejumlah arsitektur, baik model tak terawasi [23-25] dan terawasi [26, 27], telah dikembangkan. Tidak seperti jaringan saraf tiruan lainnya, model teori resonansi adaptif memiliki struktur yang berkembang, yaitu jumlah neuron dapat ditingkatkan bila diperlukan. Gambar 1.4 menunjukkan arsitektur generik dari jaringan teori resonansi adaptif tanpa pengawasan.

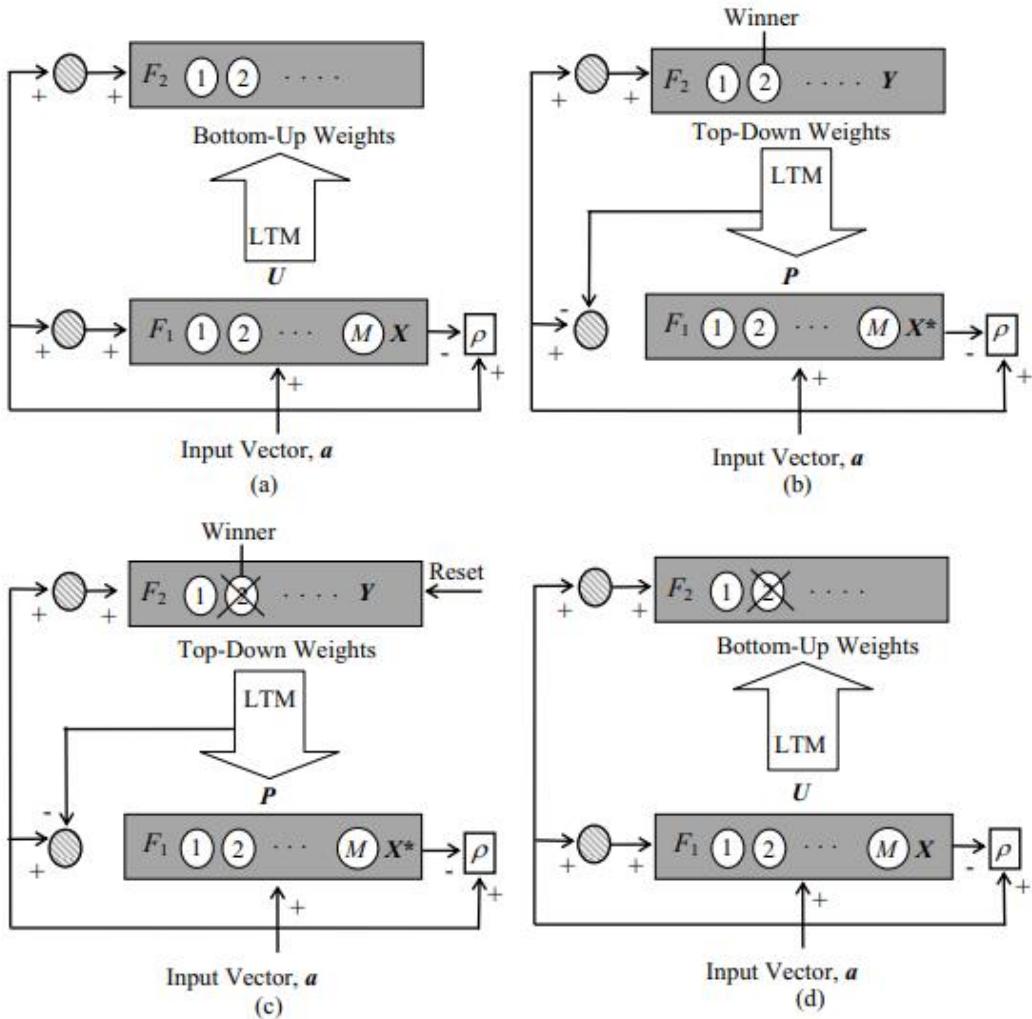


**Gambar 1.4** Arsitektur generik dari jaringan teori resonansi adaptif tanpa pengawasan.

Tanda positif (+) menunjukkan hubungan rangsang, sedangkan tanda negatif (-) menunjukkan hubungan penghambatan.

Jaringan terdiri dari dua lapisan neuron yang memainkan peran berbeda pada waktu yang berbeda: *F<sub>1</sub>* - lapisan input/perbandingan; dan *F<sub>2</sub>* - lapisan keluaran/pengenalan. Kedua lapisan ini saling terkait oleh hubungan umpan-maju dan umpan balik (bobot) dua arah, yaitu bobot umpan maju atau bottom-up dari *F<sub>1</sub>* ke *F<sub>2</sub>*, dan bobot umpan balik atau top-down dari *F<sub>2</sub>* ke *F<sub>1</sub>*. Selain itu, beberapa sinyal logika kontrol, mis. kontrol gain dan sirkuit reset, hadir. Perhatikan bahwa ada tiga saluran input yang mungkin untuk *F<sub>1</sub>* dan *F<sub>2</sub>*. Pola input, kontrol gain 1, dan bobot top-down dikaitkan dengan *F<sub>1</sub>*; sedangkan bobot bottom-up, kontrol gain 2, dan sinyal reset dikaitkan dengan *F<sub>2</sub>*. Menurut [18], *F<sub>1</sub>* dan *F<sub>2</sub>* mematuhi apa yang disebut aturan 2/3 (dua dari tiga), yaitu, neuron di *F<sub>1</sub>* dan *F<sub>2</sub>* menjadi aktif hanya jika setidaknya dua dari tiga sumber inputnya aktif. Deskripsi pengoperasian jaringan adalah sebagai berikut.

Gambar 1.5 menunjukkan siklus pencocokan pola yang khas dalam jaringan teori resonansi adaptif tanpa pengawasan. Pertama, vektor input, **a**, mendaftarkan dirinya sebagai pola aktivitas memori jangka pendek, **X**, melintasi lapisan *F<sub>1</sub>*. Hal ini menghasilkan pola keluaran, **U**, untuk ditransmisikan dari *F<sub>1</sub>* dan *F<sub>2</sub>* melalui bobot bottom-up, atau yang disebut jejak memori jangka panjang. Setiap node *F<sub>2</sub>* menerima pola **U** yang ditimbang oleh memori jangka panjang yang sesuai. Sebuah pola memori jangka pendek, **Y**, dibentuk di *F<sub>2</sub>* untuk menunjukkan respons terhadap stimulus yang masuk. Dengan dinamika persaingan internal penguatan diri dan penghambatan lateral (on-centre off-surround competition) [18], neuron yang memiliki aktivasi terbesar dipilih sebagai pemenang sementara semua neuron lainnya dimatikan (winner-take-all). Jadi, hanya satu komponen **Y** yang sesuai dengan neuron pemenang yang bukan nol.



**Gambar 1.5** Skenario pencocokan pola tipikal dalam jaringan teori resonansi adaptif tanpa pengawasan. (a) Vektor input menuju  $F_1$  dan menginduksi pola memori jangka pendek (STM) yang menghasilkan stimulus untuk ditransmisikan ke  $F_2$  melalui memori jangka panjang (LTM) dari bawah ke atas. (b) Berdasarkan tanggapan, neuron pemenang di  $F_2$  dipilih, dan prototipe dikirim ke  $F_1$  melalui LTM top-down. (c) Menanggapi ketidakcocokan antara vektor input dan pola STM  $F_1$  baru ( $X^*$ ), sinyal reset dimulai untuk menghambat neuron pemenang. (d) Vektor input diterapkan kembali ke  $F_1$  untuk memulai pencarian baru.

Neuron pemenang mengirimkan vektor prototipenya,  $P$ , ke  $F_1$  melalui bobot top-down. Pola memori jangka pendek baru,  $X^*$ , terbentuk di seluruh  $F_1$ . Pola  $X^*$  dan input  $a$  dibandingkan pada  $F_1$ . Uji kewaspadaan dilakukan di mana tingkat pencocokan  $X^*$  dengan  $a$  diuji terhadap ambang batas yang disebut parameter kewaspadaan,  $\rho$ , pada rangkaian reset. Jika tes kewaspadaan dipenuhi, jaringan memasuki keadaan resonansi untuk memungkinkan memori jangka panjang dari neuron pemenang untuk belajar atau beradaptasi dengan informasi baru yang diwakili oleh memori jangka pendek di  $F_1$ . Fakta bahwa belajar hanya terjadi dalam keadaan resonansi menunjukkan nama "teori resonansi adaptif" [18].

Di sisi lain, jika uji kewaspadaan gagal, siklus pencarian dipicu untuk menemukan simpul  $F_2$  prototipikal yang lebih cocok. Sinyal reset dikirim oleh sirkuit reset ke lapisan  $F_2$ .

Sinyal reset ini memiliki efek dua kali lipat: untuk menghambat neuron  $F_2$  yang menang selama sisa siklus pencocokan pola; dan untuk menyegarkan aktivitas apapun di jaringan sehingga input  $a$  dapat dipulihkan di  $F_1$  untuk memulai siklus pencocokan pola.

Pencarian berlanjut sampai simpul  $F_2$  dapat memenuhi uji kewaspadaan. Jika tidak ada simpul seperti itu, simpul baru dibuat di  $F_2$  untuk mengkodekan pola input. Oleh karena itu,  $F_2$  adalah lapisan dinamis di mana jumlah node dapat ditingkatkan selama pembelajaran untuk menyerap informasi baru secara mandiri.

### **Komputasi Evolusioner**

Komputasi evolusioner disebut sebagai model komputasi yang berguna untuk menangani tugas pengambilan keputusan berbasis optimasi. Dalam memecahkan kompleks, masalah dunia nyata, seseorang dapat menggunakan metode yang meniru afinitas dari alam. Dalam hal ini, model komputasi evolusioner yang terinspirasi secara biologis kohesif dengan gagasan merancang solusi yang mengeksplorasi beberapa aspek proses evolusi alami. Secara umum, ada lima jenis model komputasi evolusioner, yaitu, pemrograman evolusioner, strategi evolusi, pemrograman genetik, dan sistem pengklasifikasi pembelajaran, dan algoritma genetika.

Diperkenalkan oleh Fogel, Owens, dan Walsh [28], pemrograman evolusioner mensimulasikan perilaku cerdas melalui mesin keadaan terbatas. Dalam hal ini, solusi kandidat untuk suatu masalah dianggap sebagai populasi mesin keadaan hingga. Solusi baru (keturunan) dihasilkan dengan memutasikan kandidat solusi (orang tua). Semua kandidat solusi kemudian dinilai dengan fungsi fitness. Strategi evolusioner [29] pertama kali dikembangkan untuk mengoptimalkan parameter perangkat aeroteknologi. Metode ini didasarkan pada konsep evolusi evolusi. Setiap solusi kandidat dalam populasi dibentuk oleh blok bangunan genetik dan seperangkat parameter strategi yang memodelkan perilaku solusi kandidat dalam lingkungannya. Baik blok bangunan genetik dan parameter strategi berpartisipasi dalam evolusi.

Evolusi karakteristik genetik diatur oleh parameter strategi yang juga diadaptasi dari evolusi. Dirancang oleh Koza [30], pemrograman genetik bertujuan untuk membuat komputer memecahkan masalah tanpa diprogram secara eksplisit untuk melakukannya. Individu direpresentasikan sebagai program yang dapat dieksekusi (mis., Pohon). Operator genetik diterapkan untuk menghasilkan individu baru. Sistem pengklasifikasi pembelajaran [31] menggunakan modul penemuan aturan evolusioner untuk menangani tugas pembelajaran mesin. Pengetahuan dikodekan menggunakan kumpulan aturan produksi. Setiap aturan produksi dianggap sebagai pengklasifikasi. Aturan diperbarui menurut beberapa prosedur evolusioner tertentu.

Dikembangkan oleh Holland [32, 33], algoritma genetika adalah model komputasi evolusioner yang paling populer dan banyak digunakan. Algoritma genetika pada dasarnya adalah kelas strategi pencarian berbasis populasi yang memanfaatkan pendekatan berulang untuk melakukan pencarian global pada ruang solusi dari masalah yang diberikan. Gambar 1.6 merangkum langkah-langkah yang terlibat dalam algoritma genetika yang khas. Pada ketersediaan populasi individu, seleksi, yang didasarkan pada prinsip survival of the fittest mengikuti adanya tekanan lingkungan, dilakukan untuk memilih individu yang lebih cocok

dengan lingkungan. Mengingat fungsi kebugaran, satu set solusi kandidat secara acak. Kegunaan solusi kandidat dinilai menggunakan fungsi fitness.

Berdasarkan nilai fitness tersebut, solusi kandidat yang lebih fit memiliki peluang yang lebih besar untuk terpilih pada generasi berikutnya melalui beberapa operator genetik, yaitu rekombinasi (crossover) dan mutasi. Di satu sisi, rekombinasi diterapkan pada dua atau lebih solusi kandidat induk, dan satu atau lebih solusi kandidat baru (keturunan) dihasilkan/dihasilkan. Di sisi lain, mutasi diterapkan pada satu solusi kandidat induk, dan solusi kandidat baru dihasilkan. Solusi kandidat baru bersaing di antara mereka sendiri, berdasarkan nilai-nilai kebugaran, untuk mendapatkan tempat di generasi berikutnya. Meskipun solusi kandidat dengan nilai fitness yang lebih tinggi adalah menguntungkan, dalam beberapa skema seleksi, misalnya seleksi peringkat [35], solusi kandidat dengan nilai fitness yang relatif rendah dimasukkan dalam generasi berikutnya untuk menjaga keragaman populasi. Proses seleksi, rekombinasi, dan mutasi diulangi dari satu generasi populasi ke generasi lain sampai kriteria terminasi terpenuhi, misalnya, solusi kandidat yang mampu memenuhi beberapa persyaratan yang ditentukan sebelumnya diperoleh atau yang telah ditentukan sebelumnya. jumlah generasi tercapai.

1. Biarkan generasi sekarang,  $k=0$ .
2. Menghasilkan populasi awal individu.
3. Ulangi
  - (a) Mengevaluasi kebugaran setiap individu dalam populasi.
  - (b) Pilih orang tua dari populasi sesuai dengan nilai fitness mereka.
  - (c) Terapkan crossover ke orang tua yang dipilih.
  - (d) Terapkan mutasi pada individu baru dari (c).
  - (e) Menggantikan induk dengan keturunannya.
  - (f) Naikkan  $k$  sebanyak 1.
4. Sampai kriteria terminasi terpenuhi.

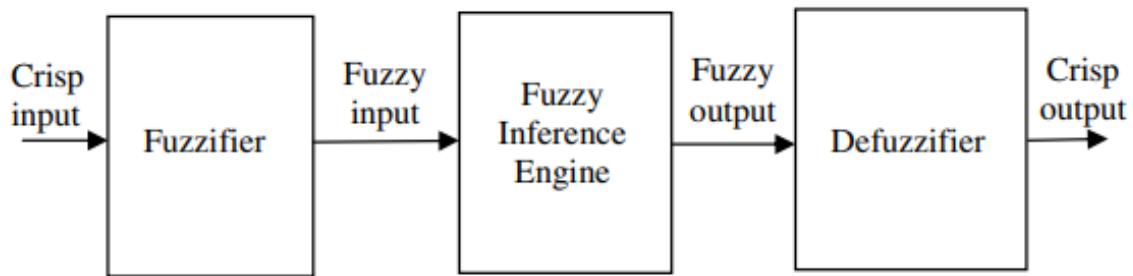
**Gambar 1.6** Sebuah algoritma genetika yang khas

### Sistem Fuzzy

Logika fuzzy diperkenalkan oleh Zadeh pada tahun 1965 [35]. Ini adalah bentuk logika multi-nilai yang berasal dari teori himpunan fuzzy untuk menangani penalaran manusia dan proses membuat inferensi dan keputusan yang diturunkan berdasarkan variabel linguistik manusia di dunia nyata. Teori himpunan fuzzy bekerja dengan data dan/atau informasi yang tidak pasti dan tidak tepat. Memang, himpunan fuzzy menggeneralisasi konsep himpunan konvensional dengan memperluas derajat keanggotaan menjadi nilai antara 0 dan 1. Fitur "ketidakjelasan" seperti itu terjadi di banyak situasi dunia nyata, di mana sulit untuk memutuskan apakah sesuatu dapat dikategorikan secara tepat ke dalam kelas tertentu atau tidak.

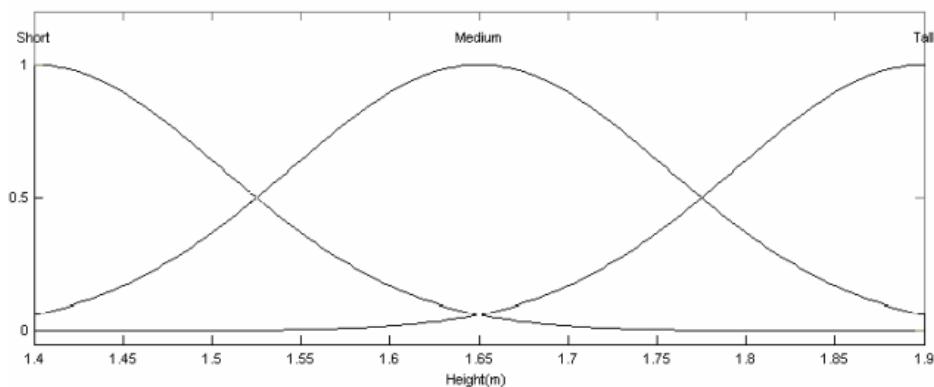
Sistem fuzzy, yang mengasimilasi konsep dari teori himpunan fuzzy dan logika fuzzy, menyediakan kerangka kerja untuk menangani pengetahuan akal sehat yang direpresentasikan dalam bentuk linguistik atau numerik yang tidak pasti. Ada dua karakteristik yang berguna dari sistem fuzzy, yaitu mereka cocok untuk penalaran yang tidak pasti atau

perkiraan, terutama untuk sistem di mana model matematika sulit untuk diturunkan; mereka memungkinkan keputusan untuk disimpulkan menggunakan informasi yang tidak lengkap atau tidak pasti dengan variabel linguistik manusia yang mudah dipahami. Gambar 7 menggambarkan sistem inferensi fuzzy yang terdiri dari tiga prosedur, yaitu fuzzifikasi, penalaran atau inferensi, dan defuzzifikasi, sebagai berikut.



**Gambar 1.7** Sistem inferensi fuzzy tipikal

Fuzzifikasi, secara umum, adalah proses mentransformasikan suatu masukan tegas menjadi himpunan nilai keanggotaan fuzzy. Misalkan  $x = \text{'Tinggi'}$  adalah input, dan tiga fungsi keanggotaan fuzzy, seperti yang ditunjukkan pada Gambar 8, digunakan untuk mewakili input  $x$  dalam istilah linguistik fuzzy, yaitu, seperti 'pendek', 'sedang' dan 'tinggi'. Oleh karena itu, nilai crisp  $x$  difuzzifikasi menjadi tiga nilai fuzzy yang menunjukkan derajat keanggotanya dalam himpunan fuzzy tertentu, yaitu  $\mu_{short}(x)$ ,  $\mu_{medium}(x)$ , dan  $\mu_{tall}(x)$ . Ini nilai keanggotaan fuzzy membentuk input fuzzy ke mesin inferensi. Selain fungsi keanggotaan Gaussian yang ditunjukkan pada Gambar 8, fungsi matematika lainnya dapat digunakan untuk mewakili himpunan fuzzy, mis. fungsi lonceng segitiga, trapesium, dan umum.



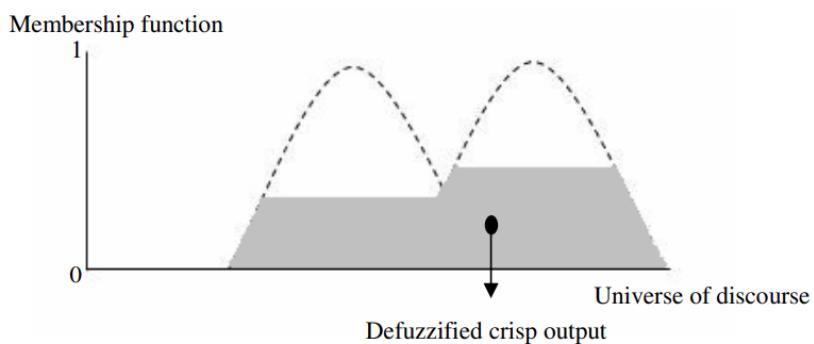
**Gambar 1.8** Fuzzifikasi untuk mendapatkan nilai keanggotaan fuzzy

Mesin inferensi fuzzy berisi serangkaian aturan fuzzy tipe IF-THEN untuk mengubah input fuzzy menjadi output fuzzy. Aturan fuzzy ini diminta dari pakar domain, dan digunakan untuk melakukan penalaran berdasarkan input fuzzy. Setiap aturan fuzzy terdiri dari bagian: antecedent dari bagian IF dan konsekuensi dari bagian THEN, sebagai berikut:

$$\underbrace{\text{IF } x_1 \text{ is } F_1 \text{ AND } x_2 \text{ is } F_2 \dots \text{ AND } x_n \text{ is } F_n}_{\text{Antecedent}} \text{ THEN } Y \text{ is } G \underbrace{\text{Consequent}}$$

di mana  $x_i$  dan  $Y$  adalah input dan output, dan,  $F_i$  dan  $G$  masing-masing adalah variabel linguistik input dan output atau himpunan fuzzy. Jika antecedent dari aturan yang diberikan memiliki lebih dari satu bagian, proses yang dikenal sebagai implikasi dilakukan. Operator fuzzy, seperti AND atau OR, dapat diterapkan untuk mendapatkan hasil yang representatif dari antecedent untuk aturan tersebut. Beberapa metode dapat digunakan untuk melakukan inferensi dengan operator AND atau OR. Sebagai contoh, sistem inferensi fuzzy tradisional Mamdani [36] memperlakukan AND dan OR sebagai fungsi "min" dan "maks". Hasil representatif kemudian diterapkan pada aturan konsekuensi, yaitu variabel linguistik keluaran yang diwakili oleh fungsi keanggotaan fuzzy. Proses implikasi ini diterapkan pada setiap aturan. Karena serangkaian aturan tersedia, proses agregasi untuk menggabungkan semua konsekuensi aturan diperlukan. Dengan agregasi, himpunan fuzzy yang mewakili output dari setiap aturan digabungkan menjadi satu himpunan fuzzy. Sekali lagi, beberapa operator agregat, mis. "maks" atau "jumlah", tersedia untuk melakukan agregasi.

Defuzzifikasi adalah kebalikan dari proses fuzzifikasi. Hal ini bertujuan untuk mendapatkan nilai representatif dari keluaran himpunan fuzzy, dan untuk menghasilkan keluaran yang tajam. Pusat gravitasi adalah salah satu operator defuzzifikasi yang paling banyak digunakan, yang mirip dengan nilai yang diharapkan dari distribusi probabilitas. Operator defuzzifikasi lainnya, mis. rata-rata maksimum, garis bagi luas, maksimum terkecil, dan maksimum terbesar, juga tersedia [36]. Contoh dari output tajam yang didefuzzifikasi ditunjukkan pada Gambar 9.



**Gambar 1.9** Defuzzifikasi untuk menghasilkan output yang tajam

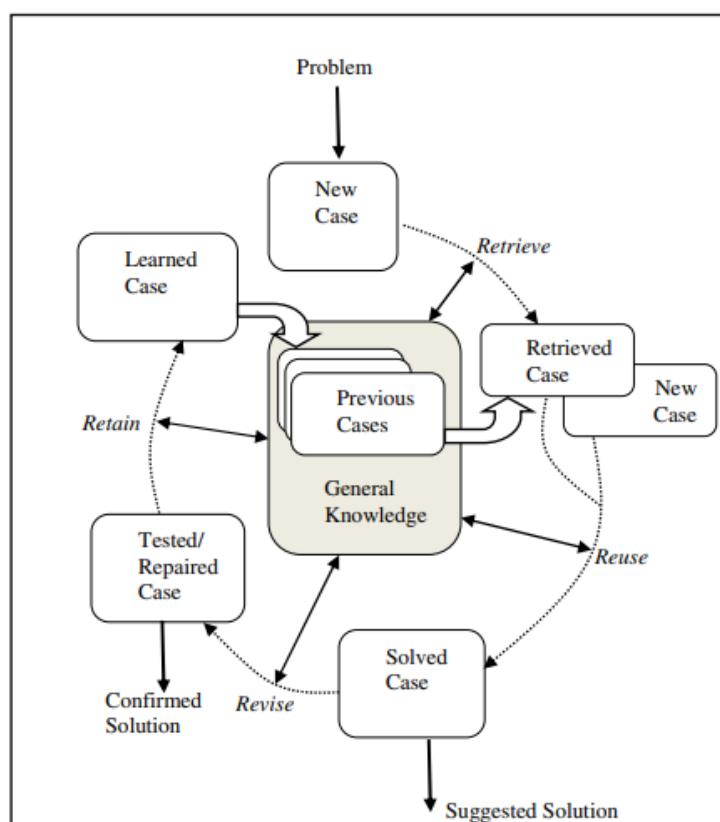
### Penalaran Berbasis Kasus

Penalaran berbasis kasus [37] adalah cabang dari kecerdasan buatan yang didirikan pada teori psikologis penalaran manusia. Penalaran berbasis kasus mengakui bahwa manusia sering memecahkan masalah baru dengan membandingkannya dengan masalah serupa yang telah mereka selesaikan di masa lalu [38]. Penalaran berbasis kasus dapat digunakan sebagai pendekatan pendukung keputusan di mana solusi serupa sebelumnya diambil dan dikonsultasikan untuk memecahkan masalah baru. Sistem penalaran berbasis kasus menarik basis pengetahuannya dari serangkaian kasus masalah dan solusi masa lalu yang cukup besar. Alasan penalaran berbasis kasus adalah bahwa situasi berulang dengan keteraturan. Apa yang dilakukan dalam satu situasi kemungkinan akan berlaku dalam situasi yang sama [39]. Seperti yang ditunjukkan pada Gambar 10, siklus penalaran berbasis kasus yang khas umumnya mencakup empat prosedur dasar, yaitu, pengambilan, penggunaan kembali, dan merevisi kasus, dan mempertahankan [37].

Sistem penalaran berbasis kasus terdiri dari pustaka kasus, yang merupakan gudang kasus historis. Pertimbangkan bahwa masalah baru (kasus baru) disajikan. Berdasarkan kasus baru, dilakukan penelusuran melalui perpustakaan kasus untuk menemukan kasus-kasus historis yang paling mirip dengan kasus baru. Perbandingan terdiri dari pencocokan atribut kasus baru dengan masing-masing kasus historis, dan menghitung untuk setiap kasus metrik kesamaan. Metrik ini memberikan indikasi seberapa dekat kasus baru dengan setiap kasus historis. Kasus historis yang paling mirip diambil dan digabungkan dengan kasus baru melalui proses reuse untuk membentuk kasus yang terpecahkan, yaitu solusi yang diusulkan untuk kasus baru.

Melalui proses revisi, solusi yang diusulkan kemudian dievaluasi kebenarannya, mis. dengan membandingkan solusi dengan sinyal pengawasan atau kelas target yang dikonfirmasi. Solusi yang diusulkan perlu diperbaiki jika gagal menyelesaikan kasus baru secara memuaskan. Setelah dipastikan bahwa solusi yang diusulkan bekerja dengan baik, proses penyimpanan dimulai. Solusi yang diusulkan diserap ke dalam perpustakaan kasus sebagai kasus baru yang dipelajari atau informasi yang berguna dari solusi yang diusulkan diintegrasikan dengan beberapa kasus serupa yang sudah ada. Tujuannya adalah untuk terus meningkatkan sistem penalaran berbasis kasus.

Dari Gambar 10 terlihat bahwa pengetahuan umum berperan dalam siklus penalaran berbasis kasus. Pengetahuan umum berguna untuk melengkapi informasi yang terkandung dalam kasus-kasus sejarah. Akibatnya, solusi yang diusulkan dapat dirumuskan dengan cara yang akurat tidak hanya berdasarkan kasus yang diambil tetapi juga dari pengetahuan yang bergantung pada domain umum.

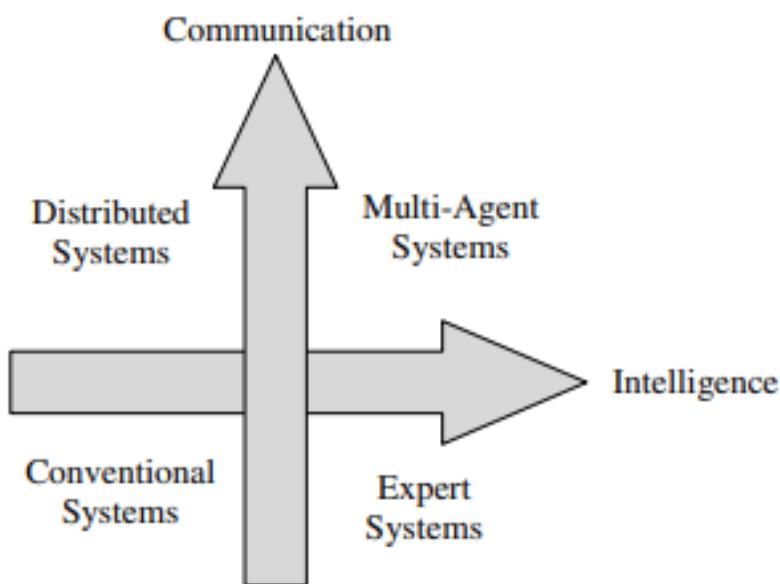


**Gambar 1.10** Siklus penalaran berbasis kasus tipikal (sumber: [39])

## Sistem Berbasis Agen

Sistem berbasis agen umumnya dianggap sebagai paradigma kecerdasan buatan terdistribusi. Dalam [40], agen digambarkan sebagai "program komputer canggih yang bertindak secara mandiri atas nama penggunanya, di lingkungan terdistribusi terbuka, untuk memecahkan semakin banyak masalah kompleks". Hal ini menunjukkan bahwa agen mampu membuat keputusan dan melakukan tugas secara mandiri. Memang, agen cerdas adalah entitas yang dapat diperbaiki untuk mengubah lingkungan dan mengubah tujuan. Mereka belajar dari pengalaman dan membuat pilihan yang tepat mengingat keterbatasan persepsi dan komputasi yang terbatas [41].

Agen memiliki berbagai fitur. Misalnya, fitur agen yang esensial versus yang memberdayakan dijelaskan dalam [42]. Fitur penting dari agen termasuk orientasi tujuan, ketekunan, dan reaktivitas dan interaktivitas. Di sisi lain, fitur pemberdayaan agen termasuk kecerdasan buatan, mobilitas, dan interaktivitas. Sebagaimana dinyatakan dalam [43], sistem berbasis agen diberdayakan oleh kecerdasan dan kemampuan mereka untuk berkomunikasi satu sama lain. Alih-alih satu agen, ansambel agen dapat digunakan untuk membentuk sistem multi-agennya. Seperti yang ditunjukkan pada Gambar 11, sistem multi-agennya duduk di kuadran dengan tingkat kecerdasan yang tinggi dan tingkat kemampuan komunikasi yang tinggi.



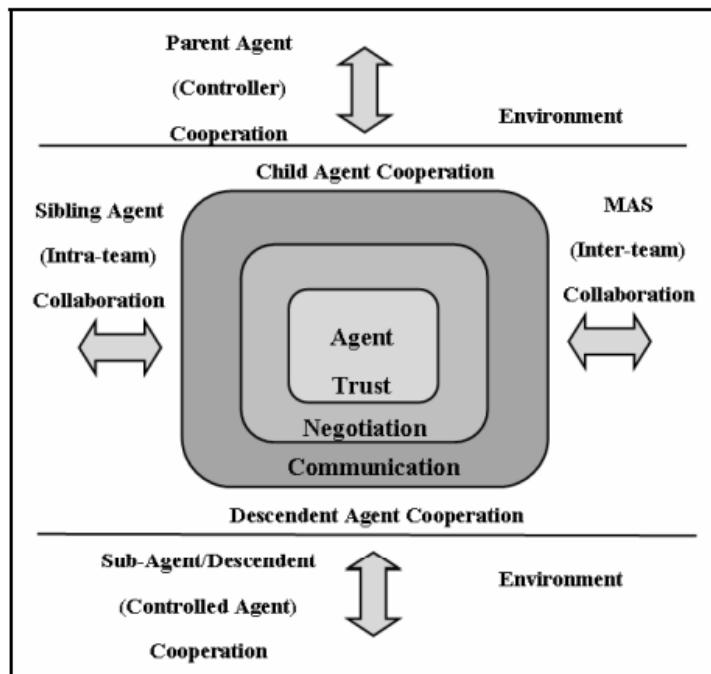
**Gambar 1.11** Perbandingan sistem berbasis agen dan sistem lainnya (Sumber: [43])

Dalam sistem multi-agennya, sejumlah area telah diselidiki. Ini termasuk arsitektur agen, arsitektur agen-sistem, dan infrastruktur agen [44]. Studi dalam arsitektur agen fokus pada arsitektur internal agen, seperti komponen untuk persepsi, penalaran, dan tindakan. Dalam arsitektur sistem agen, interaksi agen dan arsitektur organisasi dianalisis, di mana agen beroperasi dan berinteraksi di bawah batasan lingkungan yang ditentukan. Dalam infrastruktur agen, mekanisme antarmuka sistem multi-agennya, yang terutama aspek komunikasi antar agen dipelajari [45].

Untuk melakukan tugas tertentu, hubungan antara kumpulan agen dalam sistem multi-agennya perlu mengikuti beberapa model yang telah ditentukan sebelumnya. Salah satu model paling awal adalah model penalaran Beliefs, Desires, Intentions [46]. Dalam model ini,

keyakinan mewakili pemahaman agen tentang dunia luar, seperti informasi yang diperoleh dari lingkungan sekitar; keinginan adalah tujuan yang ingin dicapai agen; dan niat adalah rencana yang digunakan agen untuk mencapai keinginannya [47].

Model penalaran lainnya adalah model komunikasi negosiasi kepercayaan yang diusulkan dalam [48]. Gambar 12 menunjukkan jenis interaksi yang mungkin terjadi di antara agen. Model ini didasarkan pada premis bahwa asal dan pemberian kekuatan keyakinan berasal dari sumber keyakinan. Dalam model ini, empat kemungkinan sumber keyakinan dipertimbangkan: pengalaman langsung, kategorisasi, penalaran, dan reputasi [48].



**Gambar 1.12** Model komunikasi negosiasi kepercayaan untuk sistem multi-agen (Sumber: [48])

Dalam model komunikasi-negosiasi kepercayaan, komunikasi berkaitan dengan interaksi di antara agen agar mereka saling memahami. Negosiasi, di sisi lain, berkaitan dengan bagaimana tim agen dibentuk. Bagian inti dari model ini pada dasarnya adalah pada kepercayaan, dimana perhatian utama adalah bagaimana seorang agen menangani kepercayaan dan berinteraksi dengan agen lain. Pertanyaan yang diajukan termasuk 'haruskah agen memercayai informasi yang diberikan oleh agen lain?' atau 'haruskah agen memercayai agen lain untuk melakukan tugas tertentu?' Memang, agen dalam tim berkolaborasi satu sama lain, dan saling percaya (hubungan antar tim). Model tersebut menggambarkan kepercayaan sebagai ikatan yang dapat diperkuat melalui pertukaran token bersertifikat. Pada dasarnya, kepercayaan bersifat dinamis. Itu diperkuat oleh interaksi yang berhasil, dan dilemahkan oleh hasil yang tidak berhasil. Model ini berguna untuk menangani berbagai skenario dalam masalah pengambilan keputusan yang kompleks.

#### Keterangan

Sejumlah teknik kecerdasan buatan, yaitu, jaringan saraf tiruan, komputasi evolusioner, sistem fuzzy, penalaran berbasis kasus, dan sistem berbasis agen, yang dapat diterapkan untuk merancang dan mengembangkan sistem pendukung keputusan cerdas telah

dijelaskan secara singkat. Selain menggunakan setiap teknik cerdas untuk memecahkan masalah dunia nyata, solusi yang lebih efektif dapat diperoleh jika digunakan dalam kombinasi. Memang, paradigma hibrida yang menggabungkan dua atau lebih teknik cerdas menjadi semakin populer untuk menangani masalah yang kompleks. Contoh dari paradigma hybrid antara lain neural-fuzzy, neural-genetic, fuzzy-genetic, neural-fuzzy-genetic, fuzzy case based reasoning, model penalaran berbasis kasus evolusioner, sistem berbasis agen fuzzy, dan sistem penalaran berbasis kasus multi-agen, untuk sebutkan beberapa. Setiap kombinasi membawa sinergi ke sistem yang dihasilkan sedemikian rupa sehingga paradigma hibrida mengeksploitasi keunggulan teknik konstituen dan, pada saat yang sama, menghindari kekurangannya. Contoh aplikasi dijelaskan di bagian berikutnya.

#### **1.4 CONTOH APLIKASI**

Di bagian ini, contoh aplikasi yang berkaitan dengan teknik cerdas serta teknik cerdas hibrida untuk melakukan masalah pengambilan keputusan disajikan. Perhatikan bahwa contoh aplikasi ini hanya mewakili sampel kecil dari publikasi terbaru dalam literatur yang mencakup teknik cerdas serta paradigma hibridanya dengan aplikasi untuk mendukung proses pengambilan keputusan manusia di berbagai domain. Sebuah jaringan saraf berbasis backpropagation yang mencoba untuk memodelkan faktor emosional dalam pembelajaran manusia dan pengambilan keputusan diusulkan dalam [49]. Jaringan backpropagation emosional mencakup bobot emosional tambahan yang diperbarui menggunakan dua parameter emosional, yaitu kecemasan dan kepercayaan diri. Hasil eksperimen pada masalah pengenalan wajah menunjukkan penambahan parameter emosional mampu menghasilkan tingkat pengenalan yang lebih tinggi dan waktu pengenalan yang lebih cepat.

Hibrida yang dikenal sebagai Bayesian ARTMAP, yang menggabungkan jaringan saraf Fuzzy ARTMAP dan kerangka kerja Bayesian, diusulkan dalam [50]. Framework Bayesian digunakan untuk meningkatkan akurasi klasifikasi dan mengurangi jumlah kategori pada Fuzzy ARTMAP. Berdasarkan sintetik dan 20 database dunia nyata, ditunjukkan bahwa Bayesian ARTMAP mampu mengungguli Fuzzy ARTMAP dalam hal akurasi klasifikasi, sensitivitas terhadap tumpang tindih statistik, kurva pembelajaran, kerugian yang diharapkan, dan proliferasi kategori. Di bidang medis, sistem pendukung keputusan berdasarkan pohon keputusan, yaitu, C4.5, dan jaringan saraf backpropagation untuk membangun sistem pendukung keputusan untuk prediksi kecukupan rejimen vankomisin dilaporkan di [51].

Bagging juga diadopsi untuk meningkatkan kinerja. Hasilnya menunjukkan bahwa akurasi keseluruhan sistem pendukung keputusan berbasis C4.5 atau jaringan saraf lebih baik daripada model farmakokinetik satu kompartemen benchmark. Di sisi lain, sistem ensemble berbasis classifier yang terdiri dari jaringan saraf, mesin vektor pendukung, jaringan Bayesian, dan pohon keputusan untuk mendukung diagnosis penyakit kardiovaskular berdasarkan chip aptamer disajikan [52]. Sekali lagi, hasil menunjukkan bahwa sistem mampu menghasilkan akurasi diagnostik yang tinggi. Peramalan penjualan adalah masalah yang menantang karena volatilitas permintaan. Sebuah jaringan saraf baru yang dikenal sebagai mesin pembelajaran ekstrim untuk menyelidiki hubungan antara jumlah penjualan dan faktor-faktor signifikan yang mempengaruhi permintaan dikembangkan [53]. Dengan menggunakan data nyata dari

pengecer mode di Hong Kong, ditunjukkan bahwa model yang diusulkan mampu mengungguli jaringan saraf propagasi balik pada beberapa tugas peramalan penjualan.

Algoritme evolusi multi-tujuan untuk pengelolaan air tanah yang mengoptimalkan penempatan dan pengoperasian fasilitas pemompaan dari waktu ke waktu dijelaskan dalam [54]. Menggunakan masalah tiga wilayah, algoritme berguna dalam membantu penyelidikan ke dalam tradeoff biaya antara wilayah yang berbeda dengan memberikan perkiraan ke set Pareto-optimal. Model komputasi evolusioner lain yang menerapkan dua operator pencarian lokal dan Tabu Search untuk menangani masalah perutean inventaris diusulkan dalam [55]. Dua komponen utama dari rantai pasokan, yaitu logistik transportasi dan pengendalian persediaan, diperiksa. Operator pencarian lokal digunakan untuk menangani aspek inventaris dan perutean masalah, sementara Pencarian Tabu untuk lebih lanjut mengurangi biaya transportasi. Hasil yang memuaskan baik dalam hal efektivitas dan ketahanan dilaporkan.

Sebuah algoritma evolusioner digabungkan dengan teknik ekspektasi-maksimalisasi untuk merumuskan jaringan Bayesian berdasarkan database yang tidak lengkap disarankan dalam [56]. Kumpulan data dunia nyata yang terkait dengan pemasaran langsung, yaitu, memprediksi pembeli potensial dari catatan pembelian pelanggan sebelumnya, diterapkan untuk mengevaluasi penerapan sistem yang diusulkan. Hasilnya menunjukkan bahwa sistem yang diusulkan mampu mengungguli metode lain dengan adanya nilai yang hilang. Pengiriman ekonomi adalah masalah optimasi yang sangat terbatas yang melibatkan interaksi antara variabel keputusan. Sebuah sistem optimasi gerombolan partikel berbasis clustering fuzzy untuk melakukan masalah pengiriman tenaga listrik dijelaskan dalam [57]. Kinerja sistem yang diusulkan diperiksa menggunakan sistem uji enam generator standar IEEE 30 bus. Solusi berkualitas tinggi dihasilkan oleh sistem yang diusulkan.

Masalah analisis keputusan atribut ganda melibatkan atribut kuantitatif dan kualitatif dengan ketidakpastian, mis. ketidaklengkapan (atau ketidaktahuan) dan ketidakjelasan (atau ketidakjelasan). Untuk mengatasi masalah ini, model penalaran pembuktian kelas interval fuzzy diusulkan dalam [58]. Ketidaktahuan lokal dan ketidakjelasan kelas dimodelkan menggunakan struktur keyakinan fuzzy terdistribusi, yang mengarah ke matriks keputusan keyakinan kabur. Kemanjuran dan penerapan model yang diusulkan diilustrasikan dengan contoh numerik.

Sebuah metode untuk memangkas alternatif keputusan di memerintahkan operator rata-rata tertimbang disarankan [59]. Alternatif-alternatif inferior yang kurang kompetitif di antara alternatif-alternatif yang bersaing dalam proses agregasi rata-rata tertimbang terurut diidentifikasi dan dihilangkan. Kemanjuran metode yang diusulkan ditunjukkan dengan menggunakan masalah keputusan simulasi dari berbagai ukuran. Hasil penelitian menunjukkan bahwa jumlah alternatif dapat dikurangi secara drastis dengan menerapkan metode yang diusulkan. Dalam [60], kemampuan sistem fuzzy hierarkis untuk fungsi perkiraan dalam ruang input diskrit diperiksa. Properti berguna yang berkaitan dengan sistem fuzzy hierarkis untuk pendekatan fungsi dan akurasi pendekatan yang terkait dibahas. Metode identifikasi sistem fuzzy hierarkis yang menggabungkan pengetahuan manusia dan data numerik untuk konstruksi dan identifikasi sistem diusulkan. Penerapan metode yang diusulkan untuk mendukung keputusan pemilihan lokasi, yaitu, masalah pengambilan keputusan strategis yang dihadapi oleh banyak perusahaan ritel dan jasa, ditunjukkan. Berdasarkan

beberapa data komersial nyata, metode yang diusulkan mengungguli regresi dan pendekatan jaringan saraf.

Sebuah sistem klasifikasi persediaan berdasarkan proses hierarki analitik fuzzy dijelaskan dalam [61]. Konsep fuzzy terintegrasi dengan data persediaan nyata, dan sistem pendukung keputusan yang berguna untuk klasifikasi persediaan multi-kriteria dikembangkan. Efektivitas metode yang diusulkan ditunjukkan dengan menggunakan studi yang dilakukan di sebuah perusahaan peralatan listrik. Di sisi lain, model hibrida yang menggabungkan pengukuran kesamaan fuzzy dan pengambilan keputusan multi-kriteria fuzzy untuk desain berbasis kasus di bawah lingkungan fuzzy diusulkan dalam [62]. Keuntungan menggunakan himpunan fuzzy termasuk meningkatkan peluang kecocokan yang baik, menghindari “terlalu sedikit” kasus yang diambil, dan memungkinkan situasi dengan deskripsi linguistik untuk ditangani. Metode yang diusulkan diterapkan pada desain konkuren transformator daya, dan solusi yang lebih cocok, dibandingkan dengan solusi dari metode pengambilan hanya pengukuran kesamaan, dihasilkan.

Model penalaran berbasis kasus yang direvisi untuk melakukan masalah pengambilan keputusan dalam manajemen proyek dijelaskan dalam [63]. Pendekatan deskripsi masalah baru, yaitu, arsitektur kriteria hierarkis, diusulkan untuk meningkatkan teknik penalaran berbasis kasus tradisional, dan sistem rekomendasi untuk perencanaan proyek perangkat lunak, yang didasarkan pada keputusan ganda dan teknik penambangan pengetahuan, diimplementasikan. Eksperimen menggunakan 41 proyek nyata dari sebuah perusahaan konsultan perangkat lunak menunjukkan bahwa model penalaran berbasis kasus yang direvisi efektif untuk manajer proyek dalam merencanakan dan menganalisis kegiatan manajemen proyek.

Berdasarkan penalaran berbasis kasus hybrid dan teknik penalaran berbasis aturan, sistem pendukung keputusan klinis untuk ICU dibangun [64]. Penalaran berbasis kasus mampu melengkapi kesulitan dalam memperoleh pengetahuan eksplisit untuk membangun sistem berbasis aturan. Model hybrid yang diusulkan mampu memberikan dukungan keputusan klinis untuk semua domain ICU. Kemanjuran model yang diusulkan ditunjukkan dengan menggunakan data ICU nyata serta data simulasi. Sistem penalaran berbasis kasus umum untuk membantu manajer keselamatan membuat keputusan tentang tindakan pencegahan dijelaskan dalam [65]. Sistem membuat rekomendasi berdasarkan insiden serupa di masa lalu dan saran yang didorong oleh keahlian. Sistem ini diuji menggunakan database kecelakaan nyata dari industri kelautan, dan kegunaan sistem ini ditunjukkan.

Sebuah alat pengambilan keputusan, dikembangkan berdasarkan sistem multi-agensi, untuk menganalisis dan memahami perubahan harga dinamis di pasar tenaga grosir dijelaskan dalam [66]. Sistem ini mampu menciptakan kerangka kerja untuk menilai strategi perdagangan baru dalam lingkungan perdagangan listrik yang kompetitif. Kemampuan sistem yang diusulkan dalam hal estimasi, transmisi, pengambilan keputusan, analisis, dan kecerdasan dibandingkan dengan perangkat lunak perdagangan listrik lainnya. Sistem yang diusulkan juga menunjukkan akurasi estimasi yang lebih baik dibandingkan dengan jaringan saraf dan algoritma genetika. Sebuah studi menggunakan kumpulan data yang berkaitan dengan krisis listrik California dilakukan, dan hasilnya mengkonfirmasi validitas sistem.

Dalam [67], sebuah pendekatan untuk menggabungkan pembelajaran Bayesian ke dalam sistem multi-agen dijelaskan. Sebuah studi untuk menunjukkan bahwa sistem belajar untuk mengidentifikasi agen yang tepat untuk menjawab pertanyaan teks bebas dan pencarian kata kunci untuk kontrak pertahanan dilakukan. Keefektifan sistem yang diusulkan ditentukan dengan menganalisis akurasi dan tingkat pembelajaran dalam sistem. Sistem diuji terhadap data historis yang diketahui, dan hasilnya menunjukkan bahwa pembelajaran Bayesian adalah pendekatan yang bermakna, dan bahwa pembelajaran memang terjadi dalam sistem multi-agen.

Peran agen otomatis untuk pendukung keputusan di pasar elektronik telah menarik banyak perhatian. Dengan demikian, kemanjuran menggunakan agen otomatis untuk mempelajari strategi penawaran yang melibatkan banyak penjual dalam lelang terbalik dipelajari di [68]. Dikatakan bahwa agen harus dapat mempelajari strategi respons yang optimal atau terbaik ketika mereka ada (perilaku rasional) dan harus menunjukkan variasi keuntungan yang rendah (konvergensi). Sifat yang diinginkan dari perilaku rasional dan konvergensi ditunjukkan dengan menggunakan agen pembelajaran evolusioner dan penguatan.

Sistem pendukung keputusan berbasis multi-agen untuk membantu individu dan kelompok mempertimbangkan perspektif etis dalam kinerja tugas mereka dijelaskan dalam [69]. Empat peran berbeda untuk dukungan pemecahan masalah etis, yaitu. penasihat, fasilitator kelompok, pelatih interaksi, dan peramal, dijelaskan. Model keyakinan-keinginan-niat dalam teknologi agen digunakan sebagai metode untuk mendukung interaksi pengguna, mensimulasikan pemecahan masalah, dan memprediksi hasil di masa depan. Desain dan penerapan sistem multi-agen untuk mengatasi masalah manufaktur, yaitu penjadwalan produksi, disajikan dalam [70]. Skema koordinasi untuk sistem multi-agen diusulkan, dan kemanjurannya diuji terhadap kerangka pembelajaran multi-agen yang ada tanpa koordinasi. Agen di lantai pabrik manufaktur bertindak sebagai operator untuk mengirimkan pekerjaan melalui mesin. Basis pengetahuan aturan pengiriman dan algoritme genetika yang mempelajari aturan pengiriman baru dari waktu ke waktu disematkan ke dalam agen. Hasilnya menunjukkan bahwa sistem multi-agen di mana agen mengoordinasikan tindakan mereka berkinerja lebih baik daripada yang agen tidak mengoordinasikan tindakan mereka.

## 1.5 KESIMPULAN

Ikhtisar pengambilan keputusan yang cerdas disajikan dalam bab ini. Proses pengambilan keputusan manusia dan elemen yang terkait dengan kualitas keputusan dibahas. Taksonomi sistem pendukung keputusan juga dijelaskan. Teknik dari kecerdasan buatan yang berguna untuk desain dan pengembangan model pengambilan keputusan yang cerdas juga disajikan. Ini termasuk jaringan saraf tiruan, komputasi evolusioner, sistem fuzzy, penalaran berbasis kasus, serta sistem multi-agen. Contoh aplikasi yang menunjukkan bagaimana teknik cerdas dan hibrid dapat digunakan untuk mengatasi masalah pengambilan keputusan disorot. Dapat dibayangkan bahwa aspek-aspek umum dari pengambilan keputusan, serta teknik-teknik cerdas dan contoh-contoh penerapannya yang terkait dalam berbagai domain seperti yang disajikan dalam bab ini berfungsi sebagai latar belakang bagi pembaca untuk lebih memahami dan memahami bab-bab yang tercakup dalam buku ini.

## BAB 2

### IDSSE-M: METODOLOGI REKAYASA SISTEM PENDUKUNG KEPUTUSAN

Bab ini menjelaskan dan mengilustrasikan IDSSE-M, sebuah metodologi untuk merancang dan membangun sistem pendukung keputusan yang cerdas. IDSSE-M mengikuti pendekatan evolutif berbasis prototipe pada empat fase utama: inisiasi proyek, desain sistem, pembangunan dan evaluasi sistem, dan penerimaan definitif pengguna. IDSSE-M secara teoritis didirikan dalam Metodologi Teknik Pendukung Keputusan Saxena, dan Paradigma Pembangunan DSS Turban dan Aronson. Meskipun IDSSE-M hanya digunakan di lingkungan akademis), kompleksitas implementasinya tinggi, dan berdasarkan kasus organisasi yang realistik, dengan hasil yang memuaskan. Manfaat utama IDSSE-M adalah menyediakan proses berorientasi rekayasa perangkat lunak sistematis untuk pengembangan baru DMSS cerdas.

#### **2.1 PENDAHULUAN**

Sistem Pendukung Pengambilan Keputusan (DMSS) (Forgionne et al, 2005) – juga disebut Sistem Pendukung Manajemen (MSS) (Turban dan Aronson, 1998) – adalah Sistem Informasi (SI) yang dirancang khusus untuk mendukung beberapa, beberapa atau semua fase dari suatu individu, tim, organisasi atau proses pengambilan keputusan intra-organisasi. Dari asalnya pada awal 1970-an (Scott Morton, 1971) hingga sekarang (McCosh dan Correa-Perez, 2006), keberhasilan implementasi DMSS telah dituntut terutama oleh organisasi besar karena relevansi manfaat yang diharapkan. Tabel 1 menyajikan manfaat dan permintaan yang dilaporkan untuk empat jenis DMSS.

Terlepas dari minat yang dilaporkan, telah banyak didokumentasikan bahwa mencapai keberhasilan implementasi DMSS adalah tugas yang kompleks (Mora et al, 2003). Namun, belum ada kerangka standar atau taksonomi faktor yang terkait dengan keberhasilan implementasi DMSS. Diperbarui dari Mora et al (2003) lima skema telah diidentifikasi -dan ditampilkan dalam Tabel 2-: (i) kerangka kerja untuk implementasi DSS berbasis eksekutif (Watson et al, 1991); (ii) kerangka kerja DSS berbasis model (Eierman et al, 1995), (iii) kerangka kerja DSS berbasis pengetahuan yang berasal dari beberapa sumber; (iv) kerangka kerja untuk DMSS terintegrasi (Mora et al, 2003) dan (v) kerangka faktor sukses di bawah rasionalitas kualitatif yang berasal dari kerangka kerja (i)-(iv).

**Tabel 2.1 Alasan Utama Menggunakan DMSS**

<b>Tujuan dan Kebutuhan Penggunaan DSS Berbasis Model</b>	<b>Tujuan dan Kebutuhan Penggunaan DSS Berbasis Eksekutif</b>
<ul style="list-style-type: none"> <li>• Meningkatkan kualitas keputusan.</li> <li>• Meningkatkan produktivitas analis.</li> <li>• Memfasilitasi komunikasi antara pengambil keputusan dan analis.</li> <li>• Menghemat waktu analisis.</li> <li>• Mendukung keputusan berdasarkan tujuan.</li> </ul>	<ul style="list-style-type: none"> <li>• Meningkatnya persaingan.</li> <li>• Lingkungan bisnis yang sangat dinamis.</li> <li>• Kebutuhan akan respon eksekutif yang cepat.</li> <li>• Kebutuhan informasi eksekutif yang tepat waktu.</li> <li>• Kebutuhan komunikasi yang lebih baik</li> </ul>

<ul style="list-style-type: none"> <li>Mengurangi biaya yang berasal dari keputusan yang salah.</li> <li>Memasukkan wawasan dan penilaian pembuat keputusan ke dalam analisis.</li> </ul>	<ul style="list-style-type: none"> <li>Kebutuhan status yang cepat pada data operasional.</li> <li>Pindai lingkungan keputusan eksternal.</li> <li>Tangkap, filter, dan fokus pada data eksternal dan internal.</li> </ul>
<b>Tujuan dan Kebutuhan Penggunaan DSS Berbasis Pengetahuan</b>	<b>Tujuan dan Kebutuhan Penggunaan DSS Berbasis Umum</b>
<ul style="list-style-type: none"> <li>Pertahankan pengetahuan yang berharga dan langka.</li> <li>Berbagi pengetahuan yang berharga dan langka.</li> <li>Meningkatkan kemampuan pemecahan masalah pengguna.</li> <li>Kembangkan keterampilan kerja pengguna.</li> <li>Meningkatkan produktivitas.</li> <li>Meningkatkan kualitas solusi yang diberikan.</li> <li>Memandu pengguna melalui proses pemecahan masalah.</li> <li>Berikan penjelasan untuk tindakan yang direkomendasikan.</li> </ul>	<ul style="list-style-type: none"> <li>Meningkatkan beberapa atau beberapa fase proses pengambilan keputusan individu, tim atau organisasi.</li> <li>Meningkatkan kemungkinan hasil yang lebih baik dari proses pengambilan keputusan.</li> <li>Meningkatkan visi bersama membuat keputusan tentang organisasi</li> <li>Mencari efisiensi dan efektivitas pengambilan keputusan atas mengenai tugas keputusan.</li> <li>Jelajahi konsekuensi dari keputusan penting sebelum diambil dan diimplementasikan.</li> </ul>

Pada Tabel 2, setiap simbol ■ berarti bahwa faktor tersebut telah ditemukan di sebagian besar studi yang ditinjau oleh penulis kerangka kerja. Kumpulan delapan kategori berasal dari kerangka Mora et al (2003) dan menyarankan bahwa proses implementasi DMSS harus mempertimbangkan setidaknya satu faktor dari setiap kategori untuk memiliki penjelasan yang lebih komprehensif tentang fenomena tersebut. Kategori faktor adalah: pengguna, tugas, tim pengembangan, proses, teknologi, organisasi, lingkungan, dan sistem. Kolom terakhir Tabel 2 kemudian dibuat untuk DSS atau DMSS umum, di bawah rasionalitas kualitatif dan linier yang menyarankan faktor-faktor untuk diuji secara positif.

Dengan bukti yang dilaporkan dari beberapa kerangka kerja, faktor yang paling mungkin berhasil untuk setiap kategori masing-masing adalah: bakat pengguna terhadap DMSS, keselarasan atau prioritas tugas keputusan yang akan didukung oleh DMSS, keberadaan juara proyek untuk proyek DMSS, dukungan yang diberikan oleh area SI organisasi untuk proyek DMSS, metodologi pengembangan yang sesuai, teknologi perangkat lunak dan perangkat keras yang memadai untuk membangun dan menerapkan DMSS, adanya dukungan manajemen puncak yang positif, sponsor dan iklim organisasi, lingkungan bisnis yang tidak pasti, kemudahan dalam memanfaatkan DMSS, dan penyampaian informasi yang diberikan tepat waktu. Pada gilirannya, elemen dari Tabel 2, dengan sedikit simbol ■ menunjukkan bahwa populasi sampel proyek DMSS tersebut ditemukan tidak bermakna secara statistik.

**Tabel 2.2** Daftar Utama Faktor Keberhasilan dan Kegagalan Implementasi DMSS

Kategori Faktor dan Faktor Tunggal dan Faktor Tunggal	Skema Mora et al			Skema Eierman et al	Skema Watson et al	Beberapa Sumber	Bukti yang Paling Mungkin untuk diuji
	DSS	EIS	ES	DSS berbasis model	DSS berbasis eksekutif		
<b>1. Karakteristik pengguna</b>	■	■	■	■	■	■	■■■
Bakat pengguna	■■	■■	■■	■		■	■■■
Motivasi norma	■■	■■		■			■■■
Gaya kognitif		■■					■
Harapan yang realistik.			■■	■■		■	■■■
<b>2. Karakteristik tugas</b>	■	■	■	■		■	■■■
Kesulitan dan kebaruan tugas	■					■	■
Tingkat ketidakpastian tugas		■■				■	■
Penyelarasan organisasi tugas (prioritas)		■■	■■	■		■	■■■
Domain tugas dan kompleksitas yang memadai			■■	■■		■	■
<b>3. Karakteristik tim pengembangan</b>	■	■	■		■	■	■■■
Juara proyek	■■	■■	■■			■	■■■
Keterampilan bisnis pemimpin		■■					■
Keterampilan teknis pemimpin		■■					■
Keterampilan teknis pengembang.			■■			■■	■■■
<b>4. Karakteristik proses</b>	■	■	■	■■	■■	■■	■■■
Pelatihan pengguna.	■■				■■	■	■■■
Keterlibatan pengguna.	■■				■■	■■	■■■
Metodologi Pengembangan (Evolved)	■■					■■	■■■

Waktu kerangka pengembangan	■					■	■
Analisis biaya-manfaat		■	■		■	■	■
Aksesibilitas data		■			■		■
Manajemen perubahan dan resistensi		■	■			■	■
Dukungan untuk evolusi dan difusi		■	■		■	■	■
Dukungan departemen IS		■	■	■	■	■	■
Komitmen pemeliharaan			■			■	■
<b>5. Karakteristik teknologi</b>	■	■	■	■	■	■	■
Perangkat Lunak yang Memadai	■	■	■	■	■	■	■
Perangkat Keras yang Memadai	■	■	■	■	■	■	■
<b>6. Karakteristik organisasi.</b>	■	■	■	■	■	■	■
Dukungan manajemen puncak	■	■	■	■	■	■	■
Sponsor utama		■	■	■	■	■	■
iklim organisasi			■	■		■	■
<b>7. Karakteristik lingkungan.</b>	■	■	■	■	■	■	■
Lingkungan yang tidak bersahabat dan tidak pasti		■		■	■	■	■
Hubungan dengan pemasok TI dan pusat penelitian TI			■			■	■
<b>8. Karakteristik sistem (DMSS).</b>	■	■	■	■	■	■	■
Akurasi dan format hasil	■	■		■			■
Tingkat manajemen didukung	■			■			■
Fase keputusan didukung	■			■			■
Relevansi hasil	■			■			■
Tingkat kecanggihan sistem		■		■			■
Informasi yang tak lekang oleh waktu		■		■	■		■

Kemudahan penggunaan		<input checked="" type="checkbox"/>		<input checked="" type="checkbox"/>	<input checked="" type="checkbox"/>		<input checked="" type="checkbox"/>
Dampak dalam pekerjaan pengguna			<input checked="" type="checkbox"/>			<input checked="" type="checkbox"/>	<input checked="" type="checkbox"/>
Masalah hukum & etika			<input checked="" type="checkbox"/>			<input checked="" type="checkbox"/>	<input checked="" type="checkbox"/>

Seperti yang ditunjukkan Tabel 2 – dihasilkan dari Mora et al (2003) – ada banyak faktor yang dapat mencegah keberhasilan implementasi DMSS. Dalam bab ini, kami tertarik pada faktor-faktor yang terkait dengan metodologi pengembangan dan isu-isu teknis H/S. Secara khusus, kami mengklaim bahwa metodologi pengembangan sistem yang terintegrasi dengan baik atau gesit yang disepakati dengan baik dapat meningkatkan keberhasilan implementasi (Mahmood dan Medewitz, 1985).

Bab ini menjelaskan dan mengilustrasikan IDSSE-M, sebuah metodologi untuk merancang dan membangun sistem pendukung keputusan yang cerdas. IDSSE-M didirikan pada pendekatan evolutif berbasis prototipe yang melibatkan empat fase utama: inisiasi proyek, desain sistem, pembangunan dan evaluasi sistem, dan penerimaan definitif pengguna. Dari beberapa metodologi DMSS yang tersedia (Gachet dan Haettenschwiler, 2006), IDSSE-M mengintegrasikan kegiatan dari Metodologi Teknik Pendukung Keputusan Saxena (1991) dan Pendekatan Bangunan DSS Turban dan Aronson (1998). Kami melaporkan bahwa IDSSE-M hanya digunakan dalam pengaturan akademik (dalam enam kursus MSc tentang DMSS dari tahun 2000 hingga 2008, dan dua tesis MSc (Lopez, 2007; Calderon, 2007)). Namun, kompleksitas proyek ilmiah prototipe tinggi dan didasarkan pada kasus organisasi yang realistik, dan IDSSE-M telah menghasilkan hasil awal yang memuaskan. Secara khusus, manfaat utama IDSSE-M adalah menyediakan proses berorientasi rekayasa perangkat lunak yang sistematis untuk pengembangan baru DMSS cerdas.

Sisa dari bab ini berlanjut sebagai berikut: di bagian 2, tinjauan umum metodologi DMSS dilaporkan. Pada bagian 3, IDSSE-M dijelaskan. Di bagian 4, kasus demo untuk tujuan ilustrasi dan evaluasi eksplorasi empiris dilaporkan. Bab ini diakhiri dengan rekomendasi dan keterbatasan.

## 2.2 IKHTISAR METODOLOGI DMSS

Beberapa metodologi untuk mengembangkan DMSS (DSS, EIS dan KBS) telah dikemukakan (Gachet dan Haettenschwiler, 2005). Metodologi ini dapat dikelompokkan berdasarkan jenis paradigma pembangunan: tradisional, iteratif (prototyping/evolutive atau adaptif), dan pendekatan hybrid-integrated. Sementara literatur (Alavi dan Nappier, 1984; Mahmood dan Medewitz, 1985) melaporkan bahwa SDLC tradisional/klasik tidak disarankan untuk DMSS, mengingat kurangnya persyaratan yang ditetapkan sebelumnya dari pengguna dan semi-terstruktur dalam pengambilan keputusan. situasi, DMSS pertama dikembangkan melalui SDLC klasik (Turban dan Aronson, 1998). Kemajuan dalam metode dan fondasi DSS memiliki dampak positif dalam mengatasi kesulitan sebelumnya yang dilaporkan dalam literatur. Selain itu, sementara DMSS memiliki karakteristik khusus (tujuan pengambilan keputusan, intensif dalam desain berbasis model, dengan dampak strategis yang tinggi, dan digunakan oleh pengguna tingkat atas dan menengah), mereka juga merupakan sistem yang *Sistem Pendukung Keputusan (Dr Joseph Teguh Santoso dan Budi Hartono, M.Kom)*

harus direncanakan, dirancang, dan dibangun, melalui proses yang sistematis (baik tradisional, iteratif, atau terintegrasi-hibrida).

Dalam studi metodologi pengembangan DMSS mereka yang komprehensif, Gachet dan Haettenschwiler (2005) melaporkan "... namun demikian, SDLC tetap berguna sebagai model referensi dan sebagai abstraksi ideal dari proses pengembangan DSS yang lebih realistik". Akibatnya, sementara pendekatan pengembangan DMSS berulang lebih disukai, ada bukti yang mendukung proses pengembangan yang dikelola dengan baik atau proses terintegrasi hibrida untuk mengembangkan DMSS (Mahmood, 1987; Sage, 1981; 1991; Turban, 1992). Tabel 3 melaporkan metodologi pengembangan DMSS utama, serta fitur inti positif dan negatifnya (studi komparatif lengkap di luar cakupan bab ini). Dalam Tabel 3IDSSE-M (metodologi yang dilaporkan di sini) diklasifikasikan sebagai pendekatan terintegrasi-hibrida (misalnya, proses pengembangan yang terdefinisi dengan baik berulang-ulang).

Oleh karena itu, ketersediaan metodologi DMSS yang dilaporkan dalam literatur ilmiah dapat dianggap melimpah. Namun, dari sudut pandang skolastik, beberapa metodologi lengkap telah dilaporkan dalam buku teks DMSS. Saxena (1991, hlm. 98) misalnya melaporkan "... sayangnya pengembangan DSS seringkali merupakan proses yang inovatif tetapi bersifat ad hoc. Pengalaman konkret dengan desain dan pengembangan DSS yang kompleks dan/atau berskala besar sebagian besar masih terbatas pada lembaga penelitian atau perusahaan besar." Kami menganggap bahwa deskripsi metodologi DMSS yang lebih rinci harus dilaporkan. Bab ini mengejar tujuan ini.

**Tabel 2.3 Metodologi Pengembangan DMSS**

<b>JENIS PARADIGMA PEMBANGUNAN</b>	<b>FITUR UTAMA</b>	
	<b>KEUNTUNGAN</b>	<b>KEKURANGAN</b>
<b>Paradigma SDLC Klasik:</b> • Air Terjun (Royce, 1970; Marakas, 1999)	<ul style="list-style-type: none"> <li>• Dukungan manajemen proyek yang kuat.</li> <li>• Metodologi pengembangan yang terkenal.</li> <li>• Hal ini dapat disesuaikan.</li> </ul>	<ul style="list-style-type: none"> <li>• Pada masalah pengambilan keputusan yang kompleks, fase prototyping awalnya akan diperlukan.</li> <li>• Ini dapat dianggap sebagai metodologi yang "berat".</li> <li>• Ini memberikan hasil yang berguna sampai selesai.</li> </ul>

<p><b>Paradigma berulang:</b></p> <ul style="list-style-type: none"> <li>Prototyping/Evolutif (Courbon et al, 1980; (dikutip dalam Turban dan Aronson, 1998); Alavi dan Henderson, 1981; Nauman dan Jenkins, 1982; Alavi, 1984)</li> <li>Adaptif ( Keen, 1980)</li> </ul>	<ul style="list-style-type: none"> <li>Ini memberikan hasil awal yang cepat dan terlihat kepada pengguna.</li> <li>Ini dapat diulang sampai penyelesaian akhir sistem.</li> <li>Dalam DMSS skala besar dan kompleks dapat menghemat sumber daya yang berharga.</li> <li>Dalam DMSS skala besar dan kompleks, ini mengurangi risiko desain.</li> <li>Ini mendorong partisipasi pengguna yang mengarah ke kepuasan pengguna yang lebih.</li> </ul>	<ul style="list-style-type: none"> <li>Ini dapat menyebabkan proses yang tidak teratur jika tidak dikelola dengan baik.</li> <li>Hal ini dapat dicontohkan secara berbeda oleh tim yang sama dalam organisasi yang sama yang menghasilkan variabilitas hasil.</li> <li>Ini dapat menghasilkan DMSS akhir yang berguna tetapi tidak sepenuhnya didokumentasikan dengan risiko tinggi dalam perbaikan yang diperlukan di masa depan.</li> <li>Biasanya menuntut alat pengembangan yang canggih.</li> </ul>
<p><b>Fokus Terpadu / Paradigma Hibrida:</b></p> <ul style="list-style-type: none"> <li>Siklus Desain DSS (Keen dan Morton, 1978; dikutip dalam Gachet dan Haettenschwiler, 2005)</li> <li>Fase Pengembangan DSS (Carlson, 1979)</li> <li>Siklus Pengembangan DSS (Meador dkk, 1984)</li> <li>Rekayasa Sistem Pendukung Keputusan (Sage, 1981; 1991)</li> <li>Rekayasa Pendukung Keputusan (Saxena, 1991)</li> <li>IDSSE-M (dilaporkan dalam bab ini)</li> </ul>	<ul style="list-style-type: none"> <li>Idealnya pendekatan ini harus memberikan keuntungan yang sama dengan pendekatan sebelumnya.</li> <li>Menyajikan pendekatan dual-view di mana desainer dan pengguna dapat mengadaptasi metodologi.</li> </ul>	<ul style="list-style-type: none"> <li>Idealnya pendekatan ini harus mengurangi kerugian serupa dari pendekatan sebelumnya.</li> <li>Harus didominasi untuk menghindari kebingungan metodologis dalam penerapannya.</li> </ul>

### 2.3 IDSSE-M

IDSSE-M adalah metodologi untuk merancang dan membangun sistem pendukung keputusan yang cerdas. Draf awal dikembangkan dalam proyek penelitian internal di UAA, Meksiko (Mora, 1998), dan perbaikan selanjutnya dilaporkan dalam bab ini. IDSSE-M mengikuti pendekatan evolutif berbasis prototipe dengan empat fase utama: inisiasi proyek, desain sistem, pembangunan dan evaluasi sistem, dan penerimaan definitif pengguna. IDSSE-

M dapat dianggap sebagai adaptasi dari Metodologi Teknik Pendukung Keputusan Saxena dan Paradigma Bangunan DSS Turban dan Aronson. Tabel 4 melaporkan peta fase IDSS-M dengan metodologi sebelumnya. Keterbatasan ruang menghalangi analisis ekstensif dari perbandingan ini tetapi referensi akan digunakan dalam deskripsi IDSSE-M. IDSSE-M adalah pendekatan evolutif berbasis prototipe. Evolutif (juga disebut iteratif (Jalote, 1997)) menyiratkan bahwa perangkat lunak dirilis dalam beberapa iterasi dan di mana dalam setiap iterasi, rilis adalah versi fungsional. Dalam arti yang ketat, prototyping (Ginac, 1998) tidak memberikan versi fungsional. Di IDSSE-M, prototyping digunakan pada fase 2, jika versi sistem yang lebih realistik harus disajikan kepada pengguna, dan difokuskan pada aktivitas desain antarmuka pengguna (UI).

Pada fase pertama (inisiasi proyek), tujuan utamanya adalah formalisasi dan kesepakatan pengembangan IDSS. Tiga kegiatan disarankan: 1.1 pengenalan situasi pengambilan keputusan; 1.2 justifikasi IDSS; dan 1.3 perencanaan bangunan. Kegiatan 1.1 digunakan untuk identifikasi yang cepat tetapi penting dari situasi pengambilan keputusan yang kritis. Ini menggunakan diagram skema (pengguna, masalah, tujuan yang diharapkan, unit keputusan, dan daftar tindakan potensial) untuk mendukung visualisasi cepat dari elemen umum pengambilan keputusan utama. Sementara IDSS diasumsikan untuk mendukung keputusan semi-terstruktur, juga diharapkan bahwa pengguna dapat membantu untuk membatasi struktur umum dari masalah. Aktivitas 1.1 ini menjelaskan aktivitas Turban dan Aronson (1998) 1.1, 1.2, 1.3, dan 1.4, dan sebagian aktivitas Saxena (1991) 1.1, 2.1, 2.2 dan 2.3. Kegiatan 1.2 (pembenaran proyek) direalisasikan untuk mengidentifikasi dan mengestimasi manfaat yang diharapkan paling potensial dan tidak berwujud yang diharapkan dari IDSS. Dalam kegiatan 1.3 (perencanaan bangunan), pendekatan pembangunan ditetapkan (pengembangan internal atau eksternal baru dari awal, atau melalui paket yang sudah ada), dan perkiraan rencana dan tim proyek (pengguna, analis IDSS, dan pembangun IDSS) diidentifikasi. Pendekatan iteratif tidak berarti bahwa satu set iterasi pertama dapat diperkirakan terlebih dahulu. Hal ini diperlukan untuk memberikan versi final penuh. Ini dapat diperluas di masa depan, tetapi akan melalui proyek baru. Kedua aktivitas tersebut menjelaskan aktivitas Turban dan Aronson (1998) 2.1, dan 2.2, dan aktivitas Saxena (1991) 1.2.

Pada fase kedua (desain), tujuan utamanya adalah analisis dan desain detail dari IDSS. Lima kegiatan direalisasikan: 2.1 desain elemen inti umum IDSS; 2.2 desain arsitektur IDSS; 2.3 desain elemen inti rinci DSS; 2.4 dampak skenario; dan 2.5 desain model numerik, simbolik, DB, UI, & proses. Aktivitas-aktivitas ini menjelaskan fase-fase rekayasa dan desain sistem persyaratan penuh Saxena (1991) dan fase aktivitas 2.3 dan desain penuh Turban dan Aronson (1998).

Dalam aktivitas 2.1 (desain umum), diagram digunakan untuk mengidentifikasi empat elemen inti: variabel keputusan ( $x_1, x_2, \dots$ ); variabel skenario ( $z_1, z_2, \dots$ ); variabel keluaran ( $y_1, y_2, \dots$ ); dan parameter ( $w_1, w_2, \dots$ ). Dalam IDSS yang kompleks, variabel tersebut dapat dikelompokkan dan beberapa diagram rinci dapat digambarkan. dalam aktivitas 2.2 (desain arsitektur), lima kemungkinan pengaturan (struktur internal) disarankan: sebuah DSS-ES (sistem pendukung keputusan – sistem pakar), sebuah ES-DSS, sebuah DSS dengan ES yang disertakan, sebuah ES dengan DSS yang disertakan, sebuah sistem yang mengendalikan

setidaknya satu DSS dan satu ES. Diagram akhir arsitektur diwujudkan di mana struktur internal dan keputusan, skenario, output, dan variabel parameter dilaporkan. Dalam aktivitas 2.3 (desain detail), kamus elemen untuk empat set elemen inti (x, z, y, dan w) dibuat. Dalam kamus elemen, data berikut menurut setiap elemen dilaporkan: identifikasi kode, nama, nilai (rentang nilai numerik atau kualitatif), sumber (data pengguna, model numerik, atau model kualitatif), dan komentar. Oleh karena itu, tidak ada model numerik atau kualitatif eksplisit yang dikembangkan.

**Tabel 2.4** Peta Metodologi I-Dsse-M dan Akar Metodologi Inti

<b>IDSSE-M</b>	<b>DSE Saxena</b>	<b>Fase Pembangunan DSS Turban &amp; Aronson</b>
<b>1. Tahap Inisiasi Proyek IDSS.</b>	<b>1. Tahap Definisi Masalah dan Penilaian Kelayakan.</b>	<b>1. Tahap Perencanaan.</b>
1.1 Pengenalan situasi pengambilan keputusan. 1.2 Justifikasi IDSS. 1.3 Perencanaan bangunan.	1.1 Penilaian masalah (ukuran, kompleksitas, dan klasifikasi terstruktur). 1.2 Studi kelayakan (teknis, ekonomi dan operasional).	1.1 Identifikasi Masalah. 1.2 Tujuan DSS. 1.3 Keputusan kunci didukung. 1.4 Penelitian dokumen.
	<b>2. Tahap Analisis Tugas Keputusan.</b>	<b>2. Fase Analisis.</b>
	2.1 Menetapkan skenario keputusan. 2.2 Identifikasi objek keputusan. 2.3 Pemodelan struktur tugas.	2.1 Pemilihan strategi konstruksi. 2.2 Identifikasi sumber daya. 2.3 Desain konseptual.
<b>2. Tahap Desain IDSS.</b>	<b>3. Tahap Rekayasa Persyaratan.</b>	<b>3. Fase Desain.</b>
2.1 Elemen inti umum IDSS. 2.2 Arsitektur IDSS. 2.3 Elemen inti rinci IDSS. 2.4 Dampak skenario. 2.5 Model numerik, simbolik, DB, UI, & modul proses.	3.1 Analisis pengguna. 3.2 Analisis fungsional dan keputusan. 3.3 Analisis data & pengetahuan. 3.4 Analisis antarmuka pengguna. 3.5 Pemilihan lingkungan H&S. 3.6 Analisis kegunaan.	3.1 Desain UI. 3.2 Desain model. 3.3 Desain DB. 3.4 Desain pengetahuan.
		<b>4. Tahap Desain Sistem.</b>

	4.1 Desain arsitektur DSS. 4.2 Desain UI. 4.3 Desain model. 4.4 DB desain. 4.5 Desain pengetahuan.
--	--

**Tabel 2.4 (lanjutan)**

<b>IDSSE-M</b>	<b>DSE Saxena</b>	<b>Fase Pembangunan DSS Turban &amp; Aronson</b>
<b>3. Gedung IDSS &amp; Evaluasi.</b>	<b>5. Fase Prototyping.</b>	<b>4. Tahap konstruksi.</b>
3.1 Konstruksi & integrasi model. 3.2 Perencanaan kasus uji. 3.3 Evaluasi pengguna.	5.1 Gedung DSS.	4.1 Pemrograman DSS. <b>5. Tahap Implementasi.</b> 5.1 Pengujian, evaluasi & demonstrasi. 5.2 Pelatihan & penyebaran.
<b>4. Akhir Proyek IDSS.</b>	<b>6. Tahap Evaluasi dan Adaptasi Pengguna.</b>	<b>6. Fase Pemeliharaan &amp; Evolusi.</b>
4.1 Dokumentasi. 4.2 Pelatihan (jika diperlukan). 4.3 Proyek penutupan.	6.1 Evaluasi pengguna. 6.2 Proses adaptasi.	6.1 Dukungan berkelanjutan. 6.2 Evolusi melalui langkah-langkah sebelumnya.

Pendekatan ini adalah top-down (dari kotak hitam ke putih) yang mengelola kompleksitas desain dari lapisan desain abstraksi tinggi ke rendah. Pada kegiatan 2.4 (dampak skenario) melalui diagram pengaruh, diperkenalkan tingkat desain berikutnya. Pertama, model dikembangkan yang menghubungkan empat set variabel, dan hubungan probabilistik dan inferensial antara variabel diperkirakan.

Matriks bersyarat dengan rentang probabilitas dan keluaran yang diharapkan harus dihasilkan.

Dalam aktivitas 2.5 prosedur numerik dan inferensi (simbolik) spesifik harus didefinisikan, serta desain detail data, antarmuka pengguna, dan model modul proses. Model numerik dilaporkan dalam format klasik (input, algoritma, output), dan hubungan simbolis ditentukan melalui tabel keputusan. Model data dilaporkan melalui diagram hubungan entitas klasik dan dilengkapi dengan desain tabel yang detail. Desain antarmuka pengguna (UI) dilaporkan melalui peta navigasi ditambah desain detail setiap layar. Akhirnya, desain modul proses mengacu pada arsitektur fisik IDSS (diagram klasik 0 atau diagram komponen dapat digunakan).

Pada fase ketiga (pembangunan dan evaluasi) tiga kegiatan direalisasikan: 3.1 konstruksi & integrasi model; 3.2 perencanaan kasus uji; dan 3.3 evaluasi pengguna. Fase ini menjelaskan fase pembuatan prototipe Saxena (1991) dan aktivitas 6.1 (evaluasi pengguna), *Sistem Pendukung Keputusan (Dr Joseph Teguh Santoso dan Budi Hartono, M.Kom)*

dan untuk fase konstruksi dan implementasi Turban dan Aronson (1998). Pada kegiatan 3.1, perangkat lunak dipilih, dan ada kodifikasi dan/atau perakitan modul pra-paket, dan modul terintegrasi penuh. Dalam aktivitas 3.2, kasus uji disiapkan untuk validasi internal (dilakukan oleh pengembang) dan eksternal (kasus disiapkan oleh pengguna). Akhirnya, dalam aktivitas 3.3, evaluasi definitif dari pengguna diwujudkan. Keputusan kritis harus dibuat: (i) menutup proyek dengan versi saat ini, (ii) mengizinkan perubahan kecil dan mengakhirinya, atau (iii) mengizinkan iterasi berikutnya (dengan tambahan tambahan yang signifikan). Jika tindakan (i) diputuskan, maka fase akhir (akhir proyek) harus direalisasikan. Jika tidak, pembaruan dokumentasi disiapkan.

Tahap keempat diharapkan dapat direalisasikan setelah beberapa kali iterasi. Metodologi Saxena (1991) dan Turban dan Aronson tidak melaporkan fase ini secara eksplisit (1998). IDSSE-M mendukung pandangan manajemen proyek tentang relevansi awal dan penutupan formal. Tiga kegiatan yang disarankan: 4.1 dokumentasi lengkap lengkap; 4.2 melakukan pelatihan (jika diperlukan); dan 4.3 secara formal untuk menutup proyek. Praktik terbaik pengembangan sistem (paradigma apa pun) mencakup aktivitas penyelesaian dokumentasi. Pelatihan bersifat opsional bergantung pada jenis pengguna (lanjutan dan baru) dan kompleksitas sistem yang dikembangkan. Pengakhiran proyek secara formal berguna untuk memperjelas pencapaian dan pemanfaatan yang benar dari sumber daya ekonomi dan manusia yang diinvestasikan dalam proyek, dan untuk memisahkan potensi tambahan baru sebagai proyek baru (dan dengan permintaan sumber daya baru).

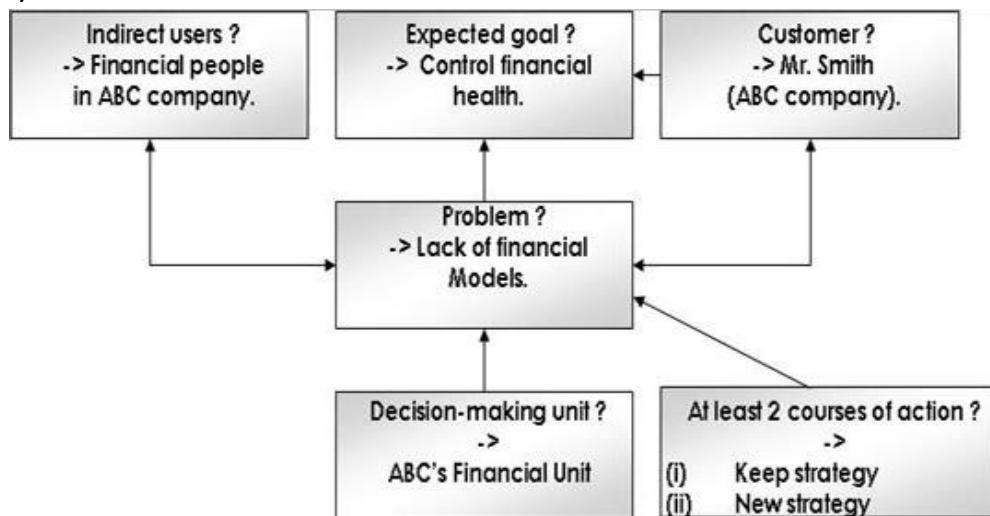
Kami percaya bahwa IDSSE-M adalah metodologi yang menyediakan struktur pengembangan yang teratur untuk memandu desain sistem pendukung keputusan cerdas yang sederhana dan kompleks. Pendekatan ini bergantung pada proses dan aktivitas pengembangan inti yang serupa yang dilaporkan dalam literatur (Saxena, 1991; Turban dan Aronson, 1998).

## **2.4 IDSSE-M: ILUSTRASI**

IDSSE-M telah digunakan dalam pengaturan akademik dalam satu proyek penelitian singkat pada tahun 1998, enam kursus MSc tentang DMSS dalam program MSc tentang TI selama tahun 2000, 2002, 2004, 2006, 2007, dan 2008 oleh sekitar 22 tim mahasiswa pascasarjana, dan untuk mengembangkan dua tesis MSc (Lopez, 2007; Calderon, 2007), semuanya di Universitas Otonom Aguascalientes, Meksiko. Penulis utama bab ini adalah perancang utama IDSSE-M, dan telah menjadi instruktur kursus MSc, serta direktur dua tesis MSc. Rekan penulis telah meninjau dan menyarankan perbaikan untuk metodologi. Sementara evaluasi numerik dari beberapa konstruksi kegunaan telah dilakukan, itu akan dilaporkan dalam artikel berikutnya. Di sini, kami dapat melaporkan bahwa komentar kualitatif dari tim selama presentasi proyek akhir mereka adalah positif. Hal ini relevan untuk melaporkan juga bahwa kompleksitas proyek ilmiah prototipe telah tinggi dan didasarkan pada kasus organisasi yang realistik.

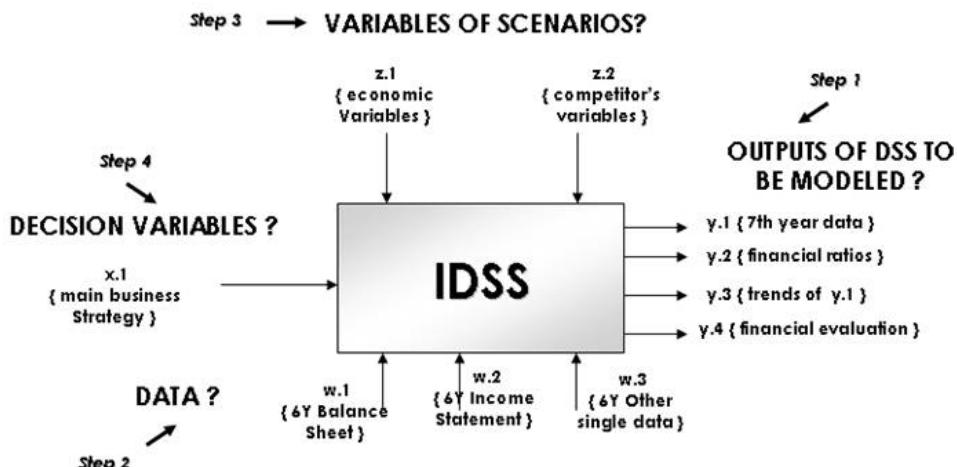
Manfaat utama IDSSE-M adalah menyediakan proses berorientasi rekayasa perangkat lunak sistematis untuk pengembang baru DMSS cerdas. Kami menggambarkan pemanfaatannya dengan kasus demo yang digunakan untuk tujuan pengajaran dalam kursus MSc. Lampiran A melaporkan gambaran umum kasus. Dalam aktivitas 1.1 (pengenalan situasi

pengambilan keputusan) sebagai bagian dari Fase Inisiasi Proyek IDSS, skema untuk menangkap struktur umum situasi pengambilan keputusan direalisasikan. Gambar 1 menunjukkan skema yang digunakan. Masalah utama adalah kurangnya model keuangan yang membantu mendukung keputusan keuangan pada strategi bisnis. Dua tindakan utama yang teridentifikasi (dan yang tidak diketahui sebelumnya mana yang terbaik) adalah: (i) mempertahankan strategi bisnis saat ini atau (ii) menerapkan strategi baru. Semua rincian konsekuensi potensial dari strategi yang sama atau baru dikembangkan pada tahap selanjutnya.



**Gambar 2.1** Pengenalan situasi umum pengambilan keputusan

Dalam aktivitas 1.2 (pembenaran IDSS) pengguna utama (Mr. Smith) dan analis IDSS harus memperkirakan manfaat berwujud dan tidak berwujud. Dalam kasus demo ini, Mr. Smith bertanggung jawab untuk memperkirakan biaya kesalahan keputusan yang disebabkan oleh estimasi keuangan yang salah, yang disebabkan oleh kurangnya model keuangan. Pada gilirannya, analis IDSS bertanggung jawab untuk memperkirakan biaya pengembangan. Setelah perkiraan diberikan, manfaat analisis biaya dapat direalisasikan. Dalam aktivitas 1.3, analis IDSS mengembangkan rencana pengembangan (aktivitas, jadwal, biaya, dan hasil utama). Dalam kasus nyata, negosiasi dapat terjadi sampai rencana akhir yang disepakati tercapai. Pada tahap desain IDSS, beberapa jenis elemen desain direalisasikan. Model desain awal adalah struktur umum untuk IDSS. Gambar 2 menunjukkan struktur seperti itu.



**Gambar 2.2** Struktur inti umum IDSS dan Arsitektur IDSS

Variabel yang diidentifikasi adalah: y1, y.2, dan y.3 (data keuangan tahun ke-7 untuk neraca dan laporan laba rugi, rasio keuangan, dan tren pada y.1); x.1 (variabel keputusan strategi bisnis utama); z.1 dan z.2 (variabel ekonomi dan strategi pesaing); dan w.1, w.2, dan w.3 (parameter neraca, laporan laba rugi, dan data keuangan lainnya selama enam tahun terakhir). Pada tahap ini, tidak ada rumus rinci yang diperlukan tetapi hanya struktur umum dari IDSS. Untuk kasus demo ini, kerumitan melibatkan kesulitan untuk menghasilkan model keuangan yang memadai daripada kesulitan untuk merancang struktur umum. Namun, kami percaya bahwa dua diagram awal (gambar 1 dan 2) dapat membantu situasi pengambilan keputusan yang lebih kompleks melalui identifikasi variabel penting: output, keputusan, skenario, dan parametrik. Pada Gambar 2, arsitektur IDSS juga dilaporkan. Struktur IDSS untuk kasus ini tidak menunjukkan komponen DSS dan ES internal, dan keempat keluaran (y) dilaporkan sebagai keluaran akhir. Dalam arsitektur IDSS, keputusan desain adalah bahwa tiga keluaran (y1, y.2, dan y.3) adalah keluaran antara, dan keluaran akhirnya adalah y.4. Dalam hal ini, pengaturan pertama (misalnya urutan DSS-ES) digunakan.

Selanjutnya, aktivitas desain adalah pembuatan kamus elemen. Untuk setiap kategori variabel (keputusan, skenario, output, dan parameter) entri data dihasilkan dengan item berikut: kode id, nama, rentang nilai, asal atau sumber, dan komentar. Tabel 5 dan 6 melaporkan sebagian beberapa entri. Misalnya, pada Tabel 5, sebagian tampilan output y dilaporkan (dari y.3.1 hingga y.3.13): tren rasio keuangan. Y.3.1 adalah tren dalam rasio lancar, dengan rentang nilai kualitatif antara menurun, stabil, atau tumbuh, yang akan dihitung dengan model numerik NM.3, melalui model regresi linier, dan akhirnya dikonversi ke nilai kualitatif. Dengan cara yang sama, pada Tabel 6, w.1 adalah kode untuk entri yang disebut sebagai parameter kas selama enam tahun terakhir, dan T.1 adalah identifikasi tabel data untuk sumbernya. Entri lain di kedua tabel melaporkan informasi serupa.

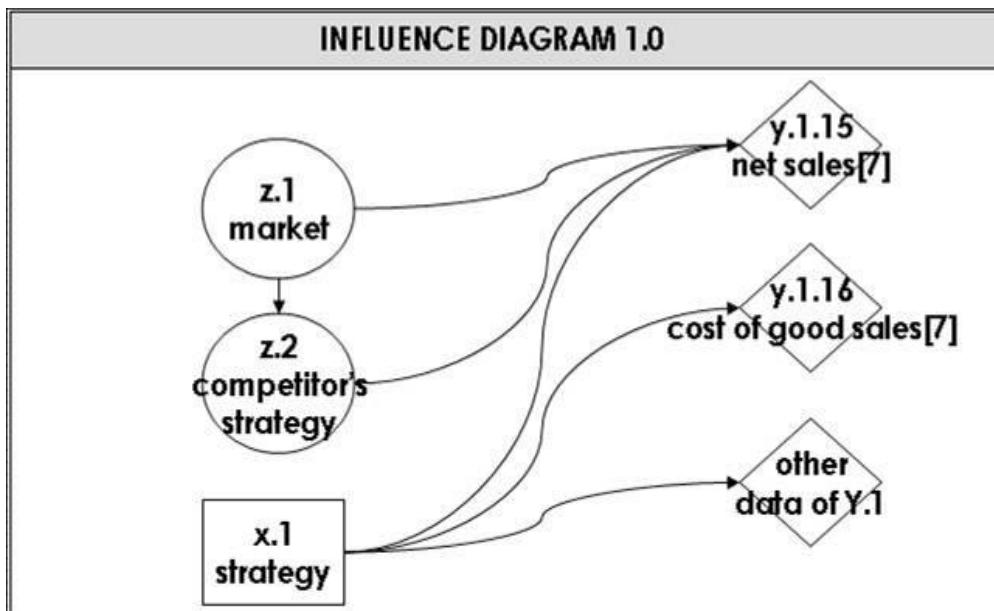
**Tabel 2.5 Kamus Unsur (tampilan sebagian dari keluaran y)**

CODE	NAME	VALUE	SOURCE	COMMENTS
Y.3	<b>Trends of Fin. Ratios</b>			
y.3.1	trend of current ratio	{decreasing, stable, growing}	NM.3	
y.3.2	trend of quick ratio	{decreasing, stable, growing}	NM.3	
y.3.3	trend of receivables turnover	{decreasing, stable, growing}	NM.3	
y.3.4	trend of inventory turnover	{decreasing, stable, growing}	NM.3	
y.3.5	trend of return on assets	{decreasing, stable, growing}	NM.3	
y.3.6	trend of net sales to working capital	{decreasing, stable, growing}	NM.3	using a linear regression model */
y.3.7	trend of debt to total assets	{decreasing, stable, growing}	NM.3	
y.3.8	trend of debt to equity ratio	{decreasing, stable, growing}	NM.3	
y.3.9	trend of gross margin on sales	{decreasing, stable, growing}	NM.3	
y.3.10	trend of net profit on sales	{decreasing, stable, growing}	NM.3	
y.3.11	trend of return on total assets	{decreasing, stable, growing}	NM.3	
y.3.12	trend of return on equity	{decreasing, stable, growing}	NM.3	
y.3.13	trend of Z-score	{decreasing, stable, growing}	NM.3	

Setelah langkah ini, kami maju dengan desain yang lebih rinci melalui perumusan dampak skenario dan definisi numerik dan simbolis dari prosedur. Proses ini akan dilengkapi dengan desain detail data, antarmuka pengguna, dan model modul proses. Dampak skenario dilakukan melalui diagram pengaruh klasik (Howard & Matheson, 2005). Notasi untuk diagram ini sudah terkenal (atau dapat dikonsultasikan dalam Howard dan Matheson, 2005), jadi kami melaporkan langsung diagram pengaruh untuk kasus demo ini pada Gambar 3.

**Tabel 2.6** Kamus Elemen (tampilan parsial parameter w)

CODE	NAME	VALUE	SOURCE	COMMENTS
w.1	cash[1..6]	N	T.1	/* T.1 contains the balance sheet */
w.2	accounts receivable[1..6]	N	T.1	
w.3	inventories[1..6]	N	T.1	
w.4	buildings & equipment[1..6]	N	T.1	
w.5	other assets[1..6]	N	T.1	
w.6	total assets[1..6]	N	NM.0	/* NM.0 is the numerical model for initializing calculated data */
w.7	accounts payable[1..6]	N	T.1	
w.8	notes payable[1..6]	N	T.1	
w.9	long-term debt[1..6]	N	T.1	
w.10	total liabilities[1..6]	N	NM.0	
w.11	capital stock[1..6]	N	T.1	
w.12	retained earnings[1..6]	N	T.1	
w.13	total stockholders equity[1..6]	N	NM.0	
w.14	total liabilities and equity[1..6]	N	NM.0	
w.15	net sales[1..6]	N	T.2	/* T.2 contains the income statement */
w.16	cost of goods sold[1..6]	N	T.2	
w.17	gross profit[1..6]	N	NM.0	
w.18	operating expenses[1..6]	N	T.2	
w.19	operating profit[1..6]	N	NM.0	
w.20	interest expense[1..6]	N	T.2	
w.21	profit before tax[1..6]	N	NM.0	
w.22	tax[1..6]	N	T.2	
w.23	net profit[1..6]	N	NM.0	
w.24	dividends paid[1..6]	N	T.3	/* T.3 contains other financial data */
w.25	number of shares[1..6]	N	T.3	
w.26	price per share[1..6]	N	T.3	

**Gambar 2.3** Dampak skenario

Variabel dalam lingkaran (z.1 dan z.2) adalah probabilistik. Variabel dalam kotak (x.1) bersifat keputusan. Variabel dalam berlian (y.1.15, y.1.16, data y.1 lainnya) adalah output. Diagram pengaruh ini sangat penting. Keluaran tambahan (menengah dan akhir) dihitung dari nilai-nilai penting ini. Namun, sementara diagram pengaruh membantu memvisualisasikan hubungan antara variabel penting seperti itu, tabel probabilistik komplementer diperlukan. Beberapa dilaporkan dalam Tabel 7 dan 8.

Sebagai contoh, pada Tabel 7, perkiraan probabilitas (oleh para ahli atau data historis) terjadinya nilai yang tumbuh dan stabil untuk variabel z.1 (pasar) adalah 0,40 dan 0,60 masing-masing. Dalam mode yang sama, perkiraan probabilitas (oleh para ahli atau data historis) dari terjadinya strategi berbasis biaya atau tetap sama untuk variabel z.2 (strategi pesaing) masing - Sistem Pendukung Keputusan (Dr Joseph Teguh Santoso dan Budi Hartono, M.Kom)

masing adalah 0,70 dan 0,30 ketika z.1 tumbuh, dan 0,20 dan 0,80 masing-masing ketika z.1 stabil. Pada Tabel 8, misalnya, efek gabungan dari kemunculan sekumpulan nilai tertentu untuk variabel x.1, z.1, dan z.2 pada variabel y.1.15, y.1.16, y.1.2, y.1.3, dan y.1.7 dilaporkan. Efek gabungan ini dihasilkan oleh para ahli, dan akhirnya dapat dihasilkan setelah beberapa iterasi. Prosedur Delphi untuk efek yang disepakati dapat digunakan jika diperlukan (Dalkey & Norman, 1963).

**Tabel 2.7** Tabel probabilitas untuk dampak skenario (tampilan parsial untuk variabel z.1 dan z.2)

<b>z.1 market</b>		<b>p( market )</b>	
<b>growing</b>		<b>0.40</b>	
<b>stable</b>		<b>0.60</b>	
<b>z.2 comp-sts</b>	<b>p( comp-s/ market )</b>	<b>p( comp-s/ market )</b>	
	<b>growing</b>	<b>stable</b>	
<b>cost-based st.</b>	<b>0.70</b>	<b>0.20</b>	
<b>keep-same st.</b>	<b>0.30</b>	<b>0.80</b>	

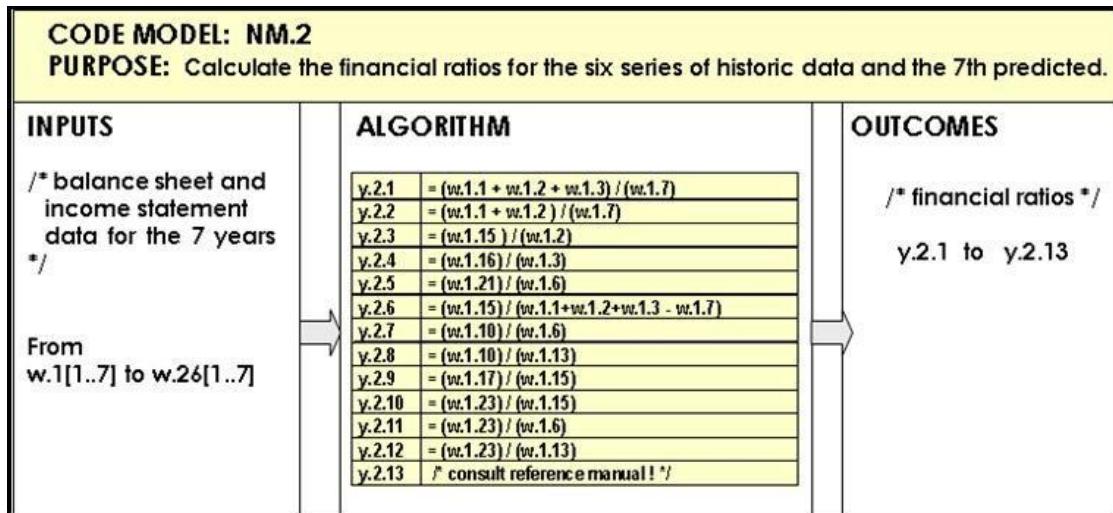
**Tabel 2.8** Tabel probabilitas untuk dampak skenario (tampilan parsial untuk efek gabungan variabel x.1, z.1 dan z.2)

<b>x.1 strategy</b>	<b>z.1 market</b>	<b>z.2 comp-strat</b>	<b>y.1.15 net sales[7]</b>	<b>y.1.16 cost of good sales[7]</b>	<b>y.1.2 accounts receivables[7]</b>	<b>y.1.3 inventory[7]</b>	<b>y.1.7 accounts payable[7]</b>
<b>keep-same</b>	<b>stable</b>	<b>same</b>	<b>5 (+/-)2%</b>	<b>5 (+/-)2%</b>	<b>5 (+/-)2%</b>	<b>5 (+/-)2%</b>	<b>inc in (y.1.2+y.1.3)</b>
<b>keep-same</b>	<b>stable</b>	<b>cost-based</b>	<b>- 7 (+/-)3%</b>	<b>- 7 (+/-)3%</b>	<b>-7%</b>	<b>-7%</b>	<b>dec in (y.1.2+y.1.3)</b>
<b>keep-same</b>	<b>growing</b>	<b>same</b>	<b>10 (+/-)5%</b>	<b>10 (+/-)5%</b>	<b>10 (+/-)5%</b>	<b>10 (+/-)5%</b>	<b>inc in (y.1.2+y.1.3)</b>
<b>keep-same</b>	<b>growing</b>	<b>cost-based</b>	<b>-10 (+/-)5%</b>	<b>-10 (+/-)5%</b>	<b>-10%</b>	<b>-10%</b>	<b>dec in (y.1.2+y.1.3)</b>
<b>based-cost</b>	<b>stable</b>	<b>same</b>	<b>8 (+/-)2%</b>	<b>5 (+/-)2%</b>	<b>5 (+/-)2%</b>	<b>5 (+/-)2%</b>	<b>inc in (y.1.2+y.1.3)</b>
<b>based-cost</b>	<b>stable</b>	<b>cost-based</b>	<b>= y.1.15[6]</b>	<b>= y.1.16[6]</b>	<b>= y.1.2[6]</b>	<b>= y.1.3[6]</b>	<b>= y.1.7</b>
<b>based-cost</b>	<b>growing</b>	<b>same</b>	<b>15 (+/-)5%</b>	<b>10 (+/-)5%</b>	<b>10 (+/-)5%</b>	<b>10 (+/-)5%</b>	<b>inc in (y.1.2+y.1.3)</b>
<b>based-cost</b>	<b>growing</b>	<b>cost-based</b>	<b>7 (+/-)2%</b>	<b>7 (+/-)2%</b>	<b>5 (+/-)2%</b>	<b>5 (+/-)2%</b>	<b>inc in (y.1.2+y.1.3)</b>

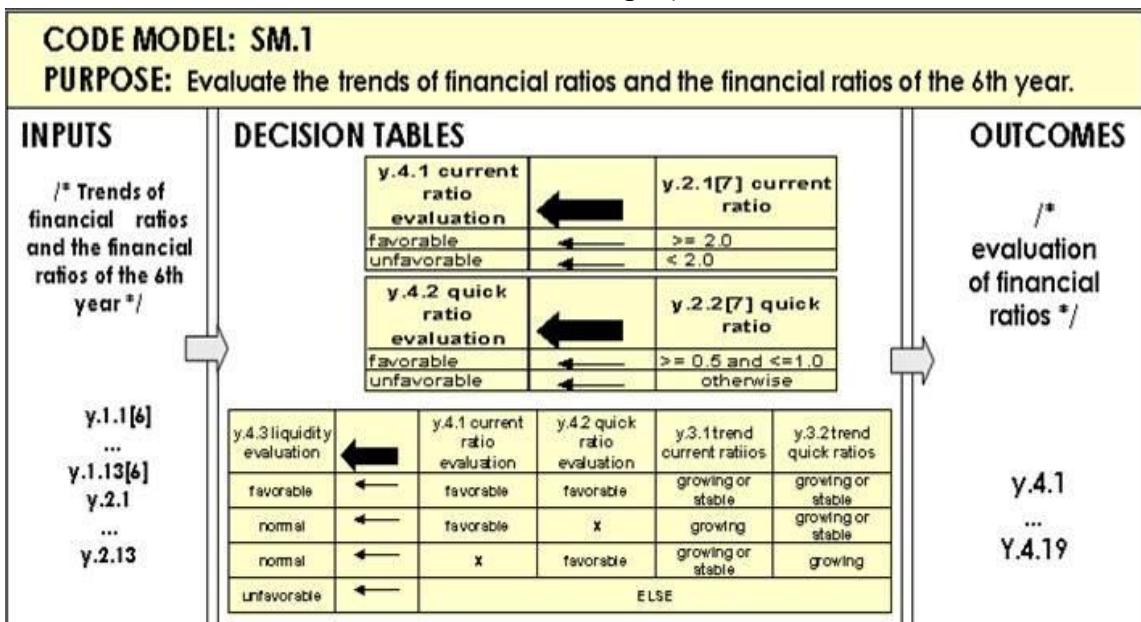
Kegiatan desain selanjutnya adalah perumusan prosedur numerik dan simbolik yang diperlukan untuk menghitung nilai numerik dan menyimpulkan nilai kualitatif. Tabel 9 dan 10 melaporkan beberapa prosedur ini. Pada Tabel 9, misalnya, dilaporkan prosedur numerik untuk menghitung rasio keuangan tahun-tahun terakhir. Pada gilirannya, pada Tabel 10, prosedur simbolis (sebagai tabel keputusan) untuk mengevaluasi situasi keuangan perusahaan secara keseluruhan dilaporkan (dari situasi yang sangat menguntungkan hingga sangat tidak menguntungkan). Pada Tabel 10, nilai kualitatif y.4.19 (evaluasi keuangan secara keseluruhan) disimpulkan dari y.4.3 (evaluasi likuiditas), y.4.7 (evaluasi aktivitas), y.4.11 (evaluasi leverage),

y.4.17 (evaluasi profitabilitas), dan y.4.18 (skor-z). Akhirnya, model database (E-R) harus dihasilkan, serta modul proses dan model antarmuka pengguna. Gambar 4, 5 dan 6 (a,b) melaporkan model tersebut.

**Tabel 2.9** Model numerik untuk menghitung nilai y.2.1 hingga y.2.13 (rasio keuangan)

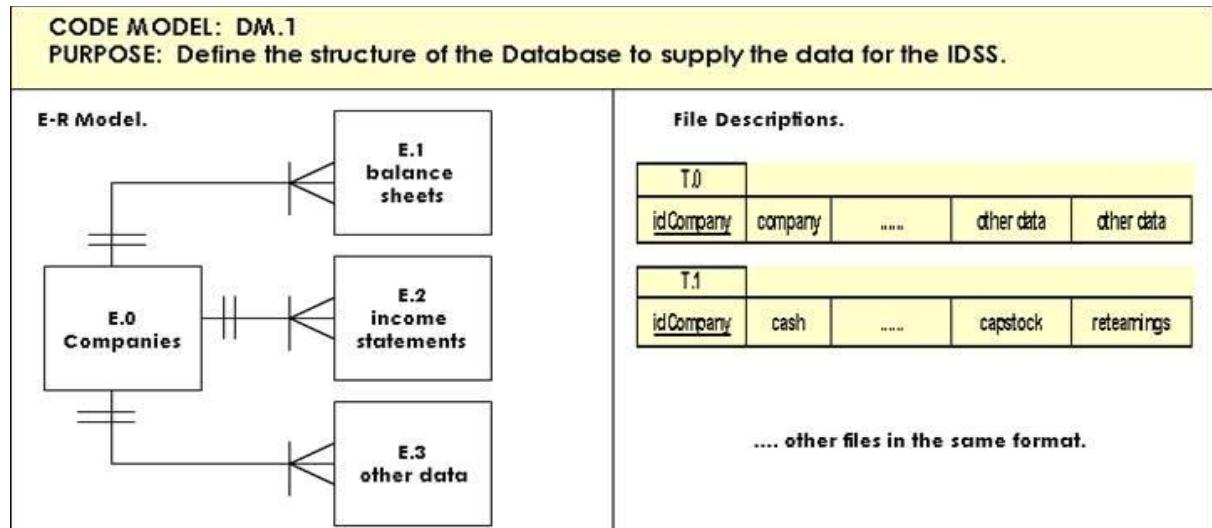


**Tabel 2.10** Model simbolik untuk menyimpulkan dari nilai kualitatif y.4.1 hingga y.4.19 (tren rasio keuangan)

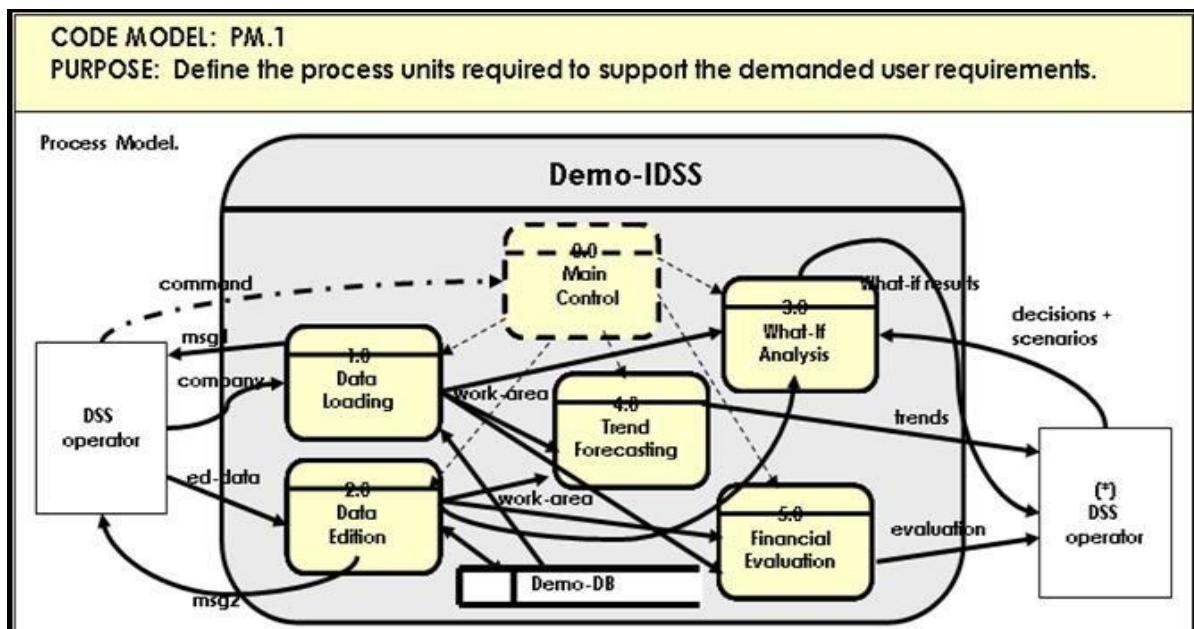


Pada Gambar 4, model data ER sederhana namun berguna yang diperlukan untuk IDSS ini dilaporkan. Hanya empat entitas yang diperlukan: perusahaan, neraca, laporan laba rugi, dan data keuangan lainnya. Setiap baris di setiap entitas mewakili satu tahun. Pada Gambar 5, model modul proses dilaporkan. Enam modul disarankan untuk mengimplementasikan IDSS tersebut: kontrol, pemuatan data, edisi data, analisis bagaimana-jika, peramalan tren, dan evaluasi keuangan. Aliran data dan penyimpanan juga dilaporkan, Akhirnya pada Gambar 6a dan 6b dua elemen model antarmuka pengguna dilaporkan: peta navigasi pengguna layar, dan salah satu layar yang dirancang (# 4.0). Di layar # 4.0, tiga proses utama akan dilakukan:

analisis bagaimana-jika, estimasi tren, dan evaluasi keuangan secara keseluruhan. Oleh karena itu, setelah realisasi tahap I dan II, IDSS telah ditentukan secara lengkap dan pengembangannya harus menjadi proses yang mulus. Mengingat bahwa kami mempertimbangkan relevansi IDSSE-M yang terfokus pada fase awal seperti itu, deskripsi dari dua fase terakhir adalah singkat.



Gambar 2.4 Model Data E-R

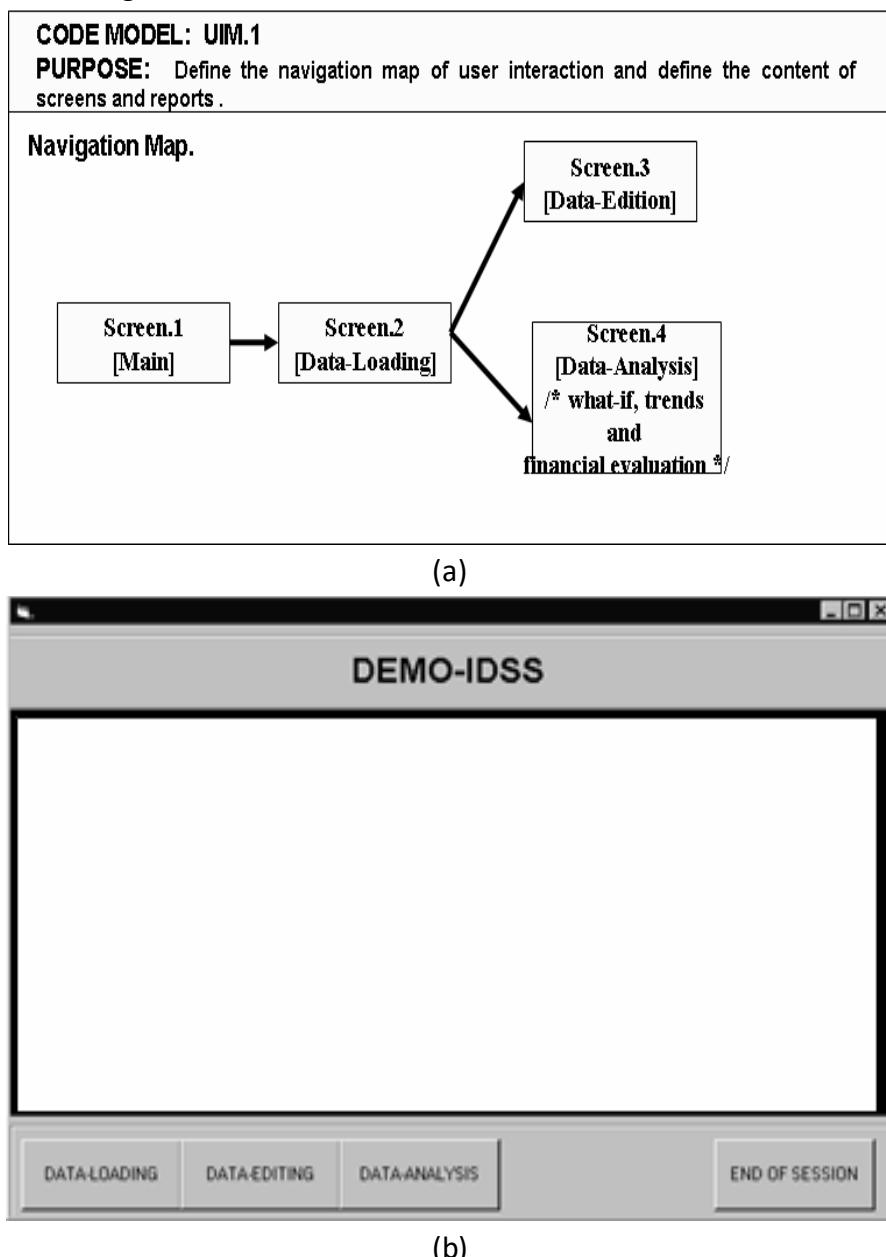


Gambar 2.5 Model Proses-Modul

Setelah desain IDSS lengkap selesai, fase ketiga (pembangunan dan evaluasi) dimulai. Dalam aktivitas 3.1, perangkat lunak yang sesuai harus dipilih untuk mengembangkan IDSS. Prosedur ilmu statistik dan manajemen harus ditempatkan untuk menghindari upaya kodifikasi yang tidak perlu. Untuk kasus ini, tidak ada pustaka yang telah ditentukan sebelumnya untuk analisis keuangan yang diidentifikasi untuk perangkat lunak yang dipilih (terjangkau, alat teknis terbaik, dan paling memadai untuk keahlian terkini dalam bahasa visual: VB.6). Pengembangan dilakukan oleh salah satu mahasiswa teknik perangkat lunak (dengan tingkat sarjana selesai (BSc. Nazario Ortiz)) pada tahun 1998. Pengembang menerima

dokumentasi lengkap dari IDSS yang dirancang dan versi lengkap pertama dibangun dalam tiga minggu, melalui tiga rilis dengan koreksi kecil.

Mengingat bahwa pengembang tidak terlatih secara formal dalam merancang dan membangun IDSS, kami menganggap bahwa penerapan IDSSE-M yang benar dapat memberikan dokumentasi (cetak biru desain) berkualitas tinggi bagi pengembang yang menghasilkan sistem final. Gambar 7 menunjukkan versi rilis awal (layar dalam bahasa Spanyol). Desain UI akhir sedikit dimodifikasi mengenai Gambar 6.b dengan batasan waktu. Rasio yang dilaporkan juga sedikit berbeda dari Porter (1998) mengingat beberapa variasi dalam formula keuangan.



**Gambar 2.6** (a) Model antarmuka pengguna (peta navigasi) (b). Model antarmuka pengguna (layar 4.0)

Dalam kegiatan 3.2, kasus terkenal tentang analisis keuangan dipertimbangkan: T.W. Kebangkrutan Grant (Porter, 1988; Largay dan Stickney, 1980). Lampiran A menjelaskan kasus umum dengan data nyata dari T.W. perusahaan Grant. Kegiatan 3.2 (evaluasi pengguna) untuk

kasus demo ini, dilakukan oleh penulis (salah satunya mengambil kursus MSc Analisis Keuangan, dan yang lain memegang gelar PhD di bidang Administrasi Bisnis). Sistem ini dianggap memuaskan dan benar. Evaluasi yang lebih luas dengan sampel analis keuangan tidak dikembangkan. Fase ini dilengkapi dengan penyelidikan kritis tentang perlunya perubahan besar atau ekstensi untuk sistem. Mengingat keterbatasan proyek penelitian, demo ini dianggap selesai.

Akhirnya, pada fase keempat (akhir proyek), dokumentasi lengkap diintegrasikan dalam satu laporan teknis (tersedia dalam bahasa Spanyol atas permintaan dari penulis utama). Pelatihan tidak diperlukan mengingat sistem tidak diberikan untuk pengguna keuangan akhir (atau mahasiswa pascasarjana dalam masalah keuangan). Namun, penulis menyadari kebutuhan untuk mendapatkan evaluasi metodologi dan produk akhir yang lebih kuat. Satu set kuesioner sedang dikumpulkan dari mahasiswa pascasarjana yang menggunakan metodologi untuk proyek akhir jangka waktu MSc ilmiah mereka. Hasil analisis statistik akan tersedia dalam publikasi mendatang.

		Economía																																
		AÑO1	AÑO2	AÑO3	AÑO4	AÑO5	AÑO6	AÑO7	T																									
<b>LIQUIDEZ</b>																																		
R1 Razón Circulante		2.56	2.47	3.22	0.56	2.10	1.99	1.49	-1																									
R2 Prueba del ácido		1.51	1.45	1.85	1.24	1.28	1.13	1.11	0																									
R3 Rotación C x C		4.04	3.99	4.80	1.76	3.23	3.55	2.78	-1																									
<b>ESTRUCTURA DE CAPITAL</b>																																		
R4 Razón De LP a Capital	%	17	10	12	20	26	21	14.60	-1																									
R5 Palanca Financiera	%	45	44	59	145	56	55	8513	1																									
<b>RENTABILIDAD.</b>																																		
R6 Retorno sobre activos	%	22	25	6	122	18	23	-19.07	-1																									
R7 Retorno sobre capital	%	42	44	14	265	41	52	105.53	-1																									
R8 Margen de Ventas	%	14	15	2	53	13	16	3.93	-1																									
R9 Margen de Operaciones	%	17	19	5	46	16	19	0.00	-1																									
R10 Margen Bruto	%	39	41	22	5	40	42	28.07	-1																									
R11 Dividendos x acción		1.08	1.25	1.40	1.49	1.48	1.49	1.65	0																									
<b>OPERACIONES</b>																																		
R12 Rotación de Inventario		2.76	2.58	1.64	2.67	2.44	2.09	0.66	-1																									
R13 Rotación de C x P		13.44	11.50	11.54	10.43	9.84	14.28	11.85	0																									
<table border="1" style="width: 100%; border-collapse: collapse;"> <tr> <td style="width: 10%;">AÑO</td> <td style="width: 30%;">ECONOMÍA</td> <td style="width: 30%;">Rendimiento</td> <td style="width: 30%;">Estado</td> </tr> <tr> <td>1</td> <td>ESTABLE</td> <td>LIQUIDEZ</td> <td>Desfavorable</td> </tr> <tr> <td>2</td> <td>CRECIENTE</td> <td>ESTRUCTURA DE CAPITAL</td> <td>Desfavorable</td> </tr> <tr> <td>3</td> <td>ESTABLE</td> <td>RENTABILIDAD.</td> <td>Desfavorable</td> </tr> <tr> <td>4</td> <td>RECESIÓN</td> <td>OPERACIONES</td> <td>Desfavorable</td> </tr> <tr> <td>5</td> <td></td> <td>SALUD FINANCIERA</td> <td>MUY DESFAVORABLE</td> </tr> <tr> <td>6</td> <td></td> <td></td> <td></td> </tr> </table>							AÑO	ECONOMÍA	Rendimiento	Estado	1	ESTABLE	LIQUIDEZ	Desfavorable	2	CRECIENTE	ESTRUCTURA DE CAPITAL	Desfavorable	3	ESTABLE	RENTABILIDAD.	Desfavorable	4	RECESIÓN	OPERACIONES	Desfavorable	5		SALUD FINANCIERA	MUY DESFAVORABLE	6			
AÑO	ECONOMÍA	Rendimiento	Estado																															
1	ESTABLE	LIQUIDEZ	Desfavorable																															
2	CRECIENTE	ESTRUCTURA DE CAPITAL	Desfavorable																															
3	ESTABLE	RENTABILIDAD.	Desfavorable																															
4	RECESIÓN	OPERACIONES	Desfavorable																															
5		SALUD FINANCIERA	MUY DESFAVORABLE																															
6																																		
<input type="button" value="Calcular Economía"/> <span style="margin-left: 20px;"><input type="button" value="Ein"/></span> <span><input type="button" value="Grabar"/></span> <span><input type="button" value="Traer"/></span> <span><input type="button" value="Cuentas"/></span>																																		

Gambar 2.7 Sistem IDSS yang dibangun (layar dalam bahasa Spanyol)

## 2.5 KESIMPULAN

Merancang dan membangun sistem pendukung keputusan cerdas (IDSS) tidak dapat dianggap sebagai tugas yang sepele. Sebagian besar IDSS yang dikembangkan di industri berasal dari organisasi berskala besar dan menuntut keahlian tinggi dalam pendekatan pemodelan DSS. Metodologi pengembangan IDSS telah tersedia sejak tahun 1980-an, tetapi penyebarannya terbatas pada jurnal ilmiah daripada buku teks. Akibatnya, beberapa praktisi (misalnya siswa MSc) memiliki akses ke metodologi tersebut.

Dalam bab ini, kami telah melaporkan IDSSE-M sebagai metodologi yang terstruktur dengan baik untuk mengembangkan sistem pendukung keputusan yang cerdas (misalnya sistem yang memiliki DSS klasik yang dilengkapi dengan komponen ES). Metodologi ini telah dijelaskan dengan mengacu pada akar teoretisnya. Kasus demo untuk tujuan ilustrasi telah dilaporkan. Meskipun kami tidak dapat mengklaim bahwa IDSSE-M telah digunakan dalam proyek nyata yang lengkap, IDSSE-M telah digunakan untuk sejumlah besar (sekitar seratus) siswa MSc dalam proyek akhir semester semu dengan hasil yang memuaskan. Oleh karena itu, kami menganggap bahwa IDSSE-M memberikan panduan metodologis yang jelas untuk tujuan tersebut.

## **Lampiran**

### **A. Deskripsi Kasus IDSS**

#### **A.1 Deskripsi Umum**

Mr Smith adalah CFO di Perusahaan ABC. Dia memiliki beberapa tanggung jawab - sebagai direktur keuangan - seperti: untuk menjaga kesehatan keuangan organisasi, mengoptimalkan penggunaan sumber daya keuangan dan mendapatkan sumber daya keuangan eksternal yang optimal. Mr Smith memiliki 3 departemen di bawah tanggung jawabnya. Ini adalah sebagai berikut: Departemen Akuntansi dipimpin oleh Mr Jones, Departemen Investasi dan Manajemen Arus Kas, dipimpin oleh Mr Fields dan Staf Analisis Keuangan, dengan satu staf, Mr Brown. Juga, Tuan Smith menerima dukungan dari asisten eksekutifnya Nona Thompson. Fungsi utama dari arah Keuangan adalah: Perencanaan Keuangan, Manajemen Keuangan dan Analisis Keuangan.

Perusahaan ABC telah memiliki hasil keuangan yang memadai dalam 5 tahun terakhir tetapi karena perubahan ekonomi di sektor industri, Mr Smith khawatir tren positif ini dapat dimodifikasi dengan dampak negatif dalam tujuan unit organisasi mereka. Kemudian, dia tertarik pada pelacakan dan pemantauan hasil keuangan utama yang diperoleh dari neraca dan laporan laba rugi . Secara khusus, ia tertarik untuk memantau rasio keuangan yang terkait dengan profitabilitas, likuiditas, leverage, dan aktivitas. Mr. Smith tertarik agar analis keuangannya dapat mengevaluasi dampak dari beberapa faktor eksternal seperti ekonomi dan strategi pesaing. Dia, Mr. Fields dan analis keuangan telah membahas model kecil di mana pergerakan ekonomi dan dari strategi pesaing dapat diperkirakan pada hasil penjualan untuk tahun berikutnya. Juga, mereka telah menurunkan model regresi linier sederhana untuk memperkirakan tren hasil rasio keuangan utama. Mr Smith juga tertarik untuk menerima evaluasi singkat dan cepat dari rasio keuangan ini dalam hal situasi yang menguntungkan, normal atau tidak menguntungkan. Trennya dapat diperkirakan dalam pola yang meningkat, stabil atau menurun. Mr Smith menganggap bahwa model yang ringkas dan sederhana bisa lebih berguna untuk memulai sistem ini daripada model yang sangat kompleks, jadi dia berpikir bahwa analisis keputusan tentang strategi apa yang harus diambil dalam ekonomi yang berbeda dan strategi pesaing yang mungkin, adalah dukungan yang baik untuk proses pengambilan keputusannya. Dia juga tahu bahwa ada indikator keuangan lain yang bisa berguna seperti Z-Score, tapi baginya fitur ini opsional.

#### **A.2 Misi dan Tujuan Unit Organisasi**

Pernyataan Misi ABC: "Untuk menjaga kesehatan keuangan organisasi untuk berkolaborasi dalam nilai penciptaan perusahaan secara keseluruhan". Tujuan: (i) meningkatkan 5% tingkat profitabilitas organisasi; (ii) menjaga leverage keuangan paling banyak 60%; dan (iii) menyelesaikan 100% kewajiban keuangan jangka pendek.

### A.3 Data Neraca dan Laporan Laba Rugi (Kasus T.W. Grant Company) (sumber: Porter, 1988; Largay dan Stickney, 1980)

**Tabel A.1** Data Neraca dan Laporan Laba Rugi

d1	ORGANIZATION	W.T. GRANT COMPANY					
	BALANCE SHEET	1	2	3	4	5	6
<b>ASSETS</b>							
d2	Cash	25,141	25,639	32,977	34,009	49,851	30,943
d3	Accounts receivable	272,450	312,776	368,267	419,731	477,324	542,751
d5	Inventories	183,722	208,623	222,128	260,492	298,696	399,533
d6	Properties and Equipment	47,578	49,931	55,311	61,832	77,173	91,420
d7	Other assets	22,716	25,140	28,112	31,564	41,626	46,051
d8	<b>TOTAL ASSETS</b>	<b>551,607</b>	<b>622,109</b>	<b>706,795</b>	<b>807,628</b>	<b>944,670</b>	<b>1,110,698</b>
<b>LIABILITIES</b>							
d9	Accounts payable	49,831	64,321	70,853	80,861	94,677	78,789
d11	Notes payables	198,456	234,417	309,847	392,421	395,816	570,898
d12	Long-term debts	62,622	43,251	35,407	32,310	128,432	126,672
d15	<b>TOTAL LIABILITIES</b>	<b>310,909</b>	<b>341,989</b>	<b>416,107</b>	<b>505,592</b>	<b>618,925</b>	<b>776,359</b>
<b>EQUITY</b>							
d16	Capital Stock	73,253	87,581	79,009	71,601	81,238	73,186
d17	Retained Earnings	167,445	192,536	211,679	230,435	244,507	261,153
d18	Total Equities	240,698	280,117	290,688	302,036	325,745	334,339
d19	<b>TOTAL LIABILITIES+EQUITIES</b>	<b>551,607</b>	<b>622,106</b>	<b>706,795</b>	<b>807,628</b>	<b>944,670</b>	<b>1,110,698</b>
<b>INCOME STATEMENT</b>							
d20	Net Sales	982,244	1,095,083	1,214,666	1,259,116	1,378,251	1,648,500
d21	Cost of Sales	669,560	739,459	817,671	843,192	931,237	1,125,261
d22	Gross Profit	312,684	355,624	396,995	415,924	447,014	523,239
d23	Operating Expenses	242,223	270,583	302,267	324,673	368,740	438,574
d24	Operating Profit	70,461	85,041	94,728	91,251	78,274	84,665
d25	Interest Expenses	11,248	13,146	14,919	18,874	16,562	21,128
d26	Profit before Taxes	59,213	71,895	79,809	72,377	61,712	63,537
d27	Taxes	26,650	34,000	38,000	32,800	26,500	25,750
d28	Net Profit	32,563	37,895	41,809	39,577	35,212	37,787
<b>OTHER DATA</b>							
d29	dividends paid	13,805	17,160	19,280	20,426	20,794	20,807
d30	number of shares	12,817	13,714	13,728	13,684	14,023	13,993
d31	price by share	38	43	55	65	43	31

### A.4 Informasi tentang Rasio Keuangan

Rasio keuangan yang diminta oleh Mr. Smith tampak pada Tabel A.2.

**Tabel A.2** Rasio Keuangan

FINANCIAL RATIOS	FORMULES
<b>LIQUITY RATIOS</b>	
Current ratio	= (<Current Assets> / <Current Liabilities> )
Quick ratio	= (<Current Assets> - <Inventory>) / <Current Liabilities> )
<b>ACTIVITY-OPERATION RATIOS</b>	
Receivables turnover	= (<Sales> / <Receivables> )
Inventory turnover	= (<Cost of Sales> / <Inventory> )
Return on Investment (ROI)	= (<Net Profit> / <Total Assets> )
Sales to Assets Ratio (SAR)	= (<Sales> / <Total Assets> )
<b>LEVERAGE RATIOS</b>	
Net sales to working capital	= (<Sales> / (WC= <Total Current Assets> - <Total Current Liabilities>)))
Debt to total assets	= (<Total Liabilities> / <Total Assets> )
Debt to Equity Ratio (DER)	= (<Total Liabilities> / <Total Equity>)
<b>PROFITABILITY RATIOS</b>	
Gross margin on sales	= (<Sales> - <Cost of Sales>) / (Sales)
Net profit on sales	= (<Net Profit> / <Sales> )
Return on assets (ROA)	= (<Net Profit before Taxes> / <Total Assets> )
Return on equity (ROE)	= (<Total Current Assets> / <Total Current Liabilities> )
Z-score	= (ROA*3.3)+( SAR*0.999)+(0.6/DER) + (WC<Assets>)*1.2 + (ER/Assets)*1.4

#### A.5 Gagasan Umum Model Mr. Smith

- Pasar mempengaruhi penjualan bersih dan strategi pesaing.
- Strategi pesaing mempengaruhi penjualan bersih kita.
- Strategi kami mempengaruhi hasil penjualan bersih, harga pokok penjualan dan data keuangan lainnya.
- Kami dapat memperkirakan beberapa probabilitas subjektif dari nilai pasar (tumbuh atau stabil) dan nilai strategi pesaing (berbasis biaya atau mempertahankan strategi yang sama saat ini).
- Selain itu, kami dapat memperkirakan persentase kenaikan atau penurunan nilai penjualan bersih, harga pokok penjualan, dan data keuangan lainnya berdasarkan nilai pasar, strategi pesaing, dan strategi kami yang diputuskan.

## BAB 3

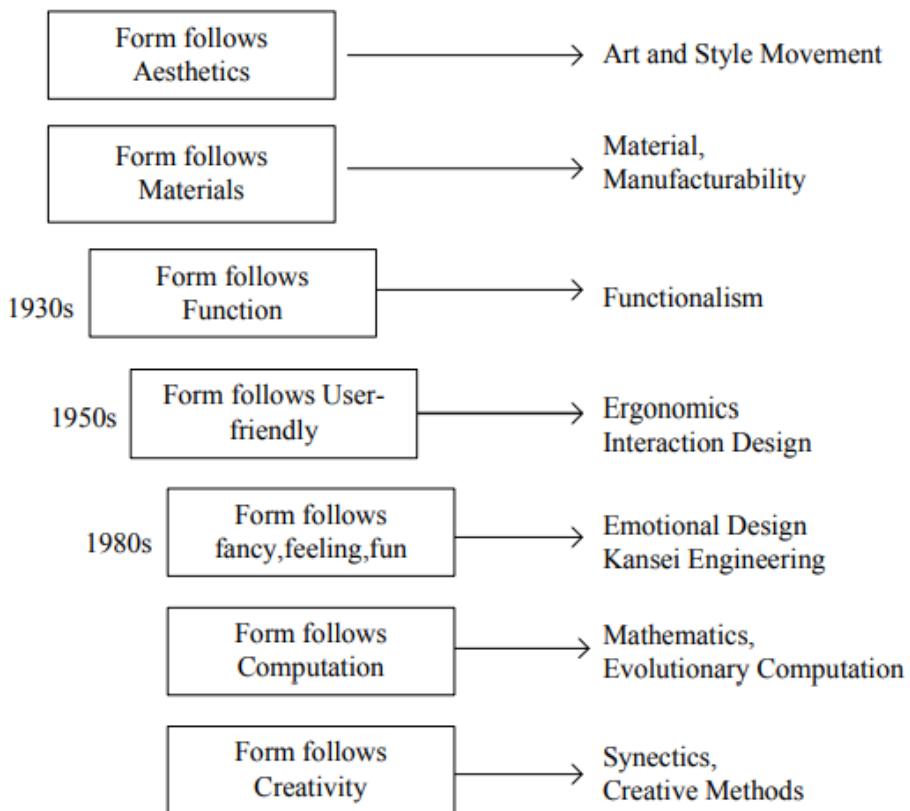
### DESAIN BENTUK PRODUK BERDASARKAN SISTEM PENDUKUNG KEPUTUSAN

Dari perspektif sejarah, dua masalah mendasar diamati untuk desainer industri: (1) apa proses desain bentuk dalam konteks proses desain produk modern, dan (2) bagaimana teori desain bentuk, metode, alat dan bantuan komputer. perangkat lunak dapat digunakan secara efektif untuk menciptakan bentuk produk. Kerangka kerja diusulkan untuk menyelesaikan masalah dengan menggambarkan hubungan masalah desain produk, proses desain produk, proses desain bentuk, metode dan alat desain bentuk dengan pertimbangan persyaratan fungsional, ergonomis, emosional, dan manufaktur. Kerangka kerja yang diterapkan di sini adalah tipe baru dari sistem pendukung keputusan (DSS) - sistem pendukung keputusan berorientasi objek untuk membantu para desainer dalam merancang bentuk produk. Kasus skuter menggambarkan penggunaan kerangka kerja dan implementasi DSS. Menurut proses desain dan metode desain yang direncanakan, tata bahasa bentuk digunakan sebagai representasi pengetahuan dan metode penalaran pengetahuan untuk membuat bentuk skuter. Persyaratan fungsional dan ergonomis dapat dinyatakan secara eksplisit dalam tata bahasa bentuk. Perancang dapat secara interaktif menerapkan tata bahasa bentuk dengan mempertimbangkan kebutuhan emosional dan manufaktur. Oleh karena itu, desainer industri dapat menggunakan DSS untuk merencanakan proses desain bentuk mereka sendiri dan memanfaatkan alat desain bentuk, metode, pengetahuan untuk masalah desain mereka sendiri tanpa mempraktikkan pengetahuan yang rumit dan interdisipliner tentang desain bentuk selama bertahun-tahun.

#### **3.1 PENDAHULUAN**

Produk modern dirancang dan diproduksi untuk pasar tertentu melalui proses pengembangan produk yang melibatkan tim yang terdiri dari orang-orang dengan beragam keahlian untuk mengembangkan produk guna memenuhi kebutuhan manusia. Dalam pasar yang sangat kompetitif, desain produk menjadi semakin menantang karena kebutuhan pelanggan yang beragam dan kompleksitas teknologi. Desainer industri berkewajiban menciptakan bentuk produk yang memenuhi semua persyaratan mulai dari fungsi teknik, estetika dan emosi, ergonomi dan kegunaan, hingga manufaktur.

Terlebih lagi, produk harus sesuai dengan keramahan lingkungan. Diamati bahwa setiap persyaratan yang disebutkan menciptakan masalah baru, dan kemudian gerakan desain utama untuk memecahkan masalah muncul sebagai pergeseran paradigma dalam sejarah desain industri. Teori desain, alat desain, dan metode desain terus dikembangkan untuk menjawab masalah desain baru. Gambar 1 menyajikan masalah desain bentuk utama yang dinyatakan sebagai pernyataan [1-3]. Transisi yang diamati ini dari satu pernyataan ke pernyataan berikutnya diikuti oleh pengembangan semua jenis teori desain, proses desain, metode, dan alat bantu komputer. Dari sejarah masing-masing desain produk, pengembangan produk modern dalam konteks sosial dan budaya yang berubah mengarah pada dua masalah mendasar bagi desainer industri untuk menciptakan bentuk produk.



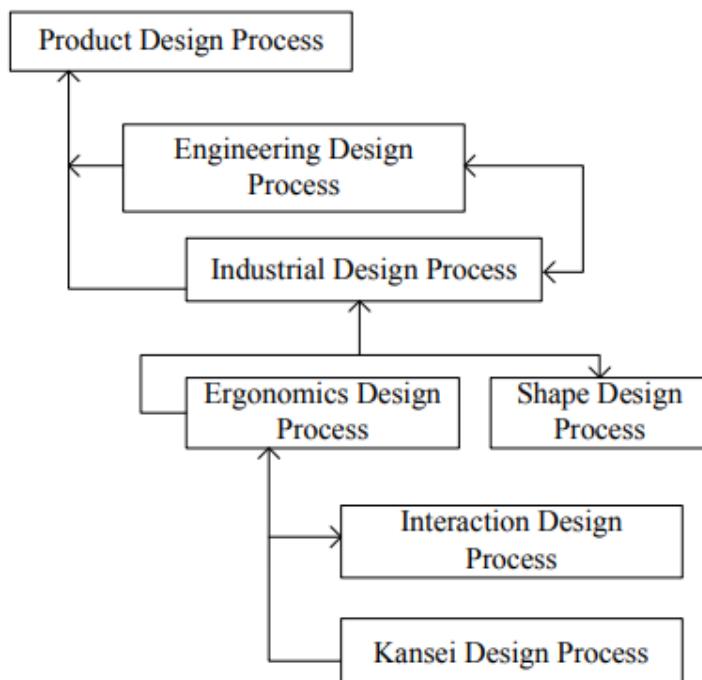
**Gambar 3.1** Pernyataan untuk masalah desain bentuk dan teori desain bentuk

### (1) Bagaimana proses desain bentuk dalam konteks desain produk?

Desain bentuk produk dapat dianggap sebagai proses pemecahan masalah untuk membuat bentuk produk akhir dari persyaratan awal [4]. Berdasarkan berbagai permasalahan desain tersebut, desainer industri perlu memikirkan bagaimana merancang bentuk produk dengan langkah, metode, dan alat yang tepat, karena berkaitan dengan kualitas produk, biaya, dan time-to-market. Kegiatan desain bentuk bukanlah rutinitas yang berlaku untuk semua jenis masalah desain dan produk di berbagai industri. Semua jenis proses untuk desain produk, desain teknik, desain industri, desain interaksi, desain ergonomis, dan desain Kansei untuk situasi desain yang berbeda telah diusulkan [5-13]. Dalam praktiknya, banyak perusahaan seperti 3M, IDEO, Microsoft, Philips, Toyota dan Xerox juga mengembangkan proses mereka sendiri yang menjadi tolok ukur dan standar perusahaan lain karena inovasi produk mereka yang sukses. Proses desain produk dari perusahaan ini telah menjadi subyek dari banyak studi kasus dan buku [14-15].

Menerapkan proses desain produk mereka ke proyek praktis menjadi tantangan karena sulitnya mengaitkan salah satu proses desain produk generik yang ada dengan tugas desain spesifik saat ini. Manajer proyek mengandalkan pengalaman dan intuisi untuk merencanakan proses desain. Pemilihan dan penyesuaian dari proses desain produk yang terkenal untuk masalah desain bentuk saat ini adalah masalah utama yang tidak dipelajari dengan baik. Selanjutnya, desain bentuk bukanlah aktivitas yang terisolasi dalam proses desain produk, seperti yang ditunjukkan pada Gambar 2. Rekayasa serentak telah dikembangkan untuk mengoordinasikan semua jenis proses desain dari berbagai disiplin ilmu

terhadap antarmuka proses keseluruhan konvensional. Antarmuka jaringan yang kompleks dalam rekayasa bersamaan menentukan kapan tugas desain bentuk aktif dan bagaimana desainer industri terlibat dalam proses desain produk. Kegiatan desain bentuk dalam konteks rekayasa konkuren lebih rumit dan tidak mudah dikelola. Beberapa studi mempertimbangkan bagaimana mengintegrasikan proses desain dari berbagai disiplin ilmu ke dalam proses desain produk [16-19].



**Gambar 3.2** Hubungan proses desain bentuk dalam proses desain produk

Singkatnya, desainer industri dihadapkan pada kesulitan merencanakan proses desain keseluruhan bentuk dalam konteks proses desain produk karena berbagai tugas desain dalam mengembangkan produk modern, dan banyaknya pilihan untuk proses desain produk dalam praktik dan literatur. Keputusan tentang proses desain bentuk untuk tugas desain saat ini tidak dapat bergantung pada intuisi dan pengalaman desainer industri saja. Kualitas pengambilan keputusan pada proses desain yang direncanakan tidak memadai di pasar yang sangat kompetitif.

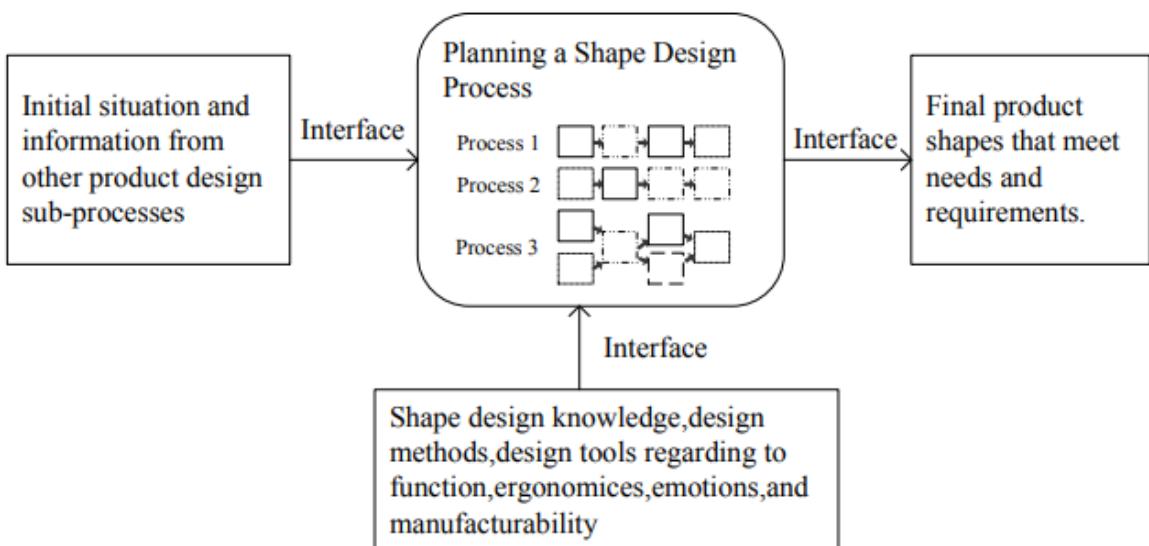
- (2) Bagaimana pengetahuan desain bentuk dapat diterapkan secara efektif untuk memecahkan masalah dalam menciptakan bentuk produk?

Desain bentuk produk biasanya dianggap sebagai kotak hitam, karena pemikiran dan pengetahuan yang diperlukan untuk mendesain ada di dalam otak desainer. Ada minat besar dalam mempelajari bagaimana seorang desainer memecahkan masalah desain dan menciptakan ide-ide dalam teori desain. Kegiatan desain diselidiki melalui wawancara desainer, catatan langsung dan observasi, dan studi kasus. Takeda menunjukkan bahwa solusi desain diperoleh dengan cara yang berbeda menggunakan pengetahuan untuk memenuhi spesifikasi yang dibutuhkan [20]. Cushman mengidentifikasi tiga cara menggunakan pengetahuan faktor manusia untuk desain bentuk: coba-coba, intuisi, dan prinsip desain [16].

Dalam tulisan ini, pendekatannya secara eksplisit menguraikan masalah desain bentuk menjadi banyak sub-masalah yang dapat lebih mudah diselesaikan oleh desainer industri.

Oleh karena itu, masalah merancang suatu bentuk produk dapat diuraikan menjadi beberapa sub-masalah yang secara terpisah dipertimbangkan dengan kendala fungsi, ergonomi, sensorik emosional, dan manufakturabilitas. Kemudian desainer dapat mensintesis bentuk produk akhir dari solusi sub-masalah. Dalam pendekatan ini, setiap sub-masalah dapat dengan mudah ditangani dengan menggunakan alat dan pengetahuan yang sesuai. Hal ini juga menjadi layak untuk memanfaatkan kecerdasan buatan dan teknologi dalam ilmu komputer untuk membantu desainer dalam memecahkan sub-masalah. Pendekatan ini menyiratkan bahwa proses desain bentuk harus dibagi menjadi beberapa fase. Selama setiap fase, masalah desain dapat diselesaikan dengan beberapa metode desain. John Chris Jones menyajikan bagan untuk memilih metode desain selama fase yang berbeda dari proses desain bentuk sebagai strategi desain [4]. Cari baris untuk informasi input yang harus siap sebelum kita ingin menggunakan metode desain tertentu. Kemudian cari kolom untuk output setelah kita menggunakan metode desain. Elemen di persimpangan baris dan kolom menunjukkan metode desain. Bagan sederhana dan mudah digunakan, tetapi tidak dapat menunjukkan antarmuka dan proses nyata untuk desain produk, dan metode desain yang disebutkan tidak diperbarui. Otto dan Wood menunjukkan peta jalan untuk pemilihan metode desain dasar atau lanjutan dalam proses desain produk [8]. Sayangnya roadmap rinci untuk proses desain bentuk tidak dijelaskan.

Gambar 3 menyajikan skema untuk mengilustrasikan masalah mendasar yang dibahas: mengubah persyaratan awal menjadi desain bentuk produk akhir dengan merencanakan proses desain bentuk yang tepat dan menggunakan metode, alat, serta pengetahuan yang sesuai. Makalah ini menyajikan kerangka kerja yang menggambarkan hubungan masalah desain produk, proses desain produk, proses desain bentuk, metode dan alat desain bentuk. Dengan demikian, desainer dapat menggunakan kerangka kerja untuk memilih atau membuat proses desain bentuk mereka sendiri, memilih alat desain bentuk, metode, dan menggunakan pengetahuan untuk masalah desain mereka sendiri. Masalah mendasar diselesaikan dengan panduan kerangka yang diusulkan dalam penelitian ini.



**Gambar 3.3** Skema yang menggambarkan masalah mendasar dalam desain bentuk produk

### **3.2 KERANGKA PROSES DESAIN PRODUK**

Tujuan dari kerangka kerja adalah untuk mengintegrasikan proses desain di berbagai disiplin ilmu serta metode desain untuk desain bentuk produk di bawah tugas desain yang berbeda dengan cara yang tepat. Dua fitur, kelengkapan dan fleksibilitas, dipertimbangkan untuk merancang kerangka kerja. Kelengkapan menunjukkan bahwa kerangka kerja dapat disesuaikan dengan semua jenis tugas desain produk. Fleksibilitas memungkinkan kerangka kerja untuk dengan mudah diperluas dengan proses desain, metode, dan alat yang baru dikembangkan. Pendekatan membangun kerangka kerja dijelaskan sebagai berikut:

- (1) Sebuah survei komprehensif dilakukan pada tugas desain produk, semua jenis proses desain dari berbagai disiplin ilmu, dan metode serta alat yang terkait.
- (2) Setiap proses desain dapat dibagi menjadi sub-proses dengan tingkat detail yang sesuai. Hubungan antara proses desain yang berbeda dari literatur diselidiki.
- (3) Kerangka proses desain dibangun.
- (4) Akhirnya, metode dan alat desain dikaitkan dengan proses desain dalam kerangka kerja.

Pekerjaan detail dari kerangka yang diusulkan hanya dilakukan untuk proses desain bentuk karena ruang lingkup makalah ini. Kerangka kerja dibahas dari dua aspek: proses desain bentuk dalam konteks desain produk dan metode serta pengetahuan desain bentuk yang terkait.

Ketika mensurvei proses desain produk, proses desain teknik, dan proses desain industri, ditemukan bahwa terminologi tersebut ambigu dalam literatur. Proses desain teknik hampir dapat mewakili proses desain produk dalam beberapa kasus. Sebuah proses desain industri mungkin setara dengan proses desain produk untuk beberapa desainer industri [21]. Itu hanya akan mengacu pada proses menciptakan bentuk produk untuk yang lain. Proses desain produk dapat menunjukkan integrasi proses rekayasa dan desain industri dalam beberapa publikasi. Selain itu, hubungan rinci antara proses desain teknik dan proses desain industri tidak ditampilkan dalam literatur. Terminologi yang berbeda tentang "proses desain" dalam literatur menghasilkan kesulitan dalam mengintegrasikan proses desain yang diusulkan ini ke dalam suatu kerangka kerja. Howard dkk. menyediakan survei yang komprehensif untuk proses desain teknik. Mereka membandingkan semua terminologi dan model proses yang diusulkan dalam literatur [22]. Karya Howard et al. membantu memahami kompleksitas proses desain rekayasa. Sayangnya, tidak ada pekerjaan serupa yang dilakukan dalam proses desain industri dan proses desain produk. Sebagai terminologi diklarifikasi, hubungan proses desain dapat diklasifikasikan dan dibandingkan untuk diskusi lebih lanjut.

Kesulitan lain dalam mempelajari proses desain muncul dari jenis produk yang terkait dengan proses desain yang sesuai. Proses desain khusus untuk beberapa produk seperti ponsel, mesin fotokopi dan mobil telah dikembangkan dan diungkapkan dalam literatur. Pengembangan untuk satu jenis produk dapat memiliki proses desain yang berbeda di bawah berbagai tugas desain. Kerangka kerja harus dapat mengintegrasikan dan mewakili proses desain di bawah berbagai tugas desain untuk semua jenis produk.

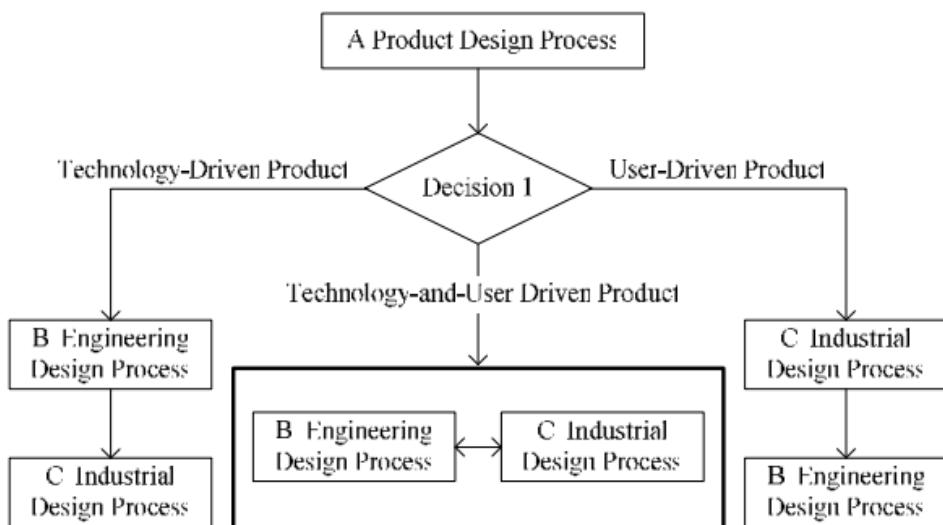
#### **Jenis Dasar Proses Desain Produk**

Situasi keputusan pertama dalam merencanakan proses desain produk adalah memilih kategori produk. Produk dapat diklasifikasikan ke dalam salah satu dari tiga kategori: produk

yang digerakkan oleh teknologi, produk yang digerakkan oleh teknologi dan pengguna, atau produk yang digerakkan oleh pengguna. Produk yang digerakkan oleh teknologi difokuskan pada fungsi rekayasa sedangkan produk yang digerakkan oleh pengguna berfokus pada fungsi faktor manusia. Strategi produk menentukan kategori produk. Pendekatan berbasis teknologi biasanya diadopsi untuk mengembangkan produk pada tahap bayi dan pertumbuhan dari siklus hidupnya – kurva S. Ketika produk sudah matang, strategi yang digerakkan oleh pengguna digunakan [7]. Proses desain produk dikaitkan dengan kategori produk. Oleh karena itu, penggunaan istilah dan literatur yang dirujuk untuk “proses desain” untuk membangun kerangka disarankan sebagai berikut:

- Proses desain untuk produk yang digerakkan oleh teknologi disebut sebagai proses desain rekayasa dalam literatur.
- Proses desain untuk produk yang digerakkan oleh pengguna disebut sebagai proses desain industri dalam literatur.
- Proses desain untuk produk yang digerakkan oleh teknologi dan pengguna disebut sebagai desain industri, desain teknik, dan desain produk dalam literatur.
- Proses desain produk mencakup proses desain teknik dan proses desain industri dalam arti luas.

Setiap kategori produk dikaitkan dengan tiga jenis umum proses desain produk seperti yang ditunjukkan pada Gambar 4. Untuk produk berbasis teknologi, proses desain rekayasa diikuti oleh proses desain industri. Proses rekayasa paralel dengan proses desain industri untuk produk yang digerakkan oleh teknologi dan pengguna. Proses desain industri memimpin proses desain rekayasa untuk produk yang digerakkan oleh pengguna [7]. Sebuah proses desain rekayasa berurusan dengan desain fungsi rekayasa dalam rentang yang luas termasuk teknik mesin, teknik elektronik, dan rekayasa perangkat lunak. Proses desain industri berkaitan dengan faktor manusia, interaksi dan estetika. Bagian berikut akan menjelaskan proses desain untuk setiap kategori produk secara rinci.



**Gambar 3.4** Proses desain produk untuk berbagai kategori produk

### Proses Desain untuk Produk Berbasis Teknologi

Proses desain untuk produk berbasis teknologi terdiri dari dua sub-proses:

(1) proses desain rekayasa dan (2) proses desain industri. Pertama, kelayakan konsep rekayasa diverifikasi. Selanjutnya, bentuk produk dibuat dengan proses desain industri. Untuk menghindari ambiguitas dari istilah yang sama yang digunakan dalam proses desain rekayasa dan proses desain industri, desain konsep dan desain detail dalam proses desain rekayasa dinamakan sebagai desain konsep rekayasa dan desain detail rekayasa; konsep dan desain detail dalam proses desain industri masing-masing disebut sebagai desain konsep industri dan desain detail industri. Desain konfigurasi dalam proses desain rekayasa disebut sebagai desain organisasi dalam proses desain industri.

Detail proses desain teknik dan desain industri tergantung pada jenis tugas desain: desain asli atau desain ulang. Proses rekayasa dan desain industri sangat berbeda untuk setiap jenis tugas desain produk. Penentuan tugas desain sebagai desain asli atau desain ulang tergantung pada strategi perusahaan untuk inovasi yang mengganggu atau inovasi yang berkelanjutan. Desain asli mengacu pada penggunaan prinsip-prinsip fisik baru untuk mewujudkan fungsi rekayasa, perubahan arsitektur sistem yang signifikan, atau menemukan aplikasi baru untuk teknologi platform yang ada. Proses desain rekayasa asli terdiri dari empat fase: desain konsep teknik, desain konfigurasi, desain parameter, dan desain detail teknik. Redesign berkaitan dengan peningkatan fungsi engineering dengan perubahan level komponen atau dimensi produk, atau modifikasi bentuk produk. Desain ulang dapat diklasifikasikan lebih lanjut menjadi tiga jenis – desain konfigurasi bagian, desain varian, dan desain pemilihan yang hanya memiliki fase yang lebih sedikit seperti yang ditunjukkan pada Gambar 5. Desain konfigurasi bagian melibatkan pembuatan arsitektur produk baru. Desain varian berkaitan dengan penyesuaian produk yang ada dengan menyesuaikan parameter produk. Desain pemilihan adalah tentang berbagai cara menggunakan suku cadang standar untuk membuat produk baru. Untuk setiap fase desain rekayasa, studi sebelumnya dapat dirujuk untuk detail [6-11].

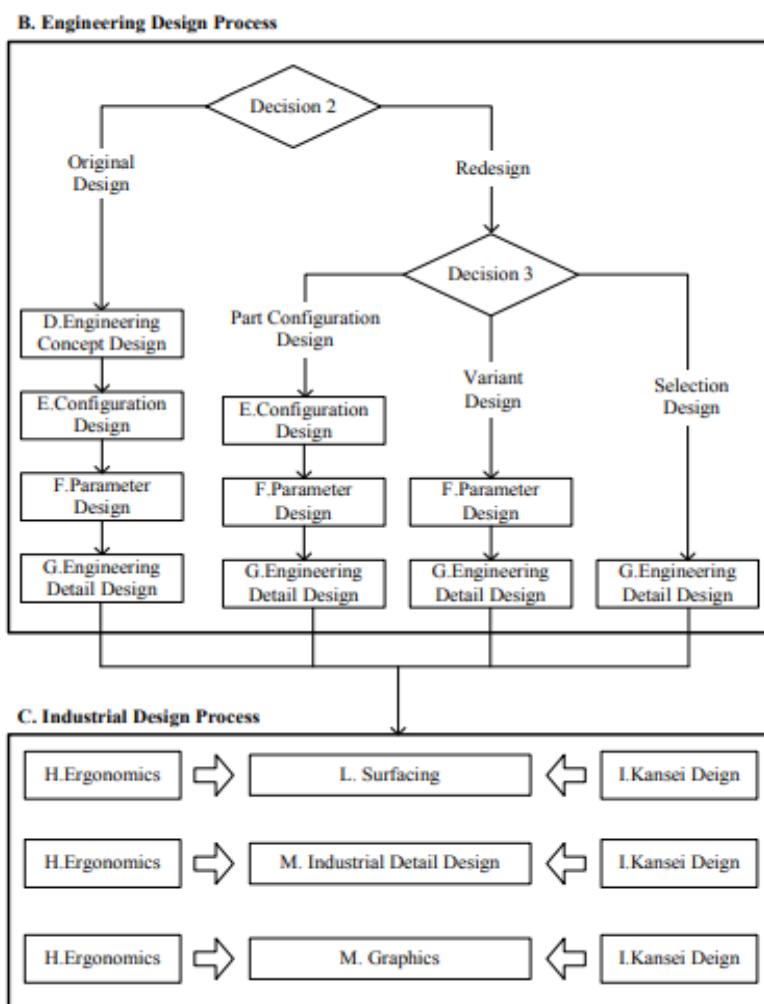
Proses desain industri dapat didekomposisi menjadi empat fase proses desain bentuk: organisasi, permukaan, detail (desain detail industri), dan grafik dari model Wallace [23-24]. Fase organisasi dalam model Wallace sama dengan desain konfigurasi yang telah dilakukan dalam proses desain rekayasa di bawah tugas desain asli. Fase permukaan adalah menghasilkan penutup dalam gaya yang berbeda, fase Detail adalah menambahkan detail seperti perubahan permukaan lokal atau elemen baru untuk melengkapi permukaan luar, dan fase Grafik adalah menerapkan elemen grafis seperti warna, penyaringan, stiker, stempel panas, dan tekstur pada permukaan luar produk. Hanya tiga fase mengikuti desain detail rekayasa seperti yang ditunjukkan pada Gambar 5. Prinsip-prinsip desain dari ergonomi dan rekayasa Kansei dapat diterapkan pada setiap fase.

### **Proses Desain untuk Produk Berbasis Pengguna**

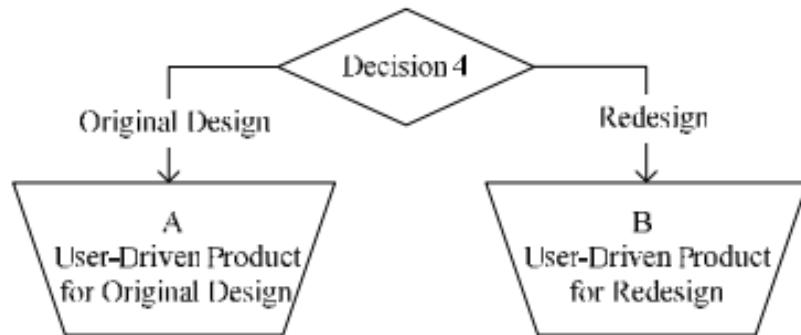
Pengembangan produk yang digerakkan oleh pengguna dapat disebut sebagai strategi tarik pasar. Konsep pengembangan selalu dimulai dari skenario pengguna, bukan dari ide teknologi. Produk dengan teknologi yang rumit dapat termasuk dalam kategori produk yang digerakkan oleh pengguna jika ide produk berasal dari skenario pengguna terlebih dahulu. Proses desain untuk produk yang digerakkan oleh pengguna biasanya dipimpin oleh desainer industri. Keputusan kategori produk diikuti oleh dua situasi desain: desain asli dan desain ulang seperti yang ditunjukkan pada Gambar 6. Gambar 7 menunjukkan proses rinci untuk

desain asli dan desain ulang masing-masing. Para desainer industri mengembangkan konsep produk dengan proses desain konseptual industri dalam kasus desain asli. Kemudian perancang dapat mempertimbangkan penataan ruang komponen dari sudut pandang ergonomi dan Kansei dalam fase desain organisasi.

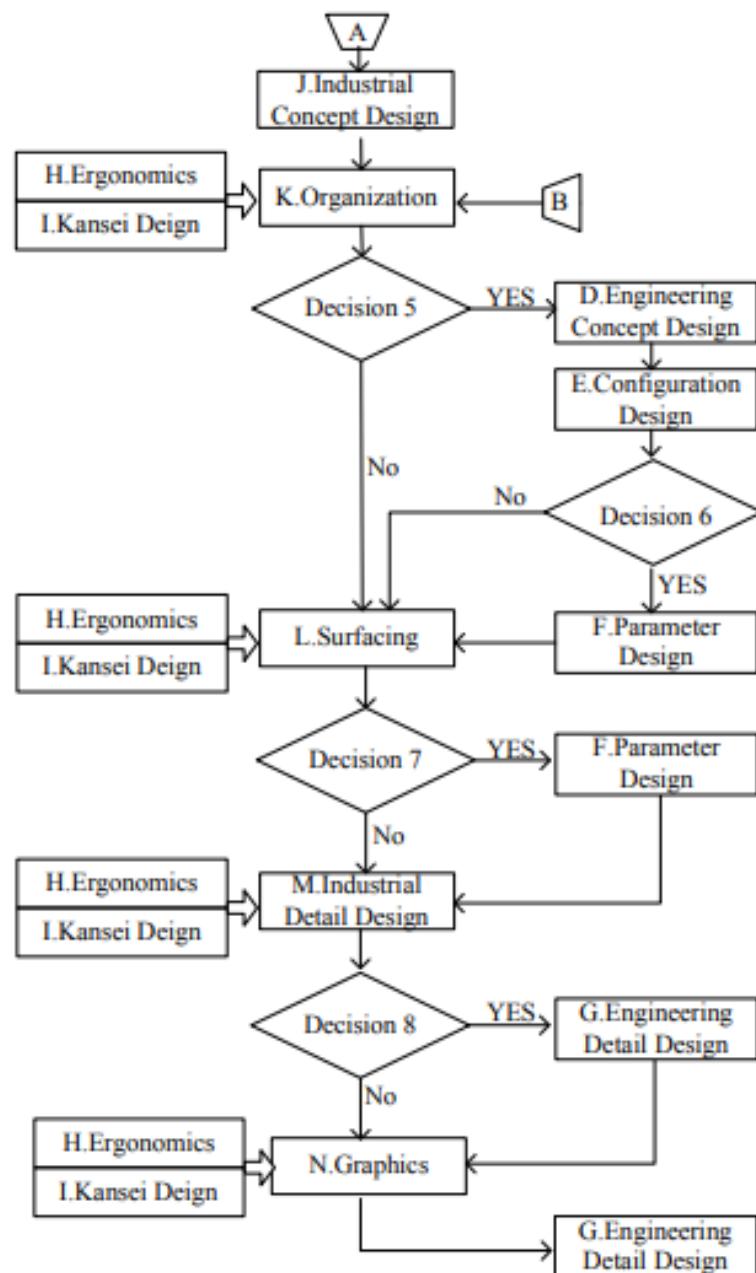
Pada saat yang sama, tim proyek harus mempertimbangkan kelayakan solusi rekayasa dari ide-ide yang diusulkan saat ini. Jika ada kebutuhan untuk berinovasi dengan solusi rekayasa baru, desain konsep rekayasa dan desain konfigurasi harus diikuti. Jika tidak, perancang industri dapat melanjutkan ke fase permukaan. Perancangan parameter rekayasa yang berkaitan dengan dimensi produk dapat dilakukan sebelum tahap perataan, atau perekayasa dapat melakukannya dengan pertimbangan disain pemukaan dari perancang industri. Prinsip-prinsip desain dari ergonomi dan desain Kansei dapat diterapkan pada fase permukaan. Setelah fase permukaan, desain detail industri dapat dilakukan. Ketika desain detail industri selesai, tim proyek dapat memutuskan apakah desain detail teknik harus dilakukan sebelum atau sesudah desain grafis. Selama fase desain grafis, perancang dapat mempertimbangkan untuk menggunakan pendekatan dari desain Kansei dan ergonomi. Perbedaan proses desain antara desain asli dan desain ulang untuk produk yang digerakkan oleh pengguna adalah bahwa hanya desain konsep industri yang termasuk dalam aktivitas desain proses desain asli.



**Gambar 3.5** Proses desain dan desain ulang asli untuk produk yang digerakkan oleh teknologi



**Gambar 3.6** Situasi desain untuk produk yang digerakkan oleh pengguna

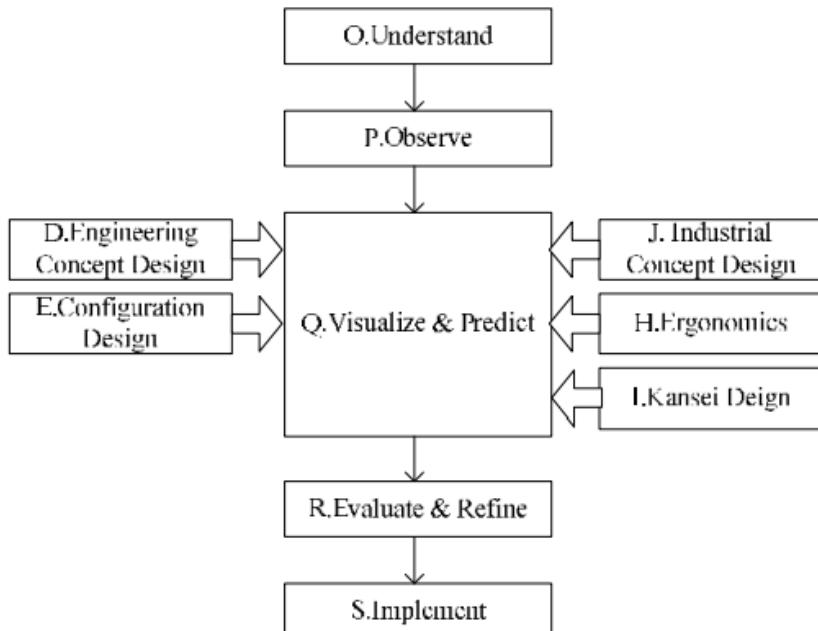


**Gambar 3.7** Desain asli dan proses desain ulang untuk produk yang digerakkan oleh pengguna

### Proses Desain untuk Produk Berbasis Teknologi dan Pengguna

Proses desain untuk produk yang digerakkan oleh teknologi dan pengguna tidak secara khusus dibahas dalam literatur. Banyak produk teknologi yang kompleks menuntut interaksi pengguna dengan sentuhan tinggi untuk menurunkan kurva belajar dan mengurangi frustrasi dengan pengoperasian produk teknologi. Dengan demikian proses desain untuk kategori produk ini dapat digambarkan secara analogis dengan proses desain interaksi. Desain interaksi telah berkembang dengan kombinasi desain industri dan desain antarmuka pengguna perangkat lunak sejak akhir 1980-an. Desain interaksi berkaitan dengan integrasi perangkat keras/perangkat lunak, desain aplikasi perangkat lunak, serta media dan konten interaktif [25]. IDEO mengusulkan proses lima tahap untuk desain interaksi: memahami, mengamati, memvisualisasikan dan memprediksi, mengevaluasi dan menyempurnakan, dan mengimplementasikan [26]. Proses desain IDEO digunakan dalam kerangka kerja seperti yang ditunjukkan pada Gambar 8. Selama fase "memahami" dan "mengamati", klien diwawancara dan perilaku pengguna sebenarnya diamati.

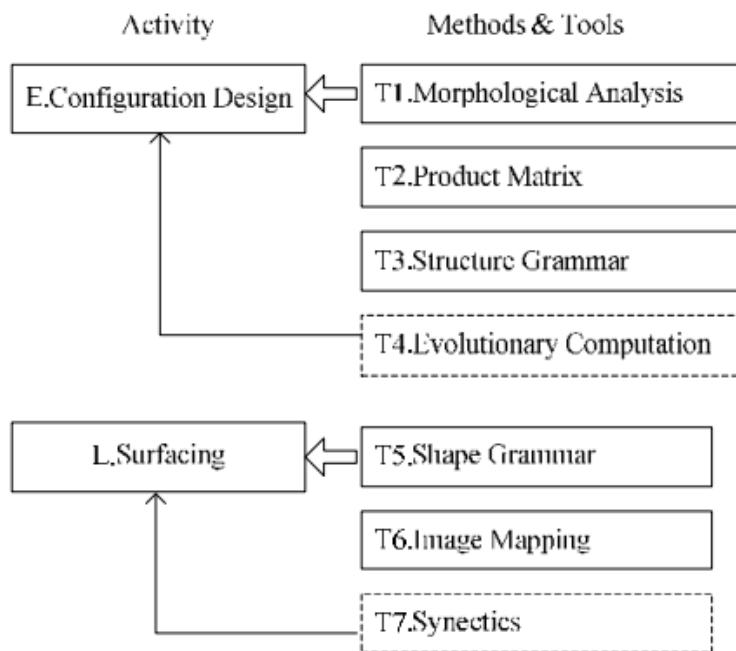
Masalah utama dapat ditemukan. Tahap selanjutnya adalah "memvisualisasikan dan memprediksi" tentang generasi konsep untuk masalah utama. Anggota tim interdisipliner melakukan brainstorming untuk membuat konsep. Semua persyaratan dari teknik, ergonomis, Kansei, dll dipertimbangkan secara bersamaan oleh sekelompok orang. Kemudian detail desain dan implementasi mengikuti. Proses desain ini cukup berhasil untuk mengembangkan banyak produk unggulan di IDEO. Keranjang belanja supermarket paling terkenal dirancang dan direkam dengan proses ini. General Electric mengadopsi proses serupa yang disebut CENCOR untuk merancang produknya [27]. CENCOR adalah singkatan dari berkolaborasi, mengeksplorasi, membuat, mengatur, dan mewujudkan. Philips memiliki proses desain yang serupa untuk mewujudkan filosofi "Sense and Simplicity" [46]. Tahapan yang berbeda adalah perencanaan proyek, pengarahan, membuat, merancang, mempresentasikan, dan menggambar. Mengikuti proses IDEO, proses desain untuk produk yang digerakkan oleh teknologi dan pengguna ini ditunjukkan pada Gambar 8. Ini sama untuk tugas desain asli atau desain ulang.



**Gambar 3.8** Proses desain untuk produk yang digerakkan oleh teknologi dan pengguna  
Sistem Pendukung Keputusan (Dr Joseph Teguh Santoso dan Budi Hartono, M.Kom)

### 3.3 METODE DAN ALAT UNTUK DESAIN BENTUK

Setelah kerangka proses desain produk sepenuhnya dibangun, setiap subproses dapat secara efektif dikaitkan dengan metode desain yang diusulkan dalam banyak penelitian. Gambar 10 menunjukkan skema penggunaan metode dan alat desain. Misalnya, matriks produk, tata bahasa struktur dan metode morfologi dapat digunakan untuk desain konfigurasi. Proses desain gaya dapat menggunakan alat tata bahasa bentuk, dan metode rekayasa Kansei (metode rekayasa berbasis emosi) [26-30]. Menurut struktur kerangka kerja, metode dan alat desain baru dapat dengan mudah ditambahkan ke kerangka yang diusulkan. Misalnya, ketika mengembangkan produk kreatif generasi berikutnya, para desainer biasanya membuat sketsa bentuk produk dari kekosongan. Kemudian para insinyur mencoba menghidupkan sketsa. Mereka biasanya membutuhkan dan mencari inspirasi dari fashion, arsitektur, dan sebagainya untuk menciptakan bentuk baru untuk produk baru. Alih-alih berkeliaran di dunia imajiner, metode berpikir kreatif seperti sinektik, metode morfologis, metode bionik, dan pemikiran analogis menjadi populer bagi para desainer untuk membuka imajinasi mereka. Buku Nicolas menjelaskan cara membuat bentuk baru dari metode kreatif dan memberikan banyak contoh [32]. Di sisi lain, buku Bentley menegaskan bahwa komputasi evolusioner untuk seni mengawali minat penelitian pada 1990-an. Salah satu contohnya adalah desain bentuk mobil dengan berbagai konfigurasi dan ukuran [33]. Sekarang kita dapat menambahkan alat baru ini ke dalam kerangka kerja seperti yang ditunjukkan pada Gambar 9.



**Gambar 3.9** Skema untuk mengasosiasikan proses desain dengan metode dan alat desain

### 3.4 DSS UNTUK PERENCANAAN PROSES DESAIN

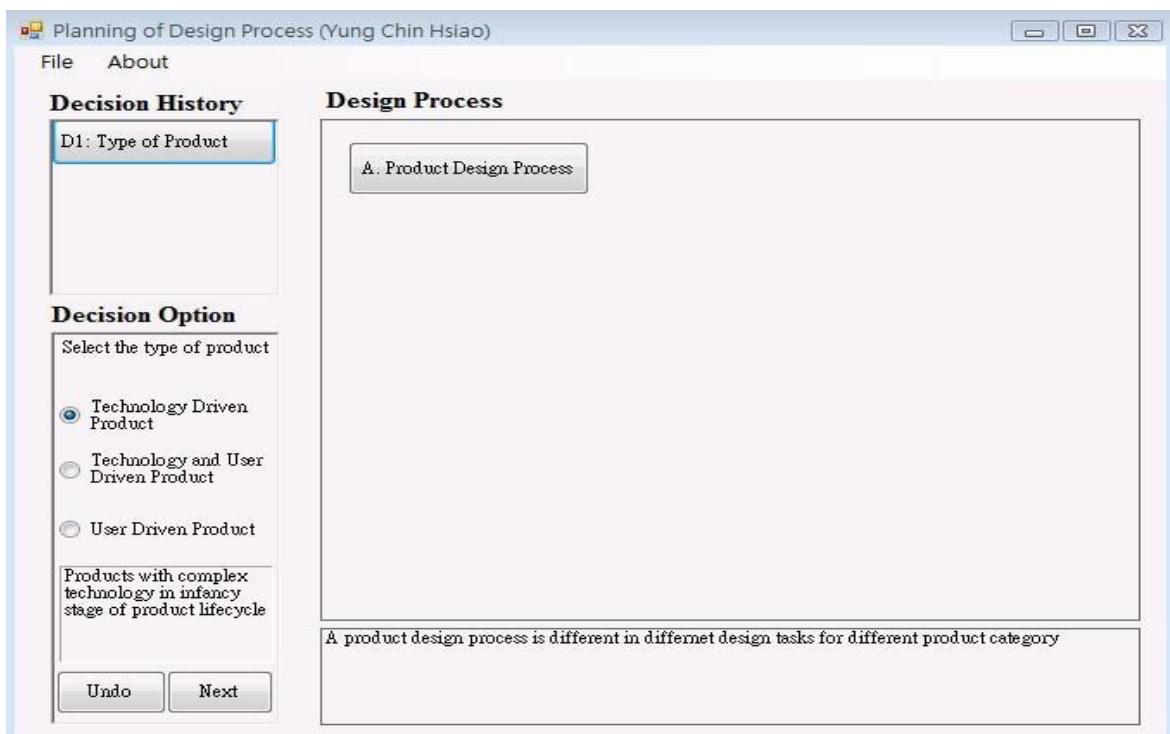
Ada dua isu mendasar tentang bagaimana menggunakan pengetahuan desain secara efektif untuk memecahkan masalah desain. Kerangka yang diusulkan menyelesaikan masalah secara konseptual, tetapi mungkin tidak memberikan cara yang ramah untuk penggunaan praktis karena kurangnya dukungan penyimpanan dan penalaran pengetahuan desain. DSS telah banyak diterapkan pada desain teknik, desain industri, dan desain produk. Untuk mengimplementasikan kerangka kerja, DSS dipertimbangkan karena alasan berikut:

- (1) DSS dapat memfasilitasi interaksi antara perancang industri dan komputer untuk menghasilkan rencana alternatif untuk proses desain.
- (2) DSS dapat menyediakan pengetahuan desain tidak terstruktur yang disimpan sebagai aturan atau metode representasi pengetahuan apa pun untuk membuat keputusan.
- (3) DSS dapat mengimplementasikan kerangka kerja dengan lebih mudah karena tersedianya alat pemrograman perangkat lunak komersial dan upaya penelitian di bidang ini.

Selama survei DSS pada desain produk, beberapa jenis aplikasi telah ditemukan. Besyaratidkk. menggunakan pendekatan pemodelan pembelian umum untuk mengembangkan metrik utilitas yang diharapkan berdasarkan pelanggan yang membentuk dasar DSS untuk mendukung pemilihan dalam desain produk [34]. Toben dan Leo membangun DSS untuk pemilihan proses manufaktur dalam desain produk [35]. Giachetti menggabungkan keputusan pemilihan material dan pemilihan proses manufaktur ke dalam DSS [36]. Masubana dan Nagamachi mengusulkan sistem rekayasa Kansei hybrid untuk mendukung pelanggan dan desainer dalam memutuskan kansei produk [37]. Jindo dkk. menggunakan perbedaan semantik untuk menemukan hubungan antara evaluasi kansei pelanggan kursi kantor dan elemen desain. Kursi kantor dapat dibuat dengan DSS yang mereka usulkan [38]. Menurut pengetahuan terbaik penulis saat ini, tidak ditemukan penelitian yang relevan tentang DSS untuk perencanaan proses desain produk. Diasumsikan bahwa alasannya adalah bahwa kebutuhan laten untuk metode perencanaan proses desain yang lebih baik tidak terungkap dan orang-orang puas dengan pendekatan saat ini untuk merencanakan proses desain. Sebenarnya pendekatan perencanaan saat ini tidak memadai.

Sekarang kita dihadapkan pada masalah baru: sintesis tipe baru DSS. Pendekatan kami adalah menemukan jenis DSS yang ada yang paling dekat dengan kebutuhan kami. Kemudian konsep baru DSS dihasilkan dengan memperbaiki tipe DSS yang ada sampai semua persyaratan terpenuhi. Menurut taksonomi Power dari DSS, Power membedakan DSS yang digerakkan oleh komunikasi, DSS yang digerakkan oleh data, DSS yang digerakkan oleh dokumen, DSS yang digerakkan oleh pengetahuan, dan DSS yang digerakkan oleh model dengan menggunakan mode bantuan sebagai kriterianya [39]. Karena kebutuhan informasi yang kompleks dan tidak terstruktur dalam merencanakan proses desain, DSS berbasis pengetahuan dipilih sebagai kandidat sistem untuk perbaikan. Di sisi lain, dari pengalaman peneliti sebelumnya, pemrograman berorientasi objek (OOP) memberikan banyak keuntungan dibandingkan alat lain seperti C atau Prolog dalam mengimplementasikan DSS untuk desain konseptual produk. OOP dapat memfasilitasi antarmuka visual yang bagus atau perawatan DSS yang mudah. Pertimbangan utama lainnya adalah bahwa pemikiran desain berorientasi objek telah diperkenalkan ke dalam desain industri dan produk. Gorti menciptakan CONGEN, sebuah sistem pendukung keputusan untuk desain konseptual. Objek CONGEN digunakan sebagai template untuk membangun artefak, proses desain, dan banyak objek lain untuk merekam aktivitas desain dari evolusi simbolik [40, 41]. Dukungan komputer dari desain konseptual menjadi layak dalam menghasilkan konsep-konsep baru daripada hanya untuk menggambar. Bijan dkk. menggunakan bahasa pemodelan universal (UML) dalam OOP untuk menggambarkan kebutuhan pengguna, skenario penggunaan, struktur produk dan pengetahuan desain terkait dalam desain produk. Desain berorientasi objek

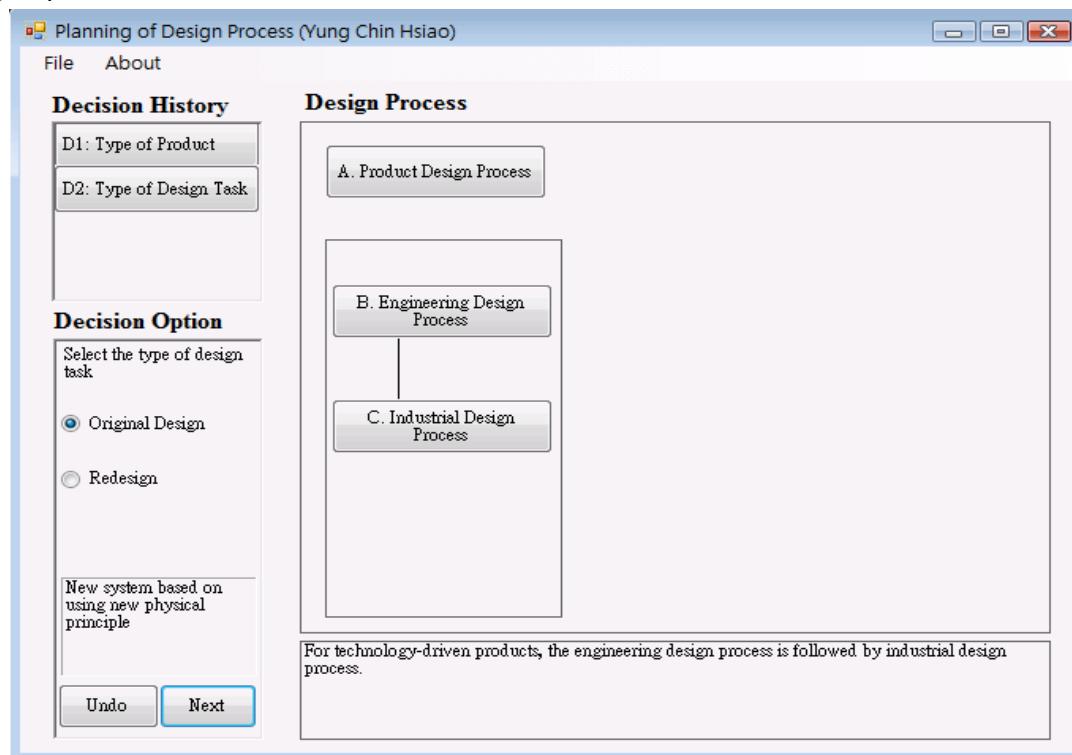
mengarah ke arah baru untuk dukungan komputer desain produk [42]. OOP memberikan keuntungan dari modularisasi, fleksibilitas dan skalabilitas. Mengintegrasikan pendekatan berorientasi objek dan berbasis pengetahuan, DSS berbasis pengetahuan berorientasi objek diusulkan dalam makalah ini. Ini menyediakan arsitektur yang baik untuk mendukung keputusan desain perencanaan berdasarkan pengetahuan desain yang kompleks. Fitur unik dalam DSS yang diusulkan adalah deskripsi simbolis dari evolusi proses desain yang direncanakan. Lebih detail tentang DSS dapat ditemukan di buku Turban dan Aronson [43].



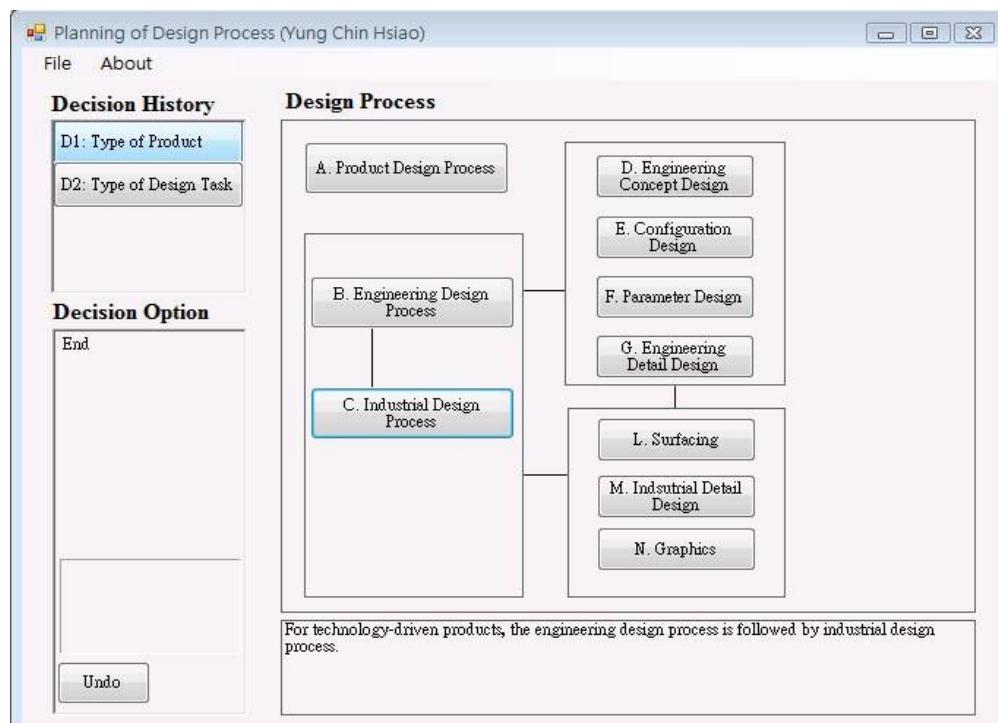
**Gambar 3.10** Antarmuka DSS untuk merencanakan proses desain

Konsep DSS berbasis pengetahuan berorientasi objek untuk merencanakan proses desain divalidasi oleh prototipe. DSS berbasis pengetahuan berorientasi objek memiliki tiga bagian: model keputusan berbasis objek, representasi proses desain berbasis objek, dan database metode desain berbasis objek. Model keputusan perencanaan proses desain digambarkan sebagai pohon keputusan seperti yang ditunjukkan pada Gambar 4 sampai 10. Setiap node dalam pohon keputusan diperlakukan sebagai objek kelas keputusan. Atribut objek kelas keputusan terdiri dari pengidentifikasi objek, deskripsi keputusan, opsi keputusan, dan tujuan keputusan. Objek kelas proses mewakili proses desain produk dan sub-proses yang dimanipulasi oleh objek kelas keputusan. Objek di kelas alat desain mewakili alat atau metode yang tersedia yang terkait dengan banyak objek kelas proses. Gambar 10 menunjukkan antarmuka dan interaksi dengan pengambil keputusan. Riwayat keputusan mencatat transisi dan status setiap simpul keputusan di pohon keputusan. Riwayat keputusan memungkinkan pengambil keputusan untuk menyimpan, mengambil, dan memodifikasi hasil dari aktivitas perencanaan saat ini dalam perangkat lunak. Opsi keputusan menunjukkan opsi keputusan untuk simpul keputusan saat ini. Kemajuan proses desain yang direncanakan dan informasi relatif akan ditampilkan di bagian kanan jendela. Misalnya, jika tujuan dari keputusan tersebut adalah menemukan jenis produk yang paling dekat dalam salah satu dari tiga kategori produk

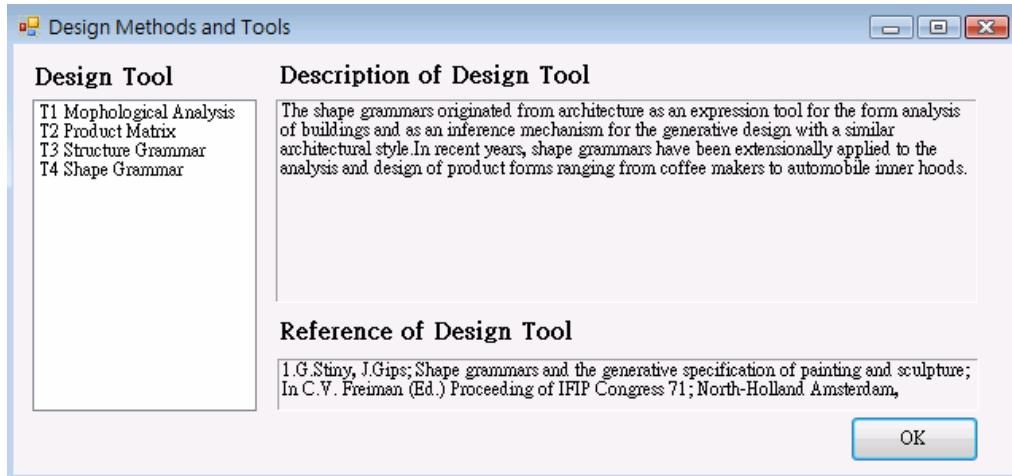
dan produk berbasis teknologi dipilih, perangkat lunak akan mengambil keputusan berikutnya dan proses desain yang direncanakan saat ini seperti yang ditunjukkan pada Gambar 11 dan 12. Jika tombol proses desain ditekan, metode dan alat terkait akan ditampilkan. Karena banyaknya informasi yang terkait dengan setiap metode dan alat desain, informasi tersebut harus dikelola oleh database. Gambar 13 menunjukkan antarmuka metode desain yang terkait dengan proses desain.



**Gambar 3.11** Proses desain yang direncanakan untuk produk berbasis teknologi



**Gambar 3.12** Proses desain yang direncanakan untuk desain asli dari produk yang digerakkan oleh teknologi



**Gambar 3.13** Antarmuka metode desain yang terkait dengan proses desain.

### 3.5 STUDI KASUS

Studi kasus skuter akan menggambarkan bagaimana menggunakan kerangka untuk merencanakan proses desain bentuk dan bagaimana membuat bentuk skuter mengikuti proses yang direncanakan [31].

#### Perencanaan Proses Desain

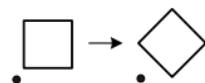
Pernyataan misi menunjukkan bahwa perusahaan tertentu perlu mengembangkan jenis skuter baru untuk citra perusahaan baru. Gaya formulir harus mematahkan citra rutin. Menurut strategi produk dalam pernyataan misi, skuter diposisikan sebagai produk yang digerakkan oleh pengguna. Desain industri harus memimpin desain teknik. Tugas desain adalah mendesain ulang skuter. Proses desain ditunjukkan pada Gambar 8. Konsep rekayasa terbatas pada arsitektur skuter konvensional dengan satu roda depan dan satu roda belakang. Rangka bodi skuter telah ditentukan untuk kasus ini. Kegiatan desain utama adalah permukaan dan desain detail industri di mana desain ergonomis juga dipertimbangkan. Untuk menciptakan gaya bentuk baru, tata bahasa bentuk sebagai metode desain digunakan untuk membantu desainer industri menciptakan konsep permukaan dan desain detail industri. Tata bahasa bentuk berasal dari arsitektur sebagai alat ekspresi untuk analisis bentuk bangunan dan sebagai mekanisme inferensi untuk desain generatif dengan gaya arsitektur serupa. Dalam beberapa tahun terakhir, tata bahasa bentuk telah diterapkan secara ekstensif pada analisis dan desain bentuk produk mulai dari pembuat kopi hingga tudung bagian dalam mobil. Bagian selanjutnya akan menjelaskan cara membuat bentuk skuter dengan tata bahasa bentuk dalam proses desain yang direncanakan.

#### Desain Bentuk dalam Proses Desain yang Direncanakan

Tata bahasa bentuk digunakan untuk membuat bentuk skuter dalam proses desain. Tata bahasa bentuk diperkenalkan secara singkat sebelum kita pergi ke diskusi rinci. Menurut Stiny, G. [44-45], tata bahasa bentuk  $G = (S, L, R, I)$  terdiri dari empat komponen:

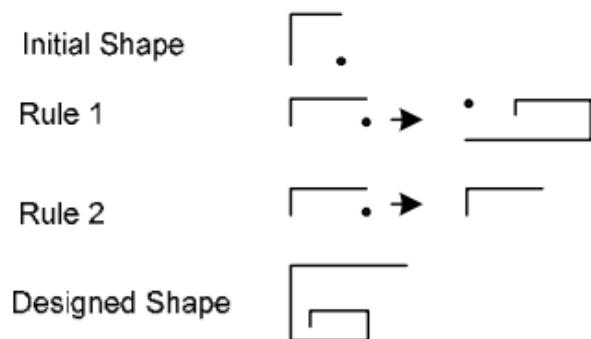
- (1)  $S$  adalah himpunan berhingga,
- (2)  $L$  adalah himpunan berhingga dari label,
- (3)  $R$  adalah himpunan berhingga aturan bentuk dari bentuk  $\alpha \rightarrow \beta$  di mana  $\alpha$  adalah bentuk berlabel di  $(S, R)^+$ , dan berlabel bentuk di  $(S, R)^*$ .
- (4)  $I$  adalah bentuk label dalam  $(S, R)^+$  yang disebut bentuk awal.

$S$  adalah himpunan primitif seperti titik, garis, bidang, atau padat, lingkaran, atau persegi panjang yang digunakan untuk membangun bentuk objek. Label di  $L$  mengarahkan operasi aturan seperti garis dasar atau kisi di latar belakang untuk membantu konstruksi bentuk. Aturan dalam  $R$  adalah transformasi bentuk label ke bentuk label  $\beta$ . Panah  $\rightarrow$  berarti transformasi bentuk. Sebagai contoh,



$\alpha$  - persegi panjang dengan label titik - berputar 45 derajat di sekitar pusatnya dan menyusutkan panjang tepinya menjadi bentuk berlian berlabel  $\beta$ . Label titik mengarahkan bentuk persegi panjang dan berlian. Tanpa label titik, bentuk persegi panjang dan berlian setara dengan rotasi.  $(S, R)^+$  dan  $(S, R)^*$  masing-masing mewakili himpunan bentuk label sisi kiri dan kanan.

Gambar 14 mengilustrasikan tata bahasa bentuk sederhana untuk membuat bentuk yang dirancang dengan menerapkan Aturan 1 dua kali dan Aturan 2 secara berurutan. Aturan 2 adalah aturan terminal untuk menghapus label titik.



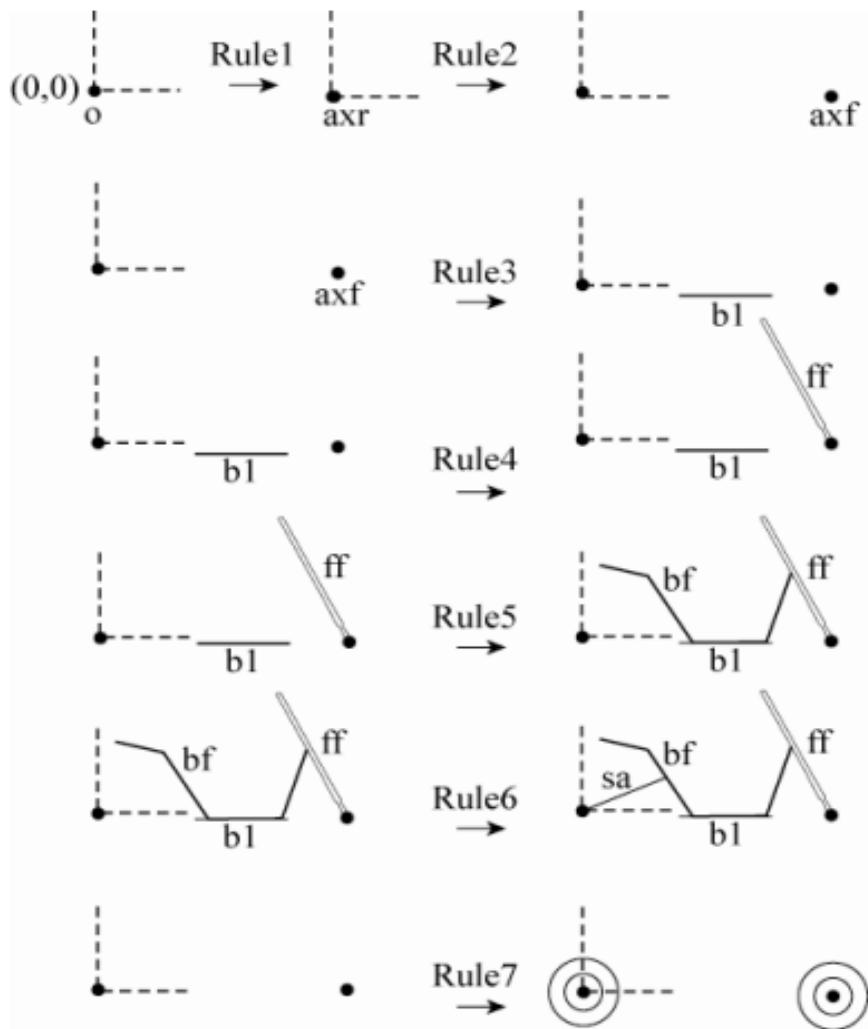
**Gambar 3.14** Tata bahasa bentuk sederhana

Setelah memperkenalkan tata bahasa bentuk, kita akan membahas tata bahasa bentuk yang terkait dengan proses desain bentuk pada pembuatan bentuk skuter. Proses desain permukaan dan detail industri menjadi fokus.

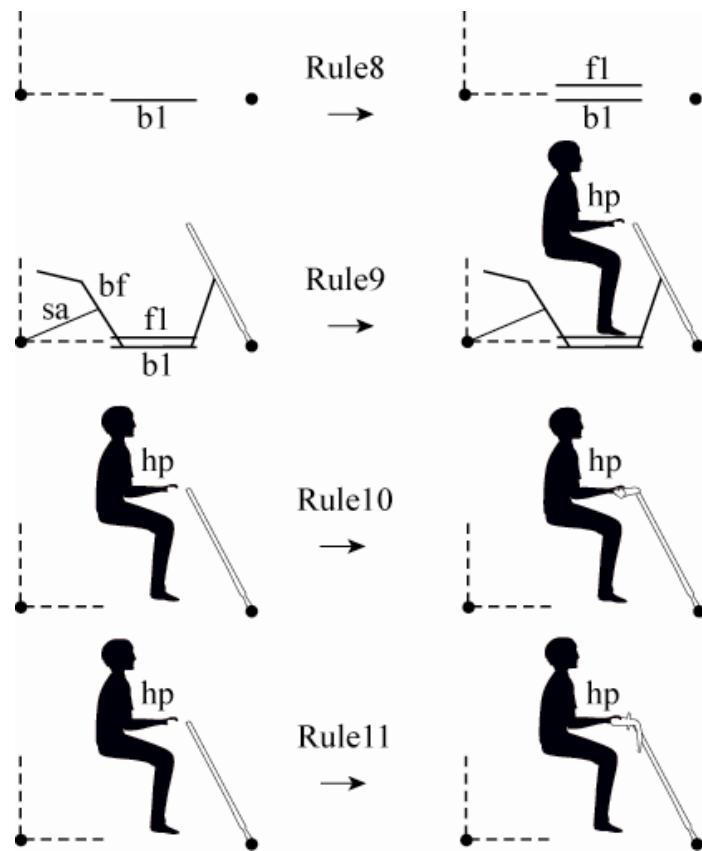
### (1) Permukaan

Selama fase ini, penutup skuter perlu didesain ulang dengan mempertimbangkan faktor manusia dan persyaratan teknis. Permukaan penutup perlu dirancang dengan gaya baru untuk skuter. Penutup dipasang pada rangka bodi skuter untuk melindungi bagian mekanis internal dari debu dan kerusakan. Rangka bodi skuter, ukuran roda, dan jarak roda merupakan pertimbangan teknis yang mendasar. Mereka adalah informasi yang diketahui dalam kasus desain ulang ini. Mereka dipatuhi ke dalam aturan tata bahasa bentuk seperti yang ditunjukkan pada Aturan 1-7 dari Gambar 15. Faktor manusia seperti postur pengendara skuter dikumpulkan. Mereka direpresentasikan dalam tata bahasa bentuk seperti yang ditunjukkan pada Aturan 8 – 11 dari Gambar 16. Tata bahasa bentuk menentukan hubungan spasial setiap penutup dari Aturan 12 – 30 dari Gambar 17 - 19. Aturan dapat diterapkan dengan cara yang berbeda untuk menghasilkan yang baru bentuk. Jika urutan penerapan

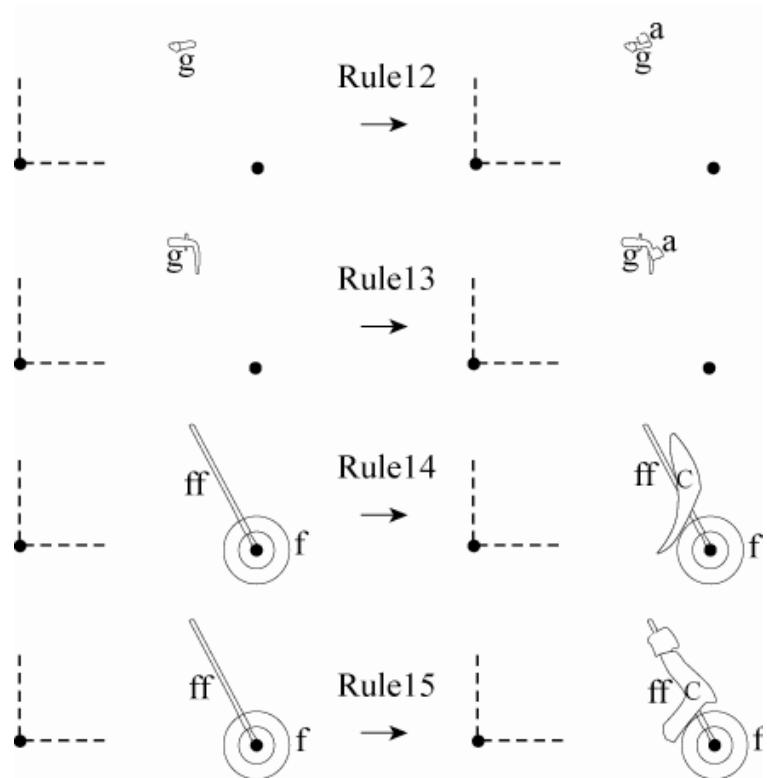
aturan adalah Aturan 1-9, 11, 13, 15, 19, 21, 24, 25, 26, 28, 29, 30, 31, 32, 35, bentuk skuter dibuat seperti yang ditunjukkan pada Gambar 20. Gambar 21 menunjukkan bentuk permukaan yang dibuat jika Aturan 1-9, 11, 13, 15, 19, 21, 24, 25, 26, 28, 29, dan 30 diterapkan. Penjelasan rincian tentang aturan tercantum dalam Tabel 2 di Lampiran. Tata bahasa bentuk memandu desainer untuk mempertimbangkan persyaratan ergonomis dan teknik. Bentuk sebenarnya dari permukaan tidak secara eksplisit ditentukan dalam tata bahasa bentuk dalam studi kasus ini. Faktor emosional dipertimbangkan ketika menerapkan setiap aturan. Perancang dapat membuat bentuk permukaan setiap sampul dengan imajinasi.



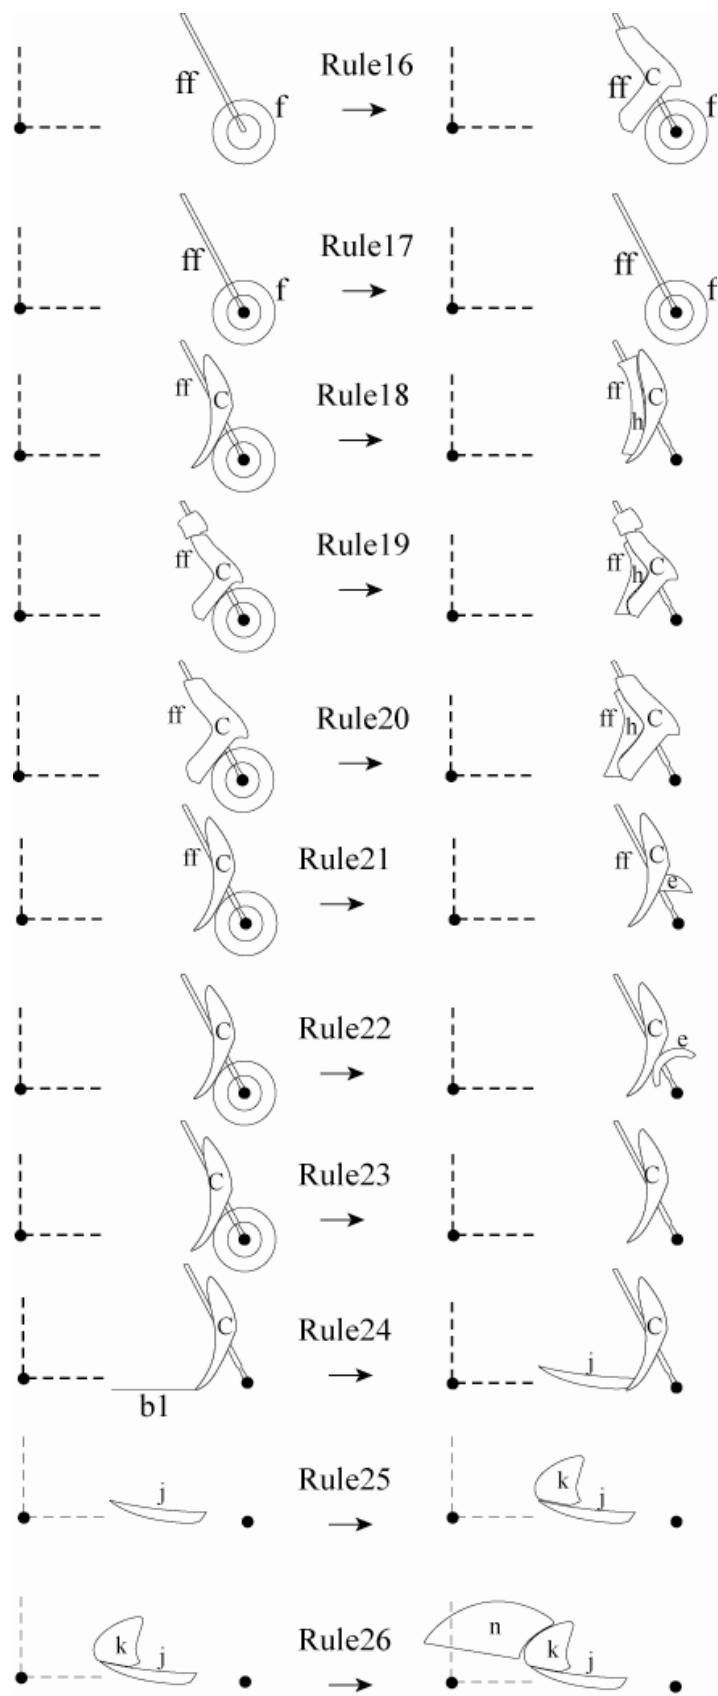
**Gambar 3.15** Persyaratan teknik dalam Aturan 1-7 tata bahasa bentuk



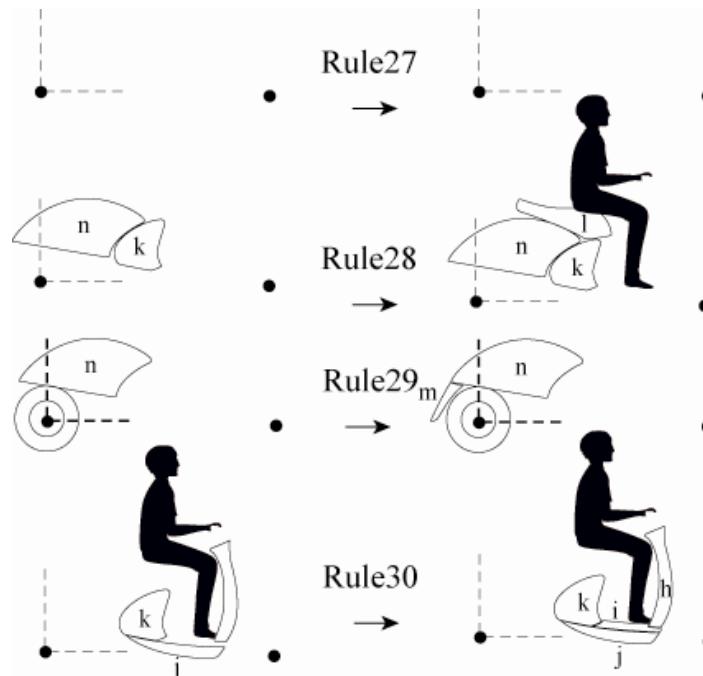
**Gambar 3.16** Persyaratan ergonomis dalam Aturan 8-11 tata bahasa bentuk



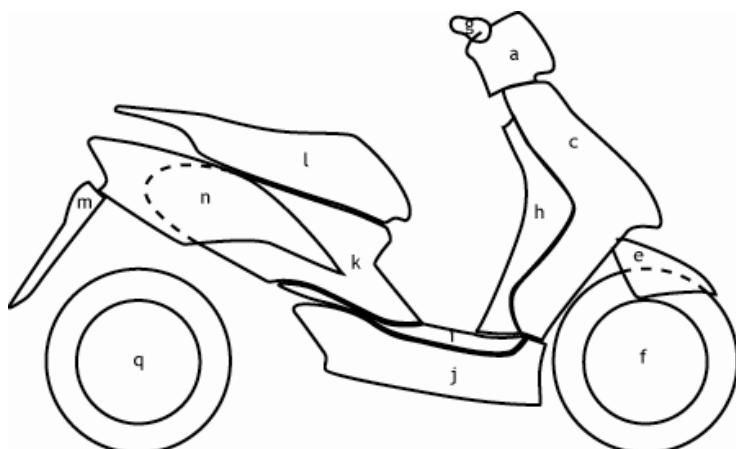
**Gambar 3.17** Desain permukaan dalam Aturan 12-15 tata bahasa bentuk



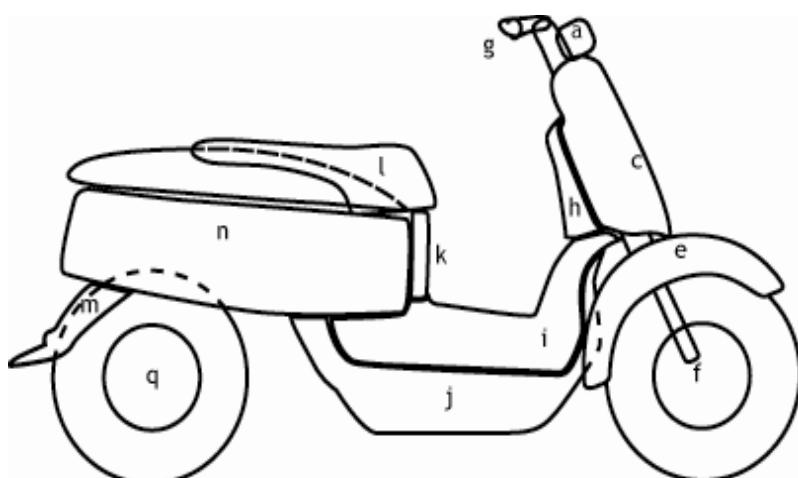
**Gambar 3.18** Desain permukaan dalam Aturan 16-26 tata bahasa bentuk



**Gambar 3.19** Aturan 27-30 tata bahasa bentuk untuk desain permukaan



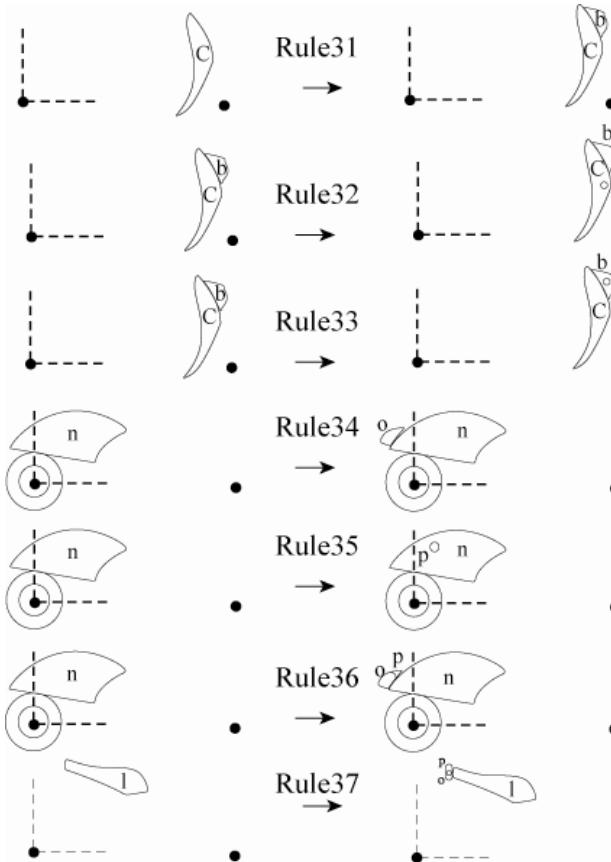
**Gambar 3.20** Permukaan skuter dibuat dengan desain permukaan dengan tata bahasa bentuk Aturan 1-9, 11, 13, 15, 19, 21, 24, 25, 26, 28, 29, dan 30



**Gambar 3.21** Permukaan skuter dibuat dengan desain permukaan dengan tata bahasa bentuk Aturan 1-9, 11, 13, 14, 18, 22, 24, 25, 26, 28, 29, dan 30

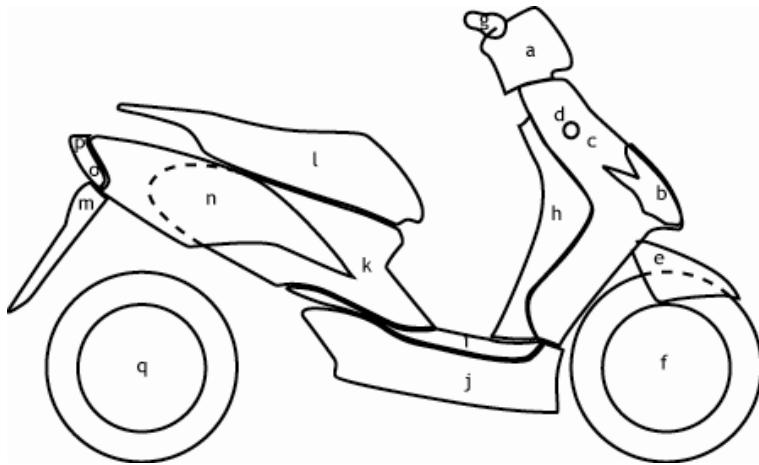
## (2) Desain Detail Industri

Selama fase ini, detail komponen skuter seperti lampu depan dan lampu belakang dipasang pada permukaan penutup. Hubungan spasial komponen detail dan penutup harus diatur dengan pertimbangan persyaratan teknik.

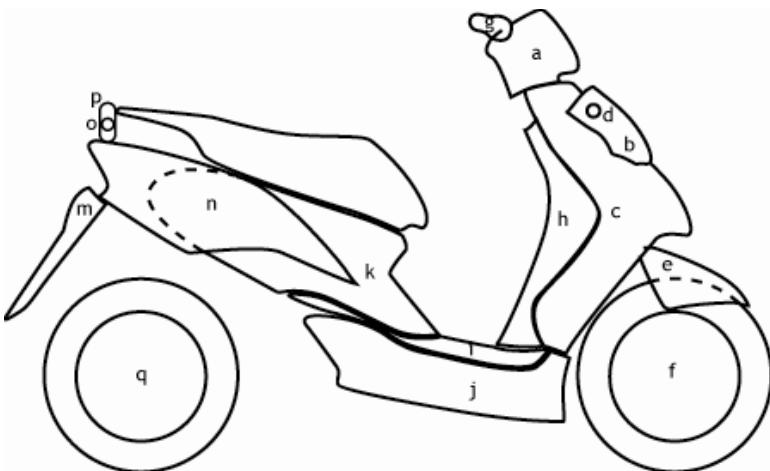


**Gambar 3.22** Desain detail industri dalam Aturan 31-37 tata bahasa bentuk

Misalnya, posisi lampu kepala dapat mempengaruhi jangkauan dan jarak iluminasi lampu kepala. Jenis detail komponen seperti LED atau lampu pijar juga dapat mempengaruhi gaya bentuk. Aturan desain dengan mempertimbangkan faktor teknik dapat dinyatakan dengan tata bahasa bentuk seperti yang ditunjukkan pada Aturan Gambar 21. Dengan asumsi bahwa salah satu bentuk permukaan yang dibuat setelah desain permukaan, misalnya, bentuk pada Gambar 19 dipilih untuk desain detail lebih lanjut dari lampu depan, lampu sinyal depan dan lampu belakang, dua set aturan dapat diterapkan untuk membuat desain detail yang berbeda seperti yang ditunjukkan pada Gambar 22 dan 23. Gambar 23 menunjukkan bahwa lampu depan berada di posisi yang lebih rendah di dekat spatbor depan, sinyal depan terpisah dari lampu depan, dan lampu belakang berada di posisi belakang penutup bodi belakang. Gambar 24 menunjukkan bahwa set lampu depan dan lampu sein depan terletak di bagian tengah cover depan, dan lampu belakang dipasang di bagian belakang jok. Kecuali pengaturan spasial komponen detail yang berbeda, semua bentuk komponen dalam dua kasus desain detail juga dibuat berbeda.



**Gambar 3.23** Komponen detail skuter dibuat untuk desain detail dengan tata bahasa bentuk Rules 1-9,11,13,15,19,21,24,25,26,28,29,30, 31, 32, dan 36



**Gambar 3.24** Komponen detail skuter dibuat untuk desain detail dengan aturan tata bahasa bentuk 1-9,11,13,15,19,21,24,25,26,28,29,30,31,33, dan 37

### 3.6 KESIMPULAN

Pengembangan produk modern adalah tugas yang menantang karena banyak kendala. Dua isu mendasar bagi desainer industri adalah: apa proses desain bentuk dalam konteks desain produk, dan bagaimana pengetahuan desain bentuk dapat diterapkan secara efektif untuk memecahkan masalah menciptakan bentuk produk. Setelah survei literatur yang komprehensif, makalah ini mengusulkan kerangka kerja yang mengintegrasikan masalah desain produk, proses desain produk, proses desain bentuk, metode dan alat desain bentuk dengan pertimbangan persyaratan fungsi, ergonomis, emosional, dan faktor manufaktur.

Dengan demikian, desainer dapat menggunakan kerangka kerja untuk merencanakan proses desain bentuk mereka sendiri, memilih alat desain bentuk, metode, untuk masalah desain mereka sendiri. Isu-isu mendasar diselesaikan dengan panduan kerangka kerja yang diusulkan. Kerangka kerja yang diusulkan diimplementasikan menggunakan DSS berorientasi objek yang dapat sepenuhnya mengintegrasikan semua penelitian desain terkini ke dalam basis pengetahuan dan menyediakan antarmuka interaktif. Oleh karena itu DSS dapat membantu desainer industri untuk membuat keputusan yang lebih baik dalam perencanaan proses desain dan menggunakan metode desain. Studi kasus skuter menggambarkan

perencanaan proses desain bentuk dengan menggunakan DSS. Sesuai dengan proses desain yang direncanakan, desain bentuk skuter dibuat dengan menggunakan tata bahasa bentuk yang mengintegrasikan persyaratan ergonomis dan teknik. Upaya masa depan akan menuju dua arah: (1) menggunakan penalaran kasus-dasar untuk menyarankan proses desain berdasarkan kasus serupa di DSS, (2) memungkinkan desainer industri menyesuaikan proses desain dari saran DSS. DSS masa depan akan berperilaku lebih cerdas.

## Lampiran: Terminologi Proses Desain dan Aturan Tata Bahasa Bentuk

**Tabel 1.** Terminologi Proses Desain

---

### A. Proses Desain Produk

Proses Desain Produk meliputi tugas mencipta, tugas pemahaman, dan tugas komunikasi, tugas menguji, dan tugas persuasi. Setiap proses pengembangan produk mencakup tiga fase: memahami peluang, mengembangkan konsep, dan menerapkan konsep [8].

---

### B. Proses Desain Rekayasa

Engineering Design adalah seperangkat proses pengambilan keputusan dan kegiatan yang digunakan untuk menentukan bentuk suatu objek yang diberikan fungsi-fungsi yang diinginkan oleh pelanggan [11].

---

### C. Proses Desain Industri

Proses desain industri adalah serangkaian kegiatan untuk menciptakan desain gaya bentuk. Ini dapat dibagi menjadi dua bagian: desain ergonomis dan desain gaya bentuk. Desain ergonomis mempertimbangkan faktor-faktor seperti biaya dan keamanan produk, dan interaksi antarmuka pengguna. Desain gaya berkaitan dengan pembagian produk kompetitif di pasar, citra produk pemilik [7].

---

### D. Desain Konsep Rekayasa

Desain Konsep Rekayasa adalah bagian dari proses desain rekayasa di mana, dengan mengidentifikasi masalah esensial melalui abstraksi, dengan pembentukan struktur fungsi dan dengan mencari prinsip kerja yang sesuai dan kombinasinya, jalur solusi dasar diletakkan turun melalui elaborasi prinsip solusi [6].

---

### E. Desain Konfigurasi

Fase desain ketika fitur geometris diatur dan dihubungkan pada bagian, atau komponen standar atau dipilih untuk arsitektur [11].

---

### F. Desain Parameter

Fase desain yang menentukan nilai spesifik untuk variabel desain [11].

---

### G. Desain Detail Rekayasa

Fase desain yang menghasilkan persiapan paket informasi yang mencakup gambar dan spesifikasi yang cukup untuk membuat suatu produk [11].

---

### H. Ergonomi/Faktor Manusia

Untuk menggambarkan kemampuan, keterbatasan, dan karakteristik fisiologis atau perilaku manusia lainnya yang mempengaruhi desain dan pengoperasian alat, mesin, sistem, pekerjaan tugas, dan lingkungan. Ergonomi merupakan sinonim yang sering digunakan oleh praktisi di Eropa [11].

---

### I. Desain Kansei

Sebuah teknologi penerjemahan perasaan psikologis konsumen (Kansei) dan citra tentang produk yang akan datang ke dalam elemen desain [47].

---

### J. Desain Konsep Industri

Desain Konsep Industri menghasilkan estetika produk dan interaksi antarmuka manusia-mesin dalam proses desain industri [7].

---

### K. Organisasi

---

---

Organisasi melakukan pemasian spasial komponen dalam bentuk proses pembuatan [24].

---

#### **L. Permukaan**

Permukaan menghasilkan penutup untuk desain produk [24].

---

#### **M. Desain Detail Industri**

Tingkat detail industri berkaitan dengan perubahan permukaan lokal atau elemen baru untuk melengkapi permukaan eksterior [24].

---

#### **N. Grafik**

Level grafis menerapkan elemen-elemen seperti pewarnaan, tekstur permukaan, decals, dan stempel panas ke permukaan luar produk [24].

---

#### **O. Memahami**

Memahami membantu membangun bahasa yang sama antara kebutuhan pelanggan dan tim desain dan memulai pengembangan tim desain yang menjembatani kedua organisasi [26].

---

#### **P. Perhatikan**

Amati informasi pengguna utama yang melakukan tugas-tugas utama. Orang-orang dan tugas-tugas yang diamati secara hati-hati dipilih untuk menutupi ruang dari masalah desain [26].

---

#### **Q. Visualisasikan & Prediksi**

Untuk mensintesis informasi dan membayangkan ide-ide interaksi kunci. Sebagai ide interaksi muncul - dan proses yang tepat di mana mereka muncul agak tidak terduga dan tidak dapat didokumentasikan - mereka divisualisasikan dalam simulasi yang cocok untuk evaluasi informal [26].

---

#### **R. Evaluasi & Perbaiki**

Menetapkan strategi pengujian untuk mengevaluasi hasil visualisasi, dan penyempurnaan desain berdasarkan umpan balik. Desain biasanya melewati beberapa iterasi visualisasi dan evaluasi sebelum desain diselesaikan. Hasil akhirnya sering merupakan sintesis dari intuisi desainer dan umpan balik dari evaluasi pengguna [26].

---

#### **S. Implementasi**

Desain bentuk produk, desain detail, spesifikasi lengkap metode interaksi dan representasinya diimplementasikan [26].

---

**Tabel 2.** Deskripsi Aturan Tata Bahasa Bentuk

---

#### **Persyaratan teknik**

Aturan 1: Bentuk awal adalah titik dengan label O di titik asal sistem koordinat. Tentukan titik awal sebagai pusat poros roda belakang.

Aturan 2: posisi aksial roda depan ditentukan oleh panjang jarak sumbu roda.

Aturan 3: garis batas bawah dibuat untuk ground clearance.

Aturan 4: panjang dan sudut rake garpu depan ditentukan.

Aturan 5: profil bingkai tubuh ditambahkan.

Aturan 6: lengan ayun terhubung ke rangka tubuh.

Aturan 7: roda ditambahkan.

---

#### **Persyaratan ergonomis**

---

---

Aturan 8: garis pijakan kaki dibuat.

Aturan 9: kaki manusia yang duduk berada di garis pijakan kaki.

Aturan 10 – 11: Aturan 10 atau 11 diterapkan untuk menambahkan batang setang lurus atau berbentuk Y. Posisi tangan dan garpu depan membatasi pemilihan aturan.

#### **Desain permukaan**

Aturan 12 - 13: Jika Aturan 10 dipilih, Aturan 12 harus diikuti untuk menambahkan konsol instrumen; jika tidak, Aturan 13 harus diterapkan.

Aturan 14 – 16: Salah satu aturan harus diterapkan untuk memasang sampul depan. Aturan 17: Tidak ada sampul depan

Aturan 18 - 20: Penutup bagian dalam harus menutupi garpu depan sebagian dan sesuai dengan bentuk penutup depan. Salah satu aturan diterapkan secara selektif untuk menambahkan penutup bagian dalam.

Aturan 21-22: Dua jenis spatbor depan dapat dipilih

Aturan 23: Tidak ada spatbor depan. Cover depan berfungsi sebagai fungsi dari spatbor depan.

Aturan 24: penutup samping dipasang ke penutup depan secara berdampingan.

Aturan 25: penutup tengah terletak di atas penutup samping.

Aturan 26: penutup badan dihubungkan dengan penutup samping dan penutup tengah.

Aturan 27: tidak ada penutup samping, penutup tengah, dan penutup badan.

Aturan 28: kursi ditambahkan.

Aturan 29: spatbor belakang dibuat.

Aturan 30: panel pijakan kaki dibuat.

---

#### **Desain detail industri**

Aturan 31: lampu depan ada di sampul depan.

Aturan 32: lampu sein depan ada di sampul depan, tapi tidak terintegrasi dengan lampu depan.

Aturan 33: rangkaian integral lampu depan dan lampu sein depan ada di sampul depan.

Aturan 34: lampu belakang dibuat.

Aturan 35: sinyal belok belakang dibuat.

Aturan 36: rangkaian integral lampu belakang dan lampu sein belakang dipasang pada penutup bodi.

Aturan 37: lampu belakang dan lampu sein belakang yang tidak terpisahkan dipasang di kursi.

---

## BAB 4

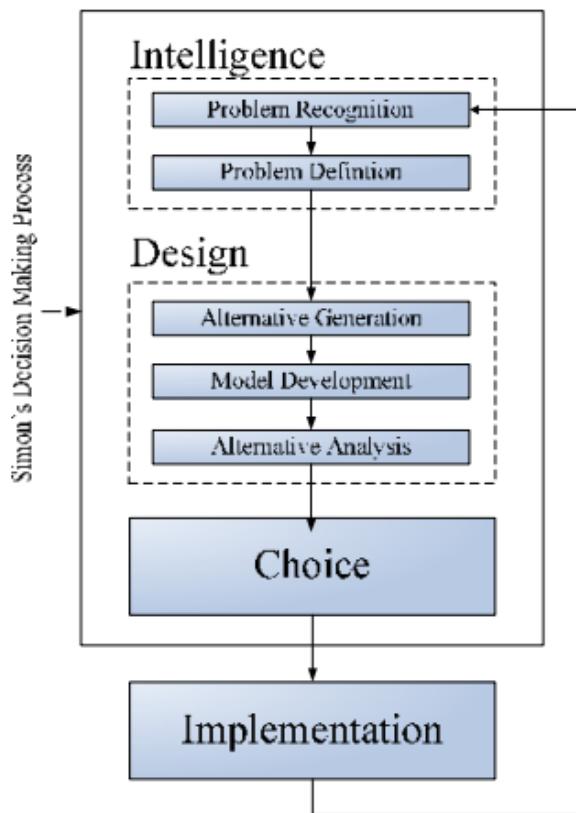
### PENINGKATAN SISTEM PENDUKUNG KEPUTUSAN DENGAN MODEL NEURAL FUZZY DAN VISUALISASI MODEL SEDERHANA

Proses pengambilan keputusan dan penciptaan pengetahuan saling bergantung karena proses pengambilan keputusan itu sendiri akan menghasilkan pemahaman yang lebih baik tentang masalah dan proses, dan menghasilkan pengetahuan baru. Integrasi dukungan keputusan dan manajemen pengetahuan dapat meningkatkan kualitas dukungan untuk pengambil keputusan, dan memberikan dukungan kualitas adalah kunci untuk sistem pendukung keputusan (DSS). Namun, orang memiliki kendala kognitif untuk sepenuhnya memahami dukungan yang mereka dapatkan dari DSS. Makalah ini menyajikan pendekatan baru untuk memecahkan eksternalisasi model dengan mempertimbangkan sifat yang tidak tepat dari penilaian pembuat keputusan pada model diam-diam yang berbeda. Pengetahuan dalam bentuk aturan fuzzy yang sangat intuitif dan mudah dipahami dibuat menggunakan sistem neuro-fuzzy yang disebut Tree-based Neural Fuzzy Inference System (TNFIS). TNFIS menggunakan algoritme pembelajaran struktur baru yang terinspirasi dari penekanan konstruktivis Piaget tentang perkembangan kognitif berbasis tindakan pada manusia. Teknik visualisasi sederhana dari model neuro-fuzzy eksplisit juga diusulkan dalam makalah ini untuk meningkatkan kemampuan internalisasi pekerja berpengetahuan. Hasil dari eksperimen menunjukkan bahwa TNFIS mampu merepresentasikan model eksplisit yang diformulasikan menggunakan seperangkat basis pengetahuan aturan fuzzy yang ringkas dan intuitif, dan mencapai generalisasi yang lebih baik atau sebanding daripada model lainnya. Visualisasi model TNFIS yang dirumuskan juga ditunjukkan untuk meningkatkan pemahaman pembuat keputusan tentang domain masalah dan internalisasi selanjutnya dari model yang dipilih.

#### **4.1 PENDAHULUAN**

Arus data, informasi, dan pengetahuan yang melimpah dari sumber yang semakin banyak jumlahnya akan terus tumbuh dan menjadi semakin kompleks. Ini telah menggarisbawahi perlunya beberapa bentuk sistem pendukung keputusan (DSS) untuk menangani kompleksitas yang semakin meningkat dalam konteks perencanaan yang efektif, pemecahan masalah, pengambilan keputusan, dan pelaksanaan operasi dan manajemen bisnis [1, 2]. Konsep DSS didefinisikan oleh Gorry dan Scott Morton [3], yang menggabungkan kategori aktivitas manajemen Anthony [4], dan kecerdasan, desain, dan deskripsi pilihan Simon dari proses pengambilan keputusan [5]. Dalam kerangka kerja mereka, kecerdasan terdiri dari pencarian kondisi yang membutuhkan keputusan, desain melibatkan pengembangan solusi yang mungkin untuk masalah, dan pilihan terdiri dari menganalisis dan memilih salah satu solusi untuk implementasi. Gambar 1 mengilustrasikan model proses pengambilan keputusan dalam lingkungan DSS. Proses pengambilan keputusan pada Gambar 1 menekankan pada analisis masalah dan pengembangan model. Setelah masalah dikenali dan didefinisikan, solusi alternatif dibuat dan model selanjutnya dikembangkan untuk menganalisis berbagai alternatif. Sebuah pilihan kemudian dibuat dan diimplementasikan.

Kerangka ini sesuai dengan deskripsi Simon [5]. Umumnya, tahap ini tumpang tindih dan mengulang kembali ke tahap sebelumnya karena lebih banyak informasi diperoleh tentang masalah tersebut.



**Gambar 4.1** Proses pengambilan keputusan DSS dimodifikasi dari [6]

DSS telah berkembang dari dua bidang utama penelitian: studi teoritis pengambilan keputusan organisasi dan pekerjaan teknis [7]. Dengan kemajuan teknologi komputer, DSS komputerisasi baru dikembangkan dan dipelajari. Saat ini masih mungkin untuk merekonstruksi sejarah DSS. Dua kategori besar DSS telah didefinisikan dan mereka adalah: sistem pendukung keputusan berbasis model, dan berbasis pengetahuan [6, 8]. Model-based DSS dapat dibagi menjadi tiga tahap: formulasi, solusi, dan analisis. Tahap formulasi melibatkan pembuatan model dalam bentuk yang dapat diterima oleh pekerja pengetahuan. Tahap solusi mengacu pada pengembangan model untuk memecahkan masalah. Tahap analisis mengacu pada analisis dan interpretasi solusi model. Pada tahap analisis, solusi model disampaikan dalam bentuk yang dapat digunakan untuk meningkatkan kemampuan menganalisis dan memahami masalah dan solusi. Pendekatan ini konsisten dengan kecerdasan, desain, dan deskripsi pilihan Simon dari proses pengambilan keputusan [5]. DSS berbasis pengetahuan adalah sistem yang dapat menangkap, mengatur, memanfaatkan, dan menyebarkan tidak hanya data dan informasi tetapi juga pengetahuan tentang perusahaan. DSS berbasis pengetahuan dapat meningkatkan model mental dan pemahaman membuat keputusan dengan menyediakan pola yang menarik dan model keputusan terkini yang dapat diambil dan dibagikan ke seluruh organisasi.

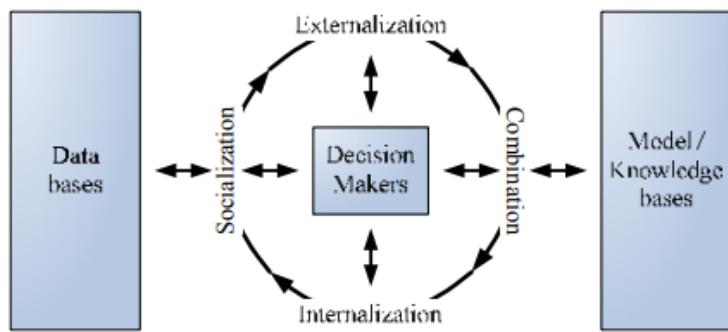
Kebutuhan akan dukungan keputusan aktif ditegaskan oleh Keen, dan Carlsson et al. [9, 10]. Fungsi DSS adalah "untuk memperluas kemampuan (pengambil keputusan) mereka

tetapi tidak untuk menggantikan penilaian mereka" dan "untuk mendukung solusi dari masalah tertentu" seperti yang didefinisikan oleh Turban et al. [11]. DSS juga diklasifikasikan oleh Arnott dan Pervan [12] sebagai "bidang disiplin sistem informasi yang berfokus pada mendukung dan meningkatkan pengambilan keputusan manajerial". Dukungan inilah yang menjadi kunci pentingnya DSS. Masalah utama penggunaan DSS tidak sepenuhnya terkait dengan teknologi tetapi lebih pada masalah yang terkait dengan manusia [10, 13, 14]. Orang-orang memiliki kendala kognitif untuk benar-benar memahami dukungan yang mereka peroleh dari DSS. Seringkali masalah dan keputusan terlalu tidak jelas untuk dikodifikasi secara memadai dan disematkan dalam program komputer. Kemampuan pengambilan keputusan manusia dapat didukung dan ditingkatkan dengan penggunaan DSS untuk membuat keputusan yang lebih baik dan lebih efektif menangani masalah sulit yang tidak terstruktur atau semi terstruktur tanpa pengalaman yang luas dan pengetahuan ahli.

Sebagian besar organisasi memandang pengetahuan sebagai sumber daya strategis, dan memanfaatkan pengetahuan itu dalam pengambilan keputusan sebagai kemampuan strategis [15]. Ada dua strategi manajemen pengetahuan yang sangat berbeda: strategi personalisasi atau strategi kodifikasi [16]. Dalam strategi personalisasi, pengetahuan dibagi terutama melalui kontak orang-ke-orang dan tujuan utama komputer adalah untuk membantu orang berkomunikasi. Untuk strategi kodifikasi, pengetahuan dikodifikasi dengan hati-hati dan disimpan dalam database, di mana ia dapat diakses dan digunakan oleh siapa saja dalam organisasi.

Dalam proses pengambilan keputusan, pengambil keputusan menggabungkan berbagai jenis data dan pengetahuan yang tersedia dalam berbagai bentuk dalam organisasi. Pengambilan keputusan dan proses penciptaan pengetahuan saling bergantung karena proses pengambilan keputusan itu sendiri umumnya akan menghasilkan pemahaman yang lebih baik tentang masalah dan proses, dan menghasilkan pengetahuan baru. Dukungan keputusan dan manajemen pengetahuan dapat diintegrasikan untuk meningkatkan kualitas dukungan yang diberikan kepada pengambil keputusan [17]. Gambar 2 mengilustrasikan kerangka kerja yang diusulkan oleh Bolloju et al. untuk mengembangkan lingkungan pendukung keputusan perusahaan yang dikombinasikan dengan manajemen pengetahuan. Kerangka kerja ini mengintegrasikan model proses penciptaan pengetahuan Nonaka [18], di mana pengetahuan organisasi dibuat melalui dialog berkelanjutan antara empat pola interaksi yang melibatkan pengetahuan tacit dan eksplisit. Keempat pola interaksi tersebut adalah: sosialisasi, eksternalisasi, kombinasi, dan internalisasi.

Organisasi modern sekarang dapat mengumpulkan dan memelihara volume besar data di gudang data. Sebuah gudang data menyediakan pekerja pengetahuan dengan informasi faktual dasar. Namun, hanya sebagian kecil dari jumlah data yang mungkin diperlukan. Selain itu, mengidentifikasi informasi yang relevan mungkin sulit jika bukan tidak mungkin. Kecuali pekerja pengetahuan memahami informasi tentang data yang mereka kerjakan, gudang data tidak selalu memberikan dukungan yang memadai bagi pekerja pengetahuan.



**Gambar 4.2** Integrasi lingkungan pendukung keputusan dan manajemen pengetahuan yang diadaptasi dari [17]

Model mart dan model warehouse [17] dapat diimplementasikan untuk menangkap pengetahuan eksternal dengan menggunakan teknik seperti data mining. Model mart dan model warehouse bertindak sebagai gudang pengetahuan untuk model keputusan operasional dan historis dan mereka menyediakan platform untuk membangun memori organisasi, memahami pola pengambilan keputusan masa lalu, dan menganalisis perubahan pola selama periode waktu yang berbeda. Karena banyak masalah keputusan operasional yang berulang, dimungkinkan untuk menghasilkan model keputusan berdasarkan keputusan historis. Pengetahuan tacit dapat direpresentasikan dalam bentuk contoh keputusan dan data terkait yang disimpan dalam basis data. Contoh keputusan dan data terkait mencerminkan model tacit historis dan terkini dari pandangan pembuat keputusan yang berbeda tentang domain masalah. Berbagi model diam-diam seperti itu memungkinkan sosialisasi di mana setiap pembuat keputusan belajar dari model diam-diam satu sama lain. Pengetahuan eksplisit dalam bentuk model keputusan yang dapat diisi dalam model/basis pengetahuan melalui eksternalisasi dan kombinasi pengetahuan. Eksternalisasi pengetahuan melibatkan konversi model tacit menjadi pengetahuan/model eksplisit yang dapat disimpan dalam model/basis pengetahuan. Kombinasi pengetahuan melibatkan kombinasi model eksplisit yang ada melalui generalisasi model eksplisit atau teknik integrasi. Fase internalisasi mengacu pada konversi model eksplisit bersama menjadi model tacit, yang menghasilkan modifikasi dan peningkatan model tacit individu.

Pengetahuan eksplisit yang disimpan dalam bentuk contoh dalam model sistem neuro-fuzzy dapat dimanfaatkan melalui sistem analisis model deduktif dan/atau induktif [19]. Di sini, sistem neuro-fuzzy dapat digunakan untuk menjelaskan model atau desain dalam kaitannya dengan prinsip-prinsip dasar yang mendasarinya; misalnya, formula yang mendasari dan hubungan antara neraca, laporan laba rugi dan laporan aliran dana dalam masalah keuangan bisnis. Selain itu, sistem neuro-fuzzy juga dapat digunakan untuk mengembangkan wawasan ke dalam lingkungan bisnis yang diwakili oleh model berbasis aturan fuzzy. Pengetahuan baru yang diperoleh selanjutnya dapat digunakan untuk membantu pengambil keputusan dalam menentukan tindakan organisasi.

Sistem neuro-fuzzy adalah model kecerdasan komputasi lunak yang dapat dikategorikan sebagai DSS yang digerakkan oleh model atau yang digerakkan oleh pengetahuan. Model neuro-fuzzy adalah estimator bebas model numerik [20-22] yang dibentuk oleh sinergi sistem fuzzy dan jaringan saraf. Pendekatan neural-fuzzy adalah *Sistem Pendukung Keputusan (Dr Joseph Teguh Santoso dan Budi Hartono, M.Kom)*

komponen kunci dari komputasi lunak [23], di mana sinergi menyediakan kemampuan pemrosesan informasi yang fleksibel untuk menangani situasi kehidupan nyata yang kompleks dan tidak pasti dan menciptakan hubungan simbiosis di mana sistem fuzzy menyediakan kerangka kerja yang kuat untuk representasi pengetahuan ahli sementara jaringan saraf melengkapi sistem fuzzy dengan kemampuan belajar yang cocok untuk implementasi perangkat keras yang efisien secara komputasi [24-28].

Jaringan syaraf tiruan itu sendiri tidak memiliki kemampuan penjelasan yang merupakan persyaratan untuk akuntabilitas keputusan dalam banyak masalah bisnis. Kesederhanaan representasi model eksplisit dalam hal aturan fuzzy sangat cocok bagi pengambil keputusan untuk memahami dan menginternalisasi. Model neuro-fuzzy dengan demikian mampu menggambarkan domain masalah menggunakan model linguistik. Model linguistik memberikan representasi deklaratif eksplisit dari pengetahuan tentang domain masalah, dalam bentuk seperangkat aturan fuzzy if-then yang sangat intuitif dan mudah dipahami. Kemampuan penjelas model neuro-fuzzy ini juga dapat digunakan dalam verifikasi logika internal model di mana keadaan internal sistem dapat diakses dan ditafsirkan secara jelas. Mekanisme penjelasan ini memungkinkan platform bagi pembuat keputusan pemula untuk mendapatkan wawasan tentang masalah yang dihadapi. Pengambil keputusan juga dapat menggunakan aturan fuzzy untuk mengidentifikasi daerah di ruang input yang tidak cukup terwakili dalam model, dan untuk melengkapi model eksplisit dengan model tacit. Selain itu, di mana terdapat pakar manusia yang pengetahuannya dapat digabungkan dalam bentuk aturan if-then ke model eksplisit yang ada melalui kombinasi pengetahuan [29]. Dalam konteks ini, penyempurnaan model keputusan dapat dilakukan. Pemodelan neuro-fuzzy cocok untuk pembelajaran tambahan di mana pengetahuan baru dalam bentuk aturan fuzzy dapat dengan mudah diintegrasikan ke dalam dan pengetahuan yang tidak sesuai dapat dihilangkan dari model/basis pengetahuan DSS yang ada. Basis pengetahuan menyediakan pembuat keputusan dengan platform analitis cerdas untuk sosialisasi, artikulasi, integrasi, dan pemahaman manajemen pengetahuan. Penggunaan pengetahuan yang dihasilkan bahasa alami memberikan kemampuan untuk memvalidasi model, dan mengidentifikasi pengetahuan baru yang dibuat dalam proses.

Selain itu, ketidakpastian secara inheren ada di hampir semua masalah kompleks dunia nyata modern. Penggabungan teori himpunan fuzzy dalam sistem neuro-fuzzy menciptakan model keputusan komputasi lunak yang mampu memanfaatkan pengetahuan dalam bentuk bahasa alami yang menyediakan kemampuan untuk menangani ketidaktepatan dan ketidakpastian. Makalah ini menyajikan pendekatan baru untuk memecahkan eksternalisasi model dengan mempertimbangkan sifat yang tidak tepat dari penilaian pembuat keputusan pada model diam-diam yang berbeda. Proses pengambilan keputusan yang melibatkan masalah yang tidak terstruktur atau semi terstruktur lebih subjektif direpresentasikan sebagai pengambil keputusan cenderung menggunakan intuisi dan pengalaman mereka dalam proses. Pandangan yang berbeda diekspresikan dengan menggunakan himpunan fuzzy yang berbeda. Pengetahuan berupa aturan fuzzy dibuat menggunakan sistem neuro-fuzzy yang disebut dengan Tree-based Neural Fuzzy Inference System (TNFIS). TNFIS menggunakan algoritme pembelajaran struktur baru yang terinspirasi dari penekanan konstruktivis Piaget tentang perkembangan kognitif berbasis tindakan; tindakan motorik daripada input sensorik

menentukan bentuk jaringan [30]. Teknik visualisasi sederhana dari model neuro-fuzzy eksplisit juga diusulkan dalam makalah ini untuk meningkatkan kemampuan internalisasi pekerja pengetahuan.

Makalah ini disusun sebagai berikut. Bagian 2 memberikan tinjauan singkat tentang beberapa sistem neuro-fuzzy yang ada dan khususnya sistem yang menggabungkan pohon keputusan. Bagian 3 secara singkat menjelaskan TNFIS yang telah diusulkan di [31]. Bagian 4 memberikan contoh menggunakan TNFIS dalam model eksternalisasi model diam-diam, yaitu, Nakanishi [32], tungku gas [33], dan bunga iris [34] set data. Visualisasi dari model TNFIS eksplisit juga disediakan untuk membantu pekerja pengetahuan untuk menginternalisasi pengetahuan eksplisit yang ditemukan. Bagian 5 menyimpulkan makalah ini.

#### **4.2 PEKERJAAN TERKAIT**

Salah satu makalah pertama yang menggabungkan jaringan saraf dan logika fuzzy sebagai kata kunci diterbitkan pada tahun 1974 [35]. Lee dkk. mengusulkan fuzzy neuron yang digeneralisasi dari model neuron MP [36]. Sampai saat ini, ada banyak pendekatan yang berbeda untuk membangun sistem neural-fuzzy yang terintegrasi selain pandangan yang berbeda dalam kategorisasi sistem hybrid ini [22, 37-39]. Terlepas dari bagaimana sistem ini dikategorikan, alasan mendasar untuk integrasi kedua sistem adalah untuk menggabungkan kekuatan dari masing-masing sistem. Pada bagian berikut, beberapa sistem neuro-fuzzy [38], serta penggabungan pohon keputusan yang mencoba mensinergikan kedua pendekatan; yaitu: sistem fuzzy dan sistem terintegrasi neural-fuzzy dibahas.

##### **Sistem Neuro-fuzzy**

Kelemahan utama dari sistem logika fuzzy adalah ketidakmampuan mereka untuk beradaptasi dan belajar. Jaringan syaraf tiruan, di sisi lain, digunakan untuk menambah sistem berbasis aturan fuzzy dengan metode pembelajaran yang mampu secara sistematis menyesuaikan parameter sistem berbasis aturan fuzzy, seperti himpunan fuzzy parameter yang mewakili istilah linguistik dari aturan fuzzy. Sistem berbasis. Sistem terintegrasi seperti ini disebut sebagai sistem neuro-fuzzy [38].

Beberapa sistem neuro-fuzzy yang ada memperlakukan penggunaan jaringan saraf sebagai komposisi fungsi (fungsi keanggotaan, operator agregasi, koneksi fuzzy, metode defuzzifikasi). Prosedur analitis kemudian diterapkan untuk menyesuaikan parameter dari salah satu fungsi tersebut berdasarkan evaluasi fungsi objektif. Sistem yang menggunakan konsep ini adalah [39-52], di mana fungsi keanggotaan disetel menggunakan metode penurunan gradien.

Sistem dari [50, 53-55] melakukan klasifikasi tanpa pengawasan (pengelompokan) selama tahap awal untuk mendapatkan partisi awal dari ruang input. Fungsi keanggotaan selanjutnya dibangun dari partisi ini. Jenis sistem ini sangat dibatasi oleh metode pengelompokan yang dilakukan pada tahap awal, dan yang lebih penting, selanjutnya akan diperparah dengan metode pengelompokan berdasarkan kepadatan spasial karena sparitas data dalam ruang dimensi tinggi [56]. Selanjutnya, cluster yang baik dapat mewakili kelas yang berbeda dari pola data dan cluster yang berbeda dapat berisi pola data dari satu kelas [57]. Selain itu, seperti yang dicatat oleh Duda dan et al. [58], diskriminasi lebih penting jika tujuannya adalah untuk membedakan pola data; yaitu: Oleh karena itu, aturan fuzzy yang

dibuat dari sebuah cluster mungkin tidak mewakili korelasi yang benar antara input lokal tertentu dan ruang output terkait. Kelemahan lain dengan menggunakan metode clustering adalah kebutuhan pengguna untuk menentukan jumlah cluster yang akibatnya menentukan jumlah aturan.

Sistem lain [39, 46, 48, 59] menggunakan beberapa bentuk algoritma pengelompokan (pembelajaran kompetitif) untuk terlebih dahulu menyesuaikan fungsi keanggotaan linguistik. Aturan kemudian dipilih oleh beberapa kriteria selama fase pembelajaran kompetitif. Pembelajaran terbimbing untuk melatih parameter fungsi keanggotaan linguistik dilakukan selama fase terakhir. Sistem neuro-fuzzy seperti yang diusulkan dalam [39, 46, 48, 51] umumnya menggunakan lima lapisan struktur jaringan saraf feedforward yang terhubung sebagian untuk menggambarkan aturan fuzzy tipe Mamdani dalam sistem. Lapisan kedua dan keempat dari jaringan masing-masing mewakili label fuzzy input dan output. Partisi yang dihasilkan dari ruang data pada dasarnya adalah grid fuzzy [60]. Partisi grid fuzzy adalah yang paling membatasi karena aturan fuzzy berbagi istilah linguistik input dan output yang tersedia. Untuk tugas klasifikasi, sistem logika fuzzy yang menggunakan partisi grid fuzzy dan tanpa menggunakan faktor kepastian untuk menggambarkan aturan pada dasarnya menjadi pengklasifikasi tabel loop-up ketika jumlah aturan ditingkatkan [61, 62]. Pendekatan ini bertentangan dengan seluruh gagasan memperkenalkan teori himpunan fuzzy untuk menangani ketidakpastian.

Sementara beberapa bentuk faktor kepastian diperkenalkan di sistem lain [48, 51], parameter ini hanya digunakan untuk pembuatan aturan yang konsisten selama fase pembelajaran struktur. Aturan fuzzy yang dikodekan dalam jaringan mereka pada dasarnya adalah aturan tanpa faktor kepastian. Sistem neuro-fuzzy dari [39, 46, 48, 49, 51, 52] di mana semua aturan yang mungkin pertama kali diisi dan kemudian dipangkas. Pendekatan list-all-then-prune ini umumnya membutuhkan sejumlah besar ruang memori karena tahap awal memerlukan penyimpanan semua informasi aturan. Sistem ini mengalami peningkatan eksponensial dalam jumlah aturan ketika dimensi data meningkat. Beberapa karya yang bertujuan untuk mengurangi jumlah aturan adalah algoritma pembelajaran LazyPOP [63], dan RSPOP [64].

### **Integrasi Pohon Keputusan**

Tujuan dari model neuro-fuzzy adalah untuk membangun sistem logika fuzzy yang mampu meramalkan dan menjelaskan perilaku sistem yang tidak diketahui. Tugas pemodelan biasanya dilakukan dalam dua tahap: identifikasi struktur dan pembelajaran parameter. Pembelajaran struktur berkaitan dengan penentuan jumlah aturan yang sesuai, skema pemilihan fitur, dan partisi ruang fitur yang tepat. Masalah yang masih harus ditangani adalah mengidentifikasi struktur yang baik untuk sistem inferensi fuzzy dalam menghadapi "kutukan dimensi", serta jumlah aturan yang optimal. Jang [65] menyarankan bahwa integrasi pohon keputusan dan sistem neuro-fuzzy dapat meringankan masalah ini.

Pohon keputusan adalah metode non-parametrik yang mampu menangani kumpulan data dengan nilai yang hilang dan sangat cocok dalam analisis data dimensi tinggi. Pohon keputusan dapat mengekstrak aturan yang berbeda dan memilih input yang relevan untuk menciptakan struktur yang benar-benar tepat dan kompak dengan tingkat interpretasi yang tinggi. Model seperti itu sangat mirip dengan penalaran manusia. Mereka didasarkan pada

metodologi bagi dan taklukkan dalam mempartisi ruang fitur menjadi wilayah yang saling eksklusif. Mereka cenderung berkinerja baik jika ada beberapa atribut yang sangat relevan. Pohon keputusan adalah pengklasifikasi yang tidak stabil karena sangat sensitif terhadap gangguan data pelatihan. Kebisingan dan atribut yang tidak relevan dapat sangat mempengaruhi kinerjanya.

Pohon keputusan lunak [66] adalah varian dari pembelajaran induktif pohon keputusan klasik dengan penggabungan teori himpunan fuzzy. Teknik fuzzy diintegrasikan dalam soft decision tree selama proses pertumbuhan pohon. Teknik pohon keputusan klasik telah terbukti dapat diinterpretasikan, efisien, bebas masalah dan mampu menangani aplikasi skala besar. Kelemahan utama dari pohon keputusan klasik adalah bahwa mereka adalah pengklasifikasi yang sangat tidak stabil sehubungan dengan gangguan kecil dalam data pelatihan. Penggabungan ketidakjelasan ke dalam pohon keputusan klasik meningkatkan stabilitas pohon keputusan.

Pendekatan lain yang memperoleh jaringan saraf dari pohon keputusan klasik dapat ditemukan di [57, 60, 67-73]. Baik AFLN [69], dan F-CID3 [71] mewarisi struktur jaringan mereka dari pohon keputusan. Prinsip dasarnya adalah untuk memetakan struktur pohon keputusan ke jaringan saraf feedforward. Neuron keputusan jaringan dikaitkan dengan fungsi yang digunakan untuk mewakili fungsi keanggotaan. Jaringan AFLN selanjutnya disetel dengan algoritme quickprop [74], sedangkan F-CID3 disetel dengan metode pelatihan Cauchy [75] yang merupakan salah satu bentuk metode penurunan gradien. F-CID3 adalah perpanjangan dari algoritma CID3 [68] yang menggabungkan teori himpunan fuzzy.

Lin dkk. [57] menginisialisasi jaringan saraf feedforward empat lapisan dengan aturan yang dihasilkan dari algoritma partisi seperti pohon biner heuristik. Ruang fitur masukan dipartisi secara rekursif pada lokasi tetap sampai salah satu perbedaan dalam label keluaran antara dua nampang yang dihasilkan dianggap tidak signifikan atau jumlah titik data minimum tercapai. MoDFuNC [73] yang terinspirasi dari SuPFuNIS [50] memiliki struktur awalnya diidentifikasi oleh pohon keputusan CART. Kepastian tinggi dan aturan kepastian rendah yang dihasilkan oleh pohon keputusan CART kemudian dipetakan ke sistem neuro-fuzzy. Aturan kepastian rendah yang dihasilkan oleh CART dapat dibagi lagi menjadi subset aturan sekunder yang menggunakan seperangkat variabel yang diperluas. Hal ini untuk memungkinkan identifikasi yang baik dari pola dalam partisi ini terkait dengan aturan kepastian yang rendah.

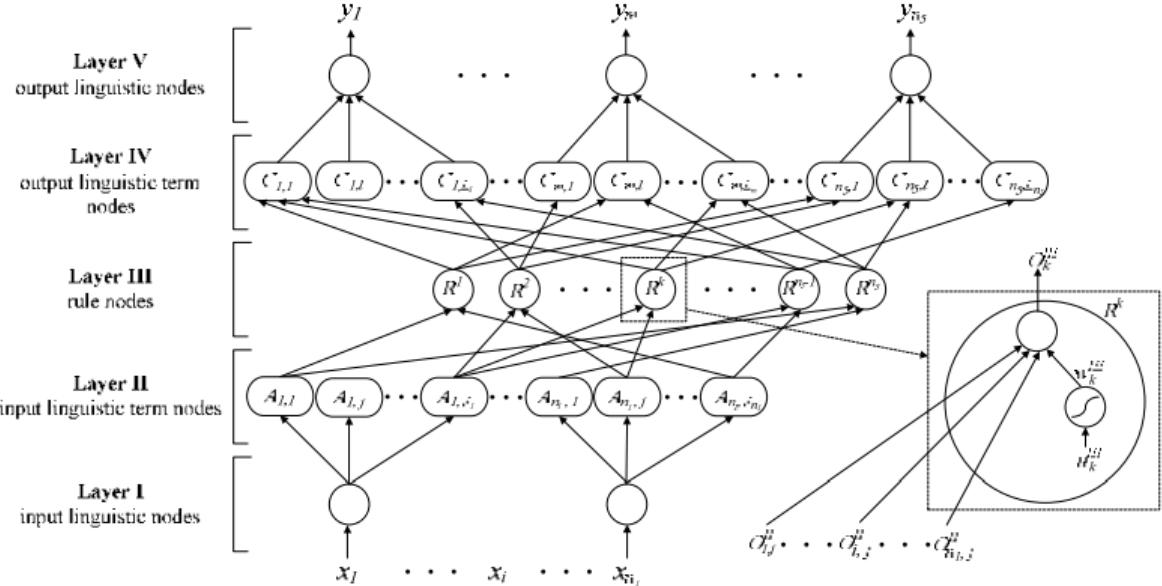
Organisasi awal jaringan saraf diwujudkan dengan pemanfaatan pohon keputusan di mana pola input yang merespon tindakan yang sama (milik kelas yang sama) dikelompokkan bersama dan pola input yang merespon tindakan yang berbeda dipisahkan. Penggunaan pohon keputusan dalam fase identifikasi struktur menyerupai pandangan kognitif Piaget tentang proses pengembangan kognitif yang digerakkan oleh tindakan yang diwujudkan dalam manusia.

#### **4.3 TNFIS: MODEL KOMPUTASI YANG TERINSPIRASI DARI PENGEMBANGAN KOGNITIF**

Pada bagian ini, struktur dan algoritma pembelajaran TNFIS [31] disajikan secara singkat.

##### **Struktur TNFIS**

TNFIS adalah jaringan feedforward lima lapisan seperti yang ditunjukkan pada Gambar. 3. Vektor  $\mathbf{x} = [x_1, \dots, x_n]^T$  mewakili input ke TNFIS. Setiap node di lapisan pertama jaringan mengambil satu elemen dari vektor input  $x$ . Lapisan terakhir dari jaringan terdiri dari node yang mewakili elemen output dari jaringan TNFIS. Setiap simpul keluaran menghitung elemen keluaran tunggal dari vektor keluaran  $\mathbf{y} = [y^1, \dots, y^n]^T$  terhadap vektor rangsangan masukan  $\mathbf{x}$ . Istilah linguistik diwakili oleh node di lapisan IV dan lapisan II. Node lapisan ketiga berfungsi sebagai node aturan. Setiap node aturan memiliki node kepastian aturannya sendiri.



Gambar 4.3 Struktur TNFIS

TNFIS secara konseptual terstruktur sebagai sistem neuro-fuzzy [38]. Struktur TNFIS dilatarbelakangi oleh dua pertimbangan. Pertimbangan pertama adalah untuk menghilangkan kesulitan dalam menafsirkan properti seperti kotak hitam dari jaringan saraf, untuk membuat model linguistik yang dapat dengan mudah mengakomodasi pengetahuan dalam bentuk aturan fuzzy if-then baik yang berasal dari data atau disediakan oleh pakar manusia. . Struktur TNFIS memfasilitasi perumusan model yang mudah, pengetahuan baru dalam bentuk aturan fuzzy dapat dengan mudah diintegrasikan atau pengetahuan yang tidak sesuai dihapus dari basis pengetahuan. Pertimbangan kedua adalah untuk memberikan informasi tambahan kepada pengambil keputusan tentang kepentingan relatif aturan berdasarkan faktor kepastian aturan. Faktor kepastian aturan memberikan indikasi tingkat kepercayaan aturan dalam basis pengetahuan.

Makalah ini menyajikan TNFIS yang mengadopsi model fuzzy Mamdani [76] dan mengimplementasikan skema Aturan Inferensi Komposisi (CRI) [77]. Propagasi sinyal maju TNFIS dibahas sebagai berikut. Setiap node di setiap lapisan memiliki jumlah terbatas koneksi fan-in dari node di lapisan sebelumnya, dan koneksi fan-out ke node di lapisan berikutnya.

#### Lapisan I: Masukan Linguistik Nodes

Ada  $n_1$  node di lapisan ini. Sebuah node di lapisan I mewakili variabel input linguistik. Node hanya menyebarkan nilai input non-fuzzy ke node istilah linguistik dari variabel linguistik yang sesuai di lapisan II. Input bersih  $f_i^l$  dan output bersih  $o_i^l$  dari linguistik ke-i dijelaskan dalam (1),

$$f_i^I = x_i, \quad o_i^I = f_i^I. \quad (1)$$

### Lapisan II: Masukan Node Istilah Linguistik

Ada

$$n_2 = \sum_{i=1}^{n_1} J_i$$

simpul istilah linguistik pada lapisan kedua. Setiap simpul istilah linguistik mewakili fungsi keanggotaan dari variabel fuzzy input tertentu.

Node istilah linguistik input  $A_{i,j}$  menunjukkan label linguistik input ke-j dari variabel linguistik ke-i.  $A_{i,j}$  diturunkan dari fungsi keanggotaan berbentuk lonceng. Input bersih  $f_{i,j}^{II}$  dan output bersih  $o_{i,j}^{II}$  dari simpul istilah linguistik input  $A_{i,j}$  diberikan dalam (2),

$$f_{i,j}^{II} = -\frac{(o_i^I - c_{i,j}^{II})^2}{2(\sigma_{i,j}^{II})^2}, \quad o_{i,j}^{II} = e^{f_{i,j}^{II}}. \quad (2)$$

Dalam (2),  $c_{i,j}^{II}$  dan  $\sigma_{i,j}^{II}$  masing-masing adalah pusat dan lebar fungsi keanggotaan Gaussian dari label linguistik ke-j dari variabel linguistik masukan ke-i. Pengoperasian node istilah linguistik setara dengan fuzzifikasi input tunggal.

### Lapisan III: Rule Node

Sebuah node di lapisan ini mewakili aturan fuzzy. Setiap node aturan melakukan operasi fuzzy AND. masukan bersih  $f_k^{III}$  dan keluaran bersih  $o_k^{III}$  dari simpul aturan ke-k adalah didefinisikan dalam (3),

$$f_k^{III} = w_k^{III} \cdot \prod_{(i,j) \in A_k^{III}} o_{i,j}^{II}, \quad o_k^{III} = f_k^{III}. \quad (3)$$

Pada (3),  $A_k^{III}$  adalah himpunan simpul antecedent (simpul istilah linguistik input) di lapisan II yang terhubung ke simpul aturan ke-k di lapisan III, dan  $w_k^{III}$  mewakili faktor kepastian aturan dari aturan ke-k. Setiap simpul aturan kepastian dilampirkan ke simpul aturan di lapisan III, dan setiap simpul aturan di lapisan III hanya memiliki satu simpul kepastian aturan yang melekat padanya. Faktor kepastian aturan diturunkan dari output fungsi sigmoidal yang dijelaskan oleh (4),

$$w_k^{III} = \frac{1}{1 + e^{-\lambda_k^{III} u_k^{III}}}. \quad (4)$$

Dalam (4),  $\lambda_k^{III}$  menentukan kecuraman fungsi sigmoidal dari simpul kepastian aturan ke-k.

#### Lapisan IV: Output Linguistic Term Nodes

Ada

$$n_4 = \sum_{m=1}^{n_5} L_m$$

node pada lapisan ini. Setiap simpul pada lapisan ini mewakili istilah/label linguistik keluaran dan melakukan operasi fuzzy OR pada semua aturan fuzzy yang mengarah ke konsekuensi yang sama. masukan bersih  $f_{m,l}^{IV}$  dan keluaran bersih  $o_{m,l}^{IV}$  dari simpul istilah linguistik keluaran  $C_{m,l}$  didefinisikan dalam (5),

$$f_{m,l}^{IV} = \max_{k \in R_{m,l}^{IV}} (o_k^{III}), \quad o_{m,l}^{IV} = f_{m,l}^{IV}. \quad (5)$$

Pada (5),  $R_{m,l}^{IV}$  adalah himpunan node aturan pada layer III yang terhubung ke node konsekuensi ke-l pada layer IV dari variabel linguistik keluaran ke-m.

#### Lapisan V: Output Linguistic Nodes

Sebuah simpul di lapisan ini mewakili variabel linguistik keluaran. Fungsi berikut seperti yang didefinisikan pada (6) digunakan untuk mensimulasikan metode defuzzifikasi pusat daerah. masukan bersih  $f_m^V$  dan keluaran bersih  $o_m^V$  dari variabel linguistik keluaran ke-m didefinisikan dalam (6),

$$f_m^V = \sum_{l=1, \dots, L_m} c_{m,l}^{IV} \sigma_{m,l}^{IV} o_{m,l}^{IV}, \quad o_m^V = \frac{f_m^V}{\sum_{l=1, \dots, L_m} \sigma_{m,l}^{IV} o_{m,l}^{IV}}. \quad (6)$$

Dalam (6),  $L_m$  adalah jumlah total simpul suku linguistik keluaran pada lapisan IV yang terkait dengan variabel keluaran ke-m, dan  $c_{m,l}^{IV}$  dan  $\sigma_{m,l}^{IV}$  berturut-turut adalah pusat dan lebar suku ke-l dari variabel keluaran ke-m.

#### Algoritma Pembelajaran TNFIS

Algoritma pembelajaran untuk sistem neuro-fuzzy yang diusulkan terdiri dari dua fase: fase pembelajaran struktur berbasis tindakan Piaget, dan fase penyetelan parameter.

#### Fase Identifikasi Struktur Berbasis Tindakan Piaget

Pada bagian ini, pandangan kognitif Piaget tentang proses perkembangan kognitif yang digerakkan oleh tindakan pada manusia yang digunakan dalam identifikasi struktur TNFIS dibahas.

Perbedaan mendasar antara psikologi kognitif dan Piaget terletak pada pandangan masing-masing terhadap bahasa. Psikologi kognitivis biasanya memandang semua aktivitas mental sebagai pemrosesan simbolik, sedangkan bagi Piaget, bahasa dipandang hanya sebagai salah satu aspek kognisi yang diturunkan dari kognisi nonlinguistik (sensori-motorik). Piaget memandang bahwa kecerdasan pada dasarnya non-linguistik dan diturunkan dari tindakan,

bukan dari bahasa. Karakteristik terdistribusi dari jaringan saraf, di mana input dipetakan ke output melalui organisasi internal jaringan saraf (arsitektur jaringan dan bobot koneksi), menyerupai definisi skema Piaget. Skema adalah perangkat adaptif yang secara otomatis mengasimilasi input baru ke skema yang sudah ada dan mengakomodasi skema yang ada sebagai fungsi dari input baru. Organisasi awal jaringan saraf perlu diwujudkan dengan fase pembelajaran struktur sedemikian rupa sehingga jaringan mematuhi dua prinsip umum berikut:

1. Untuk membuat pola input yang merespon tindakan yang sama lebih mirip satu sama lain,
2. Untuk membuat pola input yang merespon tindakan yang berbeda lebih berbeda satu sama lain.

Kedua prinsip umum ini dicapai oleh algoritma pembelajaran struktur. Tujuan dari algoritma pembelajaran struktur adalah untuk memisahkan contoh keputusan yang berasosiasi dengan derajat yang berbeda untuk tindakan yang berbeda. Fase belajar struktur terdiri dari dua langkah. Pada langkah pertama, instance data terlebih dahulu dipisahkan. Pada langkah kedua, aturan fuzzy dihasilkan dari pengelompokan data yang ditemukan pada langkah pertama. Aturan fuzzy ini selanjutnya dipetakan ke dalam struktur TNFIS. Misalnya, klasifikasi dari satu set contoh keputusan ke dalam satu set kelas yang berbeda adalah jenis umum dari masalah yang umum digunakan dalam lingkungan pengambilan keputusan kehidupan nyata. Persetujuan kredit, perdagangan sekuritas, pemilihan produk, estimasi risiko, dan pemilihan pelanggan adalah beberapa contoh masalah klasifikasi. Langkah pertama dari algoritme akan mengelompokkan contoh data menurut penilaian pembuat keputusan tentang jenis kelas yang berbeda, dan langkah kedua akan mengaitkan kelompok yang berbeda dari contoh data ke salah satu kelas pembuat keputusan. Untuk penyederhanaan ilustrasi, mari kita pertimbangkan hanya satu variabel keluaran. Sepasang data  $(x_{p,1}, \dots, x_{p,n}; y_{p,1})$  diberi nilai linguistik keluaran  $C_{1,l}$  sebagaimana didefinisikan dalam (7) jika,

$$\mu_{C_{1,l}}(y_{p,1}) > \mu_{C_{1,q}}(y_{p,1}); l, q = 1, \dots, L_1; l \neq q . \quad (7)$$

Dalam (7),  $L_1$  adalah jumlah keluaran istilah linguistik. Label linguistik keluaran bahwa pola data memiliki nilai keanggotaan maksimum ditetapkan ke pola data seperti yang dijelaskan oleh (7). Pada akhir langkah ini, setiap pola data diberi tag ke istilah linguistik keluaran tertentu berdasarkan tingkat keanggotaan pola data keluaran yang sesuai dengan suku linguistik keluaran.

Tujuan dari langkah pertama adalah untuk menentukan partisi dari ruang fitur masukan sedemikian rupa sehingga setiap partisi dalam ruang fitur masukan berisi sebanyak mungkin pola data yang ditandai dengan label linguistik keluaran yang sama. Ruang data fitur input dibagi secara iteratif hingga jumlah maksimum pemisahan yang diizinkan pada setiap sumbu fitur tercapai atau ketika semua partisi berisi pola data yang termasuk dalam istilah linguistik keluaran yang sama. Karena suatu pola sebagian dapat dimiliki oleh label linguistik keluaran yang berbeda, kriteria pemisahan didasarkan pada ukuran pengotor kesalahan klasifikasi lunak (lihat (8)) yang diturunkan dari ukuran pengotor kesalahan klasifikasi [78].

Dengan setiap pemisahan, seluruh ruang fitur dipartisi menjadi sejumlah sel hiper-persegi panjang yang terbatas. Setiap sel dievaluasi untuk kesalahan klasifikasi lunaknya. Kesalahan klasifikasi lunak  $E_{soft}(c)$  untuk sel cth dievaluasi seperti pada (8),

$$E_{soft}(c) = 1 - \max_l^{L_1} F_{soft}(C_{1,l}|c). \quad (8)$$

Dalam (8),  $F_{soft}(C_{1,l}|c)$  mewakili frekuensi lunak relatif dari pola data ke label linguistik keluaran  $C_{1,l}$  dalam sel cth, dan dihitung dalam (9),

$$F_{soft}(C_{1,l}|c) = \frac{\sum_{p=1}^{N_c} \mu_{C_{1,l}}(y_{p,1})}{\sum_{q=1}^{L_1} \sum_{p=1}^{N_c} \mu_{C_{1,q}}(y_{p,1})}. \quad (9)$$

Pada (9),  $N_c$  menyatakan banyaknya pola data yang terdapat pada partisi c. Persamaan (9) mempertimbangkan nilai keanggotaan pola data sehubungan dengan label linguistik keluaran lainnya. Jika fungsi delta digunakan untuk mewakili fungsi keanggotaan keluaran (untuk tugas klasifikasi), (9) mengurangi akurasi relatif dari pola data milik label linguistik keluaran  $C_{1,l}$  dalam sel c. Pemisahan yang menghasilkan kesalahan klasifikasi lunak berbobot minimum dipilih. Kesalahan klasifikasi lunak berbobot minimum dihitung seperti pada (10),

$$E_{soft} = \sum_{c=1}^{N_{space}} \frac{N_c}{N} E_{soft}(c). \quad (10)$$

Dalam (10),  $N_{space}$  mewakili jumlah total subruang yang dibuat oleh pemisahan, dan N mewakili jumlah total pola data. Setelah serangkaian pemisahan, ruang fitur input dibagi menjadi kisi-kisi yang berisi jumlah terbatas dari partisi/sel batas-garing hiper-persegi panjang. Partisi crisp ini selanjutnya diubah menjadi partisi fuzzy yang memiliki batas keputusan fuzzy dengan menggunakan fungsi keanggotaan Gaussian. Setiap fungsi keanggotaan Gaussian digunakan untuk mewakili segmen split dari sumbu fitur. Pusat fungsi Gaussian untuk segmen pertama dan terakhir dari suatu fitur diatur ke nilai rentang operasi minimum yang sesuai dan nilai operasi maksimum masing-masing. Untuk segmen lain, pusat fungsi Gaussian ditetapkan sebagai rata-rata titik akhir segmen split yang sesuai. Lebar dari fungsi keanggotaan Gaussian yang sesuai kemudian dihitung untuk memenuhi completeness.

Langkah pertama ini mengilustrasikan fakta bahwa organisasi awal jaringan saraf motorik sensorik ditentukan oleh tindakan motorik (label konsekuensi/kelas) yang dengannya organisme harus merespons berbagai masukan sensorik. Dengan aksi motorik yang diberikan (istilah linguistik keluaran), algoritme partisi ruang data mengelompokkan input jika input tersebut harus ditanggapi dengan aksi motorik yang sama, dan memisahkan input jika input tersebut harus direspon dengan aksi motorik yang berbeda. Ini menyiratkan bahwa tindakan

daripada input sensorik yang menentukan bentuk jaringan saraf dan sesuai dengan penekanan konstruktivis Piaget pengetahuan pandangan berbasis tindakan dalam pengembangan kognisi [30].

Pada langkah kedua, aturan fuzzy dibangkitkan berdasarkan partisi fuzzy dari langkah pertama. Untuk setiap partisi fuzzy input yang tidak kosong, aturan fuzzy dibuat dengan bagian antecedent dari aturan tersebut sesuai dengan input subruang fuzzy. Partisi fuzzy tak kosong adalah subruang yang berisi setidaknya pola data dengan setidaknya nilai keanggotaan untuk setiap variabel input linguistik. Pola yang diapit oleh partisi fuzzy yang dikonversi dari partisi crisp juga merupakan pola yang awalnya diapit oleh partisi crisp. Bagian konsekuensi dari aturan fuzzy yang sesuai  $R_k$  ditugaskan dengan istilah linguistik keluaran yang paling dominan  $C_{1,l}^k$  seperti yang didefinisikan dalam (11),

$$\begin{aligned} \text{dominant}_{C_{1,l}} &= \sum_{p \in \text{partition}} \left( \prod_{i=1}^{n_1} \mu_{A_{i,j}^k}(x_{p,i}) \right) \cdot \mu_{C_{1,l}}(y_{p,1}), \\ C_{1,l}^k &= \arg \max_l (\text{dominant}_{C_{1,l}}); l = 1, \dots, L_1. \end{aligned} \quad (11)$$

Dalam (11),  $\mu_{A_{i,j}^k}$  mewakili tingkat keanggotaan label linguistik input ke-j dari variabel input ke-i yang terkait dengan aturan ke-k,  $\mu_{C_{1,l}}$  mewakili tingkat keanggotaan label linguistik keluaran ke-l dari variabel keluaran pertama. Aturan fuzzy  $R^k$  diberikan faktor kepastian aturan  $W_k^{III}$  yang didefinisikan seperti pada (12),

$$w_k^{III} = \frac{\max(\text{dominant}_{C_{1,l}})}{\sum_{l=1}^{L_1} \text{dominant}_{C_{1,l}}}; l = 1, \dots, L_1. \quad (12)$$

### Fase Penyetelan Parameter

Pada fase ini, parameter jaringan TNFIS disetel dengan baik oleh skema pembelajaran gradien-turunan terawasi berdasarkan algoritma propagasi balik kesalahan [79]. Kesalahan sesaat antara keluaran jaringan dan nilai yang diinginkan adalah umpan balik ke jaringan untuk menyesuaikan parameter keanggotaan fuzzy dan faktor kepastian aturan.

#### 4.4 PERCOBAAN NUMERIK

Pada bagian ini, TNFIS dievaluasi pada empat eksperimen yang berbeda. Kinerja peramalan time-series TNFIS dievaluasi pada sistem nonlinier dan operasi manusia dari pabrik kimia dari kumpulan data Nakanishi [32], dan kumpulan data tungku gas Box-Jenkins [33]. Eksperimen terakhir dilakukan untuk mengevaluasi kinerja klasifikasi TNFIS pada bunga Iris [34].

##### Kumpulan Data Nakanishi

Pada bagian ini, eksperimen untuk mengevaluasi kinerja sistem yang diusulkan dilakukan pada dua set data yang telah dilaporkan oleh pekerjaan yang telah ditetapkan [32,

64, 80]. Kedua kumpulan data ini adalah: sistem nonlinier, dan operasi manusia dari pabrik kimia. Setiap set data1 [32] terdiri dari tiga kelompok pola data: A, B, dan C. Pola data di grup A dan B digunakan sebagai sampel pelatihan dan pola data lainnya di grup C digunakan sebagai sampel uji. Pengaturan ini mirip dengan metode validasi seperti yang dilaporkan dalam [32]. Hasil percobaan ini dikonsolidasikan pada Tabel 3.

#### **Kumpulan Data Nakanishi 1: Sistem Nonlinier**

Sistem nonlinier dijelaskan oleh (13),

$$Y = \left(1 + x_1^{-2} + x_2^{-1.5}\right)^2. \quad (13)$$

Dalam percobaan ini, tujuan kami adalah untuk mengevaluasi efektivitas algoritma pembelajaran struktur kami dalam mengidentifikasi struktur awal untuk TNFIS. Proses yang akan dimodelkan digambarkan dengan pemetaan pada (14),

$$(x_1, x_2) \rightarrow y. \quad (14)$$

Suku-suku linguistik keluaran awal diasumsikan memiliki jarak yang sama dalam rentang operasi keluaran menggunakan tiga fungsi keanggotaan Gaussian. Hal ini ditunjukkan pada Gambar. 4 (e). Mengingat himpunan fuzzy keluaran awal ini, setiap titik data diberi label dengan himpunan fuzzy keluaran tertentu menggunakan prosedur yang dibahas dalam Bagian. 3. Ruang fitur yang dihasilkan dipartisi menjadi sembilan subruang seperti yang ditunjukkan pada Gambar. 5. Titik data milik label kelas yang berbeda (istilah linguistik keluaran) diplot dengan penanda yang berbeda. Garis putus-putus mewakili nilai split yang dipilih. Algoritma partisi ruang data mencoba untuk memisahkan kelas yang berbeda dari titik data ke dalam partisi yang terpisah.

Fungsi keanggotaan fuzzy yang menggambarkan variabel input  $x_1$  dan  $x_2$  masing-masing ditunjukkan pada Gambar 4(a) dan Gambar 4(c). Enam aturan fuzzy dihasilkan dan aturan fuzzy ini ditunjukkan pada Tabel 1. Aturan-aturan ini digunakan untuk menginisialisasi struktur TNFIS. Tahap pembelajaran parameter selanjutnya dilakukan untuk menyempurnakan parameter fungsi keanggotaan fuzzy dan faktor kepastian aturan. Fungsi keanggotaan yang diadaptasi ditunjukkan pada gambar 4(b), 4(d), dan 4(f). Faktor kepastian aturan diadaptasi seperti yang ditunjukkan pada Tabel 1.

**Tabel 4.1** Basis aturan yang dihasilkan dari sampel data pelatihan sistem nonlinier

Aturan n	IF			THEN y	Faktor kepastian	
	$x_1$	$x_2$			Sebelum diadaptasi	Setelah diadaptasi
1	MF1	MF2	MF3	0.94116	0.94985	0.92332 9
2	MF2	MF1	MF3	0.69387	0.80058	15.3786

3	MF2	MF2	MF2	0.83246	0.26509	-68.1558
4	MF2	MF3	MF2	0.55072	0.090266	-83.6095
5	MF3	MF2	MF2	0.78585	0.88877	13.0966
					5	
6	MF3	MF3	MF1	0.87616	0.88092	0.54328

### Kumpulan Data Nakanishi 2: Operasi Manusia di Pabrik Kimia

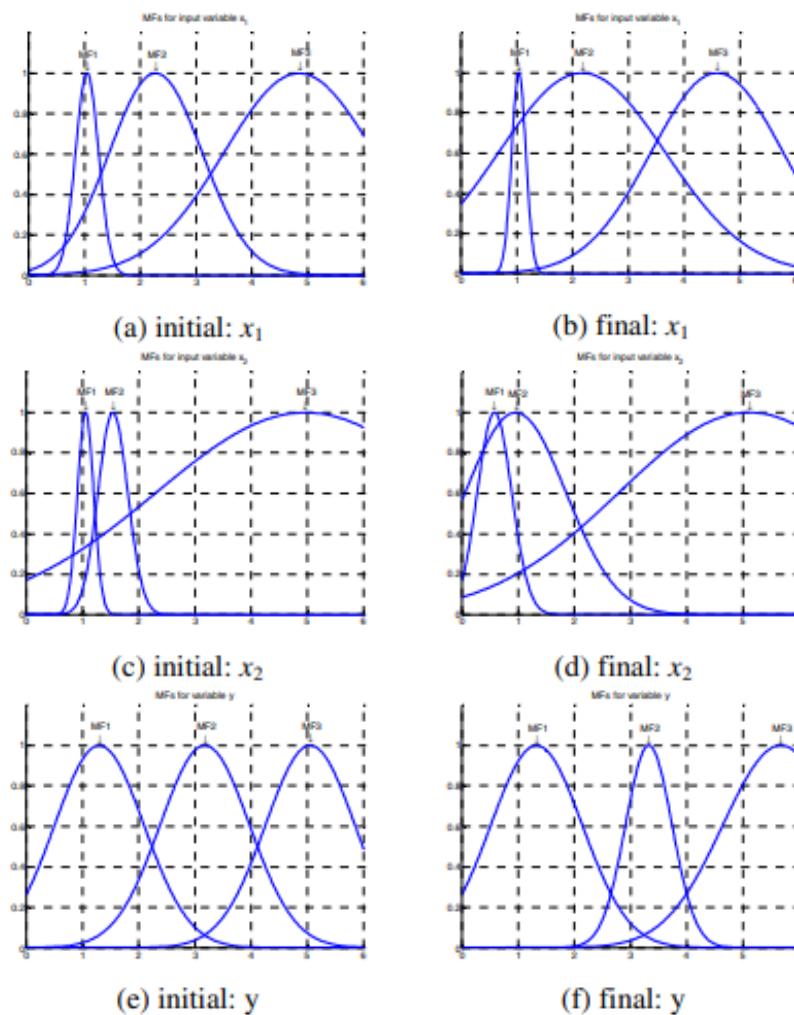
Dalam percobaan ini, kontrol operator dari pabrik kimia diperiksa. Pabrik kimia menghasilkan polimer dengan polimerisasi beberapa monomer. Operator menentukan titik setel untuk laju aliran monomer dan nilai aktual laju aliran monomer untuk pembangkit dikendalikan oleh pengontrol PID. Ada lima variabel input yang dapat dirujuk oleh operator manusia untuk mengontrol laju aliran monomer output. Hanya tiga variabel input yang digunakan dalam contoh ini. Proses tersebut dijelaskan oleh (15),

$$(x_1, x_2, x_3) \rightarrow y. \quad (15)$$

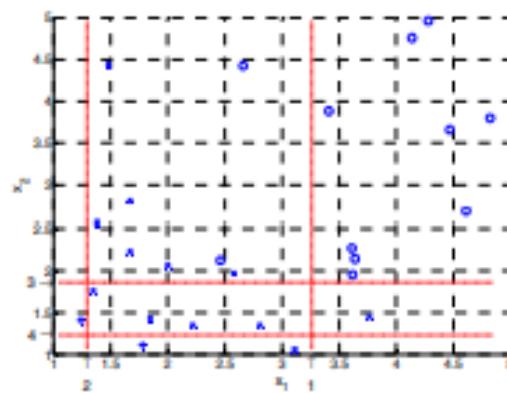
Dalam (15),  $x_1$  mewakili konsentrasi monomer ke tanaman,  $x_2$  mewakili perubahan konsentrasi monomer,  $x_3$  mewakili laju aliran monomer, dan  $y$  titik setel untuk laju aliran monomer. Fungsi keanggotaan awal dan disesuaikan untuk variabel input dan output diilustrasikan pada Gambar. 6. Tabel 2 menggambarkan aturan fuzzy yang dihasilkan untuk menggambarkan model.

**Tabel 4.2** Basis aturan yang dihasilkan dari operasi manusia dari kumpulan data pabrik kimia

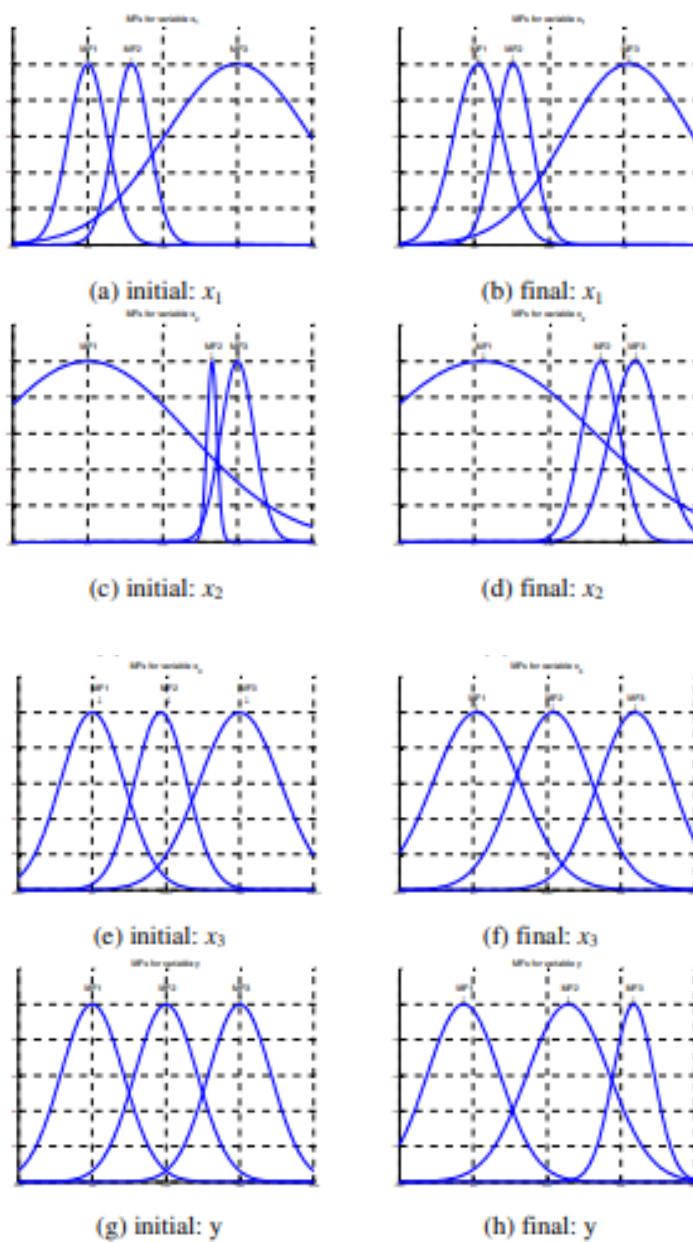
Atura n	IF			THEN	Faktor kepastian		
	$x_1$	$x_2$	$x_3$	$y$	Sebelum diadaptasi	Setelah diadaptasi	$\% \Delta$
1	MF1	MF1	MF2	MF2	0.68802	0.72678	5.63357
2	MF1	MF2	MF3	MF3	0.77484	0.80284	3.613649
3	MF1	MF3	MF3	MF3	0.89837	0.88406	-1.59288
4	MF2	MF1	MF2	MF2	0.82639	0.8263	-0.01089
5	MF2	MF3	MF2	MF2	0.65155	0.65616	0.707544
6	MF2	MF3	MF3	MF3	0.85172	0.85386	0.251256
7	MF3	MF1	MF1	MF1	0.59417	0.59404	-0.02188
8	MF3	MF2	MF1	MF1	0.88095	0.87514	-0.65952
9	MF3	MF2	MF2	MF2	0.88565	0.888667	0.11517
10	MF3	MF3	MF1	MF1	0.88989	0.89594	0.679859
11	MF3	MF3	MF2	MF2	0.88738	0.88215	-0.58938



**Gambar 4.4** Fungsi keanggotaan awal dan yang diadaptasi dari kumpulan data sistem nonlinier



**Gambar 4.5** Fitur partisi ruang dari kumpulan data sistem nonlinier



**Gambar 4.6** Fungsi keanggotaan awal dan yang diadaptasi dari operasi manusia dari kumpulan data pabrik kimia

### Diskusi

Dalam percobaan ini, kedua kumpulan data dapat dilihat sebagai model diam-diam yang diwakili oleh kumpulan nilai atribut terkait yang berkaitan dengan berbagai hasil untuk masalah peramalan deret waktu. Proses eksternalisasi model mengubah model tacit tersebut menjadi model eksplisit dalam bentuk basis pengetahuan aturan fuzzy menggunakan TNFIS yang dapat dengan mudah direpresentasikan dan disimpan dalam sistem manajemen basis data relasional yang khas. Visualisasi model eksplisit seperti plot fungsi keanggotaan dapat digunakan bersama dengan basis pengetahuan untuk meningkatkan pemahaman domain masalah yang mendasarinya.

Dalam contoh pertama, visualisasi model eksplisit seperti Gambar 4 dan Gambar 5, dan basis pengetahuan yang ditunjukkan pada Tabel 1 dapat dimanfaatkan untuk

meningkatkan pemahaman pekerja pengetahuan tentang pengetahuan eksplisit. Dengan menggunakan informasi ini, pekerja pengetahuan dapat menyimpulkan bahwa nilai kecil (mendekati 1) untuk variabel input  $x_1$  atau  $x_2$  dari sistem nonlinier umumnya akan menghasilkan nilai tinggi (lebih dari 4) untuk variabel output  $y$ . Selain itu, faktor kepastian aturan yang ditunjukkan pada Tabel 1 menunjukkan kepentingan relatif aturan dalam basis pengetahuan. Misalnya, aturan 4 memiliki faktor kepastian yang sangat rendah. Dalam kasus ini, seorang pekerja pengetahuan mungkin sepenuhnya mengabaikan pengetahuan itu dalam keputusannya atau mempertimbangkan nilai input yang dijelaskan oleh aturan 4 memiliki nilai output yang lebih mungkin dijelaskan oleh fungsi keanggotaan output MF1 karena contoh ini adalah masalah peramalan deret waktu. Sebagai alternatif, pekerja pengetahuan dapat menggunakan visualisasi dan basis pengetahuan untuk mengidentifikasi wilayah di ruang input yang tidak cukup terwakili dalam model yang ada, dan untuk melengkapi contoh data yang sesuai.

Dalam contoh kedua, pembuat keputusan mungkin menemukan korelasi yang tinggi antara variabel input  $x_3$  dan variabel output  $y$ . Kedua variabel dijelaskan oleh tiga fungsi keanggotaan, dan basis pengetahuan yang ditemukan menggunakan model yang dirumuskan oleh TNFIS seperti yang ditunjukkan pada Tabel 2 menunjukkan hal itu. Dalam contoh ini, manusia mungkin hanya mengandalkan laju aliran monomer  $x_3$  untuk mengontrol tanaman untuk mencapai laju aliran monomer  $y$  yang diinginkan. Contoh ini mengilustrasikan bahwa basis pengetahuan dan plot visualisasi dari fungsi keanggotaan dapat digunakan untuk menyederhanakan pengoperasian sistem tersebut dan memvalidasi pengoperasian operator manusia. Oleh karena itu, basis pengetahuan untuk contoh ini dapat diminimalkan menjadi hanya tiga aturan menggunakan tiga fungsi keanggotaan untuk menggambarkan variabel input  $x_3$  dan variabel output  $y$ . Model linguistik yang tergabung dalam model neuro-fuzzy menyediakan kemampuan untuk menginternalisasi model eksplisit yang tidak mudah dipahami sebagai vektor bobot dalam jaringan saraf.

Alih-alih menganalisis kemungkinan sejumlah besar model diam-diam (contoh keputusan) dari basis data, dua contoh ini menggambarkan bahwa model eksplisit dapat dibagikan di antara pembuat keputusan lain yang memungkinkan pembuat keputusan lain dengan mudah menginternalisasi hubungan baru yang ditemukan antara faktor-faktor kunci. Selain manfaat TNFIS sebagai sistem neuro-fuzzy untuk menyediakan basis pengetahuan yang dapat dipahami untuk penjelasan solusi, TNFIS mampu merumuskan model dengan tingkat akurasi generalisasi yang tinggi. Tabel 3 menunjukkan kinerja generalisasi dari beberapa model neuro-fuzzy dalam hal hasil Mean Squared Error (MSE) pada contoh data yang tidak terlihat untuk dua set data di atas. TNFIS mengungguli semua metodologi perumusan model lainnya. Hal ini dapat dilihat pada Tabel 3 dimana TNFIS mampu mencapai peningkatan sekitar 5,5 kali lipat dari model terbaik (POP-CRI) pada data set 1, dan peningkatan sekitar 8 kali lipat dari model terbaik (DENFIS) pada data set 2.

**Tabel 4.3** Hasil Eksperimen pada Kumpulan Data Nakanishi

Model	Tetapkan 1 (Sistem Nonlinier)	Tetapkan 2 (Tanaman kimia)
-------	----------------------------------	-------------------------------

POP-CRIA	0.270	$5.630 \times 10^5$
RSPOP-CRIA	0.383	$2.124 \times 10^5$
Sugeno (P-G)a	0.467	$1.931 \times 10^6$
Mamania	0.862	$6.580 \times 10^5$
Turksen (IVCRI)a	0.706	$2.581 \times 10^5$
ANFISa	0.286	$2.968 \times 10^6$
EFuNNa	0.566	$7.247 \times 10^5$
DENFISa	0.411	$5.240 \times 10^4$
<b>TNFIS</b>	<b>0.051</b>	<b><math>6.8506 \times 10^3</math></b>

### Kotak dan Tungku Gas Jenkins

Kemampuan TNFIS dalam identifikasi sistem diperiksa dengan menggunakan data tungku gas yang terkenal dan digunakan secara luas [33]. Kumpulan data ini berasal dari proses pembakaran campuran metana-udara. Selama proses, jumlah metana diatur sambil menjaga laju aliran gas ke dalam tungku gas konstan. Konsentrasi CO<sub>2</sub> yang dihasilkan kemudian diukur dari gas-gas yang keluar dari tungku. Data terdiri dari 296 pengamatan berturut-turut yang diambil sampelnya pada interval 9 detik. Setiap pengamatan mencatat laju umpan gas metana dalam kaki kubik per menit dan persentase CO<sub>2</sub> yang sesuai dalam gas keluar. Proses yang akan dimodelkan dijelaskan oleh (16),

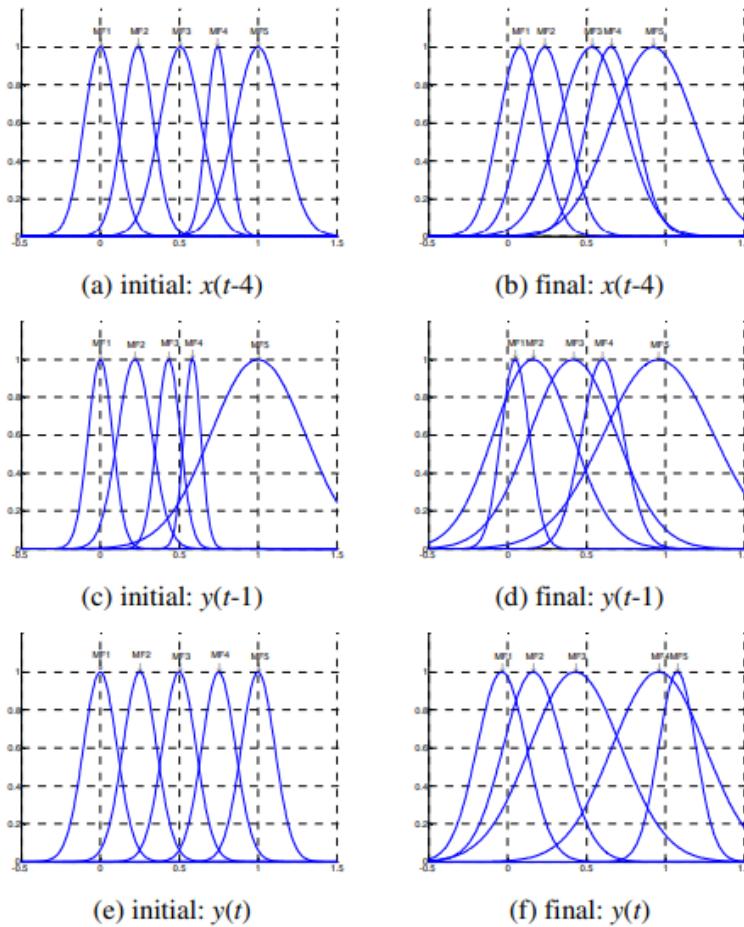
$$(x(t - \tau_1), y(t - \tau_2)) \rightarrow y(t) \quad (16)$$

Dalam (16), x(t) mewakili laju aliran gas terukur ke dalam tungku, y(t) adalah konsentrasi CO<sub>2</sub> dalam gas keluar, dan 1 dan 2 masing-masing diatur ke 4 dan 1. Dalam percobaan ini, 292 pengamatan dari kumpulan data asli dengan data input yang berisi laju aliran metana pada waktu t-4 dan CO<sub>2</sub> yang dihasilkan pada waktu t-1, dan data keluaran yang berisi CO<sub>2</sub> yang dihasilkan pada waktu t. Tugas TNFIS adalah mengidentifikasi model komputasi lunak untuk keluaran saat ini konsentrasi CO<sub>2</sub> y(t) dengan jumlah gas metana empat langkah waktu sebelumnya (x(t-4)) dan konsentrasi CO<sub>2</sub> sebelumnya (y(t -1)).

Aturan fuzzy dihasilkan berdasarkan 200 sampel pelatihan yang dipilih secara acak dari 292 pasangan data. Fungsi keanggotaan awal ditunjukkan pada gambar 7(a), 7(c), 7(e). Basis aturan yang dihasilkan oleh fase pembelajaran struktur TNFIS ditunjukkan pada Tabel 4. Fungsi keanggotaan yang dihasilkan ditunjukkan pada gambar 7(b), 7(d), dan 7(f). Faktor kepastian aturan diadaptasi seperti yang ditunjukkan pada Tabel 4.

Gambar 8 mengilustrasikan pengaruh faktor kepastian aturan pada kekuatan tembak dan daerah keputusan dari aturan fuzzy. Gambar 8(a) dan Gambar 8(b) masing-masing menggambarkan pengaruh faktor kepastian aturan pada kekuatan tembak dan daerah keputusan dari aturan fuzzy. Gambar 8(c) dan 8(d) menggambarkan pengaruh aturan fuzzy yang sama tanpa penggabungan kepastian aturan, yaitu dengan bobot yang sama, pada kekuatan penembakan aturan dan daerah keputusan masing-masing. Penomoran pada Gambar 8 mewakili indeks dari fungsi keanggotaan konsekuensi. Gambar 8(b) dan 8(d)

menggambarkan daerah dalam ruang data input yang terkait dengan konsekuensi (tindakan) yang berbeda. Konsekuensi ini diwakili oleh warna yang berbeda. Untuk subruang data input yang dijelaskan oleh semua kemungkinan aturan fuzzy dengan bobot yang sama, batas keputusan antara aturan ini selalu sejajar dengan sumbu fitur (lihat Gambar 8(d)). Hal ini berbeda dengan area yang sama dalam ruang data seperti yang ditunjukkan pada Gambar 8(b) yang menggambarkan bahwa batas keputusan antara aturan fuzzy yang sama ini memiliki faktor kepastian yang berbeda. Penggunaan faktor kepastian aturan memoderasi kekakuan dalam partisi ruang data berbasis grid fuzzy.

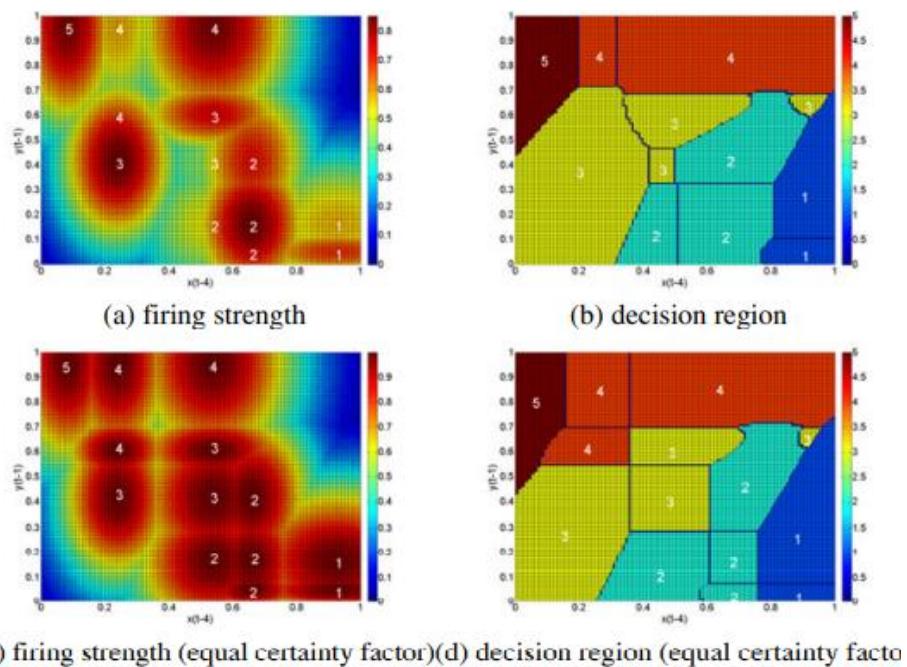


**Gambar 4.7** Fungsi keanggotaan awal dan adaptasi model tungku gas Box-Jenkins

**Tabel 4.4** Basis aturan yang dihasilkan dari 200 sampel data tungku gas Box-Jenkins yang dipilih secara acak

Atura n	IF		THEN	Faktor kepastian		
	$x_1$	$x_2$	$y$	Sebelum diadaptasi	Setelah diadaptasi	$\% \Delta$
1	MF1	MF5	MF5	0.83685	0.83577	-0.12906
2	MF2	MF3	MF3	0.67772	0.85225	25.75252
3	MF2	MF4	MF4	0.65478	0.58409	-10.796
4	MF2	MF5	MF4	0.77279	0.58762	-23.9612
5	MF3	MF2	MF2	0.68344	0.53656	-21.4913

6	MF3	MF3	MF3	0.73009	0.4482	-38.6103
7	MF3	MF4	MF3	0.79787	0.75567	-5.28908
8	MF3	MF5	MF4	0.69092	0.83774	21.24993
9	MF4	MF1	MF2	0.62053	0.62808	1.216702
10	MF4	MF2	MF2	0.824	0.84503	2.552184
11	MF4	MF3	MF2	0.69985	0.72945	4.229478
12	MF5	MF1	MF1	0.69755	0.69834	0.113254
13	MF5	MF2	MF1	0.58219	0.5753	-1.18346



**Gambar 4.8** Kekuatan pembakaran dan wilayah keputusan aturan untuk model tungku gas (angka mewakili indeks MF konsekuensi)

Selain itu, Gambar 8 memberikan wawasan tentang pengoperasian tungku gas. Laju umpan metana umumnya memiliki efek negatif pada konsentrasi CO<sup>2</sup> di masa depan. Basis pengetahuan eksplisit yang disimpan dalam bentuk aturan fuzzy juga dapat dimanfaatkan untuk menyimpulkan temuan ini. Oleh karena itu, pengoperasian tungku gas ini dapat disederhanakan dengan hanya mempertimbangkan laju aliran gas metana untuk mengontrol konsentrasi CO<sup>2</sup>.

Tabel 5 mencantumkan hasil komparatif dari berbagai pendekatan pemodelan yang dilakukan pada data tungku gas Box-Jenkins. Hasil yang lebih komparatif dapat ditemukan di [81, 82]. TNFIS secara efektif memodelkan proses nonlinier dengan kemampuan generalisasi yang baik dibandingkan dengan model lain. TNFIS memiliki peningkatan sekitar 3 kali lipat dalam hal MSE lebih baik daripada model Pedrycz dan sebanding dengan ANFIS [83] yang merupakan model fuzzy TSK [84]. Model terbaik (Chebyshev NN) mencapai peningkatan hampir 2 kali lipat dalam hal MSE lebih baik daripada TNFIS. Namun Chebyshev NN menggunakan 6 variabel input dan setiap variabel input diperluas menjadi dua suku polinomial Chebyshev. Selain itu, Chebyshev NN tidak menghasilkan model linguistik.

**Tabel 4.5** Kinerja metode pemodelan yang berbeda pada data tungku gas Box-Jenkins

Model	Training cases	No. of inputs	No. of Rules (parameters)	MSE on normalized data ( $\times 10^{-3}$ )	MSE on unnormalized data
Nie's model [85]	unknown	4 ( $y(t-1)$ , $x(t-3)$ , $x(t-4)$ , $x(t-5)$ )	45 (225)		0.169
Pedrycy's model [86]	unknown	18	77 (152)		0.3950 <sup>a</sup>
ANFIS [87]	145	2 ( $x(t-4)$ , $y(t-1)$ )	4 (24)	0.653 <sup>b</sup>	
	145	2 ( $x(t-4)$ , $y(t-1)$ )	25 (105)	0.814 <sup>b</sup>	
	200 random	2 ( $x(t-4)$ , $y(t-1)$ )	4 (24)	0.567 <sup>b</sup>	
	200 random	2 ( $x(t-4)$ , $y(t-1)$ )	25 (105)	0.525 <sup>b</sup>	
HyFIS [88]	200 random	2 ( $x(t-4)$ , $y(t-1)$ )	13 (95)	1.5	
	200 random + 92	2 ( $x(t-4)$ , $y(t-1)$ )	15 (105)	0.42	
Multi-FNN [89]	296	2 ( $x(t-3)$ , $y(t-1)$ )			0.028 <sup>c</sup> , 0.265 <sup>d</sup>
Chebyshev NN [90]	296	6	- (12)		0.0695
TNFIS	200 random	2 ( $x(t-4)$ , $y(t-1)$ )	13 (43)	0.575 0.494 <sup>c</sup> , 0.753 <sup>d</sup>	0.1277 0.109 <sup>c</sup> , 0.167 <sup>d</sup>

<sup>a</sup> MSE is stated as  $\frac{1}{2} \sum_{k=1}^N (y_k - d_k)^2$  in [86]

<sup>b</sup> Best result obtained based on program file bjtrain.m provided in [87]

<sup>c</sup> MSE on training data

<sup>d</sup> MSE on test data

### Klasifikasi Iris

Pada bagian ini akan dibahas kemampuan belajar dan kemampuan generalisasi TNFIS dalam klasifikasi masalah. Untuk percobaan ini, set data Iris [34] dari repositori UCI database pembelajaran mesin digunakan. Soal tersebut memerlukan klasifikasi tiga spesies bunga iris, yaitu Iris Setosa, Iris Versicolor, dan Iris Virginica.

#### Kemampuan Belajar untuk Pola Pelatihan

Kemampuan belajar TNFIS diperiksa dengan mengevaluasi akurasi resubstitusi TNFIS pada kumpulan data iris. Dalam percobaan ini, semua 150 pola data iris digunakan sebagai sampel pelatihan. Setelah pelatihan, pola yang sama digunakan sebagai pola pengujian untuk mengevaluasi akurasi resubstitusi jaringan yang dilatih.

Tabel 6 menunjukkan akurasi resubstitusi dari beberapa model yang dievaluasi pada data iris. Nilai K untuk TNFIS pada Tabel 6 menunjukkan jumlah himpunan fuzzy maksimum untuk setiap sumbu fitur, sedangkan nilai K untuk model lain menunjukkan jumlah himpunan fuzzy untuk setiap sumbu fitur. Tabel 6 menggambarkan bahwa kemampuan belajar TNFIS secara umum lebih baik daripada metode lainnya untuk semua nilai K kecuali K=3. Hasil pada Tabel 6 juga menunjukkan bahwa jumlah aturan yang dihasilkan oleh TNFIS secara signifikan jauh lebih sedikit daripada semua model lainnya.

**Tabel 4.6** Kemampuan Belajar Pola Latihan Iris

Model	K = 2		K = 3		K = 4		K = 5		K = 6	
	R <sub>acc</sub> (%Δ <sub>acc</sub> )	N <sub>r</sub> (%)								
Adaptive <sup>a</sup>	94.00 (0)	16 (0)	100.00 (0)	62 (0)	100.00 (0)	129 (0)	100.00 (0)	190 (0)	100.00 (0)	295 (0)
Simple-fuzzy-grid <sup>a</sup>	67.33 (-28.37)	16 (0)	94.00 (-6)	62 (0)	92.67 (-7.33)	129 (0)	96.00 (-4)	190 (0)	98.67 (-1.33)	295 (0)
TNFIS	96.67 (+2.84)	9 (-43.75)	98.00 (-2)	21 (-66.13)	100.00 (0)	45 (-65.12)	100.00 (0)	67 (-64.74)	100.00 (0)	76 (-74.24)

R<sub>acc</sub> : Akurasi substitusi dalam hal persentase

$\% \Delta_{acc}$  : Persentase peningkatan di atas akurasi resubstitusi maksimum yang diperoleh model lain

$N_r$  : Jumlah aturan

$\%_r$  : Persentase jumlah aturan maksimum yang diperlukan oleh model lain

<sup>a</sup> Hasil diadaptasi dari [91]

### Kemampuan Generalisasi untuk Pola Pengujian Iris

Dalam percobaan ini, kemampuan generalisasi TNFIS dievaluasi dengan menggunakan metode validasi yang sama seperti yang dilakukan pada [91]. Kedua metode tersebut adalah, validasi silang dua kali lipat (dilambangkan sebagai 2CV), dan leave-one-out (dilambangkan sebagai LV1).

Untuk 2CV, data iris secara acak dibagi menjadi dua subset, dengan masing-masing subset berisi 75 pola. Setiap kali, salah satu himpunan bagian digunakan untuk pelatihan dan yang lainnya untuk pengujian. Kami mengulangi 2CV selama sepuluh kali. Tabel 7 menggambarkan bahwa TNFIS memiliki kinerja klasifikasi yang unggul dibandingkan model lainnya. TNFIS mampu secara konstan mengklasifikasikan bunga iris dengan tingkat akurasi klasifikasi yang tinggi sekitar 95%. Tabel 7 juga menggambarkan bahwa ada peningkatan yang lebih besar dalam kinerja klasifikasi untuk TNFIS pada nilai K yang rendah. Sebagai contoh, TNFIS mampu mengklasifikasikan pola data sekitar 3,8% lebih banyak daripada metode terbaik pada  $K = 2$  dan 0,29% lebih banyak pada  $K = 6$ . Hal ini terutama disebabkan oleh fakta bahwa pengotor lebih mungkin dimasukkan ke dalam partisi fuzzy yang kasar. Di sisi lain, ruang data input dipartisi oleh algoritma pembelajaran struktur TNFIS untuk meminimalkan kesalahan klasifikasi lunak. Ini menjelaskan kinerja klasifikasi TNFIS yang lebih besar untuk nilai K yang rendah. Untuk nilai K yang lebih tinggi, partisi fuzzy menjadi lebih halus. Kemungkinan memasukkan pola data yang berbeda milik label kelas lain lebih kecil, sehingga ini menjelaskan kinerja klasifikasi serupa yang dicapai oleh berbagai metode ketika partisi fuzzy menjadi lebih halus.

Tabel 8 menunjukkan informasi lebih lanjut tentang model iris yang dibuat dengan metode kami. Nilai rata-rata yang tinggi dari akurasi klasifikasi menunjukkan persentase yang tinggi dari klasifikasi yang benar pada semua 20 model iris. Nilai standar deviasi yang kecil dari akurasi klasifikasi menunjukkan toleransi yang lebih baik terhadap variasi data. Tabel 8 juga menunjukkan jumlah aturan yang diperlukan untuk memodelkan data iris untuk berbagai nilai K.

**Tabel 4.7** Kemampuan Generalisasi untuk Pola Pengujian Iris ( $10 \times 2CV$ )

Model	$K = 2$	$K = 3$	$K = 4$	$K = 5$	$K = 6$
	$C_{acc}$ ( $\% \Delta_{acc}$ )				
Adaptive <sup>a</sup>	91.73 (0)	94.80 (0)	94.53 (0)	94.80 (-0.493)	95.37 (-0.209)
Simple-fuzzy-grid <sup>a</sup>	69.27 (-24.485)	92.43 (-2.5)	90.03 (-4.76)	95.27 (0)	95.57 (0)
TNFIS	95.267 (+3.855)	95.867 (+1.125)	95.867 (+1.414)	95.933 (+0.696)	95.867 (+0.311)

$C_{acc}$  : Akurasi klasifikasi

$\% \Delta acc$  : Persentase peningkatan akurasi klasifikasi maksimum yang diperoleh model lain

<sup>a</sup> Hasil diadaptasi dari [91]

**Tabel 4.8** Kemampuan Generalisasi TNFIS untuk Pola Pengujian Iris ( $10 \times 2CV$ )

TNFIS	K = 2	K = 3	K = 4	K = 5	K = 6
Akurasi minimum	90.667	92	93.33	95.2	93.33
Akurasi maksimum	100.00	98.667	98.667	98.667	98.667
Akurasi rata-rata	95.267	95.867	95.867	95.933	95.867
Standar deviasi akurasi	2.0047	1.977	1.4923	1.588	1.4923
Jumlah minimum aturan	6	16	21	29	37
Jumlah maksimum aturan	10	26	39	42	45
Rata-rata jumlah aturan	8.5	20.25	29.5	36.5	41
Standar deviasi dari jumlah aturan	1.0513	3.567	4.9364	3.5318	2.5752

Untuk LV1, satu sampel iris dipilih sebagai pola uji, dan 149 sampel iris lainnya digunakan sebagai pola pelatihan untuk melatih jaringan. Prosedur diulang sebanyak 150 kali, setiap kali dengan memilih sampel baru sebagai pola uji. Sebanyak 150 model iris dibuat dan kami menghitung akurasi klasifikasi rata-rata dari model ini. Tabel 9 menunjukkan akurasi klasifikasi rata-rata dari berbagai metode di bawah metode validasi LV1. TNFIS mampu mencapai akurasi klasifikasi yang lebih tinggi daripada metode lain untuk semua nilai K. Tabel 10 menunjukkan informasi lebih lanjut tentang 150 model iris yang dihasilkan oleh metode kami. Standar deviasi akurasi klasifikasi seperti yang ditunjukkan pada tabel 10 lebih tinggi dari pada Tabel 8 disebabkan oleh fakta bahwa hanya satu sampel yang digunakan sebagai pola pengujian, dan bahwa sampel tersebut diklasifikasikan dengan benar atau tidak.

Terlihat juga pada tabel 10 bahwa variasi jumlah aturan yang dihasilkan umumnya menjadi lebih besar ketika nilai K meningkat. Variasi yang lebih besar dari jumlah aturan yang dihasilkan dapat dilihat sebagai variasi yang lebih besar dalam hal kompleksitas model. Meskipun terdapat variasi yang lebih tinggi dalam kompleksitas model, penggabungan metode fuzzy ke dalam sistem membantu mengurangi variasi dalam akurasi klasifikasi. Hal ini dapat dilihat pada tabel 10 bahwa kinerja yang konsisten dalam akurasi klasifikasi dapat dicapai oleh TNFIS dengan variasi jumlah aturan yang umumnya meningkat dari K = 2 menjadi 6.

**Tabel 4.9** Kemampuan Generalisasi untuk Pola Pengujian Iris (LV1)

Model	K = 2	K = 3	K = 4	K = 5	K = 6
	$C_{acc}$	$C_{acc}$	$C_{acc}$	$C_{acc}$	$C_{acc}$
	( $\% \Delta acc$ )				
	)	)	)	)	)
adaptif	92.00	95.33	98.00	94.67	96.67
	(0)	(0)	(0)	(-0.692)	(0)

Sederhana-kabur-grida	67.33 (-26.815)	93.33 (-2.098)	89.33 (-8.847)	95.33 (0)	96.67 (0)
TNFIS	98.667 (+7.247)	98.667 (+3.5)	98.667 (+0.681)	96.667 (+1.402)	97.33 (+0.683)

$C_{acc}$  : Akurasi klasifikasi

$\% \Delta_{acc}$  : Persentase peningkatan akurasi klasifikasi maksimum yang diperoleh model lain

<sup>a</sup> Diadaptasi dari [91]

**Tabel 4.10** Kemampuan Generalisasi TNFIS untuk Pola Pengujian Iris (LV1)

TNFIS	K = 2	K = 3	K = 4	K = 5	K = 6
Akurasi minimum	0	0	0	0	0
Akurasi maksimum	100	100	100	100	100
Akurasi rata-rata	98.667	98.667	98.667	96.667	97.33
Standar deviasi akurasi	11.508	11.508	11.508	18.011	16.165
Jumlah minimum aturan	9	20	42	55	60
Jumlah maksimum aturan	9	30	51	70	77
Rata-rata jumlah aturan	9	21.613	45.147	66.12	74.813
Standar deviasi dari jumlah aturan	0	1.69	1.5474	2.593	2.6276

#### 4.5 KESIMPULAN

Dalam makalah ini, efektivitas sistem neuro-fuzzy yang disebut Sistem Inferensi Fuzzy Saraf Berbasis Pohon (TNFIS) diselidiki dalam perumusan model peramalan deret waktu, identifikasi sistem, dan masalah klasifikasi. Algoritma pembelajaran menyajikan pendekatan baru untuk memecahkan eksternalisasi model dengan mempertimbangkan sifat penilaian pembuat keputusan yang tidak tepat pada model diam-diam yang berbeda (contoh keputusan). Pengetahuan dalam bentuk aturan fuzzy dibuat menggunakan algoritma pembelajaran struktur baru yang terinspirasi dari penekanan konstruktivis Piaget pada pengembangan kognitif berbasis tindakan; tindakan motorik daripada input sensorik menentukan bentuk jaringan [30]. Hasil percobaan menunjukkan bahwa TNFIS sebanding jika tidak lebih unggul dari model neuro-fuzzy lainnya. Kemampuan generalisasi yang baik dari TNFIS diyakini telah diturunkan dari atribut berikut:

- Pemanfaatan faktor kepastian aturan memoderasi kekakuan partisi ruang data berbasis grid fuzzy.
- Algoritma pembelajaran struktur TNFIS didasarkan pada pandangan kognitif Piaget tentang perkembangan kognitif yang digerakkan oleh tindakan pada manusia menghasilkan aturan fuzzy yang memberikan korelasi yang lebih baik antara subruang input dan output lokal yang terkait.

Bagian konsekuensi dari aturan lebih baik ditentukan secara akurat dari sub-ruang input yang berisi pola data yang lebih mirip satu sama lain.

Hasil eksperimen menunjukkan bahwa TNFIS mampu merepresentasikan model eksplisit yang dirumuskan dengan menggunakan sekumpulan basis pengetahuan aturan fuzzy

yang ringkas dan intuitif. Basis pengetahuan ini dapat dengan mudah disimpan dalam basis pengetahuan menggunakan sistem manajemen basis data relasional diri yang khas. Visualisasi model yang dirumuskan dalam bentuk plot keanggotaan, dan kekuatan penembakan aturan model dan plot batas keputusan juga ditunjukkan untuk meningkatkan pemahaman pembuat keputusan tentang domain masalah dan internalisasi selanjutnya dari model yang dipilih. Basis pengetahuan dapat dibagikan dan divisualisasikan untuk membantu pembuat keputusan lain memahami pola keputusan saat ini dan menganalisis perubahan pola tersebut dalam jangka waktu yang lama. Misalnya, organisasi dapat menggunakan basis pengetahuan dan visualisasi tersebut untuk validasi keputusan, peramalan penjualan masa depan, atau pelatihan staf baru.

Studi ini membuka beberapa jalan untuk penelitian masa depan. Pertama, teknik visualisasi untuk model neuro-fuzzy yang diusulkan dalam makalah ini dapat diperluas ke teknik penambangan data lainnya. Kedua, model eksplisit yang dirumuskan dalam makalah ini hanya mempertimbangkan pengambilan keputusan individu. Kombinasi aturan keputusan pembuat keputusan individu adalah perpanjangan yang mungkin. Menggunakan pendekatan berbagai perspektif akan membantu dalam menemukan area di mana alat dapat dikembangkan untuk mengubah wawasan kualitatif dan data yang tidak tepat menjadi pengetahuan yang berguna. Hal ini memungkinkan individu untuk membuat keputusan yang lebih terinformasi dan kolaboratif yang akan mencapai tujuan organisasi secara lebih efektif. Ketiga, visualisasi dari model eksplisit gabungan harus dipertimbangkan. Alat tersebut akan memberikan wawasan berharga ke dalam penilaian pengambilan keputusan umum pada model diam-diam yang berbeda.

Penelitian ini memiliki implikasi yang signifikan bagi bidang DSS dalam memberikan dukungan. Implikasi utama adalah bahwa proses penciptaan pengetahuan melibatkan orang-orang, dan perumusan model keputusan harus mempertimbangkan subjektivitas penilaian pembuat keputusan. Pendekatan yang mengakomodasi keterlibatan manusia dalam proses pengambilan keputusan dapat secara positif mempengaruhi penerimaan DSS terkomputerisasi sebagai alat pengambilan keputusan strategis.

## BAB 5

### AGEN KOMPUTASI DALAM SISTEM PENDUKUNG KEPUTUSAN KOMPLEKS

Bab ini memperkenalkan pendekatan umum untuk pengambilan keputusan dalam sistem dan arsitektur yang kompleks untuk sistem pendukung keputusan berbasis agen (DSS). Pendekatan ini berkontribusi pada desentralisasi dan pengambilan keputusan lokal dalam alur kerja standar. Arsitektur mewujudkan logika keputusan mengembangkan alur kerja dan hampir diatur sebagai struktur berlapis, di mana setiap tingkat berorientasi untuk memecahkan salah satu dari tiga tujuan berikut: pengambilan data, fusi dan pra-pemrosesan; penggalian dan evaluasi data; dan, pengambilan keputusan, peringatan, solusi dan pembuatan prediksi. Untuk menguji pendekatan kami, kami telah merancang dan mengimplementasikan DSS berbasis agen, yang menangani masalah lingkungan. Sistem menghitung dampak yang ditimbulkan oleh polutan pada morbiditas, membuat model dan membuat prakiraan dengan mengizinkan untuk mencoba kemungkinan cara perubahan situasi. Kami membahas beberapa teknik data mining yang digunakan, yaitu metode dan alat untuk klasifikasi, aproksimasi fungsi, pencarian asosiasi, analisis perbedaan, dan lain-lain. Selain itu, untuk menghasilkan serangkaian solusi administratif, kami mengembangkan alur kerja pembuatan keputusan dan seleksi, yang dibentuk dan kemudian dipilih sesuai dengan kemungkinan efek positif maksimum dan dievaluasi oleh kriteria eksternal dan internal. Sebagai kesimpulan, kami menunjukkan bahwa sistem kami menyediakan semua langkah yang diperlukan untuk prosedur pengambilan keputusan standar dengan menggunakan agen komputasi. Kami menggunakan begitu banyak teknik penambangan data tradisional, serta metode hibrida lainnya, sehubungan dengan sifat data. Kombinasi alat yang berbeda memungkinkan mendapatkan kualitas dan ketepatan model yang dicapai, dan, karenanya, dalam rekomendasi yang didasarkan pada model ini. Dependensi yang diterima dari interkoneksi dan asosiasi antara faktor dan variabel dependen membantu mengoreksi rekomendasi dan menghindari kesalahan.

#### **5.1 PENDAHULUAN**

Penggunaan sistem pendukung keputusan cerdas berbasis agen (IDSS) penting untuk masalah terkait lingkungan, karena memungkinkan spesialis mengumpulkan informasi dengan cepat dan memprosesnya dengan berbagai cara untuk memahami sifat sebenarnya dari proses, pengaruhnya terhadap manusia, kesehatan, dan kemungkinan hasil untuk membuat tindakan pencegahan dan mengambil keputusan yang benar. Area yang dapat dibantu oleh sistem ini beragam, mulai dari penyimpanan dan pengambilan catatan yang diperlukan, penyimpanan dan pengambilan faktor kunci, pemeriksaan data waktu nyata yang dikumpulkan dari monitor, analisis kecenderungan proses lingkungan, deret waktu retrospektif, membuat peramalan jangka pendek dan jangka panjang, dan dalam banyak kasus lainnya [1-3].

Saat ini, di bidang sistem berbasis agen ada banyak aplikasi sistem pendukung keputusan (DSS) untuk masalah sosial dan ekologi secara umum, dan untuk dampak lingkungan pada masalah penilaian kesehatan manusia pada khususnya [4]. Untuk memahami *Sistem Pendukung Keputusan (Dr Joseph Teguh Santoso dan Budi Hartono, M.Kom)*

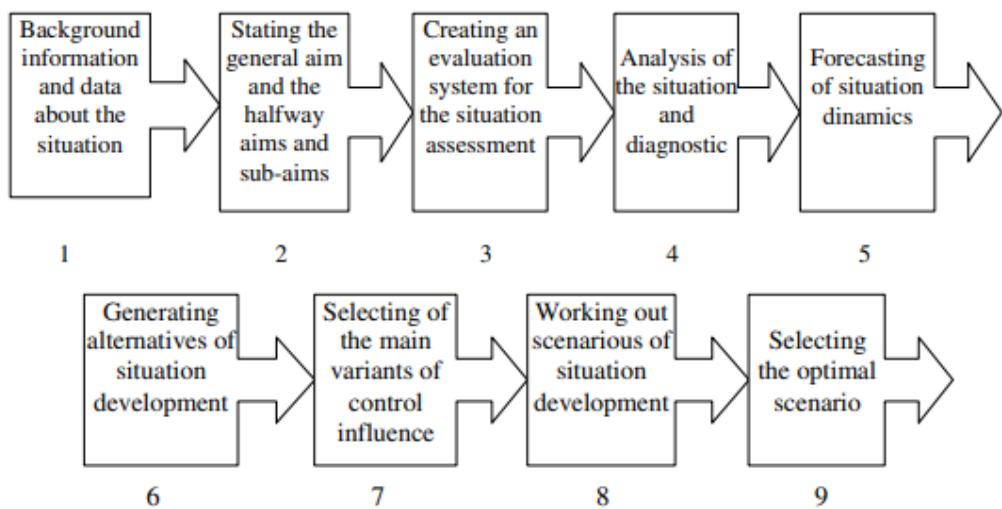
tren saat ini dan untuk menilai kemampuan penelitian pendukung keputusan cerdas berbasis agen saat ini, tampaknya masuk akal untuk mensurvei keadaan seni saat ini dan menyimpulkan bagaimana mungkin untuk mengoptimalkannya.

## 5.2 SISTEM PENDUKUNG KEPUTUSAN UNTUK STUDI SISTEM KOMPLEKS

Sebagian besar masalah kehidupan nyata yang terkait dengan pembangunan berkelanjutan dan lingkungan dapat diklasifikasikan sebagai masalah komposit yang kompleks, dan, sebagai akibatnya, mereka memiliki beberapa karakteristik khusus, karena itu, mereka memerlukan pendekatan interdisipliner untuk studi mereka. Sebuah sistem adalah integrasi yang saling berhubungan (melalui informasi, fisik, mekanik, pertukaran energi, dll) bagian dan komponen, yang menghasilkan munculnya sifat-sifat baru, dan yang berinteraksi dengan lingkungan sebagai satu kesatuan. Jika ada bagian yang diekstraksi dari sistem, ia kehilangan karakteristik khususnya, dan berubah menjadi susunan komponen atau rakitan. Pendekatan yang efektif untuk studi sistem yang kompleks harus mengikuti prinsip-prinsip analisis sistem, yaitu:

- Deskripsi sistem. Identifikasi sifat dan parameter utamanya.
- Studi interkoneksi antara bagian-bagian dari sistem, yang meliputi informasi, fisik, dinamis, interaksi temporal, serta fungsionalitas bagian-bagian dalam sistem.
- Studi interaksi sistem dengan lingkungan, dengan kata lain, dengan sistem lain, alam, dll.
- Dekomposisi dan partisi sistem. Dekomposisi mengandaikan ekstraksi rangkaian bagian sistem, dan partisi menyarankan ekstraksi bagian sistem paralel. Metode-metode ini dapat didasarkan pada analisis klaster (proses berulang dari integrasi elemen sistem ke dalam kelompok) atau analisis konten (pembagian sistem menjadi bagian-bagian, berdasarkan partisi fisik atau analisis fungsi).
- Mempelajari setiap subsistem atau bagian sistem, memanfaatkan alat yang sesuai secara optimal (pendekatan multidisiplin, metode pemecahan masalah, saran ahli, alat penemuan pengetahuan, dll.)
- Integrasi hasil yang diterima pada tahap sebelumnya, dan memperoleh pengetahuan yang menyatu tentang sistem. Sintesis pengetahuan dan komposisi dari keseluruhan model sistem dapat mencakup metode formal untuk desain, metode optimasi multi-kriteria, desain berbasis keputusan dan hierarkis, pendekatan kecerdasan buatan, penalaran berbasis kasus, dan lain-lain, misalnya hybrid. metode.

Jelas, bahwa struktur DSS harus memenuhi persyaratan, yang ditetapkan oleh spesialis, dan karakteristik serta batasan dari domain aplikasi. Pada Gambar 1 terdapat alur kerja umum dari proses pengambilan keputusan, yang diwujudkan dalam DSS. Alur kerja “pengambilan keputusan” tradisional mencakup periode persiapan, pengembangan keputusan dan, akhirnya, pengambilan keputusan itu sendiri dan realisasinya.

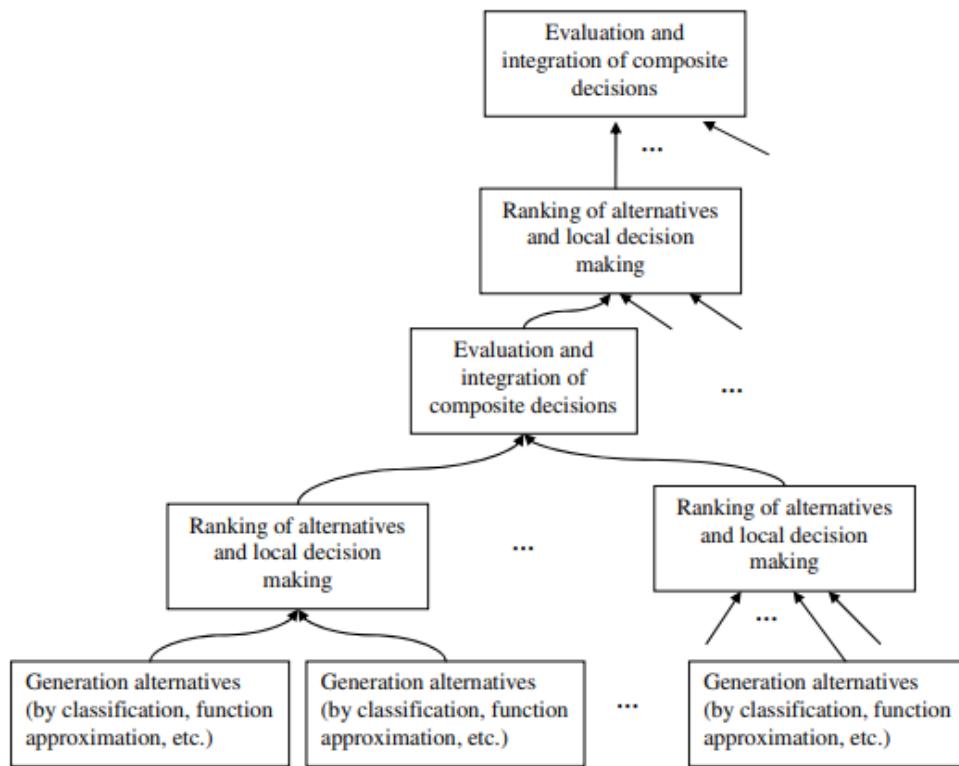


**Gambar 5.1** Alur kerja umum dari proses pengambilan keputusan

Sesuai dengan Gambar 2, keputusan dapat dilihat sebagai hasil dari keputusan lokal, alternatif, yang memenuhi kriteria seleksi. Kompleksitas meningkat jika semua ruang ini memiliki organisasi yang tersusun. Dalam kasus yang paling sederhana, alternatif yang mungkin adalah independen, tetapi mereka dapat dikelompokkan ke dalam kelompok, atau membentuk hierarki; keputusan dapat terdiri dari alternatif optimal terbaik, tetapi juga dapat dibentuk sebagai hasil kombinasi (linier, non-linier, paralel, dan sebagainya) dari alternatif, dan himpunan bagian dan stratifikasinya; kriteria dapat bersifat independen atau dependen, dan, umumnya, diatur secara hierarkis.

Pendekatan kami terhadap DSS untuk sistem yang kompleks didasarkan pada struktur DSS umum yang dibahas pada bagian 3. Komponen utama DSS, yaitu (a) antarmuka pengguna, (b) database, (c) alat pemodelan dan analisis, dan (d) arsitektur dan jaringan DSS, telah ditentukan untuk fitur dan karakteristik khusus dari domain aplikasi yang mungkin. Perbedaan yang paling penting adalah bahwa DSS diwujudkan dalam bentuk sistem multi-agenn, dan agen menyediakan fungsionalitas sistem dan mewujudkan fungsi organisasi dan administrasi.

Organisasi DSS dalam bentuk MAS memfasilitasi pengambilan keputusan yang terdistribusi dan disepakati, karena gagasan MAS berfungsi sempurna untuk mengatasi kesulitan sistem yang kompleks. MAS, yang dapat digambarkan sebagai komunitas entitas cerdas – agen komputasi, menawarkan solusi karena properti agensi, yaitu: reaktivitas (agen merespons secara tepat waktu terhadap perubahan lingkungan); otonomi (seorang agen menjalankan kendali atas tindakannya sendiri); orientasi tujuan (agen tidak hanya bertindak sebagai respons terhadap lingkungan, tetapi bermaksud untuk mencapai tujuannya); pembelajaran (agen mengubah perilakunya karena pengalaman sebelumnya), penalaran (kemampuan untuk menganalisis dan membuat keputusan), komunikasi (agen berkomunikasi dengan agen lain, termasuk entitas eksternal), dan mobilitas (agen mampu untuk mengangkut dirinya dari satu mesin ke mesin lainnya) [5-6].



**Gambar 5.2** Keputusan gabungan sebagai hasil komposisi antara kemungkinan keputusan, alternatif, sehubungan dengan kriteria seleksi

### 5.3 SISTEM PENDUKUNG KEPUTUSAN DAN KARAKTERistiknya

Ada banyak definisi tentang apa itu DSS; misalnya, salah satunya adalah bahwa sistem pendukung keputusan adalah kelas khusus dari sistem informasi terkomputerisasi yang mendukung aktivitas pengambilan keputusan bisnis dan organisasi. DSS yang dirancang dengan baik adalah sistem berbasis perangkat lunak interaktif yang dimaksudkan untuk membantu pengambil keputusan dalam mengumpulkan informasi yang berguna dari data mentah, dokumen, pengetahuan pribadi, dan/atau model bisnis untuk mengidentifikasi dan memecahkan masalah serta membuat keputusan. Bonczek dkk. [7] mendefinisikan DSS sebagai sistem berbasis komputer yang terdiri dari tiga komponen yang saling berinteraksi: sistem bahasa, sistem pengetahuan, dan sistem pemrosesan masalah. Definisi ini mencakup desain DSS lama dan baru, karena sistem pemrosesan masalah dapat berupa model berbasis, atau sistem pakar, atau sistem berbasis agen, atau sistem lain yang menyediakan kemampuan manipulasi masalah. Keen [8] menerapkan istilah DSS untuk situasi di mana sistem 'final' hanya dapat dikembangkan melalui proses pembelajaran dan evolusi yang adaptif. Dengan demikian, ia mendefinisikan DSS sebagai produk dari proses pengembangan yang melibatkan pembangun, pengguna, dan DSS itu sendiri untuk berkembang menjadi sistem gabungan.

Sprague dan Carlson [9] mengidentifikasi tiga komponen mendasar dari DSS: (a) sistem manajemen basis data (DBMS), (b) sistem manajemen berbasis model (MBMS), dan, (c) pembangkitan dialog dan sistem manajemen ( DGM). Levin [10] menganalisis sejumlah karya dan menyebutkan komponen-komponen berikut sebagai esensial untuk DSS modern: (1) model, yang mencakup teknik multi-kriteria, skema pemecahan masalah, pemrosesan data,

dan manajemen pengetahuan; (2) metode analitis dan numerik dari pra-pemrosesan data dan identifikasi masalah untuk tahap awal pengambilan keputusan; (3) interaksi manusia-komputer dan organisasinya melalui antarmuka grafis dan lain-lain; (4) dukungan informasi, komunikasi dengan database, layanan web, dll. Menurut Power [11], akademisi dan praktisi telah membahas pembangunan DSS dalam empat komponen utama: (a) antarmuka pengguna, (b) database, (c) perangkat pemodelan dan analisis, dan (d) arsitektur dan jaringan DSS. Definisi DSS, berdasarkan Levin dan Power, bahwa DSS adalah sistem untuk mendukung dan meningkatkan pengambilan keputusan, menurut pandangan kami, mewakili latar belakang yang optimal untuk pembuatan DSS praktis.

### **Agen dan Sistem Pendukung Keputusan**

Agen dan sistem multi-agensi (MAS) secara aktif digunakan untuk pemecahan masalah dan telah merekomendasikan diri mereka sendiri sebagai teknik yang andal dan kuat [12-14]. Istilah "agen" memiliki banyak definisi, dan umumnya ditentukan sebagai "suatu entitas yang dapat mengamati dan bertindak atas lingkungan dan mengarahkan aktivitasnya untuk mencapai tujuan". Dalam praktiknya, agen sering dimasukkan ke dalam sistem multi agen, yang dapat ditentukan sebagai komunitas pemecah tugas entitas cerdas yang terdesentralisasi (agen komputasi), yang berorientasi pada beberapa masalah. Agen dalam sistem multi agen memiliki beberapa karakteristik penting [6]:

- Otonomi: agen setidaknya sebagian otonom.
- Pandangan lokal: tidak ada agen yang memiliki pandangan global penuh terhadap sistem, atau sistem terlalu kompleks bagi agen untuk menggunakan pengetahuan tersebut secara praktis
- Desentralisasi: tidak ada pedoman pusat dalam sistem, dan agen menggunakan kemampuan penalaran mereka untuk bertindak sesuai dengan keyakinan internal.

MAS dapat mewujudkan pengorganisasian diri dan perilaku kompleks bahkan ketika strategi individu dari semua agen mereka sederhana. Agen dapat berbagi pengetahuan menggunakan bahasa yang disepakati dalam batasan protokol komunikasi sistem. Contoh bahasa komunikasi agen adalah Knowledge Query Manipulation Language (KQML) atau Agent Communication Language (ACL) FIPA.

Diperlukan mekanisme untuk mengiklankan, menemukan, menggabungkan, menggunakan, menyajikan, mengelola, dan memperbarui layanan dan informasi agen. Sebagian besar MAS menggunakan agen fasilitator untuk membantu menemukan agen, agen di mana agen lain menyerahkan otonomi mereka sebagai imbalan atas layanan fasilitator. Fasilitator dapat mengoordinasikan kegiatan agen dan dapat memenuhi permintaan atas nama agen bawahannya. MAS dapat diklasifikasikan sesuai dengan beberapa pengklasifikasi. Ada MAS yang tertutup dan terbuka. Yang pertama berisi agen berperilaku baik yang dirancang untuk bekerja sama dengan mudah menuju tujuan global. MAS, terkait dengan tipe kedua, dapat berisi agen yang tidak dirancang untuk bekerja sama dan berkoordinasi, tetapi untuk membantu agen dalam bekerja sama. Jenis yang paling umum dari mekanisme ini adalah untuk negosiasi dan lelang. Weiss memberikan klasifikasi lain: MAS diklasifikasikan berdasarkan tingkat otonomi, jenis organisasi, dan arsitektur [6]. Bergantung pada tingkat otonomi dan orientasi diri setiap agen, MAS dapat bervariasi dari sistem terdistribusi dan "independen" hingga sistem tipe "organisasi" yang diawasi, di mana setiap agen mengetahui

urutan dan giliran pelaksanaannya. MAS adalah sejenis sistem informasi, dan perencanaan serta pembuatannya, sebenarnya, mencakup serangkaian tugas dan pekerjaan yang sama seperti dalam kasus umum perangkat lunak apa pun.

### **Perencanaan dan Desain Multi-agenn**

#### **Siklus Hidup Pengembangan Multi-agenn**

Penciptaan, penyebaran, dan pasca implementasi MAS sebagai produk perangkat lunak adalah proses yang kompleks, yang melewati serangkaian langkah yang membentuk siklus hidupnya. Setiap langkah dari proses siklus hidup harus didukung dan disediakan oleh alat dan metodologi program. Dalam hal pengembangan MAS, tidak ada pendekatan terpadu untuk mencakup semua langkah. Namun, ada beberapa karya yang didekarasikan untuk masalah ini [15-16]. Misalnya, de Wolf dan Holvoet [15] telah menawarkan metodologi dalam konteks model siklus hidup standar, dengan aksen desentralisasi dan pandangan makroskopik proses. Sebagai alat dan kerangka kerja penulis menyebutkan Jade [17], Repast [18] dan lingkungan untuk koordinasi sistem multi-agenn yang terletak [19].

Para penulis menawarkan metodologi mereka dengan asumsi bahwa tugas penelitian telah ditentukan. Padahal, siklus hidup perangkat lunak mencakup definisi masalah dan tahap analisis domain, yang tidak dapat diabaikan. Pengembangan perangkat lunak dalam kasus MAS didasarkan pada langkah-langkah berikut [20]:

1. **Analisis Domain** - terkait dengan analisis ide proyek, definisi masalah, ekstraksi tujuan, pembuatan pohon tujuan, urutan tugas dan subtugas yang harus diselesaikan. Tahap ini juga menyiratkan penciptaan ontologi domain, yang meliputi area masalah, himpunan hubungan antara konsep dan aturan untuk menerima pengetahuan baru. Pekerjaan ahli domain area diperlukan pada tahap ini.
2. **Analisis Elemen Perangkat Lunak** - tahap ini juga berhubungan dengan pembuatan ontologi pribadi, tetapi sekarang, ontologi dibuat untuk sistem dan elemen-elemennya. Kumpulan tujuan dan tugas terkait dengan kumpulan fungsi sistem (peran), sumber daya yang dibutuhkan (umumnya dalam bentuk file informasi), interaksi, dll.
3. **Spesifikasi** - adalah deskripsi tertulis dari tahapan sebelumnya, yang menghasilkan pembuatan meta-ontologi sistem.
4. **Arsitektur Perangkat Lunak** - menyiratkan representasi abstrak dari sistem untuk memenuhi persyaratan. Arsitektur perangkat lunak mencakup antarmuka untuk komunikasi pengguna komputer.
5. **Implementasi (coding)** - proses berulang dari pembuatan program.
6. **Pengujian** - pengujian program dalam kondisi normal dan kritis.
7. **Deployment and Maintenance** - aplikasi dan dukungan program hingga perangkat lunak mulai digunakan. Terkadang beberapa kelas pelatihan tentang produk perangkat lunak dibuat.
8. **Akhir Pemeliharaan** - adalah tahap akhir dari siklus hidup perangkat lunak.

### **Representasi Ontologi**

Ada banyak bahasa untuk pembuatan ontologi. Untuk menyebutkan beberapa, tetapi tidak semua, kami memiliki: OKBC, Ontolingua/KIF, OIL, SHOE, XOL, DAML+OIL, Cycl, OWL, dan RDF. Penciptaan XML (eXtensible Markup Language) tampaknya menjadi keuntungan

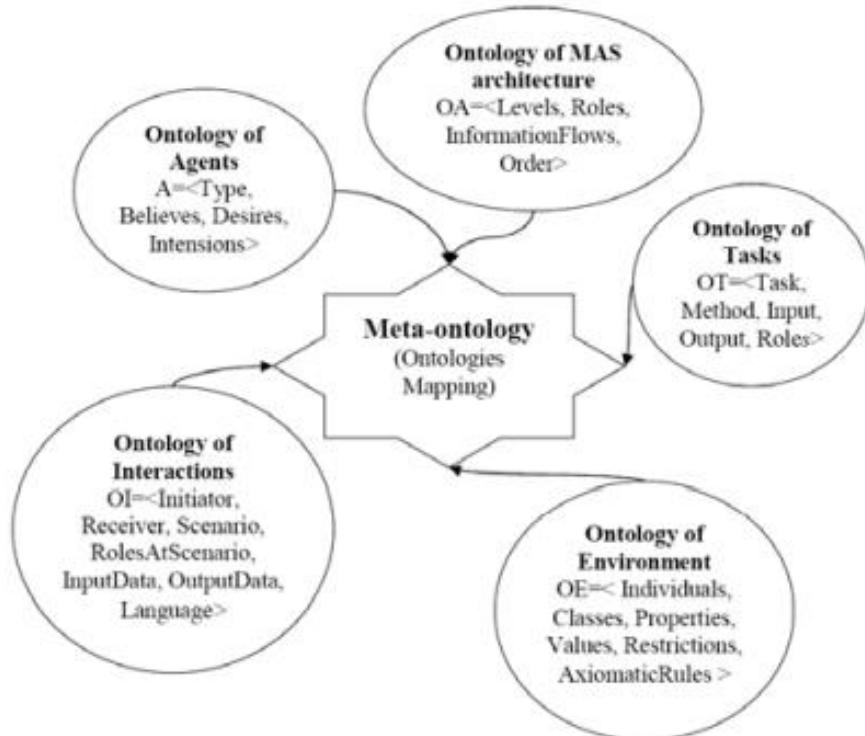
nyata terhadap representasi pengetahuan di Web. XML memberi pengguna berbagai kemungkinan untuk membuat sistem representasi data logis mereka sendiri, menentukan tag, elemen struktural, dan hubungannya. Semua koneksi antar tag dapat diselesaikan dan disimpan dalam DTD (Document Type Definition) atau dokumen skema XML. Mode representasi data dalam dokumen XML didefinisikan dalam file XSL (eXtended Style Language). Meskipun XML mengizinkan untuk mengatur dan menyusun representasi data, XML tidak memiliki kemungkinan untuk mewakili semantiknya, karena dalam XML tidak ada standar untuk tag dan definisi relasinya.

### **Perencanaan meta-ontologi**

Menurut Guarino dkk. [21], ontologi dapat dipahami sebagai struktur semantik yang disengaja yang mengkodekan aturan implisit yang membatasi struktur sepotong realitas. Ada sejumlah pendekatan untuk pembuatan ontologi, sebagian besar disebabkan oleh kekhususan domain yang diminati dan sifat tugas yang harus diselesaikan (mis. penciptaan:

1. Deskripsi situasi dalam bahasa alami.
2. Penciptaan kosakata (ekstraksi konsep yang menggambarkan situasi).
3. Pembuatan taksonomi.
4. Pembuatan struktur meta-ontologi terdistribusi.
5. Domain pernyataan ontologi kepentingan.
6. Deskripsi tugas yang harus diselesaikan dan pembuatan ontologi pribadi masing-masing.
7. Deskripsi peran MAS, agen dan pembuatan ontologi arsitektur sistem.
8. Deskripsi ontologi agen.
9. Pernyataan ontologi lingkungan agen dengan menetapkan protokol interaksi dan komunikasi.
10. Pemetaan ontologi.
11. Pengisian Data Base untuk MAS.
12. Sumber Data dikirimkan ke agen.

Ketika mempelajari secara singkat langkah-langkah dari algoritma yang diberikan, perlu dicatat bahwa langkah 1 - deskripsi masalah - berfungsi untuk lebih memahami tujuan penelitian dan struktur fungsionalitas situasi. Analisis awal ini membantu mendefinisikan secara konkret masalah yang dihadapi dan memulihkan konsep, karakteristik dan hubungannya untuk diperiksa. Pada tahap ini digunakan informasi pakar yang dilengkapi dengan data statistik dan referensi multimedia yang terkait dengan masalah.



**Gambar 5.3 Komponen meta-ontologi**

Tugas berikutnya (2) adalah penciptaan kosa kata, yang mencakup informasi yang diperlukan dan cukup tentang konsep-konsep. Langkah selanjutnya 3 terdiri dalam menambahkan satu set hubungan (termasuk yang hierarkis) antara konsep-konsep ke kosa kata, yang menghasilkan taksonomi. Seperti dalam pekerjaan kami, kami menggunakan metode induktif penciptaan ontologi, kemudian, pada langkah 4 kami menentukan struktur umum meta-ontologi (lihat Gambar 3) dan mengekstrak komponen utama yang dipisahkan secara fungsional dan semantik. Pada langkah 5 hingga 8 kami membuat ontologi pribadi untuk komponen meta-ontologi yang diekstraksi, yaitu domain yang diminati, arsitektur MAS, tugas, agen, dan interaksi. Pada langkah 9 dan 10 ontologi privat dipetakan bersama. Akhirnya, kami mengisi basis data untuk MAS (11) dan mengirimkan data nyata ke agen (12). Pada bagian artikel berikut ini, meta-ontologi terdistribusi dan ontologi privat, serta prosedur pemetaan, dijelaskan secara rinci.

Untuk memberikan dasar ontologis untuk domain yang diminati, serta untuk struktur dan organisasi MAS, kerangka penciptaan meta-ontologi, yang memetakan bersama ontologi pribadi, dikembangkan. Meta-Ontologi Terdistribusi diperoleh sebagai hasil pemetaan ontologi pribadi, dan dikumpulkan oleh penggunaan dan eksekusi umum mereka. Hal ini dicapai pada langkah 10 dari algoritma yang diusulkan sebelumnya. Dimensi ontologis bersama, diisi dengan data, menyediakan agen dengan pengalamatan yang benar ke konsep yang tepat dan menyinkronkan fungsionalitas MAS.

#### **Kerangka Perencanaan Sistem Multi-agenn**

Analisis Domain dan Langkah-langkah analisis Elemen Perangkat Lunak, yang dicatat dalam algoritma pengembangan MAS, dapat dilakukan melalui analisis domain dan pembuatan ontologi, menggunakan produk perangkat lunak untuk representasi pengetahuan,

yang dijelaskan di bagian sebelumnya. Jadi, “Analisis elemen perangkat lunak” membutuhkan informasi tentang fungsi dan taksonomi SAM. Di sini kita dapat menggunakan salah satu dari beberapa kerangka kerja, yang ada dan digunakan dalam praktik ilmiah. Beberapa yang paling sering digunakan, namun tidak terbatas, adalah: MaSE [23], Gaia [24], Agent ULM [25], Prometheus [26], Tropos [27], INGE-NIAS [28], dan beberapa lainnya.

Pengembangan Perangkat Lunak Berorientasi Agen adalah salah satu kontribusi terbaru di bidang Rekayasa Perangkat Lunak. Sampai saat ini banyak metodologi untuk pengembangan perangkat lunak berorientasi agen telah diusulkan dalam literatur. Namun, penerapannya pada masalah dunia nyata masih terbatas karena kurangnya kematangan. Mengevaluasi kekuatan dan kelemahan mereka merupakan langkah penting menuju pengembangan metodologi yang lebih baik di masa depan. MAS membawa beberapa kesulitan untuk peneliti, yang disebabkan oleh identifikasi tugas, menetapkan set protokol, interaksi, metode dan perilaku agen. Itu membuat alat desain perangkat lunak lebih canggih, yang beroperasi dengan konsep baru sebagai agen, tujuan, tugas, interaksi, rencana, keyakinan, dll. Metodologi menawarkan alat yang berbeda untuk mengatasi keterlibatan dan memfasilitasi perencanaan dan desain SAM [29]. Tinjauan singkat dari beberapa metodologi termasuk yang berikut.

Metodologi Prometheus mendefinisikan proses rinci untuk menentukan, merancang dan mengimplementasikan sistem perangkat lunak berorientasi agen. Ini terdiri dari tiga fase [30]: fase Spesifikasi Sistem, yang berfokus pada identifikasi tujuan dan fungsi dasar sistem, bersama dengan input (persepsi) dan output (tindakan) [31]; fase Desain Arsitektur, yang menggunakan output dari fase sebelumnya untuk menentukan jenis agen mana yang akan dikandung sistem dan bagaimana mereka akan berinteraksi; dan, fase Desain Terperinci, yang melihat bagian dalam setiap agen dan bagaimana ia akan menyelesaikan tugasnya dalam sistem secara keseluruhan.

**Spesifikasi Sistem.** Metodologi Prometheus berfokus terutama pada spesifikasi tujuan [32], dan deskripsi skenario [33]. Selain itu, memerlukan spesifikasi fungsionalitas – potongan kecil perilaku – terkait dengan tujuan yang diidentifikasi. Ada juga fokus pada bagaimana sistem agen berinteraksi dengan lingkungan di mana ia berada, dalam hal persepsi yang datang dari lingkungan, dan tindakan yang berdampak pada lingkungan. Sebagai bagian dari spesifikasi antarmuka, Prometheus juga membahas interaksi dengan penyimpanan data eksternal atau repositori informasi. Aspek-aspek yang dikembangkan dalam fase Spesifikasi Sistem adalah: spesifikasi tujuan sistem dengan deskriptor terkait, pengembangan serangkaian skenario yang memiliki cakupan tujuan yang memadai, definisi sekumpulan fungsi yang terkait dengan satu atau lebih tujuan dan yang menyediakan bagian terbatas dari perilaku sistem, dan, deskripsi antarmuka antara sistem agen dan lingkungan di mana ia berada.

**Desain arsitektur.** Tiga aspek yang dikembangkan selama fase Desain Arsitektur adalah: memutuskan jenis agen yang digunakan dalam aplikasi, menggambarkan interaksi antara agen menggunakan diagram interaksi dan protokol interaksi, dan, menggambarkan struktur sistem melalui diagram tinjauan sistem.

**Desain yang rinci.** Dalam Desain Terperinci, untuk setiap agen individu, diputuskan kemampuan apa yang dibutuhkan agen untuk memenuhi tanggung jawabnya sebagaimana

diuraikan dalam fungsionalitas yang dikandungnya. Spesifikasi proses untuk menunjukkan lebih banyak pemrosesan internal dari masing-masing agen dikembangkan. Dan ketika masuk ke detail yang lebih besar, deskripsi kemampuan untuk menentukan rencana individu, keyakinan dan peristiwa yang dibutuhkan dalam kemampuan dikembangkan. Kemudian pandangan yang menunjukkan pemrosesan tugas tertentu dalam agen individu dikembangkan. Selama fase terakhir dari desain terperinci inilah metodologi menjadi spesifik untuk agen yang menggunakan rencana yang dipicu peristiwa untuk mencapai tugas mereka.

Metodologi Gaia [24] memberikan dukungan penuh untuk pembuatan sistem multi-agen mulai dari penentuan kebutuhan, hingga desain detail. Ada dua fase pemodelan dengan Gaia: analisis dan desain. Tujuan dari tahap pertama adalah untuk memahami struktur sistem dan deskripsinya. Tujuan dari tahap desain adalah "untuk mengubah model abstrak yang diturunkan selama tahap analisis menjadi model pada tingkat abstraksi yang cukup rendah yang dapat dengan mudah diimplementasikan".

Fase analisis. Tahap analisis mengandaikan langkah-langkah berikut:

1. Identifikasi peran.
2. Deskripsi rinci tentang peran.
3. Pemodelan interaksi antar peran.

Pada tahap pertama, sebagai persyaratan untuk sistem dinyatakan, ada dua model yang akan dibuat: model Peran dan model Interaksi. Untuk membuat model Peran, pengembang harus memahami tujuan utama dari sistem yang dibuat, menganalisis profil organisasi dan fungsional sistem, yang diuraikan dan diwakili oleh serangkaian peran yang dimainkan. Konsep "Peran" adalah salah satu kunci dalam metodologi Gaia, karena menentukan fungsi yang terkait dengan beberapa tugas sistem (atau tugas), yang secara semantik dan fungsional berinteraksi dengan peran lainnya. Peran dapat dikaitkan dengan entitas sistem, misalnya, dalam hal organisasi manusia, peran dapat mewakili "manajer" dan "penjual".

Peran ditentukan oleh atribut berikut: tanggung jawab, izin, aktivitas, dan protokol. Tanggung jawab menentukan fungsi peran dan memiliki sifat semangat dan sifat keselamatan. Sifat keaktifan menggambarkan tindakan dan kondisi yang akan dibawa oleh agen, dengan kata lain, menentukan konsekuensi dari prosedur yang dijalankan, yang akan berpotensi dilakukan dalam peran. Sifat keselamatan menyatakan kondisi lingkungan yang penting, yang tidak dapat dilampaui atau diabaikan. Izin menentukan sumber daya dan batasannya untuk peran, dan biasanya diwakili oleh sumber daya informasi. Misalnya, bisa berupa kemampuan membaca, mengubah, atau menghasilkan informasi. Aktivitas adalah tindakan pribadi dari agen, yang dijalankan oleh agen itu sendiri, tanpa komunikasi dengan agen lain. Setiap peran dapat dikaitkan dengan satu atau lebih protokol, yang menyatakan komunikasi dengan peran lain. Atribut yang dijelaskan untuk setiap peran dikumpulkan dalam apa yang disebut skema peran, dengan demikian, terdiri dari model Peran.

Model interaksi difokuskan pada deskripsi protokol dan komposisinya. Protokol menentukan hubungan antara peran dan menyediakan interaksi dalam struktur multi-agen. Definisi protokol meliputi: tujuan - deskripsi tekstual singkat atau nama rinci protokol, yang menemukan sifat interaksi; inisiatör - nama peran, yang memulai interaksi; responder - peran yang digunakan oleh inisiatör untuk berkomunikasi; input - informasi yang diberikan oleh responden selama interaksi; pemrosesan - deskripsi singkat tentang proses yang

direalisasikan dalam protokol. Akhirnya, dalam fase analisis, ada model Peran yang dibuat, dengan protokol terkait, yang terdiri dari model Interaksi.

Fase desain. Selama fase desain, model layanan, agen, dan kenalan dibuat. Model-model ini memberikan deskripsi rinci tentang sistem multi-agennya yang kemudian dapat dengan mudah diimplementasikan. Model Agen menghubungkan peran ke setiap jenis agen, dengan mempertimbangkan bahwa agen dapat memainkan satu atau lebih peran. Agen membentuk hierarki di mana simpul daun sesuai dengan peran dan simpul lain dengan jenis agen lainnya. Jumlah instance agen juga didokumentasikan; misalnya, agen dapat dipanggil untuk dieksekusi sekali, atau n kali, atau diulang dari m hingga n kali, dll. Model Layanan mengidentifikasi sumber daya yang diperlukan untuk setiap fungsi yang dilakukan oleh agen. Setiap fungsi (atau layanan) memiliki properti, yang meliputi input, output - yang berasal dari protokol, dan prakondisi dan pascakondisi, yang menyatakan kendala dan diturunkan dari properti keselamatan dari peran terkait. Model Kenalan dibuat dari model Interaksi dan Agen, dan berfungsi untuk menyatakan hubungan komunikasi antara agen, dan diwakili oleh grafik berarah, di mana setiap simpulnya berhubungan dengan agen, dan setiap tepi ke tautan komunikasi.

### ***Alat Perangkat Lunak untuk Desain dan Implementasi Sistem Multi-agent***

Karena sifat masalah yang kompleks untuk dipecahkan, sistem multi-agennya menjadi lebih rumit untuk direncanakan dan dirancang. Ada muncul konsep baru seperti tujuan, peran, rencana, interaksi, lingkungan, yang diperlukan untuk mengidentifikasi fungsi sistem, interaksi antara agen, keadaan mental dan perilaku yang terakhir. Di sisi lain, MAS harus aman, mobile dan mampu mengatasi pemecahan masalah terdistribusi. Ini menempatkan persyaratan pada metodologi untuk membantu desainer menangani masalah ini, dan mengelola kompleksitas ini. Metodologi harus memfasilitasi dan mendukung rekayasa sistem berbasis agen dengan menyediakan dukungan terminologi yang solid, notasi yang tepat dan interaksi yang andal, dan organisasi fungsionalitas sistem secara umum.

Saat ini, ada sejumlah metodologi untuk perencanaan dan desain SAM, yang dibagi menjadi beberapa langkah, di mana sistem pertama-tama dijelaskan secara umum, dan kemudian secara lebih rinci, yang menentukan fungsionalitas internal entitas sistem. Dua metodologi terkenal disajikan dan dibahas di bagian sebelumnya. Dan, pada bagian ini akan dibahas perangkat lunak untuk implementasi pengkodean sistem. Ini dapat dilihat sebagai kelanjutan logis dari metodologi (alat Perangkat Lunak JACK terkait dengan Alat Desain Prometheus dan MASDK didasarkan pada metodologi Gaia).

**JACK Development Environment (JDE)** adalah paket perangkat lunak untuk pengembangan aplikasi berbasis agen di lingkungan berbasis Java JACK [35]. JDE memiliki antarmuka visual, yang mendukung pembuatan aplikasi. Ini dapat dilakukan secara langsung di lingkungan JDE, atau diimpor, misalnya, dari Prometheus Development Tool, editor grafis yang menyediakan desain sistem agen sesuai dengan metodologi terkait Prometheus [35]. JDE memungkinkan membangun aplikasi dengan menyediakan representasi visual dari komponen sistem dalam dua mode: mode agen dan mode tim. Jack, yang ditulis dalam Java, menyediakan pemrograman berorientasi objek untuk sistem, merangkum perilaku yang diinginkan dalam unit modular sehingga agen dapat beroperasi secara independen. Agen cerdas JACK didasarkan pada model Believe-Desire-Intention, di mana komponen perangkat lunak otomotif

(agen) mengejar tujuan yang diberikan (keinginan), mengadopsi rencana yang sesuai (niat) sesuai dengan kumpulan data saat ini (keyakinan) tentang keadaan dunia.

Oleh karena itu, agen JACK adalah komponen perangkat lunak yang memiliki (a) seperangkat keyakinan tentang dunia (kumpulan datanya), (b) serangkaian peristiwa yang akan ditanggapinya, (c) seperangkat tujuan yang mungkin keinginan untuk mencapai (baik atas permintaan agen eksternal, sebagai konsekuensi dari suatu peristiwa, atau ketika satu atau lebih keyakinannya berubah), dan, (d) seperangkat rencana yang menggambarkan bagaimana ia dapat menangani tujuan atau peristiwa yang mungkin timbul. JACK mengizinkan pembuatan beberapa agen otonom, yang dapat dijalankan dalam mode agen dan tim dalam sistem multi-agen. Penciptaan MAS dapat diwujudkan dengan menggunakan antarmuka grafis. Ekstensi JACK ke mode Tim memungkinkan Model Tim untuk diperlakukan sebagai rekan, dan memperkenalkan konsep baru sebagai tim, peran, data tim, dan rencana tim, yang diperlukan untuk semantik luas beberapa elemen, dan untuk memunculkan entitas penalaran tim, pengetahuan, dan koordinasi internal agen di dalam tim. Konsep kunci yang muncul di sini adalah konsep peran. Sebuah peran mendefinisikan cara berinteraksi antara tim yang berisi (pemegang peran) dan tim yang berisi (emain peran atau pengisi peran). Dalam mode Tim JACK, setiap tim memiliki masa hidupnya, yang dibagi menjadi dua fase: fase pertama adalah untuk menyiapkan struktur kewajiban peran awal dan fase kedua merupakan operasi tim yang sebenarnya. Selain agen percaya, dalam mode tim, pengetahuan dapat "disebarluaskan" ke anggota tim. Prometheus Development Kit mengizinkan pembuatan kode kerangka untuk implementasi selanjutnya di JACK, yang memfasilitasi tahapan perencanaan dan pengkodean MAS. Sebenarnya, tim JACK dapat digunakan untuk pemodelan sistem terdistribusi yang kompleks dan pemecahan masalah.

**Java Agent DEvelopment Framework (JADE)** adalah Framework perangkat lunak yang sepenuhnya diimplementasikan dalam bahasa Java [17]. Pengembang memposisikan JADE sebagai "peralatan tengah untuk pengembangan dan eksekusi run-time aplikasi peer-to-peer yang didasarkan pada paradigma agen dan yang dapat bekerja dengan mulus dan beroperasi baik di lingkungan kabel dan nirkabel." JADE memfasilitasi pengembangan aplikasi terdistribusi yang terdiri dari entitas otonom yang perlu berkomunikasi dan berkolaborasi untuk mencapai kerja seluruh sistem.

Di satu sisi, JADE adalah sistem run-time untuk MAS yang sesuai dengan FIPA, yang mendukung agen aplikasi yang setuju dengan spesifikasi FIPA. Di sisi lain, JADE menyediakan pemrograman berorientasi objek melalui pesan, pengelolaan siklus hidup agen, dll. Secara fungsional, JADE menyediakan layanan dasar yang diperlukan untuk mendistribusikan aplikasi peer-to-peer di lingkungan tetap dan bergerak. Setiap agen secara dinamis dapat menemukan agen lain dan dapat berkomunikasi dengan mereka secara langsung. Setiap agen diidentifikasi dengan nama yang unik dan menyediakan satu set layanan, mengelolanya, dapat mengontrol siklus hidupnya dan berkomunikasi dengan orang lain.

JADE adalah platform terdistribusi, yang terdiri dari satu atau lebih wadah agen, masing-masing didukung oleh Java Virtual Machine (JVM), dan JVM menyediakan lingkungan waktu berjalan yang lengkap untuk eksekusi agen dan memungkinkan beberapa agen untuk dieksekusi secara bersamaan pada host yang sama. Konfigurasi dapat dikontrol melalui antarmuka pengguna grafis jarak jauh. Konfigurasi bahkan dapat diubah saat run-time dengan

memindahkan agen dari satu mesin ke mesin lainnya, jika diperlukan. JADE memiliki dua jenis pesan: antar-platform dan intra-platform (agen yang berinteraksi berada di dalam platform yang sama). Pesan yang diwujudkan dalam Agent-Communication Language (ACL), disajikan dalam bentuk antrian, yang dapat diakses melalui kombinasi beberapa mode: berbasis pemblokiran, polling, timeout dan pencocokan pola. JADE sepenuhnya diimplementasikan dalam bahasa Java dan persyaratan sistem minimal adalah versi 1.4 dari JAVA (run time environment atau JDE).

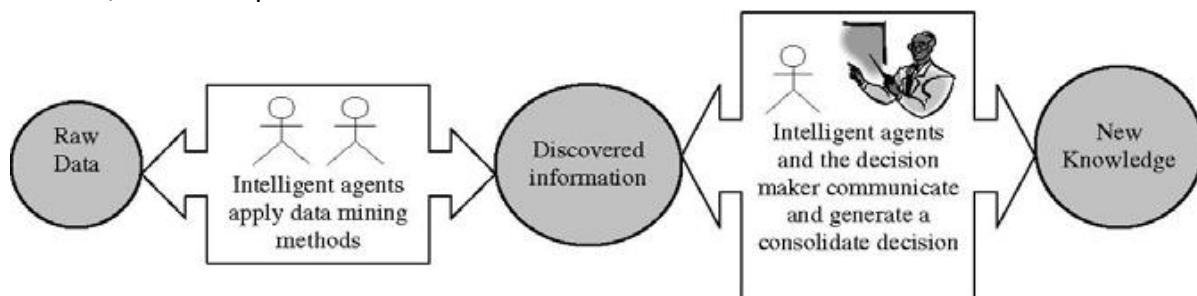
Kit Pengembangan Sistem Multi-agen (MASDK) adalah metodologi yang relatif baru, dibuat di Laboratorium Sistem Cerdas, Institut Informatika dan Otomasi St. Petersburg dari Akademi Ilmu Pengetahuan Rusia [4,36]. Alat perangkat lunak menyediakan dukungan untuk seluruh siklus hidup pengembangan MAS. Sebagai landasan terminologi, penulis menggunakan metodologi Gaia. Perangkat lunak MASDK 3.0 terdiri dari komponen-komponen berikut: (1) kernel sistem yang merupakan struktur data untuk representasi berbasis XML dari spesifikasi formal MAS yang diterapkan; (2) kumpulan editor ramah pengguna yang terintegrasi yang mendukung aktivitas pengguna yang bertujuan untuk spesifikasi formal SAM terapan yang sedang dikembangkan pada tahap analisis, desain, dan implementasi; (3) perpustakaan kelas C++ dari komponen agen yang dapat digunakan kembali yang merupakan apa yang biasanya disebut agen Generik; (4) platform komunikasi yang akan dipasang di komputer-komputer tertentu dalam suatu jaringan; dan (5) pembuat instance agen perangkat lunak yang bertanggung jawab untuk pembuatan kode sumber C++ dan kode agen perangkat lunak yang dapat dieksekusi serta penyebaran agen perangkat lunak melalui platform komunikasi yang sudah diinstal.

MASDK mencakup tiga editor, yang bertindak pada masing-masing dari tiga level. Editor yang pertama sesuai dengan fase analisis Gaia dan didedikasikan untuk penentuan ontologi, ekstraksi peran dan penentuan protokol dan interaksi antara agen. Editor tingkat kedua mendukung aktivitas desain dan terutama bertujuan untuk spesifikasi kelas agen. Mereka termasuk agen yang menentukan perilaku, ontologi agen, fungsi dan rencana. Para editor tingkat ketiga mendukung tahap implementasi MAS terapan dan komponen tertentu serta daftar contoh agen dari semua kelas dengan referensi ke lokasi mereka (nama host), dan status awal agen percaya. Tahap selanjutnya sesuai dengan tahap desain metodologi Gaia, di mana pengembang mengisi entitas struktural MAS yang digeneralisasi dengan komponen internal, yaitu sebagai berikut: (1) komponen invarian (dapat digunakan kembali) yang disebut Agen Generik, (2) meta -model perilaku kelas agen, (3) banyak fungsi kelas agen diwakili dalam mesin negara, dan, (4) perpustakaan fungsi tambahan tertentu Spesifikasi MAS diterapkan yang dihasilkan oleh desainer mengeksplorasi editor di atas disimpan sebagai file XML di kernel sistem. Spesifikasi ini, termasuk sekumpulan komponen dan fungsi tertentu yang diimplementasikan dalam C++, dan komponen Generic Agent yang dapat digunakan kembali membentuk input dari pembuat agen perangkat lunak yang menghasilkan kode perangkat lunak secara otomatis berdasarkan teknologi XSLT.

## **5.4 PENDEKATAN UMUM UNTUK PEMBUATAN SISTEM MULTI-AGEN**

### **Perubahan Informasi**

Sejumlah besar informasi data mentah menggambarkan sistem "lingkungan - kesehatan manusia", tetapi tidak semua informasi dapat berguna. Untuk pemodelan situasi, kami berorientasi pada informasi faktual dan konteks, yang disajikan dalam kumpulan data dan kami menggunakan agen komputasi untuk mengekstraknya. Jadi, informasi berubah dari keadaan "mentah" awal menjadi keadaan "informasi", yang menyarankan kumpulan data yang terorganisir, model dan dependensi, dan, akhirnya, menjadi "informasi baru" yang memiliki bentuk rekomendasi, nilai penilaian risiko dan perkiraan. Cara di mana informasi berubah, diberikan pada Gambar. 4.



**Gambar 5.4** Transformasi informasi, yang berubah dari pandangan yang tidak terorganisir dan heterogen menjadi bentuk pengetahuan

Informasi tersembunyi ditemukan oleh agen, tetapi untuk konstruksi informasi baru tidak hanya agen cerdas, tetapi pengetahuan pembuat keputusan atau ahli yang terlibat. Sistem pendukung keputusan berbasis agen (MAS) yang kami buat menyediakan perubahan informasi ini. Proses perubahan informasi, ditunjukkan pada Gambar. 4, sesuai dengan aliran siklus hidup MAS, yang, dalam kasus MAS, menghitung langkah-langkah berikut:

1. **Analisis Domain** - terkait dengan analisis ide proyek, definisi masalah, ekstraksi tujuan, pembuatan pohon tujuan, urutan tugas dan subtugas yang harus diselesaikan. Tahap ini juga menyiratkan penciptaan ontologi domain, yang mencakup area masalah, himpunan hubungan antara konsep dan aturan untuk memasukkan pengetahuan baru. Pengalaman para ahli domain area diperlukan pada tahap ini.
2. **Analisis Elemen Perangkat Lunak** - tahap ini juga berhubungan dengan pembuatan ontologi pribadi; tetapi sekarang ontologi dibuat untuk sistem dan elemen-elemennya. Kumpulan tujuan dan tugas terkait dengan kumpulan fungsi sistem (peran), sumber daya yang dibutuhkan (umumnya dalam bentuk file informasi), interaksi, dan sebagainya.
3. **Spesifikasi** - adalah deskripsi tertulis dari tahapan sebelumnya, yang menghasilkan pembuatan meta-ontologi sistem.
4. **Arsitektur Perangkat Lunak** - menyiratkan representasi abstrak dari sistem untuk memenuhi persyaratan. Arsitektur perangkat lunak mencakup antarmuka untuk komunikasi manusia-komputer.
5. **Implementasi** - proses berulang dari pembuatan program.
6. **Pengujian** - pengujian program dalam kondisi normal dan/atau kritis.
7. **Deployment and Maintenance** - aplikasi dan dukungan program hingga perangkat lunak mulai digunakan. Terkadang beberapa kelas pelatihan tentang produk perangkat lunak dibuat.

## 8. Akhir Pemeliharaan - adalah tahap akhir dari siklus hidup perangkat lunak.

Alur kerja tugas, yang harus diselesaikan untuk integrasi informasi (lihat Gambar 2) berisi empat status transformasi data berurutan: (1) sumber data heterogen awal, (2) penyimpanan data yang diekstraksi, (3) dipetakan (menyatu) meta-data, (4) ontologi global bersama dari area masalah (ontologi domain) dan tiga aliran/proses, yang menyediakan dan mengatur transformasi: (i) pengambilan dan ekstraksi data, (ii) pemetaan data (fusi), (iii) pengisian ontologi area masalah (ontologi domain).

### **Organisasi dan Arsitektur Sistem Multi-agenn**

Kami telah menerapkan sistem perangkat lunak berorientasi agen yang didedikasikan untuk penilaian dampak lingkungan. Sistem menerima informasi statistik retrospektif dalam bentuk nilai indikator langsung - polusi air, radiasi matahari - dan dalam bentuk nilai indikator tidak langsung - jenis dan jumlah kendaraan yang digunakan, energi yang digunakan setiap tahun dan energi yang dihemat, jenis dan jumlah bahan bakar yang digunakan, dll. Indikator tidak langsung digunakan sesuai dengan standar "Evaluasi Kinerja Lingkungan" ISO 14031 untuk memperkirakan polusi udara dan tanah [37]. Paparan populasi terdaftar sebagai jumlah kasus morbiditas sehubungan dengan Klasifikasi Statistik Internasional Penyakit dan Masalah Kesehatan Terkait, tinjauan ke-10 (ICD-10) [38].

Untuk menyediakan desain sistem, kami memutuskan untuk menggunakan Prometheus Development Tool (PDT), yang menyediakan berbagai kemungkinan untuk perencanaan dan implementasi SAM: arsitektur sistem, entitas sistem, internalnya dan komunikasi di dalam sistem dan dengan entitas luar. Keuntungan paling penting dari PDT adalah antarmuka visual yang mudah dimengerti dan kemungkinan untuk menghasilkan kode untuk JACK™ Intelligent Agents, yang digunakan untuk implementasi, verifikasi, dan pemeliharaan MAS. Analisis awal sistem telah menghasilkan dan menggambarkan peran sistem dan protokol. Di sana, sistem yang diusulkan secara logis dan fungsional dibagi menjadi tiga lapisan; yang pertama didedikasikan untuk pembuatan meta-data (fusi informasi), yang kedua ditujukan untuk penemuan pengetahuan (data mining), dan lapisan ketiga menyediakan pembuatan skenario alternatif secara real-time untuk pengambilan keputusan.

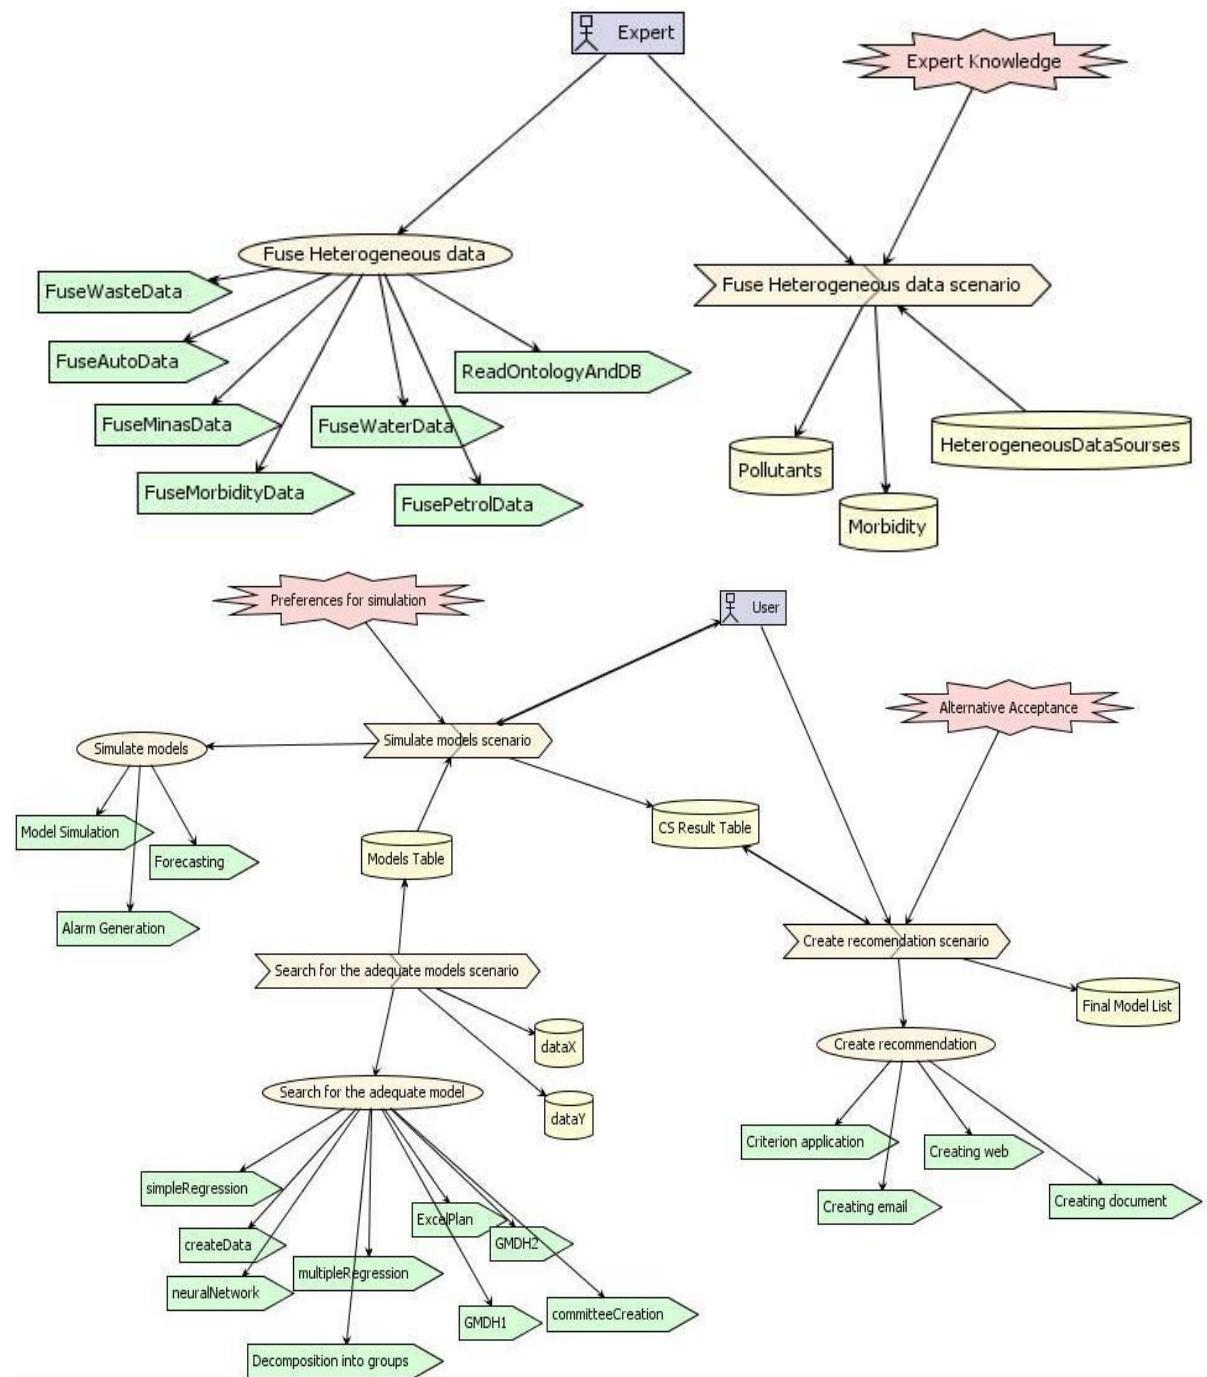
Tujuan yang digambarkan pada Gambar 5 mengulangi poin utama dari proses pengambilan keputusan tradisional, yang meliputi langkah-langkah berikut: (1) definisi masalah, (2) pengumpulan informasi, (3) identifikasi tindakan alternatif, (4) evaluasi alternatif, (5) pemilihan alternatif terbaik, dan, (6) implementasi alternatif. Tahap pertama dan kedua dilakukan pada tahap awal, ketika informasi ahli dan data retrospektif awal dikumpulkan, tahap 3, 4 dan 5 diselesaikan dengan MAS, dan tahap ke-6 seharusnya direalisasikan oleh pengambil keputusan. Diimplementasikan melalui Alat Desain Prometheus, Diagram Tinjauan Analisis MAS memungkinkan melihat tampilan tingkat tinggi yang terdiri dari aktor eksternal, skenario kunci, dan tindakan (lihat Gambar 5). MAS yang diusulkan mengandaikan komunikasi dengan dua aktor. Satu aktor disebut sebagai "Pakar" dan mewujudkan entitas eksternal yang memiliki informasi tentang area masalah -secara lebih rinci, ini mencakup pengetahuan tentang domain yang diinginkan yang direpresentasikan sebagai ontologi -dan mengirimkannya melalui protokol ReturnEI ke MAS.

Sumber data yang diberi nama "Hasil CS" menyimpan hasil simulasi dan membentuk basis pengetahuan (KB). Melalui skenario Model Simulasikan pengguna berinteraksi dengan KB, dan mendapatkan rekomendasi jika sebelumnya telah disimulasikan dan disimpan sebelumnya, atau membuat dan mensimulasikan yang baru. Sebagai hasil dari interaksi dalam skenario FuseHeterogeneousData, informasi mentah sedang dibaca, dan ditampilkan sebagai penyimpanan data "Sumber Data Heterogen", dan ada sumber data "Polusi" dan "Morbiditas".

Aktor kedua, bernama "Decision Maker", terlibat dalam proses interaktif pengambilan keputusan dan memilih alternatif yang optimal. Aktor ini berkomunikasi dengan agen melalui pesan yang melewati protokol ReturnSUI, menyatakan model, nilai simulasi, periode prediksi, tingkat perubahan variabel, dll. Ia menerima alternatif terbaik sesuai dengan keyakinannya dan MAS. Alur kerja, yang penting untuk pengambilan keputusan, mencakup tiga skenario: skenario Simulasikan model, skenario Buat rekomendasi, dan skenario Pencarian model yang memadai; dan tiga tujuan, yang terkait dengan setiap skenario dan memiliki nama yang mirip. Setiap tujuan memiliki sejumlah kegiatan, dan dalam setiap skenario digunakan, dimodifikasi atau dibuat sumber informasi dalam bentuk sumber data.

Selain arsitektur MAS yang diterima dan untuk mendapatkan waktu proses pembuatan rekomendasi dan mengoptimalkan interaksi antar agen, kami menggunakan tim agen lokal, yang mengoordinasikan dan mengawasi pelaksanaan tugas dan penggunaan sumber daya. Tim agen telah diizinkan untuk menyinkronkan pekerjaan sistem, merencanakan eksekusi dalam mode bersamaan dan memperkuat manajemen internal dengan pengambilan keputusan lokal.

Saat kami menggunakan empat tim agen dalam sistem: dua di tingkat pertama, dan satu tim di tingkat kedua dan ketiga, dan setiap agen "utama" memainkan beberapa peran. Pada Tabel 1 kami memberikan pandangan tingkat logis koresponden, dan peran, yang dimainkan di sana. Selama siklus kerja sistem, agen memanipulasi dengan aliran informasi pendapatan dan hasil yang beragam: protokol transmisi data, pesan, data pendapatan dan hasil, dll. Sumber informasi ini berbeda berdasarkan "waktu hidup": mereka dapat bersifat permanen dan sementara, berdasarkan penilaian level – beberapa dapat digunakan dimodifikasi atau dihapus oleh agen, keputusan tentang yang lain harus diambil oleh pengguna sistem. Jadi, dalam hal ini DPA harus beroperasi sebagai agen perencanaan, di satu sisi, dan harus menyatukan hasil eksekusi agen bawah. Pada bagian selanjutnya kami akan menjelaskan organisasi agen secara rinci.



**Gambar 5.5** Diagram Prometheus interaksi MAS dengan actor

**Tabel 5.1** Peran yang dimainkan dalam MAS

Tingkat logika	Agen utama	Agen bawahannya	Peran
Penggabungan Data	Agen Agregasi Data	Agen Ontologi Domain Agen Fusion Pencemaran Lalu Lintas Agen Fusi Data Air Agen Petroleum Data Fusion Agen Pertambangan Data Fusion Agen Fusion Data Morbiditas Agen Penggabungan Data Limbah	Penggabungan Data

	Agen Pra-pemrosesan Data	Agen normalisasi Agen korelasi Agen Penghalus Data Agen Periksa Kesenjangan dan Artefak	Kliring Data
Penambangan Data	Agen Perkiraan Fungsi	Agen regresi agen ANN Agen GMDH Agen mesin Komite Agen dekomposisi Agen evaluasi	Penilaian Dampak Penguraian Pendekatan Fungsi
Pengambilan Keputusan	Agen Simulasi Komputer	Agen peramalan Lihat agen Agen alarm	Simulasi komputer Pengambilan Keputusan Distribusi Data

## 5.5 DESKRIPSI AGEN DALAM MAS

### Agen Agregasi Data

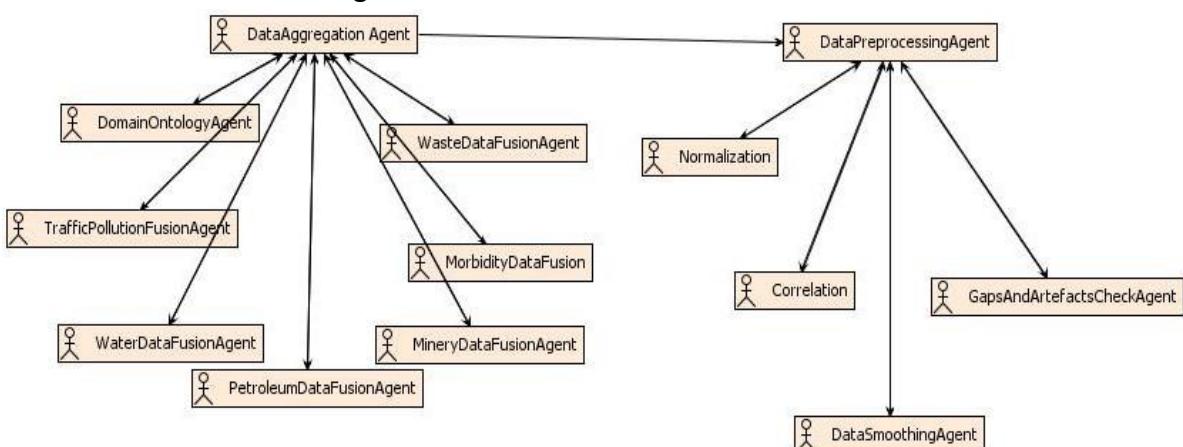
Agen Agregasi Data (DAA) memiliki sejumlah agen bawahan di bawah kendalinya; mereka adalah agen Ontologi Domain (DOA) dan agen fusi: agen Water Data Fusion (WFA), agen Petroleum Data Fusion (PFA), agen Pertambangan Data Fusion (MFA), agen Traffic Pollution Fusion (TFA), agen Penggabungan Data Limbah (WDFA) dan agen Penggabungan Data Morbiditas (MFA). Pertama, DAA mengirimkan pesan ReadOntology ke DOA, yang membaca file OWL, yang berisi informasi tentang ontologi domain, dan membuatnya tersedia untuk DAA. DOA menghentikan eksekusinya, mengirimkan pesan OntologyIsBeingRead ke DAA. Selanjutnya, DAA mengirimkan pesan Mulai Fusion ke agen fusi, yang memulai eksekusi mereka. Saat mulai mengeksekusi, setiap agen fusi mencari file yang mungkin berisi informasi tentang konsep minatnya. Setiap agen fusi bekerja dengan satu atau beberapa konsep ontologi domain: WFA mencari informasi tentang kontaminan air dan sifatnya, PFA – tentang penggunaan minyak bumi dan konsep terkait, MDF mengambil data tentang kontaminasi yang terkait dengan industri pertambangan aktivitas, WDFA mengambil data tentang limbah dan komponennya, TFA – data tentang aktivitas kendaraan pengangkut, dan MFA – data tentang morbiditas dan sifat-sifatnya. Ketika menemukan file informasi, agen mengambil informasi tentang konsep dan nilainya, dan mengubah propertinya (untuk menghilangkan heterogenitas dan untuk menyeragamkan informasi) dan mengirimkannya ke DAA, yang mengumpulkan informasi yang diambil bersama. Akhirnya, DAA mengisi ontologi domain dengan data, dan menempatkan data ke dalam format standar. Setelah itu, file data siap untuk diproses sebelumnya, dan DAA melalui protokol ReturnDF memberi tahu DPA bahwa data telah digabungkan dan pra-pemrosesan dapat dimulai.

### Agen Pra-pemrosesan Data

Agen Pra-pemrosesan Data (DPA) menyediakan pra-pemrosesan data dan memiliki sejumlah agen bawahan yang berspesialisasi dalam berbagai teknik pembersihan data: Agen normalisasi (NA), Agen korelasi (CA), Agen pemulusan Data (DSA), Agen Periksa Kesenjangan

dan Artefak (GAA). Mereka melakukan semua prosedur pra-pemrosesan data, termasuk deteksi outlier dan anomali, menangani nilai yang hilang, pemulusan, normalisasi, dll.

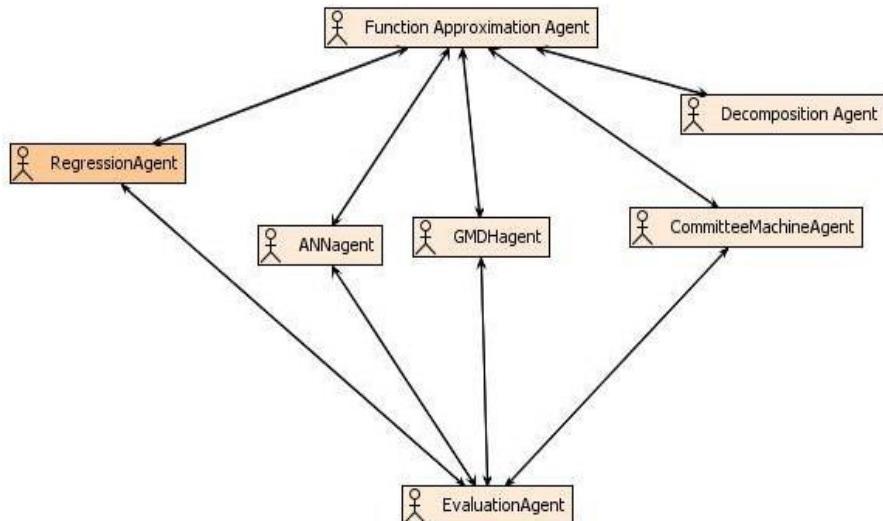
Gambar 6 memberikan tampilan pada level logis pertama, di mana agen Agregasi Data dan agen Pra-pemrosesan Data bertindak. DPA mulai dijalankan segera setelah menerima pesan pemicu dari DAA. Fungsi utama DPA adalah mengoordinasikan agen bawahan dan memutuskan kapan mereka dieksekusi dan dalam urutan apa. Memulai eksekusinya, DPA mengirimkan pesan StartDataConsistenceCheck, yang memicu GAA untuk menghilangkan artefak, mencari nilai ganda, dan mengisi celah. Setelah menyelesaikan eksekusinya, GAA mengirim pesan ke DPA. Kemudian, DPA melalui pesan StartSmoothing memanggil DSA, yang dapat mengeksekusi pemulusan eksponensial dan rata-rata tertimbang dan menghentikan pengiriman pesan SmoothingIs-Finished ke DPA. Kemudian, NA dan CA dipanggil secara bergantian. Hasil kerja DPA adalah: data, siap untuk diproses dan dimodelkan lebih lanjut, dan sumber data tambahan dengan hasil korelasi dan normalisasi.



**Gambar 5.6** Interaksi antara agen Agregasi Data dan agen Pra-pemrosesan Data

### Agen Perkiraan Fungsi

Agen Pendekatan Fungsi (FAA) memiliki tim hierarkis agen bawahan, yang berfungsi untuk mendukung peran: "Penilaian Dampak", "Dekomposisi" dan "Perkiraan Fungsi" (lihat Gambar 7). FAA memiliki di bawah kendalinya sejumlah agen penambangan data: agen Regresi (RA), agen ANN (AA), dan agen GMDH (GMDHA), yang bekerja dalam mode bersamaan, membaca informasi pendapat dan membuat model. Kemudian, jika ada agen dari grup ini yang menyelesaikan pemodelan, ia memanggil agen Evaluasi (EA), yang mengevaluasi model yang diterima, dan mengembalikan daftar model yang diterima. Yang lain dilarang dan dihapus. FAA mengumpulkan hasil kerja agen, membuat daftar dengan model yang diterima dan kemudian, setelah RA, AA dan GMDHA menyelesaikan eksekusi mereka, memanggil agen Mesin Komite (CMA), yang membuat model akhir dalam bentuk komite untuk masing-masing dari variabel dependen, dan menyimpannya.

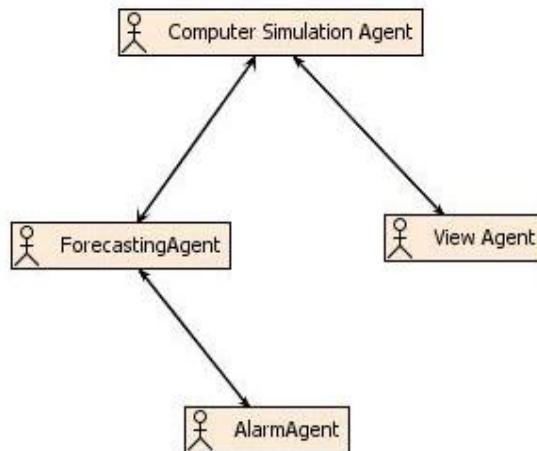


**Gambar 5.7 Agen Perkiraan Fungsi dan timnya**

Siklus kerja FAA adalah sebagai berikut. FAA mengirimkan pesan StartDecomposition dan menunggu sampai DA menyelesaikan eksekusinya. Kemudian, setelah menerima pesan StartDataMining, agen data mining memulai eksekusi dalam mode bersamaan. Masing-masing memiliki rencana dengan alat tertentu, dan dalam kasus AA, ia memiliki rencana NeuralNetwork dan evaluasiImpactAssessment, di mana rencana pertama berorientasi pada pembuatan dan pelatihan jaringan saraf tiruan (JST), dan rencana kedua bertujuan untuk mengevaluasi lingkungan. dampak melalui JST dengan struktur dan karakteristik yang ditentukan. EA dipanggil oleh masing-masing agen data mining untuk mengevaluasi model yang dibuat, dan untuk memeriksa kecukupan model terhadap data eksperimen. EA dipicu oleh pesan StartEvaluation dari agen data mining, dan, setiap kali tidak sibuk, mulai dijalankan. Setelah menghentikan eksekusi, ia siap menerima tugas dan menanganinya. CM adalah yang terakhir dipanggil oleh FAA, karena CM membuat model hibrida akhir untuk setiap variabel dependen. Setiap model hybrid didasarkan pada model yang dibuat dan dievaluasi sebelumnya dari agen data mining, dan menggunakan sumber data yang dibuat oleh mereka: Models Table, IAResults.

#### Agen Simulasi Komputer

Agen Simulasi Komputer (CSA) berinteraksi dengan pengguna dan melakukan serangkaian tugas dalam peran Simulasi Komputer, Pengambilan Keputusan, dan Distribusi Data. Ini memiliki tim agen, yang meliputi agen Peramalan (FA), Agen Alarm (AmA) dan ViewAgent (VA) seperti yang ditaburkan pada Gambar 8.



**Gambar 5.8** Agen Simulasi Komputer dan timnya

Siklus eksekusi CSA dimulai dengan menanyakan preferensi pengguna, lebih tepatnya, untuk informasi penyakit dan polutan yang diinginkan, periode ramalan, dan kisaran perubahan nilainya. Setelah informasi dari pengguna diterima, CSA mengirimkan pesan SimulateAlternative ke FA, yang menjelaskan dan menjalankan salah satu rencana, yaitu Forecasting, ModelSimulation, dan CriterionApplication. Saat alternatif dibuat, CSA mengirimkan pesan StartAlarmCheck ke AmA. AmA membandingkan simulasi dan perkiraan data dari FA dengan tingkat yang diizinkan dan alarm untuk indikator koresponden. Jika melebihi level, AmA menghasilkan peringatan alarm.

## 5.6 HASIL

MAS memiliki arsitektur berbasis agen terbuka, yang memungkinkan penggabungan modul dan alat tambahan dengan mudah, memperbesar sejumlah fungsi sistem. Sistem milik tipe organisasi, di mana setiap agen memperoleh kelas alat dan tahu bagaimana dan kapan menggunakaninya. Sebenarnya, sistem seperti itu memiliki agen perencanaan yang merencanakan perintah eksekusi agen. Dalam kasus kami, modul utama dari program Jack menjalankan fungsi-fungsi ini. View-Agent menampilkan output dari fungsionalitas sistem dan melakukan interaksi dengan pengguna sistem. Karena sistem ini otonom dan semua perhitungan dijalankan olehnya, pengguna hanya memiliki akses ke output hasil dan jendela simulasi. Dia dapat meninjau hasil penilaian dampak, pemodelan dan peramalan dan mencoba mensimulasikan kecenderungan dengan mengubah nilai polutan.

Untuk mengevaluasi dampak parameter lingkungan terhadap kesehatan manusia di wilayah Spanyol Castilla-La Mancha, secara umum, dan di kota Albacete pada khususnya, kami telah mengumpulkan data retrospektif sejak tahun 1989, menggunakan sumber informasi terbuka yang ditawarkan oleh Institut Statistik Spanyol dan oleh Institut Statistik Castilla-La Mancha. Sebagai indikator kesehatan manusia dan faktor-faktor yang mempengaruhi lingkungan, yang dapat menyebabkan efek negatif pada indikator kesehatan manusia yang disebutkan di atas, faktor-faktor yang dijelaskan dalam Tabel 2 diambil.

**Tabel 5.2** Penyakit dan polutan yang diteliti dalam penelitian

Jenis Penyakit/Pencemar	Kelas penyakit
----------------------------	----------------

<b>Penyakit endogen:</b>	Kondisi tertentu yang berasal dari masa prenatal; Malformasi kongenital, deformasi dan kelainan kromosom.
<b>Penyakit eksogen:</b>	Penyakit infeksi dan parasit tertentu; Neoplasma; Penyakit darah dan organ pembentuk darah serta kelainan tertentu yang menyangkut mekanisme kekebalan tubuh; Penyakit endokrin, nutrisi dan metabolisme; Gangguan mental dan perilaku; Penyakit pada sistem saraf; Penyakit mata dan adneksa; Penyakit telinga dan proses mastoid; Penyakit pada sistem peredaran darah; Penyakit pada sistem pernapasan; Penyakit pada sistem pencernaan; Penyakit kulit dan jaringan subkutan; Penyakit pada sistem musculoskeletal dan jaringan ikat; Penyakit pada sistem genitourinari; Kehamilan, persalinan dan nifas; Gejala, tanda dan temuan klinis dan laboratorium abnormal, tidak diklasifikasikan di tempat lain; Penyebab eksternal morbiditas dan mortalitas.
<b>Mengangkat:</b>	Jumlah Lori, Bus, Mobil, Traktor, Sepeda Motor, Lainnya;

MAS telah memulihkan data dari file biasa, yang berisi informasi tentang faktor-faktor yang menarik dan polutan, dan digabungkan sesuai dengan ontologi area masalah. Ini telah mengasumsikan beberapa perubahan yang diperlukan dari properti data (skalabilitas, dll.) dan pra-pemrosesan mereka. Setelah prosedur ini, jumlah polutan yang valid untuk diproses lebih lanjut telah berkurang dari 65 menjadi 52. Perubahan signifikan ini disebabkan oleh banyak blanko yang terkait dengan beberapa deret waktu, karena beberapa faktor mulai dicatat baru-baru ini. Setelah mempertimbangkan ini sebagai kelemahan penting, tidak mungkin untuk memasukkannya ke dalam analisis. Indikator kesehatan manusia, menjadi lebih homogen, telah menyatu dan berhasil dibersihkan.

Penilaian dampak telah menunjukkan ketergantungan antara karakteristik air dan neoplasma, komplikasi kehamilan, persalinan dan malformasi kongenital, deformasi dan kelainan kromosom. Bagian dari Tabel 3 menunjukkan bahwa dalam faktor terpenting selain dari polutan air, terdapat indikator penggunaan minyak bumi, produk hasil tambang dan beberapa jenis limbah.

**Tabel 5.3** Bagian dari tabel dengan keluaran penilaian dampak

Kelas Penyakit	Polutan, yang mempengaruhi penyakit
Neoplasma	Nitrit dalam air; produk penambang; DBO5; Limbah kimia berbahaya; Minyak bakar; Gas cair minyak bumi; Air: padatan dalam suspensi; aspal; Limbah kimia tidak berbahaya;
Penyakit darah dan organ pembentuk darah, mekanisme kekebalan tubuh	DBO5; produk penambang; Minyak bakar; Nitrit dalam air; Limbah berbahaya dari industri kertas; Air: padatan dalam suspensi; Limbah logam berbahaya

Kehamilan, persalinan dan nifas	Minyak tanah; Minyak bumi; mobil minyak bumi; Gas cair minyak bumi; bensin; Minyak bakar; aspal; Air: DQO; DBO5; Padatan dalam suspensi; Nitrit.
Kondisi tertentu yang berasal dari periode prenatal	Limbah tidak berbahaya: limbah umum; mineral, penyempitan, tekstil, organik, logam. Limbah minyak berbahaya.
Malformasi kongenital, deformasi dan kelainan kromosom	bensin; Minyak bakar; DQO dalam air; Memproduksi aspal; Minyak bumi; mobil minyak bumi; Minyak tanah; Gas cair minyak bumi; DBO5 dalam air; Padatan dalam suspensi dan Nitrit.

---

MAS memiliki berbagai metode dan alat untuk pemodelan, termasuk regresi, jaringan saraf, GMDH, dan model hibrida. Agen pendekatan fungsi memilih model terbaik, yaitu: regresi sederhana – 4381 model; regresi berganda – 24 model; jaringan saraf – 1329 model; GMDH – 2435 model. Model yang dipilih dimasukkan ke dalam mesin panitia. Kami telah memperkirakan penyakit dan nilai polutan untuk periode empat tahun, dengan langkah enam bulan, dan memvisualisasikan kecenderungan mereka, yang, secara umum, dan sesuai dengan model yang dibuat, akan mengatasi tingkat kritis. Pengendalian faktor-faktor “signifikan” yang berdampak pada indikator kesehatan dapat menyebabkan penurunan beberapa jenis penyakit.

Akibatnya, MAS menyediakan semua langkah yang diperlukan untuk prosedur pengambilan keputusan standar dengan menggunakan agen komputasi cerdas. Tingkat arsitektur sistem, terhubung secara logis dan fungsional, telah disajikan. Interaksi waktu nyata dengan pengguna memberikan berbagai kemungkinan dalam memilih satu tindakan dari beberapa alternatif, yang dihasilkan oleh sistem melalui penambangan data terpandu dan simulasi komputer. Sistem ini ditujukan untuk penggunaan reguler untuk manajemen yang memadai dan efektif oleh otoritas pemerintah kota dan negara bagian yang bertanggung jawab.

Kami juga menggunakan teknik penambangan data tradisional, seperti metode hibrida dan spesifik lainnya, sehubungan dengan sifat data (data tidak lengkap, kumpulan data pendek, dll.). Kombinasi alat yang berbeda memungkinkan kami untuk mendapatkan kualitas dan presisi model yang dicapai, dan, karenanya, dalam rekomendasi, yang didasarkan pada model ini. Ketergantungan yang diterima dari interkoneksi dan asosiasi antara faktor dan variabel dependen membantu memperbaiki rekomendasi dan menghindari kesalahan. Untuk menyimpulkan, perlu tentang rencana masa depan kita mengenai pekerjaan. Karena pekerjaan tampaknya sangat memakan waktu selama pemodelan, kami berharap untuk merevisi dan meningkatkan sistem dan memperdalam penelitian kami. Ketiga, kami mempertimbangkan untuk membuat lebih banyak eksperimen dengan memvariasikan keseluruhan struktur data dan mencoba menerapkan sistem ke bidang aplikasi lain yang serupa.

## 5.7 KESIMPULAN

Pengambilan keputusan berbasis agen adalah masalah yang rumit, terutama untuk masalah umum seperti dampak lingkungan terhadap kesehatan manusia. Meskipun menganggapnya sebagai masalah yang dapat diselesaikan, kita harus mencatat beberapa keuntungan penting yang telah kita capai, dan beberapa arahan untuk penelitian masa depan. Akibatnya, pekerjaan masa depan kita dapat ditarik pada berbagai tingkatan.

1. Pertama, MAS mendukung pengambil keputusan dalam memilih garis perilaku (set tindakan) dalam kasus umum, yang berpotensi sulit untuk dianalisis dan diramalkan. Adapun sistem yang kompleks, MAS memungkinkan prediksi pola, dan pilihan pembuat keputusan harus menentukan. Kerangka kerja yang kami buat menyediakan alur kerja untuk pembuatan keputusan, menerima data mentah yang diolah oleh tim agen, dan mengubahnya menjadi pengetahuan.
2. Kedua, terlepas dari pekerjaan pemodelan yang memakan waktu, kami berharap untuk merevisi dan meningkatkan sistem dan memperdalam penelitian kami. Kami berencana untuk menyempurnakan metode penambangan data dan memodifikasi beberapa di antaranya, untuk menambahkan beberapa metode baru, yang dapat sangat berharga untuk pekerjaan beton, misalnya, beberapa metode untuk bekerja dengan informasi kualitatif, metode berbasis fuzzy, metode pengurangan dimensi, dll.
3. Ketiga, karena arsitektur sistem memiliki struktur umum, kami mempertimbangkan untuk membuat lebih banyak eksperimen dengan memvariasikan struktur data, dan mencoba menerapkan sistem ke bidang aplikasi lain.

## BAB 6

### PENDEKATAN DUKUNGAN KEPUTUSAN MULTI-KRITERIA UNTUK ENERGI PEDESAAN BERKELANJUTAN DI NEGARA BERKEMBANG

Banyak model telah dikembangkan untuk membantu dalam proses pengambilan keputusan untuk mengidentifikasi opsi penyediaan energi yang paling sesuai untuk komunitas atau area tertentu. Beberapa model hanya berfokus pada satu aspek perencanaan utama, seperti biaya atau teknologi (analisis keputusan kriteria tunggal), sementara model lain mempertimbangkan beberapa kriteria, seperti biaya dan teknologi, faktor sosial, manusia dan lingkungan (analisis multi-kriteria). Bab ini bertujuan untuk menunjukkan bahwa dimasukkannya beberapa kriteria teknis dan non-teknis dapat menghasilkan hasil pembangunan yang lebih berkelanjutan. Untuk melakukannya, ini memberikan perbandingan antara beberapa model faktor tunggal dan multi-kriteria, menyoroti aplikasi dan keterbatasan mereka dalam konteks perencanaan energi pedesaan di negara-negara berkembang. Ini diikuti dengan diskusi tentang faktor-faktor yang harus dipertimbangkan untuk memastikan penyediaan layanan yang optimal, keberlanjutan jangka panjang dari proyek-proyek elektrifikasi pedesaan dan pengentasan kemiskinan. Bagian selanjutnya memperkenalkan dan menganalisis komponen pendekatan dan metodologi Sistem Pendukung Keputusan Energi Pedesaan Berkelanjutan (SURE-DSS). Kebaruan alat SURE terletak pada tujuannya untuk mencocokkan kebutuhan energi masyarakat pedesaan di negara berkembang dengan teknologi yang sesuai dan dengan demikian meningkatkan mata pencaharian dan keberlanjutan proyek. Bab ini menjelaskan pendekatan dan mengilustrasikan aplikasi alat ini melalui studi kasus di Kolombia.

#### **6.1 PENDAHULUAN**

Akses ke listrik masih terbatas meskipun perluasan jaringan listrik skala besar yang substansial terjadi selama tahun 1960-an hingga 1980-an di negara-negara berkembang. Sebagian besar dari sekitar 1,6 miliar orang (Bank Dunia, 2006) yang tidak memiliki akses listrik berada di daerah pedesaan di negara berkembang (Sebitosi dan Pillay, 2005). Sementara off-grid, khususnya terbarukan, teknologi energi seringkali merupakan satu-satunya pilihan yang layak untuk lokasi terpencil, banyak instalasi di daerah pedesaan telah berhenti berfungsi pada akhir siklus proyek (Cherni et al., 2007). Sejumlah faktor telah menyebabkan kegagalan tersebut, termasuk informasi teknis yang tidak memadai, kurangnya sumber daya keuangan yang berkelanjutan, dan keterbatasan kapasitas di tingkat lokal untuk memelihara peralatan. Untuk tingkat yang signifikan, kegagalan ini berasal dari pemilihan teknologi energi yang tepat yang tidak sesuai.

Terlalu sering, kriteria finansial dan teknis mendominasi pilihan teknologi energi dengan mengorbankan kerangka kerja pengembangan energi yang lebih komprehensif dan berkelanjutan (lihat, misalnya, Roseland, 2000; Huang et al. 1995; Srivastava dan Rehman, 2006). Jika penyediaan energi hanya didasarkan pada parameter teknis dan finansial, solusi-solusi tersebut mungkin terbukti tidak berkelanjutan dan karenanya hanya memberikan

sedikit dukungan dalam hal pengurangan kemiskinan (Cherni et al., 2007). Pertukaran pendekatan kriteria tunggal untuk perencanaan energi menyiratkan bahwa perbaikan dalam satu aset masyarakat (misalnya, teknologi) dapat dicapai dengan mengorbankan aset lain (misalnya, lingkungan) (Pohekar dan Ramachandran, 2004). Kekhawatiran dan keterbatasan ini telah memotivasi desain sistem pendukung keputusan multi-kriteria (SURE-DSS) yang disajikan di sini. Tujuan model ini adalah untuk mengidentifikasi dan mempromosikan solusi energi yang efektif dan berkelanjutan melalui pertimbangan dimensi teknis dan non-teknis infrastruktur pedesaan melalui penerapan metodologi multi-kriteria dan mekanisme jaminan internal yang bertujuan untuk meningkatkan proses pengambilan keputusan.

Sampai saat ini, sejumlah besar model optimasi energi tunggal dan multi-kriteria telah dikembangkan untuk membantu pengambilan keputusan untuk aplikasi energi modern di tingkat nasional, regional atau lokal, termasuk elektrifikasi daerah pedesaan di negara berkembang. Pendekatan optimasi kriteria tunggal yang diterapkan pada skema energi pedesaan telah dijelaskan oleh Løken (2007), Georgopoulou et al. (1997), Kablan (1997), dan Pelet et al. (2005). Kelemahan utama dari pengambilan keputusan dengan kriteria tunggal adalah bahwa kondisi fisik dan sosial ekonomi dari calon pengguna teknologi dapat diabaikan (Nigim et al, 2004; Huang et al, 1995). Demikian pula, berbagai bentuk konseptualisasi dan kerangka kerja multi-kriteria telah digunakan untuk perencanaan prioritas alternatif pasokan energi di daerah terpencil, termasuk model yang mempertimbangkan dampak lingkungan (Huang et al, 1995; Kablan, 1997; Beccalli et al, 1998; Hobbs). dan Meier, 2000; Mladineo dkk., 1987; Georgopoulou dkk, 2003). Mereka juga terdiri dari optimasi multi-kriteria dan simulasi sistem pendukung keputusan seperti LEAP (Long Range Energy Alternatives Planning), MARKAL (MARKet ALlocation) dan HOMER.

Sementara alat keputusan ini sangat penting untuk mendukung pengembangan sistem tenaga off-grid dan interkoneksi, bab ini berpendapat bahwa keterbatasan penting masih tetap ada dalam kaitannya dengan i. skala geografis aplikasi; ii. partisipasi masyarakat pedesaan dalam pengambilan keputusan (Beer dan Swanepole, 1994; Sebitosi dan Pillay, 2005); iii. aku aku aku. sejumlah kecil dimensi keberlanjutan yang dicakup (Limmeechokchaia dan Chawana, 2007); iv. replikasi solusi yang sama (Roseland, 2000); dan, secara signifikan, v. dampak keseluruhan energi modern terhadap mata pencaharian masyarakat. Selanjutnya, ada pengakuan bahwa sementara penyediaan energi modern dapat memfasilitasi pembangunan, hal itu mungkin juga berdampak negatif pada lingkungan atau menguras sumber daya keuangan yang langka, yang semuanya dapat dikurangi jika solusi teknologi dipilih dengan lebih hati-hati. Masalah-masalah ini dipertimbangkan di bawah ini.

Bagian pertama dari bab ini menyoroti perbedaan antara pendekatan tunggal dan multi-kriteria – memberikan pertimbangan yang lebih luas untuk yang terakhir – dalam konteks perencanaan energi pedesaan yang berkelanjutan di negara-negara berkembang. Untuk menjelaskan pendekatan multi-kriteria dalam pengambilan keputusan, diskusi ini diikuti dengan presentasi singkat dari beberapa model yang telah ditetapkan. Bab ini kemudian melihat model SURE-DSS secara rinci dan melaporkan hasil penerapan SURE-DSS di komunitas pedesaan Kolombia yang terpencil di mana total kebutuhan energi dipenuhi hanya sebagian melalui generator diesel.

## 6.2 MEMBANDINGKAN SISTEM PENDUKUNG KEPUTUSAN ENERGI SINGLE DAN MULTIKRITERIA

Dua pendekatan utama dapat dibedakan dalam pengambilan keputusan energi, metode kriteria tunggal dan multi kriteria. Bagian ini merangkum karakteristik utama dari metodologi ini.

Model kriteria tunggal mempertimbangkan satu aspek perencanaan utama saja, seperti biaya atau teknologi, dan telah digunakan secara luas dalam pengembangan skema energi pedesaan (misalnya, Løken, 2007; Georgopoulou et al., 1997; Kablan, 1997; Pelet et al., 2005). Kelemahan utama pengambilan keputusan dengan kriteria tunggal adalah kondisi fisik, sosial ekonomi, dan/atau lingkungan calon pengguna teknologi diabaikan (Nigim et al, 2004; Huang et al, 1995). Seringkali, perbaikan dalam satu aset dapat menyebabkan kerusakan aset lain (Pohekar dan Ramachandran, 2004). Misalnya, ketika pertimbangan teknologi dan ekonomi mendominasi selama perluasan layanan (Mirasgedis dan Diakoulaki, 1997; Georgopoulou et al., 1997), pertimbangan seperti potensi pendapatan dan pengaruhnya terhadap lingkungan sering diabaikan (seperti yang diamati selama elektrifikasi pedesaan di 1960-an hingga 1980-an).

RET Finance dan e-analisis adalah dua contoh DSS kriteria tunggal yang telah digunakan untuk menganalisis biaya proyek energi yang diusulkan. Keduanya dikembangkan oleh Laboratorium Energi Terbarukan Nasional AS (NREL). Model Keuangan Teknologi Energi Terbarukan (RET Finance) adalah model pembiayaan teknologi energi terbarukan (RET) yang digunakan untuk menghitung biaya energi RET seperti biomassa, panas bumi, surya, dan angin. Ini adalah model biaya energi yang diratakan yang mensimulasikan arus kas nominal dolar 20 tahun yang terperinci untuk proyek-proyek energi terbarukan, termasuk pendapatan, arus kas, dan pembayaran utang untuk menghitung biaya listrik proyek, nominal setelah pajak. Tingkat Pengembalian, dan Rasio Hutang-Layanan-Cakupan-tahunan. Model e-analisis memungkinkan perencana untuk melakukan penilaian opsi nyata dari penelitian dan pengembangan energi terbarukan (R&D) dan aset pembangkitan terdistribusi (NREL).

Jika penyediaan layanan energi ditangani hanya dari perspektif teknis atau keuangan, dan perencana mengabaikan untuk mempertimbangkan kerangka kerja konseptual pengembangan energi berkelanjutan yang lebih mencakup (lihat, misalnya, Roseland, 2000; Huang et al. 1995; Srivastava dan Rehman, 2006) , solusi cenderung tetap tidak berkelanjutan dan karenanya memberikan sedikit dukungan untuk pengurangan kemiskinan (Cherni et al., 2005; 2007). Namun, perlu ditekankan bahwa model ini dapat sangat berguna jika diterapkan untuk tujuan yang sangat spesifik, atau jika dilengkapi dengan alat tambahan.

Pendekatan kedua, analisis keputusan multi-kriteria (MCDA), menyediakan kerangka kerja untuk penilaian berbagai alternatif dan dengan demikian mempertimbangkan lebih dari satu aspek perencanaan dalam desain kebijakan dan proyek pembangunan. Meningkatnya kebutuhan untuk memasukkan pertimbangan lingkungan ke dalam perencanaan energi pada 1980-an mempercepat penggunaan pendekatan multi-kriteria (Georgopoulou et al., 1997). Analisis multi-kriteria berguna dan perlu, karena penentuan prioritas pilihan pembangkit listrik merupakan masalah multi-aspek yang memerlukan pertimbangan faktor kualitatif dan kuantitatif, serta teknis dan non-teknis. Dalam mendekati perencanaan penyediaan energi di daerah pedesaan, alat dan metode penilaian konvensional umumnya menekankan tiga aspek

pengambilan keputusan utama, yang dapat diklasifikasikan sebagai pendekatan teknologi, ekonomi, sosial dan lingkungan (Cherni et al., 2007).

Tujuan utama dari kategori teknologi adalah untuk memaksimalkan pasokan energi. Analisis berbagai faktor teknologi dapat mempertimbangkan jenis solusi energi yang diusulkan (teknologi energi konvensional dan/atau terbarukan); efisiensi dan kesesuaian dalam memenuhi kebutuhan energi (Georgopoulou et al., 1997); kematangan teknologi energi yang dipertimbangkan (Beccali et al., 1998); penerapannya (Georgopoulou et al., 2003); ketergantungannya pada bahan bakar fosil (Kablan, 1997) dan ketersediaan sumber daya bahan bakar yang dibutuhkan (Borroto et al., 1998); dan kerugian dan ketidakpastian yang terkait dengan proses konstruksi fasilitas pembangkit listrik (Angel y Smith, 2000), antara lain. Kriteria teknis tambahan yang dipertimbangkan mungkin adalah keadaan teknologi dalam hal aplikasi dan kondisi di mana mereka digunakan; sumber daya teknis suatu lokasi, seperti kecepatan angin, radiasi matahari, dan ketersediaan biomassa; karakteristik operasi, termasuk kapasitas lokal untuk mengoperasikan dan memelihara sistem; dan tingkat replikasi lokal (Biswas et al., 2001). Contoh model yang berpusat pada teknologi adalah Model Simulasi Sistem Tenaga Hibrida (Hybrid2). Alat ini dikembangkan oleh Renewable Energy Research Laboratory (RERL) di University of Massachusetts di Amherst, mensimulasikan kinerja berbagai hibrida angin, fotovoltaik, dan diesel, dan memberikan perbandingan kinerja jangka panjang dari sistem serupa. Hybrid2 dapat digunakan untuk melakukan kinerja jangka panjang yang terperinci dan analisis ekonomi pada berbagai macam sistem tenaga hibrida.

Sebaliknya, tujuan utama dari pendekatan ekonomi adalah untuk meminimalkan biaya keuangan yang terkait dengan proyek energi (misalnya, Smith et al., 2000; Georgopoulou et al., 1997; Koroneos et al., 2005). Indikator yang digunakan dalam analisis ekonomi dapat mencakup: biaya investasi (Kablanc, 1997); biaya per unit baik instalasi maupun pembangkitan (Angel dan Smith, 2000; Polatidis dan Haralambopoulos, 2002); biaya operasi dan pemeliharaan (Watson dan Ter-Gazarian, 1999); biaya bahan bakar (Kolhe et al., 2002) dan biaya sumber daya yang tersedia (Kablan, 1997); tingkat pengembalian internal (Angel dan Smith, 2000); biaya pengurangan emisi gas rumah kaca (Georgopoulou et al., 1997, 2003) – atau kredit; penciptaan lapangan kerja yang disebabkan oleh proyek (Borroto et al., 1998); dan lain-lain (Cherni et al., 2007). Misalnya, model yang dikembangkan oleh Biswas et al. termasuk kondisi bahwa RET layak secara finansial dan berkelanjutan melalui peningkatan pendapatan rumah tangga dan pemantauan lanjutan serta layanan pemeliharaan di tempat (2001).

Contoh ilustratif dari model yang bertujuan untuk meminimalkan biaya keseluruhan adalah VIPOR. VIPOR adalah alat komputasi yang mampu merancang sistem elektrifikasi desa otonom menggunakan kombinasi biaya terendah dari pembangkitan terpusat dan terisolasi. Berdasarkan informasi tentang medan setempat, tata letak dan ukuran desa, ukuran beban dan biaya peralatan, model menentukan rumah mana yang harus diberi daya oleh sistem tenaga terisolasi (misalnya, sistem rumah surya) dan mana yang harus dimasukkan dalam jaringan distribusi terpusat. Contoh lain adalah Energy10, yang telah dirancang oleh NREL untuk mengidentifikasi kombinasi yang paling hemat biaya dari strategi efisiensi energi dan langkah-langkah penghematan energi untuk bangunan komersial dan perumahan kecil,

seperti pencahayaan siang hari, pemanas matahari pasif, dan mekanik efisiensi tinggi. sistem (NREL).

Fokus pendekatan sosial adalah untuk memaksimalkan dampak kesejahteraan (Beccali et al., 1998). Misalnya, Georgopoulou et al., (1997) menganggap kriteria sosial sebagai tujuan makro yang 50% politis (misalnya, kohesi antara kegiatan lokal dan pekerjaan regional) dan 50% lingkungan (misalnya, kualitas udara, kebisingan, kemudahan visual, diantara yang lain). Boroto dkk. (1998) menyarankan bahwa kriteria sosial harus ditarik pada kendala yang sebenarnya, seperti pencapaian permintaan energi pedesaan tahunan. Kriteria khusus dapat mencakup kesetaraan sosial dan kesesuaian budaya, penciptaan lapangan kerja, dan pengembangan kapasitas kelembagaan (termasuk kebijakan penetapan harga energi yang memungkinkan dan sistem pajak, undang-undang dan standar produk energi) (Biswas et al., 2001).

Fokus utama dari pendekatan lingkungan, di sisi lain, adalah upaya untuk mengurangi kerusakan lingkungan yang diantisipasi (Mirasgedis dan Diakoulaki, 1997; Georgopoulou et al., 2003, Huang et al, 1995; Kablan, 1997; Beccalli et al. , 1998; Hobbs dan Meier, 2000; Mladineo et al., 1987; 2003). Cherni dkk. tunjukkan bahwa beberapa model DSS menggunakan indeks untuk memperhitungkan dampak lingkungan, seperti emisi gas rumah kaca (Beccali et al., 1998; Borroto et al., 1998; Georgopoulou et al., 2003) atau indeks deforestasi (Kablan, 1997) ; indeks luas lahan minimum yang dibutuhkan oleh teknologi energi tertentu (Beccali et al., 1998; Georgopoulou et al., 1997); tingkat kebisingan (Georgopoulou et al., 1997), air, udara, dan indeks kualitas tanah, antara lain (2007).

Selain alat-alat tersebut di atas, Jebaraj dan Iniyan memberikan deskripsi rinci tentang sejumlah model perencanaan energi, pasokan-permintaan, peramalan dan optimasi yang lebih terintegrasi (2006). Studi kasus untuk model DSS ini sebagian besar terletak di India dan mewakili berbagai skala, yaitu, tingkat pertanian/rumah tangga, kelompok rumah tangga, dan regional. Selain melihat kriteria teknis, ekonomi atau lingkungan, penulis membedakan jenis model berikut: perencanaan energi, pasokan-permintaan energi, peramalan, energi terbarukan, pengurangan emisi, dan model optimasi (2006). Dalam analisisnya tentang sistem pendukung keputusan perencanaan energi (DSS), Løken membagi model MCDA menjadi tiga kategori berbeda: model pengukuran nilai; model tujuan, aspirasi dan tingkat referensi; dan model outranking (2007).

Selain pertimbangan yang cermat dari beberapa kriteria, penerapan DSS juga sangat bergantung pada skala yang digunakan dan tingkat agregasi data. Ini perlu dicocokkan dengan hati-hati dengan jenis dan ukuran proyek. Biasanya, perencanaan energi dilakukan pada tingkat berikut: rumah tangga, desa; daerah; Nasional; dan internasional. Contoh model skala regional adalah Model Perencanaan Sistem Energi Cluster Kota (CCEM), yang dapat diterapkan ke beberapa kota dalam suatu wilayah. Model memperhitungkan emisi lingkungan, pilihan teknologi, pertimbangan kebijakan, biaya, demografi, lingkungan dan sosiologi. CCEM digunakan di Wilayah Toronto-Niagara untuk 'mengoptimalkan' produksi energi berdasarkan strategi berbiaya paling rendah, menilai emisi lingkungan berdasarkan sumbernya, dan mengeksplorasi konsekuensi ekonomi dan lingkungan dari berbagai kebijakan (Lin et al., 2009).

Pendekatan multi-kriteria untuk perencanaan energi belum mengatasi sejumlah keterbatasan. Misalnya, pengambilan keputusan kebijakan masih cenderung mengutamakan kriteria teknis dan informasi kuantitatif, yaitu output daya dan biaya. Dengan demikian, fitur teknis dari ekspansi teknologi cenderung mendominasi model dan pikiran para membuat keputusan daripada prioritas valid lainnya, seperti kesejahteraan sosial. Setelah meninjau karakteristik utama pendekatan kriteria tunggal dan multikriteria, bab ini sekarang membahas beberapa model energi spesifik untuk menggambarkan kemungkinan penerapannya.

### **6.3 JANGKAUAN DAN KETERBATASAN ENERGI MULTI-KRITERIA DSS**

Analisis multi-kriteria telah digunakan untuk mendukung pengambilan keputusan dalam konteks penyediaan energi pedesaan di negara berkembang dengan tujuan untuk menggantikan teknologi yang ada (misalnya, pembakaran kayu untuk pemanasan dan memasak), atau untuk menerapkan yang baru (lihat misalnya. Huang et al., 1995; Kablan, 1997; Beccali et al., 1998; Watson dan Ter-Gazarian, 1996; Hobbs dan Meier, 2000) sambil mengurangi dampak lingkungan (Georgopoulou et al., 2003; Borroto et al., 1998 ).

Bagian ini menganalisis model perencanaan energi multi-kriteria tertentu, memberikan contoh penerapannya dan menyoroti kekuatan dan keterbatasannya. Ini tidak dimaksudkan sebagai ringkasan yang komprehensif, melainkan ilustrasi sejauh mana beberapa model yang sering digunakan dapat merujuk pada kriteria yang dibahas di atas. Setiap deskripsi mencakup nama model, metodologi yang mendasarinya, dan, jika tersedia, contoh penerapan praktisnya. HOMER, model pengoptimalan yang diterapkan secara luas yang dikembangkan oleh Laboratorium Energi Terbarukan Nasional AS (NREL, 2003), membantu dalam evaluasi distribusi daya untuk aplikasi pembangkitan off-grid, remote, stand-alone dan sistem yang terhubung ke jaringan. Ini adalah alat yang berguna dan telah digunakan di sejumlah negara berkembang dengan hasil yang baik. Namun, HOMER menilai hasil berdasarkan dua kriteria saja, manfaat ekonomi dan teknisnya, dan sementara ini adalah aspek penting dari sistem energi off-grid, model tersebut belum dirancang untuk mengevaluasi dampak signifikan seperti sosial dan lingkungan.

Long Range Energy Alternatives Planning (LEAP) juga merupakan alat pemodelan energi-lingkungan berbasis skenario. Skenario yang dipertimbangkan didasarkan pada perhitungan komprehensif tentang bagaimana energi diproduksi, dikonversi, dan dikonsumsi di wilayah atau ekonomi tertentu di bawah berbagai asumsi alternatif tentang populasi, perkembangan ekonomi, teknologi, dan harga. Berbeda dengan HOMER, LEAP telah diterapkan di beberapa tingkat spasial termasuk daerah pedesaan lokal, kota metropolitan besar, dan di tingkat nasional, regional dan global (SEI).

MARKAL (Alokasi MARKet) adalah alat pemrograman linier mapan yang meminimalkan biaya penyediaan di bawah beberapa kendala, termasuk permintaan energi; telah digunakan terutama dalam konteks pengembangan listrik skala besar (Cherni et al. (2007). Model ini mengintegrasikan faktor energi, lingkungan, dan ekonomi untuk menginformasikan kebijakan energi dan untuk mendukung pengambilan keputusan perencanaan energi nasional. MARKAL mengusulkan satu set pilihan teknologi yang meminimalkan biaya, sekaligus memenuhi permintaan konsumen dan mempertimbangkan dampak lingkungan (BNL).

ELECTRE adalah metodologi lain yang banyak digunakan yang dikembangkan oleh Bernard Roy pada 1970-an dan menerapkan pendekatan outranking dengan ambang batas tertentu untuk memecahkan masalah kehidupan nyata (Roy, 1991). Baru-baru ini, ELECTRE telah disesuaikan dengan perencanaan energi. Misalnya, Beccali et al. merancang model berdasarkan ELECTRE untuk menganalisis opsi penyebaran RET di tingkat regional. Metodologi multi-kriteria yang digunakan oleh model mereka memungkinkan pengambil keputusan untuk menilai berbagai pilihan energi inovatif dan memilih rangkaian yang paling tepat berdasarkan tujuan yang telah ditentukan sebelumnya (2003). Model tambahan dikembangkan dengan tujuan untuk membantu pengambilan keputusan dalam situasi perencanaan energi yang agak spesifik, misalnya, pemantauan penggunaan energi rumah tangga (SAVE, lihat Boonekam, 1997; FACE, lihat Messner dan Strubegger, 1987; Lutzenhiser, 1992; Reddy, 1995 ; PERKIRAAN, FORCEE, lihat Kimmims, 1997).

Akhirnya, sejumlah model berdasarkan sistem energi terbarukan terintegrasi (IRES) dikembangkan dan diterapkan pada upaya elektrifikasi pedesaan di India, Nepal dan Bangladesh (Akella et al., 2007). Model tersebut membantu menentukan opsi energi terbarukan yang paling tepat – atau kombinasi dari berbagai RET – untuk aplikasi rumah tangga dan komunitas tertentu di daerah pedesaan ini. Baru-baru ini, Terrados et al. mengusulkan metodologi "hibrida" untuk perencanaan energi terbarukan di tingkat regional berdasarkan pembelajaran dari model analisis keputusan multikriteria yang ada, analisis Kekuatan-Kelemahan-Peluang-Ancaman (SWOT), dan pendapat ahli metode "Delphi". Model mengusulkan langkah-langkah berikut: "1) Diagnosis awal sistem energi regional; 2) Konfigurasi diagnosis sebagai matriks SWOT; 3) Pemilihan strategi awal melalui analisis SWOT; 4) Validasi dan penilaian strategi melalui pendapat ahli; 5) Pemeringkatan alternatif yang menerapkan MCDA; 6) Analisis rencana referensi; dan 7) Pemilihan strategi akhir dan penetapan target" (2009). Pendekatan SWOT, sebagai metodologi SURE-DSS, memerlukan proses berulang yang menggabungkan pendapat para ahli di berbagai tahap. Tabel 1 memberikan perbandingan model yang disebutkan di atas dalam hal kriteria penentuannya.

Sementara alat-alat ini telah memenuhi peran dalam mendukung keputusan untuk mempromosikan sistem tenaga off-grid dan interkoneksi, keterbatasan tetap ada dalam hal skala penerapannya, yaitu, ini mungkin terlalu luas atau terlalu spesifik, terbatas pada keterlibatan masyarakat dalam pengambilan keputusan (Beer dan Swanepole, 1994; Sebitosi dan Pillay, 2005), pertimbangan yang buruk dari isu-isu keberlanjutan, dan kemungkinan replikabilitas solusi terlalu tipis (Roseland, 2000; TERI, 2003).

**Tabel 6.1** Kriteria analitik utama yang ditemukan dalam model perencanaan energi tertentu

<b>Model</b>	<b>Kriteria</b>					
	<b>Ekonomis</b>	<b>Teknis</b>	<b>Sosial</b>	<b>Manusi a</b>	<b>Lingkungan</b>	<b>Timbanga n) *</b>
<b>Model kriteria tunggal</b>						
Keuangan RET	ü					
analisis elektronik	ü					

<b>Model multi-kriteria</b>						
HOMER	ü	ü				H?, V, R
Hibrida2	ü	ü				
VIPOR	ü	ü				V
Energi10	ü	ü				H
MELOMPAT	ü	ü			ü	V, R, N
IRES	ü	ü	ü	ü		
Biswas dkk.	ü	ü	ü	?	ü	
MARKAL	ü	ü			ü	N
IRES	ü	ü				
LISTRIK	ü	ü	?			R
CCEM	ü	ü	ü	ü	ü	R
SWOT & Delphi	ü	ü				R

\* Timbangan: H – rumah tangga; V – desa; R – wilayah; N – nasional; I – internasional

Selain itu, metode multi-kriteria sejauh ini gagal mengukur secara memadai keberlanjutan opsi energi, yaitu, kemungkinan peningkatan aset masyarakat dalam jangka panjang yang dihasilkan dari penerapan teknologi yang dipilih secara efektif. Akibatnya, solusi yang diterapkan sebagian besar mengabaikan masalah keberlanjutan dan pengurangan kemiskinan (Cherni et al., 2007).

Seperti disebutkan di atas, kegagalan sistem energi pedesaan off-grid yang terpasang sebagian besar dapat ditelusuri ke keputusan baik berdasarkan kriteria politik, keuangan dan lingkungan, tetapi tanpa pertimbangan yang memadai untuk keberlanjutan keseluruhan pembangunan infrastruktur (lihat, misalnya, Roseland, 2000 ; Polatidis dan Haralambopoulos, 2002; Huang et al 1995; Omer, 2006; Srivastava dan Rehman, 2006) atau preferensi komunitas dan kebutuhan yang diungkapkan (lihat, misalnya, Beer dan Swanepole, 1994; Sebitosi dan Pillay, 2005).

Demikian pula, Santos dan Linares mencatat bahwa faktor penting dalam kegagalan penyediaan proyek teknologi energi yang efektif adalah kegagalan untuk mengidentifikasi secara eksplisit keinginan, kebutuhan, dan kekuatan pengguna sasaran (2003). Faktanya, metode saat ini sering memungkinkan populasi untuk berpartisipasi hanya setelah para ahli membuat keputusan teknis. Namun, telah diklaim bahwa itu diinginkan, jika tidak penting, baik untuk perencanaan dan penilaian untuk mendorong partisipasi dari mereka yang intervensi energi yang diberikan akan mempengaruhi sebagian besar, individu pedesaan dan rumah tangga (lihat Bannister, 2002; Barnes, 2000; Barnett, 2000).

Namun, para ahli energi pedesaan semakin menyadari bahwa agar berhasil, proyek energi harus melibatkan masyarakat lokal sejak awal, memprioritaskan masukan mereka dan memanfaatkan minat, dukungan, dan investasi mereka (misalnya, Kartha dan Leach, 2001). Ini adalah kemajuan yang cukup besar dibandingkan dengan pendekatan teknokratis murni dari dekade sebelumnya. Metode partisipatif bertujuan untuk belajar dari individu pedesaan  
*Sistem Pendukung Keputusan (Dr Joseph Teguh Santoso dan Budi Hartono, M.Kom)*

tentang status quo dalam komunitas mereka dan bagaimana keberadaan mereka dapat ditingkatkan melalui bantuan eksternal. Kekhawatiran ini dan keterbatasan pendekatan yang ada telah memotivasi desain pendekatan dan metodologi pendukung keputusan SURE-DSS (Sustainable Renewable Energy Decision Support System) untuk mempromosikan solusi energi yang efektif dan berkelanjutan, menggabungkan kriteria teknis dan non-teknis untuk pengembangan infrastruktur pedesaan, untuk merancang metode partisipatif dan memasukkan mekanisme jaminan bawaan untuk meningkatkan proses pengambilan keputusan.

#### **6.4 SURE-DSS: PENDEKATAN DAN APLIKASI MULTI-KRITERIA YANG KOMPREHENSIF**

Meskipun ada pengakuan bahwa energi modern dapat memfasilitasi pembangunan, dan dapat menjadi sangat penting untuk pencapaian Tujuan Pembangunan Milenium (MDG) (DFID, 2002), beberapa teknologi energi mungkin juga memiliki dampak negatif terhadap lingkungan atau menguras energi yang sudah ada. sumber keuangan yang langka. Dengan mempertimbangkan berbagai faktor yang lebih luas dan potensi dampak positif dan negatif, pendekatan multi-kriteria lebih siap dalam pemilihan teknologi dengan jejak ekologis yang lebih ramah atau dampak sosial-ekonomi yang kurang merugikan. Namun, pemilihan teknologi untuk memasok energi bagi kaum miskin pedesaan di negara-negara berkembang untuk meningkatkan mata pencaharian mereka merupakan kegiatan yang sangat kompleks. Sistem Pendukung Keputusan Energi Terbarukan Berkelanjutan (SURE-DSS) dirancang dengan tujuan untuk membantu dan meningkatkan proses pengambilan keputusan untuk mencapai pasokan energi yang berkelanjutan dan terjangkau di daerah pedesaan yang miskin, banyak di antaranya mungkin juga berlokasi jauh.

SURE-DSS adalah paket perangkat lunak metodologis yang dirancang untuk mengisi kesenjangan saat ini dalam perencanaan pengembangan energi masa depan yang sesuai secara teknologi dan berkelanjutan dalam jangka panjang. Ini memberikan penilaian optimasi berbagai skenario elektrifikasi dan bertujuan untuk membantu dalam pengembangan energi untuk meningkatkan mata pencaharian pedesaan. Model ini dikembangkan oleh proyek penelitian internasional (2001-2006) Energi Terbarukan untuk Penghidupan Pedesaan Berkelanjutan (RESURL), yang didanai oleh Departemen Pembangunan Internasional Inggris (DFID). SURE-DSS dirancang untuk membantu para pengambil keputusan untuk menentukan dan memilih opsi pasokan energi yang tepat di daerah pedesaan untuk pengurangan kemiskinan dan keberlanjutan.

SURE-DSS menggabungkan kriteria kuantitatif dan kualitatif dan – tidak seperti perangkat lunak multi-kriteria lain yang ada yang membantu pengambilan keputusan energi pedesaan – pendekatan SURE memungkinkan prioritas sekelompok calon pengguna untuk dipertimbangkan dalam analisis. Model tersebut mengacu pada konsep pendekatan Sustainable Livelihoods (SL), yaitu pendekatan yang berpusat pada masyarakat yang menekankan pentingnya memahami dan menghubungkan berbagai komponen mata pencaharian. Istilah "berkelanjutan" menandakan bahwa mekanisme yang dipraktikkan untuk memungkinkan orang memastikan dan meningkatkan mata pencaharian mereka harus bertahan lama (Ashley dan Carney, 1999).

Pendekatan SL mengakui bahwa masyarakat memiliki lima kategori aset atau modal, yang dapat dikategorikan sebagai berikut: fisik (misalnya, rumah, jalan), keuangan (misalnya, upah, tabungan), alam (misalnya, air, sumber daya tanah), sosial (misalnya, jaringan dan organisasi lokal), dan manusia (misalnya, pendidikan, keterampilan). Dalam pendekatan SURE, ibu kota ini bertindak sebagai indikator untuk menilai kondisi yang ada di masyarakat pedesaan, menghitung kebutuhan energi dan menentukan prioritas keseluruhan populasi, dan mensimulasikan kondisi masa depan mereka melalui penerapan sistem energi alternatif. Model SURE-DSS berupaya memfasilitasi keputusan yang mempromosikan infrastruktur energi yang menjamin dan meningkatkan kualitas mata pencaharian pedesaan secara permanen dengan memberikan perhatian yang sama pada aspek non-teknis penyediaan energi, seperti faktor sosial ekonomi dan lingkungan.

Untuk mencapai hal ini, model SURE-DSS pada awalnya menilai kekuatan dan kelemahan suatu komunitas dengan menunjukkan status modal atau asetnya secara keseluruhan. Kemudian dilanjutkan dengan menyusun rencana energi, yang akan mempengaruhi aset masyarakat secara berbeda. Model ini bertujuan untuk menemukan solusi energi yang akan membentuk aset-aset yang menurut calon pengguna teknologi perlu ditingkatkan. Salah satu aspek yang sangat berguna dari model ini adalah bahwa SURE-DSS menggunakan segi lima untuk menggambarkan hubungan di antara lima aset atau modal ini secara grafis dan untuk menunjukkan potensi perubahan dan pertukaran yang terkait dengan penerapan berbagai alternatif energi 'sebelum' dan 'sesudah'. 'intervensi energi. Ilustrasi grafis dari berbagai solusi energi adalah atribut unik dari metodologi ini dan terbukti sangat berguna karena segilima menggambarkan potensi perubahan pada kondisi dasar rumah tangga, komunitas, atau wilayah sebagai respons terhadap penerapan teknologi energi modern. Dalam Persamaan. (1) di bawah,  $X_j$  mewakili satu set faktor terpisah untuk setiap fungsi aset.

$$C_j(A_i) = \frac{1}{1 + e^{-\alpha_j X_j(A_i)}}, \quad (j=1, \dots, 5; i=1, \dots, n) \quad (1)$$

$C_j(A_i)$  merupakan evaluasi alternatif energi ke- $i$  ( $A_i$ ,  $i=1, \dots, n$ ) terhadap sumber daya  $j$ ,  $j=1, 2, \dots, 5$ , (1 menunjukkan Fisik, 2 Finansial, 3 Alami, 4 Sosial dan 5 Modal Manusia);  $X_j(A_i)$  mewakili efek dari energi alternatif ke- $i$  pada sumber daya komunitas terkait  $j$ ; dan  $j$  adalah parameter skala, terkait dengan jumlah faktor yang menyusun setiap sumber daya  $j$ . Dalam SURE-DSS setiap faktor menunjukkan rentang nilai antara 0 dan 1, di mana 0 tidak mencerminkan efek positif dari energi alternatif  $i$  pada aset  $j$ , dan 1 berarti efek tertinggi. Oleh karena itu, ukuran ideal dan maksimal dari dampak positif yang dapat dicapai oleh suatu komunitas adalah 1; pengukuran lebih lanjut diberikan oleh baseline komunitas; dan perhitungan akhir diperoleh dari dampak energi alternatif terhadap aset masyarakat.

Misalnya, SURE-DSS diterapkan di komunitas pedesaan terpencil San José de Cravo Norte II (SJCN II; 400 penduduk), terletak di bagian timur Kolombia di dataran oriental Arauca (DANE, 2000). 101 rumah tangga dan pemimpin lokal disurvei, dan informasi yang dikumpulkan dengan cara ini digunakan untuk membangun basis komunitas dan untuk menentukan kebutuhan penduduk akan listrik dan layanan energi lainnya. Survei Sistem Pendukung Keputusan (Dr Joseph Teguh Santoso dan Budi Hartono, M.Kom)

mengungkapkan bahwa hanya 12% dari populasi yang disuplai dengan listrik yang dihasilkan oleh pembangkit listrik diesel 5kWh. Karena biaya operasional yang tinggi dan keterbatasan keuangan masyarakat, PLTD hanya beroperasi selama 7 jam per hari.

Analisis informasi yang diperoleh dalam survei mengungkapkan perlunya solusi teknologi yang akan menyediakan klinik kesehatan saat ini dengan listrik tanpa gangguan untuk vaksin dan obat-obatan agar dapat didinginkan dengan aman. Listrik tambahan diminta untuk memberi daya pada pusat komunal. Selain untuk meningkatkan akses listrik, sistem energi baru ini bertujuan untuk meningkatkan akses listrik harian untuk memompa air. Terakhir, energi diminta untuk meningkatkan produktivitas industri susu lokal – yaitu mekanisasi pemeliharaan, pendinginan dan pengolahan ternak – yang merupakan kegiatan ekonomi utama di wilayah tersebut, dan untuk memacu pengembangan usaha baru.

Penilaian terhadap lima jenis sumber daya yang ditemukan dalam SJCN II – yaitu, fisik, keuangan, alam, sosial dan sumber daya manusia – sebelum penerapan sumber listrik tambahan, menyoroti kelemahan dan kekuatan masyarakat pedesaan ini. Dengan menggunakan pendekatan SURE-DSS, diketahui bahwa luasan sumber daya yang dimiliki SJCN II dengan menggunakan generator diesel kecil berada di bawah setengah dari potensi total aset yang dimiliki masyarakat. Dalam SJCN II terdapat modal sosial dan finansial (keduanya 0,4) yang lebih besar daripada modal alam (0,3) dan manusia (0,3), tetapi sumber daya ini lebih tinggi daripada aset fisik (0,1) (lihat Tabel 2). Angka-angka ini (yaitu, semuanya lebih rendah dari 1) menunjukkan bahwa setiap aset dapat ditingkatkan melalui peningkatan pasokan energi, jika prioritas yang diartikulasikan masyarakat sesuai dengan opsi teknologi energi yang diusulkan. Alat SURE menghitung bahwa SJCN II perlu menghasilkan setidaknya 40kWh tambahan jika ingin memenuhi permintaan pengguna.

**Tabel 6.2** Keadaan aset lokal\* saat menggunakan generator diesel, SJCN II, Kolombia 2003

Teknologi Energi	Sumber daya yang dimiliki oleh SJCN II				
	Fisik	Keuangan	Alami	Sosial	Manusia
Pembangkit diesel (5 KWH)	0.1	0.4	0.3	0.4	0.3

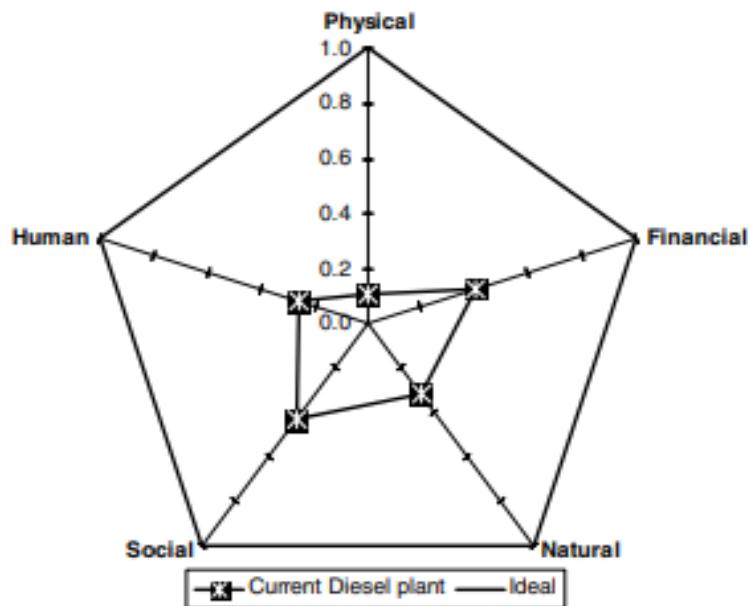
\* Keadaan tertinggi yang mungkin = 1.

Seperti disebutkan di atas, “pentagon mata pencarian dan energi” SURE-DSS memberikan representasi visual dari keadaan perkembangan masyarakat dan garis dasar yang ditetapkan melalui survei partisipatif, dan informasi teknis dan observasi tambahan di bawah kondisi pasokan energi yang nyata dan terkini. . Oleh karena itu, jarak antara pentagon yang lebih kecil dan segi lima terluar menggambarkan sejauh mana suatu komunitas kekurangan aset. Dengan kata lain, semakin dekat setiap tepi segi lima kecil ke titik pusatnya (yaitu, = 0), semakin lemah akses ke, atau kepemilikan aset tertentu, dan sebaliknya, semakin besar, semakin dekat dengan sosok ideal yang lebih baik dari masyarakat. (Lihat pentagon besar dan internal pada Gambar 1).

SURE-DSS dengan demikian memungkinkan pengambil keputusan untuk mengevaluasi efek yang mungkin dimiliki sistem energi baru terhadap aset yang dimiliki oleh individu, komunitas, atau sejumlah desa. Hal ini dilakukan dengan menghitung dan membandingkan

kondisi awal aset di suatu komunitas dengan nilai-nilai yang dihasilkan dari pemodelan implementasi energi alternatif baru. Kontribusi utama dari sistem karena itu adalah bahwa model: kesenjangan antara kondisi yang dikembangkan secara teoritis sepenuhnya dan keadaan aset yang sebenarnya; kemungkinan efek pada aset teknologi energi tertentu tersebut; dan akhirnya, dimungkinkan juga untuk meramalkan pertukaran khusus yang akan diimplikasikan oleh solusi energi alternatif untuk mata pencaharian.

Alat pendukung keputusan juga menghitung pertukaran yang terjadi ketika satu set teknologi, daripada yang lain, dipilih (lihat Gambar 2 untuk solusi yang mungkin). Pertukaran semacam itu kemungkinan terjadi di mana akses ke sumber daya dapat berubah sebagai akibat dari intervensi teknologi tertentu. Misalnya, dalam kasus SJCN II, sumber daya keuangan pengguna umumnya akan meningkat (0,5) dengan penerapan alternatif energi yang berbeda, dengan pengecualian dua opsi teknologi; jika dipilih, opsi fotovoltaik surya (0) dan solar-solar (0) tidak akan meningkatkan aset pengguna karena biaya pabrik dan pemasangannya serta kinerja yang buruk dalam kaitannya dengan permintaan yang dilaporkan, (untuk detail lebih lanjut, lihat Cherni et al., 2007 ). Multi-kriteria SURE-DSS mengacu pada metode Compromise Programming (CP) dengan metrik dua untuk pengambilan keputusan dan bobot. Untuk preferensi pembuat keputusan CP dapat dinyatakan sebagai ukuran jarak metrik antara dua alternatif dalam ruang tujuan (Yu, 1973; Zeleny, 1973). Alasan utama untuk mencari solusi kompromi adalah bahwa sementara Tindakan A mungkin lebih baik daripada Tindakan B menurut satu kriteria, mungkin lebih buruk menurut yang lain, akibatnya, solusi kompromi harus dicari (Munda et al., 1994) (Cherni et al., 2007).

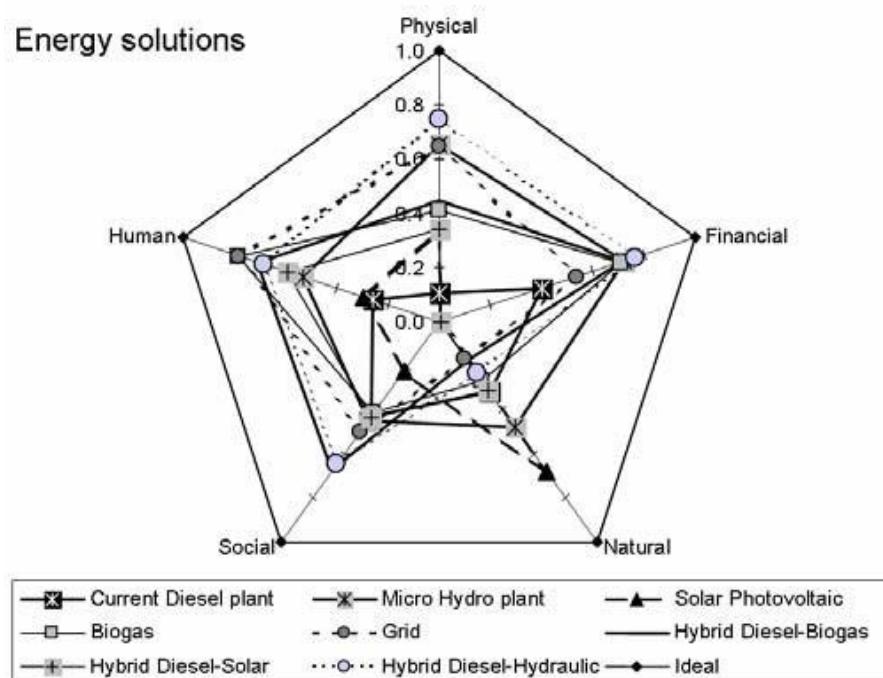


\* segi lima kecil; Indeks Dasar: 0,0 hingga 1,0

**Gambar 6.1** Sumber daya ideal dan pentagon dasar\* dengan pembangkit diesel 5 KWH di SJCN II, Kolombia 2003

Seperti yang dinyatakan sebelumnya, pilihan opsi energi untuk daerah pedesaan yang miskin bukanlah tugas yang sederhana. Namun, dengan memodelkan hasil melalui

pendekatan PASTI dan menggunakan bentuk geometris segi lima membuat tugas lebih dapat dicapai. Dalam kasus SJCN II dimungkinkan untuk memastikan kemungkinan perubahan pada baselinanya. Dengan memodelkan dampak prospektif suatu teknologi dalam satu gambar, pendekatan DSS ini berhasil menghindari fragmentasi informasi yang biasanya muncul dari tabel atau diagram batang, (meskipun demikian, fragmen informasi mungkin diperlukan untuk tujuan tertentu). Selanjutnya, segilima energi dan mata pencaharian untuk SJCN II juga menunjukkan masing-masing modal secara individual (lihat Gambar 2).



**Gambar 6.2** Kemungkinan teknologi energi yang tepat untuk SJCN II

Batas segi lima yang diperoleh dengan cara ini menunjukkan bagaimana total mata pencaharian akan terlihat setelah beberapa tahun di mana solusi teknologi energi tertentu telah beroperasi.

Berbagai segi lima yang ditunjukkan pada Gambar. 2 menunjukkan bagaimana berbagai teknologi akan mempengaruhi aset di SJCN II. Bentuk-bentuk tersebut telah dikonfigurasi dalam kaitannya dengan kerangka kondisi penghidupan yang optimal untuk SJCN II, yaitu segilima ideal yang menunjukkan tingkat pembangunan setinggi mungkin di mana semua aset dikembangkan sepenuhnya dan sama (yaitu, di mana Kapital  $j = 1$  ; lihat di atas). Sementara satu pentagon mensimulasikan keadaan mata pencaharian dengan generator diesel saat ini yang memasok energi untuk 12% populasi, pentagon lainnya menggambarkan mata pencaharian alternatif yang dapat dicapai dengan penerapan teknologi lain.

Dalam kasus SJCN II, pilihan energi yang optimal (mendorong ibu kota lebih dekat ke segi lima yang ideal) adalah terus menggunakan generator diesel yang ada bersama dengan penambahan pembangkit listrik tenaga mikro hidro (lihat Tabel 3). Pilihan terbaik berikutnya adalah pembangkit listrik tenaga mikro hidro saja, dengan skor sedikit lebih rendah (0,9) dari solusi nomor 1. Menurut analisis ini, pembangkit listrik tenaga diesel saja adalah solusi yang paling tidak direkomendasikan dari semua solusi (0,0).

Namun, pilihan teknologi energi sebagian besar akan bergantung pada preferensi pembuat keputusan yang bergantung pada pengakuan dan pengakuan atas prioritas dan keadaan keuangan calon pengguna, seperti yang diidentifikasi selama survei. Solusi 1 akan menghasilkan hingga 45kWh, yaitu daya yang dibutuhkan untuk memenuhi permintaan SJCN II. Mengikuti opsi ini, pembangkit diesel saat ini harus terus beroperasi dan menghasilkan 5 kWh dan tambahan 40 kWh akan dipasok oleh pembangkit mikro hidro baru. Biaya solusi per kWh adalah US\$ 1.024 dan total investasi awal adalah US\$ 40.960. Solusi ini akan menghasilkan listrik setidaknya selama 30 tahun dan menyediakan energi antara 90% dan 100% populasi.

**Tabel 6.3** Skor untuk opsi teknologi yang paling tepat, SJCN II, 2003

nomor solusi	Teknologi Energi	Skor kesesuaian*
1	Diesel dan mikrohidro	1.0
2	Mikro hidro	0.9
3	Diesel dan Biogas	0.8
4	Biogas	0.8
5	kisi-kisi	0.8
6	Diesel-Solar	0.3
7	fotovoltaik surya	0.1
8	Pabrik Diesel saat ini	0.0

\*Semakin besar skornya, semakin sesuai teknologinya

Diharapkan kualitas layanan akan sama dengan yang diterima oleh penerima manfaat yang terhubung ke jaringan nasional. Pembangkit biogas di SJCN II akan memakan biaya sedikit lebih rendah (Rp 540.000.000, atau Rp 13.500.000 per kWh) dibandingkan pembangkit mikro hidro, tetapi tidak akan dapat memenuhi semua permintaan. Pemasangan sistem fotovoltaik 40kWh akan membutuhkan investasi kira-kira tiga kali lebih besar (yaitu, Rp 2.550.000.000) daripada yang dibutuhkan untuk pembangkit listrik tenaga mikro hidro baru dan biaya penyambungan ke jaringan akan melebihi Rp 4.500.000.000, dengan biaya sebesar Rp 150.000.000 per km perpanjangan jaringan. Namun, jika kombinasi solusi diesel dan mikrohidro diterapkan (lihat Gambar 3), perbaikan akan terjadi pada aset fisik (+0,7), keuangan (+0,4) dan manusia (+0,4) SJCN II.

Dalam hal infrastruktur atau modal fisik, penyediaan energi yang lebih memuaskan berarti: layanan listrik yang andal selama 30 tahun; layanan energi yang fleksibel; ketergantungan yang lebih rendah pada bahan bakar fosil daripada yang mereka pilih untuk memperluas generator diesel yang ada atau menyambung ke jaringan listrik; dan penyediaan pasokan setidaknya selama 18 jam per hari dari kemungkinan layanan tanpa gangguan ke semua sektor permintaan. Pasokan tersebut akan memfasilitasi pengoperasian pusat kesehatan, sekolah, rumah dan sistem pasokan air seperti yang diminta oleh calon pengguna. Selanjutnya, infrastruktur energi baru akan meningkatkan aset keuangan yang ada. Perubahan seperti itu akan menjadi hasil dari intervensi langsung dan tidak langsung: sekitar 30 pekerjaan lokal akan dihasilkan selama fase konstruksi proyek energi dan 40% lebih banyak kesempatan kerja akan muncul di peternakan, kerajinan tangan, bisnis dan jasa.

Dalam jangka panjang, satu-satunya sumber daya SJCN II yang tidak membaik akibat solusi kelistrikan baru adalah lingkungan. Modal alam akan mengalami penurunan kualitas tidak hanya karena intervensi baru di lingkungan lokal (yaitu, pembangunan pembangkit listrik tenaga air mikro baru) tetapi karena generator diesel akan terus mencemari udara dan membuat kebisingan. Apalagi, bagian sungai yang akan digunakan untuk pembangunan pembangkit listrik tenaga mikrohidro akan sedikit rusak. Namun kemungkinan bahwa penyediaan listrik dari jaringan mikrohidro akan sedikit mengurangi kebutuhan akan kayu bakar. Beberapa perubahan dalam jaringan sosial komunitas akan terjadi karena kemungkinan partisipasi masyarakat lokal dalam tahap konstruksi, selama penggunaan dan operasi, dan selama pemeliharaan pembangkit listrik tenaga mikrohidro. Sebagai bagian dari modal sosial yang lebih besar, komite pemerintah daerah juga dapat dibentuk untuk mengelola pembangkit dan memungut biaya konsumsi listrik.

Terakhir, pemodelan di SJCN II menunjukkan bahwa penyediaan teknologi energi yang tepat akan diterjemahkan ke dalam perbaikan dalam kehidupan 400 penduduk. Misalnya, akan ada potensi pertumbuhan 60% dalam pendidikan (yaitu, sekolah dapat menampung lebih banyak anak, sementara lebih banyak ruang sekolah serta lebih banyak jam mengajar akan tersedia), dan peningkatan standar kesehatan dapat dicapai melalui kualitas perluasan layanan ketenagalistrikan.

## **6.5 SOLUSI ENERGI JANGKA PANJANG**

Di antara aspek lain yang dapat dipelajari dari penerapan sistem pendukung keputusan ini adalah mengatasi kompleksitas teknologi—yang dalam hal ini sedang—menawarkan kesempatan untuk memperoleh keterampilan baru. Potensi pengembangan setiap aset dengan penyediaan energi bervariasi sesuai dengan keadaan awalnya dan kapasitas opsi teknologi untuk memenuhi permintaan tertentu. Hasil ini juga menunjukkan bahwa masih ada potensi besar untuk perbaikan SJCN II, namun perubahan lebih lanjut akan dicapai dengan pengenalan kebijakan sosial melalui penerapan lebih lanjut dari pengembangan energi teknologi. Model SURE-DSS memungkinkan analisis data dari survei rumah tangga serta informasi teknis tambahan dan dengan cara ini, model ini tidak hanya memastikan solusi teknologi, tetapi yang terpenting, memproyeksikan efek teknologi energi pada kondisi aset masyarakat saat ini dan kemungkinan peningkatan, atau sebaliknya, yang mungkin timbul.

Sementara perbaikan kemungkinan akan terjadi melalui penggunaan teknologi energi, seperti yang terlihat dalam kasus SJCN II, kemungkinan munculnya masalah baru dan trade-off penting juga dapat muncul (yaitu, kerusakan lingkungan yang sedikit lebih besar akan terjadi dari terus mengandalkan diesel; lebih sedikit emisi akan dipancarkan jika solusi yang lebih disukai adalah diesel dan surya, atau hanya solusi fotovoltaik yang akan, bagaimanapun, terlalu mahal). Temuan ini menunjukkan bahwa sementara teknologi energi mungkin penting untuk mencapai mata pencaharian pedesaan yang berkelanjutan, pilihan teknologi harus didekati dari perspektif yang dinamis dan komprehensif untuk mempertimbangkan banyak keterkaitannya dan mencapai potensinya.

Masalah yang dibahas dalam DSS ini meliputi perumusan dan pemilihan sistem pasokan energi yang paling sesuai dengan kebutuhan energi dan kemungkinan masyarakat, sambil menjamin kinerja sistem energi dalam jangka panjang dan meningkatkan mata

pencaharian lokal. Dalam kerangka ini, sistem pendukung keputusan ini menyederhanakan tugas mengevaluasi berbagai pilihan energi yang paling sesuai dengan kebutuhan masyarakat sambil memaksimalkan sumber dayanya dan dengan demikian berkontribusi pada pengurangan kemiskinan. Aspek yang sangat berguna dari SURE-DSS adalah bahwa, secara unik, dan tidak seperti DSS lainnya yang dibahas di atas, ia menggabungkan aset saat ini, tuntutan aktual, dan prioritas dari komunitas target dan mencocokkannya dengan pilihan energi.

Mengingat bahwa penerapan teknologi energi tertentu dapat mengarah pada perbaikan di beberapa dimensi sementara terbukti merugikan yang lain, ada implikasi tertentu yang muncul dari penelitian ini. Misalnya, penilaian moneter kuantitatif dari pertukaran semacam itu dapat sangat membantu pengambilan keputusan kebijakan. Selain itu, ada kebutuhan untuk memperluas pentagon trade-off untuk menggambarkan tidak hanya bagaimana kelompok sosial dalam masyarakat mendistribusikan manfaat dan beban, tetapi juga bagaimana aktor yang berbeda, yaitu penyedia utilitas, pemerintah dan masyarakat, bermain keluar.

Dengan demikian, keuntungan utama yang terkait dengan SURE-DSS adalah bahwa, dalam menerapkan pendekatan multi-kriteria berdasarkan kerangka SL, memungkinkan pertimbangan penuh dari sejumlah besar data, hubungan dan tujuan yang umumnya hadir dalam masalah kebijakan dunia nyata. Selanjutnya, model ini kemungkinan efek dan trade-off dari solusi energi yang diproyeksikan pada berbagai jenis sumber daya yang mungkin dimiliki masyarakat. Dengan demikian, SURE-DSS memungkinkan pengambil keputusan untuk melihat pilihan teknologi yang dapat meningkatkan peluang keberhasilan pengembangan energi masa depan di daerah miskin.

Akhirnya, tujuan utama DSS ini adalah untuk membuktikan bahwa solusi sistem energi akan efektif bila, selain kinerja teknologi dan ekonomi yang tinggi, juga mendorong perubahan positif dalam pelaksanaan aspek lain dari komunitas sasaran. Penerapan SURE-DSS diharapkan dapat membantu dalam mencapai energi berkelanjutan jangka panjang di daerah pedesaan. Agar keputusan apa pun mengenai opsi energi pedesaan dapat berkelanjutan, keputusan tersebut harus melibatkan faktor teknis dan non-teknis, seperti halnya SURE.

## **6.6 KESIMPULAN**

SURE dapat membantu dalam kasus-kasus ketika membuat keputusan kebijakan mencoba untuk mempertimbangkan dengan hati-hati dan mempertimbangkan kapasitas investasi, persyaratan lokal dan kondisi yang ada. Sistem alat SURE kemudian dapat digunakan untuk menghitung solusi energi yang paling tepat, yaitu solusi yang memenuhi prioritas populasi dan mengurangi kemiskinan, serta mematuhi kebijakan pemerintah. Selanjutnya, pemilihan opsi energi terbaik perlu mengukur dampak keberlanjutan teknologi energi pada masyarakat dan, untuk melakukannya, perlu memiliki pandangan terpisah tentang faktor-faktor di tingkat masyarakat yang mungkin terpengaruh oleh pengembangan energi. Ini dicapai dengan membingkai analisis dalam SLA. Masalah sah yang perlu dipertimbangkan adalah apakah populasi target akan berbagi dan menerima hasil yang disarankan oleh model seperti SURE.

Pendekatan mata pencaharian berkelanjutan multi-kriteria PASTI untuk pengambilan keputusan dapat menunjukkan kepada pembuat kebijakan bagaimana penyediaan teknologi energi tertentu dapat secara positif mempengaruhi aspek tertentu dari mata pencaharian masyarakat sementara berdampak negatif pada orang lain. Ini adalah kontribusi yang berharga untuk upaya membawa energi yang terjangkau dan berkelanjutan bagi masyarakat pedesaan yang miskin di negara berkembang. Jenis informasi ini dan ilustrasinya yang lugas dapat menjadi sangat penting bagi masyarakat yang mencari solusi yang layak untuk masalah konkret serta untuk program pemerintah nasional yang menargetkan pembangunan pedesaan berkelanjutan di wilayah tertentu. Bagaimana baseline dapat diubah biasanya merupakan aspek yang sedikit dieksplorasi dalam perhitungan oleh para ahli. Metodologi ini, bagaimanapun, memungkinkan identifikasi prioritas petani dalam format yang seragam.

Pendekatan SURE merupakan langkah maju dalam mengakui peran penyediaan energi untuk pengurangan kemiskinan. Ini juga mempromosikan solusi yang berkelanjutan secara lingkungan dan sosial dalam jangka panjang. Bab ini telah menjelaskan dan menganalisis secara sistematis kemungkinan dampak energi yang efektif, terjangkau, dan bersih pada masyarakat. Sejauh mana sumber daya manusia dan sosial dapat ditingkatkan ketika lebih banyak energi tersedia telah ditunjukkan, sebagai bagian dari metodologi baru untuk pengambilan keputusan.

Konsep dan metode dalam pendukung keputusan terkait penyediaan energi modern untuk pengentasan kemiskinan di negara berkembang sendiri merupakan arah baru. Dalam konteks ini, pendekatan SURE adalah hal baru bukan hanya karena secara sistematis memasukkan prioritas calon pengguna, tuntutan mereka, dan kondisi aktual sebagai bagian dari analisis. SURE juga merupakan alat kelayakan yang penting karena melihat aspek teknis, sosial, lingkungan, keuangan, dan manusia dari pengembangan energi, bukan hanya beberapa komponen ini. Ini memberikan pendekatan yang komprehensif dan, karena mengacu pada prinsip-prinsip Mata Pencaharian Berkelanjutan, tujuannya adalah untuk mencapai kesetaraan akses ke semua penduduk miskin, perlindungan lingkungan dan partisipasi pengguna. Penyediaan layanan energi yang terjangkau dan efisien di daerah miskin di negara berkembang dapat berkontribusi untuk meningkatkan mata pencaharian 1,6 miliar orang di seluruh dunia yang berada dalam kemiskinan parah dan masih bergantung pada kayu bakar atau memiliki akses yang sangat terbatas ke layanan energi yang mahal dan sangat berpolusi.

## BAB 7

### SISTEM PENGAMBILAN KEPUTUSAN MENURUT PEMBELAJARAN PELENGKAP

Pengambilan keputusan medis sering dikaitkan dengan kelangsungan hidup dan kesejahteraan pasien. Dengan demikian, sangat penting bagi sistem pendukung keputusan klinis untuk tidak hanya memberikan penjelasan yang dapat dimengerti manusia, tetapi juga penalaran yang berhubungan dengan manusia. Sebuah model pengambilan keputusan manusia Complementary Decision Making System (CDMS) diusulkan. CDMS didasarkan pada pembelajaran pelengkap yang secara fungsional memodelkan penghambatan lateral dan mekanisme segregasi yang diamati dalam pengambilan keputusan manusia di lobus prefrontal dan parietal. Dengan demikian, CDMS memiliki proses pengambilan keputusan yang mirip manusia. Pemetaan penalaran hipotetis-deduktif lebih lanjut melengkapi CDMS dengan alur pengambilan keputusan yang mirip dengan dokter. CDMS kemudian diterapkan dalam diagnosis dan menunjukkan potensinya sebagai sistem pendukung keputusan klinis.

#### **7.1 PENDAHULUAN**

Pengambilan keputusan adalah jembatan antara sensasi dan tindakan, yaitu jembatan antara pemrosesan input stimulus dan pembangkitan output motorik [1]. Ini adalah proses menghasilkan, mengevaluasi, dan memilih opsi atau tindakan dari serangkaian setidaknya dua alternatif [2]. Memilih opsi yang tepat yang menghasilkan imbalan, dari serangkaian alternatif sangat penting untuk kelangsungan hidup dan kesejahteraan individu. Menariknya, pengambilan keputusan dapat dilihat tidak hanya pada level psikologis, tetapi juga pada level neurologis [1][3][4]. Namun, baik pada tingkat psikologis maupun neurologis, mekanisme pengambilan keputusan memiliki proses dasar yang sama, yaitu observasi/stimulus, seleksi, tindakan, dan evaluasi [5].

Kemajuan dalam teknik pencitraan otak telah memungkinkan pemodelan proses pengambilan keputusan di tingkat neurologis. Di atas model keputusan psikologis, banyak model keputusan berdasarkan neurobiologi diusulkan [6][7]. Model yang diusulkan mencakup proses pengambilan keputusan di bawah situasi yang berbeda, di bawah rincian neurologis yang berbeda, dan di bawah keadaan emosional yang berbeda. Misalnya, pengambilan keputusan organisasi, pengambilan keputusan kelompok, pengambilan keputusan rasional, pengambilan keputusan emosional, pengambilan keputusan visual-sakadik, dll [8-14]. Banyaknya model keputusan menunjukkan pentingnya dan kesulitan proses pengambilan keputusan.

Memahami bagaimana seseorang memutuskan dalam situasi yang berbeda adalah penting. Pemahaman ini membantu seseorang untuk membuat keputusan yang lebih baik, dan karenanya mengarah pada tindakan yang lebih efektif yang terpenting untuk mencapai tujuan seseorang [10]. Hal ini juga memungkinkan adanya desain teknologi yang dapat memfasilitasi proses pengambilan keputusan [15]. Sistem pendukung keputusan (DSS) berdasarkan model pengambilan keputusan manusia adalah salah satu teknologi yang dapat memberikan pengambilan keputusan yang mirip secara kognitif dengan manusia, dan selanjutnya meningkatkan kualitas pengambilan keputusan dan mengurangi kesalahan [16].

Teori keputusan yang muncul dari studi pengambilan keputusan memiliki tujuan yang sama untuk mengurangi kesalahan pengambilan keputusan dengan memandu proses secara sistematis [17]. Di sisi lain, studi dan pemodelan substrat saraf yang mendasari proses pengambilan keputusan mencirikan berbagai perilaku maladaptif, dan upaya pemodelan ini membuktikan pengetahuan yang berguna dalam memerangi gangguan psikiatri [18].

Namun, memahami pengambilan keputusan dan penalaran manusia bukanlah hal yang sepele. Pengambilan keputusan manusia adalah proses yang sangat kompleks yang disebabkan oleh interaksi banyak faktor [19], seperti ketidakpastian [20], emosi [9], penghargaan/hukuman [21], tindakan/hasil masa lalu [22], interaksi dengan kelompok [23], konteks (nilai, preferensi, keyakinan) [24], keyakinan [25], asumsi [26], metode penalaran [27] dan seterusnya. Karena pengambilan keputusan dipengaruhi oleh banyak faktor, ini menunjukkan bahwa pengambilan keputusan manusia rentan terhadap kesalahan, yang menunjukkan perlunya model pengambilan keputusan untuk memahami proses kognitif, dan pada saat yang sama kebutuhan DSS seperti manusia [16].

Oleh karena itu, DSS yang berbasis pada pengambilan keputusan manusia sangat dibutuhkan karena dapat memberikan second opinion kepada pengguna sehingga kesalahan dalam pengambilan keputusan dapat dikurangi [16][28]. Selain itu, DSS berbasis pengambilan keputusan manusia tidak hanya memiliki kemungkinan biologis yang masuk akal, tetapi juga memfasilitasi pemahaman pengguna tentang sistem. Alur penalaran yang mirip dengan pengambilan keputusan manusia memfasilitasi analisis "rasionalitas" DSS, yang, pada gilirannya, dapat meningkatkan kepercayaan pengguna terhadap sistem. Oleh karena itu, dalam karya ini kami mengusulkan model keputusan jaringan saraf fuzzy yang dikenal sebagai sistem pengambilan keputusan komplementer (CDMS). Karena jaringan saraf tiruan meniru pemrosesan saraf manusia, CDMS dikembangkan sedemikian rupa sehingga memiliki dasar saraf pengambilan keputusan. Untuk itu, CDMS dibangun berdasarkan pembelajaran komplementer [29], pembelajaran berbasis rangsangan hadiah dan hukuman yang menerapkan penghambatan lateral dan pemisahan pengetahuan hadiah dan hukuman. Alasan pengembangan CDMS berbasis pembelajaran komplementer fuzzy neural network adalah pengambilan keputusan merupakan proses paralel yang mirip dengan pengenalan pola [28]. Ini disediakan oleh jaringan saraf pemrosesan paralel, dan oleh pembelajaran pelengkap pengenalan pola. Ini akan dibahas di bagian 2.

## 7.2 SISTEM PENGAMBILAN KEPUTUSAN PELENGKAP

### **Dasar Neural Pengambilan Keputusan**

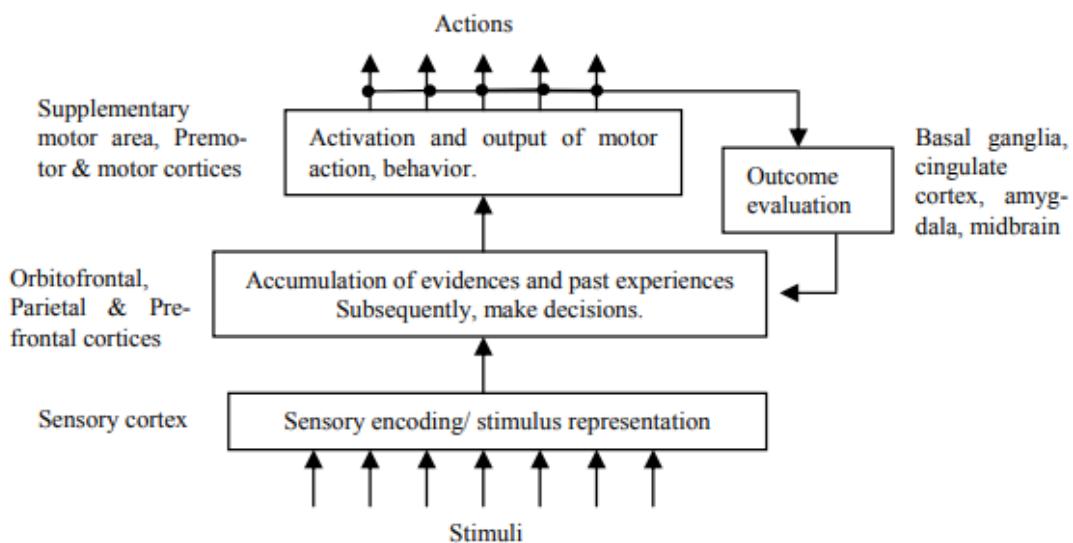
Pengambilan keputusan adalah proses yang sangat kompleks. Dalam karya ini, kami tidak mencoba untuk memodelkan setiap aspek dari proses pengambilan keputusan, tetapi kami memodelkan secara fungsional arsitektur otak yang mendukung proses pengambilan keputusan. Hal ini karena pemodelan setia setiap detail dari proses pengambilan keputusan membuat model terlalu rumit dan keras. Dengan demikian, model fungsional lebih mudah dipahami. Pertama, kami secara fungsional memodelkan otak manusia dalam mendukung proses pengambilan keputusan dengan memetakan tugas pengambilan keputusan ke area otak (substrat saraf). Selanjutnya, kami secara fungsional memodelkan proses pengambilan keputusan manusia berdasarkan pengambilan keputusan sakral visual dari gerakan mata.

Ada banyak literatur yang mendefinisikan substrat saraf yang mendasari pengambilan keputusan. Struktur seperti korteks prefrontal (PFC) dan korteks parietal secara konsisten terlibat dalam tugas-tugas yang membutuhkan pengambilan keputusan. Karena sifat pengambilan keputusan yang multifaset, banyak struktur terkait emosi, terkait penghargaan, motorik, dan sensorik lainnya seperti ganglia basal, amigdala, korteks cingulate anterior, dll, juga diaktifkan selama tugas pengambilan keputusan. Akibatnya, struktur yang bertanggung jawab belum dikonfirmasi [1]. Tidak diketahui apakah pengambilan keputusan adalah interaksi antara struktur yang berbeda, atau merupakan sistem terdistribusi dengan masing-masing struktur memainkan perannya untuk mencapai pengambilan keputusan yang sukses [30]. Substrat saraf pengambilan keputusan membentang di belahan otak. Gambar 1 merangkum langkah-langkah utama dalam pengambilan keputusan dan struktur saraf yang mendasarinya [1][3][31][32].

Setelah mengidentifikasi substrat saraf yang mendasari setiap proses pengambilan keputusan, kami mencoba untuk memodelkan secara fungsional aktivitas saraf yang berkorelasi dengan pengambilan keputusan yang diakui dalam literatur neuropsikologis. Pemetaan proses pengambilan keputusan digambarkan berdasarkan studi pengambilan keputusan visual-sakadik [11]. Dalam studi pengambilan keputusan visual saccadic, subjek diminta untuk membedakan arah gerakan titik acak dengan gerakan mata saccadic. Gambar 2 merangkum aktivitas saraf dalam proses pengambilan keputusan ini.

### **1. Presentasi Stimulus**

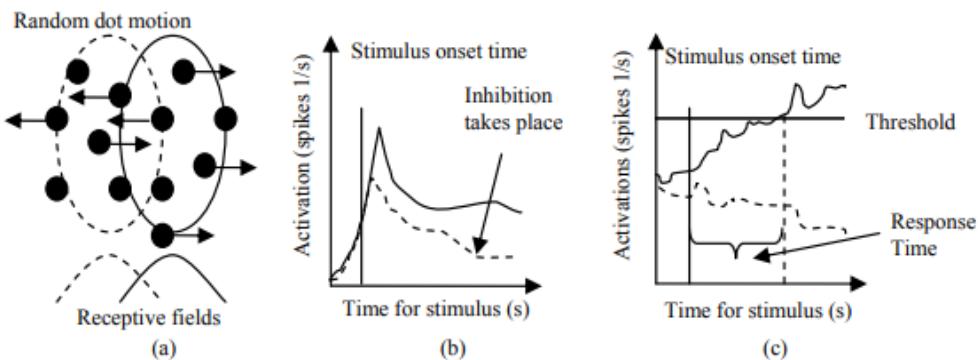
Stimuli diwakili oleh bidang reseptif neuron di korteks sensorik pendengaran, somatosensori dan sistem visual [33][34][35]. Bidang reseptif ini mencakup wilayah ruang di mana respons neuron akan diubah. Dengan cara ini, representasi kortikal dari dunia luar dapat memasukkan informasi baru berdasarkan relevansi stimulus tertentu [34], dan ini dilakukan melalui perubahan posisi, ukuran dan bentuk bidang reseptif [35]. Dalam proses pengambilan keputusan sakral visual, subjek mengkodekan rangsangan di area visual temporal tengah yang diproyeksikan ke korteks intra-parietal lateral [11].



**Gambar 7.1** Langkah-langkah utama dan substrat saraf dari pengambilan keputusan.

Ketika disajikan satu set rangsangan, korteks sensorik mengkodekan rangsangan. Korteks parietal dan prefrontal memproses rangsangan ini dan membandingkan rangsangan

dengan pengalaman masa lalu yang diwakili dalam korteks orbitofrontal dan amigdala. Perbandingan tersebut untuk menentukan apakah itu positif (menghargai) atau negatif (tidak menyenangkan). Selanjutnya, segera setelah akumulasi bukti cukup, aksi motorik dipicu oleh premotor, area motorik tambahan, atau korteks motorik. Setelah tindakan dilakukan, itu dievaluasi oleh otak tengah, sebuah struktur yang bertanggung jawab untuk pemrosesan emosional dan diproyeksikan ke amigdala dan korteks cingulate. Korteks cingulate dan ganglia basalis memproses konflik, dan pengetahuan yang dipelajari disimpan di korteks orbitofrontal dan amigdale.



**Gambar 7.2** Korelasi saraf dari keputusan saccadic visual.

Keterangan:

- Ketika disajikan satu set gerakan titik acak, neuron sensorik visual mewakili arah stimulus menggunakan bidang reseptif (garis putus-putus = arah pilihan kiri, garis padat = arah pilihan kanan).
- Neuron arah yang disukai (dalam hal ini kanan) diaktifkan, dan pada saat yang sama neuron terkait arah kiri dihambat
- Tidak ada tindakan yang diambil sampai akumulasi aktivasi mencapai ambang batas. Waktu yang dibutuhkan dari permulaan stimulus hingga tindakan disebut waktu respons. Kekuatan keseluruhan dari arah kanan lebih besar. Oleh karena itu, keputusan dibuat: arah yang benar, dengan demikian mengarahkan gerakan mata ke kanan.

## 2. Akumulasi Bukti

Otot menggasosiasikan tindakan dengan rangsangan yang diterima dari dunia luar, yang diterjemahkan menjadi pola penembakan bidang reseptif di korteks sensorik. Oleh karena itu, untuk melakukan tindakan tertentu, pola penembakan bidang reseptif harus cukup mirip dengan pola yang terdaftar di otak. Dengan kata lain, bukti/pengamatan yang cukup harus dikumpulkan untuk mengaktifkan tindakan yang sesuai. Anehnya, tidak hanya otak yang mengaitkan pola penembakan yang berbeda dengan suatu tindakan, tetapi juga area otak yang berbeda [36].

Hal ini diamati dalam tugas diskriminasi saccadic visi, di mana dua kelompok terpisah neuron yang terkait dengan arah kanan dan kiri ditemukan di korteks intraparietal. Setelah kedatangan stimulus, dua kelompok neuron akan ditembakkan. Setelah akumulasi kekuatan tembak dari setiap arah, keputusan dibuat sesuai dengan perbedaan antara akumulasi bukti (lihat Gambar 2). Ada mekanisme untuk memastikan keputusan yang tepat dibuat, dan itu

disebut sebagai penghambatan lateral, atau pembacaan lawan [10]. Ini berarti ketika arah kanan terdeteksi, kelompok neuron yang terdaftar untuk arah kanan akan memiliki kekuatan tembak yang lebih besar daripada kelompok arah kiri. Dengan kata lain, semakin besar kekuatan tembak kelompok arah kanan memberikan bukti bagi kelompok arah kanan untuk menembak, dan bukti terhadap penembakan kelompok arah kiri. Selain neuron di korteks visual, neuron di premotor ventral, prefrontal, korteks somatosensori juga menunjukkan penghambatan lateral dalam berbagai tugas diskriminasi [33][38], yang melibatkan penghambatan lateral sebagai mekanisme penting dalam proses pengambilan keputusan.

### **3. Aktivasi Aksi**

Setelah bukti terakumulasi melampaui ambang batas tertentu, neuron motorik yang sesuai memanggil tindakan terdaftar. Dalam kasus tugas diskriminasi saccadic visual, setelah melebihi ambang batas bukti oleh neuron yang bekerja di korteks intra-parietal, neuron mengaktifkan area di colliculus superior dan bidang mata depan yang menghasilkan gerakan saccade yang benar (pergeseran cepat dalam garis pandang) [11].

### **4. Evaluasi Hasil**

Setelah tindakan dilakukan, hasil tindakan dievaluasi untuk menentukan apakah itu hasil positif atau negatif, yaitu hadiah atau hukuman. Beberapa struktur otak yang saling terhubung seperti basolateral amygdale, orbitofrontal cortex, dan nucleus accumbens telah dikaitkan dengan harapan penghargaan dan perilaku yang diarahkan pada tujuan [39]. Amigdale basolateral bertanggung jawab untuk menghubungkan rangsangan dengan hadiah atau mengkontraskan fitur hadiah, sedangkan korteks orbitofrontal memandu respons berdasarkan harapan hadiah. Diyakini bahwa harapan akan penghargaan ini akan mengubah perilaku dan proses pengambilan keputusan. Di sisi lain, hukuman juga mengubah perilaku dan pengambilan keputusan. Dengan kata lain, penghargaan dan hukuman memainkan peran penting dalam pengambilan keputusan. Sangat menarik untuk mengetahui bahwa, penghambatan lateral dan mekanisme segregasi diamati pada substrat saraf penghargaan dan hukuman. Wächter dkk.

[36] menyelidiki efek penghargaan dan hukuman dalam pembelajaran manusia, dan mereka mengamati bahwa penghargaan dan hukuman melibatkan area otak yang berbeda, yaitu pengetahuan yang terpisah. Area otak yang terlibat dalam rangsangan hadiah adalah nukleus accumbens, amigdale, dan korteks prefrontal, sedangkan area otak yang terlibat dalam stimulus hukuman adalah insula bilateral serta bagian korteks prefrontal. Selain itu, mereka menemukan bahwa hadiah dan hukuman memiliki pola penembakan yang berbeda, menunjukkan penghambatan lateral diterapkan untuk rangsangan hadiah dan hukuman.

Dari tinjauan literatur neuropsikologis ini, kami melihat bahwa proses pengambilan keputusan manusia juga ditemukan di tingkat saraf, menunjukkan empat langkah dalam pengambilan keputusan. Pada catatan terpisah, kami mengamati bahwa mekanisme penghambatan lateral dan pemisahan struktur/neuron penghargaan dan hukuman baik dalam akumulasi bukti dan langkah evaluasi hasil. Hal ini menunjukkan penghambatan lateral dan mekanisme segregasi adalah fasilitas penting untuk pengambilan keputusan manusia, dan sangat penting untuk membuat keputusan yang baik. Dengan demikian, kami secara fungsional memodelkan mekanisme penghambatan dan segregasi lateral, yang disebut

sebagai pembelajaran komplementer, dan kami akan membahas model tersebut di bagian berikut.

### **Model Pengambilan Keputusan Pelengkap**

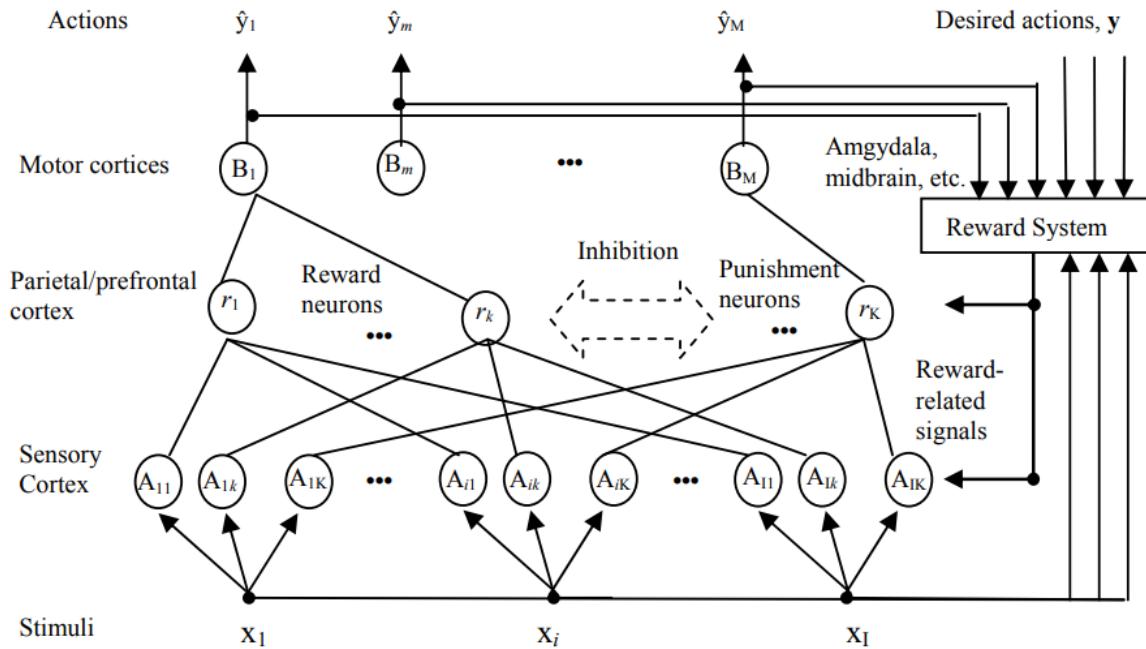
Model dengan pengambilan keputusan yang mirip dengan manusia diinginkan karena pengguna dapat memahami model dalam istilah akrabnya. Untuk tujuan ini, kami mengusulkan model pengambilan keputusan berdasarkan pembelajaran komplementer, yang secara fungsional memodelkan basis saraf pengambilan keputusan manusia. Kami menyebutnya sebagai Complementary Decision Learning System (CDMS). Karena fuzzy neural network menunjukkan karakteristik seperti proses pengambilan keputusan seperti manusia, dapat dijelaskan, dan memiliki langkah-langkah yang menyerupai pengambilan keputusan manusia, CDMS dikembangkan berdasarkan fuzzy neural network. Di sisi lain, karena pengambilan keputusan manusia melibatkan penghambatan lateral antara rangsangan hadiah dan hukuman, dan pemisahan pengetahuan hadiah dan hukuman, CDMS diimplementasikan dengan pembelajaran pelengkap [29]. CDMS didasarkan pada substrat saraf yang dilaporkan di bagian sebelumnya, dan arsitekturnya ditunjukkan pada Gambar 3.

Seperti terlihat pada Gambar 3, CDMS dikembangkan berdasarkan substrat saraf pengambilan keputusan yang digambarkan pada Gambar 1. Alur pengambilan keputusan CDMS diformalkan sebagai berikut.

Biarkan  $x_i$  menjadi stimulus dari neuron sensorik ke- $i$ , di mana  $i \in [1, I]$ , dan  $A_{ij}$  menjadi neuron sensorik ke- $j$  yang mewakili  $x_i$ , di mana  $j \in [1, J]$ .  $A_{ij}$  ini dicirikan oleh bidang reseptifnya  $\mu_{A_{ij}}(\bullet)$ , yang kemudian memproyeksikan responsnya ke neuron di korteks prefrontal, dilambangkan sebagai  $r_k$ , di mana  $k = j$ ,  $k \in [1, K]$ . Himpunan  $r_k$  yang mencapai ambang aksi mengaktifkan representasi motorik yang terkait di korteks motorik,  $B_{(lm)r_k}^+$  (didefinisikan oleh  $\mu_{B_{(lm)r_k}^+}(\bullet)$ ), di mana  $l \in [1, L]$ , dan  $m \in [1, M]$ . Superscript '+' dan '-' digunakan untuk menunjukkan elemen yang terkait dengan hadiah dan hukuman, masing-masing.

#### **1. Presentasi Stimulus**

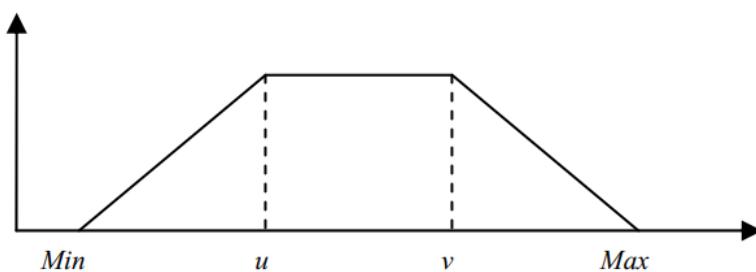
Dalam CDMS, rangsangan sensorik  $x = (x_1, x_2, \dots, x_I)$  diwakili oleh fungsi keanggotaan trapesium, yang memiliki karakteristik bidang reseptif yang serupa. Fungsi keanggotaan trapesium adalah empat tupel  $\langle min, u, v, max \rangle$  di mana  $min$  dan  $max$  adalah tumpuannya (lihat Gambar 4).  $\langle u, v \rangle$  adalah inti dari fungsi keanggotaan di mana rangsangan berada dalam kisaran  $\langle u, v \rangle$  memiliki derajat keanggotaan satu, seperti yang dijelaskan dalam Persamaan 1.



Gambar 7.3 Arsitektur CDMS.

CDMS sangat mirip dengan substrat saraf pengambilan keputusan. Lapisan pertama dianalogikan dengan korteks sensorik, di mana representasi stimulus dibentuk menggunakan himpunan fuzzy. Neuron di lapisan kedua menyerupai neuron kortikal parietal atau prefrontal, yang mengumpulkan bukti berdasarkan rangsangan. Akhirnya, lapisan ketiga berhubungan dengan korteks motorik yang mengaktifkan aksi. Sebuah sistem umpan balik yang berusaha untuk memodelkan peran amigdala, otak tengah, dan ganglia basal, disertakan untuk mengevaluasi hasil tindakan.

$$\mu(x) = \begin{cases} 0 & \text{if } (x \leq Min) \text{ or } (x \geq Max) \\ (x - Min)/(u - Min) & \text{if } x \in (Min, u) \\ 1 & \text{if } x \in [u, v] \\ (Max - x)/(Max - v) & \text{if } x \in (v, Max) \end{cases} \quad (1)$$



Gambar 7.4 Fungsi keanggotaan trapezium

Algoritma pembelajaran memodifikasi fungsi keanggotaan untuk memasukkan atau mengecualikan rangsangan baru dengan cara menyesuaikan celah (ukuran) dan lokasi (posisi) kernel, serta gradien kernel dan dukungan (ukuran) fungsi keanggotaan.

## **2. Akumulasi Bukti**

Sama seperti asosiasi stimulus-aksi dalam pengambilan keputusan neurobiologis, CDMS mewakili asosiasi tersebut dengan aturan. Aturan menghubungkan representasi rangsangan, A dari input ke representasi motor, B dari output, yaitu  $r_k : A_k \rightarrow B_k$ . Aturan-aturan ini membentuk basis pengetahuan CDMS. Untuk meniru penghambatan lateral dan pemisahan basis pengetahuan di neuron prefrontal, pembelajaran dari rangsangan terkait hadiah dan hukuman dipisahkan. Oleh karena itu, aturan terkait hadiah dan hukuman dibuat secara terpisah. Algoritma pembelajaran untuk konstruksi rulebase diringkas sebagai berikut, *Langkah 1:* Jika ada aturan yang ada, lanjutkan ke Langkah 2. Jika tidak, buat aturan berdasarkan sampel tindakan rangsangan berikut. Kernel dari fungsi keanggotaan diinisialisasi ke nilai stimulus, dan dukungan disetel ke nilai maksimum dan minimum dari dimensi tersebut.

Yaitu:

$$Max_i = (x_i^1, x_i^2, \dots, x_i^T)$$

$$Min_i = (x_i^1, x_i^2, \dots, x_i^T),$$

Dan

$$(u_{ij}, v_{ij}) = (x_i^t, x_i^t),$$

di mana  $t = [1, T]$  adalah indeks sampel.

Kemudian lanjutkan ke langkah 4.

*Langkah 2:* Hitung kekuatan tembak/bukti dari setiap aturan menggunakan Persamaan 3.

$$\mu_{r_k}(\mathbf{x}) = \frac{1}{I} \sum_{i=1}^I \mu_{A_{ij}}(x_i)$$

*Langkah 3:* Temukan aturan yang dipecah secara maksimal dari pengalaman hadiah dan hukuman (Persamaan 4 dan 5).

$$r^{*+} = \arg \max_{k^+} R^+ = \arg \max_{k^+} \bigcup_{k=1}^{K^+} r_k^+ \quad (4)$$

$$r^{*-} = \arg \max_{k^-} R^- = \arg \max_{k^-} \bigcup_{k=1}^{K^-} r_k^- \quad (5)$$

Jika rangsangan saat ini dikaitkan dengan hadiah, maka cari aturan hadiah yang dipecah secara maksimal. Jika aturan ini cukup dekat dengan rangsangan input, maka umumkan aturan ini untuk memasukkan input, jika tidak buat aturan baru untuk pasangan rangsangan-tindakan ini. Definisi "tutup" menurut ambang batas yang ditentukan pengguna,  $\rho$ . Populasi hadiah dan hukuman memiliki pengaturan ambang mereka sendiri,  $\rho^+$  dan  $\rho^-$  masing-masing. Ketika ambang batas terlampaui, aturannya disesuaikan dengan rangsangan, seperti yang dijelaskan oleh Persamaan 6 dan 7.

$$(u_{ij}^{t+1}, v_{ij}^{t+1}) = \begin{cases} [u_{ij}^t - \beta^t(u_{ij}^t - x_i), v_{ij}^t + \beta^t(x_i - v_{ij}^t)], & \text{if } \mu_{r^+}(x) > \rho \\ (u_{ij}^t, v_{ij}^t), & \text{Otherwise} \end{cases} \quad (6)$$

Dimana:

$$\beta^t = \eta \exp\left(-\frac{(t-1)^2}{Age}\right) \quad (7)$$

dan  $\eta$  = plastisitas awal, dan  $\beta^t$  = konstanta belajar pada epoch t. Umur adalah parameter preset yang menentukan plastisitas sistem. Bersama-sama, dan Age memantau plastisitas sistem. Secara umum, nilai dan Umur yang lebih besar berarti plastisitas yang lebih besar. Penurunan plastisitas sistem secara bertahap, selain untuk memodelkan proses aging, adalah untuk menghindari ketidakstabilan sistem yang mungkin terjadi pada saat data mengalami noise.

*Langkah 4:* Periksa apakah kondisi penghentian pembelajaran terpenuhi. Ini dapat dilakukan dengan menetapkan iterasi maksimum atau berdasarkan beberapa pengurangan fungsi biaya. Dalam studi ini, pelatihan dihentikan jika akurasi keseluruhan yang dicapai oleh sistem lebih besar dari beberapa ambang batas yang telah ditetapkan. Algoritma pembelajaran yang ditampilkan memisahkan pengetahuan reward dan punishment dan membangun aturan masing-masing secara independen. Adapun penghambatan lateral, CDMS kontras dengan kekuatan menembak aturan hadiah dan hukuman ketika stimulus disajikan, seperti yang diberikan dalam Persamaan 8.

$$y_m = \begin{cases} \mu_{B_{(lm)}_{k^+}}^+(x) \times \max_{k^+} \mu_{k^+}(x), & \text{if } \mu_{r^+}(x) > \mu_{r^-}(x) \\ \mu_{B_{(lm)}_{k^-}}^-(x) \times \max_{k^-} \mu_{k^-}(x), & \text{otherwise} \end{cases} \quad (8)$$

Dimana:

$$\mu_{r^+}(\mathbf{x}) = \arg \max_k \sum_{k=1}^{K^+} \sum_{i=1}^I \mu_{A_{ik}}(x_i) ,$$

Dan

$$\mu_{r^-}(\mathbf{x}) = \arg \max_k \sum_{k=1}^{K^-} \sum_{i=1}^I \mu_{A_{ik}}(x_i) .$$

Oleh karena itu, ketika stimulus terkait hadiah disajikan, CDMS memungkinkan aturan hadiah diaktifkan, dan menghambat aturan hukuman. Demikian juga, ketika stimulus terkait hukuman disajikan, aturan yang terkait dengan hukuman akan diaktifkan dan secara bersamaan, aturan yang terkait dengan hadiah dihambat. Mekanisme penghambatan lateral berguna dalam meminimalkan kebingungan selama pengambilan keputusan, yang dapat diterjemahkan menjadi akurasi yang baik dalam pengenalan dan pengambilan keputusan [29].

### **3. Aktivasi Aksi**

Setelah CDMS telah memutuskan, kekuatan tembak dari aturan pemenang digunakan untuk menentukan tindakan yang akan diambil, seperti yang ditunjukkan pada Persamaan 8.

### **4. Evaluasi Hasil**

Setelah CDMS mengeluarkan tindakan, sistem penghargaan mengevaluasi apakah keputusan yang dibuat membawa hadiah atau hukuman. Selanjutnya, sistem penghargaan belajar untuk memprediksi hasil keputusan CDMS. Kami menggunakan jaringan saraf fuzzy pembelajaran komplementer [29] juga untuk menerapkan sistem penghargaan karena penghambatan lateral dan sifat segregasi pengetahuan juga ada dalam sistem penghargaan. Dua input tambahan, keputusan CDMS, dan hasilnya, diumpulkan ke sistem penghargaan, yaitu.

$$[(x_1^t, x_2^t, \dots, x_I^t, y_1^t, y_2^t, \dots, y_M^t, \text{fitness}_{r^*}), (d_{\text{reward},1}, d_{\text{reward},2}, \dots, d_{\text{reward},M})].$$

$d_{\text{reward},m}$  adalah hasil ke- $m$  dari sistem penghargaan untuk input yang diberikan, dan digambarkan dalam Persamaan 9.

$$d_{\text{reward},m} = \begin{cases} 1, & \text{if } y_m^t = d_m^t \\ 0, & \text{Otherwise} \end{cases} \quad (9)$$

Kapan pun ada hadiah nyata

Misalnya,

$$d_{\text{reward},m} = 1$$

sistem penghargaan akan memperkuat aturan yang bertanggung jawab atas perilaku tersebut, dan menghukumnya sebaliknya. Dalam pekerjaan ini, perilaku ini dilakukan dengan memberikan setiap aturan nilai kebugaran berdasarkan hadiah atau hukuman yang mereka terima, seperti yang ditunjukkan pada Persamaan 10.

$$\text{fitness}_{r^*}^{t+1} = \begin{cases} \text{fitness}_{r^*}^t + 1, & \text{if } d_{\text{reward},m} = 1 \\ \text{fitness}_{r^*}^t, & \text{Otherwise} \end{cases} \quad (10)$$

Nilai fitness ini dapat dilihat dari seberapa kredibel suatu aturan dalam menjalankan tugas. Ketika CDMS memutuskan, ia mempertimbangkan keluaran CDMS, nilai kesesuaian aturan yang bertanggung jawab atas keputusan itu, dan keluaran dari sistem penghargaan. Hal ini diinginkan karena mirip dengan pengambilan keputusan klinis yang melibatkan diagnosis oleh dokter, keahliannya, dan prediksi penghargaan [28].

#### **CDMS dan Pengambilan Keputusan Manusia**

Untuk melengkapi CDMS dengan pengambilan keputusan seperti manusia, kami secara fungsional memodelkan langkah-langkah pengambilan keputusan neuropsikologis. Seperti yang ditunjukkan pada Bagian 2.1 dan 2.2, baik CDMS maupun pengambilan keputusan neuropsikologis memiliki alur proses yang serupa, dan menunjukkan penghambatan lateral dan pemisahan pengetahuan. Kesamaan antara CDMS dan pengambilan keputusan manusia diringkas dalam Tabel 1.

**Tabel 7.1** Persamaan antara pengambilan keputusan dan CDMS

Sifat-sifat	Pengambilan Keputusan tingkat neuron	CDMS
Pilihan tanggapan	Pengambilan keputusan melibatkan akumulasi bukti dari rangsangan, dan ambang batas digunakan untuk memutuskan tindakan yang tepat [25][40].	CDMS mengakumulasikan output dari setiap neuron input, dan memutuskan berdasarkan ambang batas untuk menjalankan aturan. Aturan dipecah digunakan untuk mendapatkan output yang benar.
Pola menembak	Ada eksitasi simultan dan penghambatan neuron hadiah dan hukuman berdasarkan rangsangan sensorik. Sinyal-sinyal ini dipertahankan untuk mendapatkan respon yang benar [40].	Ada aktivasi simultan dan penghambatan penghargaan dan hukuman di CDMS berdasarkan input. Kekuatan menembak dipertahankan selama pengambilan keputusan.

Pengambilan keputusan	Neuron menggabungkan informasi sensorik masa lalu dan sekarang untuk sampai pada keputusan [20].	CDMS menyimpan dan mengkarakterisasi input masa lalu menggunakan himpunan fuzzy. Keputusan untuk input saat ini dilakukan dengan mengacu pada input masa lalu dan sekarang.
-----------------------	--	---

Selain itu, untuk melengkapi CDMS dengan proses penalaran seperti manusia, CDMS dipetakan ke skema inferensi fuzzy hipotetis-deduktif yang dikenal sebagai Skema Penalaran Perkiraan Analogi (AARS). Penalaran hipotetis-deduktif diadopsi karena merupakan salah satu cara yang digunakan dokter untuk membuat keputusan [17]. Pemetaan ini tidak hanya meresmikan pengoperasian CDMS, tetapi juga melengkapi CDMS dengan proses pengambilan keputusan yang serupa dengan dokter. Ini berguna karena dokter dapat menganalisis CDMS dalam istilah yang mereka kenal [29], yang membuat CDMS lebih mudah dipahami. Proses inferensi CDMS setelah pemetaan diberikan sebagai berikut.

Misalkan  $t \in [1, T]$  = indeks untuk sampel, proses inferensi CDMS adalah sebagai berikut:

Diberikan satu set rangsangan sensorik

$$(\mathbf{x}^t = (x_1^t, x_2^t, \dots, x_I^t), y^t):$$

Diberikan sampel positif

$$\mathbf{x}^t = (x_1^t, x_2^t, \dots, x_I^t) \in X^+,$$

CDMS mengambil keputusannya:

1. Presentasi sampel ke sistem,

$$\mathbf{x} = (x_1, x_2, \dots, x_I).$$

2. Pencocokan anteseden (perbandingan input saat ini dengan pengetahuan yang tersimpan) dari aturan hadiah dan hukuman, yaitu menghitung  $\mu_{A_{ij}}(x_i)$  untuk setiap aturan.
3. Pemenuhan aturan dari setiap aturan dihitung menurut

$$\mu_{r_k}(\mathbf{x}) = \frac{1}{I} \sum_{i=1}^I \mu_{A_{ij}}(x_i),$$

dan aturan dengan kekuatan tembak maksimum dipilih,

$$r_k^* = \begin{cases} r_k^{*+}, & \text{if } \arg \max_k \{R^+\} > \arg \max_k \{R^-\} \\ r_k^{*-}, & \text{Otherwise} \end{cases}.$$

4. Derivasi konsekuensi berdasarkan aturan yang dipilih. Pada fase ini, prediksi CDMS dan sistem penghargaannya akan dibandingkan. Dalam karya ini, kesimpulan diturunkan dari keluaran CDMS, keluaran sistem penghargaannya, dan kesesuaian aturan (lihat Persamaan 11).

$$y_{cdms,m} = \begin{cases} +, & \text{if } y_m = + \text{ AND } d_{reward,m} = 1 \\ +, & \text{if } y_m = - \text{ AND } d_{reward,m} = 0 \text{ AND } fitness_{r^{*-}} < \rho \\ +, & \text{if } y_m = + \text{ AND } d_{reward,m} = 0 \text{ AND } fitness_{r^{*+}} > \rho \\ -, & \text{if } y_m = - \text{ AND } d_{reward,m} = 1 \\ -, & \text{if } y_m = + \text{ AND } d_{reward,m} = 0 \text{ AND } fitness_{r^{*+}} < \rho \\ -, & \text{if } y_m = - \text{ AND } d_{reward,m} = 0 \text{ AND } fitness_{r^{*-}} > \rho \end{cases} \quad (11)$$

5. Pengurangan kesimpulan dan output ke pengguna; dalam hal ini,  $y_1 = +$ .

Dengan demikian, CDMS memiliki proses penalaran yang mirip dengan manusia, di mana pemetaan satu-ke-satu dari pengambilan keputusan manusia dan CDMS diamati. Ini memfasilitasi validasi dan pembenaran sistem. Contoh CDMS dan inferensi dokter diberikan pada Tabel 2.

**Tabel 7.2** Proses pengambilan keputusan CDMS dan dokter

Langkah	Dokter	CDMS (AARS)
1	Amati gejalanya dan tanyakan pada pasien.	Ambil input dari data.
2	Menilai kesamaan masukan saat ini dengan pengetahuan dan pengalaman masa lalu.	Kumpulkan bukti dengan membandingkan kesamaan antara input saat ini dan aturan yang disimpan.
3	Pilih pengalaman atau pengetahuan terbaik yang menggambarkan situasi saat ini.	Pilih aturan terbaik yang menjelaskan input saat ini.
4	Putuskan respons yang tepat berdasarkan pengetahuan yang dipilih.	Pilih representasi output yang sesuai berdasarkan aturan yang dipilih.
5	Bertindak berdasarkan keputusan.	Keluarkan keputusan yang disarankan oleh representasi keluaran.

### 7.3 APLIKASI

Untuk menilai kinerja CDMS, digunakan lima dataset medis yang diperoleh dari repositori UCI [64]. Lima kumpulan data medis tersebut adalah Prognosis kanker payudara Wisconsin (WBCP), SPECT, diagnosis jantung SPECTF (SPECTF adalah versi numerik dari tugas diagnosis SPECT), deteksi Parkinson, dan klasifikasi informasi transfusi darah. Dataset ini digunakan untuk menilai kemampuan CDMS dalam mengklasifikasikan dataset yang tidak pasti dan tidak seimbang. Karena CDMS menerapkan pembelajaran komplementer, yang memisahkan pembelajaran dari penghargaan dan hukuman, efek ketidakseimbangan data dapat diminimalkan. Rincian data diberikan pada Tabel 3. Rasio ketidakseimbangan hanyalah rasio kasus penyakit dengan kasus normal. Semakin dekat rasio ketidakseimbangan ke satu, semakin seimbang datanya.

**Tabel 7.3** Dataset dari repositori UCI yang digunakan dalam percobaan ini

Himpunan data	Jumlah atribut	Jumlah contoh	Rasio ketidakseimbangan
WBCP	34	198	0.31
SPECT	22	267	0.26
SPECTF	45	267	0.26
parkinson	23	197	0.33
Transfusi darah	5	748	0.31

Dari Tabel 3, terlihat bahwa dataset yang digunakan dalam percobaan ini memiliki sedikit ketidakseimbangan di kelas. Validasi silang tiga kali lipat digunakan untuk semua eksperimen dan kinerja sistem CDMS dibandingkan dengan beberapa pilihan sistem pendukung keputusan yang populer [41]: Multilayer Perceptron (MLP), Radial Basis Function (RBF), Support Vector Machine (SVM), pohon keputusan C4.5, k-Nearest Neighbor (kNN), Naïve Bayesian. Perhatikan bahwa pengaturan eksperimental yang sama (set pelatihan/pengujian yang sama, mesin yang sama) seperti CDMS digunakan untuk sistem pendukung keputusan ini. Pengaturan parameter model diberikan dalam Lampiran. Hasilnya dirangkum dalam Tabel 4, perhatikan bahwa hasilnya adalah akurasi prediksi.

**Tabel 7.4** Kinerja CDMS dalam berbagai tugas medis

Metode	WBCP	SPECT	SPECTF	parkinson	Transfusi darah
MLP	70.45	56.25	72.5	92.3	79
RBF	76.92	65	82.5	81.54	77.94
SVM	78.12	67.5	75	70.26	76.2
C4.5	64.84	66.3	66.25	84.1	76.74
kNN	62.59	62.5	67.5	93.3	71.12
Bayesian Naif	70.99	67.5	80	81.16	75
CDMS	83.46	79.7	92.5	96.9	78.16

Seperti terlihat pada Tabel 4, CDMS mengungguli metode lain di sebagian besar tugas medis. Umumnya, CDMS berkinerja baik dengan data numerik dibandingkan dengan data kategoris. Selain itu, CDMS dapat mengklasifikasikan data ketidakseimbangan relatif baik bahkan ketika rasio ketidakseimbangan adalah 0,26, menyarankan pembelajaran pelengkap dapat meminimalkan efek ketidakseimbangan kelas. Ini adalah analisis awal karena rasio ketidakseimbangan semua dataset mendekati dan hanya ada satu dataset dengan rasio ketidakseimbangan kurang dari 0,3. Waktu pelatihan CDMS mendekati metode benchmark, dan sekitar 0,59-0,83 detik. Ini sebanding dengan metode benchmark seperti C4.5 yang membutuhkan waktu sekitar 0,2-0,3 detik. CDMS membutuhkan waktu lebih lama karena melibatkan dua pembelajaran jaringan saraf fuzzy yang saling melengkapi, dan memisahkan pembelajaran penghargaan dan hukuman. Dengan mengacu pada penerapan CDMS di WBCP,

penilaian awal CDMS diberikan sebagai berikut. Aplikasi dataset tidak diberikan karena sangat mirip dengan WBCP.

CDMS dapat dipahami karena menyediakan aturan fuzzy intuitif untuk menjelaskan bagaimana ia sampai pada keputusannya. Aturan fuzzy ini dicirikan oleh himpunan fuzzy, yang dapat dikaitkan dengan istilah linguistik seperti 'tinggi', 'rendah', dll. Hal ini memungkinkan pengguna untuk dengan mudah memahami sistem. Selain itu, aturan fuzzy yang dihasilkan oleh sistem penghargaan menggambarkan kemungkinan sistem untuk memprediksi hasil dengan benar. Sebagai pengambil keputusan manusia memperhatikan probabilitas, ini menawarkan saran bagi pengguna untuk memutuskan apakah akan mengadopsi saran. Aturan fuzzy terkait penghargaan ini juga memberi tahu pengguna seberapa yakin sistem dalam kasus yang disajikan ini. Contoh aturan diberikan pada Tabel 5.

**Tabel 7.5** Aturan fuzzy yang dihasilkan oleh CDMS

Aturan	CDMS	Sistem Penghargaan
Aturan hadiah	<b>IF</b> $x_1$ sedang <b>AND</b> $x_2$ cukup tinggi <b>AND</b> $x_3$ sedang <b>AND</b> $x_4$ tinggi <b>AND</b> $x_5$ sangat rendah, <b>THEN</b> terulang.	<b>IF</b> $x_1$ sedang <b>AND</b> $x_2$ tinggi <b>AND</b> $x_3$ sedang <b>AND</b> $x_4$ sangat tinggi <b>AND</b> $x_5$ rendah <b>AND</b> kekuatan menembak aturan tinggi, prediksi CDMS berulang, <b>THEN</b> sistem benar.
Aturan hukuman	<b>IF</b> $x_1$ adalah marjinal rendah ke sedang <b>AND</b> $x_2$ tinggi <b>AND</b> $x_3$ sedang <b>AND</b> $x_4$ cukup tinggi <b>AND</b> $x_5$ sangat tinggi, <b>THEN</b> tidak berulang.	<b>IF</b> $x_1$ sedang <b>AND</b> $x_2$ tinggi <b>AND</b> $x_3$ sedang <b>AND</b> $x_4$ cukup tinggi <b>AND</b> $x_5$ sedang <b>AND</b> kekuatan tembak aturan sedang <b>AND</b> prediksi CDMS berulang, <b>THEN</b> sistem salah.

Seperti yang terlihat pada Tabel 5, aturan dapat dengan mudah dipahami. Aturan penghargaan dan hukuman dari sistem penghargaan memandu pembelajaran. Selain itu, aturan sistem penghargaan ini melengkapi aturan CDMS saat prediksi dibuat. CDMS membuat penilaian berdasarkan aturan dari CDMS dan sistem penghargaannya. Dengan mempertimbangkan aturan sistem penghargaan, CDMS memperhitungkan kemungkinan prediksinya salah, dan mungkin mengabaikan keputusan yang disarankan oleh CDMS. Sebaliknya, CDMS dapat memutuskan sesuai dengan CDMS meskipun bukti rendah ketika sistem penghargaan menunjukkan bahwa itu mungkin benar, dan kesesuaian aturan tinggi. Contoh proses pengambilan keputusan CDMS diberikan di bawah ini:

1. Diberikan sampel positif:

$$\mathbf{x} = (0.05883 \ 0.01885 \ 0.1374 \ 0.2364 \ 14.34), y=1$$

2. Kumpulkan bukti dan bandingkan kekuatan tembak dari setiap aturan CDMS:

Aturan hadiah (seperti yang diberikan dalam Tabel 4):

$$\mu_{\frac{1}{k=1}}^+ (\mathbf{x}) = \frac{1}{I} \sum_i^1 \mu_{A_j} (x_i) = \frac{1}{5} \left( \frac{0.05883 - 0.056}{0.58 - 0.056} + \frac{0.01885 - 0.014}{0.016 - 0.014} + \dots \right) = 1.0,$$

di mana  $j=k$ , 0,056 dan 0,014 masing-masing adalah  $\text{Min}_{11}$  dan  $\text{Min}_{21}$ . Juga, 0,58 dan 0,016 masing-masing adalah  $u_{11}$  dan  $u_{21}$ . Demikian juga, kekuatan menembak dari aturan hukuman adalah,

$$\mu_{\frac{1}{n_k=1}}(\mathbf{x}) = \frac{1}{5} \left( \frac{0.05883 - 0.058}{0.63 - 0.058} + 0.0 + \dots \right) = 0.3.$$

3. Oleh karena itu, aturan hadiah memiliki kekuatan tembak yang lebih besar dan dipilih. Karena keputusan yang ditautkan oleh aturan adalah 'berulang', CDMS akan memutuskan 'berulang'.
4. Namun, sebelum keputusan ini, CDMS harus berkonsultasi dengan sistem penghargaan. Aturan pencocokan terbaik dari sistem hadiah adalah aturan hadiah pada Tabel 4. Karena output aturan CDMS tinggi, dan prediksi CDMS 'berulang', penerapan aturan ini dari sistem hadiah tinggi. Dengan kata lain, kemungkinan CDMS benar adalah tinggi.
5. Karena sistem penghargaan dan CDMS setuju, keputusannya 'berulang', yang merupakan keputusan yang benar.

#### 7.4 KESIMPULAN

CDMS dikembangkan berdasarkan substrat saraf dari pengambilan keputusan manusia. Mekanisme penghargaan dan hukuman mendasari pembentukan keputusan manusia. CDMS secara fungsional memodelkan proses pengambilan keputusan, dan menawarkan sifat-sifat yang menguntungkan seperti kinerja yang baik dan analisis sistem yang lebih mudah. Sayangnya, CDMS memiliki kekurangan yaitu membutuhkan basis aturan yang lebih besar karena menggunakan pemrosesan aturan penghargaan dan hukuman yang terpisah. Hal ini membatasi penerapan CDMS dalam dataset skala besar, yang terjadi di sebagian besar domain. Oleh karena itu, kami bermaksud untuk mengeksplorasi algoritma yang dapat mengurangi kompleksitas basis aturan seperti pemangkasan aturan. Kami juga berencana untuk mengeksplorasi teknik paralelisasi untuk CDMS sehingga dapat memanfaatkan kekuatan komputasi dari arsitektur komputer tingkat lanjut.

## BAB 8

### SISTEM PENDUKUNG PERAMALAN MENURUT EXPONENTIAL SMOOTHING

Bab ini menyajikan sistem pendukung peramalan berdasarkan skema pemulusan eksponensial untuk meramalkan data deret waktu. Metode pemulusan eksponensial mudah diterapkan, yang memfasilitasi komputasi dan sangat mengurangi kebutuhan penyimpanan data. Akibatnya, mereka banyak digunakan sebagai teknik peramalan dalam sistem persediaan dan perencanaan bisnis. Setelah memilih model yang paling memadai untuk mereplikasi pola deret waktu yang diteliti, sistem memberikan perkiraan akurat yang dapat memainkan peran penting dalam perencanaan organisasi, penganggaran, dan pemantauan kinerja.

#### **8.1 PENDAHULUAN**

Peramalan adalah alat yang digunakan oleh hampir setiap perusahaan besar untuk memprediksi masa depan yang tidak pasti dalam upaya untuk membuat keputusan yang lebih baik yang mempengaruhi masa depan organisasi. Prakiraan diperlukan oleh banyak departemen yang beragam dalam suatu organisasi untuk merencanakan operasi mereka. Pemasaran menggunakan prakiraan untuk merencanakan kegiatan pemasaran, periklanan, dan promosi penjualannya. Penjualan menggunakan prakiraan untuk mengukur kinerja operasionalnya terhadap target dan tujuan penjualan. Dalam menyiapkan anggaran, akuntan perlu mengetahui berapa penjualan produk yang berbeda, berapa tarif tenaga kerja, berapa biaya material, dan seterusnya. Prakiraan juga sangat penting untuk manajemen persediaan, yang sangat penting untuk keberhasilan kompetitif perusahaan. Organisasi yang membawa persediaan besar menimbulkan biaya penyimpanan yang besar baik dalam ruang maupun modal, sementara persediaan rendah dapat mencegah organisasi memenuhi permintaan pasar. Jadi logistik membutuhkan prakiraan untuk menentukan di mana, kapan dan berapa banyak persediaan yang dibutuhkan. Akibatnya, perkiraan yang akurat dapat memberikan informasi yang kuat untuk memotong biaya, meningkatkan penggunaan sumber daya yang efisien, dan meningkatkan kemampuan untuk bersaing dalam ekonomi kita yang berubah [23, 24].

Metode peramalan dapat dibagi menjadi dua kategori besar berdasarkan ketersediaan data deret waktu historis: metode kualitatif dan kuantitatif. Kelompok metode pertama umumnya menggunakan penilaian para ahli untuk menghasilkan prakiraan dan dapat diterapkan dalam situasi di mana data historis tidak tersedia. Di sisi lain, metode kuantitatif didasarkan pada analisis data historis mengenai deret waktu dari variabel yang diminati. Metode-metode ini lagi dikelompokkan ke dalam salah satu dari dua kategori. Yang pertama, metode deret waktu, menggunakan tren masa lalu dari variabel tertentu untuk mendapatkan prakiraan. Kategori kedua, metode kasual, meneliti hubungan sebab-akibat antara variabel dan variabel lain yang relevan seperti tingkat kepercayaan konsumen, tingkat pengangguran, dll.

Di antara metode deret waktu kuantitatif, salah satu yang paling banyak digunakan dalam sistem persediaan dan perencanaan bisnis adalah metode pemulusan eksponensial [17, *Sistem Pendukung Keputusan (Dr Joseph Teguh Santoso dan Budi Hartono, M.Kom)*

3]. Awalnya, metode ini tidak secara eksplisit didasarkan pada model probabilistik apa pun tetapi pada analisis deret waktu sebelumnya untuk menentukan fitur utamanya. Dengan rumus sederhana, dengan mempertimbangkan tingkat, tren dan efek musiman dari data, metode ini menghasilkan prakiraan untuk nilai masa depan dari seri [13]. Kesederhanaan relatif mereka memfasilitasi komputasi dan sangat mengurangi kebutuhan penyimpanan data. Oleh karena itu, mereka sangat berguna dalam organisasi yang memperkirakan ribuan produk setiap bulan. Selain itu, hasil kompetisi peramalan telah melaporkan kekokohan metode pemulusan eksponensial sebagai prosedur otomatis serba guna umum [22, 6].

Untuk menggunakan skema pemulusan eksponensial, analis harus memberikan nilai dari kedua kondisi awal, yaitu komponen level, tren dan musiman pada awal deret, dan parameter pemulusan. Dalam praktiknya, nilai-nilai ini tidak diketahui dan harus diperkirakan dari data yang diamati. Ada berbagai macam prosedur heuristik untuk memperkirakan kondisi awal, yang memiliki pengaruh pada proses model-fitting dan dapat menyebabkan prakiraan yang berbeda secara substansial [11, 27]. Selain itu, kita perlu menggunakan seri data dari setidaknya satu siklus musiman sebagai periode awal, yang dapat menjadi rumit jika kita memiliki jumlah data yang terbatas. Setelah nilai awal telah ditetapkan, parameter pemulusan umumnya diperkirakan dengan meminimalkan kesalahan prediksi satu langkah ke depan yang terkait dengan data yang diamati. Estimasi gabungan dari kondisi awal dan parameter pemulusan menggunakan prosedur optimasi yang berbeda membuatnya layak untuk mencapai pengurangan yang cukup besar dalam kesalahan perkiraan [3, 4].

Pengenalan selanjutnya dari kelas model state-space yang mendasari metode pemulusan eksponensial memungkinkan metode untuk menikmati keuntungan yang dimiliki prosedur peramalan berdasarkan model statistik yang tepat, seperti estimasi kemungkinan maksimum dan perhitungan kriteria pemilihan model dan prediksi interval [19, 25]. Perhatikan bahwa peramalan interval penting karena memungkinkan pengukuran tingkat kredibilitas pada titik peramalan. Selain itu, sangat nyaman dalam beberapa aplikasi seperti kontrol inventaris di mana interval prediksi memungkinkan pengaturan tingkat stok pengaman yang sesuai.

Tidak seperti perkiraan titik berdasarkan estimasi kemungkinan maksimum [19, 5] dan metode optimasi lainnya [3, 4], yang telah terbukti sangat akurat, interval prediksi cenderung terlalu sempit dalam arti bahwa lebih banyak pengamatan daripada yang diharapkan berada di luar perkiraan. interval prediksi. Hal ini terutama disebabkan oleh fakta bahwa formula yang berbeda yang diusulkan untuk perhitungannya tidak memperhitungkan kesalahan estimasi dari yang tidak diketahui.

Kami merancang SIOPRED (singkatan bahasa Spanyol untuk Sistema Integrado de Optimización y PREdicción de la Demanda) sebagai sistem pendukung peramalan berdasarkan skema pemulusan eksponensial Holt-Winters yang digeneralisasi untuk meramalkan deret waktu tingkat permintaan [6 ]. Ini menggunakan skema berbasis optimasi yang menyatakan tahapan estimasi parameter dan pemilihan metode. Strategi pemilihan model didasarkan pada kerangka optimasi penuh yang memungkinkan pertimbangan simultan dari berbagai metode peramalan pemulusan eksponensial, termasuk prosedur Holt dan Holt-Winters yang tidak musim, keduanya dengan tren teredam dan tidak teredam. Setelah menentukan metode untuk membangun prakiraan, prakiraan titik yang andal dan

interval prediksi dihasilkan secara otomatis, yang terakhir melalui prosedur bootstrap nonparametrik berdasarkan kesalahan pemasangan data historis.

Namun demikian, prakiraan interval yang lebih akurat dapat diperoleh dengan analisis model Bayesian, yang memungkinkan kita untuk menggabungkan kesalahan estimasi parameter model dan, sebagai hasilnya, mendapatkan interval prediksi dengan cakupan empiris yang mendekati satu nominal [7]. Meskipun paradigma Bayesian mengatasi masalah kesalahan estimasi, ini mengarah pada masalah integrasi yang umumnya sulit diselesaikan dan harus ditangani dengan menggunakan integrasi numerik, yang mungkin merupakan kelemahan bagi analis yang tidak memiliki pengalaman dan keahlian statistik. Dalam upaya mengatasi masalah ini, SIOPRED-Bayes dirancang sebagai sistem pendukung peramalan Bayesian yang melengkapi SIOPRED. Berdasarkan kerangka Bayesian, sistem ini menggabungkan semua model pemulusan eksponensial univariat yang ada serta beberapa generalisasi model ini untuk menangani fitur yang muncul dalam adegan ekonomi dan industri. Misalnya, batasan khusus harus dimasukkan ke dalam model saat bekerja dengan deret waktu penjualan atau permintaan, yang datanya semuanya non-negatif, dengan beberapa di antaranya mungkin sama dengan nol. Masalah umum lainnya dalam praktik adalah adanya data yang hilang, yang harus ditangani secara efektif untuk melakukan analisis rangkaian yang tepat dan mendapatkan prakiraan yang andal [2]. Setelah model yang paling memadai untuk menggambarkan perilaku deret waktu yang diberikan dipilih, prakiraan titik akurat dan interval prediksi secara otomatis dihasilkan sesuai dengan preferensi yang ditentukan oleh peramal.

Bab ini disusun sebagai berikut. Dalam Bagian 2 kami menjelaskan prosedur pemulusan eksponensial. Bagian 3 berkaitan dengan estimasi parameter. Bagian 4 membahas strategi pemilihan model. Bagian 5 dikhawasukan untuk prosedur peramalan, yang memungkinkan kita untuk menghitung perkiraan titik dan interval prediksi. Pada Bagian 6 kami menyajikan sistem pendukung peramalan SIOPRED-Bayes. Bagian terakhir memberikan beberapa komentar penutup.

## 8.2 PROSEDUR PEMULUSAN EKSPONENSIAL

Prosedur Holt-Winters, awalnya dikembangkan pada [28], adalah bentuk paling umum dari teknik pemulusan eksponensial dan memungkinkan kita untuk menggabungkan komponen lokal dari tren dan musiman. Variasi musiman dapat berupa bentuk aditif atau perkalian, tergantung pada apakah amplitudo pola musiman tidak tergantung pada tingkat deret atau tidak. Tabel 1 memperkenalkan beberapa notasi untuk pemulusan eksponensial.

**Tabel 8.1** Notasi standar untuk pemulusan eksponensial

Simbol	Definisi
$y_t$	Nilai yang diamati dari deret waktu pada waktu t
$n$	Jumlah pengamatan
$s$	Panjang siklus musiman
$a_t$	Tingkat deret pada waktu t

$b_t$	Tren saat ini
$c_t$	Indeks musiman pada waktu t
$\alpha$	Parameter penghalusan untuk level seri
$\beta$	Parameter penghalusan untuk tren
$\gamma$	Parameter pemulusan untuk indeks musiman
$\phi$	Parameter tren redaman
$\hat{y}_{n+h}$	perkiraan h-langkah-maju pada waktu n
$e_t$	Kesalahan prediksi selangkah lebih maju pada waktu t

---

Misalkan  $\{y_t\}_t^n = 1$  adalah data yang diamati dari deret waktu. Versi musiman aditif dari metode Holt-Winters disajikan dalam persamaan pemutakhiran berikut. Diasumsikan sebagai tren teredam aditif dengan cara yang mirip dengan versi yang diusulkan di [14]

$$a_t = \alpha(y_t - c_{t-s}) + (1 - \alpha)(a_{t-1} + b_{t-1}) \quad (1)$$

$$b_t = \beta(a_t - a_{t-1}) + (\phi - \beta)b_{t-1} \quad (2)$$

$$c_t = \gamma(y_t - a_t) + (1 - \gamma)c_{t-s} \quad (3)$$

Perkiraan h-langkah-depan diberikan oleh:

$$\hat{y}_{n+h} = a_n + \sum_{i=1}^h \phi^{i-1} b_n + c_{n+h-s} \quad (4)$$

Perhatikan bahwa dengan formulasi teredam ini, tidak ada peredam untuk periode prakiraan pertama [19]. Jika  $\phi = 1$ , metode ini identik dengan prosedur standar Holt-Winters.

Versi perkalian dari metode Holt-Winters sesuai ketika efek musiman bergantung pada tingkat rata-rata dari deret tersebut. Persamaan pemutakhiran untuk level dan musiman masing-masing ditransformasikan menjadi:

$$a_t = \alpha(y_t/c_{t-s}) + (1 - \alpha)(a_{t-1} + b_{t-1}) \quad (5)$$

$$c_t = \gamma(y_t/a_t) + (1 - \gamma)c_{t-s} \quad (6)$$

Demikian pula, ramalan h-langkah-depan menjadi:

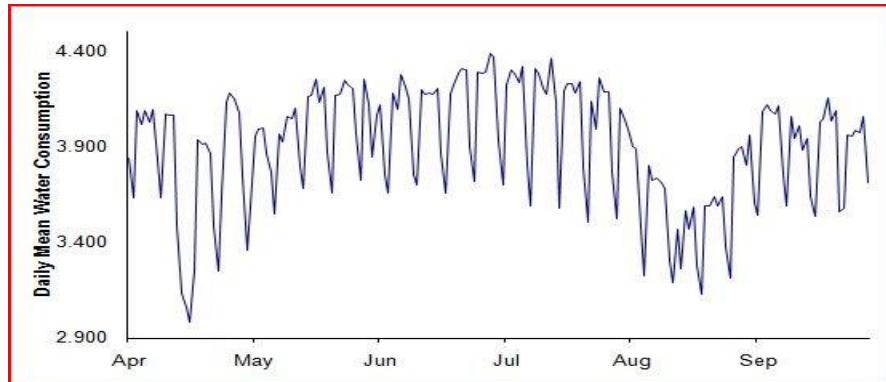
$$\hat{y}_{n+h} = \left( a_n + \sum_{i=1}^h \phi^{i-1} b_n \right) c_{n+h-s} \quad (7)$$

Parameter smoothing,  $\alpha$ ,  $\beta$ ,  $\gamma$ , dan  $\varphi$  biasanya dibatasi pada rentang 0-1, dan untuk parameter redaman kita tambahkan kendala  $\beta \leq \phi$ . Selain itu, baik versi aditif dan perkalian dari metode, yang diberikan oleh persamaan pemutakhiran rekursif di atas, diparameterisasi berlebihan sehingga model menjadi tidak dapat diidentifikasi. Dalam [28] direkomendasikan untuk menormalkan faktor musiman di awal deret sehingga  $\sum_{i=1}^s c_{i-s} = 0$  untuk bentuk aditif dari metode Holt-Winters, sedangkan  $\sum_{i=1}^s c_{i-s} = s$  untuk perkalian. Prosedur rekursif di atas menghasilkan berbagai metode pemulusan eksponensial dalam klasifikasi Pegels [26]. Penjelasan rinci tentang persamaan yang sesuai untuk metode standar pemulusan eksponensial dapat ditemukan di [13].

Karya selanjutnya oleh Ord et al pada kelas model ruang keadaan nonlinier dinamis dengan satu sumber keacakan menyebabkan beberapa model yang set optimal memperbarui persamaan sangat dekat dengan rumus Holt-Winters perkalian biasa [25]. Berdasarkan karya ini, dalam [19] diturunkan formulasi state-space ekivalen untuk masing-masing metode pemulusan eksponensial lainnya. Formulasi ini, yang melibatkan pengenalan komponen stokastik ke dalam proses deret waktu, memberikan dasar statistik pada metode, yang sekarang dapat menikmati keuntungan yang sama seperti prosedur peramalan berdasarkan model statistik yang tepat. Pemulusan eksponensial tidak lagi dianggap sebagai pendekatan ad hoc untuk peramalan tanpa formulasi stokastik yang mendasarinya. Kerangka negara-ruang membawa pemulusan eksponensial ke dalam kelas yang sama dengan model ARIMA, yang berlaku secara luas dan memiliki model stokastik suara di belakang perkiraan [19].

### Data Konsumsi Air

Sepanjang bab ini kita akan mengacu pada deret waktu yang sesuai dengan data konsumsi air rata-rata harian (dalam liter per detik) di Valencia, sebuah kota di pantai timur Spanyol. Data konsumsi air biasanya dianalisis menggunakan regresi berganda, antara lain dengan mempertimbangkan faktor iklim dan sosial ekonomi. Juga umum adalah penggunaan teknik intervensi, yang memungkinkan penggabungan informasi tambahan seperti hari libur umum, dengan tujuan mengurangi kesalahan perkiraan. Namun, dalam bab ini, kami akan menganalisis deret tersebut dari sudut pandang deret waktu, dengan mempertimbangkan tingkat rata-rata, tren, dan komponen musiman. Secara khusus, kami mempelajari kumpulan data yang berisi pengamatan dari 1 April 2006 hingga 30 September 2006. Gambar 1 menunjukkan plot waktu dari seri di mana siklus musiman dengan panjang tujuh diamati dengan jelas, yang membenarkan penggunaan Holt-Winters prosedur. Meskipun data konsumsi air biasanya menyajikan siklus musiman mingguan dan tahunan, dalam contoh ini hanya siklus musiman mingguan yang diamati karena kami hanya melakukan pengamatan selama enam bulan. Pada setiap siklus pengamatan terendah selalu sesuai dengan data hari Minggu sedangkan pada hari biasa konsumsi air lebih besar. Patut dicatat adalah penurunan konsumsi air karena Paskah, yang terjadi pada bulan April 2006, dan musim panas.



**Gambar 8.1** Plot waktu deret waktu yang sesuai dengan konsumsi air rata-rata harian (dalam liter per detik) di Valencia dari 1 April hingga 30 September 2006

### 8.3 ESTIMASI PARAMETER DAN PEMASANGAN MODEL

Untuk menggunakan skema pemulusan eksponensial, analis harus memberikan nilai kondisi awal, yaitu nilai awal untuk komponen level, tren dan musiman,  $a_0$ ,  $b_0$ ,  $c_{1-s}$ ,  $c_{2-s}, \dots, c_0$ , dan nilai parameter redaman,, dan pemulusan,  $\alpha$ ,  $\beta$ ,  $\gamma$ . Dalam prakteknya, nilai-nilai ini tidak diketahui dan harus diperkirakan dari data yang diamati. Estimasi ini adalah pertanyaan kontroversial. Faktanya, kita dapat menemukan banyak pendekatan yang berbeda untuk menangani estimasi parameter untuk prosedur pemulusan eksponensial dan dalam bagian ini kita meninjau beberapa pendekatan ini. Seperti yang telah kami sebutkan sebelumnya, perumusan ruang keadaan ekuivalen untuk setiap metode pemulusan eksponensial memungkinkan penghitungan kemungkinan, yang tidak mungkin dilakukan saat bekerja dengan metode sebagai prosedur ad hoc untuk menghitung prakiraan nilai masa depan dari waktu tertentu. seri. Oleh karena itu pentingnya membedakan antara metode pemulusan eksponensial dan model untuk estimasi parameter.

#### Estimasi Parameter untuk Metode Exponential Smoothing

Banyak algoritma heuristik telah diusulkan dalam literatur untuk menghitung nilai awal deret, meskipun tidak ada bukti empiris yang mendukung metode tertentu. Untuk bentuk musiman aditif dari metode Holt-Winters, salah satu algoritma sederhana berdasarkan data dari siklus musiman pertama adalah sebagai berikut [16]:

$$\begin{aligned} a_0 &= \bar{y}_1 \\ b_0 &= 0 \\ c_{i-s} &= y_i - \bar{y}_1 \quad i = 1, 2, \dots, s \end{aligned}$$

di mana  $\bar{y}_1$  adalah rata-rata aritmatika dari data untuk siklus musiman pertama. Prosedur lain yang memperkenalkan modifikasi ke dalam perhitungan tren awal adalah [21]:

$$\begin{aligned} a_0 &= \bar{y}_1 \\ b_0 &= (\bar{y}_2 - \bar{y}_1)/s \\ c_{i-s} &= y_i - \bar{y}_1 \quad i = 1, 2, \dots, s \end{aligned}$$

di mana  $\bar{y}_2$  adalah rata-rata aritmatika dari data untuk siklus musiman kedua. Untuk versi perkalian dari metode Holt-Winters, persamaan yang sesuai dengan faktor musiman mengadopsi bentuk  $c_{i-s} = y_i/\bar{y}_1$ . Pendekatan lain dapat ditemukan di [28, 11].

Setelah nilai awal ditetapkan, parameter pemulusan biasanya diestimasi dengan meminimalkan fungsi tertentu dari kesalahan peramalan satu langkah ke depan dari data historis. Nilai parameter pemulusan sangat sensitif terhadap rumus khusus yang digunakan untuk menghitung nilai awal tingkat lokal, tren dan faktor musiman pada awal rangkaian, yang dapat menghasilkan prakiraan yang sangat berbeda [11, 27].

Namun, hasil yang lebih memuaskan dapat diperoleh dengan mempertimbangkan kondisi awal sebagai parameter metode dan secara bersamaan menentukan nilainya bersama dengan parameter pemulusan dengan meminimalkan kesalahan prediksi satu langkah ke depan [3, 25, 19]. Misalkan  $= (a_0, b_0, c_{1-s}, c_{2-s}, \dots, c_0)*$  adalah vektor kondisi awal, dan  $= (\alpha, \beta, \gamma, \phi)*$  vektor parameter ing dan smoothing. Secara khusus, kriteria model-fitting yang diusulkan dalam [3] adalah RMSE (akar kuadrat dari kesalahan kuadrat rata-rata):

$$\varphi(\omega, \theta) = \sqrt{\frac{1}{n} \sum_{i=1}^n e_i^2}$$

di mana  $e_i = y_i - \hat{y}_i = y_i - (\hat{a}_{i-1} + \hat{b}_{i-1} + \hat{c}_{i-s})$  adalah kesalahan prakiraan selangkah lebih maju untuk versi musiman aditif. Dalam bentuk perkalian kesalahan ini diberikan oleh  $e_i = y_i - \hat{y}_i = y_i - ((\hat{a}_{i-1} + \hat{b}_{i-1})\hat{c}_{i-s})$ . Persamaan memperbarui setiap metode dan kendala yang berlaku untuk komponen awal dan parameter pemulusan menentukan himpunan kendala dari masalah optimasi. Misalnya, masalah optimasi yang terkait dengan metode aditif Holt-Winters dapat dirumuskan sebagai berikut:

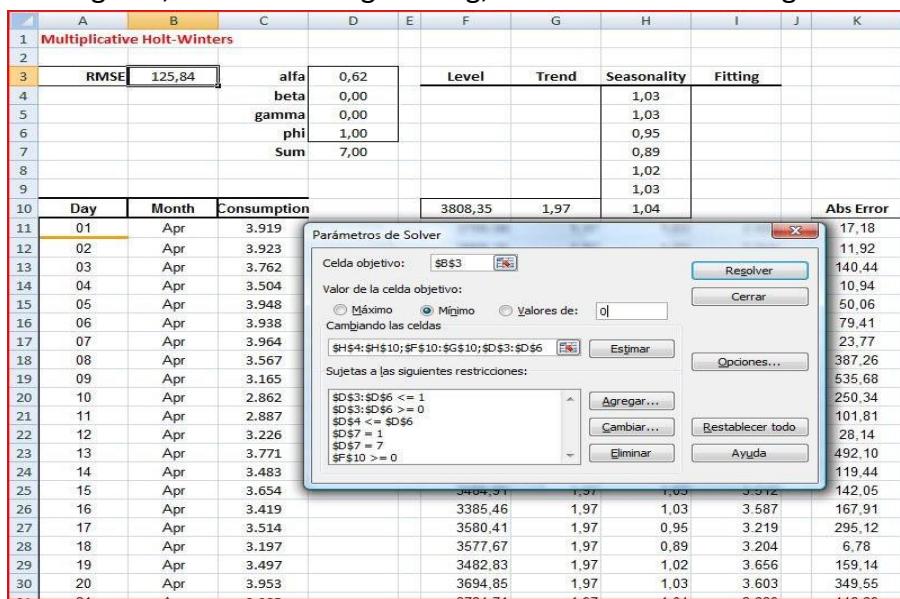
$$\begin{aligned} & \min \varphi(\omega, \theta) \\ \text{s.t. } & a_t = \alpha(y_t - c_{t-s}) + (1 - \alpha)(a_{t-1} + b_{t-1}), \quad t = 1, 2, \dots, n \\ & b_t = \beta(a_t - a_{t-1}) + (\phi - \beta)b_{t-1}, \quad t = 1, 2, \dots, n \\ & c_t = \gamma(y_t - a_t) + (1 - \gamma)c_{t-s}, \quad t = 1, 2, \dots, n \\ & \sum_{i=1}^s c_{i-s} = 0 \\ & \theta \in [0, 1]^4 \\ & \beta \leq \phi \end{aligned}$$

Demikian pula, masalah optimasi yang sesuai dengan bentuk perkalian dari metode Holt-Winters diberikan oleh:

$$\begin{aligned}
 & \min \varphi(\omega, \theta) \\
 \text{s.t. } & a_t = \alpha(y_t/c_{t-s}) + (1-\alpha)(a_{t-1} + b_{t-1}), \quad t = 1, 2, \dots, n \\
 & b_t = \beta(a_t - a_{t-1}) + (\phi - \beta)b_{t-1}, \quad t = 1, 2, \dots, n \\
 & c_t = \gamma(y_t/a_t) + (1-\gamma)c_{t-s}, \quad t = 1, 2, \dots, n \\
 & \sum_{i=1}^s c_{i-s} = s \\
 & \theta \in [0, 1]^4 \\
 & \beta \leq \phi \\
 & c_{1-s}, c_{2-s}, \dots, c_0 \geq 0
 \end{aligned}$$

Aplikasi Solver yang disertakan dalam spreadsheet Microsoft Excel dapat digunakan untuk menyelesaikan masalah pengoptimalan di atas. Gambar 2 menunjukkan spesifikasi model spreadsheet untuk versi aditif dari metode Holt-Winters untuk deret waktu konsumsi air. Karena kriteria pas adalah fungsi parameter yang sangat nonlinier, rutinitas optimasi numerik tidak dapat menjamin optimal global, dalam hal ini strategi multi-start direkomendasikan. Hal ini mengarah pada identifikasi himpunan minima lokal alternatif daripada mengidentifikasi solusi optimal tunggal. Solusi 'praktik terbaik' kemudian dipilih menjadi solusi dengan kesalahan pemasangan terendah.

Telah diketahui dengan baik bahwa untuk setiap versi pemulusan eksponensial, perkiraan titik dan akurasi prakiraan pasca-sampel mungkin juga berbeda tergantung pada kriteria yang dipilih untuk mengukur kesalahan pemasangan dalam sampel. Dalam upaya untuk mengatasi masalah ini, kami mengusulkan untuk bersama-sama memperkirakan semua yang tidak diketahui, yaitu kondisi awal dan parameter pemulusan, melalui skema estimasi yang bekerja secara paralel dengan tiga ukuran fit: MAPE (mean absolute presentase error), RMSE (akar kuadrat dari kesalahan kuadrat rata-rata) dan MAD (deviasi absolut rata-rata), dilambangkan dengan 1, 2 dan 3 masing-masing, dan didefinisikan sebagai:



**Gambar 8.2** Model spreadsheet Holt-Winters Multiplicative dan jendela Solver Parameters. Ini menunjukkan algoritme pengoptimalan untuk deret waktu konsumsi air, yang muncul di kolom berjudul Konsumsi

$$\varphi_1(\omega, \theta) = \frac{100}{n} \sum_{i=1}^n \frac{|e_i|}{y_i}$$

$$\varphi_2(\omega, \theta) = \sqrt{\frac{1}{n} \sum_{i=1}^n e_i^2}$$

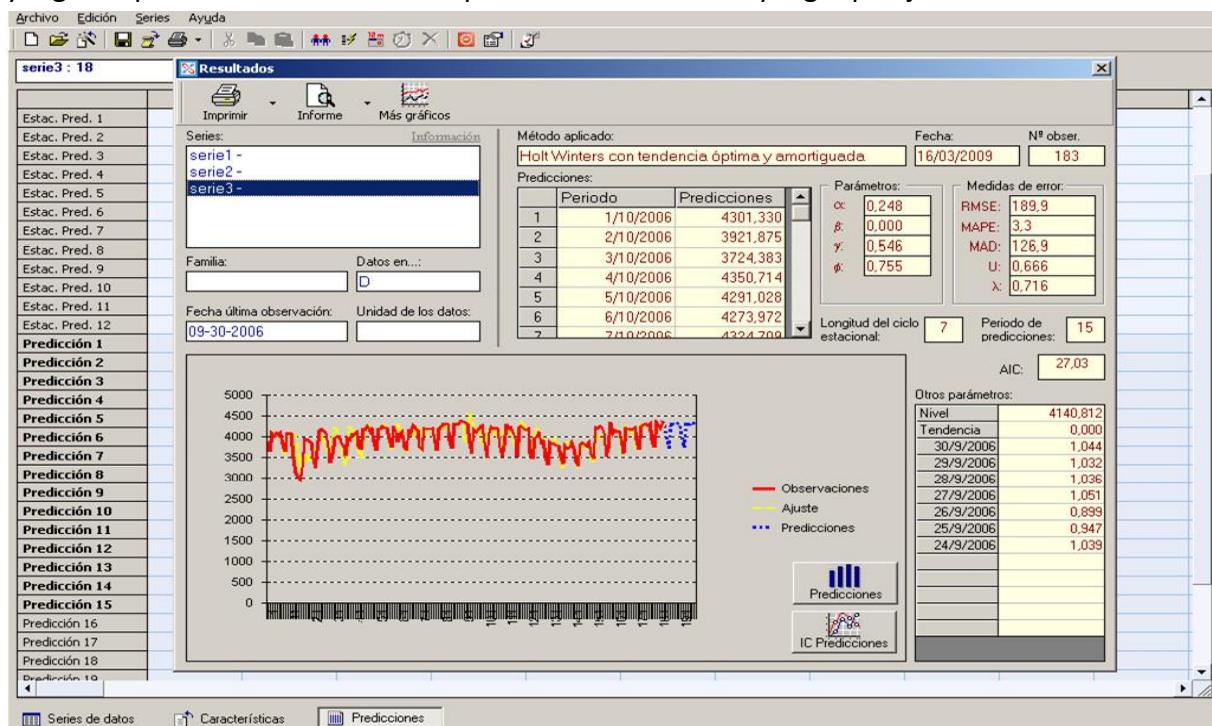
$$\varphi_3(\omega, \theta) = \frac{1}{n} \sum_{i=1}^n |e_i|$$

Dimana,

$$\{e_i = y_i - \hat{y}_i\}_{i=1}^n$$

adalah kesalahan perkiraan selangkah lebih maju dari sejarah data.

Pada tahap pertama, dengan menggunakan strategi multi-start, satu set minimum lokal untuk setiap ukuran kesalahan dihitung. Solusi kompromi kemudian ditemukan dengan mengoptimalkan kembali semua tujuan secara bersamaan menggunakan formulasi multi-tujuan. Usulan penulis untuk memecahkan masalah multi-tujuan non-linier menggabungkan semua informasi yang diperoleh sebelumnya pada tahap pertama melalui pendekatan fuzzy berdasarkan operator max-min Zimmermann (lihat [4] untuk penjelasan rinci). Perlu ditunjukkan bahwa pendekatan estimasi dan pemilihan model ini, di mana nilai kondisi awal ditentukan dalam proses model-fitting, memungkinkan penulis untuk mencapai pengurangan yang cukup besar dalam kesalahan perkiraan untuk kasus yang dipelajari.



**Gambar 8.3** Jendela hasil dari SIOPRED untuk metode Holt-Winters perkalian dengan tren teredam

Gambar 3 menunjukkan hasil dari prosedur di atas, seperti yang diperoleh aplikasi SIOPRED, ketika diterapkan pada kumpulan data konsumsi air rata-rata harian menggunakan metode Holt-Winters perkalian. Solusi yang diperoleh dengan prosedur ini menunjukkan

RSME pas 189,9, yang lebih besar dari yang ditunjukkan pada Gambar 2, yaitu 125,84. Perhatikan bahwa prosedur multi-tujuan kabur ini meminimalkan kompromi antara ukuran MAPE, MAD dan RMSE, tetapi bukan RMSE.

### **Estimasi Parameter Ketika Komponen Stochastic Ditambahkan**

Pengenalan kelas model ruang keadaan nonlinier dinamis, yang dicirikan oleh satu sumber keacakan, prosedur pemulusan eksponensial yang mendasari memberikan landasan statistik untuk metode tersebut [25, 19]. Untuk setiap metode pemulusan eksponensial, dimungkinkan untuk memperoleh formulasi ruang keadaan ekuivalen yang memungkinkan penghitungan interval kemungkinan dan prediksi dengan mudah. Sebenarnya ada dua kemungkinan model state-space yang sesuai dengan asumsi kesalahan aditif dan multiplikatif. Jadi model Holt-Winters dengan aditif musiman dan kesalahan aditif diperoleh dengan mengasumsikan bahwa pengamatan pada waktu  $t$  berasal dari variabel acak  $Y_t$  didefinisikan sebagai:

$$Y_t = \mu_t + \epsilon_t$$

di mana  $\mu_t = a_{t-1} + b_{t-1} + c_{t-s}$  dan  $\{\epsilon_t\}$  adalah error, biasanya diasumsikan sebagai homoskedastis independen Variabel acak normal,  $N(0, \sigma^2)$ . Model ini dapat dirumuskan sebagai model state-space dengan sumber kesalahan tunggal sebagai berikut:

### **Persamaan Observasi**

$$Y_t = a_{t-1} + b_{t-1} + c_{t-s} + \epsilon_t \quad (8)$$

### **Persamaan transisi**

$$a_t = a_{t-1} + b_{t-1} + \alpha \epsilon_t \quad (9)$$

$$b_t = \phi b_{t-1} + \alpha \beta \epsilon_t \quad (10)$$

$$c_t = c_{t-s} + \gamma \epsilon_t \quad (11)$$

di mana persamaan memperbarui metode Holt-Winters aditif, Persamaan. (1)- (3), telah ditulis dalam formulir koreksi kesalahannya. Perhatikan bahwa persamaan di atas (11) untuk memperbarui indeks musiman tidak setara dengan yang asli diusulkan dalam [28], Persamaan. (3), tetapi untuk persamaan yang dimodifikasi yang diusulkan dalam [25]:

$$c_t = \gamma(y_t - a_{t-1} - b_{t-1}) + (1 - \gamma)c_{t-s}$$

Secara analog, model Holt-Winters dengan musiman aditif dan kesalahan perkalian dapat ditulis dengan cara yang sama, di mana persamaan observasi menjadi:

$$Y_t = \mu_t(1 + \epsilon_t) \quad (12)$$

sedangkan persamaan transisi dapat dibuat dalam bentuk berikut:

$$a_t = a_{t-1} + b_{t-1} + \alpha \mu_t \epsilon_t \quad (13)$$

$$b_t = \phi b_{t-1} + \alpha \beta \mu_t \epsilon_t \quad (14)$$

$$c_t = c_{t-s} + \gamma \mu_t \epsilon_t \quad (15)$$

Formulasi state-space serupa diperoleh untuk metode pemulusan eksponensial yang tersisa [19].

$$L^*(\omega, \theta) = n \log \left( \frac{1}{n} \sum_{t=1}^n \frac{e_t^2}{k^2(\mu_t)} \right) + 2 \sum_{t=1}^n \log |k(\mu_t)|$$

Untuk setiap model pemulusan eksponensial, misalkan dua kali logaritma negatif dari fungsi kemungkinan terkonsentrasi dengan suku konstan dihilangkan, di mana  $\omega = (a_0, b_0, c_{1-s}, c_{2-s}, \dots, c_0)^*$  adalah vektor dari kondisi awal,  $\theta = (\alpha, \beta, \gamma, \phi)^*$  adalah vektor parameter redaman dan pemulusan,  $t$  mewakili ramalan satu langkah yang dibuat pada waktu  $t - 1$ ,  $\epsilon_t = y_t - \mu_t$  adalah satu langkah -ahead forecast error, dan  $k(\mu_t)$  adalah fungsi yang mengambil nilai 1 untuk model dengan kesalahan aditif, dan nilai t untuk model dengan kesalahan perkalian [25, 19]. Kondisi awal dan parameter pemulusan kemudian dapat diestimasi secara bersamaan dengan meminimalkan  $L^*(\omega, \theta)$ .

Di sisi lain, Bermudez et al merumuskan versi aditif dari model Holt-Winters, yaitu model dengan musiman aditif dan kesalahan aditif, sebagai model linier heteroskedastis [5]. Berdasarkan pekerjaan ini, kami memperoleh formulasi linier untuk model Holt-Winters aditif dengan tren teredam. Dengan menggunakan persamaan observasi (8) secara rekursif bersama dengan persamaan transisi (9)-(11), vektor data  $y = (y_1, y_2, \dots, y_n)^*$  dapat dinyatakan sebagai berikut:

$$y = M\psi + L\varepsilon \quad (16)$$

di mana  $\psi = (b_0, c_{1-s}, c_{2-s}, \dots, c_0)^*$  adalah  $(s+1) \times 1$  vektor dari kondisi awal dengan batasan  $a_0 + b_0 = 0$ . Perhatikan bahwa batasan ini, diperlukan agar model dapat diidentifikasi, merupakan alternatif meskipun kendala yang setara dengan yang umum digunakan  $c_{1-s} + c_{2-s} + \dots + c_0 = 0$ ;  $M$  adalah  $n \times (s+1)$ , matriks desain berpangkat lengkap, yang kolom pertamanya adalah vektor  $(0, \phi, \phi + \phi^2, \dots, \sum_{i=1}^{n-1} \phi^i)^*$  dan yang kolom terakhirnya terdiri dari blok matriks identitas  $s \times s$  yang dirakit untuk menutupi  $n$  baris;  $L$  adalah  $n \times n$  matriks segitiga bawah, fungsi dari parameter redaman dan pemulusan  $\theta = (\alpha, \beta, \gamma, \phi)^*$ , yang elemen-elemennya pada diagonal utama sama dengan 1 dan  $l_{i,j} = \alpha(1 + (\sum_{k=1}^{i-j} \phi^{k-1})\beta) + \gamma(i \equiv j \pmod{s})$  jika  $i > j$ ; adalah vektor kesalahan, biasanya diasumsikan terdistribusi Normal dengan vektor rata-rata 0 dan matriks kovarians  $\sigma^2 I_n$ .

Oleh karena itu, fungsi kemungkinan log dari vektor data diberikan oleh:

$$\begin{aligned}
 & -\frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2}(y - M\psi)'(LL')^{-1}(y - M\psi) = \\
 & -\frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2}(L^{-1}y)'(I_n - P_X)L^{-1}y - \frac{1}{2\sigma^2}(\psi - \tilde{\psi})'X'X(\psi - \tilde{\psi}) \quad (17)
 \end{aligned}$$

dimana  $X = L^{-1}M$ ,  $\tilde{\psi} = (X'X)^{-1}X'L^{-1}y$  adalah estimator kuadrat terkecil dari  $\psi$  ketika nilai  $\theta$  diketahui, dan  $P_X = X(X'X)^{-1}X'$  adalah ortogonal matriks proyeksi pada ruang vektor yang dihasilkan oleh kolom-kolom X.

Bentuk kuadrat kedua pada (17) selalu dapat dianulir, berapa pun nilai  $\theta$ , sedangkan bentuk kuadrat pertama hanya melibatkan parameter  $\theta$ , yang muncul dalam matriks L dan akibatnya dalam matriks X dan  $P_X$ . Jadi estimator kemungkinan maksimum dari parameter pemulusan  $\theta$ ,  $\hat{\theta}$ , diperoleh dengan menyelesaikan masalah optimasi berikut

$$\min_{\theta} (L^{-1}y)'(I_n - P_X)L^{-1}y \quad (18)$$

Setelah diperoleh  $\hat{\theta}$ , misalkan  $\hat{L}$  adalah matriks L yang dihitung pada  $\hat{\theta}$  dan  $\hat{X} = \hat{L}^{-1}M$ . Penduga kemungkinan maksimum dari  $\psi$  kemudian diberikan oleh vektor  $\psi$  yang dihitung pada  $\hat{\theta}$ , yaitu:

$$\hat{\psi} = (\hat{X}'\hat{X})^{-1}\hat{X}'\hat{L}^{-1}y \quad (19)$$

Akhirnya, penduga kemungkinan maksimum dari  $\sigma^2$  adalah:

$$\hat{\sigma}^2 = \frac{1}{n}(\hat{L}^{-1}y)'(I_n - P_{\hat{X}})\hat{L}^{-1}y \quad (20)$$

**Tabel 8.2** Estimasi kemungkinan maksimum dari parameter model aditif Holt-Winters untuk kumpulan data konsumsi air rata-rata harian

Parameter		Kondisi awal			
$\alpha$	0,59	Senin	81.17	Sabtu	-197.14
$\beta$	0.00	Selasa	136.95	Minggu	-413,99
$\gamma$	0.00	Rabu	151,52		
$\varphi$	0,50	Kamis	131.63	Tingkat	3717.38
$\sigma$	130.39	Jumat	109,86	Kecenderungan	78,79

Perhatikan bahwa formulasi ini, alternatif meskipun secara matematis setara dengan model ruang-negara dengan sumber kesalahan tunggal yang diberikan oleh Persamaan. (8)-(11), menyederhanakan perhitungan estimasi kemungkinan maksimum dari semua yang tidak diketahui: parameter redaman dan pemulusan, kondisi awal dan varians. Faktanya, hanya satu masalah optimasi yang melibatkan empat parameter, yang diberikan oleh (18), yang harus diselesaikan, optimasi parameter lainnya bersifat analitik. Meskipun skema ini tidak tepat jika efek musiman atau varians kesalahan bergantung pada tingkat deret, skema ini dapat berguna setelah transformasi data yang memadai seperti logaritmik.

Tabel 2 menunjukkan perkiraan kemungkinan maksimum dari parameter model Holt-Winters aditif untuk kumpulan data konsumsi air rata-rata harian. Solusi ini menunjukkan RSME 126,75, yang lebih kecil daripada yang diperoleh dengan Holt-Winters multiplikasi atau Holt-Winters aditif setelah transformasi log data. Minggu menunjukkan konsumsi terendah sementara yang tertinggi diperkirakan pada hari kerja. Perhatikan bahwa estimasi parameter pemulusan musiman adalah nol, yang berarti bahwa komponen musiman awal akan tetap. Estimasi parameter tren juga nol, tetapi karena estimasi parameter teredam lebih kecil dari satu, kondisi tren awal akan menjadi semakin kecil dan tren akan cepat konvergen ke nol.

#### **8.4 STRATEGI PEMILIHAN MODEL**

Aplikasi pemulusan eksponensial untuk peramalan deret waktu biasanya mengandalkan tiga metode dasar [8]:

- a) Pemulusan eksponensial sederhana
- b) Metode tren linier Holt, dengan atau tanpa redaman
- c) Metode Holt-Winters, dengan atau tanpa redaman dan dengan musiman aditif atau multiplikasi

Ketika prakiraan deret waktu tertentu diperlukan, perlu untuk mengidentifikasi metode yang paling tepat untuk menggambarkan perilakunya. Pendekatan umum untuk memilih metode adalah interpretasi penilaian dari alat grafis sederhana, seperti plot waktu dan korelogram dari data berbeda yang sesuai. Hal ini memungkinkan penilaian tren dan musiman dan harus memungkinkan analis untuk melihat, misalnya, apakah ada musiman aditif atau multiplikatif, yaitu apakah efek musiman bergantung pada tingkat rata-rata rangkaian atau tidak. Perlu ditunjukkan bahwa versi perkalian dari metode Holt-Winters tidak dapat digunakan dengan deret waktu yang berisi pengamatan sama dengan nol. Ketika tren sulit untuk dinilai, penggunaan tren teredam bisa menjadi pilihan yang bijak dan kuat, terutama jika konteksnya menunjukkan bahwa tren apa pun tidak mungkin bertahan tanpa batas waktu [9].

Ketika prakiraan interval diperlukan bersama-sama dengan prakiraan titik, penggunaan model prakiraan memungkinkan interval prediksi untuk dihitung secara teoritis. Dalam hal ini, teknik pemilihan model tertentu harus digunakan untuk mengidentifikasi model yang sesuai. Salah satu pendekatan yang mungkin memerlukan penggunaan teknik pemilihan model untuk memilih model terbaik sehingga dapat memilih bentuk pemulusan eksponensial yang tepat [19]. Namun, dalam bab ini, kami menganjurkan memilih model yang sesuai dengan syarat telah memilih bentuk pemulusan eksponensial. Pendekatan ini memungkinkan praktisi untuk memilih antara tren teredam dan tidak teredam dan bentuk aditif dan multiplikatif dari model Holt-Winters. Model yang lebih fleksibel di mana varians kesalahan hanya bergantung pada tingkat lokal atau faktor musiman juga dapat dipertimbangkan [20].

Banyak kriteria informasi telah diusulkan untuk pemilihan model pemulusan eksponensial. Kriteria ini biasanya dalam bentuk  $\log f(y | \hat{\phi}) - q(n, p)$ , di mana  $\log f(y | \hat{\phi})$  menunjukkan fungsi log-likelihood yang dievaluasi pada estimasi kemungkinan maksimum dan  $q(n, p)$ , sebuah fungsi dari  $n$ , jumlah pengamatan, dan  $p$ , jumlah parameter bebas dalam model, adalah yang disebut fungsi penalti. Tidak ada teori yang jelas untuk memutuskan kriteria mana yang paling efektif, meskipun hasil studi simulasi menunjukkan bahwa pendekatan kriteria informasi memberikan dasar terbaik untuk pemilihan model otomatis, AIC

[Akaike Information Criterion, 1] memiliki sedikit perbedaan. keunggulan atas rekan kriteria informasinya [8]. Oleh karena itu, setelah bentuk pemulusan eksponensial telah ditentukan, kami mengusulkan untuk memilih model dalam kelas ini dengan menggunakan AIC. Untuk masalah pemilihan model khusus kami, kriteria ini diberikan oleh:

$$AIC = -2 \log f(y|\hat{\omega}, \hat{\theta}, \hat{\sigma}^2) + 2p$$

di mana  $\hat{\omega}$ ,  $\hat{\theta}$  dan  $\hat{\sigma}^2$  berturut-turut adalah estimasi kemungkinan maksimum dari vektor kondisi awal  $\omega$ , vektor parameter redaman dan pemulusan , dan varians dari komponen stokastik  $\sigma^2$ ;  $p$  adalah jumlah parameter yang termasuk dalam model. Sehingga model dengan AIC terkecil akan digunakan dalam prediksi time series yang diteliti. Perhatikan bahwa pendekatan ini melibatkan estimasi model yang hanya terkait dengan bentuk pemulusan eksponensial yang dipilih.

Kami menganalisis dan membandingkan hasil yang diperoleh untuk kumpulan data konsumsi air rata-rata harian menggunakan model Holt-Winters aditif dan multiplikasi, baik dengan dan tanpa parameter tren teredam, dan juga menggunakan aditif Holt-Winters pada data log-transform. Kumpulan data ini menunjukkan tren yang hampir dapat diabaikan, sehingga tidak diharapkan untuk mengamati perbedaan yang tinggi antara efek musiman aditif atau multiplikatif. RMSE model aditif dan perkalian sangat mirip, semuanya antara 125,84 dan 126,95; RMSE yang terkait dengan model tanpa parameter tren teredam selalu lebih besar atau sama dengan model lengkap. Dalam hal ini perbedaannya sangat kecil dan AIC minimum diperoleh untuk model aditif Holt-Winters tanpa parameter tren teredam. Oleh karena itu, proposal peramalan kami untuk kumpulan data ini akan didasarkan pada model aditif Holt-Winters tanpa parameter tren teredam.

## 8.5 PROSEDUR PERAMALAN

Setelah parameter dalam model telah diestimasi, kita dapat mempertimbangkan untuk memperoleh prakiraan, baik prakiraan titik maupun interval prediksi, untuk nilai masa depan dari deret waktu yang diteliti. Hal ini juga penting di sini untuk membedakan antara metode dan model pemulusan eksponensial, karena dalam kasus terakhir ketika interval prediksi dapat dihitung pada basis statistik yang kuat.

### Peramalan dengan Metode Exponential Smoothing

**Perkiraan Titik.** Masalah menghitung perkiraan titik sangat mudah. Bahkan, jika perkiraan titik saja diperlukan, tidak penting untuk mengidentifikasi model yang mendasarinya. Misalkan  $\hat{\omega} = (\hat{a}_0, \hat{b}_0, \hat{c}_{1-s}, \hat{c}_{2-s}, \dots, \hat{c}_0)'$  adalah vektor dari estimasi kondisi awal, dan  $\hat{\theta} = (\hat{\alpha}, \hat{\beta}, \hat{\gamma}, \hat{\phi})'$  vektor dari estimasi redaman dan parameter penghalusan. Prakiraan  $h$ -step-ahead untuk bentuk musiman tambahan dari prosedur Holt-Winters kemudian dapat dihitung sebagai:

$$\hat{y}_{n+h} = \hat{a}_n + \sum_{i=1}^h \hat{\phi}^{i-1} \hat{b}_n + \hat{c}_{n+h-s} \quad (21)$$

Demikian pula, untuk efek musiman perkalian, persamaan di atas menjadi:

$$\hat{y}_{n+h} = \left( \hat{a}_n + \sum_{i=1}^h \hat{\phi}^{i-1} \hat{b}_n \right) \hat{c}_{n+h-s}$$

dimana estimasi level, tren dan komponen musiman pada waktu  $n$ ,  $\hat{a}_n$ ,  $\hat{b}_n$  dan  $\hat{c}_{n+h-s}$  masing-masing dihitung dengan menerapkan persamaan pemutakhiran secara rekursif, menggantikan  $\hat{\omega}$  dan  $\hat{\theta}$  untuk  $\omega$  dan  $\theta$ .

**Interval Prediksi.** Interval prediksi terdiri dari batas atas dan bawah di mana nilai masa depan diharapkan terletak dengan probabilitas yang ditentukan. Jadi mereka membantu untuk menunjukkan kemungkinan ketidakpastian dalam perkiraan titik [10]. Untuk menghitung interval prediksi, biasanya diasumsikan bahwa kesalahan ramalan terdistribusi Normal sehingga interval prediksi  $100(1-\alpha)\%$  untuk  $y_{n+h}$  diberikan oleh:

$$\hat{y}_{n+h} \pm z_{\alpha/2} \sqrt{\text{Var}(e_{n+h})} \quad (22)$$

di mana  $\text{Var}(e_{n+h})$  adalah varians dari kesalahan perkiraan langkah ke- $h$  dan  $z_q$  menunjukkan kuantil ke- $q$  dari distribusi Normal standar. Oleh karena itu interval prediksi memerlukan varians dari kesalahan ramalan untuk diketahui.

Secara tradisional, interval prediksi untuk metode pemulusan eksponensial telah ditemukan melalui pendekatan heuristik atau dengan menggunakan model ARIMA yang setara atau mendekati. Ekspresi varians analitik untuk bentuk musiman aditif dari metode Holt-Winters dapat ditemukan dengan mengasumsikan bahwa kesalahan perkiraan satu langkah ke depan tidak berkorelasi dengan varians yang sama [29]. Varians ini ternyata sama dengan model ARIMA yang ekuivalen. Dengan asumsi yang sama untuk kesalahan perkiraan satu langkah ke depan, rumus perkiraan untuk varian kesalahan juga dapat diturunkan untuk bentuk perkalian [12]. Berbeda dengan kasus aditif, lebar interval prediksi perkalian ini akan bergantung pada asal waktu prakiraan dan dapat menurun (mendekati palung musiman) serta meningkat (mendekati puncak musiman) dengan waktu tunggu.

Baru-baru ini, kami telah mengembangkan SIOPRED sebagai sistem pendukung peramalan berdasarkan skema pemulusan eksponensial Holt-Winters yang digeneralisasi untuk meramalkan rangkaian waktu dari tingkat permintaan. Sistem ini memperkenalkan metodologi baru untuk memperoleh prakiraan yang kuat dan interval prediksi yang andal. Pada tahap pertama, menggunakan skema berbasis optimasi yang diperkenalkan pada [4] yang menyatukan tahapan estimasi parameter dan pemilihan metode, lihat Bagian 3.1, sistem mencari spesifikasi model yang dapat mereplikasi pola seri yang diamati. Kemudian, setelah menentukan metode untuk membangun prakiraan di atas cakrawala tertentu, prakiraan titik yang andal dan interval prediksi dihasilkan secara otomatis. Prakiraan titik diperoleh dengan menggunakan persamaan prediksi yang sesuai, menggantikan semua yang tidak diketahui dengan perkiraannya. Melihat (21) untuk bentuk musiman aditif dari metode Holt-Winters. Interval prediksi dihitung dengan menggunakan prosedur bootstrap non-Sistem Pendukung Keputusan (Dr Joseph Teguh Santoso dan Budi Hartono, M.Kom)

parametrik tanpa asumsi pada distribusi kesalahan perkiraan. Untuk setiap  $h$  dari 1 ke cakrawala prediksi  $k$ , sistem memperkirakan distribusi kesalahan perkiraan  $h$ -langkah-depan dengan cara distribusi empiris kesalahan pemasangan  $h$ -langkah-depan yang diamati  $\{e_{i+h} = y_{i+h} - \hat{y}_{i+h}, i = 1, 2, \dots, n-h\}$ .

Untuk menambahkan gangguan acak yang serupa dengan yang diharapkan pada perkiraan  $h$ -langkah-depan yang dihitung sebelumnya, realisasi  $N$  disimulasikan dari distribusi empiris kesalahan pemasangan  $h$ -langkah-depan yang diamati. Hasilnya adalah sampel simulasi ukuran  $N$  dari perkiraan distribusi prediksi yang akan digunakan untuk menghitung persentil yang sesuai dan oleh karena itu interval prediksi yang diperlukan.

### **Peramalan dengan Model Exponential Smoothing**

Sementara prakiraan titik adalah sama secara independen dari apakah metode atau model pemulusan eksponensial telah digunakan untuk perhitungannya, ini tidak terjadi ketika menghitung interval prediksi, yang memerlukan keberadaan model statistik yang mendasari untuk dihitung secara teoritis.

Pengenalan kelas model ruang-negara dengan satu sumber kesalahan yang metode pemulusan eksponensialnya optimal memberikan dasar statistik yang kuat untuk perhitungan interval prediksi. Secara khusus, kesetaraan ini memungkinkan penurunan ekspresi analitik yang tepat untuk varians kesalahan perkiraan yang dapat digunakan untuk membangun interval prediksi satu atau beberapa langkah ke depan [18]. Setelah varians untuk kesalahan perkiraan dihitung, interval prediksi biasanya ditentukan menurut (22) dengan yang tidak diketahui diganti dengan perkiraan mereka. Karena pengaruh kesalahan estimasi pada prediksi diabaikan, interval prediksi tersebut cenderung terlalu sempit.

Masalah kesalahan estimasi ini sebagian dapat diatasi dengan menggunakan formulasi linier untuk model aditif Holt-Winters [5]. Perhatikan bahwa dalam bab ini kita bekerja dengan tren teredam,  $\theta = (\alpha, \beta, \gamma, \phi)'$  menjadi vektor parameter redaman dan pemulusan. Namun demikian, hasil serupa dapat diperoleh dengan menggunakan formulasi linier yang sesuai dengan model aditif Holt-Winters dengan tren teredam, yang diberikan oleh (16). Biarkan  $y_{obs}$  menjadi  $n \times 1$  vektor data yang diamati dan  $y_{pred}$  vektor  $h \times 1$  data masa depan. Pertimbangkan sendiri  $(n + h) \times 1$  vektor  $(y'_{obs}, y'_{pred})'$  dan misalkan masih mengikuti distribusi yang diberikan oleh (16), di mana vector  $\varepsilon$  dan matriks  $M$  dan  $L$  dipartisi dengan cara yang sama dengan vektor  $(y_{obs}, y_{pred})'$ , yaitu:

$$\begin{pmatrix} y_{obs} \\ y_{pred} \end{pmatrix} = \begin{pmatrix} M_1 \\ M_2 \end{pmatrix} \psi + \begin{pmatrix} L_1 & 0 \\ L_{21} & L_2 \end{pmatrix} \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \end{pmatrix}$$

Berdasarkan asumsi tersebut, distribusi kondisional  $y_{pred}$  yang diberikan  $y_{obs}$  adalah multivariat Normal dengan mean  $\mu_{2,1}$  dan matriks kovarians  $\Sigma_{2,1}$  diberikan oleh [5]:

$$\begin{aligned} \mu_{2,1} &= M_2 \psi + L_{21} L_1^{-1} (y_{obs} - M_1 \psi) \\ \Sigma_{2,1} &= \Sigma_{22} - \Sigma_{21} \Sigma_{11}^{-1} \Sigma_{12} \\ &= \sigma^2 L_2 L_2' \end{aligned}$$

Prakiraan titik kemudian diberikan oleh penaksir dari rata-rata prediksi 2.1, misalnya penaksir dihitung sebagai:

$$\hat{\mu}_{2.1} = M_2\hat{\psi} + \hat{L}_{21}\hat{L}_1^{-1}(y_{obs} - M_1\hat{\psi}) \quad (23)$$

Perhatikan itu  $\hat{L}_1^{-1}(y_{obs} - M_1\hat{\psi})$  adalah vektor kesalahan yang diamati satu langkah di depan, sehingga vektor peramalan yang diberikan oleh (23) setuju dengan prediktor Holt-Winters biasa, tetapi dihitung menggunakan perkiraan kemungkinan maksimum  $\psi$  dan  $\vartheta$  yang diperoleh di Bagian 3.2, lihat (18) dan (19).

Untuk menghitung interval prediksi, distribusi vektor acak  $y_{pred} - \hat{\mu}_{2.1}$  harus dihitung. Misalkan vektor parameter pemulusan  $\theta$  diketahui, vektor  $y_{pred} - \hat{\mu}_{2.1}$  diberikan oleh:

$$\begin{aligned} y_{pred} - \hat{\mu}_{2.1} &= M_2\psi + L_{21}\varepsilon_1 + L_2\varepsilon_2 - M_2\hat{\psi} - L_{21}\hat{L}_1^{-1}(M_1\psi + L_1\varepsilon_1 - M_1\hat{\psi}) \\ &= M_2(\psi - \hat{\psi}) + L_2\varepsilon_2 - L_{21}\hat{L}_1^{-1}M_1(\psi - \hat{\psi}) \\ &= M_{2.1}(\psi - \hat{\psi}) + L_2\varepsilon_2 \end{aligned} \quad (24)$$

Dimana  $M_{2.1} = M_2 - L_{21}\hat{L}_1^{-1}M_1$ .

Dalam hal itu, dengan  $\theta$  diketahui  $\hat{\psi}$ , adalah penduga kuadrat terkecil biasa, sehingga tidak bias dan variansnya diberikan oleh  $\sigma^2(X'X)^{-1}$ . Selain itu, karena ini semata-mata merupakan fungsi dari vektor acak  $\varepsilon_1$ , tidak bergantung pada  $\varepsilon_2$ , kedua penjumlahan pada (24) adalah bebas. Karenanya:

$$\begin{aligned} E(y_{pred} - \hat{\mu}_{2.1}) &= M_{2.1}E(\psi - \hat{\psi}) + L_2E(\varepsilon_2) = 0 \\ V(y_{pred} - \hat{\mu}_{2.1}) &= M_{2.1}V(\psi - \hat{\psi})M_{2.1}' + L_2V(\varepsilon_2)L_2' \\ &= \sigma^2 \left[ M_{2.1}(M_1'L_1'^{-1}L_1^{-1}M_1)^{-1}M_{2.1}' + L_2L_2' \right] \end{aligned}$$

Misalkan  $v \neq 0$  sembarang vektor konstanta yang diketahui, dan  $S = \sigma^{-2}V(y_{pred} - \hat{\mu}_{2.1})$ . Distribusi variabel acak  $t_v$  didefinisikan sebagai:

$$t_v = \sqrt{\frac{n-s-1}{n}} \frac{1}{\hat{\sigma}} (v'Sv)^{-\frac{1}{2}} v'(y_{pred} - \hat{\mu}_{2.1}) \quad (25)$$

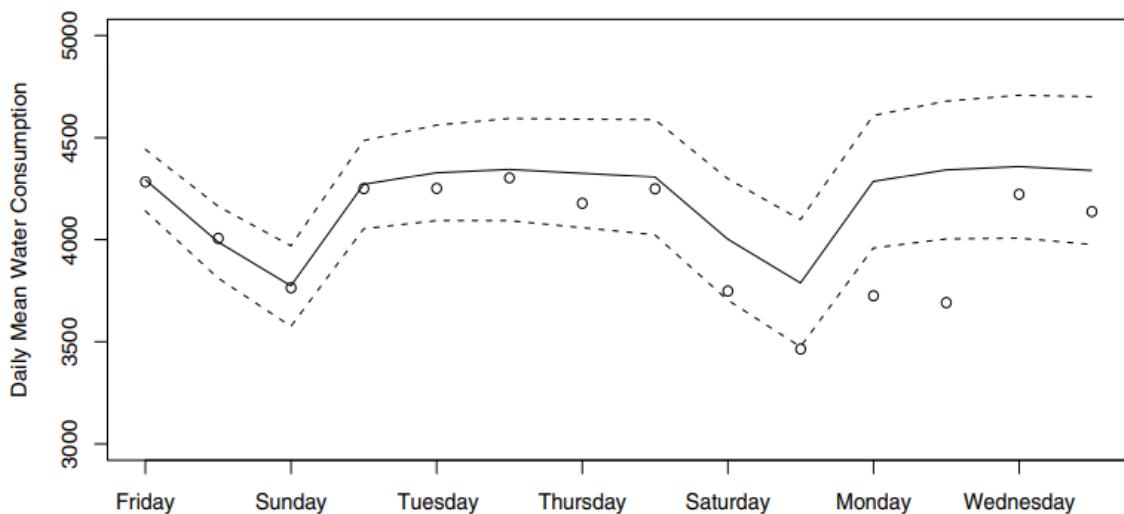
adalah distribusi t-Student dengan  $n - s - 1$  derajat kebebasan [5]. Hasil ini memungkinkan diperolehnya interval prediksi yang tepat untuk tujuan yang berbeda. Misalkan, interval prediksi satu langkah ke depan dibangun menggunakan  $v = (1, 0, \dots, 0)'$ , sedangkan interval prediksi kumulatif untuk  $h$  langkah pertama diperoleh dengan menggunakan  $v = (1, 1, \dots, 1)'$ . Interval untuk kombinasi linear lainnya dari prediksi dapat diperoleh dengan cara yang sama.

Dalam kasus biasa di mana  $\theta$  tidak diketahui, penulis mengusulkan untuk mendapatkan perkiraan interval prediksi menggunakan (25) dengan bukan , pendekatan V ( $y_{pred} - \hat{\mu}_{2.1}$ ) dengan:

$$\hat{\sigma}^2 \left[ (M_2 - \hat{L}_{21} \hat{L}_1^{-1} M_1)(M_1' \hat{L}_1'^{-1} \hat{L}_1^{-1} M_1)^{-1} (M_2 - \hat{L}_{21} \hat{L}_1^{-1} M_1)' + \hat{L}_2 \hat{L}_2' \right]$$

Perhatikan bahwa penjumlahan kedua dalam matriks kovarians ini,  $\hat{\sigma}^2 \hat{L}_2 \hat{L}_2'$ , adalah varians biasa yang diusulkan untuk menghitung interval prediksi yang digunakan untuk memberikan interval yang terlalu sempit. Varians di atas lebih besar karena mereka memasukkan ketidakpastian tentang kondisi awal deret, dan karenanya intervalnya harus lebih lebar.

Gambar 4 menunjukkan perkiraan titik, garis padat, dan interval prediksi 80%, garis putus-putus, dari 1 Oktober hingga 14 Oktober untuk kumpulan data konsumsi air rata-rata harian. Data yang diamati diplot sebagai lingkaran kecil; semua kecuali tiga dari mereka berada di dalam interval prediksi.



**Gambar 8.4** Prakiraan titik dan interval prediksi 80% menggunakan formulasi linier kami untuk model aditif Holt-Winters tanpa tren teredam

## 8.6 SIOPRED-BAYES

Dalam beberapa aplikasi seperti pengendalian persediaan, tujuan utama analis adalah peramalan interval. Interval prediksi, yang mengukur tingkat kredibilitas pada prakiraan titik, memungkinkan kontrol proses pengisian dan pengaturan tingkat stok pengaman yang sesuai. Ketika bekerja dengan metode pemulusan eksponensial sebagai prosedur ad hoc untuk mendapatkan prakiraan deret waktu yang diamati, SIOPRED dirancang sebagai perangkat lunak canggih dan terintegrasi yang menggabungkan prediksi titik dan interval. Interval prediksi tersebut, yang didekati melalui prosedur simulasi berdasarkan kesalahan pemasangan yang diamati, membantu menilai ketidakpastian masa depan, tetapi mungkin tidak cukup akurat tergantung pada kebutuhan analis.

Studi sebelumnya tentang interval prediksi untuk model pemulusan eksponensial menunjukkan bahwa mereka cenderung terlalu sempit, sehingga cakupan empirisnya jauh dari yang nominal. Hal ini terutama disebabkan oleh fakta bahwa rumus yang berbeda yang

diusulkan untuk memperoleh interval prediksi tidak memperhitungkan ketidakpastian dalam model karena tidak diketahui [29, 19, 18]. Interval prediksi yang lebih memuaskan diperoleh ketika memasukkan kesalahan estimasi dari kedua kondisi awal dan varians dari kesalahan [5]. Bahkan, mereka berperilaku cukup baik ketika parameter pemulusan untuk tren, , adalah nol, tetapi sebaliknya mereka masih terlalu sempit.

SIOPRED-Bayes, sistem pendukung peramalan Bayesian yang melengkapi SIOPRED, dirancang dalam upaya untuk mendapatkan interval prediksi yang akurat. Paradigma Bayesian memungkinkan kita untuk mendapatkan distribusi probabilitas untuk semua parameter dalam model, mewakili ketidakpastian tentang semua yang tidak diketahui setelah data diamati. Dengan menggunakan distribusi tersebut dan beberapa kalkulus probabilitas dasar, distribusi prediktif yang bebas dari parameter yang tidak diketahui dapat diperoleh. Distribusi ini, yang merangkum semua informasi mengenai data masa depan dari seri, memungkinkan kita untuk memperoleh perkiraan titik yang akurat, yang diberikan oleh rata-rata distribusi, dan interval prediksi yang andal pada setiap lag tertentu, dihitung dengan menggunakan kuantil yang sesuai dari distribusi prediksi [15].

Sistem ini menggabungkan semua model pemulusan eksponensial univariat yang ada serta beberapa generalisasi yang berhubungan dengan deret waktu positif dan data yang hilang. Oleh karena itu kebutuhan untuk memilih model terbaik untuk deret waktu tertentu. Masalah pemilihan model ini dapat diselesaikan secara memuaskan dengan menggunakan AIC, menggunakan estimasi Bayesian dari parameter dan bukan dari kemungkinan maksimum yang digunakan dalam Bagian 4. Pada beberapa kesempatan, pendekatan Bayesian mengarah pada masalah integrasi yang sulit diselesaikan secara analitis dan harus ditangani dengan menggunakan integrasi numerik. Berdasarkan formulasi linier untuk model Holt-Winters aditif [7], sistem harus berurusan dengan kalkulus matriks serta menggabungkan beberapa rutinitas optimasi dan simulasi. Semua prosedur ini dapat dengan mudah diimplementasikan dalam Bahasa R (<http://www.R-project.org>). Secara khusus, lihat [7] untuk detailnya, distribusi prediktif Bayesian diperoleh sebagai:

$$f(y_{pred}|y_{obs}) = \int_{\Theta} f(y_{pred}|y_{obs}, \theta) f(\theta|y_{obs}) d\theta \quad (26)$$

dimana  $f(\theta|y_{obs})$  adalah distribusi posterior dari vektor parameter pemulusan, yang sebanding dengan:

$$f(\theta|y_{obs}) \propto |X'X|^{-1/2} [(L_1^{-1}y_{obs})'(I - P_X)(L_1^{-1}y_{obs})]^{-(n-s-1)/2}$$

dan di mana  $f(y_{pred}|y_{obs}, \theta)$  adalah distribusi prediksi Bayesian jika diketahui, yang ternyata adalah  $St_h(m, V, n - s - 1)$ ; yaitu, distribusi t Student-variate h dengan  $n - s - 1$  derajat kebebasan dan vektor rata-rata dan matriks varian diberikan masing-masing oleh:

$$m = M_2 \tilde{\psi} + L_{21} L_1^{-1} (y_{obs} - M_1 \tilde{\psi}) \quad (27)$$

$$V = \frac{n-s-1}{n-s-3} \tilde{\sigma^2} (L_2 L_2' + M_{2.1} (X'X)^{-1} M_{2.1}') \quad (28)$$

menjadi  $\tilde{\sigma^2} = 1/(n-s-1) (L_1^{-1} y_{obs})' (I - P_X) (L_1^{-1} y_{obs})$  penaksir tak bias dari  $\sigma^2$  ketika  $\theta$  diketahui dan, seperti dalam Bagian 3, menjadi  $X = L_1^{-1} M_1$ ,  $\tilde{\psi} = (X'X)^{-1} X' L_1^{-1} y_{obs}$  penaksir kuadrat terkecil dari  $\psi$  ketika  $\theta$  diketahui,  $M_{2.1} = M_2 + L_{21} L_1^{-1} M_1$  dan  $P_X = X(X'X)^{-1} X'$ .

Karena tidak ada pendekatan analitis untuk karakteristik distribusi posterior  $f(\theta | y_{obs})$  yang tampaknya layak, kami mengusulkan algoritma simulasi untuk mendapatkan sampel acak berukuran  $N$  darinya,  $\{\theta_1, \dots, \theta_N\}$ , yang akan digunakan untuk mendapatkan pendekatan Monte Carlo untuk (26):

$$f(y_{pred} | y_{obs}) \approx \frac{1}{N} \sum_{i=1}^N St_h(m_i, V_i, n-s-1)$$

di mana  $m_i$  dan  $V_i$  diberikan oleh (27) dan (28) masing-masing dihitung pada  $\vartheta = \vartheta_i$ .

Prakiraan univariat pada lag tertentu atau prakiraan kumulatif diperoleh sebagai kasus tertentu dari transformasi linier umum  $v'y_{pred}$  yang telah diperkenalkan di bagian sebelumnya. Distribusi prediktif Bayesian dari kombinasi linier semacam itu juga dapat didekati dengan campuran distribusi t univariat:

$$f(v'y_{pred} | y_{obs}) \approx \frac{1}{N} \sum_{i=1}^N St(v'm_i, v'V_i v, n-s-1) \quad (29)$$

Prakiraan titik Bayesian, ekspektasi distribusi prediktif, dapat didekati dengan ekspektasi campuran distribusi tersebut:

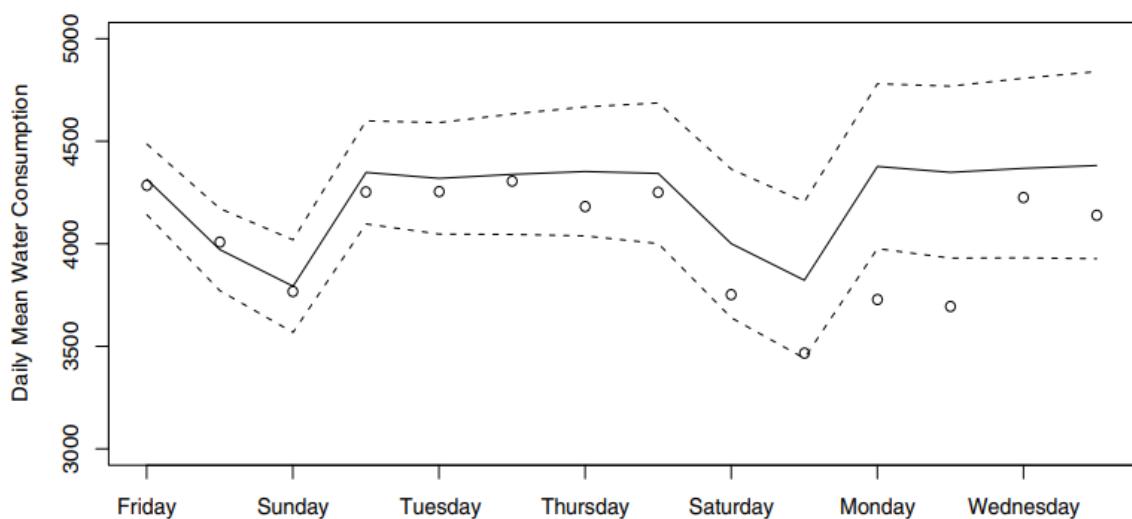
$$E(v'y_{pred} | y_{obs}) \approx \frac{1}{N} \sum_{i=1}^N v'm_i$$

Interval prediksi Bayesian untuk  $v'y_{pred}$  juga dapat didekati dengan menggunakan kuantil yang sesuai dari campuran di atas (29). Kuantil orde  $\omega$ ,  $q_\omega$ , adalah solusi dari persamaan

$$\frac{1}{N} \sum_{i=1}^N F_i(q_\omega) = \omega$$

di mana  $F_i$  adalah fungsi distribusi dari distribusi t Student univariat  $St(v'm_i, v'V_iv, n - s - 1)$ . Persamaan tersebut tidak memiliki solusi analitik, tetapi mudah diselesaikan dengan menggunakan metode numerik karena setiap kuantil adalah satu-satunya nol dari fungsi nyata naik monoton kontinu.

Gambar 5 menunjukkan perkiraan titik Bayesian, garis padat, dan interval prediksi Bayesian 80%, garis putus-putus, dari 1 Oktober hingga 14 Oktober untuk kumpulan data konsumsi air rata-rata harian. Data yang diamati diplot sebagai lingkaran kecil; semua kecuali dua dari mereka berada di dalam interval prediksi. Interval tersebut sangat mirip meskipun sedikit lebih lebar dari yang digambarkan pada Gambar 4. Alasannya adalah bahwa parameter tren pemulusan telah diperkirakan nol dan, dari studi empiris [5], ketika parameter tren pemulusan adalah nol interval prediksi diperoleh (25) digunakan untuk dikalibrasi dengan baik.



**Gambar 8.5** Prakiraan titik dan interval prediksi 80% menggunakan SIOPRED-Bayes untuk model aditif Holt-Winters tanpa tren teredam

## 8.7 KESIMPULAN

Dalam makalah ini kami telah mempresentasikan SIOPRED-Bayes, sistem pendukung peramalan berdasarkan skema pemulusan eksponensial. Sistem pendukung peramalan ini merupakan perpanjangan dari SIOPRED, yang merupakan antarmuka pengguna grafis yang mudah beradaptasi dan intuitif, adalah alat otomatis untuk menyediakan prakiraan dan interval prediksi yang sesuai yang dapat berguna dalam perencanaan produksi atau pengendalian inventaris. Ini juga memungkinkan pengguna untuk memperbaiki data historis dan bekerja dengan keluarga, periode agregat, dan referensi agregat.

Sedangkan perkiraan titik telah terbukti sangat akurat, interval prediksi, yang dihasilkan melalui prosedur bootstrap non-parametrik berdasarkan kesalahan pemasangan data historis, mungkin tidak cukup akurat untuk preferensi analis. Dalam hal ini, pendekatan Bayesian direkomendasikan. Kemudian, setelah memilih model pemulusan eksponensial univariat yang paling memadai untuk menggambarkan perilaku deret waktu tertentu, sistem menyediakan prakiraan titik dan interval prediksi yang akurat dari sudut pandang Bayesian.

## BAB 9

### U-TREE BERBASIS PENGUATAN: PENDEKATAN BARU UNTUK MENGATASI POMDP

Proses keputusan Markov yang dapat diamati sebagian (POMDP) menyediakan kerangka kerja matematis untuk perencanaan agen di bawah lingkungan stokastik dan sebagian yang dapat diamati. Solusi optimal Bayesian klasik dapat diperoleh dengan mentransformasikan masalah ke dalam proses keputusan Markov menggunakan status keyakinan. Namun, karena ruang keadaan keyakinan terus berlanjut, masalahnya sangat sulit dipecahkan. Banyak metode berbasis heuristik praktis yang diusulkan, tetapi kebanyakan dari mereka memerlukan pengetahuan awal yang lengkap tentang lingkungan. Artikel ini menyajikan algoritma pembelajaran penguatan berbasis memori, yaitu U-Tree berbasis penguatan, yang tidak hanya dapat mempelajari transisi status dari pengalaman, tetapi juga membangun model status dengan sendirinya berdasarkan input sensor mentah. Artikel ini menjelaskan peningkatan proses pembuatan status U-Tree asli untuk membuat model yang dihasilkan lebih ringkas, dan menunjukkan kinerjanya menggunakan tugas mengemudi mobil dengan 31.224 negara bagian dunia. Artikel ini juga menyajikan modifikasi pada uji statistik untuk estimasi imbalan, yang memungkinkan algoritme untuk dibandingkan dengan beberapa algoritme berbasis model dengan serangkaian masalah POMDP yang terkenal.

#### **9.1 PENDAHULUAN**

Salah satu ciri kecerdasan adalah kemampuan membuat keputusan yang tepat dalam berbagai keadaan. Oleh karena itu, sebagian besar penelitian Artificial Intelligence (AI) [1] dikhususkan untuk masalah pengambilan keputusan. Ada banyak pendekatan untuk memformalkan masalah. Karya awal AI menyebutnya perencanaan. Pendekatan dasarnya adalah untuk menangkap pengetahuan sebelumnya tentang lingkungan sebagai proposisi logis dan kemudian mengandalkan inferensi logis untuk membuat keputusan. Pendekatan lain berasal dari kontrol sistem. Richard Bellman, yang memberikan kontribusi mendasar untuk bidang ini, menciptakannya sebagai pemrograman dinamis (DP) [2]. Bentuk dasar dari masalah keputusan diformalkan sebagai proses keputusan Markov (MDP) di DP. MDP memodelkan lingkungan dan dinamikanya menggunakan status dan transisi status. Di setiap negara bagian, ada daftar tindakan yang tersedia untuk dipilih oleh agen. Setelah menjalankan satu tindakan dalam suatu keadaan, agen akan menerima imbalan skalar (atau biaya), dan transit ke keadaan lain. Tujuannya adalah untuk memaksimalkan akumulasi imbalan (atau meminimalkan total biaya yang dikeluarkan). Tidak seperti perencanaan AI tradisional, lingkungan dapat bersifat stokastik. Transisi keadaan di bawah setiap tindakan biasanya dijelaskan menggunakan matriks probabilitas. DP klasik menggunakan iterasi nilai [2, 3] untuk menyelesaikan MDP secara rekursif. Reinforcement Learning (RL) [4, 5] adalah ekstensi DP berbasis simulasi. Asumsi dasar RL untuk menyelesaikan MDP mirip dengan DP kecuali bahwa ia mempelajari probabilitas transisi keadaan dari pengalaman selama simulasi.

MDP mengasumsikan bahwa pada setiap langkah waktu, agen mengetahui secara pasti statusnya. Hal ini tidak selalu memungkinkan dalam praktik. Formulasi yang lebih realistik disebut proses keputusan Markov yang dapat diobservasi sebagian (POMDP) [6-10], di mana agen menerima pengamatan pada setiap langkah waktu, tetapi tidak dapat sepenuhnya menentukan keadaan mana berdasarkan pengamatan. Selain probabilitas transisi keadaan, model POMDP juga mencakup probabilitas menerima setiap pengamatan di semua keadaan. Solusi klasik untuk masalah POMDP adalah mengubahnya menjadi MDP keadaan kepercayaan berkelanjutan. Status keyakinan adalah vektor dengan setiap komponen yang berkorespondensi dengan satu status POMDP yang menunjukkan keyakinan agen berada dalam status yang sesuai. Mengetahui probabilitas pengamatan keadaan, agen dapat memperbarui keadaan kepercayaannya menggunakan teorema Bayes setelah menerima pengamatan pada setiap langkah waktu. Karena kepercayaan dapat berupa bilangan real apa pun dari nol hingga satu, ruang keadaan kepercayaan mungkin tidak terbatas. Namun, Sondik membuktikan bahwa seseorang dapat menyelesaikan MDP keadaan kepercayaan dengan hanya mempertimbangkan representasi linier dan cembung dari estimasi fungsi nilai. Namun demikian, untuk mendapatkan solusi yang tepat dari POMDP masih sulit. Dapat ditunjukkan bahwa menemukan solusi optimal untuk masalah POMDP horizon hingga adalah sulit PSPACE [11], dan masalah horizon tak terbatas yang didiskon mungkin tidak dapat dihitung [12].

Ada banyak solusi heuristik dalam literatur [9, 12, 13] yang menawarkan solusi perkiraan. Sebagian besar algoritma memerlukan pengetahuan awal yang lengkap tentang lingkungan, yaitu matriks probabilitas transisi status lengkap, matriks observasi status, dan matriks reward status tindakan. Namun, lingkungan mungkin terlalu kompleks atau tidak diketahui, dan oleh karena itu diperlukan agen cerdas untuk menjelajahinya dengan informasi awal yang minimal. Artikel ini menyajikan algoritme pembelajaran penguatan berbasis memori yang mempelajari model MDP lengkap berdasarkan pengetahuan awal minimum dan pengalaman sensor mentah. Algoritma ini diturunkan dari U-Tree McCallum [14]. McCallum mengusulkan tugas mengemudi jalan raya yang menarik sebagai patokan. Artikel ini memberikan analisis formal dari tugas ini menggunakan pemrograman dinamis hadiah rata-rata klasik [15, 16], yang menentukan jumlah tepat negara bagian dunia, dan memperoleh solusi optimal teoretis. Artikel tersebut juga mengusulkan modifikasi prosedur pembangkitan keadaan U-Tree untuk meningkatkan efektivitas model keadaan. Iterasi nilai hadiah yang didiskon di U-Tree asli diganti dengan iterasi nilai hadiah rata-rata [17] untuk menyelesaikan tugas mengemudi mobil. Tujuan dari modifikasi ini adalah pertama untuk menunjukkan bahwa efektif untuk menerapkan metode pemrograman dinamis klasik yang lebih kuat secara teoritis untuk model yang dihasilkan U-Tree untuk menyelesaikan tugas-tugas kompleks. Dan kedua, ini dapat menunjukkan dengan lebih baik keefektifan model yang dihasilkan U-Tree versus proses dinamis yang mendasarinya yang sebenarnya dengan membandingkan solusi terkait yang dihasilkan menggunakan algoritma yang sama (yaitu pemrograman dinamis hadiah rata-rata). Meskipun tugas mengemudi mobil memiliki ruang keadaan dan ruang sensor yang besar, semua pengamatan dan tindakan bersifat deterministik, yang tidak benar dalam banyak masalah POMDP. Oleh karena itu, algoritma ini diuji lebih lanjut dengan menggunakan banyak masalah POMDP yang terkenal sebagai benchmark. Hasilnya menunjukkan bahwa U-Tree yang dimodifikasi, dengan pengetahuan awal yang minimum,

masih memiliki kinerja yang sebanding dengan beberapa metode heuristik keadaan keyakinan.

Artikel ini disusun sebagai berikut. Bagian 2 memberikan pengenalan singkat tentang latar belakang matematika yang diperlukan dari MDP dan POMDP. Beberapa algoritma benchmark yang digunakan dalam bab ini akan dijelaskan pada bagian 2.7. Algoritma U-Tree pertama kali akan diperkenalkan di bagian 3, di mana modifikasi algoritma juga disorot. Bagian 4 secara resmi menyajikan algoritma U-Tree yang dimodifikasi. Tugas mengemudi mobil dan eksperimen benchmark POMDP lainnya dijelaskan di bagian 5. Hasil eksperimen dianalisis lebih lanjut di bagian 6, dan beberapa potensi peningkatan diusulkan. Bagian 7 menyimpulkan seluruh artikel.

## 9.2 PROSES KEPUTUSAN MARKOV

Proses keputusan Markov (MDP) adalah kerangka matematika dasar untuk memecahkan masalah pengambilan keputusan. Di bawah MDP konvensional, lingkungan dimodelkan menggunakan status diskrit, yang menangkap semua informasi yang diperlukan agen untuk membuat keputusan. Seluruh proses diasumsikan berkembang dalam langkah-langkah waktu diskrit. Dalam setiap langkah waktu, agen sepenuhnya menyadari keadaan lingkungan saat ini. Ada serangkaian tindakan yang tersedia bagi agen untuk dipilih di setiap negara bagian. Tindakan agen akan menyebabkan lingkungan berubah ke keadaan berikutnya dan menghasilkan hadiah skalar.

Secara formal, MDP didefinisikan menggunakan tuple  $(S, A, M, R)$  dimana:

- $S$  adalah himpunan berhingga keadaan;
- $A$  adalah serangkaian tindakan yang terbatas;
- $M : S \times A \times S \rightarrow [0,1]$  adalah fungsi transisi keadaan.  $M(s, a, s')$  memberikan probabilitas tiba keadaan  $s'$  dengan mengeksekusi tindakan  $a$  dalam keadaan  $s$ . Untuk mematuhi hukum probabilitas  $\sum_{s' \in S} M(s, a, s') = 1$  for all  $s \in S$  ;
- $R : S \times A \rightarrow \mathbb{R}$  adalah fungsi penghargaan.  $R(s, a)$  mengembalikan hadiah skalar bernilai nyata setelah mengeksekusi aksi  $a$  dalam keadaan  $s$ .

Perhatikan bahwa probabilitas transisi status dan hadiah ditentukan sepenuhnya berdasarkan status dan tindakan saat ini, yang berarti bahwa agen dapat membuat keputusan hanya berdasarkan pengetahuan tentang status lingkungan saat ini. Properti ini disebut properti Markov.

Tujuan agen adalah menemukan kebijakan untuk memaksimalkan fungsi tujuan. Kebijakan adalah pemetaan keadaan ke tindakan, atau secara formal  $\pi_t : S \rightarrow A$  adalah fungsi yang memberikan tindakan setiap keadaan pada langkah waktu  $t$ . Jika state-action mapping tidak bergantung pada waktu, maka disebut kebijakan stasioner.

Ada banyak definisi fungsi tujuan yang berbeda tergantung pada apa yang ingin dimaksimalkan oleh agen. Beberapa yang paling umum adalah

- Jumlah imbalan yang diharapkan dari cakrawala-terbatas, yang didefinisikan sebagai:

$$\rho_{finite} = E \left\{ \sum_{t=0}^{n-1} R_t \right\}, \quad (1)$$

yang merupakan hadiah total selama n langkah waktu yang terbatas. Dalam MDP, horizon berarti jumlah langkah waktu yang harus ditempuh dari waktu saat ini, di mana fungsi tujuan didefinisikan.

- Jumlah diskon yang diharapkan dari cakrawala tak terbatas, yang didefinisikan sebagai:

$$\rho_{\text{discounted}} = E \left\{ \sum_{t=0}^{\infty} \gamma^t R_t \right\}, \quad (2)$$

di mana  $\gamma \in (0,1)$  adalah faktor diskon konstan yang mengontrol seberapa jauh agen akan melihat ke masa depan ketika merencanakan.

- Penghargaan rata-rata yang diharapkan dari cakrawala tak terbatas, didefinisikan sebagai:

$$\rho_{\text{average}} = \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{t=1}^N E \{ R_t \}, \quad (3)$$

yang merupakan imbalan yang diharapkan per langkah waktu, rata-rata selama jumlah langkah waktu yang tak terbatas.

### Nilai Iterasi

Ada banyak algoritma untuk menyelesaikan MDP. Yang paling umum disebut iterasi nilai. Untuk menurunkan algoritma ini, pertama-tama kita pertimbangkan masalah finite-horizon. Biarkan  $V_k(s)$  mewakili jumlah hadiah yang diharapkan mulai dari keadaan  $s$  dan lanjutkan untuk  $k$  langkah.  $V$  disebut juga fungsi nilai. Untuk  $k = 1$ , yaitu ketika hanya ada satu langkah waktu yang tersisa, nilai optimal hanyalah hadiah langsung maksimal

$$V_1^*(s) = \max_{a \in \mathcal{A}} R(s, a),$$

di mana '\*' menunjukkan optimalitas. Secara induktif, nilai step-to-go  $k$  optimal dapat diturunkan dari nilai step-to-go  $k-1$  optimal sebagai:

$$V_k^*(s) = \max_{a \in \mathcal{A}} \left\{ R(s, a) + \sum_{s' \in \mathcal{S}} M(s, a, s') V_{k-1}^*(s') \right\}, \quad (4)$$

di mana  $s$  adalah keadaan saat ini, dan  $s'$  berarti semua kemungkinan keadaan berikutnya. Dan kebijakan optimal yang sesuai hanyalah

$$\pi_k^*(s) = \arg \max_{a \in \mathcal{A}} \left\{ R(s, a) + \sum_{s' \in \mathcal{S}} M(s, a, s') V_{k-1}^*(s') \right\}.$$

Sangat mudah untuk melihat bahwa persamaan (4) adalah versi rekursif dari fungsi tujuan (1), dan karenanya menunjukkan bahwa kebijakan yang sesuai memaksimalkan fungsi Sistem Pendukung Keputusan (Dr Joseph Teguh Santoso dan Budi Hartono, M.Kom)

tujuan. Untuk mendapatkan nilai k step-to-go dan kebijakan yang optimal, hanya perlu menerapkan secara iteratif (4) sebanyak k-1 kali, oleh karena itu algoritma ini disebut dengan iterasi nilai.

Untuk memperluas algoritme ke masalah cakrawala tak terbatas, jumlah hadiah yang diharapkan harus terlebih dahulu dibatasi. Salah satu caranya adalah dengan menggunakan faktor diskonto seperti pada persamaan (2). Dan fungsi nilai optimal yang sesuai memenuhi persamaan Bellman yang didefinisikan sebagai:

$$V^*(s) = \max_{a \in \mathcal{A}} \left\{ R(s, a) + \gamma \sum_{s' \in \mathcal{S}} M(s, a, s') V^*(s') \right\}, \forall s \in \mathcal{S}. \quad (5)$$

Dengan jumlah persamaan  $|\mathcal{S}|$  dan jumlah yang tidak diketahui yang sama, kita dapat memecahkan nilai setiap keadaan. Salah satu cara untuk menyelesaiakannya adalah dengan menggunakan iterasi nilai yang mirip dengan (4). Bagi mereka yang akrab dengan teori sistem dinamik, persamaan (5) mendefinisikan peta non-linier1. Dapat ditunjukkan [17] bahwa persamaan (5) adalah peta kontraksi, yaitu:

$$\max_{s \in \mathcal{S}} |V_{k+1}(s) - V_k(s)| \leq \max_{s \in \mathcal{S}} |V_k(s) - V_{k-1}(s)|,$$

dan dengan demikian terdapat titik tetap, di mana nilai optimal V tercapai. Mungkin karena hubungan ini dengan teori sistem dinamik, Bellman [2] menyebut jenis metode ini untuk menyelesaikan pemrograman dinamis (DP) MDP.

Masalah imbalan rata-rata yang didefinisikan dalam persamaan (3) sedikit lebih rumit untuk dipecahkan. Dapat dibuktikan [17] bahwa jika suatu fungsi H(s) ada sedemikian rupa sehingga:

$$\rho + H(s) = \max_{a \in \mathcal{A}} \left\{ R(s, a) + \sum_{s' \in \mathcal{S}} M(s, a, s') H(s') \right\}, \forall s \in \mathcal{S}, \quad (6)$$

maka konstanta  $\rho$  sama dengan imbalan rata-rata optimal, yaitu  $\rho = \max\{\rho_{\text{average}}\}$ , di mana  $\rho_{\text{average}}$  didefinisikan dalam (3). Fungsi H disebut fungsi nilai relatif, karena memainkan peran yang sama seperti V dalam masalah hadiah yang didiskon. H(s) adalah jumlah selisih yang diharapkan antara rata-rata reward optimal dan reward yang diterima pada setiap state mulai dari state s, yang dapat lebih mudah dilihat jika persamaan (6) disusun ulang sebagai:

$$H(s) = \max_{a \in \mathcal{A}} \left\{ (R(s, a) - \rho) + \sum_{s' \in \mathcal{S}} M(s, a, s') H(s') \right\}. \quad (7)$$

Agar solusi H(s) ada, masalah harus memiliki nilai optimal identik yang tidak bergantung pada keadaan awal. Salah satu syarat untuk menjamin hal tersebut adalah adanya kebijakan yang stasioner sehingga memungkinkan untuk mencapai suatu state mulai dari state lainnya [17].

Atau secara formal, untuk setiap dua keadaan  $s$  dan  $s'$ , terdapat kebijakan stasioner (tergantung pada  $s$  dan  $s'$ ) sedemikian sehingga untuk beberapa waktu indeks  $t$ ,

$$\Pr(s_t = s | s_0 = s', \pi) > 0. \quad (8)$$

Untuk menyelesaikan  $n-1$  yang tidak diketahui dalam  $n$  persamaan di (7), kita dapat memilih keadaan arbitrer  $s^*$  sebagai keadaan referensi, memperbaiki  $H(s^*)$  ke nol, dan kemudian menyelesaikan yang tidak diketahui lainnya. Salah satu metode iterasi nilai untuk menyelesaikan masalah penghargaan rata-rata dijelaskan dalam [17] sebagai:

$$H_k(s) = (1 - \tau)H_{k-1}(s) + \max_{a \in \mathcal{A}} \left\{ R(s, a) + \tau \sum_{s' \in \mathcal{S}} M(s, a, s') H_{k-1}(s') \right\} - \max_{a \in \mathcal{A}} \left\{ R(s^*, a) + \tau \sum_{s' \in \mathcal{S}} M(s^*, a, s') H_{k-1}(s') \right\}, \quad (9)$$

di mana  $\tau \in (0, 1)$  adalah konstanta. Hadiah rata-rata yang optimal dapat diturunkan dari  $H(s)$  sebagai:

$$\rho = \lim_{k \rightarrow \infty} \max_{a \in \mathcal{A}} \left\{ R(s^*, a) + \tau \sum_{s' \in \mathcal{S}} M(s^*, a, s) H_k(s) \right\}. \quad (10)$$

### Iterasi Kebijakan

Metode serupa lainnya untuk menyelesaikan MDP disebut iterasi kebijakan. Ini terdiri dari dua langkah. Yang pertama disebut evaluasi kebijakan, yang mengevaluasi nilai kebijakan tertentu menggunakan iterasi

$$V_k^\pi(s) = R(s, \pi(s)) + \gamma \sum_{s' \in \mathcal{S}} M(s, a, s') V_{k-1}^\pi(s'),$$

yang mirip dengan iterasi nilai (5), dan keberadaan dan bukti konvergensi yang sama ada. Langkah kedua disebut perbaikan kebijakan, yang pertama menghitung nilai tindakan sebagai

$$Q^\pi(s, a) = R(s, a) + \gamma \sum_{s' \in \mathcal{S}} M(s, a, s') V^\pi(s'),$$

di mana  $Q$  adalah nilai dari mengambil tindakan  $a$  di negara bagian  $s$  dan kemudian mengikuti kebijakan  $\pi$  dan seterusnya. Kebijakan tersebut dapat ditingkatkan sebagai

$$\pi'(s) = \arg \max_{a \in \mathcal{A}} Q^\pi(s, a)$$

Kedua langkah tersebut diulangi sampai  $\pi' = \pi$ .

### Penguatan Pembelajaran

Ada situasi di mana model MDP tidak lengkap, dan agen harus mempelajari transisi status M dan status penghargaan R dari pengalaman. Jenis masalah ini umumnya dikategorikan dengan nama pembelajaran penguatan (RL). Salah satu algoritma RL yang paling representatif disebut Q-learning [18], yang memperbarui nilai Q secara iteratif. Iterasi untuk masalah horizon tak terbatas yang didiskon didefinisikan sebagai:

$$Q_k(s, a) = Q_{k-1}(s, a) + \alpha \left( r + \gamma \max_{a' \in A} Q_{k-1}(s', a') - Q_{k-1}(s, a) \right),$$

di mana  $\alpha \in (0,1)$  adalah konstanta yang menentukan laju pembelajaran, r dan s' adalah imbalan langsung yang diamati dan keadaan berikutnya setelah menjalankan tindakan a dalam keadaan s selama pengalaman atau simulasi yang sebenarnya. Dapat dibuktikan bahwa nilai Q akan konvergen ke  $Q^{\pi^*}$  dari kebijakan optimal  $\pi^*$  selama semua pasangan state dan aksi sering dikunjungi tak terhingga [19]. Bertsekas [17] menjelaskan versi reward rata-rata dari Q-learning.

### Proses Keputusan Markov yang Dapat Diamati Sebagian

Dalam banyak aplikasi, agen mungkin tidak dapat mengidentifikasi keadaan lingkungan saat ini. Misalnya, saat menavigasi melalui lorong, robot yang dilengkapi dengan sensor untuk mendeteksi dinding mungkin bingung di persimpangan yang memiliki konfigurasi dinding yang sama persis. Selain itu, sensor mungkin rusak oleh kebisingan dan terkadang melaporkan dinding saat tidak ada dinding, yang membuat identifikasi status menjadi lebih sulit. Proses keputusan Markov yang dapat diamati sebagian (POMDP) memberikan kerangka matematika yang lebih realistik untuk memformalkan masalah.

Secara formal, model POMDP dideskripsikan oleh sebuah tuple  $(S, A, M, R, \Theta, O, b_0)$ , dimana:

- S, A, M, R sama dengan MDP;
- $\Theta$  adalah sekumpulan observasi;
- $O: S \times A \times \Theta \rightarrow [1, 0]$  adalah himpunan distribusi probabilitas yang menggambarkan hubungan antara tindakan, keadaan dan pengamatan.  $O(s', a, o)$  memberikan probabilitas menerima pengamatan o dalam keadaan s' setelah melakukan tindakan a, dan  $\sum_{o \in \Theta} O(s', a, o) = 1, \forall s' \in S$ ;
- $b_0: S \rightarrow [1, 0]$  adalah distribusi probabilitas dari keadaan awal.

Tujuan agen masih sama seperti di MDP, di mana fungsi tujuan yang didefinisikan masih berlaku.

Cara tradisional untuk menyelesaikan POMDP adalah dengan mengubah masalah menjadi MDP ruang keadaan kontinu menggunakan keadaan keyakinan. Keadaan kepercayaan adalah vektor dengan ukuran  $|S|$ , di mana setiap komponen mewakili keyakinan berada dalam status MDP yang sesuai. Biarkan b menjadi vektor seperti itu. Persamaan pembaruan keadaan dapat diturunkan menggunakan teorema Bayes sebagai:

$$b_a^o(s') = \frac{O(s', a, o) \sum_{s \in S} M(s, a, s') b(s)}{\Pr(o | a, b)}, \quad (11)$$

di mana  $b_a^o(s')$  memberikan probabilitas berada dalam keadaan  $s'$  setelah melakukan tindakan  $a$  dan menerima pengamatan  $o$  dalam keadaan kepercayaan lama  $b$ , dan  $b_a^o$  adalah keadaan kepercayaan berikutnya.  $\Pr(o|a,b)$  adalah konstanta re-normalisasi yang sama dengan probabilitas mengamati  $o$  dalam keadaan keyakinan  $b$  setelah menjalankan tindakan  $a$ . Karena persamaan pembaruan status keyakinan (11) hanya memerlukan pengamatan dan tindakan saat ini, persamaan ini memenuhi properti Markov, dan dengan demikian mengubah POMDP menjadi MDP status keyakinan. Cakrawala tak terbatas yang sesuai, iterasi nilai hadiah diskon yang diharapkan didefinisikan sebagai:

$$V_k(b) = \max_{a \in \mathcal{A}} \left\{ \sum_{s \in \mathcal{S}} R(s, a)b(s) + \gamma \sum_{o \in \Theta} \Pr(o|a, b)V_{k-1}(b_a^o) \right\}. \quad (12)$$

### Nilai Iterasi untuk POMDP

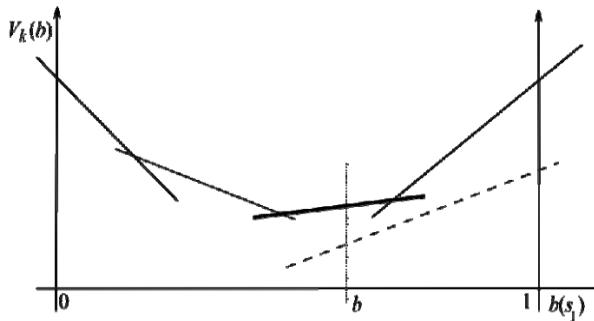
Berbeda dengan MDP konvensional, MDP keadaan-keyakinan memiliki ruang keadaan kontinu, yang mungkin memiliki jumlah keadaan yang tak terhitung. Oleh karena itu, memecahkan MDP negara-keyakinan tidak mudah. Namun, gagasan umum tentang iterasi nilai masih berlaku. Menurut [20], untuk finite horizon POMDP, nilai optimal fungsi  $V^*$  adalah piecewise linear and convex (PWLC), dan untuk tugas-tugas horizon tak terbatas dapat didekati secara arbitrer dengan baik oleh fungsi PWLC. Mewakili setiap segmen garis (lihat Gambar 1 untuk contoh plot fungsi PWLC untuk masalah 2 keadaan) menggunakan vektor ukuran  $|\mathcal{S}|$ , fungsi nilai langkah-ke-pergi PWLC  $k$  dapat ditulis sebagai:

$$V_k(b) = \max_{\alpha_k \in \Gamma_k} \sum_{s \in \mathcal{S}} b(s)\alpha_k(s), \quad (13)$$

di mana  $\Gamma_k$  adalah himpunan terbatas vektor yang mewakili semua segmen garis dalam fungsi nilai PLWC step-to-go  $k$ . Setiap vektor  $\alpha_k$  berasosiasi dengan aksi  $a_\alpha$  menunjukkan tindakan yang harus diambil untuk mencapai nilai yang sesuai yang diwakili oleh vektor yang sesuai. Agar iterasi nilai (12) berfungsi, kita perlu menyatakan pembaruan  $V_k$  dalam bentuk vektor  $\Gamma_{k-1}$  di himpunan  $k-1$  dengan mensubstitusi (13) ke (12) dan mendapatkan

$$\begin{aligned} V_k(b) &= \max_{a \in \mathcal{A}} \left\{ \sum_{s \in \mathcal{S}} R(s, a)b(s) + \gamma \sum_{o \in \Theta} \Pr(o|a, b) \max_{a \in \Gamma_{k-1}} \sum_{s' \in \mathcal{S}} b_a^o(s')\alpha(s') \right\} \\ &= \max_{a \in \mathcal{A}} \left\{ \sum_{s \in \mathcal{S}} R(s, a)b(s) + \gamma \sum_{o \in \Theta} \max_{a_{k-1} \in \Gamma_{k-1}} \sum_{s' \in \mathcal{S}} [\Pr(o|a, b)b_a^o(s')] \alpha(s') \right\} \\ &= \max_{a \in \mathcal{A}} \left\{ \sum_{s \in \mathcal{S}} R(s, a)b(s) + \gamma \sum_{o \in \Theta} \max_{\alpha_{k-1} \in \Gamma_{k-1}} \sum_{s' \in \mathcal{S}} \left[ O(s', a, o) \sum_{s \in \mathcal{S}} M(s, a, s')b(s) \right] \alpha(s') \right\} \end{aligned} \quad (14)$$

dimana persamaan terakhir diperoleh dengan mensubstitusikan dengan (11).



**Gambar 9.1** Fungsi nilai PWLC untuk POMDP dua keadaan.

Hanya perlu untuk menunjukkan kepercayaan dari satu keadaan  $b(s_1)$ . Setiap segmen garis sesuai dengan vektor  $\alpha$ . Perhatikan bahwa dalam setiap iterasi, beberapa vektor yang baru dibuat (ditunjukkan dalam garis putus-putus) mungkin sepenuhnya didominasi oleh yang lain. Setiap vektor yang mendominasi memaksimalkan fungsi nilai dalam wilayah ruang kepercayaan.

Untuk menyelesaikan persamaan (14) dengan tepat, salah satu solusi yang mungkin adalah menghitung semua cara yang mungkin untuk membangun vektor langkah berikutnya  $\alpha_k$  dari  $\alpha_{k-1}$  [8]. Ukuran vektor yang baru dibangkitkan pada setiap iterasi nilai adalah eksponensial dalam ukuran observasi. Tidak semua vektor yang dihasilkan diperlukan, karena beberapa di antaranya mungkin sepenuhnya didominasi oleh yang lain (lihat Gambar 1). Banyak algoritma yang menggunakan ide generate-and-test ini bertujuan untuk menemukan cara yang efisien untuk memangkas vektor di setiap iterasi [8, 21]. Namun, ternyata tugas mengidentifikasi semua vektor yang berguna juga sulit [22].

Solusi lain yang mungkin adalah menghitung vektor yang mendominasi untuk satu set titik kepercayaan di setiap iterasi. Tangkapannya adalah, bagaimanapun, untuk menemukan semua titik kepercayaan sehingga vektor yang dihasilkan sepenuhnya menggambarkan fungsi PWLC. Algoritma jenis ini mencoba mengidentifikasi daerah-daerah dalam ruang keyakinan yang terdapat vektor-vektor yang mendominasi [10, 20].

### Metode Berbasis Heuristik untuk POMDP

Dapat ditunjukkan bahwa solusi tepat dari POMDP tidak dapat dipecahkan untuk tugas apa pun dengan ukuran yang wajar [12, 22]. Banyak metode heuristik diusulkan untuk mengatasi kendala komputasi [13, 23, 24]. Salah satu jenis metode awal adalah pertama-tama memecahkan MDP yang mendasarnya, dan menggunakan status keyakinan untuk menginterpolasi solusinya. Metode tipikal jenis ini disebut  $Q_{MDP}$  [25], yang mendekati nilai  $Q$  dari POMDP sebagai jumlah tertimbang dari nilai MDP  $Q$

$$Q(b, a) = \sum_{s \in S} b(s) Q_{MDP}(s, a).$$

Jenis metode ini memiliki keuntungan menjadi sangat cepat dan dengan demikian dapat menangani masalah yang jauh lebih besar. Namun, ia menderita asumsi bahwa ambiguitas negara diselesaikan setelah satu langkah, yaitu, bergantung pada nilai MDP optimal langkah berikutnya,  $Q_{MDP}$ , yang hanya dapat diperoleh jika ambiguitas negara berikutnya diselesaikan

sepenuhnya. Metode ini merupakan salah satu algoritma benchmark yang digunakan dalam artikel ini.

Perkembangan terakhir telah mengusulkan metode berbasis heuristik yang lebih canggih. Salah satu jenis metode [26-29] meminjam ide dari teknik pemangkasan pohon keputusan cabang-dan-terikat. Diagram transisi keadaan keyakinan dapat direpresentasikan dengan sebuah pohon. Algoritme biasanya mempertahankan batas atas dan batas bawah dari fungsi nilai optimal  $V^*$ , dan menerapkan penelusuran pertama yang mendalam ke pohon transisi status keyakinan untuk mengeksplorasi status keyakinan yang berguna untuk memperbarui batas. Pada contoh algoritma jenis ini, yang disebut HSVI [30], digunakan sebagai algoritma benchmark yang dijelaskan pada bagian 5.

Jenis utama lain dari metode berbasis heuristik yang baru-baru ini dikembangkan disebut iterasi nilai berbasis titik acak. Metode ini memilih satu set acak poin keyakinan menggunakan berbagai jenis heuristik untuk memperbarui fungsi nilai perkiraan [13, 31-33]. PBVI dari [34] digunakan sebagai algoritma benchmark di bagian 5.

### **Di luar POMDP**

Dalam kerangka POMDP, model lingkungan yang lengkap diasumsikan sebagai pengetahuan sebelumnya. Namun, asumsi ini mungkin tidak selalu praktis dalam penerapannya. Agen mungkin tidak mengetahui statistik transisi keadaan, yang dapat diselesaikan dengan menggunakan pendekatan berbasis simulasi seperti yang disebutkan di bagian 2.4. Masalahnya lebih sulit dipecahkan ketika agen tidak mengetahui ruang keadaan. Lingkungan terlalu kompleks atau kurang dieksplorasi, dan merupakan tugas agen untuk menjelajahinya. Yang diketahui agen hanyalah sensor yang dipasang dan tindakan yang dapat dilakukan.

Solusi paling sederhana adalah memperlakukan setiap pengamatan sebagai keadaan, dan mempelajari kebijakan berdasarkan itu. Jenis kebijakan ini disebut kebijakan reaktif, atau kebijakan tanpa memori [35-37]. Karena keterbatasan pengetahuan tentang dinamika lingkungan, hanya bergantung pada pengamatan saat ini dapat menyebabkan banyak ambiguitas dalam identifikasi keadaan. Ini disebut sebagai perceptual aliasing oleh [38]. Littman [39] secara formal mempelajari kebijakan reaktif, dan menunjukkan keterbatasan teoretisnya.

Dalam beberapa masalah, menggunakan memori pengamatan masa lalu dapat membantu menyelesaikan ambiguitas yang disebabkan oleh aliasing perceptual. Dan jika negara dapat diidentifikasi sepenuhnya, masalah POMDP dapat direduksi menjadi MDP. Ada banyak cara untuk mengatur memori. Yang paling mudah adalah dengan menggunakan jendela sejarah tetap, dan ukuran jendela diberikan sebagai parameter dari algoritma [36, 39]. Cara yang lebih canggih adalah dengan memiliki ukuran jendela variabel, dan biarkan algoritme belajar menyesuaikan ukuran jendela. Meuleau dkk. [40] menggunakan mesin keadaan terbatas sebagai pengontrol dengan ukuran jendela variabel. U-Tree, bagaimanapun, menyimpan semua pengalaman selama pelatihan, dan menggunakan pohon untuk mengatur memori.

## **9.3 U-TREE DAN U-TREE YANG DIMODIFIKASI**

### **Pengenalan U-Tree**

U-Tree adalah algoritma pembelajaran penguatan (RL) dalam arti belajar dari pengalaman. Tidak seperti kebanyakan algoritma RL konvensional, U-Tree tidak hanya mempelajari probabilitas transisi keadaan, tetapi juga representasi keadaan sebenarnya dari lingkungan. Model yang dipelajari memiliki properti Markov, yang berarti bahwa agen dapat mengidentifikasi statusnya saat ini hanya berdasarkan pengamatan saat ini. Algoritme membutuhkan pengetahuan awal yang minimal tentang lingkungan. Lebih khusus lagi, itu hanya membutuhkan satu set semua pengamatan dan tindakan yang mungkin. Fitur ini diperlukan dalam situasi di mana lingkungan terlalu kompleks untuk dimodelkan secara eksplisit, atau tidak diketahui dan ditargetkan untuk tugas eksplorasi.

U-Tree menyimpan pengalaman mentah sebagai instans. Setiap instance terdiri dari triple action-perception-reward, dan terhubung ke transisi sebelumnya dan berturut-turut dalam rantai waktu yang dipesan. Sebuah pohon dibangun untuk mengatur instance. Setiap daun pohon mewakili sebuah negara. Daun pohon bertindak sebagai ember, menampung sekelompok instance yang memiliki kesamaan fitur tertentu. Fitur ditentukan oleh node di jalan dari daun yang mengandung ke akar pohon. Setiap simpul interior pohon memperkenalkan perbedaan baru berdasarkan dua parameter: (1) dimensi persepsi, yang menunjukkan pengamatan individu mana yang akan dicocokkan ketika contoh baru ditambahkan ke dalam pohon, dan (2) indeks riwayat, yang menunjukkan berapa banyak waktu mundur dari waktu saat pengamatan akan diperiksa. Indeks sejarah nol menunjukkan pengamatan saat ini.

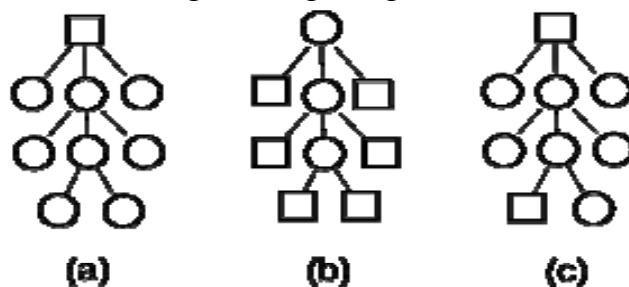
Pohon dibangun secara on-line selama pelatihan, mulai dari satu simpul akar, dan secara selektif menambahkan cabang hanya di mana perbedaan tambahan diperlukan. Untuk mengeksplorasi cabang potensial, agen membangun pinggiran, yang merupakan cabang tambahan di bawah daun yang ada. Node pinggiran, seperti node daun, juga bertindak sebagai ember untuk menampung instance yang cocok. Instance di fringe node diuji untuk perbedaan dalam distribusi ekspektasi diskon imbalan masa depan menggunakan uji Kolmogorov-Smirnov (K-S) [41]. Jika uji K-S menunjukkan bahwa instance berasal dari distribusi yang berbeda, maka masuk akal untuk percaya bahwa perbedaan ini dapat membantu agen untuk memprediksi hadiah. Node pinggiran yang sesuai kemudian menjadi daun resmi, dan pinggiran baru diperpanjang di bawahnya. Contoh-contoh yang terkandung dalam daun-daun tua dihilangkan dan digunakan untuk mengisi daun-daun baru. Untuk mencegah pertumbuhan kedalaman pohon yang eksponensial, simpul tepi barunya akan ditambahkan di bawah simpul yang telah mengumpulkan cukup banyak contoh.

### **Modifikasi Generasi Negara**

Menurut algoritme U-Tree asli, setelah simpul tepi menjadi daun, simpul induknya berhenti menjadi status, dan karena ini, semua saudara dari simpul status baru juga akan dipromosikan sebagai status sebelum waktunya, atau, beberapa contoh mungkin menjadi yatim piatu yang bukan milik simpul negara mana pun, yang akan melanggar properti Markov dari model yang dihasilkan. Situasinya bahkan lebih buruk ketika node status lama bukan merupakan induk langsung dari node yang baru dipromosikan, dalam hal ini semua node saudara di sepanjang jalur akan dipaksa menjadi status baru. Namun, diferensiasi keadaan prematur tersebut tidak dibenarkan secara statistik. Dan beberapa negara bagian baru mungkin berisi terlalu sedikit contoh untuk memiliki kekuatan prediksi yang berarti.

Modifikasi prosedur pembangkitan keadaan diusulkan untuk mengatasi masalah ini. Pertama, simpul akar selalu merupakan simpul keadaan, yang menghilangkan kemungkinan setiap instance yatim piatu. Sebuah node interior sekarang diperbolehkan untuk mewakili sebuah negara. Ketika fringe node menjadi node state resmi, ia mengambil kepemilikan dari semua instance yang ada di dalam dirinya sendiri (yaitu melepaskan instance tersebut dari semua node ancestornya), dan ancestor state node tetap menjadi state node kecuali jika tidak ada cukup instance yang tersisa untuk tes K-S. Prosedur penemuan keadaan juga dimodifikasi karena node keadaan interior. U-Tree asli hanya perlu melintasi pohon dari simpul akar, dan mengembalikan simpul keadaan pertama yang ditemui, karena hanya ada satu dan hanya satu simpul keadaan di jalurnya. Sementara dalam algoritma yang dimodifikasi, seseorang perlu melintasi semua jalan ke bawah dan mengembalikan node keadaan terakhir yang ditemui.

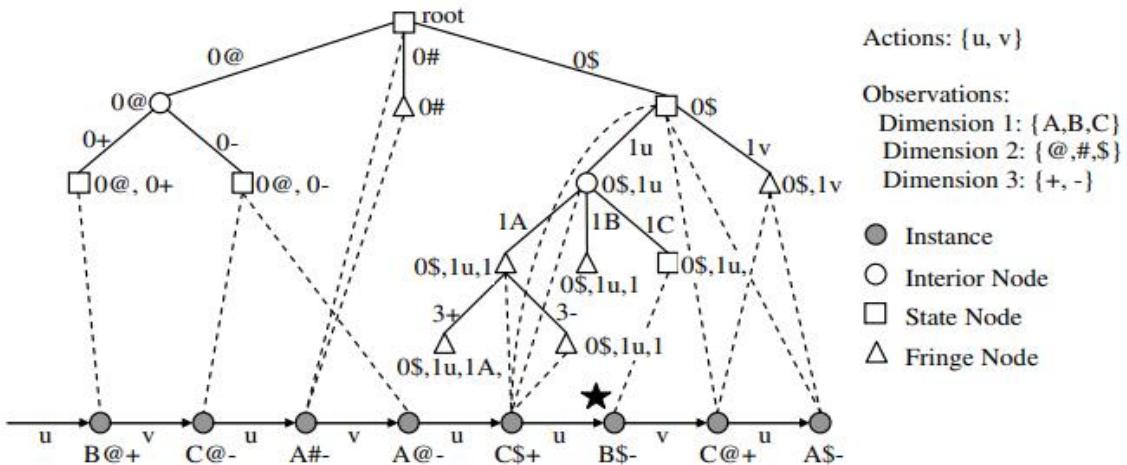
Gambar 2 menyoroti perbedaan yang dihasilkan oleh dua prosedur pembangkitan keadaan. Simpul persegi mewakili simpul keadaan. Dengan asumsi simpul pinggiran lingkaran abu-abu pada Gambar 2 (a) dipromosikan. Pohon asli akan mempromosikan semua saudara kandungnya dan semua saudara kandung simpul leluhurnya ke simpul status, yang menghasilkan Gambar 2 (b). Prosedur yang dimodifikasi hanya mempromosikan simpul yang disarankan oleh uji K-S, yang ditunjukkan pada Gambar 2 (c). Perhatikan betapa lebih sedikit status baru yang dihasilkan dibandingkan dengan algoritme asli.



**Gambar 9.2** Prosedur pembangkitan keadaan. Kotak mewakili simpul negara. (a) Node abu-abu akan dipromosikan sebagai node status baru. (b) Hasil dari U-Tree asli setelah promosi. (c) Hasil dari U-Tree yang dimodifikasi.

### Sebuah Ilustrasi

Bagian ini memberikan ilustrasi yang lebih detail mirip dengan yang ada di kertas U-Tree asli. Gambar 3 menggambarkan pohon dan rantai contoh berdasarkan tugas abstrak sederhana di mana agen dapat menjalankan dua tindakan (berlabel 'u' dan 'v') dan menerima pengamatan terdiri dari tiga jenis fitur (berlabel 'Dimensi 1', '2', dan '3'). Misalnya, dalam aplikasi keuangan, 'u' dan 'v' mungkin sesuai dengan 'beli' dan 'jual', sedangkan 'Dimensi 1' mungkin harga saham target, '2' menjadi volume, dan '3' bisa dari indeks pasar saham utama.



**Gambar 9.3** Contoh struktur pohon dan rantai instans yang dihasilkan oleh algoritma U-Tree yang dimodifikasi.

Setiap lingkaran abu-abu mewakili pengamatan yang diperoleh dalam satu langkah waktu, dan panah di depan menunjukkan tindakan yang diambil sebelum melakukan pengamatan. Setiap cabang pohon diberi label berdasarkan indeks sejarah dan dimensi persepsinya. Setiap simpul dari pohon diberi label oleh total konjungsi dari fitur-fitur yang diwakili oleh simpul tersebut. Garis putus-putus mewakili kepemilikan instance.

Pertimbangkan momen di mana agen baru saja mengalami urutan yang mengarah ke instance berbintang pada Gambar 3 (pengamatan 'B\$-'). Misalkan simpul berlabel '0\$' awalnya adalah simpul keadaan, dan semua simpul turunannya adalah simpul pinggiran. Instance baru melintasi pohon dan mencapai simpul '0\$' dengan mencocokkan indeks riwayat '0', dan pengamatan '\$'. Ini berlanjut ke bawah pohon sampai simpul '0\$, 1u, 1c', di mana tidak ada pencocokan lebih lanjut yang dapat ditemukan. Menelusuri kembali dari simpul ini hingga simpul keadaan pertama yang ditemui, simpul '0\$', '0\$, 1u' dan '0\$, 1u, 1c' akan mengambil alih kepemilikan instance baru. Misalkan uji K-S menunjukkan bahwa distribusi imbalan diskon masa depan yang diharapkan di simpul '0\$, 1u, 1c' berbeda secara signifikan dari yang ada di simpul '0\$'. Node '0\$, 1u, 1C' dipromosikan ke node status baru, tetapi semua saudara kandungnya tetap menjadi simpul pinggiran. Semua instance yang terkandung dalam node status baru dihapus dari node status lama '0\$'.

Modifikasi meningkatkan kemampuan representasi dari algoritma U-Tree. Alih-alih hanya menjawab pertanyaan seperti, jika pengamatan saat ini 1 adalah '\$' (yaitu '0\$'), dan tindakan sebelumnya adalah 'u' ('1u'), dan pengamatan sebelumnya 2 adalah 'C' ('1C'), apa tindakan optimal untuk diambil selanjutnya, sekarang dapat menjawab, Bagaimana jika pengamatan saat ini 1 adalah '\$', tindakan sebelumnya adalah 'u', tetapi pengamatan sebelumnya 2 bukan 'C'.

### Nilai Iterasi untuk U-Tree

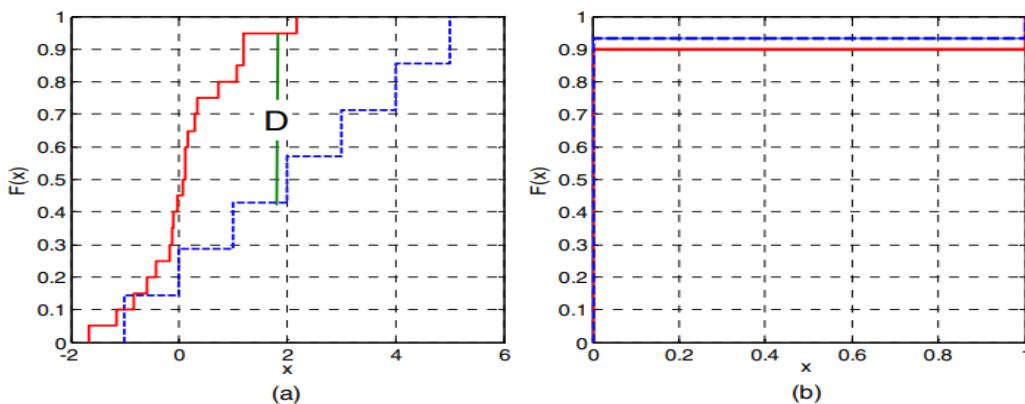
U-Tree asli menggunakan iterasi nilai-Q. Untuk setiap langkah waktu, ia melakukan satu sapuan pencadangan nilai-Q. Untuk meningkatkan kinerja, juga dapat melakukan pencadangan setiap k langkah, di mana k adalah parameter yang ditentukan pengguna. Namun, fakta bahwa satu sapuan cadangan tidak memberikan nilai Q yang tepat dapat menyebabkan beberapa masalah jika proses pembuatan status bergantung pada nilai Q yang

salah ini untuk pengujian statistik. Eksperimen kami menunjukkan bahwa menggunakan iterasi nilai Q penuh batch meningkatkan kinerja keseluruhan. Batch di sini berarti bahwa iterasi nilai-Q penuh dilakukan setiap k langkah waktu. Karena keadaan yang dihasilkan oleh U-Tree seringkali cukup terbatas, DP klasik bisa cukup efisien.

Desain U-Tree membuat pilihan algoritma iterasi nilai aktual sangat fleksibel. Baik iterasi nilai imbalan harapan yang didiskontokan cakrawala tak terbatas yang didefinisikan dalam persamaan (5) dan iterasi nilai imbalan rata-rata yang ditentukan dalam persamaan (9) digunakan dalam artikel ini untuk eksperimen yang berbeda. Bahkan dimungkinkan untuk menerapkan beberapa metode heuristik POMDP keadaan keyakinan untuk mendapatkan nilai yang lebih akurat jika U-Tree entah bagaimana dapat mempelajari probabilitas pengamatan keadaan. Ide ini dibahas lebih lanjut di bagian 6.

### Tes Kebugaran yang Baik

U-Tree asli memilih tes Kolmogorov-Smirnov (K-S) untuk membedakan dua distribusi imbalan yang diharapkan di masa depan. Uji K-S dua sampel membandingkan dua distribusi kumulatif empiris, dan menggunakan jarak vertikal maksimum antara dua kurva distribusi ini sebagai statistik D , yang ditunjukkan pada Gambar 4 (a). Distribusi Kolmogorov kemudian digunakan untuk menghasilkan tingkat signifikansi untuk pengujian hipotesis apakah dua distribusi empiris berasal dari sumber yang sama. Keuntungan menggunakan uji K-S adalah bahwa pengujian tersebut efektif terlepas dari jenis distribusi pengujinya. Tetapi juga memiliki beberapa kelemahan yang menonjol. Uji K-S hanya berfungsi untuk distribusi kontinu, dan cenderung lebih sensitif di dekat pusat distribusi daripada di ekor. Ini dapat menyebabkan masalah pada U-Tree saat melakukan beberapa tugas, seperti navigasi labirin, yang biasanya menawarkan hadiah satu kali hanya ketika agen mencapai status tujuan, dan hadiah nol saat berada di negara bagian lain. Jika labirin cukup kompleks, agen, yang awalnya berkeliaran secara acak, akan mengalami sejumlah besar instance dengan nol hadiah, dan hanya kadang-kadang benar-benar dihargai. Oleh karena itu, pada tahap awal, distribusi akumulasi hadiah yang diharapkan di masa depan akan berbentuk aneh, dan perbedaan distribusi akan berada di ujung karena kelangkaan hadiah. Contoh dari jenis distribusi kumulatif ini ditunjukkan pada Gambar 4 (b). Tes K-S tidak akan dapat berfungsi dan U-Tree tidak akan pernah mempelajari perbedaan status yang dapat digunakan. Fenomena ini ditunjukkan oleh eksperimen “lorong2” di bagian 5.



**Gambar 9.4** Distribusi Kumulatif untuk Uji Kolmogorov-Smirnov. (a) menunjukkan D-statistik dalam CDF biasa. (b) menunjukkan distribusi bermasalah dengan hanya dua nilai yang berbeda.

Uji statistik serupa lainnya dapat digunakan untuk menggantikan uji K-S, atau setidaknya digunakan pada tahap awal untuk bootstrap proses pembangkitan state U-Tree. Ketika status yang cukup dihasilkan, akan ada lebih banyak variasi dalam nilai yang diharapkan. Uji divergensi Kullback–Leibler (KL) membandingkan dua distribusi dengan memperkirakan laju kode pengkodean satu distribusi berdasarkan yang lain. Ini digunakan dalam Probabilistic Suffix Trees (PST) [42] untuk mendeteksi divergensi distribusi probabilitas observasi. PST adalah salah satu prekursor U-Tree. Namun, ketika diterapkan pada distribusi imbalan yang diharapkan di masa depan, divergensi KL terkadang ditemukan tidak stabil. Mungkin karena fakta bahwa nilai imbalan yang diharapkan di masa depan selalu berubah karena statistik transisi status berubah ketika status baru dihasilkan. Chi-square dipilih sebagai gantinya untuk bootstrap generasi negara. Pada tahap awal, ketika hanya ada beberapa keadaan, nilai imbalan yang diharapkan di masa depan dari semua contoh memiliki variasi yang sangat sedikit, dan dengan demikian, dapat dianggap sebagai diskrit. Nilai imbalan yang diharapkan di masa depan dari setiap instans hanya di-binned sesuai dengan nilai numeriknya. Ketika variasi (yaitu jumlah tempat sampah) melebihi ambang batas yang ditentukan pengguna tertentu, algoritme akan beralih kembali ke uji K-S.

#### 9.4 DETAIL ALGORITMA

Bagian ini menjelaskan secara rinci algoritma dari U-Tree yang dimodifikasi. Notasi sedikit diubah untuk memperhitungkan modifikasi algoritma U-Tree.

##### Notasi

Interaksi antara agen dan lingkungannya terdiri dari tindakan, penghargaan, dan pengamatan. Ada sejumlah aksi berhingga  $\mathcal{A} = \{a_1, a_2, \dots, a_{|\mathcal{A}|}\}$ , rentang skalar imbalan  $R = [x, y], x, y \in \mathbb{R}$ , himpunan berhingga dimensi pengamatan  $\mathcal{D} = \{D_1, D_2, \dots, D_{|\mathcal{D}|}\}$ , dan setiap dimensi  $d \in \mathcal{D}$  memiliki himpunan berhingga nilai observasi yang mungkin  $\mathcal{O}_d = \{o_{d,1}, o_{d,2}, \dots, o_{d,|\mathcal{D}|}\}$ . Nilai observasi dimensi  $d$  pada langkah waktu  $t$  ditulis sebagai  $o[d]_t$ . Dengan demikian, pada setiap langkah waktu, pengamatan dapat ditulis sebagai vektor  $\mathcal{O}_t = \langle o[1]_t, o[2]_t, \dots, o[|\mathcal{D}|]_t \rangle$ .

Pengalaman yang terkait dengan waktu  $t$  ditangkap sebagai contoh transisi, ditulis sebagai  $T_t$ . Berbeda dengan U-Tree asli, yang menyimpan instans sebagai vektor empat dimensi termasuk pengamatan saat ini, tindakan sebelumnya, dan hadiah saat ini, kami memilih untuk menyimpan pengamatan saat ini, tindakan saat ini, dan hadiah yang diterima setelah melakukan tindakan ini, yaitu,  $T_t = \langle o_t, a_t, r_{t+1} \rangle$ . Di sini, kami berasumsi bahwa rantai instance disimpan dalam array dan instance sebelumnya  $T_{t-1}$  dan  $T_{t+1}$  berikutnya mudah diakses. Setiap episode akan membuat larik baru untuk menyimpan rantai instance yang sesuai. Kami memilih untuk menyimpan tindakan saat ini daripada yang sebelumnya, sehingga kami dapat mengelompokkan instance di setiap node menurut tindakan ini untuk menyederhanakan perhitungan nilai Q.  $r_{t+1}$  disimpan sebagai ganti  $r_t$  untuk alasan yang sama.

Setiap simpul di pohon diberi label oleh indeks sejarah  $h$ , dan dimensi pengamatan  $d$ . Tindakan juga diperlakukan sebagai pengamatan khusus sehingga kita dapat membedakan keadaan berdasarkan tindakan sejarah. Indeks sejarah menunjukkan berapa banyak langkah waktu mundur dari langkah waktu saat ini pengamatan atau tindakan harus diperiksa.  $h=0$  menunjukkan langkah waktu saat ini. Setiap node akan memiliki anak sebanyak ukuran dimensi pengamatannya. Setiap node dapat diidentifikasi secara unik dengan sekumpulan

label pada jalur dari node ke root. Kumpulan label ini disebut konjungsi simpul. Konjungsi node state sepenuhnya mendefinisikan sebuah state. Jadi, kami menggunakan  $s$  untuk mewakili konjungsi, simpul, dan keadaan.

Sebuah instance,  $T$ , disimpan dalam sebuah node yang hubungannya adalah  $s$ , cocok dengan semua observasi, tindakan dan indeks sejarah yang ditentukan dalam  $s$ . Himpunan instance yang terkandung dalam node  $s$  ditulis sebagai  $T(s)$ , dan  $T(s, a)$  menunjukkan instance yang direkam memiliki tindakan yang dieksekusi  $a$ . Distribusi hadiah yang diharapkan di masa depan dari instance di bawah node  $s$  dan tindakan eksekusi  $a$  adalah  $T_R(s, a)$ , dan  $|T_R(s, a)|$  menunjukkan jumlah nilai numerik yang berbeda dalam distribusi hadiah.

Ada beberapa parameter yang dapat ditentukan pengguna untuk algoritme.  $n$  mendefinisikan jumlah total langkah pelatihan.  $k$  adalah jumlah langkah untuk setiap iterasi nilai batch.  $e$  menentukan probabilitas eksplorasi selama pemilihan tindakan.  $m$  mendefinisikan jumlah minimum instance di bawah setiap node agar memenuhi syarat untuk perluasan node pinggiran dan pengujian statistik.  $c$  menentukan jumlah maksimum bin untuk melakukan pengujian Chi-kuadrat.

### **Kode Pseudo untuk U-Tree yang Dimodifikasi**

Kode semu untuk U-Tree yang dimodifikasi tercantum dalam algoritma 1. Langkah 3 dari prosedur GROW\_FRINGE membutuhkan lebih banyak elaborasi. Urutan ekspansi, yaitu pengamatan atau tindakan mana yang lebih dulu diperluas, akan berdampak pada proses pembangkitan keadaan. Kami memilih untuk memperluas dari indeks riwayat saat ini ke yang lebih lama, dan secara acak memilih satu pengamatan atau tindakan dalam indeks riwayat yang sama. Setiap fringe node memiliki hitungan usia, sehingga ketika usianya berakhir dan node masih tetap menjadi fringe node, ia akan dihancurkan, bersama dengan semua anak-anaknya. Sebuah simpul pinggiran baru akan ditambahkan, dengan pengamatan atau tindakan yang dipilih secara acak dari indeks riwayat yang berkembang saat ini.

### Algoritma 1: Algoritma U-Tree yang Dimodifikasi

```

1: procedure U-TREE(tree)
2:   Initialize tree with a root node
3:   Create an array to store instance chain
4:   Arbitrarily choose an initial action  $a_0$ 
5:   Take action  $a_0$ , get observation  $o_0$ 
6:    $t:=1$ 
7:   repeat
8:     for step:=1 do
9:       Find state node  $s$  using  $o_0$ 
10:      Choose action  $a_t := \arg \max_{a \in A} Q(s, a)$  or with
          probability  $\epsilon$  randomly choose an action as  $a_t$ 
11:      Take action  $a_t$ , get  $o_t$  and  $r_t$ 
12:      Create new instance  $T_t = \langle o_t, a_t, r_{t+1} \rangle$ 
13:      Add  $T_t$  to tree
14:       $t:=t+1$ 
15:      if at the end of the episode then break
16:    end for
17:    VALUE_ITERATE(tree)
18:    GROW_FRINGE(tree)
19:    if at the end of the episode then
20:      go to step 3
21:    end if
22:   until  $t > n$ 
23:end procedure

1: procedure GROW_FRINGE(tree)
2:   for all non-interior node  $s$  such that  $|T(s, a)| > m$  do
3:     Expand fringe nodes below  $s$ 
4:   end for
5:   for all fringe node  $f$  such that  $|T(f, a)| > m$  do
6:      $s :=$  nearest parent state node of  $f$ 
7:     for all action  $a$  do
8:       if  $|T_k(s, a)| < c$  then
9:         result := Cm2_TEST( $T_k(s, a), T_k(f, a)$ )
10:       else
11:         result := K_S_TEST( $T_k(s, a), T_k(f, a)$ )
12:       end if
13:       if result is tree then
14:         Mark  $f$  as state node
15:         Detach all instances in  $f$  from  $f$ 's ancestors
16:         if  $|T(f, a)| > m$  for any  $a$  then demote  $s$ 
17:       end if
18:     end for
19:   end for
20:end procedure

```

Fungsi VALUE\_ITERATE melakukan iterasi nilai. Seperti yang dijelaskan di bagian 3.4, U-Tree fleksibel tentang jenis algoritma iterasi nilai mana yang akan digunakan. Dua jenis iterasi nilai akan digunakan di sini; ini didefinisikan dalam persamaan (5) dan (9) Imbalan langsung yang diharapkan  $R(s, a)$  dapat dengan mudah diperoleh dari U-Tree dengan akumulasi instance di node  $s$  sebagai:

$$R(s, a) = \frac{\sum_{T_i \in T(s, a)} r_{i+1}}{|T(s, a)|}.$$

Dan dengan cara yang sama, probabilitas transisi keadaan dapat diperoleh sebagai:

$$M(s, a, s') = \frac{|\{\forall T_i \in T(s, a) | L(T_{i+1}) = s'\}|}{|T(s, a)|},$$

di mana  $L(T)$  mengembalikan node yang berisi instance  $T$ .

Fungsi K\_S\_TEST melakukan uji Kolmogorov-Smirnov, dan fungsi CHI2\_TEST melakukan uji Chi kuadrat. Keduanya menguji distribusi nilai semua instance di bawah dua node yang diberikan, dan mengembalikan TRUE jika kedua distribusi dianggap berbeda. Definisi nilai instance tergantung pada aplikasinya. Dalam artikel ini, dua definisi digunakan. Nilai tak hingga yang didiskontokan dari sebuah instance dalam waktu t dengan faktor diskon didefinisikan sebagai:

$$V(T_t) = r_{t+1} + \gamma V(L(T_{t+1})).$$

Nilai relatif dari sebuah instance dalam waktu t, yang digunakan dalam pengaturan hadiah rata-rata, didefinisikan sebagai:

$$V(T_t) = r_{t+1} - \rho + \tau V(L(T_{t+1}))$$

di mana adalah imbalan rata-rata optimal dari model saat ini, yang didefinisikan dalam persamaan (10).

## 9.5 EKSPERIMEN DAN HASIL

### Tugas Mengemudi Mobil Jalan Raya

Tugas mengemudi jalan raya yang sama seperti dalam makalah asli McCallum [14] diadopsi. Lingkungan terdiri dari empat jalur lalu lintas searah. Lalu lintas termasuk mobil agen, dan banyak truk lambat yang berada di depan mobil agen. Ketika mobil agen menabrak bagian belakang truk yang lambat, kedua kendaraan saling bergesekan, dan agen akan menerima hadiah -10. Agen menerima hadiah 0,1 untuk clear pass. Mobil agen bisa berpindah jalur, tapi truk tidak bisa. Kami hanya mempertimbangkan langkah dan jarak waktu diskrit. Mobil agen berjalan pada jarak dua satuan per langkah waktu, dan truk berjalan pada jarak satu satuan. Agen hanya dapat melihat truk dalam jarak delapan satuan per langkah waktu. Agen dapat memilih dari empat tindakan di setiap langkah, yaitu menatap ke kiri, menatap ke tengah, menatap ke kanan, dan mengalihkan perhatian ke jalur pandang. Setelah agen menggeser jalur, arah tatapannya akan diatur ulang ke tengah. Sensor agen tercantum dalam tabel 1. Pada setiap langkah waktu, sebuah truk muncul di sisi jauh bidang pandang dengan probabilitas 0,5 di jalur yang dipilih secara acak, dan dengan warna yang dipilih secara acak dari enam variasi.

**Tabel 9.1** Sensor Agen

Sensor	Nilai	deskripsi
Obyek	Truk, jalan, bahu	Agen akan melihat bahu jalan jika melihat ke kiri di jalur paling kiri, dan begitu juga untuk bahu kanan. Agen akan melihat jalan jika menatap jalur yang tidak ada truk.
Samping	Kiri, tengah, kanan	Memberitahu di mana agen melihat

Jarak	Jauh, tengah, dekat, hidung	Relatif di mana agen berada, hidung berarti truk berada pada jarak dua satuan, empat tengah, dekat enam, dan jauh adalah delapan.
Jarak Halus	Jauh-setengah, hampir-setengah	Jarak halus membedakan jarak dua unit dengan setiap jarak Tatapan.
Warna	Enam warna	Perilaku truk tidak bergantung pada warna. Sensor ini baru saja ditambahkan untuk menguji persepsi selektif U-Tree.

Di koran McCallum, ada juga truk cepat yang datang dari belakang, dan klakson jika menabrak bagian belakang mobil agen. Kami menghilangkan bagian ini sehingga kami dapat menyelesaikan masalah menggunakan DP klasik, dan mendapatkan pemahaman yang lebih baik tentang masalah tersebut. McCallum meremehkan jumlah negara dunia, bahkan untuk tugas yang disederhanakan ini. Mengabaikan warna truk, kami memiliki empat jalur dan delapan unit jarak per jalur. Jadi, agen dapat melihat truk pada delapan kemungkinan jarak yang berbeda di setiap jalur. Dan, karena agen hanya bisa mengamati satu jalur pada satu waktu, maka tidak bisa melacak truk di semua jalur secara bersamaan. Untuk memecahkan masalah menggunakan DP, bagaimanapun, kita harus mengasumsikan bahwa agen memiliki pengetahuan yang lengkap tentang dinamika lingkungan untuk memodelkan masalah sebagai MDP.

Jadi, jika agen menemukan jalur I tanpa truk pada waktu t dan kemudian melihat ke arah  $t + 1$  dan seterusnya, agen tersebut akan tetap mengetahui bahwa tidak ada truk pada jarak  $8 - d$  terdekat di jalur I pada waktu  $t + d$ , dengan  $0 \leq d \leq 8$ .  $d = 0$  menunjukkan bahwa agen mengetahui tidak ada truk di jalur I, dan  $d = 8$  berarti tidak ada informasi untuk jalur I. Itu menambahkan sembilan kemungkinan lain untuk setiap jalur. Secara keseluruhan, ada  $8^9 = 512$  kemungkinan. Agen juga harus memperhitungkan posisinya sendiri dan melihat ke samping. Karena lajur kiri-kanan simetris, kita hanya perlu mempertimbangkan dua lajur. Agen memiliki tiga sisi pandangan, tetapi tidak ada gunanya menatap ke kiri di jalur paling kiri, jadi total lima kemungkinan. Oleh karena itu, batas atas jumlah negara dunia adalah  $5^9 = 1953125$ , tetapi tidak semuanya valid.

Misalnya, tidak mungkin bagi agen untuk mengetahui truk pada jarak delapan di jalur paling kiri, dan truk lain pada jarak tujuh di jalur paling kanan, karena setidaknya ada jarak tiga langkah antara menatap paling kiri di jalur untuk melihat jalur paling kanan. Terlalu rumit untuk secara eksplisit menghitung status yang valid. Cara termudah adalah dengan membuat tabel dengan 417.605 entri, mulai dari beberapa status yang jelas valid dan tandai status apa pun dengan kemungkinan bukan nol transisi satu langkah dari status valid yang sudah ditandai. Proses berulang sampai tidak ada status baru yang dapat ditandai. Jumlah sebenarnya negara bagian yang valid adalah 31.224. Dapat diverifikasi bahwa kebijakan yang secara berurutan mengalihkan pandangan dan jalur sehingga agen berosilasi di antara jalur akan mencakup semua status yang valid, dan karenanya memenuhi kondisi yang ditentukan dalam persamaan (8). Namun, tiga puluh ribu negara bagian masih merupakan jumlah yang besar untuk DP klasik. Hal ini layak di sini karena sparitas matriks transisi. Beberapa kemungkinan transisi hanya terjadi ketika agen melihat ke jalur yang tidak diketahui dengan paling banyak sembilan kemungkinan hasil. Jadi, tidak perlu tabel kemungkinan transisi yang besar, dan kecepatan konvergensi akan cepat. Dengan menerapkan iterasi DP hadiah rata-rata yang didefinisikan

dalam persamaan (9), hadiah rata-rata optimal diperoleh sekitar 0,095, yang setara dengan dihapuskan sekali setiap 2.000 langkah waktu. Hal ini sesuai dengan hasil simulasi mengikuti kebijakan yang optimal.

Apa yang terjadi jika agen memiliki sedikit pengetahuan tentang lingkungan? Bagaimana jika agen tidak mengetahui ada berapa lajur, atau kecepatan dan probabilitas kemunculan truk, atau pandangan ke kiri di lajur paling kiri tidak masuk akal? Algoritma U-Tree diterapkan di mana agen hanya dapat menerima informasi dari sensor terbatasnya yang ditentukan dalam tabel 1, di mana bahkan ada sensor berbahaya yang merasakan warna sebagai pengalih perhatian. Kami melakukan percobaan di bawah beberapa konfigurasi yang berbeda, yang bervariasi dalam jumlah langkah pelatihan dan k-langkah (interval waktu iterasi DP, lihat bagian 3.4 untuk lebih jelasnya). Ambang probabilitas K-S dan probabilitas eksplorasi tidak terlalu kritis menurut eksperimen kami. Setiap sesi latihan diikuti dengan pengujian 5.000 langkah untuk mendapatkan hasil jumlah kali tumbukan. Setiap konfigurasi mengulangi sesi pelatihan dan pengujian sebanyak 100 kali, dan hasilnya dipasang ke dalam kurva normal untuk mendapatkan estimasi mean dan standar deviasi dalam kepercayaan 95%. Diamati bahwa U-Tree kadang-kadang dapat terjebak dalam keadaan tertentu tanpa melakukan tindakan yang efektif, yang memberikan hasil yang sangat buruk. Satu penjelasan yang mungkin adalah bahwa model baru yang dibuat mungkin tidak selalu memenuhi kondisi yang didefinisikan dalam persamaan (8). Hasil ekstrim ini dianggap sebagai outlier. Hasilnya disajikan dalam tabel 2.

Ada 31.224 negara dunia yang berbeda. Setiap negara bagian memiliki frekuensi kunjungan yang diharapkan berbeda. Dapat ditunjukkan bahwa kebijakan optimal hanya mencakup sekitar 12,5% dari semua negara bagian dunia dalam sesi pengujian 90.000 langkah waktu. Ini memberi kita gambaran yang sangat kasar tentang berapa banyak langkah pelatihan yang diperlukan untuk menghasilkan hasil yang masuk akal. Seperti yang ditunjukkan pada tabel 2, hasilnya, baik dari segi rata-rata yang diestimasi maupun standar deviasi, meningkat ketika lebih banyak langkah pelatihan digunakan. Hasilnya juga menunjukkan bahwa langkah k yang lebih kecil meningkatkan kinerja, terutama ketika sampel pelatihan tidak mencukupi. Hal ini diharapkan, karena langkah k mengontrol seberapa sering model keadaan direvisi dan rata-rata imbalan diestimasi ulang dalam algoritma U-Tree yang dimodifikasi.

Kami juga menyertakan beberapa uji coba tanpa variasi warna untuk dijadikan referensi. Uji coba tersebut ditandai dengan bintang di tabel 2. Sangat mengejutkan melihat bahwa untuk sesi latihan 10.000 langkah, hasilnya sebenarnya lebih baik dengan warna. Ini mungkin karena sampel pelatihan yang tidak mencukupi dan sistemnya kurang terlatih. Namun, untuk sesi lainnya, hasilnya memang memiliki peningkatan yang luar biasa. Ini menunjukkan bahwa U-Tree dapat menghasilkan model yang lebih efektif dengan sampel pelatihan yang lebih sedikit tanpa sensor non-informatif sebagai pengalih perhatian. Hal ini juga menunjukkan bahwa kemampuan persepsi selektif U-Tree perlu ditingkatkan lebih lanjut.

**Tabel 9.2** Hasil eksperimen yang diperoleh dengan algoritma u-tree yang dimodifikasi

Langkah Pelatihan	Langkah	Mean	Standar deviasi	Penciran	Cakupan negara DP	Jumlah negara bagian U-Tree
10,000	1,000	50 – 59	19 – 25	3	%7	52

10,000	300	48 – 55	17 – 22	1	%7	53
10,000*	300	50 – 58	18 – 24	3	%7	54
10,000	100	43 – 51	16 – 21	1	%7	53
30,000	1,000	50 – 61	23 – 31	0	%12	90
30,000	300	47 – 56	19 – 25	0	%12	83
30,000*	300	29 – 35	12 – 16	0	%12	120
30,000	100	46 – 54	17 – 23	0	%12	90
90,000	1,000	28 – 32	8 – 11	0	%20	313
90,000	300	29 – 33	8 – 10	0	%20	314
90,000*	300	20 – 24	8 – 11	1	%20	510
90,000	100	28 – 31	7 – 9	0	%20	320
300,000	1,000	22 – 25	5 – 7	0	%30	1,167
300,000	300	21 – 24	5 – 8	0	%30	1,231
300,000*	300	10 – 11	3 – 4	1	%30	1,561

Semua eksperimen menetapkan ambang probabilitas K-S ke 0,0001, dan probabilitas eksplorasi sebagai 1,0 pada 40% langkah pelatihan pertama, dan 0,6, 0,2, 0,1 untuk masing-masing 20% sisanya.

### Masalah Tolok Ukur

Meskipun tugas mengemudi mobil memiliki keadaan dan ruang pengamatan yang besar, semua pengamatan dan tindakan bersifat deterministik, yang tidak benar dalam banyak masalah POMDP. Pada bagian ini, beberapa masalah POMDP yang terkenal digunakan untuk membandingkan U-Tree terhadap algoritma pemecahan POMDP lainnya. Pertama, beberapa masalah kecil digunakan untuk menguji kelayakan penerapan U-Tree pada masalah POMDP formal, dan untuk menunjukkan keefektifan prosedur pembangkitan negara bagian baru dalam pengurangan jumlah negara bagian. Masalah yang dipilih diringkas dalam tabel 3. Littman et al. [25] memberikan ringkasan yang lebih rinci.

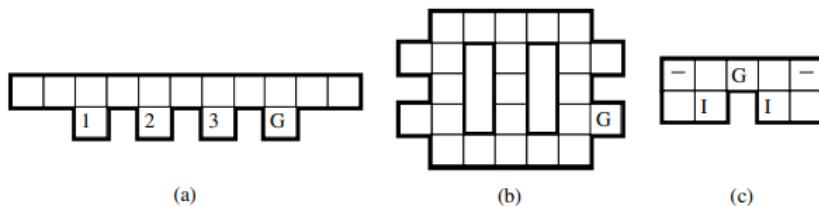
**Tabel 9.3** Masalah kecil POMDP

Nama	S	A		Kebisingan
Pesawat ulang-alik	8	3	5	T/O
Labirin Keju	11	4	7	-
Lukisan Bagian	4	4	2	T/O
Kotak 4x4	16	4	2	-
Kotak 4x3	11	4	6	T

Kolom | S | menunjukkan ukuran ruang keadaan, | A | ukuran ruang aksi, dan || | adalah ukuran ruang observasi. T menunjukkan derau dalam transisi keadaan, dan O menunjukkan derau dalam pengamatan keadaan.

Selanjutnya, tiga navigasi labirin dengan ruang keadaan yang lebih besar dipilih, yang biasanya digunakan untuk menguji algoritme pemecahan POMDP yang dapat diskalakan. Semuanya adalah masalah navigasi labirin. Lingkungan dimodelkan sebagai dunia grid seperti yang ditunjukkan pada Gambar 5. Agen berkeliaran di dalam grid, dan hanya akan menerima

hadiah satu ketika mencapai status tujuan, di mana transisi status berikutnya didistribusikan secara merata di antara semua status non-tujuan . Agen memiliki empat tindakan: maju, belok kanan, belok kiri, putar balik, dan tetap di tempat. Setiap tindakan gerakan hanya berhasil dalam 80% dari waktu. Ketika gagal, tindakan aktual yang dieksekusi didistribusikan secara merata di antara tindakan lainnya. Agen memiliki satu sensor untuk masing-masing dari empat arah yang melaporkan keberadaan dinding di posisi langsung dari arah yang sesuai. Sensor tidak sepenuhnya dapat diandalkan. Ini mendeteksi dinding dengan probabilitas 0,9 ketika benar-benar ada dinding, dan probabilitas 0,05 ketika tidak ada dinding. Rincian lebih lanjut dapat ditemukan di [25].



**Gambar 9.5** Masalah navigasi labirin. Dalam semua masalah, 'G' menandai status tujuan.

Keadaan ditentukan oleh posisi dan orientasi agen. (a) Lorong, 61 negara bagian. '1, 2, 3' menandai tiga posisi di mana agen dapat mengamati keadaan dunia. (b) Hallway2, 93 negara bagian. (c) Tiger-Grid, 36 negara bagian. 'I' menandai dua kemungkinan keadaan awal. '-' menandai negara bagian di mana agen akan menerima penalti -1.

### Eksperimen Tolok Ukur

Tabel 4 merangkum algoritma benchmark, beberapa di antaranya dibahas secara singkat di bagian 2.7. Untuk setiap masalah kecil, setiap algoritma melakukan 21 run untuk mendapatkan hasil perbandingan. Algoritme benchmark menggunakan 75.000 langkah pelatihan diikuti dengan 2.500 langkah pengujian untuk setiap proses. Performa diukur sebagai imbalan rata-rata yang diterima dalam sesi uji semua lari. Untuk U-Tree (baik versi asli maupun versi modifikasi), karena ditemukan dapat mempelajari masalah dengan langkah pelatihan yang jauh lebih sedikit, hasil yang ditunjukkan pada tabel 5 diperoleh setelah 8.000 langkah pelatihan saja. Uji chi-kuadrat tidak digunakan karena masalahnya kecil dan ada variasi nilai yang cukup untuk uji K-S agar berfungsi dengan baik. Ambang uji K-S diatur ke 0,001. Karena U-Tree perlu mempelajari seluruh model lingkungan, itu membutuhkan lebih banyak eksplorasi daripada algoritma pembelajaran penguatan berbasis model konvensional. Probabilitas eksplorasi dijadwalkan sebagai: 1,0 untuk 40% langkah pelatihan pertama, dan 0,6, 0,4, 0,2, 0,1, 0,01, 0,001 untuk masing-masing 10% langkah pelatihan berikut. Jadwal ini digunakan dalam semua eksperimen dalam artikel ini.

**Tabel 9.4** Ringkasan masalah benchmark

Metode	deskripsi
Batang VI	Iterasi nilai eksak terpotong pada status keyakinan. Iterasi terpotong setelah waktu berjalan 100 detik [25].
Q <sub>MDP</sub>	Abaikan observabilitas parsial, dan selesaikan MDP yang mendasarinya. Kebijakan tersebut dihasilkan dengan pembobotan nilai status MDP

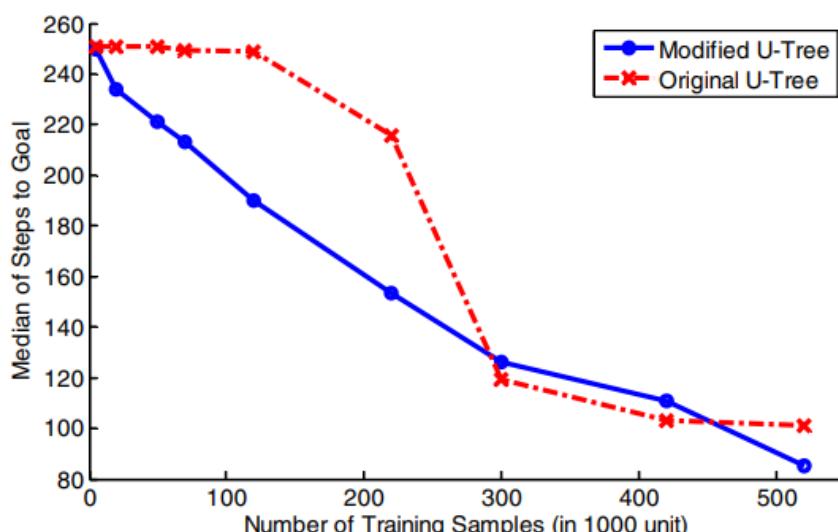
	dengan keyakinan. Sangat cepat, dan efisien pada banyak masalah POMDP [25].
3-PWLC Q	Tiga vektor per fungsi Q, karena satu vektor Q mungkin tidak cukup dalam banyak masalah, mis. Tiger-Grid [25].
PBVI	Iterasi nilai berbasis titik untuk POMDP. Alih-alih seluruh ruang keyakinan, pilih satu set poin keyakinan untuk iterasi nilai [34].
Hsvi	Iterasi nilai pencarian heuristik untuk POMDP. Gunakan pohon untuk ruang kebijakan pencarian, dan buat batas bawah dan atas dari iterasi nilai saat ini sebagai heuristik untuk pencarian [30].

**Tabel 9.5** Hasil Percobaan Soal Kecil

Metode	Pesawat ulang-alik	Labirin Keju	Lukisan Bagian	Kotak 4x4	Kotak 4x3
Batang VI	1.805	0.188	0.179	0.193	0.109
$Q_{MDP}$	1.809	0.185	0.112	1.192	0.112
U-Tree (tua)	1.833 (62)	0.184 (53)	0.163 (27)	0.179 (47)	0.091 (87)
U-Tree (baru)	1.820 (25)	0.184 (19)	0.144 (11)	0.179 (20)	0.089 (27)

\*Tabel mencantumkan hadiah rata-rata yang diterima dalam sesi tes. Angka dalam kurung menunjukkan jumlah status yang dihasilkan.

Masalah yang lebih besar membutuhkan lebih banyak langkah pelatihan. Untuk masalah Tiger-Grid dan Hallway, setiap lari terdiri dari 75.000 langkah pelatihan. Karena masalah tersebut bersifat episodik, pengujian untuk setiap proses melibatkan 251 percobaan, dan setiap percobaan dihentikan ketika keadaan tujuan tercapai atau jika lebih dari 251 langkah dilakukan. Setiap percobaan diulang selama 50 kali. Performa diukur sebagai median dari persentase 50 run di mana tujuan tercapai. Ukuran lainnya adalah median dari jumlah langkah yang digunakan untuk mencapai tujuan. Hallway2 memiliki struktur yang lebih kompleks. Gambar 6 memplot kinerja dari dua versi U-Tree karena lebih banyak langkah pelatihan yang digunakan. Tabel 6 daftar kinerja U-Tree terhadap algoritma lain.

**Gambar 9.6** Performa U-Tree vs. langkah-langkah pelatihan

**Tabel 9.6** Hasil eksperimen soal navigasi tipe labirin

Metode	Sasaran %	Median	Waktu(s)	$ \pi $
<b>Tiger-Grid</b>				
Trunc VI	39.8	>251	n. a.	n. v.
Q <sub>MDP</sub>	17.9	>251	0.19	n. a.
3-PWLC Q	98.4	5	n. v.	n. v.
Pohon U asli	99.9	20	21	1186
Modifikasi	100	12	25	306
<b>Pohon U</b>				
<b>Lorong</b>				
Trunc VI	62.9	150	n. v.	n. a.
Q <sub>MDP</sub>	47.4	>251	0.51	n. a.
PBVI	96.0	12.3*	3448	86
HSV1	100	12.7*	10836	147
Pohon U asli	99.5	24	23	2009
Modifikasi	100	23	37	454
<b>Pohon U</b>				
<b>Lorong2</b>				
Trunc VI	44.6	>251	n. v.	n. a.
Q <sub>MDP</sub>	25.9	>251	1.44	n. a.
PBVI	98.0	21*	360	95
HSV1	100	20.5*	1.5	114
Pohon U asli	68.1	101	440	7490
Modifikasi	71.9	85	899	2337
<b>Pohon U</b>				

n. v. = tidak tersedia, n. sebuah. = tidak berlaku. Kolom 'Goal%' memberikan persentase lari di mana tujuan tercapai tepat waktu. 'Median' adalah median langkah-langkah untuk mencapai keadaan tujuan. 'Waktu' hanya memberikan perkiraan yang sangat kasar tentang efisiensi algoritme, karena dilakukan pada platform yang berbeda.  $|\pi|$  daftar ukuran kebijakan. Untuk metode berbasis-keadaan-keyakinan, itu adalah jumlah vektor nilai. Untuk U-Tree, ini adalah status angka yang dihasilkan.

\* Langkah-langkah median ke tujuan PBVI dan HSV1 diperkirakan dari nilai akhir yang diperoleh.

## 9.6 DISKUSI

Dibandingkan dengan U-Tree asli, prosedur pembuatan status baru secara efektif mengurangi jumlah status dengan faktor tiga hingga empat, dan menghasilkan kinerja yang sedikit lebih baik pada saat yang sama. Gambar 6 menunjukkan bahwa U-Tree asli gagal menghasilkan keadaan yang berguna ketika kurang dari 200.000 langkah pelatihan digunakan, sedangkan algoritma yang dimodifikasi memiliki kurva kemajuan yang stabil mulai dari hanya 10.000 langkah pelatihan, yang menunjukkan bahwa uji Chi-kuadrat Prosedur ini efektif dalam Sistem Pendukung Keputusan (Dr Joseph Teguh Santoso dan Budi Hartono, M.Kom)

meningkatkan uji statistik dari distribusi hadiah yang diharapkan pada tahap awal pelatihan. U-Tree yang dimodifikasi memiliki waktu berjalan sedikit lebih lama daripada versi aslinya seperti yang ditunjukkan pada tabel 6, yang disebabkan oleh prosedur pencarian keadaan yang lebih kompleks. Perbedaan waktu yang lebih signifikan dalam masalah Hallway2 adalah karena fakta bahwa U-Tree asli gagal menghasilkan keadaan apa pun untuk 200.000 langkah pertama pelatihan.

Lebih lanjut, tolok ukur yang tercantum pada tabel 6 menunjukkan bahwa kinerja U-Tree yang dimodifikasi sebanding, atau bahkan lebih baik daripada beberapa metode heuristik berbasis kepercayaan POMDP awal. Namun, tidak dapat bersaing dengan banyak metode terbaru yang lebih kuat, seperti PBVI [34] dan HSVI [30]. Alasannya adalah karena U-Tree adalah metode murni berbasis simulasi, dan tidak memerlukan ruang keadaan yang telah ditentukan, probabilitas transisi keadaan, atau probabilitas pengamatan keadaan. U-Tree bekerja dengan baik pada masalah kecil, dan juga terbukti bekerja dalam tugas mengemudi mobil dengan ruang keadaan yang jauh lebih besar. Namun, tugas mengemudi mobil bebas dari pengamatan dan kebisingan tindakan. Tampaknya U-Tree tidak menskalakan dengan baik dengan munculnya noise. Ini mungkin juga menjelaskan mengapa U-Tree bekerja sangat baik di Hallway, tetapi memiliki kinerja yang buruk pada masalah Hallway2 serupa, karena Hallway memiliki posisi khusus untuk menyelesaikan ambiguitas, yang secara efektif mengurangi masalah menjadi beberapa sub-masalah dengan ruang keadaan yang lebih kecil.

Untuk meningkatkan kemampuannya dalam menangani kebisingan pengamatan dan tindakan, U-Tree mungkin memerlukan pengetahuan sebelumnya yang ekstra. Keuntungan terbesar U-Tree dibandingkan algoritma benchmark tersebut adalah dapat diterapkan dalam tugas-tugas eksplorasi di mana dinamika lingkungan tidak diketahui sebelumnya. Namun demikian, masih diinginkan jika U-Tree mampu mengambil keuntungan dari informasi sebelumnya tambahan bila tersedia. Salah satu contoh sederhana adalah statistik keandalan sensor. Dalam domain navigasi labirin, ini akan menjadi probabilitas melihat dinding ketika ada atau tidak ada dinding. Masuk akal untuk mengasumsikan bahwa statistik tersebut dapat diperoleh melalui pengujian sensor offline.

Seperti yang ditunjukkan pada tabel 6, ruang keadaan yang dihasilkan oleh U-Tree seringkali jauh lebih besar daripada ruang keadaan fisik POMDP yang sebenarnya. Ini karena status U-Tree dapat dilihat sebagai bagian dari status keyakinan. Sangat mudah untuk mengubah status U-Tree menjadi status keyakinan dengan menerapkan persamaan pembaruan status (11) di sepanjang konjungsi status U-Tree mundur (yaitu dari daun ke akar) dengan matriks probabilitas pengamatan status POMDP. Dalam perspektif ini, proses pembangkitan status U-Tree memanfaatkan pengalaman simulasi untuk mengidentifikasi status keyakinan yang lebih penting yang membantu memprediksi imbalan yang diharapkan di masa depan dengan lebih baik.

Dengan dua ide di atas, U-Tree dapat lebih ditingkatkan dengan memanfaatkan iterasi nilai berdasarkan status keyakinan POMDP menggantikan iterasi nilai-Q MDP. Pendekatan serupa diambil oleh [43], di mana mereka mengusulkan perpanjangan Memori Sufiks Util McCallum [44] yang memanfaatkan statistik keandalan sensor dan versi modifikasi dari iterasi nilai status keyakinan berbasis titik Perseus [31]. Namun, pendekatan statistik mereka untuk memperoleh probabilitas pengamatan keadaan tampaknya tidak dibenarkan. Untuk setiap

contoh simulasi, mereka menggunakan kemungkinan fitur dunia aktual yang diberikan pengamatan sensor sebagai bobot, tetapi gagal memperbarui kemungkinan ini dengan pengamatan berikutnya. Sebagaimana diakui dalam makalah mereka, memperoleh probabilitas pengamatan keadaan yang tepat melalui simulasi yang diberikan hanya statistik keandalan sensor adalah tugas yang sulit. Menerapkan iterasi nilai berdasarkan status keyakinan sangatlah mudah setelah menyelesaikan kesulitan ini.

### 9.7 KESIMPULAN

Proses keputusan Markov yang dapat diobservasi sebagian (POMDP) menyediakan kerangka matematis yang realistik dari pemodelan pengambilan keputusan di bawah ketidakpastian. Solusi POMDP klasik mengubah POMDP menjadi ruang berkelanjutan Proses keputusan Markov (MDP) menggunakan status keyakinan. Namun, solusi yang tepat dari POMDP sangat sulit. Meskipun metode heuristik dapat digunakan untuk menemukan solusi yang mendekati dalam waktu yang wajar, model POMDP yang lengkap masih diperlukan. U-Tree adalah algoritma pembelajaran penguatan berbasis simulasi murni. Ini hanya membutuhkan serangkaian tindakan dan pengamatan, dan mempelajari model MDP yang lengkap. Kinerja U-Tree sebanding dengan beberapa metode heuristik berbasis kepercayaan, tetapi lebih buruk daripada beberapa metode heuristik terbaru yang lebih kuat untuk memecahkan masalah yang lebih besar dengan lingkungan yang sangat bising. Hal ini diduga karena belum adanya model POMDP yang lengkap. U-Tree dapat lebih ditingkatkan dengan memanfaatkan lebih banyak pengetahuan sebelumnya bila tersedia untuk menyimpulkan model yang kompatibel dengan POMDP, dan kemudian menerapkan beberapa metode status keyakinan heuristik untuk mendapatkan nilai status yang lebih akurat.

## BAB 10

### TENTANG PENGGUNAAN SISTEM INFERENSI FUZZY UNTUK MASALAH PENILAIAN DAN PENGAMBILAN KEPUTUSAN

Fuzzy Inference System (FIS) adalah paradigma populer untuk melakukan penilaian/pengukuran dan masalah keputusan. Dalam aplikasi praktis, penting untuk memastikan sifat monotonisitas antara atribut (input) dan indeks pengukuran (output) dari model penilaian/pengukuran berbasis FIS. Dalam bab ini, kondisi yang cukup untuk model berbasis FIS untuk memenuhi sifat monotonisitas akan diselidiki terlebih dahulu. Kemudian, model Nomor Prioritas Risiko (RPN) berbasis FIS untuk Mode Kegagalan dan Analisis Efek (FMEA) diperiksa. Secara khusus, kerangka FMEA dengan model RPN berbasis FIS yang mempertahankan monotonisitas yang memenuhi kondisi memadai diusulkan. Sebuah studi kasus yang berkaitan dengan penggunaan kerangka FMEA yang diusulkan dalam industri semikonduktor disajikan. Hasil yang diperoleh dibahas dan dianalisis.

#### **10.1 PENDAHULUAN**

Dalam model penilaian/pengukuran berbasis Fuzzy Inference System (FIS), atribut adalah input dari FIS, dan indeks pengukuran adalah output dari FIS. Hubungan antara atribut dan indeks pengukuran dijelaskan oleh seperangkat aturan fuzzy If-then. Penggunaan model FIS dalam aplikasi penilaian/pengukuran sangat populer dalam literatur. Contohnya termasuk model Nomor Prioritas Risiko (RPN) berbasis FIS [1] untuk Mode Kegagalan dan Analisis Efek (FMEA), model Kejadian berbasis FIS [2] untuk FMEA, model penilaian pendidikan berbasis FIS [3], model penilaian kerentanan air tanah berbasis FIS [4], dan berbagai model penilaian risiko berbasis FIS [5-7]. Ada beberapa alasan mengapa model berbasis FIS, daripada model penilaian konvensional, lebih disukai. Ini termasuk (i) model FIS memungkinkan pemodelan hubungan nonlinier antara indeks ukuran dan atribut [1, 4]; (ii) model FIS kuat terhadap ketidakpastian dan ketidakjelasan [5-8]; (iii) atribut dapat mengasumsikan skala kualitatif, bukan kuantitatif [1,3,5]. Berbagai metode untuk meningkatkan paradigma penilaian/pengukuran berbasis FIS, baik secara umum maupun aplikasi khusus, telah diusulkan. Beberapa kemajuan terbaru termasuk model penilaian berbasis FIS hirarkis atau multi-layer [9, 10], model FIS dengan teori hubungan abu-abu [11], sifat-sifat yang berhubungan dengan monotonisitas dari model FIS [2, 9], FIS berbasis model penilaian dengan prosedur pembelajaran [8].

Dalam bab ini, properti monotonisitas model RPN berbasis FIS untuk FMEA diselidiki. Sifat monoton dari paradigma penilaian/pengukuran berbasis FIS telah dijelaskan dalam berbagai kasus. Pentingnya sifat monotonisitas dalam penilaian dan masalah pengambilan keputusan, misalnya penilaian pembangunan berkelanjutan dan pengukuran daur ulang material, telah dijelaskan sebagai persyaratan alami dalam [9]. Dimungkinkan juga untuk menjelaskan pentingnya sifat monotonisitas dari aspek teoritis fungsi panjang dalam bidang teori ukuran [12]. Skema perbandingan dan/atau pemeringkatan yang valid (yang akhirnya mengarah pada pengambilan keputusan) di antara objek/situasi yang berbeda berdasarkan

indeks pengukuran yang diprediksi adalah penting [2, 13]. Saat menangani masalah penilaian dengan model berbasis FIS, sifat monotonisitas harus dipenuhi sehingga diperoleh hasil yang berarti untuk pengambilan keputusan. Misalnya, dalam model RPN fuzzy, sifat monotonisitas memastikan bahwa risiko di antara mode kegagalan yang berbeda untuk dibandingkan dan diberi peringkat secara logis menggunakan skor RPN fuzzy [2, 13, 14]. Dalam [3], signifikansi monotonisitas dalam model penilaian pendidikan ditekankan, dan kegagalan untuk memenuhi monotonisitas dianggap sebagai anomali.

Tujuan utama dari pekerjaan ini adalah untuk mengembangkan sederhana (yang dapat dengan mudah dipahami oleh pengguna domain), mudah digunakan, namun prosedur yang dapat diandalkan untuk melestarikan sifat monoton dari penilaian berbasis FIS dan model pengambilan keputusan. Secara khusus, kondisi yang cukup untuk model berbasis FIS menjadi monoton [2, 9, 13, 15] diperiksa. Dalam derivasi, FIS diperlakukan sebagai fungsi, dan kondisi cukup adalah kondisi matematis sedemikian rupa sehingga turunan pertama selalu lebih besar atau sama dengan atau lebih kecil dari atau sama dengan nol untuk FIS yang naik atau turun monoton. Dari derivasi, dihasilkan dua hasil. Pertama, pada bagian antecedent diperoleh metode untuk menyetel fungsi keanggotaan; kedua, pada bagian konsekuensi, diperlukan basis aturan yang monoton. Dalam karya ini, kedua kondisi ini diterapkan secara langsung pada model penilaian dan pengambilan keputusan berbasis FIS sebagai solusi untuk mempertahankan sifat monotonisitas.

FMEA adalah metodologi pencegahan masalah yang efektif yang dapat dihubungkan dengan banyak pendekatan rekayasa dan keandalan [16]. Ini adalah kelompok sistematis kegiatan dimaksudkan untuk mengenali dan mengevaluasi potensi kegagalan produk / proses dan efek yang terkait [17]. FMEA mengidentifikasi tindakan yang dapat mengurangi atau menghilangkan kemungkinan kegagalan potensial dari berulang. Ini juga membantu pengguna untuk mengidentifikasi desain utama atau karakteristik proses yang memerlukan kontrol khusus untuk manufaktur, dan untuk menyoroti area untuk perbaikan [17]. FMEA konvensional menggunakan RPN untuk mengevaluasi risiko yang terkait dengan setiap mode kegagalan. RPN adalah produk dari tiga faktor risiko, yaitu, Severity (S), Occurrence (O), dan Detect (D). FMEA mengasumsikan bahwa ada beberapa mode kegagalan, dan setiap mode kegagalan memiliki tingkat risiko berbeda yang harus dievaluasi, dan diberi peringkat. Secara umum, setiap nilai S, O, atau D adalah bilangan bulat antara 1 dan 10, dan ditentukan berdasarkan tabel skala. Model RPN konvensional dapat digantikan oleh model penilaian berbasis FIS [1, 2, 8, 13, 14]. Model RPN berbasis FIS memungkinkan hubungan antara skor RPN dan tiga faktor risiko (S, O, dan D) menjadi nonlinier, yang terlalu rumit untuk dimodelkan oleh model RPN konvensional sederhana. Model RPN berbasis FIS telah berhasil diterapkan pada sejumlah masalah FMEA. Contohnya termasuk sistem air umpan tambahan dan sistem kontrol volume kimia di pembangkit listrik tenaga nuklir [18, 19], sistem mesin [20], jalur manufaktur semikonduktor [21], dan kapal penangkap ikan [22].

Tujuan dari pekerjaan ini adalah untuk mengusulkan kerangka kerja FMEA dengan model RPN berbasis FIS yang mempertahankan kemonotonan. Idenya adalah untuk memasukkan kondisi yang cukup ke dalam kerangka FMEA yang berisi model RPN berbasis FIS. Kondisi pertama terdiri dari metode untuk menyempurnakan fungsi keanggotaan model RPN berbasis FIS. Kondisi kedua menyoroti pentingnya memiliki basis aturan monoton untuk

model RPN berbasis FIS. Kondisi ini dapat dilihat sebagai solusi praktis, mudah, dan andal untuk mempertahankan sifat monoton dari penilaian berbasis FIS dan model pengambilan keputusan. Pendekatan yang sama juga dapat diterapkan pada model berbasis FIS lainnya. Untuk mengevaluasi lebih lanjut FMEA yang diusulkan dengan model RPN berbasis FIS, disajikan studi kasus menggunakan data nyata yang dikumpulkan dari pabrik semikonduktor.

Bab ini disusun sebagai berikut. Pada bagian 2, model FIS dan kondisi memadai ditinjau. Pada bagian 3, model RPN berbasis FIS dijelaskan. Kerangka FMEA yang diusulkan dengan model penilaian berbasis FIS dan penerapannya pada proses manufaktur di pabrik semikonduktor disajikan di bagian 4 dan 5, masing-masing. Catatan penutup kemudian disajikan di bagian 6.

## 10.2 TINJAUAN SISTEM INFERENSI FUZZY DAN KONDISI YANG MEMADAI

Sebuah FIS dapat dipandang sebagai kerangka komputasi yang didasarkan pada konsep teori himpunan fuzzy, aturan produksi fuzzy (aturan If-then), dan penalaran fuzzy [24]. Dalam FIS, pengetahuan ahli diwakili oleh basis aturan yang terdiri dari seperangkat Aturan Produksi Fuzzy (FPR). Setiap FPR memiliki dua bagian: anteseden yang merupakan input; konsekuensi yang merupakan output. Secara umum, FPR memiliki bentuk:

$$\begin{aligned} & \text{IF } (x_1 \text{ is } A_1^{j_1}) \text{ AND } (x_2 \text{ is } A_2^{j_2}) \dots \text{ AND } (x_n \text{ is } A_n^{j_n}) \\ & \text{THEN } y \text{ is } B^{j_1 j_2 \dots j_n} \end{aligned} \quad (1)$$

di mana  $x_i$  dan  $y$  masing-masing adalah input dan output dari FIS;  $A$  dan  $B$  adalah variabel linguistik dari input dan output, masing-masing.  $A$  diwakili oleh fungsi keanggotaan fuzzy, diberi label sebagai  $(x)$ . Outputnya diperoleh dengan menggunakan FIS orde nol sebagai:

$$y = f(\bar{x}) = \frac{\sum_{j_n=1}^{M_n} \dots \sum_{j_2=1}^{M_2} \sum_{j_1=1}^{M_1} \mu_1^{j_1}(x_1) \times \mu_2^{j_2}(x_2) \times \dots \times \mu_n^{j_n}(x_n) \times b^{j_1 j_2 \dots j_n}}{\sum_{j_n=1}^{M_n} \dots \sum_{j_2=1}^{M_2} \sum_{j_1=1}^{M_1} \mu_1^{j_1}(x_1) \times \mu_2^{j_2}(x_2) \times \dots \times \mu_n^{j_n}(x_n)} \quad (2)$$

dimana  $b$  adalah nilai representatif dari fungsi keanggotaan fuzzy  $B$ .

Jika untuk semua  $x^a$  dan  $x^b$  sedemikian rupa sehingga  $x^a < x^b$ , maka untuk suatu fungsi  $f$  naik atau turun secara monoton, kondisinya  $f(x^a) \leq f(x^b)$  atau  $f(x^a) \geq f(x^b)$  harus dipenuhi, masing-masing. Dimungkinkan untuk menyelidiki sifat monotonitas FIS dengan membedakan  $y$  terhadap  $x_i$ . Untuk model yang meningkat secara monoton,  $\frac{dy}{dx_i} \geq 0$ . Dengan

mengunakan aturan hasil bagi, misalkan  $\varphi$  menyatakan  $\prod_{s=1, s \neq i}^n \mu_s^{j_s}(x_s)$ .

Kemudian,

$$u(\bar{x}) = \sum_{j_n=1}^{j_n=M_n} \dots \sum_{j_2=1}^{j_2=M_2} \sum_{j_1=1}^{j_1=M_1} \mu_1^{j_1}(x_1) \times \mu_2^{j_2}(x_2) \times \dots \times \mu_n^{j_n}(x_n) \times b^{j_1 j_2 \dots j_n} = \sum_{j_n=1}^{j_n=M_n} \dots \sum_{j_2=1}^{j_2=M_2} \sum_{j_1=1}^{j_1=M_1} \mu_i^{j_i}(x_i) \times b^{j_1 j_2 \dots j_n} \times \varphi$$

$$v(\bar{x}) = \sum_{j_n=1}^{j_n=M_n} \dots \sum_{j_2=1}^{j_2=M_2} \sum_{j_1=1}^{j_1=M_1} \mu_1^{j_1}(x_1) \times \mu_2^{j_2}(x_2) \times \dots \times \mu_n^{j_n}(x_n) = \sum_{j_n=1}^{j_n=M_n} \dots \sum_{j_2=1}^{j_2=M_2} \sum_{j_1=1}^{j_1=M_1} \mu_i^{j_i}(x_i) \times \varphi,$$

Dan  $\partial = (v(x))^2$

Menggunakan aturan hasil bagi, asumsikan  $\pi^k = \prod_{s=1, s \neq i}^n \mu_s^k(x_s)$  dan  $\pi^l = \prod_{s=1, s \neq i}^n \mu_s^l(x_s)$ ,

$$\begin{aligned} f_{x_i}(\bar{x})' &= \frac{1}{\partial} \left[ \sum_{k=1}^{M'} \sum_{l=1}^{M'} \pi^k \pi^l \left[ \sum_{p=1}^{p=M_i} \sum_{q=1}^{q=M_i} \left( \mu_i^p(x_i) \times \mu_i^q(x_i) \times b^{j_1 j_2 \dots j_i=p \dots j_n} \right) - \sum_{p=1}^{p=M_i} \sum_{q=1}^{q=M_i} \left( \mu_i^p(x_i) \times \mu_i^q(x_i) \times b^{j_1 j_2 \dots j_i=p \dots j_n} \right) \right] \right] \\ f_{x_i}(\bar{x})' &= \frac{1}{\partial} \left[ \sum_{k=1}^{M'} \sum_{l=1}^{M'} \pi^k \pi^l \left[ \sum_{p=1}^{p=M_i} \sum_{q=1}^{q=M_i} \left( \left( b^{j_1 j_2 \dots j_i=p \dots j_n} - b^{j_1 j_2 \dots j_i=q \dots j_n} \right) \left( \mu_i^p(x) \times \mu_i^q(x) \right) \right) \right] \right] \\ f_{x_i}(\bar{x})' &= \frac{1}{\partial} \left[ \sum_{k=1}^{M'} \sum_{l=1}^{M'} \pi^k \pi^l \left[ \sum_{p=1}^{p=M_i-1} \sum_{q=p+1}^{q=M_i} \left( \left( b^{j_1 j_2 \dots j_i=p \dots j_n} - b^{j_1 j_2 \dots j_i=q \dots j_n} \right) \left( \mu_i^p(x) \times \mu_i^q(x) - \mu_i^p(x) \times \mu_i^q(x) \right) \right) \right] \right] \\ f_{x_i}(\bar{x})' &= \frac{1}{\partial} \left[ \sum_{k=1}^{M'} \sum_{l=1}^{M'} \pi^k \pi^l \left[ \sum_{p=1}^{p=M_i} \sum_{q=p+1}^{q=M_i} \left( \left( b^{j_1 j_2 \dots j_i=p \dots j_n} - b^{j_1 j_2 \dots j_i=q \dots j_n} \right) \times \mu_i^p(x) \times \mu_i^q(x) \times \left( \frac{\mu_i^p(x)}{\mu_i^p(x)} - \frac{\mu_i^q(x)}{\mu_i^q(x)} \right) \right) \right] \right] \end{aligned} \quad (3)$$

Dari Persamaan (3), untuk memenuhi  $dy/dx_i \geq 0$ , diperlukan dua kondisi matematis (yaitu kondisi cukup), sebagai berikut:

Kondisi (1):  $b^{j_1 j_2 \dots j_i=p \dots j_n} - b^{j_1 j_2 \dots j_i=q \dots j_n} \geq 0$  pada aturan konsekuensi. Hal ini mensyaratkan bahwa himpunan fuzzy pada aturan konsekuensi menjadi urutan monoton.

Kondisi (2):  $\mu_i^p(x)/\mu_i^p(x) - \mu_i^q(x)/\mu_i^q(x) \geq 0$ . Ini dapat dilihat sebagai metode untuk menyempurnakan fungsi keanggotaan.

Perhatikan bahwa  $\mu'(x)/\mu(x)$  adalah rasio antara laju perubahan derajat keanggotaan dan derajat keanggotaan itu sendiri. Rasio ini mirip dengan prinsip elastisitas dalam matematika dan ekonomi [25]. Asumsikan bahwa  $\mu(x)$  adalah fungsi keanggotaan Gaussian,  $G(x) = e^{-[(x-c)^2]/2\sigma^2}$ . Turunan dari  $G(x)$  adalah  $G'(x) = -((x-c)/\sigma^2)G(x)$ . Rasio  $G'(x)/G(x)$  dari fungsi keanggotaan Gaussian mengembalikan fungsi linier, yaitu,

$$E(x) = G'(x)/G(x) = -\left(1/\sigma^2\right)x + \left(c/\sigma^2\right) \quad (4)$$

Hal ini dapat dilihat sebagai proyeksi fungsi keanggotaan Gaussian yang memungkinkan kondisi yang cukup untuk divisualisasikan.

### 10.3 MODEL ANGKA PRIORITAS RISIKO BERBASIS SISTEM INFERENSI FUZZY

Model RPN berbasis FIS mengambil tiga faktor, yaitu S, O, dan D, dan menghasilkan skor RPN melalui teknik inferensi fuzzy. Secara umum, ketiga faktor ini diperkirakan oleh para ahli sesuai dengan skala dari "1" hingga "10" berdasarkan seperangkat kriteria evaluasi yang disepakati bersama. Tabel 1, 2, dan 3 merangkum kriteria evaluasi, yang digunakan di pabrik semikonduktor, untuk peringkat S, O, dan D, masing-masing.

**Tabel 10.1** Tabel skala untuk Keparahan

Pangkat	Istilah Linguistik	Kriteria
10	<b>Sangat Tinggi</b> (Kewajiban)	Kegagalan akan mempengaruhi keselamatan atau kepatuhan terhadap hukum.
9~8	<b>Tinggi</b> (Keandalan / reputasi)	Dampak pelanggan.
7~6	<b>Sedang</b> (Kualitas / Kenyamanan)	Kunjungan keandalan utama.
5~2	<b>Rendah</b> (Penanganan Khusus)	Mempengaruhi hasil pelanggan.
1	<b>Tidak ada</b> (Tanpa diperhatikan)	Paket/par/penandaan salah.

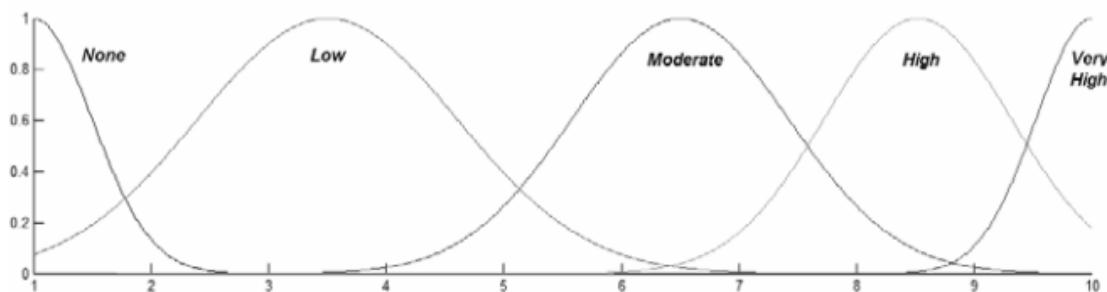
**Tabel 10.2** Tabel skala untuk Kejadian

Pangkat	Istilah Linguistik	Kriteria
10~9	<b>Sangat tinggi</b>	Banyak/shift, Banyak/hari
8~7	<b>Tinggi</b>	Banyak/minggu, Sedikit/minggu
6~4	<b>Sedang</b>	Sekali/minggu, Beberapa/bulan
3	<b>Rendah</b>	Sekali/bulan
2	<b>Sangat rendah</b>	Sekali/seperempat
1	<b>Terpencil</b>	Sekali

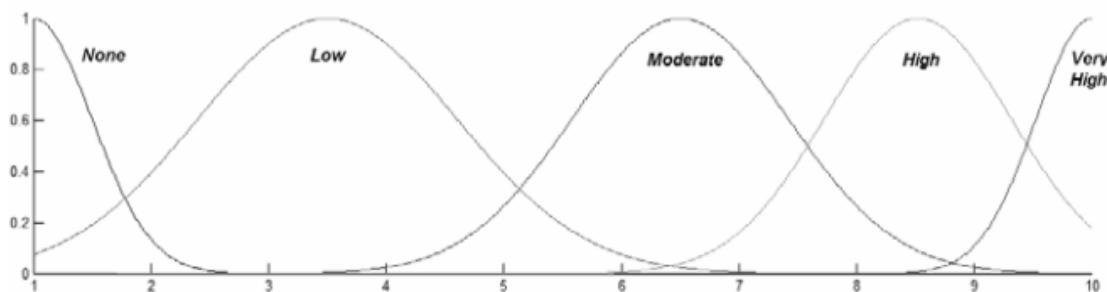
Fungsi keanggotaan S, O, dan D dapat dibangkitkan berdasarkan kriteria masing-masing pada Tabel 1, 2, dan 3. Gambar 1, 2, dan 3 menggambarkan fungsi keanggotaan fuzzy untuk  $S(\mu_s)$ ,  $O(\mu_o)$ , dan  $D(\mu_d)$ , masing-masing. Sebagai contoh, mengacu pada Gambar 1, fungsi keanggotaan kedua S, yaitu, 2 , dengan label linguistik "Rendah" mewakili peringkat S dari 2 hingga 5, yang sesuai dengan "Hasil hasil, Kosmetik" seperti pada Tabel 1. Skenario yang sama berlaku untuk Gambar 2, mis. keanggotaan "Sedang", yaitu  $\mu_o^4$  , mewakili peringkat O dari 4 hingga 6, yang sesuai dengan "Sekali/minggu, Beberapa/bulan" seperti pada Tabel 2. Pada Gambar 3, fungsi keanggotaan "Tinggi", yaitu,  $\mu_d^2$  , mewakili peringkat D dari 3 dan 4, yang sesuai dengan "Kontrol dapat Mendeteksi dalam mesin/modul yang sama" seperti pada Tabel 3.

Keluaran model RPN berbasis FIS, yaitu nilai RPN, bervariasi dari 1 hingga 1000. Dalam penelitian ini, dibagi menjadi lima partisi yang sama, dengan fungsi keanggotaan fuzzy B menjadi "Rendah", "Rendah". Sedang", "Sedang", "Sedang Tinggi", dan "Tinggi". Skor yang

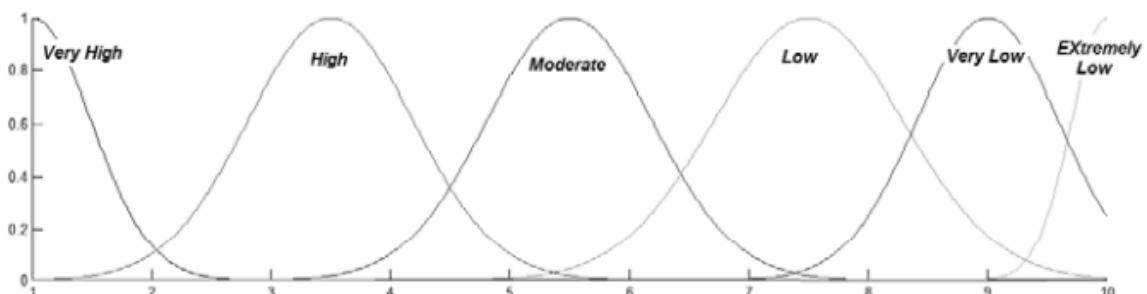
sesuai dari b (nilai representatif dari fungsi keanggotaan keluaran) diasumsikan ke titik dimana nilai keanggotaan B adalah 1. Oleh karena itu, b adalah 1, 250,75, 500,5, 750,25, dan 1000, masing-masing.



**Gambar 10.1** Fungsi keanggotaan Severity



**Gambar 10.2** Fungsi keanggotaan Kejadian



**Gambar 10.3** Fungsi keanggotaan Deteksi

Seperti yang telah dijelaskan sebelumnya, basis aturan fuzzy adalah kumpulan pengetahuan dari para ahli dalam format If-then. Mempertimbangkan S, O, dan D, dan istilah linguistiknya, basis aturan fuzzy memiliki total 180 ( $5 (S) \times 6 (O) \times 6 (D)$ ) aturan menggunakan pendekatan partisi grid. Sebagai contoh, Gambar 4 menunjukkan dua aturan yang menggambarkan sebagian kecil dari aturan fuzzy yang dikumpulkan dari ahli domain (misalnya, insinyur pemeliharaan).

**Aturan 1**

Jika Keparahan Sangat Tinggi dan Kejadian Sangat Tinggi dan Deteksi Sangat Rendah maka RPN Tinggi.

**Aturan 2**

Jika Keparahan Sangat Tinggi dan Kejadian Sangat Tinggi dan Deteksi Sangat Rendah maka RPN Tinggi.

**Gambar 10.4** Contoh dua aturan produksi fuzzy

Dalam karya ini, FIS Sugeno orde nol yang disederhanakan digunakan untuk mengevaluasi RPN:

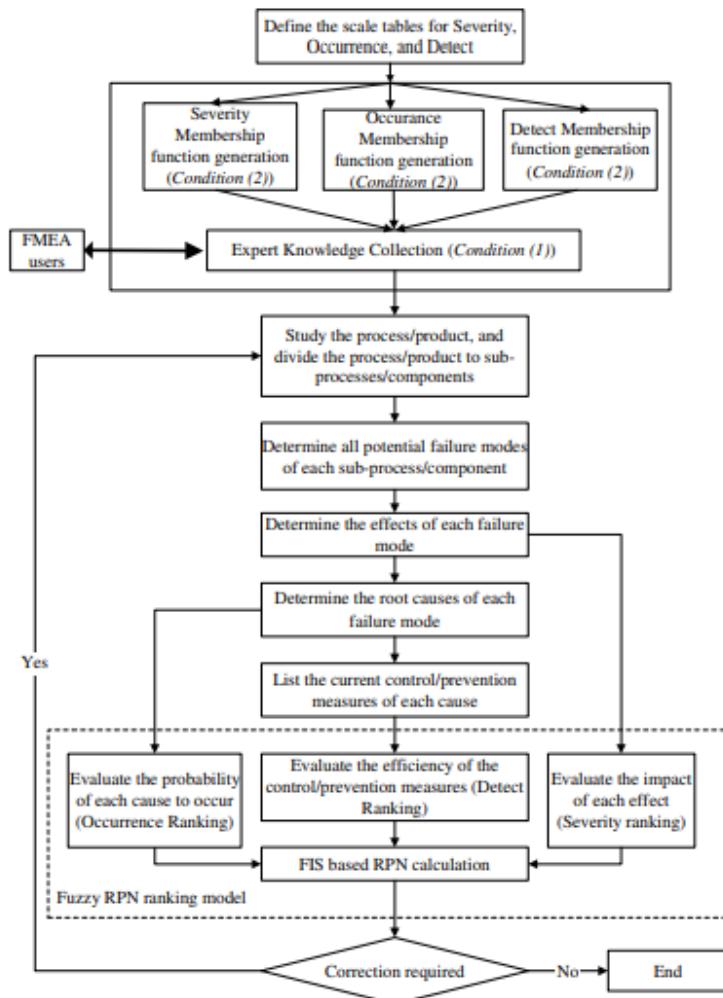
$$\text{Fuzzy\_RPN score} = \frac{\sum_{a=1}^{M_s} \sum_{b=1}^{M_o} \sum_{c=1}^{M_d} \mu_s^a(S) \times \mu_o^b(O) \times \mu_d^c(D) \times b^{a,b,c}}{\sum_{a=1}^{M_s} \sum_{b=1}^{M_o} \sum_{c=1}^{M_d} \mu_s^a(S) \times \mu_o^b(O) \times \mu_d^c(D)} \quad (5)$$

#### 10.4 KERANGKA FMEA YANG DIUSULKAN DENGAN MODEL RPN BERBASIS FIS

Dalam bab ini, dikemukakan bahwa model RPN berbasis FIS perlu memenuhi sifat monotonisitas. Atribut model RPN berbasis FIS (yaitu, peringkat S, O, dan D) didefinisikan sedemikian rupa sehingga semakin tinggi input, semakin kritis situasinya. Output dari model RPN berbasis FIS (yaitu, skor RPN) adalah ukuran risiko kegagalan. Properti monotonisitas penting untuk hubungan input-output dalam praktik, yang memungkinkan perbandingan yang valid antara mode kegagalan [2,13]. Misalnya, untuk dua mode kegagalan dengan set input [5, 5, 6] (mewakili [S, O, dan D]) dan [5, 5, 7], skor RPN untuk mode kegagalan kedua harus lebih tinggi dari atau sama dengan yang pertama. Prediksi tersebut dianggap tidak logis jika model RPN memberikan hasil yang kontradiktif. Hal ini dapat dijelaskan dengan mengacu pada Tabel 1, 2, dan 3. Biarkan dua mode kegagalan memiliki skor S dan O yang sama yaitu 5, tetapi dengan skor D masing-masing 6 dan 7. Mode kegagalan dengan D dari 6 ("Kontrol dapat Mendeteksi dalam area fungsional yang sama") mewakili mekanisme kontrol yang lebih baik daripada D dari 7 ("Kontrol mungkin tidak Mendeteksi ekskusi hingga mencapai area fungsional berikutnya."). Dengan demikian, skor RPN untuk [5, 5, 6] harus lebih rendah daripada [5, 5, 7]. Sifat monotonisitas menyatakan bahwa selama skor D meningkat, skor RPN tidak boleh menurun.

Gambar 5 menggambarkan diagram alur untuk kerangka FMEA yang diusulkan dengan model RPN berbasis FIS yang mempertahankan nada monoton. Perhatikan bahwa kerangka FMEA dengan model RPN berbasis FIS telah diusulkan di [22]. Kerangka kerja yang kami usulkan di sini dapat dilihat sebagai perpanjangan dari itu di [22]. Dalam kerangka yang kami usulkan, kondisi yang memadai secara sistematis dimasukkan ke dalam model RPN berbasis FIS. Gambar 5 menggambarkan diagram alur untuk kerangka kerja FMEA yang diusulkan dengan model RPN berbasis FIS yang mempertahankan nada monoton. Perhatikan bahwa kerangka FMEA dengan model RPN berbasis FIS telah diusulkan di [22]. Kerangka kerja yang

kami usulkan di sini dapat dilihat sebagai perpanjangan dari itu di [22]. Dalam kerangka yang kami usulkan, kondisi yang memadai secara sistematis dimasukkan ke dalam model RPN berbasis FIS.

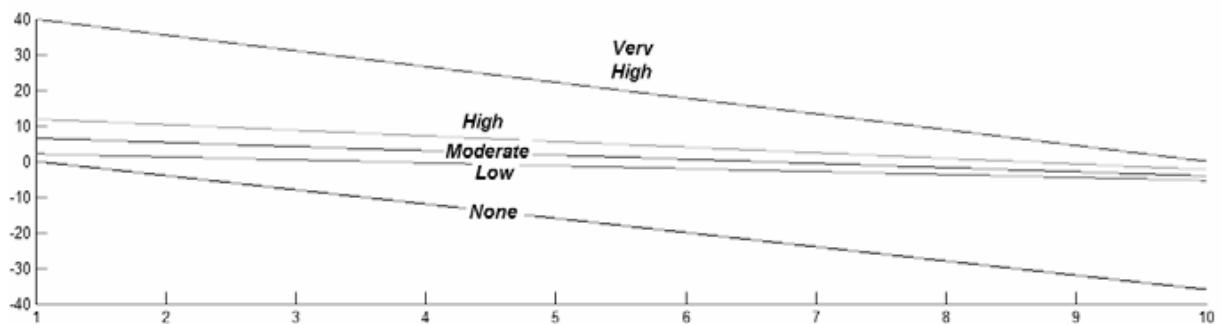


**Gambar 10.5** Prosedur FMEA yang diusulkan dengan model RPN berbasis FIS yang mempertahankan monoton

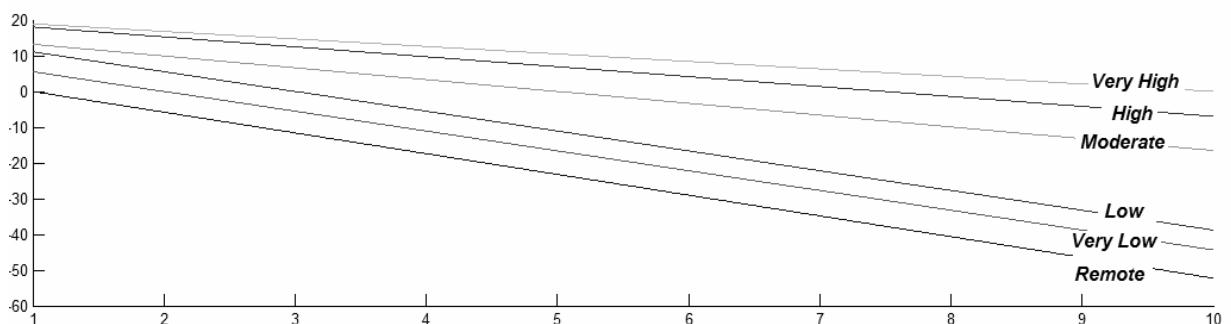
Fungsi keanggotaan S, O, dan D diatur sesuai dengan Kondisi (1). Kondisi (1) dapat dilihat sebagai kriteria untuk seperangkat basis aturan yang valid. Ini digunakan untuk memeriksa validitas basis aturan yang dikumpulkan. Ini juga dapat digunakan sebagai mekanisme umpan balik untuk menginformasikan pengguna FMEA setiap kali aturan yang tidak valid diberikan.

Kondisi (2) dapat digunakan sebagai kriteria untuk menyempurnakan fungsi keanggotaan fuzzy. Gambar 1, 2, dan 3 menggambarkan fungsi keanggotaan untuk S, O, dan D masing-masing, yang memenuhi Kondisi (2). Persamaan (4) memungkinkan kondisi matematis ini untuk divisualisasikan. Sebagai contoh, dengan menggunakan Persamaan (4), fungsi keanggotaan S pada Gambar 1 dapat diproyeksikan sebagai satu set garis linier seperti pada Gambar 6. Dapat dilihat bahwa garis linier yang diubah dari "Tidak Ada", "Rendah", "Sedang", "Tinggi", dan "Sangat Tinggi" berada dalam urutan menaik. Garis linier "Rendah" selalu lebih besar daripada garis "Tidak Ada" di atas semesta pembicaraan (S dari 1 hingga 10). Hal yang sama berlaku untuk fungsi keanggotaan O dan D, masing-masing seperti pada

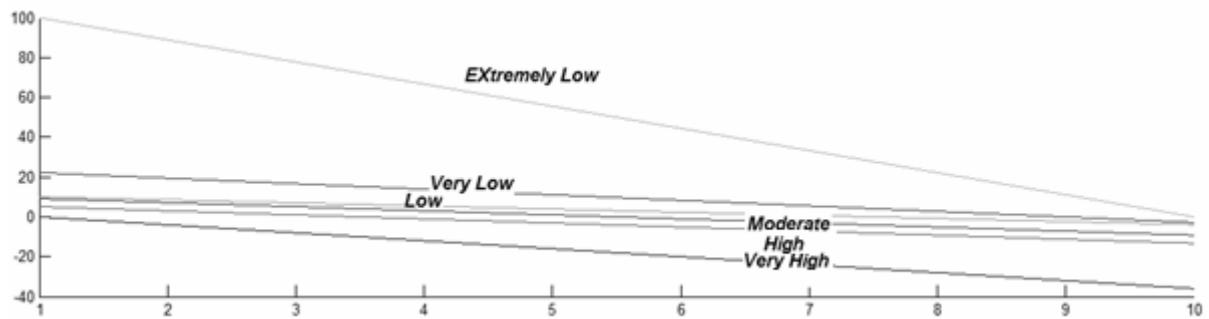
Gambar 2 dan 3. Mereka dapat diproyeksikan sebagai satu set garis linier, seperti pada Gambar 7 dan 8, masing-masing.



**Gambar 10.6** Proyeksi fungsi keanggotaan Severity



**Gambar 10.7** Proyeksi fungsi keanggotaan Kejadian



**Gambar 10.8** Proyeksi fungsi keanggotaan Detect

## 10.5 STUDI KASUS

Untuk memvalidasi kerangka FMEA yang diusulkan, percobaan dengan data/informasi yang dikumpulkan dari proses Flip Chip Ball Grid Array (FCBGA) [23] di pabrik manufaktur semikonduktor dilakukan. FCBGA adalah solusi pengemasan semikonduktor berbiaya rendah yang memanfaatkan teknologi Controlled Collapse Chip Connect, atau dikenal sebagai Flip Chip (FC) untuk interkoneksi die-to-substratnya. FC dimulai pada awal 1960-an untuk menghilangkan ekspansi, tidak dapat diandalkan, dan produktivitas rendah dari proses ikatan kawat manual [23]. Studi kasus pada salah satu proses manufaktur FCBGA, yaitu proses pemasangan wafer, dilakukan.

Pemasangan wafer adalah proses memberikan dukungan kepada wafer dan untuk memudahkan pengolahan wafer dari proses penggergajian melalui die attach sekaligus menjaga dies agar tidak berhamburan saat wafer dipotong. Ini terdiri dari beberapa langkah, *Sistem Pendukung Keputusan (Dr Joseph Teguh Santoso dan Budi Hartono, M.Kom)*

yaitu, 1) pemuatan bingkai; 2) pemuatan wafer; 3) aplikasi pita ke wafer dan bingkai wafer; 4) pemotongan pita berlebih; dan 5) pembongkaran wafer yang terpasang. Sejumlah mode kegagalan potensial yang harus dicegah selama proses ini adalah: wafer retak atau pecah, bubble trapping pada sisi perekat pita, goresan pada sisi aktif wafer, dan ketegangan pita yang tidak seragam yang dapat mengakibatkan pita berkerut. . Dengan metodologi FMEA, mode kegagalan ini, akar penyebabnya, dan konsekuensinya (efek) diidentifikasi. Peringkat S, O dan D dari setiap mode kegagalan disediakan lebih lanjut. Model RPN berbasis FIS juga dibangun dengan prosedur yang diusulkan pada Gambar 5.

Tabel 4 merangkum hasil FMEA menggunakan model RPN berbasis FIS tradisional dan monoton. Kolom "Sev" (S), "Occ" (O), dan "Det" (D) menunjukkan tiga peringkat atribut yang menjelaskan setiap kegagalan. Evaluasi risiko kegagalan dan hasil prioritas berdasarkan model RPN tradisional ditunjukkan masing-masing pada kolom "RPN" dan "RPN rank". Misalnya, pada Tabel 4, mode kegagalan "1" mewakili "wafer rusak", yang menyebabkan kehilangan hasil, dan diberi skor S 3 (lihat Tabel 1). Kegagalan ini terjadi karena "drawing out arm failure", dan karena jarang terjadi, maka diberikan skor O 1 (lihat Tabel 2). Untuk menghilangkan penyebabnya, telah dilakukan peningkatan perangkat lunak sebagai tindakan yang diambil. Karena tindakan yang diambil sangat efektif, yang dapat menghilangkan akar penyebab; diberikan skor D 1 (lihat Tabel 3). Menggunakan model RPN tradisional ( RPN S O D ), diperoleh RPN 3, dengan peringkat RPN terendah (peringkat RPN=1).

Kolom "Fuzzy RPN" menunjukkan hasil evaluasi risiko kegagalan menggunakan prosedur FMEA yang diusulkan. Sub-kolom "FRPN" dan "FRPN Rank" masing-masing menunjukkan evaluasi risiko kegagalan fuzzy dan hasil prioritas. Mengacu pada contoh di atas (failure mode=1), FRPN=2 (menggunakan Persamaan (5)) dan FRPN Rank=1. Kolom "Expert's Knowledge" menunjukkan istilah linguistik yang diberikan oleh maintenance engineer, Low, (Low adalah fungsi keanggotaan fuzzy dengan nilai representatif, b dari 1,00 (seperti pada kolom b)).

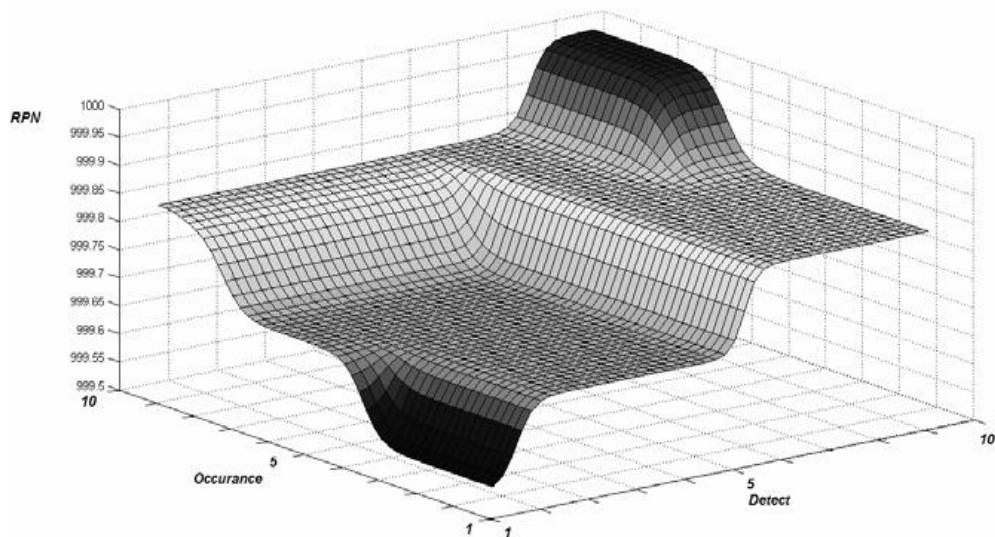
Menggunakan model RPN tradisional yang dengan skema perkalian sederhana ( RPN S O D ), hubungan monotonisitas antara skor RPN dan S, O, dan D dapat dijamin. Namun, ini mengasumsikan hubungan antara skor RPN dan S, O, dan D adalah linieritas, dan mengabaikan informasi kualitatif dalam tabel skala (S, O, dan D). Oleh karena itu, dari Tabel 3, skor RPN yang diprediksi tidak sesuai dengan pengetahuan ahli.

**Tabel 10.3** Hasil evaluasi risiko kegagalan, peringkat dan prioritas menggunakan model RPN tradisional, serta RPN fuzzy dan model yang disempurnakan dari proses pemasangan wafer

Mode Kegagalan	Peringkat input			RPN	RPN Rank	Model RPN kabur			
						RPN Fuzzy		Pengetahuan Pakar	
	Sev	Occ	Det			FRPN	Rank	Istilah linguistik	b
1	3	1	1	3	1	2	1	Rendah	1.00
2	3	2	1	6	2	2	1	Rendah	1.00
3	2	3	2	12	3	80	2	Rendah	1.00

4	3	1	2	6	2	108	3	Rendah	1.00
5	3	2	2	12	3	108	3	Rendah	1.00
6	3	3	2	18	5	108	3	Rendah Sedang	250.75
7	2	4	2	16	4	161	4	Rendah Sedang	250.75
8	2	2	3	12	3	187	5	Rendah Sedang	250.75
9	2	3	3	18	5	187	5	Rendah Sedang	250.75
10	3	4	1	12	3	190	6	Rendah Sedang	250.75
11	3	4	2	24	6	216	7	Rendah Sedang	250.75
12	3	2	3	18	5	251	8	Rendah Sedang	250.75
13	3	3	3	27	7	251	8	Rendah Sedang	250.75
14	3	2	4	24	6	280	9	Rendah Sedang	250.75
15	4	3	4	48	11	285	10	Rendah Sedang	250.75
16	2	2	10	40	9	437	11	Sedang	500.50
17	3	2	5	30	8	472	12	Sedang	500.50
18	3	3	5	45	10	472	12	Sedang	500.50

Dengan model RPN berbasis FIS, skor FRPN yang diprediksi sesuai dengan pengetahuan para ahli. Misalnya, mode kegagalan 1 hingga 5 ditetapkan dengan istilah linguistik Rendah. Ini diikuti oleh mode kegagalan 6 sampai 15, dan 16 sampai 18, yang ditugaskan dengan istilah linguistik Rendah Menengah dan Menengah, masing-masing. Selain itu, dari pengamatan pada Tabel 4, model RPN berbasis FIS (dibangun dengan prosedur seperti pada Gambar 5) mampu memenuhi sifat monotonisitas untuk semua mode kegagalan, tanpa prediksi yang tidak logis. Salah satu metode yang efektif untuk mengamati sifat monotonisitas adalah melalui plot permukaan. Gambar 9 menggambarkan plot permukaan skor RPN fuzzy versus O dan D ketika S diatur ke 10. Permukaan monoton diamati.



**Gambar 10.9** Plot permukaan skor FRPN Kejadian dan Deteksi dengan Keparahan diatur ke 10

## 10.6 KESIMPULAN

Dalam bab ini, pentingnya penilaian berbasis FIS dan model pengambilan keputusan untuk memenuhi sifat monotonisitas diselidiki. Kerangka kerja FMEA dengan model RPN berbasis FIS yang mempertahankan monotonisitas telah diperiksa. Properti monotonisitas sangat penting untuk memastikan validitas skor RPN fuzzy sehingga perbandingan logis antara mode kegagalan yang berbeda di FMEA dapat dibuat. Kondisi yang memadai telah dimasukkan ke dalam kerangka FMEA. Ini adalah solusi sederhana, mudah, dan andal untuk mempertahankan monotonisitas dalam model RPN berbasis FIS. Sebuah studi kasus tentang penerapan kerangka FMEA dengan model RPN berbasis FIS untuk proses semikonduktor telah disajikan. Hasilnya menunjukkan pentingnya sifat monotonisitas model RPN berbasis FIS.

Dimungkinkan untuk menggunakan pendekatan serupa (dengan menerapkan kondisi yang memadai) dalam model penilaian berbasis FIS lainnya. Selain itu, ada baiknya untuk menyelidiki sifat lain dari fungsi panjang, misalnya, sub-aditifitas [12], untuk penilaian berbasis FIS dan model pengambilan keputusan dalam pekerjaan masa depan.

**BAGIAN II**

**ULASAN DAN APLIKASI SISTEM PENDUKUNG KEPUTUSAN CERDAS**

**BAB 11**

**SISTEM PENDUKUNG KEPUTUSAN DALAM TRANSPORTASI**

Bab ini menjelaskan transportasi khusus – Sistem Pendukung Keputusan berbasis komputer (DSS-s). Definisi dan klasifikasi DSS-s berorientasi transportasi disajikan dan ciri-ciri khusus DSS-s mutakhir yang diterapkan dalam transportasi dicirikan. Kategori utama masalah keputusan, termasuk yang operasional, taktis dan strategis, diselesaikan dengan DSS-s berorientasi transportasi disajikan. Tren penelitian saat ini dalam merancang dan mengembangkan DSS-s untuk transportasi dibahas. Metodologi utama yang memfasilitasi proses pengambilan keputusan yang didukung oleh DSS-s yang berfokus pada transportasi serta teknologi informasi terkini yang diterapkan dalam sistem tersebut dilaporkan. Bab ini mencakup tinjauan 43 DSS-s yang diterapkan oleh berbagai sektor transportasi, seperti: transportasi jalan, perkotaan, udara, kereta api, dan lintas laut.

### **11.1 PENDAHULUAN**

Transportasi adalah industri besar yang telah menghasilkan di Eropa 10% hingga 12% dari PDB Eropa secara keseluruhan, baru-baru ini [45], [55]. Diperkirakan sekitar 1 juta perusahaan transportasi (operator) menawarkan layanan mereka di pasar Eropa, yang sangat kompetitif dan sangat beragam. Situasi serupa diamati di Amerika Utara dan di kawasan Asia-Pasifik. Perusahaan yang bersaing di pasar ini berbeda dalam tingkat penjualan yang dihasilkan, jumlah karyawan, dan ukuran armada. Bisnis keluarga kecil mempekerjakan 1-5 orang dan mengoperasikan armada 1-3 kendaraan. Mereka menghasilkan pendapatan tahunan sebesar Rp 1.500.000.000 – Rp 15.000.000.000. Perusahaan terbesar mempekerjakan beberapa ribu karyawan, mengoperasikan ratusan armada kendaraan dan menghasilkan penjualan tahunan sebesar Rp 15.000 miliar hingga Rp 300.000 miliar. Karena persaingan yang kuat, industri transportasi ditandai dengan profitabilitas yang relatif rendah. Di sektor transportasi jalan AS, misalnya, margin keuntungan untuk 100 operator teratas berkisar antara 3,0% hingga 3,5% untuk tahun-tahun sebelum krisis keuangan [49], [51]. Karena profitabilitas sektor ini rendah, perusahaan transportasi tertarik pada penghematan biaya, optimalisasi pemanfaatan armada dan rasionalisasi proses pengambilan keputusan mereka.

Karena argumen yang disebutkan di atas, banyak upaya telah dilakukan untuk mengembangkan: keputusan tingkat lanjut – metodologi bantuan, prosedur pengambilan keputusan yang andal, metode dan algoritma optimasi yang efisien serta alat komputer yang ramah pengguna untuk transportasi. Banyak ide inovatif berbantuan komputer telah diusulkan untuk meningkatkan kepuasan pelanggan dalam transportasi, menyediakan layanan transportasi yang lebih aman dan andal, mengurangi biaya dan meningkatkan profitabilitas kegiatan transportasi, memberikan kepuasan lebih kepada karyawan perusahaan transportasi, meningkatkan infrastruktur transportasi, lebih baik mencocokkan penawaran

dan permintaan di sektor transportasi, dan banyak lainnya. Alat berbasis komputer untuk transportasi menyediakan fungsionalitas yang berbeda dan memecahkan berbagai kategori masalah keputusan transportasi, seperti: rute dan penjadwalan kendaraan, penjadwalan kru, komposisi dan penggantian armada, optimalisasi portofolio layanan, pemeliharaan dan renovasi infrastruktur armada dan transportasi., evaluasi proyek transportasi, dan lain-lain. Bab ini menyajikan tinjauan komprehensif tentang Sistem Pendukung Keputusan berbasis komputer yang berorientasi pada transportasi yang ada. Ini terdiri dari elemen-elemen berikut: definisi dan klasifikasi Transportasi – Berorientasi DSS-s, karakterisasi masalah keputusan yang diselesaikan oleh transportasi DSS-s, deskripsi metodologi utama yang mendukung proses pengambilan keputusan dan Teknologi Informasi (TI) terkemuka yang diterapkan dalam transportasi – DSS-s berorientasi dan presentasi mendalam dari DSS-s yang dipilih untuk transportasi.

Karena sektor transportasi biasanya dibagi menjadi sub-sektor berdasarkan pembagian modanya, pendekatan yang sama telah diterapkan dalam bab ini. Dengan demikian, DSS-s yang dianalisis dibagi menjadi: DSS-s transportasi jalan (13), DSS-s transportasi perkotaan (8), DSS-s transportasi udara (10), DSS-s transportasi kereta api (5), transportasi laut DSS-s (2) dan transportasi DSS-s diterapkan di industri yang berbeda, bersama-sama dengan multimodal DSS-s (5). Secara keseluruhan 43 DSS-s telah disajikan. Karena adanya banyak solusi berbasis komputer untuk transportasi, tinjauan yang disajikan tidak lengkap. Namun, ini memberikan contoh yang baik dan representatif dari konsep, solusi dan metodologi yang diterapkan dalam DSS-s berbasis komputer, berorientasi transportasi. Baik DSS-s universal/generik dan masalah atau sektor – spesifik disajikan dan dicirikan. Paket perangkat lunak komersial siap pakai dibandingkan dan dikontraskan dengan DSS-s prototipe yang berasal dari penelitian. Berbagai alat komputer khusus negara dijelaskan, yang memungkinkan kita untuk mencakup spektrum luas wilayah geografis yang menghasilkan berbagai kategori DSS-transportasi.

Karena kenyataan bahwa spektrum definisi umum Sistem Pendukung Keputusan (DSS-s) yang populer dan tersebar luas, disesuaikan dengan area transportasi, sangat luas [8], [41], [47], [48], [67], [70], [71] berbagai kategori alat komputer diklasifikasikan sebagai DSS-s berorientasi transportasi. Berdasarkan definisi yang mengaitkan arti yang lebih luas dengan DSS-s [3], [41], [67] semua alat berbasis komputer yang mendukung proses pengambilan keputusan dalam transportasi dapat diklasifikasikan sebagai DSS-s berorientasi transportasi. Dalam arti ini semua sistem manajemen informasi, metode analisis data dan bahkan spreadsheet yang diterapkan untuk memecahkan masalah keputusan transportasi dapat diklasifikasikan sebagai DSS-s berorientasi transportasi. Berdasarkan definisi lain – definisi DSS-s yang lebih fokus dan sempit [8], [9], [14], [32], [33], [39], [58], disesuaikan dengan bidang transportasi – DSS berorientasi transportasi dapat didefinisikan sebagai sistem berbasis komputer interaktif yang mendukung pengambil keputusan (DM) dalam memecahkan masalah keputusan transportasi yang kompleks, biasanya tidak terstruktur (atau tidak terstruktur dengan baik) [41], [47], [70], [71]. Dalam arti ini, peran ideal dari DSS berorientasi transportasi adalah peran "asisten berbasis komputer" yang menyediakan informasi yang berfokus pada transportasi khusus DM, meningkatkan pengetahuannya tentang masalah keputusan transportasi tertentu dan memperkuat keputusan DM.

keterampilan dalam memecahkan masalah keputusan transportasi yang dipertimbangkan. Pertimbangan yang disajikan dalam bab ini didasarkan pada definisi kedua di atas.

Sama halnya dengan area aplikasi lainnya, DSS-s berorientasi transportasi dijelaskan dengan definisi dan karakterisasi komponen utamanya, termasuk: basis data, basis model, dan antarmuka pengguna [1], [9], [32 ], [71]. Banyak peneliti membuktikan bahwa basis model adalah elemen penting dari DSS berorientasi transportasi [19], [20], [41], [47]. Basis model terdiri dari kumpulan terstruktur alat analisis, teknik pemodelan dan metode pemecahan masalah, termasuk: algoritma universal dan khusus, metode eksak dan perkiraan (prosedur heuristik), yang berlaku dalam memecahkan berbagai masalah keputusan transportasi yang kompleks. Tren saat ini dalam membangun DSS berorientasi transportasi adalah untuk melengkapinya dalam berbagai alat dan metode komputasi yang efisien yang dikembangkan di bidang ilmiah seperti: Riset Operasi (OR), Ilmu Keputusan (DS), Pembantu Keputusan (DA) dan Ilmu Pengetahuan Buatan. Intelijen (AI). Metode-metode tersebut dirancang untuk memecahkan masalah transportasi tertentu, seperti: penugasan armada, perutean dan penjadwalan kendaraan, komposisi armada, penugasan dan penjadwalan kru, pengantian armada, pemeliharaan armada dan lain-lain dan mungkin menemukan solusi optimal atau mendekati optimal untuk itu. masalah [1], [8]. Salah satu tugas DSS berorientasi transportasi adalah memilih prosedur solusi terbaik untuk fitur spesifik dari masalah keputusan yang dipertaruhkan dan mencocokkan metode yang sesuai dengan masalah keputusan yang dipertimbangkan. Dengan demikian, peran penting DSS berorientasi transportasi adalah untuk membantu DM untuk menavigasi melalui basis model dan basis data, membantu DM dalam pemrosesan dan ekstraksi data, mendukung DM dalam memanfaatkan data dan model serta pemodelan dan penyelesaian masalah keputusan transportasi.

## 11.2 KLASIFIKASI TRANSPORTASI – BERORIENTASI DSS-S

Ada banyak klasifikasi DSS-s yang diusulkan oleh penulis yang berbeda, termasuk: E. Turban dan J. Aronson [47], F. Burnstein dan C. Holsapple [8], [9] dan banyak lainnya. Dengan mempertimbangkan pedoman klasifikasi DSS umum dan menyesuaikannya dengan DSS-berorientasi transportasi, daftar lengkap untuk mengklasifikasikan DSS-fokus transportasi dapat juga diusulkan. Meskipun DSS-s berorientasi transportasi dapat diklasifikasikan menurut berbagai kriteria, karakteristik/ukuran/parameter klasifikasi yang paling umum digunakan adalah sebagai berikut [1], [22], [35], [67] (lihat Gambar 1) :

- **Fokus modal**, yang memungkinkan untuk membedakan DSS-s airborne – transportasi, DSS-s transportasi air (laut dan perairan darat) DSS-s, DSS-s transportasi darat, DSS-s transportasi kereta api dan transportasi multimodal DSS-s, termasuk kategori khusus DSS-s angkutan kota umum.
- **Ukuran dan cakupan**, yang membagi DSS-s berorientasi transportasi menjadi: pengguna tunggal, sistem individual, biasanya berada di komputer pribadi (PC-s) manajer transportasi; jaringan kecil dan/atau DSS-berorientasi kelompok yang mendukung kegiatan bersama tim, yang anggotanya melaksanakan tugas individu tetapi terkoordinasi (misalnya perencanaan rute oleh operator individu), terpusat, DSS-lebar perusahaan yang mengatur transportasi kegiatan dan proses di unit organisasi yang berbeda dari perusahaan.

Transportation oriented DSS-s						
Modal focus	Airbone transportation DSS-s	Waterbone transportation DSS-s	Road transportation DSS-s	Rail transportation DSS-s	Multimodal transportation DSS-s	Public urban transportation DSS-s
Size and scope	Single user oriented DSS-s					
Conceptual focus	Communication driven DSS-s					
Problem solving approach	Passive DSS-s	Active DSS-s	Cooperative DSS-s	Model driven DSS-s	Knowledge driven DSS-s	
Organizational level/	Strategic DSS-s					
Time horizon	Tactical DSS-s					
Subject scope and focus	Fleet management	Transportation personnel mgmt. DSS-s	Transportation processes mgmt. DSS-s	Supply chain mgmt. DSS-s	Marketing mgmt. DSS-s	
Underlaying decision making methodology	Optimization based DSS-s	Simulation based DSS-s	Game theory based DSS-s	Data mining based DSS-s	Hybrid methodology	DSS-s
Character of data	Deterministic DSS-s	Non-deterministic DSS-s				
Time variability of data	Static DSS-s	Dynamic DSS-s				
Internet utilization	On-line DSS-s	Off-line DSS-s				
Communication with user	Passive, Single phase DSS-s	Interactive DSS-s				

**Gambar 11.1 Klasifikasi Transportasi – Berorientasi DSS-s**

- **Fokus konseptual**, yang memungkinkan untuk mengenali kategori transportasi – DSS-s berorientasi berikut: komunikasi – DSS-berorientasi, yang fokus pada pertukaran informasi di antara orang-orang yang mengerjakan tugas bersama; data-driven DSS-s, yang menekankan akses dan manipulasi pada berbagai kategori data internal dan eksternal; DSS-s berbasis dokumen, yang terutama memfasilitasi manajemen, pengambilan dan manipulasi informasi tidak terstruktur yang dikumpulkan dalam dokumen yang berbeda dan penanganannya dalam berbagai format elektronik; model-driven DSS-s, yang menyediakan akses ke berbagai alat analisis, teknik pemodelan dan metode pemecahan masalah yang dapat memecahkan berbagai masalah keputusan transportasi yang kompleks dan pengetahuan-driven DSS-s, yang dicirikan oleh masalah khusus – keahlian pemecahan yang disimpan dalam bentuk fakta yang ditafsirkan, aturan keputusan, mekanisme eksplorasi.

- **Pendekatan pemecahan masalah**, yang membagi DSS-s berorientasi transportasi menjadi: sistem pasif, yang tidak menyarankan pendekatan alternatif dan tidak memberikan metode solusi yang berbeda untuk masalah keputusan tertentu; sistem aktif yang mendukung DM dalam memilih prosedur solusi yang paling sesuai dan sistem kooperatif yang memungkinkan DM untuk memodifikasi dan menyesuaikan prosedur solusi pada berbagai tahap proses pengambilan keputusan.
- **Tingkat organisasi** di mana keputusan dibuat dan cakrawala waktu yang terkait dengannya, yang membagi DSS-berorientasi transportasi menjadi: DSS-strategis yang menangani situasi keputusan pada tingkat organisasi tertinggi, terkait dengan tujuan jangka panjang dari organisasi/sistem transportasi; DSS taktis yang mendukung manajer tingkat menengah dan atas dari perusahaan/sistem transportasi yang menangani perencanaan dan pengendalian jangka menengah dan DSS operasional yang mendukung manajer tingkat bawah dalam keseharian mereka (jangka pendek). ) kegiatan manajerial.
- **Lingkup dan fokus subjek**, yang menentukan area penerapan DSS-s berorientasi transportasi yang tepat; kriteria ini memungkinkan untuk membedakan kategori berikut dari sistem komputer untuk transportasi: sistem manajemen armada, termasuk: sistem komposisi armada (ukuran armada dan sistem pemilihan jenis kendaraan), sistem penggantian armada, sistem perbaikan dan pemeliharaan kendaraan, sistem pelacakan dan pemantauan kendaraan dan konsinyasi , sistem perutean dan penjadwalan kendaraan, sistem manajemen proses transportasi dan sistem manajemen rantai pasokan dengan solusi transportasi yang disesuaikan, sistem pengiriman barang, sistem manajemen kecelakaan armada, sistem kontrol konsumsi dan pengeluaran bahan bakar elektronik, sistem manajemen personel transportasi, termasuk penugasan kru dan kru sistem penjadwalan, sistem pelatihan personel dan pengembangan karier, sistem perekutan kru.
- **Metodologi pengambilan keputusan yang mendasari**, yang membedakan:
  - optimasi – transportasi berbasis – DSS-s berorientasi (tujuan tunggal dan ganda);
  - simulasi – transportasi berbasis – DSS-berorientasi;
  - teori permainan – transportasi berbasis – DSS-berorientasi;
  - penambangan data / eksplorasi – transportasi berbasis – DSS-berorientasi;
  - transportasi metodologi hibrid – DSS-berorientasi (misalnya optimasi gabungan dan sistem berbasis simulasi);
- **Karakter data** yang ditangani oleh DSS, yang memungkinkan kita mengenali DSS-s berorientasi transportasi deterministik dan non-deterministik; DSS berorientasi deterministik, yang menangani parameter tajam yang didefinisikan secara tepat masih sangat populer dalam aplikasi transportasi; DSS-s non-deterministik, termasuk sistem berbasis stokastik dan fuzzy mendapatkan popularitas lebih dan lebih dalam transportasi (misalnya jendela waktu dalam VRP dapat dimodelkan sebagai angka fuzzy atau distribusi probabilitas).
- **Variabilitas waktu dari data** yang ditangani oleh DSS; kriteria ini menghasilkan pengenalan DSS berorientasi transportasi statis dan dinamis (tergantung waktu); dinamis (tergantung waktu) DSS-s saat ini merupakan solusi paling populer untuk

transportasi; mereka mengumpulkan data langsung dari sistem transportasi (on-line), memproses dan memodelkannya dan akhirnya menggunakan untuk optimalisasi dinamis masalah keputusan transportasi.

- **Pemanfaatan internet** selama proses pengambilan keputusan memungkinkan kita untuk menentukan DSS-s berorientasi on – line dan off – line transportasi.
- **Cara komunikasi dengan pengguna**, yang memungkinkan kita membedakan antara DSS-s fase tunggal pasif dan DSS-s interaktif; kategori pertama DSS-s setelah menerima data input memprosesnya dan menghasilkan solusi yang disajikan kepada pengguna; kategori kedua dari DSS-s memungkinkan DM untuk melakukan dialog dengan sistem komputer; proses pengambilan keputusan terdiri dari fase komputasi yang bergantian dengan fase pengambilan keputusan.

### **11.3 KATEGORI UTAMA MASALAH KEPUTUSAN YANG DIPECAHKAN OLEH TRANSPORTASI DSS-S**

Secara umum, tujuan keseluruhan dari setiap DSS berorientasi transportasi adalah untuk mendukung DM dalam memecahkan masalah keputusan transportasi yang konkret atau spektrum masalah tersebut. Beberapa DSS-s sangat terfokus dan memecahkan satu kategori masalah keputusan transportasi saja; yang lain lebih kompleks dan menangani masalah transportasi yang lebih luas. DSS-s dirancang dan dibangun sedemikian rupa sehingga menjamin penerapannya di perusahaan, organisasi, dan sistem transportasi dunia nyata. Entitas-entitas tersebut secara teratur menangani berbagai kategori masalah keputusan dan mengharapkan dari DSS-s untuk diberi tahu dan didukung dalam memecahkannya. Dalam keadaan ini, penting untuk menyadari apa masalah keputusan transportasi utama yang diselesaikan oleh DSS-s yang berbeda. Demi kejelasan kita mulai dengan definisi masalah keputusan, yang merupakan tugas atau pertanyaan kompleks yang membutuhkan solusi atau keputusan [7], [8], [67]. Itu muncul ketika DM mencari tindakan yang paling diinginkan (keputusan, varian) di antara banyak tindakan yang layak (keputusan, varian). Berdasarkan penelitian survei komprehensif yang dilakukan oleh J. Zak [66] daftar berikut dari masalah keputusan transportasi yang paling penting telah dibangun:

- **Peramalan situasi pasar transportasi**, berdasarkan data yang diekstraksi dan fenomena eksternal yang diamati;
- **Jumlah tenaga kerja** di perusahaan transportasi, unit organisasi atau proses dan sistem transportasi; definisi jumlah karyawan yang optimal untuk satu set pekerjaan transportasi, terkait erat dengan seleksi (perekrutan) karyawan (khususnya pengemudi) untuk posisi / tugas tertentu;
- **Desain/konstruksi portofolio layanan transportasi yang paling diinginkan**; pencocokan permintaan yang diwakili oleh berbagai kategori pesanan masuk dan penawaran yang diwakili oleh layanan yang dapat ditawarkan;
- **Mengelola pemenuhan pesanan transportasi** pada tahapan yang berbeda, termasuk: keputusan mengenai penerimaan atau penolakan pesanan yang masuk, menyusun penawaran atau proposal untuk pelanggan, definisi harga layanan transportasi yang sesuai (masalah harga; definisi tarif ), pelacakan dan pemantauan konsinyasi;

- **Penugasan kendaraan untuk pekerjaan/rute transportasi;** mencocokkan pekerjaan transportasi dengan fitur khusus dan kendaraan dengan karakteristiknya (termasuk kapasitas);
- **Komposisi armada dalam suatu perusahaan/sistem transportasi,** meliputi: pemilihan jenis/kategori/merek kendaraan yang paling sesuai dengan pekerjaan transportasi yang akan dilakukan dan pendefinisian ukuran armada (jumlah kendaraan) di masing-masing kategori armada;
- **Rute dan penjadwalan kendaraan** sering digabungkan dengan penugasan dan penjadwalan kru (rostering), yang terdiri dari definisi rute rasional untuk kendaraan dan tugas/tugas khusus untuk kru, yang menghasilkan definisi pergerakan armada dan kru yang optimal di ruang angkasa dan waktu;
- **Penggantian dan perawatan armada,** termasuk analisis dan pemantauan kondisi teknis armada (sangat penting dalam transportasi udara), penjadwalan layanan perawatan dan perbaikan kendaraan serta penggantianya pada saat-saat tertentu dalam hidupnya;

Kategori masalah keputusan transportasi tersebut di atas mungkin memiliki karakter yang sedikit berbeda antar moda/sektor transportasi. Dengan demikian, formulasi dan prosedur penyelesaiannya mungkin berbeda karena fitur khusus dari masalah di berbagai bidang transportasi. Beberapa masalah (misalnya rute kendaraan) dapat memiliki karakter operasional di satu sektor (barang, transportasi jalan) dan karakter strategis di sektor lain (transportasi umum perkotaan dan transportasi penumpang udara). Penanganan masalah keputusan juga dapat berbeda tergantung pada ukuran perusahaan transportasi yang dipertimbangkan dan prosedur manajerial yang diterapkan. Harga untuk layanan transportasi tertentu, misalnya, mungkin memiliki karakter ad-hoc di perusahaan transportasi barang yang lebih kecil dan dapat dinegosiasikan kasus per kasus sementara mereka mungkin memiliki karakter taktis – strategis di perusahaan transportasi barang yang lebih besar, yang menentukan ukuran / tarif tergantung berat dan jarak yang berlaku untuk jangka waktu tertentu. Definisi harga didasarkan pada prinsip yang berbeda dalam transportasi penumpang udara (harga variabel tergantung pada standar pelayanan dan ketersediaan kursi) dan transportasi penumpang jalan (harga tetap). Penugasan pekerjaan transportasi untuk kendaraan tertentu juga berbeda di seluruh sektor transportasi dan perusahaan. Biasanya memiliki karakter statis di perusahaan transportasi udara serta di perusahaan transportasi jalan dan kereta api yang lebih besar (static dial – a – ride problem), sedangkan memiliki karakter dinamis di perusahaan transportasi jalan menengah.

Terlepas dari perbedaan yang disebutkan di atas antara masalah keputusan transportasi di sektor dan perusahaan transportasi yang berbeda, karakteristik umum dan fitur utamanya serupa. Daftar masalah keputusan transportasi yang disebutkan di atas dapat dicirikan sebagai berikut:

- Masalah keputusan transportasi dapat memiliki karakter yang berbeda, termasuk: operasional, taktis dan strategis; karakter masalah tertentu mungkin berbeda tergantung pada sektor/moda transportasi dan ukuran perusahaan transportasi;

- Ciri-ciri pokok masalah keputusan transportasi dan klasifikasinya serupa untuk semua sektor/moda transportasi; kategori dominan dari masalah keputusan transportasi dapat diklasifikasikan sebagai: masalah manajemen armada (komposisi armada, rute dan penjadwalan kendaraan, penugasan kendaraan untuk pekerjaan transportasi, pemeliharaan armada dan penggantian armada), masalah pemasaran dan layanan pelanggan (harga jasa transportasi, konstruksi/optimasi portofolio jasa transportasi, peramalan situasi pasar transportasi, pengelolaan pemenuhan pesanan transportasi), masalah manajemen sumber daya manusia (pengukuran tenaga kerja, rekrutmen – seleksi karyawan, penugasan dan penjadwalan kru) dan masalah keuangan lemah yang meliputi semua kategori yang disebutkan sebelumnya dan melekat pada isu-isu seperti: optimasi biaya, analisis profitabilitas;
- Sebagian besar masalah keputusan transportasi yang disebutkan di atas memiliki karakter kuantitatif; sehingga model keputusan dan prosedur solusi yang sesuai dapat dibangun untuk memecahkan masalah ini dan menemukan solusi optimal untuk mereka; dalam banyak kasus, masalah keputusan transportasi yang dipertimbangkan memiliki karakter dan kepentingan ganda yang objektif (seringkali bertentangan) dari pemangku kepentingan yang berbeda (pelanggan, manajer dan karyawan perusahaan transportasi, pemilik / pemegang saham perusahaan transportasi, masyarakat lokal, mitra bisnis - pemasok) dapat dikenali saat menganalisis masalah ini;
- Banyak masalah keputusan transportasi dapat dirumuskan sebagai masalah optimasi kombinatorial (misalnya masalah rute dan penjadwalan kendaraan, masalah komposisi dan penggantian armada, masalah penugasan kru dan penjadwalan); model matematika mereka dicirikan oleh peningkatan presisi dalam deskripsi fenomena dunia nyata; model memperhitungkan sebagian besar faktor yang diamati dalam kenyataan; dengan demikian, masalah keputusan transportasi dijelaskan secara tepat, tetapi pada saat yang sama, karena presisi dan agregasinya dikombinasikan dengan karakter kombinatorialnya, mereka dicirikan oleh kompleksitas komputasi yang tinggi dan meningkat; akibatnya semakin banyak masalah keputusan transportasi diselesaikan dengan metode perkiraan (heuristik khusus dan metaheuristik yang menghasilkan perkiraan yang baik dari solusi optimal) sebagai lawan dari algoritma eksak yang menjamin generasi tepat, solusi optimal terbukti secara matematis.

#### **11.4 METODE UTAMA PROSES KEPUTUSAN DAN TEKNOLOGI INFORMASI TRANSPORTASI DSS-S**

Pengamatan dan fitur yang dikenali dari masalah keputusan transportasi merupakan tren / aliran penelitian utama yang mendukung desain dan pengembangan DSS-transportasi terkini. Mereka juga menyarankan metodologi tertentu yang saat ini sedang dikembangkan untuk mendukung proses keputusan yang dilakukan dalam DSS-s berorientasi transportasi. Itu adalah sebagai berikut:

- Karena kompleksitas komputasional dari masalah keputusan transportasi, prosedur komputasi yang mendekati – heuristik dan metaheuristik semakin sering diterapkan dan diimplementasikan dalam DSS-s berorientasi transportasi. Baik heuristik maupun metaheuristik tidak menjamin generasi solusi optimal. Mereka memungkinkan DM

untuk mendapatkan solusi yang mendekati optimalitas. Karena banyak situasi transportasi memerlukan keputusan real-time, generasi solusi yang baik (perkiraan solusi optimal) dalam waktu singkat adalah prioritas. Dalam banyak kasus, heuristik khusus terbukti menjadi algoritma yang sangat efisien, meskipun kelemahannya adalah prosedur yang sangat disesuaikan dan hanya dapat diterapkan pada masalah keputusan tertentu. Berbeda dengan mereka, metaheuristik, termasuk: Pencarian Lokal, Pencarian Tabu, Simulasi Annealing dan Algoritma Genetika adalah prosedur meta-komputasi yang memiliki karakter yang sangat universal dan dibangun sebagai skema komputasi umum. Mereka dapat disesuaikan dengan kategori yang berbeda dari masalah keputusan transportasi, terutama masalah optimasi kombinatorial, seperti: rute kendaraan dan masalah penjadwalan, masalah penjadwalan kru, masalah komposisi armada, masalah penggantian armada, masalah penjadwalan pemeliharaan armada, dll. algoritma metaheuristik hybrid yang diterapkan dalam transportasi menjadi semakin populer. Seperti yang ditunjukkan oleh namanya, mereka terdiri dari beberapa (biasanya dua) algoritma metaheuristik gabungan. Kombinasi yang umum adalah: pencarian lokal (untuk menghasilkan solusi awal yang baik dari suatu masalah) dan algoritma genetika (untuk meningkatkan solusi ini) atau pencarian tabu dan algoritma genetika. Dalam bab ini popularitas metode heuristik dalam transportasi telah ditunjukkan dengan jelas. Sistem berikut yang disajikan di bawah ini, antara lain, didasarkan pada prosedur heuristik: Xenios [64], Hastus [63], Tabor [33], Street Routing DSS-s [27], [43], Paragon Routing and Scheduling System [60 ], Sistem Pusat LogiX [56], Manajer Jadwal Sabre AirFlite [63], Rutarep [5].

- Karena proses dan sistem transportasi sangat kompleks, evaluasinya harus bersifat multidimensi. Harus mempertimbangkan beberapa aspek, antara lain: ekonomis (biaya, keuntungan, pemanfaatan aset), sosial (kepentingan karyawan dan masyarakat setempat), orientasi pasar (layanan pelanggan, keandalan, ketepatan waktu, waktu pengiriman), teknis (armada dan kondisi infrastruktur, ketersediaan teknis armada, parameter teknis armada – kecepatan, kapasitas), lingkungan (emisi gas dan kebisingan) dan lain-lain. Selain itu, kegiatan transportasi harus memuaskan banyak pelaku (stakeholder) yang kepentingannya mungkin bertentangan. Biasanya, entitas berikut, dengan kepentingan terkait, disebutkan di antara pemangku kepentingan transportasi: operator / operator – biaya minimal, pelanggan (penumpang, pengirim, perusahaan logistik, produsen)
- layanan pelanggan, pengguna jalan lain (pejalan kaki, pengemudi) – kenyamanan penggunaan jalan, masyarakat lokal – kenyamanan hidup, otoritas lokal dan pemerintah – kepentingan sosial dan politik, keterbatasan anggaran. Untuk alasan-alasan ini Pengambilan Keputusan / Bantuan Kriteria Ganda (MCDM/A) menjadi metodologi pilihan yang digunakan dalam proses pengambilan keputusan untuk transportasi dan aturannya merupakan kerangka kerja untuk membangun DSS-berorientasi transportasi. MCDM/A adalah bidang yang mengembangkan alat dan metode canggih yang memungkinkan DM untuk memecahkan masalah keputusan yang kompleks di mana banyak sudut pandang yang sering bertentangan harus diperhitungkan [67]. Beberapa aplikasi MCDM/A dalam DSS-s berorientasi transportasi

- telah dilaporkan, termasuk karya: N. Caliskan [10], B. Vannieuwenhuyse et al. [50], G. Tavares dkk [43], J. Selih dkk. [38], M. Jakimavicius dan M. Burinskiene [23], C.-C. Kuo dan F. Soflarsky [24], A. Redmer et al. [33] dan J. Zak [67], [68], [70], [72], [73], [74].
- Sebagian besar DSS-s berorientasi transportasi dilengkapi dengan kemampuan grafis. Ini mengacu pada demonstrasi grafis dan interpretasi hasil (Gantt Charts, Jadwal) serta visualisasi solusi transportasi (lokasi, rute) pada peta digital. Untuk alasan ini banyak DSS-s berorientasi transportasi digabungkan dengan Sistem Informasi Geografis (SIG) [18], [25], [31], [56], [59], [60], [62]. Secara formal, GIS terdiri dari data, perangkat lunak, perangkat keras, personel dan pengaturan kelembagaan untuk mengumpulkan, menyimpan, dan menyebarkan informasi tentang wilayah bumi [22]. GIS terdiri dari 3 modul dasar untuk menangani data spasial: antarmuka pengguna grafis (GUI), sistem manajemen basis data (DBMS) dan alat pemodelan spasial. Ini menyediakan 4 fungsi utama, termasuk: pemetaan digital GIS, manajemen data GIS, analisis data GIS dan presentasi data GIS. Pada tahun 1990-an muncul istilah khusus GIS-T yang merupakan singkatan dari GIS untuk transportasi. GIS –T mencakup berbagai fungsi yang mendukung perencanaan strategis dan manajemen operasional transportasi. Itu termasuk: visualisasi arus lalu lintas pada jaringan, pemetaan digital – visualisasi dampak desain, tampilan dan animasi lalu lintas, analisis dan visualisasi rute dan jadwal.
  - Kecenderungan lain yang diamati pada DSS-s berorientasi transportasi adalah kebutuhan akan komunikasi on-line dan pertukaran data yang akurat secara real-time [21]. Untuk alasan ini, semakin banyak solusi bergerak untuk transportasi dikembangkan dan dihubungkan dengan DSS-s berorientasi transportasi. Analisis data operasi transportasi yang andal dan real-time sangat penting untuk memprediksi kejadian tak terduga (kendaraan rem - down, kemacetan lalu lintas, dll) yang dapat terjadi selama transportasi. Informasi ini memungkinkan DM-s untuk merasionalisasi keputusan mereka, termasuk: mengubah rute kendaraan, mengubah jadwal pengiriman, mengganti kendaraan, dll. Karena dalam transportasi kita berurusan dengan asset bergerak, kecenderungan alaminya adalah menerapkan teknologi seluler untuk mendeteksi dan memantau operasinya. . Saat ini ada dua teknologi seluler utama yang memungkinkan transmisi data tentang lalu lintas, yaitu: GSM (Global Systems for Mobile Communications) dan GPRS (General Packet Radio Service). Keduanya menjadi populer dalam aplikasi DSS-s berorientasi transportasi. GSM dicirikan oleh kecepatan transfer data yang lebih rendah dan biaya yang lebih tinggi (per unit waktu), sedangkan kinerja GPRS lebih baik pada dua aspek ini (tarif tetap per unit data yang ditransmisikan dan kecepatan transmisi data yang lebih tinggi: 56 – 112 kbit/dtk.).
  - Fitur baru lain dari transportasi – DSS-s berorientasi adalah penggunaan sumber Internet dan komunikasi Internet. Kecenderungan ini sekali lagi disebabkan oleh karakter transportasi yang mobile dan ketersediaan Internet yang tersebar luas di seluruh dunia. Aplikasi tertentu dari DSS-s transportasi berbasis web telah dilaporkan, termasuk karya: N. Prindezis dan C. Kiranoudis [30], J. Ray [32] dan B. Vannieuwenhuyse et al. [50]. Penerapan DSS-s berbasis Internet dalam transportasi

memunculkan aspek lain dari komunikasi. Karena operator / operator transportasi adalah perantara antara entitas yang berbeda, ketidakcocokan sistem informasi dan komunikasi merupakan masalah serius yang dipertaruhkan. Akibatnya banyak upaya dilakukan untuk menstandarisasi pertukaran data antara terminal, operator, forwarder dan pelanggan. Saat ini, ada dua format utama untuk komunikasi Internet, yaitu: XML (Extensible Markup Language) dan EDIFACT (Electronic Data Interchange for Administration, Commerce and Transport). Standar ini meningkatkan kualitas, keandalan, dan konsistensi informasi, pada saat yang sama meningkatkan kompatibilitas antara beragam sistem komputer dari mitra yang berbeda. Hal ini menghasilkan efisiensi dan kualitas yang lebih tinggi dari proses keputusan yang dilakukan dengan bantuan DSS-s berbasis web.

- Fenomena berikutnya adalah penerapan alat kecerdasan buatan dalam DSS-s berorientasi transportasi, yang mengarah pada penciptaan Intelligent Decision Support Systems (IDSS). Sistem tersebut dicirikan oleh fitur luar biasa dari "pendidikan mandiri". Berdasarkan data historis dan fakta dan kejadian yang ditemui, IDSS-s dapat menangani berbagai masalah kompleks yang tidak mereka ketahui. IDSS-s mampu menghasilkan aturan keputusan tertentu, menafsirkan fakta, menarik kesimpulan tertentu dan saran DMs pada berbagai masalah yang mereka hadapi. Dalam beberapa kasus, DSS-s berorientasi transportasi cerdas dikembangkan sebagai kombinasi dari DSS-s dan Sistem Pakar (ES-s). Mereka menggunakan akumulasi pengetahuan para ahli dalam domain tertentu dan meniru perilaku yang paling rasional berdasarkan keahlian mereka. Teknik kecerdasan buatan yang paling umum digunakan dalam DSS-s berorientasi transportasi adalah: Jaringan Syaraf Tiruan, Logika Fuzzy dan Sistem Fuzzy, metode Data Mining (termasuk Rough Sets), Sistem Berbasis Agen dan banyak lainnya. Dalam survei ini, karya-karya berikut menyajikan transportasi cerdas – DSS-berorientasi: W. Cheung et al. [13], W. Dullaert dkk. [17], J. Mendoza et al. [28], K. Salling dkk. [36], P. Sawicki dan J. Zak [37], J. Zak [69].
- Transportasi – DSS-berorientasi sangat sering memiliki karakter interaktif. Mereka memungkinkan DM-s untuk melakukan "apa - jika" analisis dan membangun skenario alternatif yang berbeda. Berkat itu, pengguna sistem dapat lebih memahami masalah yang dianalisis dan mempelajari fitur spesifik mereka. Dalam interaksi dengan sistem komputer mereka dapat menemukan apa konsekuensi dari keputusan tertentu dan menjadi lebih matang dalam memecahkan masalah keputusan. Prosedur interaktif yang diusulkan dalam DSS-s berorientasi transportasi biasanya dibangun di sekitar mekanisme di mana fase komputasi bergantian dengan fase analisis keputusan. Banyak DSS-s yang disajikan dalam bab ini memiliki karakter interaktif. Contohnya adalah karya: A. Cheung et al. [12], W. Cheung dkk. [13], R. Freling dkk. [20], I. Manataki dan K. Zografos [26], S. Peng dan H. Fan [29], Y. Suzuki [42], J. Zak [68] dan J. Zak et al. [72], [73]. Juga banyak sistem komputer komersial memiliki karakter interaktif, misalnya. LogiX Central System [56], Paragon Routing and Scheduling System [60] atau Hastus [63].
- Aspek terakhir dari transportasi saat ini – DSS-s berorientasi adalah karakter mereka yang semakin kompleks. Sistem dilengkapi dengan berbagai prosedur komputasi,

algoritma, dan alat bantu keputusan. Dalam banyak kasus mereka didasarkan pada metodologi campuran atau gabungan, termasuk: simulasi dan metode optimasi, CAD dan teknik simulasi, metode eksak dan perkiraan (heuristik), algoritma tujuan tunggal dan ganda, metode optimasi dan peringkat, metode optimasi dan peramalan, dll. Contoh-contoh berikut mendukung pernyataan tersebut: I. Manataki dan K. Zografos [26], P. Matis [27], S. Peng, H. Fan [29], J. Selih dkk. [38], G. Tavares dkk. [43] dan J. Zak [70], [71].

### **11.5 REVIEW TRANSPORTASI TERPILIH – BERORIENTASI DSS-S**

Seperti telah disebutkan sebelumnya, analisis DSS-s transportasi telah dilakukan menurut pembagian modanya yang meliputi penyajian: DSS-s jalan – transportasi, DSS-s transportasi perkotaan, DSS-s transportasi udara, kereta api dan transportasi laut. DSS-s, dan DSS-s berorientasi transportasi lainnya, termasuk DSS-s transportasi multimoda dan DSS-s yang digunakan di industri lain. Dalam bagian tersebut, DSS-s populer, komersial, siap pakai telah dibedakan dari solusi prototipe, yang merupakan hasil dari proyek penelitian dan masih memerlukan pengujian tambahan. Karena fakta bahwa transportasi jalan memainkan peran dominan di pasar internasional [7], [35], [49], [55], [66], [67] banyak DSS-s yang disajikan difokuskan pada mendukung keputusan manajerial di sektor ini. Namun, DSS-s transportasi umum dan DSS-s transportasi udara juga telah dibahas secara luas. Kurangnya penekanan diberikan pada transportasi kereta api dan laut karena fakta bahwa sektor-sektor ini sedikit tertinggal di belakang transportasi darat dan udara dalam hal pengembangan solusi berbasis komputer yang mendukung proses pengambilan keputusan. Tinjauan terhadap DSS transportasi yang ada mencakup spektrum yang luas dari metodologi dan teknologi terapan serta menyajikan aplikasi dari berbagai negara. Namun, itu tidak menghabiskan seluruh topik karena keterbatasan ruang.

#### **Transportasi Jalan DSS-s**

Sejauh menyangkut transportasi jalan, DSS-s berikut telah dicirikan: TransCad, Paragon Routing and Scheduling System, LogiX Central System, Route Planner, Truckstops, Pengoptimal pembelian bahan bakar, DSS untuk penugasan pesanan transportasi (FTL dan LTL), Xenios, DSS untuk manajemen pemeliharaan infrastruktur jalan, DSS untuk analisis sistem transportasi, DSS untuk transportasi bahan berbahaya, Tabor dan DSS untuk manajemen sistem transportasi jalan. Beberapa dari mereka termasuk dalam "Sistem Perangkat Lunak Perencanaan Transportasi" komersial, sangat dikenal dan didistribusikan secara intensif di seluruh dunia. Lainnya disesuaikan, produk berorientasi penelitian yang dirancang dan dikembangkan untuk tujuan tertentu dan biasanya ditandai dengan ketersediaan terbatas di pasar.

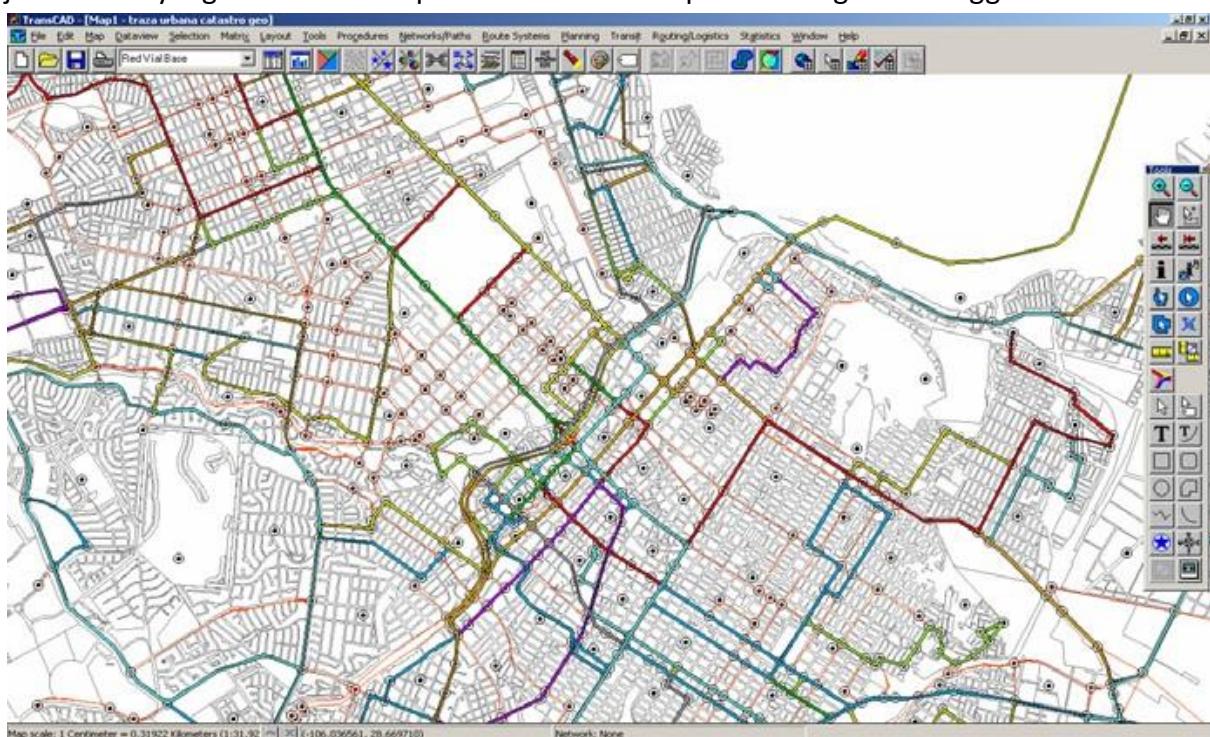
TransCad [62] adalah Sistem Informasi Geografis (SIG) yang dirancang khusus untuk digunakan oleh para profesional transportasi untuk menyimpan, menampilkan, mengelola, dan menganalisis data transportasi. Ini menggabungkan GIS dan kemampuan pemodelan transportasi dalam satu platform terintegrasi. TransCad, yang dapat diterapkan untuk berbagai moda transportasi, dilengkapi dengan komponen utama berikut: Mesin GIS dengan ekstensi khusus untuk transportasi, visualisasi pemetaan dan alat analisis yang dirancang untuk aplikasi transportasi dan modul canggih untuk permintaan perjalanan, peramalan,

angkutan umum, logistik, perutean, lokasi situs, dan manajemen wilayah. TransCad GIS memiliki ekstensi berorientasi transportasi khusus, seperti: jaringan transportasi, matriks transportasi, sistem rute dan data referensi linier. Jaringan transportasi adalah struktur data khusus yang digunakan untuk memodelkan aliran melalui jaringan. Visualisasi jaringan transportasi di TransCad disajikan pada Gambar 2. Matriks transportasi menyimpan data seperti jarak, waktu tempuh, arus asal – tujuan. Sistem rute menunjukkan jalur yang diambil oleh kendaraan yang berbeda (truk, kereta api, mobil, bus). Linear – modul data referensi mengidentifikasi lokasi objek transportasi sebagai jarak dari titik tetap di sepanjang rute. TransCad terdiri dari modul aplikasi transportasi berikut: Analisis Jaringan (NA), Analisis Transit (TA), Perencanaan Transportasi dan Pemodelan Permintaan (TP&DM), Perutean dan Logistik Kendaraan (VR&L), Manajemen Wilayah dan Pemodelan Lokasi Lokasi (TM&SLM) . Setiap modul mencakup sejumlah prosedur dan algoritma komputasi yang berfokus pada area tertentu yang memungkinkan pemecahan masalah keputusan transportasi tertentu. Modul NA mencakup prosedur komputasi berikut: metode jalur terpendek, algoritma partisi jaringan, dan metode salesman keliling. Modul TA mampu memecahkan masalah penugasan lalu lintas, merancang jadwal multi-moda yang optimal, terintegrasi, untuk sistem angkutan massal, menentukan koneksi optimal untuk penumpang yang tunduk pada struktur tarif yang ditentukan dan zona yang telah ditentukan.

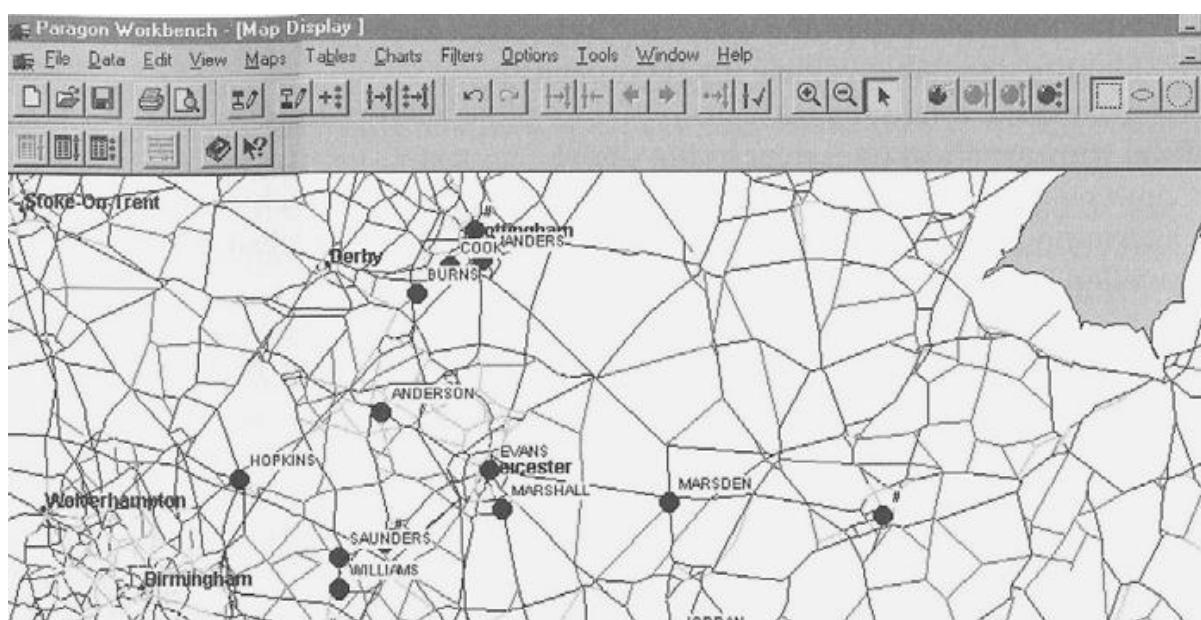
Modul TM&SLM dilengkapi dengan: bangkitan perjalanan, tarikan perjalanan, penyeimbang perjalanan dan model distribusi perjalanan, dilengkapi dengan metode split modal, mengubah prosedur yang mengubah matriks pembangkitan perjalanan – tarikan (G-A) menjadi matriks asal – tujuan dan menguraikan matriks tabel perjalanan 24 jam ke dalam tabel perjalanan per jam, dan metode penugasan lalu lintas. Modul VR&L mencakup: metode perutean dan penjadwalan kendaraan, algoritme perutean busur, serta metode analisis aliran dan distribusi jaringan (metode transportasi, metode aliran biaya minimum, metode penugasan – pencocokan). Modul TM&SLM menyediakan prosedur otomatis untuk pembagian wilayah dan pengelompokan serta pengoptimalan lokasi situs. Dalam modul yang berbeda, algoritma eksak dan perkiraan (heuristik) diterapkan.

Sistem komputer komersial lain yang menyediakan solusi untuk transportasi jalan raya adalah Paragon Routing and Scheduling System [60]. Ini dirancang untuk menghasilkan solusi yang efektif, mendekati – ke – optimal untuk berbagai kategori dan versi yang diperluas dari masalah perutean dan penjadwalan kendaraan (mis. Mengingat rincian armada kendaraan dan pengemudi, bersama dengan pengiriman dan/atau pengambilan yang akan dilakukan, Sistem Paragon menentukan: penetapan pesanan pelanggan untuk kendaraan tertentu, urutan pesanan pelanggan, tabel waktu untuk operasi rute. Sistem Paragon memungkinkan kegiatan kendaraan yang berbasis di beberapa lokasi (depot) yang berbeda untuk direncanakan secara bersamaan. Saat merencanakan rute dan jadwal pemesanan yang efisien, Sistem Paragon mempertimbangkan faktor-faktor berikut: hari dan waktu pemesanan yang dinominasikan, karakteristik kendaraan (kapasitas, kesesuaian untuk pesanan tertentu) dan ketersediaan, waktu parkir, waktu bongkar muat, kecepatan perjalanan pada berbagai jenis jalan, pembatasan mengemudi (waktu mengemudi dan tugas maksimum, frekuensi istirahat).

Fitur utama Paragon adalah modul grafik peta jalan yang kuat, yang memungkinkan pengguna untuk menampilkan file jaringan jalan (peta) dan rute yang dihasilkan di layar (lihat Gambar 3). Selain itu, jadwal numerik dan grafik (grafik batang) dihasilkan oleh sistem. Paragon mengoptimalkan biaya keseluruhan dari rencana pengiriman yang diusulkan. Untuk tujuan ini prosedur heuristik khusus diterapkan. Telah terbukti bahwa penerapan Sistem Paragon mengurangi rata-rata 5% sampai 15% dari total biaya transportasi perusahaan. Selain itu, routing dan penjadwalan kendaraan yang terkomputerisasi dengan penerapan Paragon System lebih efisien dibandingkan dengan perencanaan rute secara manual. Akibatnya, jumlah staf yang terlibat dalam perencanaan rute dapat dikurangi 30% hingga 50%.

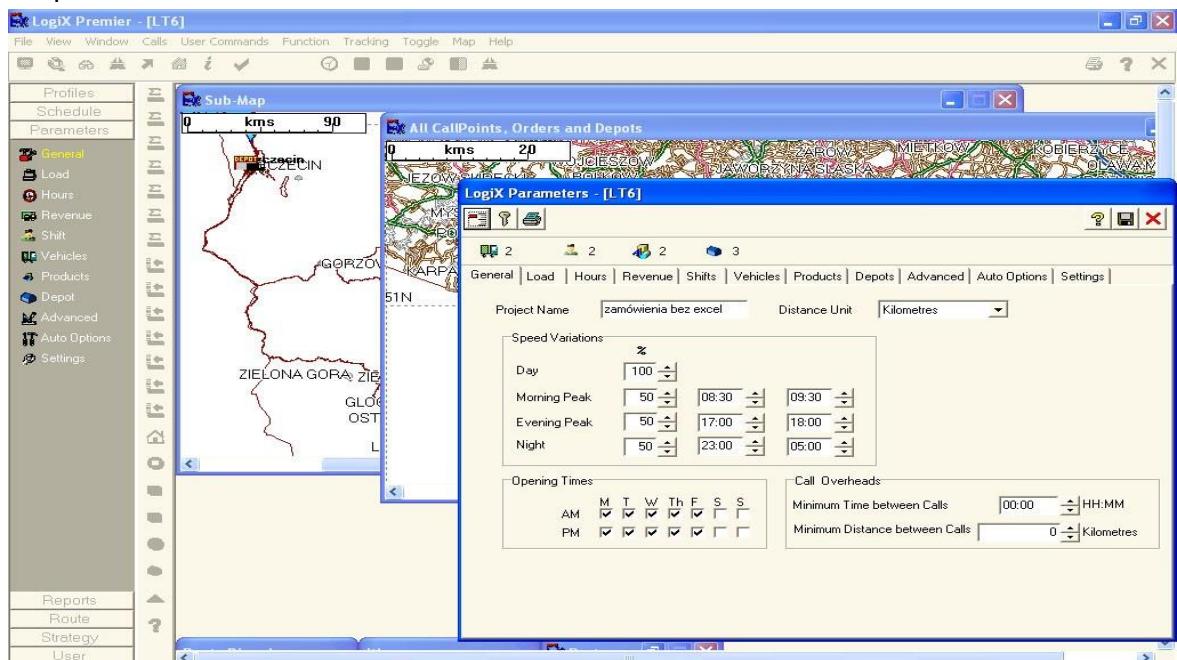


**Gambar 11.2** Visualisasi jaringan transportasi di TransCad



**Gambar 11.3** Peta digital drop point dan depot yang digunakan dalam Sistem Paragon Routing and Scheduling

Paket komersial berikutnya dengan karakter serupa adalah LogiX Central System [56] (lihat Gambar 4), yang menyediakan fungsionalitas berikut: perencanaan rute interaktif dan otomatis, perutean dan penjadwalan kendaraan yang berbasis di depot tunggal dan ganda, perencanaan ulang dan penjadwalan ulang skema pengiriman yang ada (menambahkan pesanan baru ke rute yang ada, perluasan rute yang ada, perencanaan rute berdasarkan pembagian zona), perutean dan penjadwalan dengan depot yang berubah secara dinamis (kendaraan diizinkan untuk memulai dan menyelesaikan rute mereka di depo yang berbeda), pelacakan dan penelusuran kendaraan dan pesanan. LogiX Central System dapat diterapkan pada salah satu level berikut: optimasi rute tunggal, optimasi beberapa rute yang berasal dari satu depot dan optimasi beberapa rute yang berasal dari banyak depot. Dalam kasus yang paling kompleks, ini memecahkan Masalah Perutean dan Penjadwalan Kendaraan Berkapasitas Beberapa Depot dengan Jendela Waktu, Armada Heterogen, dan kendala tambahan. Dalam proses optimasi, kondisi berikut dipertimbangkan: pemanfaatan kendaraan dan pengemudi yang efisien, pembatasan mengemudi, waktu pengiriman dan jendela waktu untuk pelanggan tertentu, prioritas pemenuhan pesanan, batasan tertentu lainnya. LogiX Central System mengoptimalkan total biaya transportasi/distribusi atau fungsi tujuan yang setara (total panjang rute, total waktu pengiriman). Heuristik khusus diterapkan untuk tujuan ini. Hasil akhir dari proses optimasi ditampilkan secara numerik (dalam tabel) dan grafis (pada peta). LogiX Central System terutama diterapkan di jaringan distribusi yang kompleks. Manfaat yang dilaporkan dari penerapannya meliputi: pengurangan total biaya distribusi hingga 25%, pengurangan substansial dari perencanaan manual, peningkatan pemanfaatan armada, tingkat layanan pelanggan yang lebih tinggi dan kontrol yang lebih baik dari proses transportasi.



**Gambar 11.4** Definisi parameter untuk optimasi masalah perutean kendaraan di LogiX Central System

Dua contoh lain dari perutean dan penjadwalan kendaraan Amerika, sistem komersial adalah: Route Planner [54] dan Truckstops [57]. Keduanya memberikan solusi semi-optimal

untuk rute kendaraan yang kompleks dan masalah penjadwalan di jalan raya, industri transportasi barang. Mereka mengalokasikan beban kerja ke kendaraan dan mengurutkan pemberhentian untuk meminimalkan biaya tanpa melanggar batasan yang dikonfigurasi pengguna. Baik Route Planner dan Truckstops mampu memecahkan masalah rute dan penjadwalan kendaraan berkapasitas depot tunggal dan ganda, dengan jendela waktu dan gabungan penjemputan dan pengiriman. Mereka juga memungkinkan pengguna untuk melacak dan melacak kendaraan dan pesanan. Sistem menentukan kecocokan terbaik antara pesanan (karakter muatan) dan kendaraan, mengoptimalkan kembali rencana rute saat pesanan pelanggan berubah, memfasilitasi kontrol terpusat dan dukungan keputusan kolaboratif waktu nyata untuk memastikan distribusi rasional batas teritorial dan fungsional armada , menggunakan peta digital canggih untuk memvisualisasikan jaringan jalan dan rute yang dirancang.

Kedua produk telah menawarkan solusi perutean dan penjadwalan yang terbukti di pasar selama lebih dari 20 tahun. Route Planner dan Truckstops Systems telah digunakan oleh ratusan perusahaan di seluruh dunia (terutama di AS). Operator yang menerapkan salah satu sistem tersebut melaporkan manfaat berikut: 10% hingga 30% pengurangan biaya bahan bakar, 20% hingga 40% peningkatan dalam pemanfaatan kendaraan, dan 10% hingga 20% peningkatan tingkat layanan pelanggan (pengiriman tepat waktu, pengiriman selesai sepenuhnya), hingga 50% pengurangan intensitas tenaga kerja dari proses perencanaan. Selain pengiriman barang tradisional, Truckstops juga menyediakan kemampuan perutean jalan yang penting untuk layanan seperti: pengiriman susu dan surat kabar, pengumpulan sampah, pembersihan jalan , penggilingan jalan, distribusi selebaran, dan pengiriman surat.

Perlu disebutkan bahwa beberapa sistem komersial serupa dengan fasilitas numerik dan grafis, yang menyediakan kemampuan perutean dan penjadwalan kendaraan tersedia di pasar. Semuanya memungkinkan pengguna untuk memecahkan masalah penjadwalan dan rute kendaraan dunia nyata yang diperluas dan menemukan solusi semi-optimal yang tunduk pada sejumlah kendala. Rute dan jadwal kendaraan yang dihasilkan biasanya disajikan pada peta digital dari area yang dipertimbangkan. Sistem tersebut meliputi: Optrak 4 [59], Perencanaan Rute [53], Routemate [58], Logisplan [52] dan Trando [61]. P. Toth dan D. Vigo [44] menyajikan tinjauan komprehensif rute kendaraan dan metode penjadwalan, termasuk beberapa yang telah diimplementasikan dalam sistem komputer.

Selain itu, beberapa perkembangan terakhir dari routing kendaraan dan penjadwalan DSS-s [25], [28], [34], [32] tampaknya sangat menjanjikan Y. Suzuki [42] menjelaskan DSS untuk optimasi dinamis pembelian bahan bakar di perusahaan transportasi jalan yang mengoperasikan armada kendaraan. DSS dapat diklasifikasikan sebagai versi yang disempurnakan dan lebih canggih dari “pengoptimal bahan bakar”, yang merupakan sistem berbasis komputer yang menentukan momen pengisian bahan bakar yang optimal, sesuai dengan “tempat pembelian” konkret (tempat pemberhentian truk) dan jumlah optimal / jumlah bahan bakar yang harus dibeli untuk setiap truk yang melakukan pekerjaan transportasi tertentu. DSS yang diusulkan bertujuan untuk mengatasi keterbatasan utama dari “pengoptimal bahan bakar” lain yang ada yang menyita kebebasan pengemudi truk untuk memilih pemberhentian truk dan tidak mempertimbangkan fluktuasi dinamis harga bahan bakar.

Dua syarat harus dipenuhi untuk menerapkan DSS yang diusulkan: semua kendaraan pengangkut motor harus dilengkapi dengan GPS dan perangkat komunikasi satelit dan pengangkut harus memiliki akses ke basis data harga bahan bakar yang mencatat perubahan harga bahan bakar secara teratur. Masalah keputusan dirumuskan sebagai masalah pemrograman dinamis stokastik, di mana setiap tahap ditentukan oleh kejadian pengisian bahan bakar dan keadaan ditentukan oleh jumlah bahan bakar yang harus dibeli oleh pengemudi sebelum mencapai tujuan akhirnya. Dua kategori variabel keputusan digunakan dalam perumusan model matematika. Variabel keputusan tersebut sesuai dengan dua keputusan, yang menunjukkan: waktu pengisian bahan bakar – sebelum atau sesudah pengemudi istirahat dan jumlah pengisian bahan bakar – jumlah minimum atau maksimum bahan bakar yang harus dibeli.

Masalahnya didekomposisi menjadi dua bagian dan setiap bagian (masalah waktu dan masalah kuantitas) diselesaikan secara independen dengan heuristik yang relatif sederhana. DSS melakukan tugas utama berikut: mengidentifikasi lokasi pemberhentian truk "saat ini", menerapkan heuristik "waktu" ("Metode Sebelum atau Setelah") dan heuristik "kuantitas" ("Metode Min – Maks") dan akhirnya mentransmisikan solusi ke pengemudi, yang menunjukkan waktu dan jumlah pengisian bahan bakar. DSS yang diusulkan memungkinkan operator untuk mengurangi biaya bahan bakar sebesar 2%. Penulis membuktikan bahwa sistem ini mengungguli pengoptimal bahan bakar standar lebih dari Rp 1.500.000.000 dan Rp 15.000.000.000 dalam penghematan biaya bahan bakar tahunan untuk pengangkut dengan 500 dan 10.000 truk, masing-masing.

A. Caputo, L. Fratocchi dan P. Pelagagge [11] menyajikan DSS untuk perencanaan optimal kegiatan transportasi jalan, jarak jauh, dan angkutan barang. Sistem ini berfokus pada meminimalkan total biaya transportasi melalui agregasi pesanan pelanggan yang tepat dalam pengiriman penuh – truk (FTL) dan kurang – dari – muatan truk (LTL) yang terpisah. Situasi keputusan dirumuskan sebagai masalah pemrograman matematika dengan variabel kontinu dan kemudian ditransformasikan menjadi masalah pemrograman matematika dengan variabel keputusan biner. Karena kompleksitas komputasinya, masalah keputusan asli didekomposisi menjadi sub-masalah yang lebih sederhana dan setiap sub-masalah diselesaikan secara terpisah. Pada langkah pertama prosedur komputasi, seluruh daftar pesanan dibagi menjadi subkelompok yang disebut kelompok pesanan yang kompatibel (COG). Kompatibilitas pesanan ditentukan berdasarkan kedekatan geografis tujuan, kesamaan kargo dan kesamaan biaya untuk layanan. Prosedur heuristik diterapkan untuk mendefinisikan COG. Langkah selanjutnya adalah agregasi pesanan yang optimal ke dalam pengiriman FTL dan pengiriman LTL dalam setiap COG. Untuk tujuan ini Algoritma Genetika diterapkan. Penulis menyajikan penerapan DSS untuk menganalisis lebih dari 4000 pesanan yang dikirimkan ke lebih dari 200 pelanggan di Eropa. Hasil eksperimen komputasi membuktikan bahwa pendekatan yang diusulkan dapat menghasilkan penghematan 35% lebih tinggi daripada perencanaan manual tradisional.

Contoh lain dari DSS transportasi jalan adalah "XENIOS", sistem berbasis komputer yang dikembangkan untuk membantu aktivitas sehari-hari perusahaan transportasi Yunani selama acara khusus [64]. Sistem komputer yang diusulkan adalah contoh yang baik dari DSS-s berorientasi transportasi yang dirancang dan dikembangkan untuk mendukung

pengendalian lalu lintas dan manajemen aktivitas transportasi selama peristiwa penting, yang memerlukan upaya organisasi dan logistik yang terkonsentrasi dan meningkat dalam waktu singkat. Ada beberapa sistem (dijelaskan dalam [64]) yang memiliki karakter serupa dan dikembangkan untuk mengelola kegiatan transportasi selama acara khusus. "XENIOS" menggabungkan fungsi penting GIS, subsistem basis data, dan subsistem basis model, termasuk teknik optimasi dan manajemen lanjutan untuk mendukung DM dalam memecahkan masalah rute dan penjadwalan kendaraan yang kompleks yang dihadapi selama Olimpiade Athena 2004. Masalahnya dirumuskan sebagai masalah Rute dan Penjadwalan Kendaraan dengan pickup dan pengiriman, armada yang heterogen, jendela waktu dan keamanan tambahan dan pembatasan lalu lintas. DSS memungkinkan setiap DM (perusahaan transportasi) untuk memilih ukuran evaluasi yang berbeda untuk proses optimasi, termasuk: aspek ekonomis, tingkat layanan pelanggan dan kondisi kerja pengemudi. Dengan demikian, keputusan akhir dapat diambil berdasarkan kriteria berikut (antara lain): total waktu pengiriman, total biaya penggunaan kendaraan, tingkat pelanggaran waktu sulit pelanggan – jendela, penyimpangan antara jadwal jam kerja yang sebenarnya dan yang diinginkan. Masalah ini diselesaikan dengan algoritma heuristik khusus yang memanfaatkan fitur khusus dari Masalah Perutean Kendaraan yang digerakkan oleh peristiwa dan disesuaikan. Prosedur solusi dikodekan dalam Visual Basic.

J. Selih dkk. [38] menyajikan DSS yang berfokus pada manajemen rasional dan pemeliharaan infrastruktur transportasi jalan. DSS bertujuan untuk menentukan serangkaian proyek pemeliharaan, perbaikan dan rehabilitasi (MR&R) jalan yang menghasilkan manfaat (utilitas) keseluruhan yang dimaksimalkan dengan tunduk pada kendala anggaran dan kompatibilitas. Evaluasi hasil yang dihasilkan (set proyek) didasarkan pada penerapan metodologi pengambilan keputusan beberapa kriteria. Dengan demikian, utilitas individu dari setiap proyek dihitung sebagai jumlah tertimbang (kombinasi) dari kriteria seperti: peringkat fasilitas (kondisi teknis), usia fasilitas, pengelompokan proyek (berdasarkan kompatibilitas), biaya tidak langsung proyek MR&R, biaya langsung proyek MR&R. biaya. Utilitas keseluruhan dari solusi optimal (kumpulan proyek) dihitung sebagai jumlah utilitas individu dari semua proyek yang dianalisis.

Masalah keputusan dirumuskan sebagai masalah pemrograman matematika objektif ganda dengan variabel biner, yang dikenal dalam literatur sebagai masalah ransel objektif ganda. DSS menggunakan fungsionalitas dari dua metode: algoritma cabang dan terikat, diimplementasikan dalam Ms Excel Solver dan AHP (Analytic Hierarchy Process) yang diusulkan oleh T. Saaty. Metode AHP digunakan untuk menentukan kepentingan relatif – bobot kriteria tertentu, sedangkan solver diterapkan untuk menghasilkan sekumpulan proyek MR&R yang optimal. DSS yang diusulkan diuji pada studi kasus kehidupan nyata yang melibatkan analisis 27 proyek MR&R (jalan layang, sambungan jalan, jembatan, terowongan) untuk bagian jalan raya. Hal ini menunjukkan bahwa biaya tidak langsung proyek MR&R signifikan dibandingkan dengan biaya langsung proyek MR&R, sehingga penghapusan kriteria ini memiliki dampak besar pada pemilihan proyek MR&R.

M. Jakimavicius dan M. Burinskiene [23] mengusulkan DSS dengan fasilitas GIS (Geographic Information System) untuk analisis sistem transportasi jalan/mobil berbasis aksesibilitas. DSS yang diusulkan mengevaluasi sistem transportasi jalan yang berbeda

berdasarkan analisis multidimensi aksesibilitas berorientasi waktu dari berbagai daerah dan lokasi karakteristik di wilayah wilayah administrasi tertentu dari pusat administrasi mereka. Kriteria yang digunakan sebagai parameter pengukuran aksesibilitas adalah: kepadatan jaringan jalan, panjang jalan per kapita, luas wilayah yang dapat dicapai dalam batas waktu tertentu. DSS menggunakan pengetahuan para ahli untuk menetapkan bobot (kepentingan) untuk kriteria tersebut dan akhirnya memberi peringkat sistem transportasi berdasarkan evaluasi beberapa kriteria mereka.

Dua prosedur komputasi diterapkan untuk menentukan peringkat sistem transportasi di wilayah administratif tertentu: SAW (Simple Additive Weighting) dan TOPSIS (Teknik untuk Preferensi Pesanan berdasarkan Kesamaan dengan Solusi Ideal). Pemeringkatan dibangun berdasarkan perhitungan deviasi agregat varian (sistem transportasi) dari solusi ideal dan solusi nadir (oposisi terhadap solusi ideal) [67]. DSS dapat memberikan saran kepada DM dalam mengalokasikan investasi untuk pengembangan dan perluasan jaringan jalan di wilayah administratif tertentu serta dalam perencanaan dan penetapan batas wilayah tersebut. Sistem ini diterapkan di Lithuania untuk analisis kehidupan nyata dari sistem transportasi.

K. Zografos dan K. Androutsopoulos [65] mengusulkan DSS berbasis komputer untuk manajemen risiko transportasi bahan berbahaya yang mencakup distribusi bahan berbahaya terintegrasi dan keputusan tanggap darurat. DSS yang diusulkan berkontribusi pada integrasi perutean dan keputusan logistik tanggap darurat untuk meningkatkan efektivitas proses tanggap darurat bahan berbahaya. Kemampuan DSS berikut memastikan pemenuhan tujuan tersebut di atas: 1) penyediaan jalur distribusi bahan berbahaya alternatif yang efisien dalam hal biaya dan risiko minimum, 2) identifikasi lokasi unit tanggap darurat yang meminimalkan waktu tanggap insiden dan mengamankan tingkat layanan yang telah ditentukan untuk insiden bahan berbahaya, 3) perutean unit tanggap darurat, 4) identifikasi rencana evakuasi yang optimal (jalur dan lalu lintas evakuasi yang optimal penugasan yang diberikan area evakuasi). DSS terdiri dari modul-modul berikut: Basis Model Logistik, Basis Model Tanggap Darurat, Basis Data, dan Antarmuka Manusia-Mesin (HMI). Basis Model Logistik meliputi: logistik dan alat penilaian risiko. Yang pertama membahas keputusan perutean bahan berbahaya dengan memecahkan masalah perutean dan penjadwalan kendaraan bi-objektif dan memungkinkan pengguna untuk menentukan trade-off antara biaya distribusi dan risiko. Yang terakhir menghitung nilai risiko pada link jaringan jalan yang mendasari dengan memecahkan model matematika probit yang memperkirakan probabilitas relatif dari kecelakaan bahan berbahaya pada segmen jalan tertentu.

Basis Model Tanggap Darurat mencakup modul berikut: alat konsekuensi bahan berbahaya (yang memperkirakan radius area yang terkena dampak), alat lokasi unit tanggap darurat (yang mengidentifikasi lokasi unit tanggap darurat yang meminimalkan waktu respons rata-rata dan menyediakan tingkat layanan tertentu), alat perutean unit respons darurat (yang menentukan jalur terpendek untuk setiap unit respons dari lokasi saat ini ke lokasi kecelakaan) dan alat evakuasi (yang memecahkan masalah penugasan lalu lintas statis dan mengidentifikasi rute evakuasi yang optimal untuk dicapai. - Panied dengan arus lalu lintas yang optimal). Modul basis data menyimpan data yang diperlukan untuk penggunaan alat-alat tersebut di atas, seperti: topologi jaringan, karakteristik lalu lintas, kepadatan penduduk, karakteristik armada, informasi terkait pelanggan. HMI berbasis GIS dan menyajikan secara

grafis jaringan jalan raya dari area yang diminati dengan informasi geografis tambahan. Ini juga memvisualisasikan rute distribusi yang diusulkan, area dampak, lokasi unit tanggap darurat dan rute evakuasi. DSS yang diusulkan telah diimplementasikan, digunakan dan dievaluasi untuk manajemen bahan berbahaya di Yunani.

A. Redmer, P. Sawicki dan J. Zak [33] menyajikan DSS, yang disebut TABOR (lihat Gambar 5) yang mengoptimalkan kebijakan penggantian armada di perusahaan transportasi. TABOR memecahkan masalah optimasi tujuan ganda dengan variabel biner. Saat mengoptimalkan masalah penggantian kendaraan, hal itu memperhitungkan kepentingan dua pemangku kepentingan utama: pengemudi dan manajemen perusahaan. Dengan demikian, sistem menganalisis kriteria berikut: usia armada, biaya unit operasional, intensitas tenaga kerja pemeliharaan armada, biaya investasi, ketersediaan armada, kenyamanan berkendara. DSS terdiri dari 3 komponen utama: basis data, basis model, dan antarmuka pengguna grafis. Basis model mencakup dua prosedur komputasi: heuristik khusus yang menghasilkan serangkaian solusi optimal Pareto untuk masalah penggantian armada dan prosedur pencarian interaktif yang meninjau solusi yang dihasilkan dan membantu DM menemukan opsi kompromi yang paling diinginkan.

TABOR memungkinkan DM untuk menentukan preferensinya dalam bentuk tingkat aspirasi untuk setiap kriteria yang dianalisis, meninjau area yang berbeda dari kumpulan solusi dan akhirnya menerima salah satunya. DM dapat meninjau dan mengevaluasi solusi baik secara numerik maupun grafis. Untuk jangka waktu tertentu, sistem menentukan kendaraan yang akan diganti dan momen di mana penggantian harus dilakukan. Karena kebijakan penggantian dijabarkan untuk jangka waktu 3-5 tahun, prediksi parameter tertentu diperlukan. Untuk tujuan ini TABOR menggunakan teknik peramalan tingkat lanjut. TABOR diimplementasikan dalam bahasa pemrograman Delphi dan dilengkapi dengan fasilitas grafis yang canggih. Antarmuka grafis dirancang dalam standar Windows.

TABOR - strategia v1.0																			
Dane		Parametry		Zestawy		Wyjazdy		Zadania		Kryteria		Opcje		Pareto SA		Wyjiki		Info	
I	J	T1	T2	TypI	KSWI	KZWI	WZWI	WSTI	QPI	AI	VI	ZPI	WBI						
W1	1	1000	C	2520	0.46	2	0	33	-25100	53	0.34	1							
W2	1	1000	C	2439	0.51	2	0	33	-25100	53	0.35	1							
W3	1	1000	C	1877	0.83	-5	-4	33	-43100	53	0.35	1							
W4	1	1000	C	1968	1.24	2	2	33	-11000	53	0.37	1							
W5	1	1000	C	2045	0.37	-1	0	33	-35200	53	0.42	1							
W6	1	1000	C	2441	0.53	-1	0	33	-35200	53	0.44	1							
W7	1	1000	C	2415	0.37	-3	0	33	-16100	53	0.37	1							
W8	1	1000	C	2415	0.56	-3	0	33	-16100	53	0.37	1							
W9	1	1000	C	2463	0.46	2	0	33	-30000	53	0.35	1							
W10	1	1000	C	2412	1.5	-1	0	33	-33600	53	0.35	1							
W11	1	1000	C	2438	0.57	-1	0	33	-33600	53	0.35	1							
W12	1	1000	C	2426	0.79	-1	0	33	-33600	53	0.37	1							
W13	1	1000	C	2440	0.28	-4	0	33	-37700	53	0.34	1							
W14	1	1000	C	2515	0.55	-4	0	33	-37700	53	0.33	1							
W15	1	1000	C	2441	0.32	-4	0	33	-37700	53	0.34	1							
Rozw=0		Master=1		Wyjazd=1		A=3693900.00		KI=0.00		KII=0.00		Status=Gotów							

**Gambar 11.5** Matriks data multidimensi yang mencakup karakteristik kendaraan dalam TABOR DSS (digunakan dalam optimasi beberapa kriteria kebijakan penggantian armada)

DSS lain, yang dikembangkan oleh J.Zak et al, [68], [70], [71], [72], [73], [74] adalah sistem komputer prototipe generik yang dirancang untuk membantu DM dalam mengelola

keduanya. sistem transportasi jalan dan perkotaan. Kerangka kerja DSS didasarkan pada penerapan metodologi Multiple Criteria Decision Making. Dengan demikian, masalah keputusan dirumuskan baik sebagai optimasi beberapa kriteria atau masalah peringkat beberapa kriteria. Bagian transportasi jalan dari DSS menyediakan fungsionalitas berikut: ukuran armada dan kru, rute dan penjadwalan kendaraan yang dikombinasikan dengan penjadwalan kru, penugasan kendaraan hingga pekerjaan transportasi. Bagian transportasi perkotaan berfokus pada penugasan kendaraan dan penjadwalan untuk jaringan trem dan bus yang ada. Penjadwalan kendaraan digabungkan dengan penjadwalan kru. Sistem ini terdiri dari basis data dua bagian yang luas (satu untuk jalan raya dan satu untuk transportasi perkotaan), basis model dan antarmuka pengguna grafis.

Basis model mencakup kumpulan algoritma eksak dan heuristik yang memecahkan masalah keputusan tujuan ganda yang disebutkan di atas. Masalah penugasan kendaraan, perutean dan penjadwalan diselesaikan dengan algoritma evolusioner hibrid, sedangkan untuk penjadwalan kru diterapkan prosedur heuristik khusus. Masalah ukuran armada diselesaikan dengan algoritma optimasi kombinatorial yang tepat. Untuk semua masalah satu set solusi optimal Pareto dihasilkan dan kemudian dievaluasi dengan beberapa kriteria, metode pencarian interaktif. Selama mencari solusi kompromi, fase analisis keputusan bergantian dengan fase komputasi. DM dapat meninjau solusi dan menganalisisnya baik secara grafis maupun numerik. Dia juga dapat menghasilkan satu set solusi. Berdasarkan preferensi DM yang ditentukan, sistem mencari solusi yang paling diinginkan, yang sedekat mungkin dengan ideal atau titik referensi lain yang dipilih.

### **Transportasi Perkotaan DSS-s**

Kategori lain dari DSS-s berorientasi transportasi difokuskan pada perencanaan dan manajemen sistem transportasi perkotaan. Sistem tersebut menangani kategori masalah keputusan berikut: kontrol dan manajemen lalu lintas, rute dan penjadwalan kendaraan di daerah perkotaan yang dikombinasikan dengan penjadwalan kru, perancangan sistem transportasi penumpang multimoda yang terintegrasi, pengumpulan dan pembuangan sampah kota.

M. Dridi, K. Mesghouni dan P. Borne [16] menyajikan DSS untuk kontrol lalu lintas perkotaan multimoda real-time. Tujuan utama dari DSS adalah untuk membantu DM (regulator) dalam pengaturan lalu lintas setelah terjadinya gangguan. Tugas utama DSS adalah sebagai berikut: mendeteksi dan menganalisis gangguan, memecahkan gangguan melalui pencarian yang layak, dan mendekati jadwal optimal kendaraan terpilih pada jalur tertentu yang tunduk pada gangguan spesifik – kendala terkait. Dalam DSS yang diusulkan jaringan transportasi dimodelkan dengan Jaring Petri Biasa dan Berwarna. Jaringan lalu lintas dicirikan oleh sejumlah persimpangan dan pemberhentian, dan dimuat oleh sekumpulan kendaraan. Ketika gangguan terjadi, DSS “menghidupkan” regulator otomatis yang dapat memilih beberapa tindakan untuk meredakan gangguan.

Tindakan tersebut meliputi: penyuntikan kendaraan tambahan di jaringan, memajukan atau menunda beberapa kendaraan, mengubah rute dan menjadwal ulang kendaraan pada jalur tertentu. Dengan demikian, tugas utama DSS adalah merumuskan kembali masalah keputusan dan menemukan solusi semi-optimal yang layak untuk keadaan baru sistem transportasi perkotaan. Karena masalah yang dipertaruhkan ditandai dengan kompleksitas

komputasi yang tinggi, prosedur metaheuristik berdasarkan Algoritma Evolusi diterapkan untuk menyelesaiannya. Pengkodean genetik yang orisinal dan efisien diterapkan untuk menyelesaikan masalah penjadwalan transportasi umum yang kompleks. Untuk evaluasi solusi yang dihasilkan, fungsi tujuan multi-dimensi digunakan. Ini mencakup kriteria berikut: waktu tunggu, waktu transit dan total waktu perjalanan. DSS mampu menyesuaikan jadwal teoretis dengan situasi yang baru dihadapi. Sistem ini telah dikembangkan untuk jaringan transportasi di Valenciennes, Prancis.

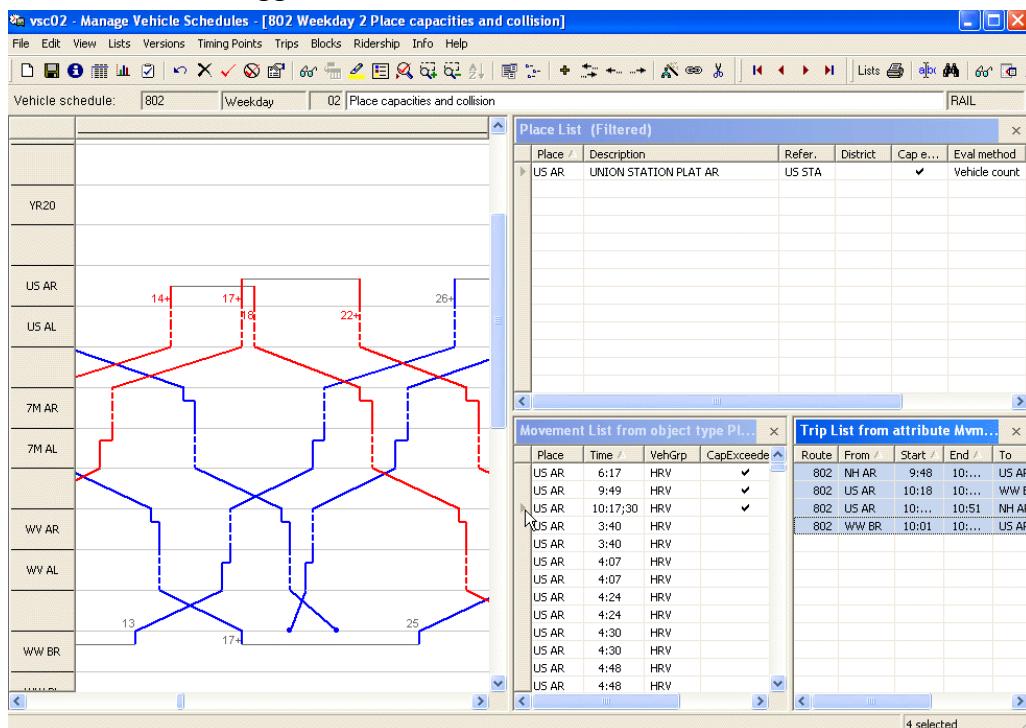
HASTUS [63] adalah sistem komputer komersial yang populer untuk perencanaan transportasi perkotaan. Ini adalah DSS terintegrasi dan modular untuk penjadwalan transit, operasi, dan informasi pelanggan. Ini telah diterapkan di 250 perusahaan angkutan massal di 22 negara dan digunakan untuk menjadwalkan dan mengelola sistem bus, trem, kereta bawah tanah, troli, feri, dan kereta api komuter di kota-kota dengan persyaratan, ukuran, lokasi, dan fitur bentang alam yang bervariasi, seperti: New York , Sydney, Singapura, Barcelona, Oslo atau Wina. Contoh jadwal kendaraan yang dihasilkan oleh HASTUS DSS disajikan pada gambar 6. HASTUS juga mendukung pengguna dalam mengintegrasikan sistem transportasi perkotaan multi-moda, melalui sinkronisasi layanan bus, kereta api dan trem (tabel waktu) dalam wilayah metropolitan tertentu. Modul inti dari Sistem HASTUS meliputi: Penjadwalan, Operasi Harian, Informasi Pelanggan, Analisis dan Perencanaan. Modul penjadwalan membantu dalam menggambarkan jaringan rute dan menentukan jadwal yang diinginkan. Masalah Penjadwalan Kendaraan dan Kru diselesaikan dengan algoritme heuristik khusus dan prosedur metaheuristik yang disesuaikan. Berdasarkan biaya proses optimasi – menghemat kendaraan dan jadwal kru serta daftar nama multi-hari dibuat.

Modul Operasi Harian memungkinkan DM-s untuk mengelola perubahan layanan harian, serta penugasan kendaraan dan operator. Jadwal aktual versus jadwal yang direncanakan dapat dibandingkan dan kinerja operator dapat dipantau. Modul Informasi Pelanggan menyediakan informasi terencana atau real-time bagi penumpang tentang status terkini dari tabel waktu. Semua perubahan dan penyimpangan dari jadwal dilaporkan, yang memungkinkan penumpang untuk merencanakan perjalanan mereka. Informasi pelanggan ditampilkan di situs web, poster pemberhentian, sistem IVR, dan tanda elektronik. Modul analisis dan perencanaan menyediakan fungsi pemodelan jaringan dan penjadwalan, termasuk sinkronisasi dan minimalisasi kebutuhan armada. Waktu berjalan dan analisis data penumpang berkontribusi pada peningkatan pemanfaatan armada dan peningkatan layanan yang lebih baik disesuaikan dengan kebutuhan pelanggan. Algoritme penjadwalan HASTUS menghasilkan penghematan biaya dalam kisaran 2% hingga 5% dibandingkan sistem yang bersaing dan metode manual.

S. Peng dan H. Fan [29] menyajikan DSS yang berkontribusi pada desain jaringan angkutan umum antar-moda perkotaan. Sistem komputer yang diusulkan adalah alat yang berguna untuk perencana transportasi dalam melaksanakan perencanaan layanan, dan perutean serta penjadwalan kendaraan untuk jaringan transit antar-moda. DSS dapat digunakan untuk membantu dalam desain sistem transit terintegrasi dengan faktor-faktor yang relatif kompleks atau menyesuaikan sistem yang ada di bawah tujuan dan kendala tertentu. DSS membantu DM dalam mengevaluasi strategi operasi alternatif dari sistem angkutan massal dan membantunya untuk mencari yang optimal. DSS juga mampu memeriksa

hubungan antara variabel keputusan penting dari layanan transit dan parameter sistem transit. Identifikasi hubungan tersebut (misalnya kemajuan operasi dan biaya operasi) mendukung proses perancangan atau perancangan ulang sistem angkutan massal terintegrasi dengan cara yang paling efisien. DSS difokuskan pada analisis layanan kereta api yang dikombinasikan dengan layanan bus ekspres dan layanan bus pengumpulan. Jaringan yang diasumsikan memiliki sejumlah jalur kereta api dan bus ekspres yang dialiri oleh layanan bus pengumpulan. Jaringan angkutan umum antarmoda memiliki wilayah pelayanan yang tidak teratur yang dibagi menjadi zona-zona kecil.

Perjalanan penumpang zona dikelompokkan menjadi pasangan Asal – Tujuan (OD). Setiap jalur kereta api dan bus ekspres adalah jalur utama berkecepatan tinggi yang masing-masing melayani pasangan OD permintaan yang lebih tinggi dan lebih rendah. Peran layanan bus pengumpulan adalah untuk menyediakan akses dan jalan keluar dari halte layanan utama di setiap zona. Kombinasi heuristik dan derivasi analitis diterapkan untuk memecahkan masalah optimasi. Strategi langkah demi langkah digunakan untuk mengoptimalkan layanan kereta api, bus ekspres, dan bus pengumpulan secara terpisah. Namun, moda angkutan yang berbeda tetap dianggap bersama-sama untuk mencerminkan ketergantungan satu sama lain. Di setiap tahap optimasi, layanan yang dioptimalkan pada yang sebelumnya masih disimpan dalam lingkaran dan dioptimalkan bersama dengan layanan baru yang ditemukan. DSS terdiri dari tiga modul, masing-masing sesuai dengan layanan kereta api, layanan bus ekspres, dan layanan bus pengumpulan. Optimalisasi layanan kereta api dan bus ekspres difokuskan pada minimalisasi biaya, sedangkan optimalisasi layanan bus feeder berkonsentrasi pada aksesibilitas penumpang dan jangkauan layanan. DSS telah diterapkan untuk merancang sistem angkutan massal terintegrasi untuk area layanan dengan 10 zona. Optimalisasi tersebut menghasilkan 11 jalur kereta api dan 7 jalur bus ekspres yang beroperasi dengan headway berbeda mulai dari 1,5 hingga 6 menit.



**Gambar 11.6** Jadwal kendaraan untuk stasiun kereta api beton yang dihasilkan oleh HASTUS DSS

G. Giaglis dkk. [21] mengusulkan sistem komputer perutean kendaraan bergerak, real-time (on-line) untuk distribusi barang di perkotaan. DSS yang diusulkan memiliki arsitektur generik, orisinal, dan inovatif berdasarkan koneksi seluler dan nirkabel tanpa batas antara kendaraan pengiriman dan fasilitas distribusi. Sistem ini memungkinkan manajemen armada operasional yang digerakkan oleh waktu dan peristiwa secara real-time berdasarkan pengenalan on-line dari peristiwa tertentu yang kejadianya mengubah keadaan sistem yang ada menjadi yang baru. Berbeda dengan sebagian besar sistem perutean kendaraan yang memiliki karakter terpusat dan menghasilkan rencana harian rute kendaraan statis sebelum dimulainya pelaksanaannya, solusi yang diusulkan menggunakan teknologi seluler dan pemasangan canggih untuk mendeteksi kejadian tak terduga dan mengirimkan informasi tentangnya pada saat terjadi langsung dari truk yang terkena dampak melalui jaringan seluler ke markas besar dan kendaraan lain.

Berkat algoritme perencanaan ulang yang efisien (berdasarkan heuristik dan metaheuristik khusus), DSS dilengkapi dengan, rencana rute kendaraan yang dirancang dapat disesuaikan dan modifikasi yang sesuai dapat diterapkan. Modifikasi tersebut ditransmisikan kembali ke armada secara tepat waktu untuk merespons secara efektif status sistem baru. DSS dirancang untuk melakukan tugas-tugas berikut: pengamatan status sistem; rekomendasi tentang jenis intervensi (penyesuaian rencana lokal vs. perencanaan ulang global), definisi tujuan sistem (kriteria pengoptimalan). DSS terdiri dari tiga sub-sistem utama: sistem back-end (modul pengambilan keputusan dan modul fasilitasi koneksi ERP), sub-sistem komunikasi nirkabel (jaringan terestrial akses seluler dan sistem penentuan posisi) dan sub-sistem ujung depan (antarmuka pengguna, modul komputasi lokal, modul interaksi antara komputer truk on-board dan sistem back-end).

G. Tavares dkk. [43] dan P. Matis [27] menyajikan dua DSS-s berbeda yang menangani masalah perutean jalan. Yang pertama mendukung pengguna dalam memecahkan kasus tertentu dari masalah rute jalan atau busur, yaitu pengumpulan sampah kota. DSS yang diusulkan berkonsentrasi pada penghematan bahan bakar melalui optimalisasi rute transportasi sampah kota. DSS kedua adalah platform universal untuk memecahkan berbagai kategori masalah perutean jalan. Penulis, selain kriteria optimasi klasik yang digunakan dalam masalah rute kendaraan (panjang total rute, total waktu pengiriman) memperkenalkan ukuran kualitatif lainnya, yang disebut sebagai "daya tarik visual". G. Traves dkk. [43] menggunakan DSS mereka sistem informasi geografis (GIS) untuk pemodelan rute pengumpulan sampah 3D (3 – Dimensi) dan kemudian mengoptimalkan rute sesuai dengan kriteria konsumsi bahan bakar minimum. Pemodelan rute 3D GIS memperhitungkan pengaruh kemiringan jalan dan beban kendaraan.

Berbeda dengan pendekatan yang umum diterapkan di mana jarak terpendek dicari, penulis DSS yang diusulkan memperkenalkan kriteria konsumsi bahan bakar sebagai faktor terpenting yang mempengaruhi biaya pengumpulan sampah. Prosedur solusi terdiri dari 3 fase, termasuk: pemodelan 3D jaringan jalan, perhitungan faktor konsumsi bahan bakar untuk seluruh jaringan jalan 3D, melakukan optimalisasi pengangkutan sampah kota untuk konsumsi bahan bakar minimum. Untuk perhitungan perutean optimal, perangkat lunak ArcGIS, perpanjangan dari ArcInfo dan Analis Jaringan, diterapkan. Perangkat lunak ArcGIS menggunakan prosedur heuristik canggih untuk optimasi masalah busur dan perutean jalan.

Struktur DSS yang diusulkan oleh P. Matis [27] mencakup 5 komponen utama: sistem GIS, Database GIS, Heuristik, Integrator (Antarmuka pengguna utama) dan Interpreter (Alat bantu visualisasi). P. Matis mengusulkan dalam DSS 9 prosedur heuristik alternatifnya untuk optimasi masalah perutean jalan, yang dapat diklasifikasikan sebagai: Cluster – First, Route – Second Heuristics, Shaping Heuristics, Metaheuristics, Heuristics based on Visual Attractiveness, Hueristics with fuzzy clustering , Hueristik dengan model campuran layanan simpul dan busur. Semua algoritma yang disebutkan di atas tersedia untuk digunakan dalam DSS yang diusulkan. Pengguna menentukan waktu yang tersedia untuk perhitungan dan parameter hasil yang diinginkan dan sistem memilih jenis heuristik terbaik.

T. Randall, C. Churchill dan B. Baetz [31] telah mengembangkan DSS berbasis GIS (Sistem Informasi Geografis) untuk menenangkan lalu lintas lingkungan (NTC). NTC merupakan perluasan dari sistem Arc View GIS yang berfokus pada perancangan program pengurangan/penenangan lalu lintas (skenario alternatif yang akan diterapkan) untuk semua jenis jalan, termasuk arteri di daerah perkotaan (perumahan). NTC DSS adalah alat berteknologi canggih yang menghasilkan saran tentang langkah-langkah menenangkan lalu lintas untuk mengurangi kecepatan dan volume dan untuk memprioritaskan keselamatan dan fasilitas bagi pejalan kaki, pengendara sepeda dan transit. Konsep DSS sesuai dengan keinginan publik yang berkembang untuk jalan yang lebih aman. DSS tergantung pada masalah yang diukur atau dirasakan, jenis jalan dan tujuan pengguna serta biaya pemasangan saat ini dari tindakan menenangkan lalu lintas. Hal ini dibangun di sekitar daftar pilihan menu yang melaksanakan tugas-tugas utama dalam mengevaluasi kebutuhan, dan pelaksanaan, menenangkan lalu lintas lingkungan. NTC DSS terdiri dari tiga opsi menu utama: 1) "Pengenalan dan Tampilan Area Kritis untuk NTC", 2) "Tinjauan dan Pemilihan Tindakan Penenangan Lalu Lintas", 3) "Menempatkan tindakan dan mengevaluasi biayanya". Modul pertama mengidentifikasi dan menampilkan segmen jalan kritis yang membutuhkan NTC, berdasarkan tiga kategori faktor: kecepatan melebihi ambang batas yang diinginkan, volume lalu lintas harian melebihi ambang batas yang diinginkan, permintaan khusus untuk lalu lintas yang tenang. Modul kedua menyediakan berbagai informasi deskriptif dan visual mengenai 29 tindakan / pilihan penenang lalu lintas yang tersedia untuk jalan lokal, kolektor dan arteri.

Setiap ukuran dicirikan; keuntungan dan kerugian yang dimaksudkan disajikan. Modul ketiga bertanggung jawab untuk evaluasi perkiraan biaya kombinasi yang diusulkan dari tindakan NTC dan lokasinya (dalam bentuk digital) pada segmen jalan tertentu yang diidentifikasi pada peta. Setiap peta keluaran adalah iteratif, memungkinkan pengguna untuk menambah dan menghapus langkah-langkah menenangkan lalu lintas dan mengevaluasi kembali biaya rencana. Dalam proses pengambilan keputusan tentang langkah-langkah penentuan lokasi, DM dapat mempertimbangkan opsi prioritas berikut: sekolah yang tenang, zona bermain dan pejalan kaki, memberikan kelonggaran untuk sepeda di kolektor dan arteri utama, memprioritaskan akses untuk transit di arteri. Fungsionalitas DSS ditunjukkan berdasarkan penerapannya di pinggiran kota Hamilton (Kanada).

### **Transportasi Udara DSS-s**

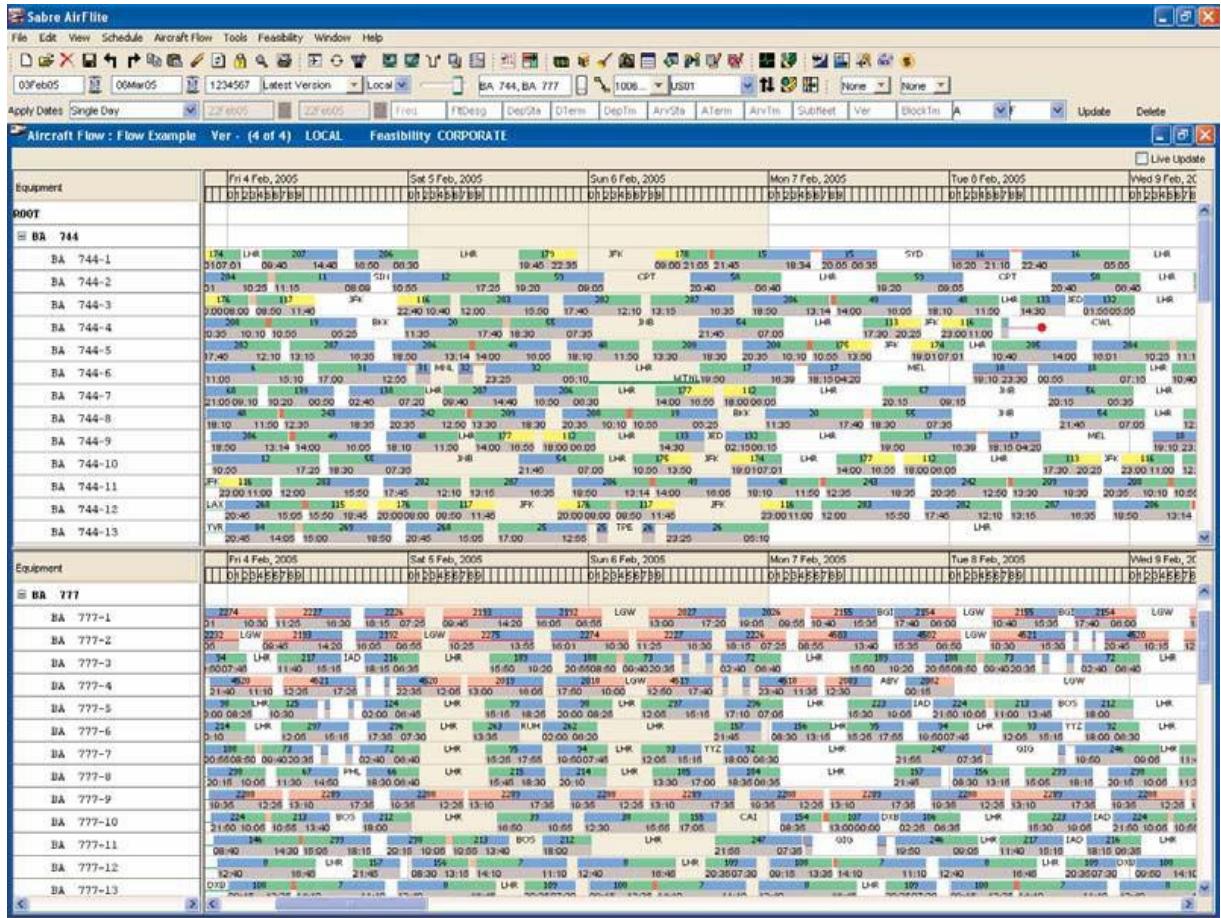
Karena industri transportasi udara sangat sensitif terhadap segala jenis keputusan yang salah dan / atau tidak sempurna, banyak penekanan telah diberikan pada prosedur pengambilan keputusan yang komprehensif dan efisien di cabang ini. Selain itu, transportasi

udara merupakan industri yang sangat padat modal dan biaya; oleh karena itu, diperlukan algoritme canggih yang menjamin investasi rasional, pemanfaatan aset transportasi yang memadai, dan kontrol yang tepat atas tingkat pengeluaran sehari-hari (biaya operasional). Karena biaya transportasi udara, baik untuk penumpang dan kargo, jauh lebih tinggi daripada moda transportasi lain, tingkat pelayanan yang ditawarkan harus sangat memuaskan. Akibatnya industri transportasi udara telah mengembangkan banyak DSS-s berbasis komputer yang menyediakan solusi transportasi yang berfokus pada: jaminan keselamatan dan keandalan, kepuasan pelanggan dan rasionalisasi biaya. DSS-s yang paling populer untuk transportasi udara dijelaskan di bawah ini.

AeroTURN [63] adalah sistem komputer berbasis CAD untuk membuat desain sisi udara, mengevaluasi manuver darat pesawat, dan memenuhi persyaratan izin dan ruang. AeroTURN DSS memungkinkan untuk menempatkan beberapa garis depan pesawat, mengatur amplop ledakan jet, menandai jalur roda hidung pesawat, menjalankan animasi sisi udara, dan melakukan operasi lainnya. AeroTURN DSS dibuat untuk perencana, perancang, dan insinyur bandara. Platform CAD digabungkan dengan paket simulasi, yang memfasilitasi desain gerbang dan stand pesawat yang dilengkapi dengan simulasi manuver pesawat dan pergerakan kendaraan pendukung darat di fasilitas bandara. Para desainer dilengkapi dengan perpustakaan lengkap peralatan teknis bandara, seperti: boarding bridge, tangga pesawat, dan koleksi lengkap pesawat.

DSS transportasi udara lainnya adalah Sabre AirFlite Schedule Manager (SAFSM), yang termasuk dalam keluarga besar Saber Air Solutions [63]. SAFSM adalah sistem komputer penjadwalan penerbangan universal yang dapat disesuaikan dengan kebutuhan spesifik setiap maskapai. Hal ini memungkinkan maskapai penerbangan untuk mengembangkan jadwal penerbangan semi-optimal dan/atau terus menyesuaikannya dengan permintaan yang berfluktuasi dan kebutuhan pelanggan yang berubah. DSS yang diusulkan memiliki karakter interaktif dan memungkinkan pengguna (penjadwal) untuk menghasilkan sejumlah besar solusi (jadwal penerbangan), meninjaunya dan mengeksplorasi opsi yang lebih baik (lihat Gambar 7).

Selama proses optimasi, DM didukung oleh alat grafis dan numerik yang memungkinkannya untuk melihat, mengedit, dan melaporkan informasi jadwal penerbangan. Penjadwal juga disarankan oleh sistem bagaimana membuat perubahan dan penyesuaian tertentu dalam jadwal yang diusulkan. Sejak pilihan yang berbeda dari jadwal penerbangan dengan nilai yang sesuai dari fungsi tujuan disajikan kepada DM, dia terlibat secara mendalam dalam proses optimasi dan menjadi lebih dan lebih berpengalaman dalam menemukan solusi yang optimal. Sistem membantu DM untuk mendidik dirinya sendiri sambil meninggalkan tanggung jawab untuk mengontrol proses pengambilan keputusan. Selain itu, SAFSM juga mendukung pembuatan database penjadwalan penerbangan di seluruh perusahaan dan menyediakan konektivitas yang mudah ke sistem lama. Sistem ini dapat digunakan dalam kombinasi dengan produk Sabre lainnya seperti: Codeshare Manager, Profit Manager dan Fleet Manager.



**Gambar 11.7** Bagan Gantt untuk tugas transportasi pesawat yang dibuat oleh Manajer Jadwal Sabre AirFlite

Codeshare Manager menawarkan maskapai yang berbeda cara untuk mengembangkan jadwal penerbangan codeshare ketika mereka setuju untuk bekerja sama dan codeshare penerbangan mereka. Menggunakan jadwal penerbangan operasional untuk dua maskapai, sistem komputer membangun koneksi untuk mengidentifikasi penerbangan codeshare potensial dan menghilangkan pengulangan koneksi tertentu yang tidak berguna. Akhirnya, Codeshare Manager menyesuaikan jadwal penerbangan kedua maskapai dan menetapkan nomor penerbangan berdasarkan aturan penetapan nomor penerbangan. Baik SAFSM dan Codeshare Manager memungkinkan maskapai mengurangi waktu pengembangan jadwal secara signifikan.

Manajer Laba mengevaluasi profitabilitas dari jadwal yang diberikan untuk membantu dalam perencanaan strategis jangka panjang. Ini dapat mengidentifikasi kekuatan dan / atau kelemahan dalam jadwal operator serta mengukur dampak jadwal tertentu terhadap pendapatan dan biaya. Manajer Laba memperkirakan profitabilitas minggu biasa untuk jaringan O&D yang lengkap. Rata-rata itu menghasilkan 1% hingga 3% pendapatan tambahan tahunan. Fleet Manager memungkinkan maskapai penerbangan mengalokasikan kapasitas armada secara optimal untuk lebih meningkatkan profitabilitas jadwal. Ini menggunakan teknik optimasi global untuk menyediakan maskapai dengan dukungan analisis strategis dan taktis ketika mengembangkan jadwal yang menguntungkan dan layak secara operasional. Dalam proses optimasi, model aliran penumpang O&D yang dipatenkan diterapkan. Fleet

Manager memungkinkan penjadwal untuk menukar penugasan pesawat, mengatur ulang waktu dan membatalkan penerbangan, meningkatkan pemanfaatan dan meminimalkan penarik pesawat. Itu dapat meningkatkan keuntungan tahunan sebesar 0,5% hingga 3%.

Selain itu, Sabre menawarkan berbagai produk transportasi udara terkomputerisasi tradisional, seperti: reservasi penerbangan on-line lanjutan (SabreSonicRes) dan sistem pemesanan penumpang (SabreSonicWeb) yang dikombinasikan dengan tiket elektronik (SabreSonicTicket).

Contoh lain DSS transportasi udara adalah produk berbasis komputer yang dikembangkan oleh A. Cheung, W. Ip dan D. Lu [12]. Penulis mengusulkan DSS generik untuk industri jasa perawatan pesawat yang mendukung DM dalam masalah perencanaan personel yang kompleks. Tugas utama dari DSS yang diusulkan adalah mengalokasikan sumber daya tenaga kerja untuk kegiatan perawatan khusus yang diperlukan untuk memeriksa dan meningkatkan kondisi teknis pesawat. Sistem ini juga membantu pengguna untuk memilih kandidat terbaik untuk tugas-tugas konkret di bawah kekurangan insinyur yang berpengalaman dan berkualitas. Dalam evaluasi calon dan alokasi tenaga kerja beberapa kriteria/variabel (termasuk yang tidak berwujud) dan kendala (peraturan otoritas penerbangan, undang-undang keselamatan, kualifikasi karyawan, persyaratan pelanggan) diperhitungkan.

Penulis menggunakan pendekatan proses hirarki analitik fuzzy (AHP) DSS yang diusulkan untuk menimbang pentingnya beberapa kriteria tidak berwujud dan memberi peringkat kandidat dari yang terbaik hingga yang terburuk. Prosedur komputasi dua tahap diterapkan untuk menentukan peringkat kandidat untuk pekerjaan pemeliharaan tertentu. Pada tahap pertama, jumlah karyawan/insinyur yang lebih besar (misalnya 40) dipertimbangkan dan dievaluasi dengan serangkaian kriteria kritis (Lisensi Insinyur Pemeliharaan Pesawat, Persetujuan Pesawat dan Maskapai Penerbangan, Pengalaman, termasuk pengalaman Pesawat dan Maskapai Penerbangan, dan Spesialisasi). Pada tahap kedua, jumlah kandidat yang terbatas (misalnya 5-10) yang memiliki peringkat tinggi pada tahap pertama akan dipertimbangkan lebih lanjut. Mereka dievaluasi oleh seperangkat parameter seperti: pelatihan, peraturan, waktu shift dan faktor manusia. Pada proses seleksi tahap kedua jadwal shift karyawan terpilih dicocokkan dengan jadwal penerbangan. Terbukti dengan banyaknya percobaan, usulan DSS berbasis fuzzy – AHP memberikan manajemen sumber daya manusia yang lebih baik dan produktivitas yang lebih tinggi untuk industri pesawat terbang daripada metode terapan lainnya.

I. Manataki dan K. Zografos [26] mengusulkan DSS generik untuk perencanaan terminal bandara dan analisis kinerja. Sistem ini didasarkan pada model simulasi mesoscopic dari operasi terminal bandara dan pendekatan dinamika sistem yang memperhitungkan berbagai interaksi antara komponen tertentu dari terminal bandara serta fenomena dan proses yang terjadi di dalamnya dan saling mempengaruhi. Penulis mengklaim bahwa sistem yang diusulkan mengisi kesenjangan antara model terlalu rinci (mikroskopis) yang mengacu pada terminal bandara tertentu dan model terlalu agregat (makroskopik) yang tidak mencerminkan operasi terminal dengan cukup detail. DSS yang diusulkan memiliki arsitektur modular dan hierarkis, dan antarmuka yang memungkinkan pembuatan model yang cepat dan ramah pengguna. Sistem ini menyediakan kemampuan untuk beradaptasi dengan konfigurasi dan

karakteristik operasional dari spektrum terminal bandara yang luas. DSS yang diusulkan memperhitungkan tiga faktor/dimensi utama yang mempengaruhi kompleksitas keseluruhan dari terminal bandara yang dianalisis, yaitu: dimensi topologi, dimensi operasional dan dimensi kinerja.

Tiga asumsi metodologis berikut ini menciptakan kerangka kerja untuk pengembangan model generik, namun fleksibel untuk analisis dan evaluasi kinerja terminal: 1) kemampuan model untuk mengatasi kompleksitas sistem terminal bandara; 2) kemampuan model untuk menganalisis dan memodelkan operasi terminal bandar udara secara holistik; 3) fleksibilitas model, sehingga mudah beradaptasi dengan bandara yang sedang dipertimbangkan. Keseluruhan arsitektur DSS disusun menjadi dua tingkat hierarki: 1) dekomposisi sistem terminal bandara menjadi satu set Area Fungsional Bandara (AFA), 2) dekomposisi setiap AFA menjadi Fasilitas Layanan (modul SF). Arsitektur ini sesuai dengan metamodel simulasi terminal. Metamodel ini mencakup: "Jenis Pelanggan" yang terkait dengan "Proses Layanan" masing-masing, didukung oleh "Fasilitas", "Sumber Daya" dan "Penyedia Layanan". Model terminal bandara didasarkan pada simulasi berorientasi objek dan memerlukan input data sebagai berikut: 1) Karakteristik permintaan; 2) konfigurasi fisik terminal bandar udara; 3) karakteristik kelompok pelanggan; 4) Karakteristik Operasional/Layanan. DSS dilengkapi dengan kemampuan numerik dan grafis. Penerapan sistem memungkinkan DM untuk melakukan analisis multidimensi, termasuk: pola kedatangan penumpang ke bandara berdasarkan moda transportasi, panjang antrian dan waktu tunggu di area layanan yang berbeda (misalnya pemeriksaan paspor, konter check-in ) selama periode waktu yang berbeda, perilaku jam sibuk dan di luar jam sibuk dari fasilitas yang berbeda (misalnya konveyor sabuk). Fitur dan kemampuan utama dari DSS yang diusulkan telah ditunjukkan melalui analisis terminal Bandara Internasional di Athena (Yunani).

DSS transportasi udara lainnya adalah produk komersial berbasis komputer yang disebut Global Logistics Network (GLN) [63], penerus Sistem Global Freight Exchange (GF-X). GLN adalah sistem komputer manajemen pengiriman ujung ke ujung yang canggih untuk industri kargo udara. Sistem ini dicirikan oleh fungsi berikut: 1) Mengelola secara elektronik seluruh siklus pengiriman udara, termasuk pemesanan, air waybill, house waybill, status message, dan prosedur bea cukai; 2) Mengelola tarif mulai dari pemesanan awal hingga presentasi faktur, peringkat tagihan pemuatan, dan audit; 3) Membantu pengguna untuk mematuhi peraturan bea cukai dan standar industri terkemuka. Fitur utamanya adalah sebagai berikut: Centralized Rates and Reservations (CRR), Automated and Electronic Air Way and House Way Bills (AEAHWB), Client Configured Data Capture (CCDC), Supply Chain Visibility and Status Massages (SCVSM), Pengajuan dan Kepatuhan Kepabeanan (CFC), Impor dan Ekspor Data (IED), Konektivitas Mitra Dagang (TPC), Perencanaan dan Optimalisasi (PO), Eksekusi Pesanan (OE) dan Penyelesaian (S). Banyak dari fungsi ini sesuai dengan operasi berurutan dari proses pemenuhan pesanan. Modul CRR menyediakan informasi on-line secara berkala tentang tarif layanan, kontrak, dan perincian pengiriman.

Operator mengirimkan informasi berikut tentang layanan mereka ke modul ini: armada yang tersedia dan kapasitasnya, kemungkinan rute, karakteristik layanan inti dan tambahan, tarif layanan. Forwarder dapat mengakses informasi operator melalui modul CRR dan melakukan pemesanan elektronik. Setelah reservasi dibuat, modul AEAHWB secara

elektronik membuat Air Waybill dan House Waybill yang masing-masing dikirim ke maskapai dan pengirim. Ketika proses pengiriman dimulai, komunikasi pesan status dan pembaruan berkelanjutan didistribusikan, yang memungkinkan penyedia layanan dan pelanggan untuk memantau semua tahapan proses pemenuhan pesanan di seluruh rantai pasokan. GLN DSS menyediakan satu titik akses ke prakarsa elektronik bea cukai dari berbagai pemerintah di seluruh dunia. Fungsi IED dan CCDC memungkinkan manipulasi data off-line dan impornya dalam format yang berbeda, serta transfer data ke sistem warisan back-office pengguna dalam standar yang sesuai. Fungsi TPC memfasilitasi kontak perdagangan antara pemasok dan pelanggan dan memungkinkan forwarder dan operator untuk mengurangi biaya akuisisi pelanggan. Fungsi PO memungkinkan operator untuk memilih operator berdasarkan ukuran yang berbeda (biaya, tingkat layanan, komitmen kepada pelanggan). Berkat fungsi OE, beban ditenderkan secara elektronik ke operator, di mana mereka dapat secara otomatis menerima dan merespons pengambilan, menyediakan pelacakan sesuai kebutuhan, dan menunjukkan bukti pengiriman. Fungsi S mendukung pengiriman faktur elektronik dari operator dan menyimpan semua kontrak dan tarif untuk referensi di masa mendatang. GLN DSS telah berhasil digunakan oleh beberapa maskapai, termasuk American Airlines Cargo.

Contoh lain dari DSS transportasi udara adalah sistem komputer cerdas yang dikembangkan oleh W. Cheung, L. Leung dan P. Tam [13], berfokus pada perencanaan jaringan layanan. Prototipe Intelligent Decision Support System (IDSS) berbasis PC yang diusulkan mengintegrasikan DSS dengan Expert System (ES), untuk memberikan panduan kepada DM selama proses perencanaan jaringan. Metodologi dua tahap, yang menggunakan model optimasi perencanaan makro dan model simulasi perencanaan operasional, telah diterapkan dan diimplementasikan dalam IDSS yang diusulkan. Makro – model perencanaan dirumuskan sebagai masalah pemrograman integer campuran. Ini bertujuan untuk mencari (dalam cakrawala 10 tahun) untuk konfigurasi jaringan distribusi (lokasi fasilitas, definisi kapasitasnya dan tahun pemasangannya, penetapan rute pengiriman) dengan pengaturan biaya minimal yang tunduk pada permintaan pelanggan agregat, kapasitas fasilitas dan waktu respon layanan. Sebuah model simulasi digunakan untuk memvalidasi dan mengevaluasi kinerja jaringan distribusi yang diberikan pada tingkat operasional. Ini memperhitungkan fluktuasi operasional dalam sistem distribusi dan perilaku acak komponennya. Perangkat lunak simulasi ARENA telah digunakan untuk memodelkan dan mensimulasikan operasi harian kurir ekspres udara.

Sistem distribusi telah dievaluasi berdasarkan dua ukuran kinerja: cakupan layanan dan keandalan layanan. Saat menggunakan metodologi dua tahap, DM perlu terbiasa dengan kedua model karena dia memanipulasinya secara iteratif menggunakan pengetahuan ahlinya dalam domain untuk mencapai solusi perencanaan. Penulis mengintegrasikan DSS asli dengan ES sedemikian rupa sehingga ES adalah tambahan untuk DSS. Struktur IDSS meliputi: model base dengan model optimasi dan model simulasi, model dan sistem manajemen basis data (MBMS dan DBMS), basis pengetahuan, mesin antarmuka dan antarmuka pengguna. IDSS yang diusulkan telah diterapkan dalam desain jaringan layanan untuk kurir ekspres udara utama DHL dengan 33 zona permintaan. Dalam percobaan uji target operasional berikut telah ditetapkan: pemanfaatan fasilitas kurang dari 85%; waktu cut-off layanan tidak lebih awal dari 17:15; cakupan layanan minimal 90% dan keandalan layanan minimal 95%. Interaksi antara

model simulasi dan optimasi telah ditunjukkan. IDSS memberikan panduan cerdas kepada perencana tentang logika alur perencanaan secara keseluruhan, memberikan saran tentang modifikasi yang diperlukan dan menyarankan model mana yang harus dijalankan kembali. Di tingkat mikro, IDSS mengidentifikasi penyebab masalah dan memberi saran kepada DM tentang tindakan tertentu yang harus dilakukan untuk mengubah situasi yang tidak menyenangkan. Salah satu kelemahan dari IDSS yang diusulkan adalah kenyataan bahwa ia tidak dapat memainkan peran pemodel. Tes komputasi telah membuktikan bahwa manipulasi data itu membosankan dan sering kali rentan terhadap kesalahan. DM-s membutuhkan pelatihan ekstensif untuk menggunakan model dengan benar.

R. Freling, R. Lentink dan A. Wagelmans [20] telah mengembangkan sebuah DSS untuk perencanaan kru pada transportasi penumpang baik udara maupun kereta api, yang disebut Harmony CDR (Crew Duty Rostering). Sistem ini didasarkan pada algoritma branch-and-bound dan branch-and-price yang tepat dan heuristik dan dirancang untuk menghasilkan jadwal kru dan daftar nama kru yang optimal. Dua pendekatan yang berbeda untuk penjadwalan dan rostering kru diimplementasikan dalam DSS yang diusulkan. Pada pendekatan pertama, jadwal kru yang optimal dihasilkan sebelum daftar nama kru yang optimal, sedangkan pada pendekatan kedua, dua masalah perencanaan diselesaikan secara terintegrasi. Masalah keputusan dirumuskan sebagai masalah partisi himpunan dengan variabel biner dan kontinu dan fungsi tujuan biaya yang diminimalkan, tunduk pada kendala klasik (peraturan kode tenaga kerja, perjanjian). Algoritma solusi dari masalah keputusan didasarkan pada relaksasi LP dan prosedur pembangkitan kolom.

Sistem Harmony CDR mendukung seluruh proses perencanaan, yang terbagi menjadi perencanaan jangka panjang dan jangka pendek (rostering dan pengendalian operasi), realisasi dan evaluasi. Ini membantu manajemen untuk menentukan: kapasitas yang dibutuhkan untuk melakukan tugas, tingkat staf permanen dan sementara yang diperlukan untuk memenuhi kapasitas yang diperlukan, liburan yang diizinkan, siaga yang diperlukan, dll. untuk periode tertentu. DSS yang diusulkan mampu menghasilkan beberapa solusi alternatif - jadwal kru dan daftar nama kru (dalam waktu yang relatif singkat) yang memenuhi kepentingan ekonomi (manajemen) dan sosial (karyawan). Tiga kategori kriteria yang saling bertentangan diperhitungkan: efisiensi – minimalisasi biaya sehubungan dengan jumlah tugas yang tidak terungkap dan jumlah tugas atau kru yang diperlukan; kesejahteraan – beban kerja daftar nama harus merata di antara kru; ketahanan – tugas atau daftar nama harus kuat sehubungan dengan penundaan (misalnya dengan memaksakan jumlah maksimum perubahan kendaraan).

Sistem ini mengenali berbagai kategori kelas awak di industri penerbangan dan kereta api, seperti: awak kokpit dan kabin di pesawat terbang dan pengemudi kereta api, pengontrol tiket dan penjaga di kereta api, yang menjalankan fungsi kru yang berbeda. Kerangka kerja DSS diimplementasikan dalam bahasa pemrograman C++, memanfaatkan sepenuhnya sifat berorientasi objeknya. Sistem ini terdiri dari modul-modul berikut: Penerjemah Input dan Output, Pemrograman Linier (LP) dan Pemrograman Integer (IP), Modul Algoritma Jaringan, Generator Kolom, Pemeriksa Aturan dan Koordinator Pengoptimalan. Harmony CDR DSS telah berhasil diimplementasikan di beberapa perusahaan, antara lain: maskapai charter, maskapai regional Eropa, Dutch Railway dan RailRest (perusahaan katering kereta api berkecepatan

tinggi di Eropa Barat). Contoh yang dianalisis mencakup antara 500 dan 2200 tugas (tugas) dan 55 hingga 126 kru.

### **Kereta Api dan Transportasi Laut DSS-s**

Kereta api dan transportasi laut adalah area di mana sistem komputer canggih kurang populer dan penerapannya tidak begitu sering. Terlepas dari kenyataan ini, beberapa aplikasi DSS dalam perkeretaapian dan transportasi laut disajikan di bawah ini. Kami berharap bahwa hasil yang dihasilkan di industri transportasi lainnya akan mendorong perusahaan perkeretaapian dan pelayaran di masa depan untuk memanfaatkan solusi berbasis komputer yang ada dengan lebih baik.

N. Bojovi [6] mengusulkan prototipe DSS untuk masalah penjadwalan dan ukuran armada gerbong kereta api. Sistem ini menggunakan model optimasi jaringan dinamis dengan permintaan yang bergantung pada waktu, yang ditetapkan ke tepi jaringan. DSS mengoptimalkan jumlah gerbong untuk sistem perkeretaapian yang dianalisis di mana transportasi muatan penuh truk hanya dilakukan. Sistem memutuskan jumlah pergerakan mobil yang dimuat dan kosong antara node jaringan tertentu dalam periode waktu yang berbeda. Hasilnya menentukan jumlah gerbong kereta yang dibutuhkan dalam armada, berdasarkan optimalisasi fungsi biaya, yang meliputi: biaya transportasi (pergerakan) (kendaraan muat dan kosong), biaya tunggu armada, biaya perawatan armada dan biaya penalti (untuk pesanan yang tidak terpenuhi). DSS menghasilkan jumlah kendaraan optimal yang berbeda yang memenuhi permintaan dalam periode waktu tertentu.

Contoh lain dari DSS transportasi kereta api adalah prototipe sistem komputer yang dikembangkan oleh H. Sheralie dan C. Tuncbilek [39]. Sistem memberikan DM kemampuan untuk menentukan strategi manajemen armada yang optimal yang menghasilkan penentuan jumlah gerbong kereta yang optimal untuk sistem perkeretaapian tertentu. Dua model keputusan strategis, waktu – ruang yang bersifat statis dan dinamis diimplementasikan dalam sistem. Yang pertama dirumuskan sebagai masalah transportasi, dengan armada yang homogen. Dalam hal ini, mengingat permintaan harian untuk layanan transportasi, jarak dan waktu perjalanan antara asal dan tujuan, jumlah pergerakan kembali kosong dioptimalkan. Ukuran armada ditentukan oleh hasil bagi total waktu berkendara selama sehari dan jumlah perjalanan harian yang diharapkan (dimuat dan kosong) per setiap kendaraan.

Pada model kedua, sebagai perpanjangan dari model pertama, jaringan spasial (waktu – jarak) telah dimasukkan ke dalam masalah transportasi tradisional. Jaringan ini memungkinkan penyajian pergerakan kosong kendaraan antara asal dan tujuan dalam periode waktu tertentu. Sekali lagi, jumlah gerakan kosong telah dioptimalkan. Untuk tujuan ini algoritma dekomposisi heuristik telah diterapkan. Akhirnya, ukuran armada telah ditentukan dengan cara yang sama seperti pada model pertama. DSS yang diusulkan memungkinkan DM untuk menyesuaikan salah satu model yang dijelaskan di atas untuk situasi keputusan tertentu dan menghasilkan jumlah gerbong yang optimal untuk keseluruhan sistem perkeretaapian yang dianalisis.

Ada beberapa paket perangkat lunak komersial untuk transportasi kereta api, termasuk: InfraManager [63] dan Ramsys [63]. InfraManager adalah perencanaan berbasis komputer dan alat pendukung keputusan yang dirancang dan dikembangkan untuk Italian Railways (RFI). Ini membantu DM-s untuk merancang, memelihara, mengontrol dan

mengembangkan sistem transportasi kereta api. InfraManager mendukung aktivitas manajerial dan proses pengambilan keputusan yang berfokus pada: analisis permintaan untuk layanan transportasi kereta api, manajemen armada dan infrastruktur transportasi, manajemen sumber daya manusia, kontrol keselamatan, dan layanan pelanggan. InfraManager membantu pengguna dalam merancang dan mendesain ulang jaringan transportasi, menyarankan perluasan dan pengurangan jaringan, menjadwalkan kereta api dan kru, menganalisis kondisi teknis kendaraan dan kereta api, merekomendasikan layanan pemeriksaan dan pemeliharaan. Penerapan InfraManager di Italian Railways menghasilkan pengurangan biaya tertentu, pengenalan solusi inovatif dan peningkatan substansial layanan pelanggan. Ramsys (Railway Asset Management System) adalah DSS yang canggih, generik, dan modular yang dirancang untuk mendukung analisis data guna mengoptimalkan perencanaan pemeliharaan dan pembaruan infrastruktur perkeretaapian (lihat Gambar 8).



**Gambar 11.8** Diagnostik grafis dan analisis kondisi teknis infrastruktur transportasi kereta api di Ramsys DSS

Ramsys adalah perangkat keras dan perangkat lunak gabungan yang mengumpulkan dan memproses berbagai data yang relevan dengan analisis kondisi teknis infrastruktur perkeretaapian. Sistem mengukur sejumlah parameter diagnostik, mendeteksi masalah teknis di jaringan kereta api dan mengevaluasi kondisinya. Ini menjembatani rekayasa diagnostik dan pemeliharaan untuk infrastruktur kereta api melalui kegiatan berorientasi proses yang meliputi: pemantauan infrastruktur dan menghasilkan generasi catatan pengukuran, menganalisis situasi dan mendeteksi cacat, intervensi perencanaan dan mengeluarkan peringatan, penjadwalan kegiatan pemeliharaan dan menciptakan perintah

kerja, mengendalikan pelaksanaan kegiatan pemeliharaan. Sistem kereta api divisualisasikan di Ramsys dan segmen jaringan tertentu di mana masalah teknis terdeteksi ditampilkan di layar.

Grafik grafik dengan sinyal dan parameter diagnostik membantu DM-s (perencana) untuk menganalisis situasi yang ada dan mengembangkan serangkaian skenario intervensi. Mengadopsi segmentasi bertingkat yang canggih, Ramsys dapat memproses dan melakukan penalaran secara efektif berdasarkan semua jenis data (titik pengukuran lokal, segmen, bagian lintasan, jalur, departemen pemeliharaan, area kontraktor pemeliharaan, wilayah, dll.) untuk memberikan pengetahuan lokal dan global tentang infrastruktur perkeretaapian baik dari segi kondisi jaringan (dulu, sekarang dan yang akan datang) maupun kebutuhan pemeliharaan dan pembaruannya. Ramsys, yang dilengkapi dengan kumpulan alat pengoptimalan, mengoptimalkan biaya pemeliharaan dan rencana pembaruan yang tunduk pada batasan lalu lintas dan anggaran. Berdasarkan optimasi tersebut, sistem komputer menjadwalkan kegiatan pemeliharaan dan mengeluarkan perintah kerja. Contoh tambahan DSS-s transportasi kereta api adalah sistem yang dijelaskan di atas: Harmony CDR untuk penjadwalan kru dan rostering [20] dan Hastus [63] yang dapat diterapkan untuk perencanaan operasi kereta api ringan, terutama di wilayah metropolitan.

Sejauh transportasi laut yang bersangkutan, penekanan yang paling ditempatkan pada pengembangan DSS-s memecahkan masalah perutean kapal dan penjadwalan. Namun, sebagian besar perusahaan pelayaran laut melakukan perencanaan jadwal armada secara manual berdasarkan pengalaman mereka. Hanya sedikit yang menggunakan optimasi – berbasis DSS-s. Karena berbagai kategori operasi lintas laut, termasuk: pelayaran industri, pelayaran kargo komersial, pelayaran tramp dan liner dan operasi angkatan laut, memerlukan pendekatan yang berbeda untuk perutean dan penjadwalan kapal, dengan demikian, DSS-s yang dikembangkan memiliki karakter yang disesuaikan dan dapat diterapkan dengan sangat baik. situasi tertentu. Di sisi lain kesamaan antara berbagai kategori masalah perutean dan penjadwalan kapal menghasilkan penerapan teknik yang sama untuk memecahkan masalah tersebut. Dalam sebagian besar kasus, algoritma yang paling umum digunakan meliputi: pemrograman linier (LP) dengan heuristik, pemrograman integer dan integer campuran, partisi set dan simulasi.

D. Bausch, G. Brown dan D. Ronen [4] menyajikan DSS untuk penjadwalan jangka menengah (2–3 minggu) armada kapal tanker pesisir dan tongkang yang mengangkut produk curah cair di antara pabrik, pusat distribusi, dan pelanggan industri. Kapal mungkin memiliki hingga 7 kompartemen tetap, yang diterjemahkan ke dalam beberapa kategori produk yang akan diangkut oleh kapal yang sama. Selain kumpulan muatan tertentu yang harus dikirim, mungkin ada beberapa pengangkutan belakang opsional yang tersedia. Pengangkutan kembali ini menghasilkan pendapatan dan dapat diambil jika menguntungkan. Masalah penjadwalan kapal dirumuskan sebagai masalah pembagian himpunan elastis, di mana beberapa kendala mungkin dilanggar dengan biaya. Metode solusi mengeksplorasi pengetahuan masalah dalam prosedur enumerasi elastis. Masalah keputusan diselesaikan dengan membangkitkan semua jadwal yang layak karena dibatasi dengan baik. DSS dilengkapi dengan antarmuka yang ramah pengguna berdasarkan spreadsheet Excel sederhana. Solusi ini membuat sistem dapat digunakan melalui berbagai bahasa alami. Dispatcher di seluruh

dunia dapat berkomunikasi melalui spreadsheet terlepas dari bahasa ibu mereka dan melihat jadwal yang direkomendasikan yang ditampilkan dalam bagan Gantt.

K. Fagerholt [19] telah mengembangkan DSS serupa untuk penjadwalan armada kapal, yang disebut TurboRouter. Saat merancang sistem, penulis mendefinisikan prasyarat utama berikut untuk DSS penjadwalan armada kapal: 1) Ini harus menjamin waktu respons yang cepat, yaitu solusi harus dihasilkan dalam waktu singkat; 2) Solusi harus ditampilkan dengan kualitas tinggi (mendekati solusi optimal); 3) DSS harus fleksibel dalam memodelkan kendala kehidupan nyata; 4) Ini harus memungkinkan interaksi yang baik dengan pengguna. Untuk memenuhi asumsi tersebut, sebuah rutin optimasi yang terdiri dari dua algoritma heuristik yang berbeda telah dikembangkan. Yang pertama adalah algoritma penyisipan yang memproses kargo secara berurutan, memasukkan satu per satu ke dalam jadwal kerja hingga semua kargo diproses. Algoritma kedua adalah pencarian lokal hibrida yang meningkatkan solusi yang dihasilkan.

Rutin optimalisasi yang diterapkan dalam DSS yang diusulkan mengakomodasi fitur-fitur berikut: mengoptimalkan sehubungan dengan hasil keuangan dan pemanfaatan kapasitas armada dalam periode perencanaan yang ditentukan pengguna, memperhitungkan jendela waktu kargo dan kapasitas kapal, memeriksa kompatibilitas antara kapal dan pelabuhan muat / bongkar serta peralatan kapal dan karakteristik produk, memperhitungkan beberapa produk, kargo paket dan muatan kapal penuh serta kargo terpisah, menggabungkan kargo spot dan kontrak, termasuk atau tidak termasuk kapal sewa waktu. Antarmuka DSS memiliki spreadsheet – seperti formulir yang mewakili penugasan kargo ke kapal. Warna khusus yang digunakan dalam spreadsheet mewakili batasan fisik, batasan waktu, dan penugasan kargo ke kapal. Selain itu, visualisasi jadwal yang dihasilkan dimungkinkan. DM dapat melihat diagram Gantt, grafik pemanfaatan kapasitas, lokasi geografis rute kapal di grafik laut.

## **11.6 TRANSPORTASI – DSS-S DITERAPKAN DI BERBAGAI INDUSTRI DAN DSS-S MULTIMODAL**

Karena fitur alami transportasi adalah transfer kategori barang yang berbeda dan integrasi fisik dari tautan/organisasi/industri yang berbeda dari rantai pasokan, solusi transportasi tertentu mengacu pada industri tertentu yang mereka rancang. Dengan demikian, DSS-s yang dipilih difokuskan pada pemecahan masalah keputusan transportasi di cabang-cabang tertentu. DSS-s yang dijelaskan di bawah ini melibatkan kasus-kasus khusus berikut dari masalah keputusan transportasi yang dihadapi di berbagai industri dan negara: pemilihan pembawa motor untuk produsen peralatan penahanan gas tekanan tinggi di AS, perutean dan penjadwalan truk logging di industri kehutanan di Swedia, merancang rute pengiriman untuk produsen daging di Spanyol. Juga disajikan dua contoh DSS-s transportasi multimoda.

C.-C. Kuo dan F. Soflarsky [24] menyajikan DSS yang berfokus pada pemilihan pembawa motor untuk perusahaan manufaktur yang memproduksi peralatan penahanan gas bertekanan tinggi di Amerika Serikat. Sistem komputer membantu manajer lalu lintas perusahaan manufaktur dalam proses pengambilan keputusan yang berfokus pada pemilihan perusahaan truk yang paling sesuai untuk mengirimkan barang jadi kepada pelanggan terpilih.

Pemilihan operator dikombinasikan dengan penjadwalan layanan transportasi. DSS yang dipertimbangkan memperhitungkan pengangkut penuh – truk (FTL) dan kurang dari – angkutan truk (LTL) dan mengasumsikan tiga biaya pengiriman alternatif: tarif tetap per pengiriman, tarif variabel per mil (kilometer) dengan biaya minimum dan tarif variabel per pon (kilogram) beban dengan muatan minimum. Perhatian utama dalam proses pemilihan pembawa yang dilakukan oleh DSS adalah minimisasi biaya.

Dengan demikian, DSS mengurutkan pengangkut dari yang termurah hingga yang paling mahal untuk pengiriman tertentu dan memilih varian terbaik. Selain itu, sistem mengoptimalkan rencana pengiriman melalui konsolidasi pesanan yang dikirim ke wilayah geografis yang sama dalam rentang waktu yang sama. Berdasarkan model pemrograman linier yang relatif sederhana, DSS mendefinisikan rencana pengiriman yang optimal. Rencana yang dibuat secara otomatis ini dibandingkan dengan rencana manual dan intuitif yang diusulkan oleh manajer lalu lintas. Studi menunjukkan bahwa dalam beberapa kasus (beberapa pengiriman) manual, prosedur intuitif mengungguli metode otomatis. Ini mengungkapkan, bagaimanapun, bahwa pengeluaran transportasi secara keseluruhan dapat dikurangi sebesar 3%.

G.Andersson et. Al. [2] mencirikan RUTTOPT – DSS terkomputerisasi canggih untuk perutean dan penjadwalan truk logging di industri kehutanan di Swedia. Sistem ini terdiri dari beberapa modul, antara lain: aplikasi utama (Central Module), yang merupakan pusat user interface dari RUTTOPT DSS. Antarmuka pengguna ini terdiri dari 3 komponen utama, seperti: Basis Data Internal, Sistem Informasi Geografis (SIG) dan Komponen Presentasi. Ini menawarkan fungsionalitas yang berbeda untuk: melihat data geografis yang diambil dari GIS, mengedit data, mengembangkan laporan dan menganalisis hasil yang dihasilkan. Semua informasi dan hasil dapat dilihat pada peta, jadwal Gantt dan tabel, sehingga semuanya memiliki bentuk numerik dan grafik. Basis Data Internal berisi semua informasi relevan yang diperlukan untuk merumuskan dan menyelesaikan masalah rute kendaraan, seperti: informasi penawaran dan permintaan, karakteristik truk, informasi tentang depot dan perubahan pengemudi yang diperlukan, definisi jendela waktu, dll.

Hal ini terkait dengan eksternal Swedia National Road Database (NVDB) yang berisi informasi digital dari semua jalan Swedia. Jalan-jalan sepanjang kurang lebih 500.000 kilometer tersebut digambarkan secara geometris dan topologis dengan tambahan informasi pada setiap ruas jalan. NVDB merupakan Modul ke-2 dari RUTTOPT DSS. Modul ini juga mencakup alat untuk menghitung jarak antar lokasi. Modul 3 – Perencana Rute adalah paket pengoptimalan yang menemukan rute dan jadwal optimal untuk semua truk. Modul ini menggunakan algoritma dua fase berdasarkan pemrograman linier (fase 1) dan versi lanjutan dari algoritma pencarian tabu terpadu (UTSA), yang diusulkan oleh Cordeau et al. Pada fase pertama, aliran yang layak antara titik suplai dan permintaan didefinisikan dan node transportasi yang optimal (titik pengambilan dan pengiriman) dihasilkan melalui penerapan program linier. Pada fase kedua masalah rute kendaraan diselesaikan dengan penerapan UTSA. RUTTOPT DSS telah diterapkan di beberapa contoh mulai dari 10 hingga 110 truk dengan horizon perencanaan 1 hingga 5 hari. DSS terbukti berguna dalam kasus VRP yang relatif besar. Hasil komputasi yang dihasilkan oleh sistem RUTTOPT menjamin potensi penghematan sebesar 5% hingga 30%.

Contoh lain dari DSS berorientasi transportasi, melayani di cabang yang berbeda adalah RUTAREP, dikembangkan oleh J. Belenguer, E. Benavent dan M. Martinez [5]. Sistem ini membantu DM untuk merancang rute pengiriman untuk perusahaan daging menengah di Spanyol. Masalah yang dipecahkan oleh DSS adalah varian yang diperluas dari masalah rute kendaraan dengan karakteristik khusus berikut: armada kendaraan yang heterogen, jendela waktu yang lunak, fungsi biaya tujuan ganda termasuk keterlambatan total (keterlambatan) pengiriman dan total jarak yang ditempuh., partisi pesanan berdasarkan zona dan kendaraan (dengan batasan tambahan bahwa setiap kendaraan harus melayani persentase pesanan yang telah ditentukan sebelumnya).

Masalahnya diselesaikan dengan seperangkat/kombinasi heuristik khusus dan metaheuristik, yang memanfaatkan fitur spesifik dari masalah keputusan yang dihadapi perusahaan daging. Solusi semi-optimal dihasilkan oleh prosedur komputasi dua fase. Pada tahap pertama prosedur heuristik konstruktif berdasarkan algoritma penyisipan M. Solomon digunakan untuk merancang rute yang layak untuk setiap kendaraan. Rute ini mencakup sebanyak mungkin urutan zonanya. Semua pesanan yang tidak dirutekan dimasukkan ke rute lain, terlepas dari zonanya dengan heuristik tambahan. Setelah solusi yang layak diperoleh, algoritma perbaikan berdasarkan Tabu Search dan terinspirasi oleh karya E. Tailard et al. diterapkan. Sistem ini memungkinkan untuk meminimalkan total jarak yang ditempuh oleh kendaraan dan total keterlambatan (keterlambatan) yang terjadi saat melayani pesanan serta untuk menyeimbangkan kedua tujuan. Sistem telah dikodekan dalam Visual C++ dan berjalan pada komputer pribadi di bawah sistem Windows. Hal ini ditandai dengan fitur/fungsi berikut: membaca, mengedit dan menangani data pelanggan, kendaraan dan pesanan (termasuk data geografis dalam bentuk digital); membangun, menampilkan dan memodifikasi rute; menghitung jarak dan waktu tempuh antar pelanggan; mengoptimalkan rute pengiriman. RUTAREP DSS secara substansial meningkatkan solusi yang ada masing-masing sebesar 9% - 15% dan 81% - 88% dalam hal jarak total dan keterlambatan total (keterlambatan).

Dua contoh DSS-transportasi multimoda mencakup usulan:

B. Vannieuwenhuyse, L. Gelders dan L. Pintelon [50] dan W. Dullaert et al. [17]. Produk pertama yang diberi nama Promodi adalah DSS online untuk pilihan moda transportasi. Ini mengumpulkan melalui data Internet dari para praktisi tentang persepsi mereka tentang moda transportasi yang berbeda, memproses data dan mengubahnya menjadi pentingnya kriteria terpilih yang mengevaluasi moda untuk rantai logistik dan kinerja moda tertentu pada kriteria tertentu. Sistem mempertimbangkan kriteria berikut saat mengevaluasi moda transportasi: biaya transportasi, keandalan, fleksibilitas, waktu transportasi, keselamatan, kapasitas, kepadatan jaringan, peraturan dan undang-undang, dampak, citra, elemen strategis. Promodi menggunakan metode konsensus beberapa kriteria untuk mengevaluasi varian. Berdasarkan evaluasi tersebut dihasilkan peringkat moda transportasi dan ditampilkan baik secara numerik maupun grafis.

**Tabel 11.1** menyajikan perbandingan transportasi yang dipilih – berorientasi DSS-s.

DSS berorientasi transportasi	Fokus modal	Metodologi pengambilan keputusan	daerah aplikasi;	Produsen	Manfaat yang dilaporkan
-------------------------------	-------------	----------------------------------	------------------	----------	-------------------------

		yang mendasari	lingkup & fokus subjek		
TransCAD	jalan, perkotaan , rel, pipa	pengoptimalan	manajemen armada, analisis jaringan transportasi	Perusahaan Kaliper	<ul style="list-style-type: none"> <li>- penghematan biaya</li> <li>- pengurangan substansial dari perencanaan manual,</li> <li>- peningkatan utilisasi armada,</li> <li>-tingkat layanan pelanggan yang lebih tinggi,</li> <li>-kontrol yang lebih baik dari proses transportasi,</li> </ul>
Sistem Pusat Logix	jalan	pengoptimalan	manajemen armada (perutean dan penjadwalan kendaraan)	DPS Internasional	<ul style="list-style-type: none"> <li>- pengurangan total biaya distribusi hingga 25%,</li> <li>- pengurangan substansial dari perencanaan manual,</li> <li>- peningkatan utilisasi armada,</li> <li>-tingkat layanan pelanggan</li> </ul>

					yang lebih tinggi, -kontrol yang lebih baik dari proses transportasi,
Perencana Rute	jalan	pengoptimala n	manajemen armada (perutean dan penjadwalan kendaraan)	Descartes Systems Group Inc.	- Pengurangan 10-30% dalam biaya bahan bakar, -Peningkatan 20% -40% dalam pemanfaatan kendaraan, -10%-25% peningkatan tingkat layanan pelanggan, -hingga 50% pengurangan intensitas tenaga kerja dari proses perencanaan .
Pemberhentian truk	jalan	pengoptimala n	manajemen armada (perutean dan penjadwalan kendaraan)	Mekanika Peta	- Pengurangan 10-30% dalam biaya bahan bakar, - Peningkatan 20% -40% dalam pemanfaatan kendaraan, -10% -20% peningkatan tingkat

					layanan pelanggan, -hingga 50% pengurangan intensitas tenaga kerja dari proses perencanaan .
Xenios	jalan	pengoptimalan	manajemen armada (perutean dan penjadwalan kendaraan); pengaturan acara	Universitas Aristoteles di Thessaloniki , Universitas Ekonomi dan Bisnis Athena	- penghematan biaya - pengurangan perencanaan manual
TAMBUR KECIL	jalan	pengoptimalan	manajemen armada (penggantian kendaraan)	Universitas Teknologi Poznan	- pengurangan substansial dari usia armada, -10-20% pengurangan biaya kendaraan, - pengurangan perbaikan armada dan tugas sernice -Peningkatan 15-20% ketersediaan armada dan kenyamanan berkendara
HASTUS	perkotaan multimoda	pengoptimalan	perencanaan transportasi perkotaan (penjadwalan transit, operasi, dan	GIRO Inc.	- penghematan biaya 2% - 5% - pengurangan

			informasi pelanggan) perancangan sisi udara		substansial dari perencanaan manual,
AeroTURN	mengudara	simulasi	manajemen armada (penjadwalan penerbangan )	Transoft Solutions Inc.	- penghematan biaya - pengurangan substansial dari perencanaan manual,
Manajer Jadwal Sabre AirFlite	mengudara	pengoptimalan	manajemen pengiriman, manajemen armada	Solusi Maskapai Saber	- peningkatan profitabilitas, - meningkatkan perencanaan strategis, - perbaikan perencanaan jangka pendek, - peningkatan pemanfaatan pesawat - peningkatan liburan dan penjadwalan acara khusus, - penghematan biaya
Jaringan Logistik Global	mengudara	pengoptimalan	manajemen personalia (penjadwalan dan daftar kru),	Descartes Systems Group Inc.	- penghematan biaya - pengurangan substansial dari

					perencanaan manual,
Harmoni CDR	udara, kereta api	pengoptimala n	pemeliharaa n dan pembaruan infrastruktur	ORTEC bv	<ul style="list-style-type: none"> <li>- penghemata n biaya</li> <li>- pengurangan substansial dari perencanaan manual,</li> </ul>
Ramsys	rel	pengoptimala n, penambangan data	manajemen armada (penjadwala n armada)	Grup MERMEC	<ul style="list-style-type: none"> <li>- meningkatka n keselamatan lalu lintas &amp; mengurangi risiko kecelakaan,</li> <li>- peningkatan ketersediaan jaringan dan penggunaan waktu kepemilikan,</li> <li>- penurunan biaya pemeliharaa n &amp; siklus hidup aset yang diperpanjang ,</li> </ul>
TurboRouter	terbawa air	pengoptimala n	manajemen armada (perutean dan penjadwalan kendaraan)	Solusi MARINTEK	<ul style="list-style-type: none"> <li>- penghemata n biaya</li> <li>- pengurangan substansial dari perencanaan manual,</li> </ul>

RuttOpt	jalan	pengoptimalan	Manajemen Transportasi (pilihan moda)	Skogforsk	- penghematan biaya 5%-30%.
Promo	multimoda	MCDM	daerah aplikasi; lingkup & fokus subjek	Katholieke Universiteit Leuven	- penghematan biaya

DSS kedua, yang disebut Mam-MoeT adalah platform komunikasi waktu nyata di mana agen perangkat lunak cerdas menangani tugas-tugas komunikatif, bertukar sejumlah informasi yang diinginkan di antara pengguna yang berbeda. Agen perangkat lunak, yaitu perangkat lunak mewakili satu pengguna. Mereka mengambil alih berbagai tugas komunikatif secara real-time dan memungkinkan pertukaran informasi antara mitra dalam rantai pasokan (pengirim, pengiriman, pengangkut, pelanggan). DSS juga memungkinkan penyesuaian tingkat tinggi, sehingga pengguna dapat memutuskan sendiri berapa banyak informasi yang akan dibagikan (masalah kepercayaan). MamMoeT memproduksi dan menggunakan protokol pertukaran umum yang bertindak sebagai penerjemah antara sistem yang berbeda.

## 11.7 KESIMPULAN

Bab ini menyajikan gambaran umum tentang DSS berbasis komputer yang diterapkan dalam transportasi. Ini mencirikan baik solusi perangkat lunak komersial maupun DSS-s berorientasi transportasi berbasis penelitian. Analisis ini mencakup spektrum DSS-s yang dikembangkan untuk berbagai sektor transportasi, termasuk: transportasi jalan, transportasi perkotaan, transportasi udara, kereta api dan transportasi laut serta transportasi yang digunakan di industri lain dan transportasi multimoda. Secara keseluruhan ada 43 DSS-s berorientasi transportasi. Definisi dan klasifikasi DSS-s berorientasi transportasi disediakan dan kategori utama dari masalah keputusan transportasi yang diselesaikan oleh sistem berbasis komputer transportasi dibahas. Penulis menjelaskan metodologi utama dan teknologi informasi yang saat ini digunakan dalam DSS-s berorientasi transportasi.

Kecenderungan-kecenderungan utama yang diamati pada DSS-s berorientasi transportasi canggih adalah sebagai berikut:

- pemanfaatan metode eksak dan perkiraan (heuristik) dengan minat yang berkembang dalam prosedur heuristik dan metaheuristik;
- penerapan Beberapa Kriteria Pengambilan Keputusan / Metodologi Pembantu;
- integrasi DSS-s dengan Sistem Informasi Geografis (GIS-s) untuk visualisasi dan analisis solusi transportasi;
- penyediaan komunikasi bergerak on-line dengan DSS-s melalui teknologi GSM dan GPRS;
- pengembangan DSS-s on-line berbasis web;
- integrasi DSS-s dan ES-s; pemanfaatan pengetahuan ahli dan metode kecerdasan buatan;

- menyediakan metodologi gabungan-hibrida dan berbagai teknik berbeda untuk memecahkan masalah keputusan transportasi yang kompleks dalam satu DSS;
- mempromosikan karakter interaktif DSS-s dan mekanisme pembelajaran, mendorong DM untuk menggunakan sistem.

Studi ini telah membuktikan bahwa DSS-s berorientasi transportasi dapat menghasilkan manfaat nyata bagi pengguna, termasuk:

- penghematan biaya kegiatan transportasi;
- peningkatan layanan pelanggan transportasi;
- efisiensi dan keandalan proses transportasi yang lebih tinggi;
- peningkatan akurasi proses pengambilan keputusan;
- peningkatan fleksibilitas dan pengurangan intensitas tenaga kerja dari proses perencanaan transportasi;
- pengurangan kesalahan dan kerjasama yang lebih baik antara mitra yang menggunakan DSS-s;
- peningkatan pemanfaatan aset (armada dan infrastruktur);
- pengurangan kejadian tak terduga dan tak terduga;
- waktu reaksi yang singkat terhadap fenomena eksternal dan peristiwa mendesak;
- penghapusan keputusan intuitif – pengambilan.

Manfaat tersebut ditunjukkan dan diukur dengan baik oleh J. Christie dan S. Satir [15]. Penulis mengklaim bahwa untuk kondisi lalu lintas Kanada, penerapan sistem perutean dan penjadwalan kendaraan yang terkomputerisasi dapat menghasilkan: 20% - 30% peningkatan keselamatan, 1% hingga 5% peningkatan layanan pelanggan dan 10% hingga 40% perpanjangan daya tahan perkerasan. Studi yang sama menunjukkan bahwa penerapan sistem komputer seperti: Optrak 4 System [59], Paragon Routing and Scheduling System [60] atau Truckstops System [57] dapat menghasilkan penghematan biaya transportasi dalam kisaran 10% hingga 30%. Karya J. Christie dan S. Satir [15] dan J. Zak [67] membuktikan bahwa penerapan sistem komputerisasi secara substansial dapat mengurangi intensitas tenaga kerja perencanaan manual operasi kegiatan transportasi, bahkan sebesar 50%.

Intensitas pemanfaatan DSS-s di berbagai sektor transportasi sangat berbeda. Banyak sistem komputerisasi diterapkan dalam transportasi jalan, perkotaan dan udara. Kereta api dan transportasi laut tertinggal dalam hal pengembangan solusi berbasis komputer yang mendukung proses pengambilan keputusan. Namun, situasinya berubah, dan lebih banyak lagi DSS-kereta api dan lintas laut sedang dikembangkan.

## BAB 12

### SISTEM PENDUKUNG KEPUTUSAN UNTUK INDUSTRI MAKANAN

Aplikasi Sistem Pendukung Keputusan (SPK) dalam industri makanan, dan khususnya industri makanan laut, dibahas. Jumlah data yang direkam dalam industri makanan telah meningkat pesat dalam dekade terakhir, sejajar dengan penurunan biaya perekaman data melalui otomatisasi dan sistem komputer. Data tersebut dapat digunakan untuk memenuhi kebutuhan konsumen yang menginginkan informasi tentang produk pangannya, seperti asal, dampak terhadap lingkungan dan lainnya. Dengan menggunakan ketertelusuran, aliran data ini dapat digunakan untuk mendukung keputusan. Banyak bidang dalam pengolahan makanan dapat memperoleh keuntungan dari penggunaan DSS. Bidang tersebut termasuk misalnya menurunkan dampak lingkungan dari pengolahan makanan, manajemen keamanan, manajemen pengolahan dan manajemen stok. Proyek penelitian dan pengembangan yang telah diikuti oleh penulis dan implementasi solusi perangkat lunak berikut dibahas dan beberapa contoh penggunaan praktis DSS dalam industri makanan sebagai hasil dari pekerjaan tersebut.

#### **12.1 PENDAHULUAN**

Industri makanan laut adalah satu-satunya industri makanan terpenting di Islandia dan Norwegia. Oleh karena itu, sebagian besar diskusi kita dalam bab ini didasarkan pada penelitian di industri makanan laut dan mengambil sudut pandang dalam industri itu. Penelitian dan pengembangan mengenai pendukung keputusan dalam industri makanan laut telah diperluas ke industri daging dan dikombinasikan dengan metode lain, seperti manajemen pasokan stok. Itu menunjukkan dengan baik karakteristik rantai nilai industri makanan secara umum. Jika beberapa metode dapat diterapkan pada satu rantai nilai, misalnya rantai makanan laut, metode tersebut juga sering diterapkan pada rantai lainnya.

Pasar makanan telah berubah secara dramatis dalam beberapa tahun terakhir. Penggabungan pengecer telah menciptakan perusahaan multi-nasional yang menjual sebagian besar produk mereka di bawah label mereka sendiri, yang mampu memberikan tekanan pada produsen produk makanan terkait harga. Kemungkinan besar skala ekonomi akan terus menjadi penting ketika bersaing untuk mendapatkan perhatian konsumen dengan daya beli yang menurun. Perkembangan ini, serta munculnya toko khusus, yang bertujuan untuk menarik perhatian konsumen berpenghasilan tinggi, sering kali dipasarkan dengan pernyataan keberlanjutan dan oriinalitas. Ini telah menyebabkan tekanan besar pada mata rantai berikutnya, yaitu pemrosesan. Tuntutan dari pasar berarti seorang pengelola pengolahan membutuhkan bahan baku yang mudah diolah dan dalam jumlah yang tepat, sesuai dengan pesanan dari pasar. Dalam banyak kasus, pasokan bahan baku dibatasi. Dalam industri terpenting bagi Islandia, industri makanan laut, total tangkapan yang diizinkan misalnya dibatasi oleh regulasi (kuota). Oleh karena itu, pendapatan terutama ditentukan oleh harga produk dan hasil produksi dari pasokan bahan baku yang terbatas. Sifat bahan baku yang dicari oleh pabrik pengolahan adalah agar ikan dapat dimanfaatkan dengan baik, sifat dan volume hasil tangkapan memenuhi permintaan konsumen sehingga menghasilkan harga

produk yang tinggi. Seperti yang ditunjukkan Hasan dan Raffensberger [9], aktivitas yang termasuk dalam rantai nilai makanan laut, seperti penangkapan ikan, penjadwalan kapal, pemrosesan, dan pemasaran saling bergantung satu sama lain.

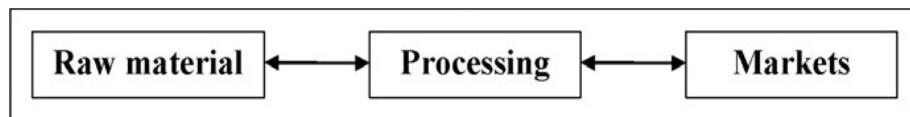
Keputusan tentang penangkapan ikan, pengolahan, alokasi tenaga kerja, alokasi kuota dan pemasaran dapat memainkan peran penting dalam kualitas akhir produk yang dipasarkan dan dengan demikian keuntungan yang diperoleh. Untuk memasok pasar ikan segar dengan penjadwalan trawl produk berkualitas, penanganan bahan mentah, penjadwalan pemrosesan, dan logistik semuanya harus berjalan beriringan. Penanganan ikan yang buruk mengakibatkan kualitas produk yang kurang baik. Pendinginan dan icing yang tidak tepat, misalnya, menghasilkan suhu daging yang lebih tinggi, yang memengaruhi pertumbuhan bakteri. Peningkatan pertumbuhan bakteri berkontribusi pada umur simpan yang lebih pendek, salah satu faktor terpenting bagi pengecer. Usia bahan baku sangat penting dan dengan demikian rencana waktu yang terorganisir dengan baik dari penangkapan hingga pemrosesan juga sama pentingnya. Seperti yang disebutkan oleh Arnarson dan Jensson [2], produsen yang memiliki lebih banyak waktu untuk memproses sejumlah bahan baku dapat diharapkan untuk menghasilkan produk yang lebih bernilai, daripada produsen yang berjuang dengan tekanan waktu. Oleh karena itu, memiliki waktu yang cukup untuk pemrosesan dan pengetahuan tentang bahan mentah terlebih dahulu untuk mengatur pemrosesan dengan cara yang paling efisien, sangatlah penting.

Biaya pemrosesan juga penting. Tenaga kerja, energi dan transportasi merupakan beberapa faktor yang mempengaruhi biaya. Faktor biaya yang sama berlaku untuk mata rantai penangkapan. Nelayan membutuhkan ikan yang dapat ditangkap dengan mudah, sebaiknya tidak jauh dari pelabuhan pendaratan, karena waktu berlayar yang lama ke tempat penangkapan akan meningkatkan biaya minyak dan mempersulit pasokan ikan segar ke pabrik pengolahan, tetapi bahan baku tersebut adalah tentu saja merupakan syarat untuk dapat mengolah fillet untuk dieksport ke pasar dalam keadaan segar sehingga dengan margin kontribusi yang tinggi.

Pendukung keputusan juga penting dalam kaitan pemrosesan. Pengetahuan awal tentang sifat-sifat bahan baku sangat penting ketika merencanakan produksi. Banyak pabrik pengolahan ikan memiliki tenaga kerja yang fleksibel, dan dalam waktu singkat (biasanya sehari) memilih untuk mempekerjakan lebih banyak atau lebih sedikit orang dalam pengolahan. Proses yang paling intensif secara manual dalam rantai ikan yang ditangkap adalah pemangkasan manual dan deboning akhir dari fillet ikan, dan lusinan orang sering bekerja secara paralel dalam tugas ini. Keterampilan, pengalaman, kecepatan, dan hasil sangat bervariasi antara orang-orang di garis pemangkasan, dan merupakan hal yang umum untuk menyimpan riwayat kinerja untuk setiap pekerja dan memberikan bonus uang untuk kecepatan tinggi/hasil tinggi/sedikit tulang yang terlewatkan. Salah satu keputusan harian terpenting yang harus dibuat oleh pemimpin produksi adalah berapa banyak orang yang akan ditempatkan di jalur pemangkasan. Terlalu banyak, dan pemangkas tidak digunakan. Terlalu sedikit, dan kemacetan akan terbentuk di depan garis pemangkasan yang pada gilirannya akan menyebabkan peningkatan yang signifikan dalam waktu throughput, dan penurunan yang sesuai dalam kualitas produk jadi. Untuk membuat keputusan ini, pemimpin produksi perlu mengetahui kinerja yang diharapkan dari para pekerja, tetapi juga seberapa padat karya

pemangkasan diharapkan. Memperkirakan faktor terakhir ini sangat kompleks. Pekerjaan yang terlibat dalam pemangkasan manual tergantung langsung pada spesies, ukuran, bentuk dan tekstur ikan. Umumnya, spesies ikan telah diketahui sebelumnya (walaupun tangkapan dalam praktiknya sering kali mengandung beberapa spesies), tetapi data rinci tentang sifat-sifat lainnya tidak tersedia secara langsung sebelumnya. Apa yang diketahui adalah bahwa banyak faktor lain, seperti area penangkapan ikan, waktu dalam setahun, suhu, jenis peralatan, perawatan di atas kapal, dll. mempengaruhi ukuran, bentuk dan tekstur, dan begitu keputusan penting harus dibuat berdasarkan skala besar, kompleks, dan saling terkait. Kumpulan data, ada yang diketahui dan ada yang diperkirakan.

Industri ikan Nordik sangat mengeksplorasi solusi teknis. Peralatan pencarian ikan modern, seperti radar, digunakan untuk membantu menemukan ikan. Buku log elektronik sekarang menjadi wajib. Dengan mengumpulkan data elektronik tentang tangkapan, perusahaan memungkinkan berbagi informasi antara kapal dan pemrosesan berbasis darat tentang bahan baku dan membangun database tentang tangkapan dan propertinya.



**Gambar 12.1** Rantai nilai ikan kod yang disederhanakan. Panah mewakili aliran material (hulu) dan informasi (hulu dan hilir).

## 12.2 KUALITAS DAN KETERTELUSURAN DATA

Salah satu tantangan terbesar untuk pendukung keputusan adalah ketersediaan ex-ante data nyata, relevan dan representatif untuk mendasarkan keputusan. Dalam industri produksi pada umumnya, ketersediaan dan pengelolaan data bahan, proses dan produk melalui sistem ketertelusuran. Definisi ketertelusuran produk yang paling ringkas adalah dalam standar ISO 8402 lama di mana 'kemampuan ketertelusuran' didefinisikan sebagai 'kemampuan untuk melacak sejarah, aplikasi, atau lokasi suatu entitas melalui identifikasi yang direkam', dan 'ketertelusuran produk' adalah dikatakan secara khusus mencakup 'asal bahan dan suku cadang, riwayat pemrosesan produk, dan distribusi serta lokasi produk setelah pengiriman'. Kesalahpahaman yang populer adalah bahwa ketertelusuran identik dengan kemampuan untuk mengidentifikasi asal. Perhatikan bahwa definisi tersebut secara eksplisit menunjukkan bahwa jika Anda memiliki ketertelusuran, Anda seharusnya tidak hanya mengetahui dari mana produk atau bahan-bahan itu berasal, tetapi juga proses apa yang mereka lalui dan di mana mereka berakhir.

Untuk industri produksi secara umum, ada berbagai alasan mengapa perusahaan memilih untuk berinvestasi dalam sistem ketertelusuran. Manfaat paling penting dari ketertelusuran internal telah disebutkan oleh Moe [24] menjadi:

1. Kemungkinan untuk meningkatkan kontrol proses
2. Indikasi sebab-akibat ketika produk tidak sesuai dengan standar
3. Kemungkinan menghubungkan data produk dengan karakteristik bahan baku dan data pemrosesan
4. Perencanaan yang lebih baik untuk mengoptimalkan penggunaan bahan baku untuk setiap jenis produk

5. Menghindari pencampuran bahan baku berkualitas tinggi dan rendah yang tidak ekonomis
6. Kemudahan pencarian informasi dalam audit manajemen mutu
7. Alasan yang lebih baik untuk menerapkan solusi TI untuk sistem kontrol dan manajemen

Selain itu, memiliki sistem ketertelusuran yang baik juga memberikan keuntungan yang signifikan ketika berhadapan dengan pemasok, pelanggan, dan rantai pasokan lainnya. moe [24] menunjukkan bahwa keuntungan dari ketertelusuran eksternal, atau rantai pasokan, terutama terkait dengan:

1. Prosedur penarikan yang efisien untuk meminimalkan kerugian
2. Informasi tentang bahan baku dapat digunakan untuk kualitas dan kontrol proses yang lebih baik
3. Menghindari pengulangan pengukuran yang tidak perlu dalam dua atau lebih langkah berurutan
4. Meningkatkan insentif untuk menjaga kualitas bahan baku yang melekat
5. Memungkinkan pemasaran bahan baku atau fitur produk khusus
6. Memenuhi persyaratan pemerintah saat ini dan masa depan (misalnya, mengonfirmasi negara asal)

Selain pendorong di atas, kemungkinan untuk meningkatkan dukungan keputusan (baik secara internal maupun dalam kaitannya dengan pemasok dan pelanggan) dengan sendirinya dapat dilihat sebagai pendorong untuk berinvestasi dalam sistem ketertelusuran. Penggerak di atas umum untuk industri produksi secara umum, dan setiap perusahaan memutuskan seberapa penting ketertelusuran bagi mereka, dan tingkat ambisi serta tingkat akurasi dan perincian apa yang mereka inginkan untuk data dalam sistem ketertelusuran mereka.

Sehubungan dengan ketertelusuran, industri makanan adalah kasus khusus di mana persyaratan dan penggerak khusus berlaku. Aspek keamanan pangan adalah alasan utama untuk ini, tetapi ada juga beberapa alasan lain mengapa lebih banyak pencatatan dan dokumentasi produk yang lebih baik diperlukan dalam industri makanan. Yang paling penting dapat diringkas sebagai berikut:

1. Memiliki sistem untuk penelusuran ke belakang (hulu, menuju asal) jika sumber kontaminasi perlu diidentifikasi
2. Memiliki sistem untuk pelacakan ke depan (hilir, menuju konsumen) jika ada kontaminasi dan penarikan yang ditargetkan perlu dilakukan
3. Dokumentasi dan ketertelusuran produk makanan sebagai bagian dari sistem Analisis Bahaya dan Titik Kendali Kritis (HACCP) wajib
4. Memenuhi persyaratan hukum yang berkaitan dengan dokumentasi produk makanan dan ketertelusuran dalam produksi
5. Memenuhi persyaratan hukum yang berkaitan dengan dokumentasi produk makanan dan ketertelusuran saat mengekspor makanan
6. Memenuhi persyaratan komersial yang berkaitan dengan dokumentasi dan ketertelusuran produk makanan
7. Mendokumentasikan sifat produk pangan yang berkaitan dengan pemanfaatan sumber daya, keberlanjutan, etika dan lingkungan, khususnya terkait dengan berbagai

jenis ekolabel. Contohnya antara lain Fair Trade, Max Havelaar, Green Point, Free Range, Svanen, Marine Stewardship Council, namun ada juga puluhan label nasional dan internasional lainnya berbagai jenis.

Poin terakhir mencerminkan keprihatinan yang berkembang bagi konsumen dan juga untuk industri produksi makanan. Selain skema pelabelan yang disebutkan di atas, berbagai perusahaan besar telah melaporkan rencana untuk mendokumentasikan penggunaan sumber daya dan beban lingkungan secara lebih eksplisit untuk beberapa produk makanan. Ini termasuk menempatkan informasi tentang jarak yang ditempuh (mil makanan), CO<sub>2</sub> terkait atau emisi gas rumah kaca, penggunaan air atau sumber daya lainnya, dll. langsung pada label produk makanan. Selain itu, ada minat yang meningkat serta meningkatnya persyaratan legislatif dan komersial yang berkaitan dengan dokumentasi asal-usul yang berkelanjutan. Untuk produk ikan khususnya illegal, unreported and un-regulated (IUU) fishing merupakan masalah utama, dan tekanan untuk merekam data, mendokumentasikan produk dan memiliki sistem ketertelusuran yang baik telah meningkat secara signifikan di industri perikanan.

Karena industri makanan memiliki semua pendorong ekstra untuk ketertelusuran ini, ini berarti bahwa secara umum lebih banyak data, dan data yang lebih akurat dan terperinci akan tersedia dalam sistem ketertelusuran untuk produk makanan daripada untuk produk non-makanan yang sebanding, dan keputusan yang lebih baik dapat dibuat.

### **Pemodelan Termal untuk Pendukung Keputusan dalam Rantai Dingin**

Kontrol yang tepat dari suhu produk di seluruh rantai pendinginan sangat penting untuk meminimalkan biaya dan memaksimalkan kualitas produk dan dengan demikian nilai produk. Tahap paling mungkin dari rantai dingin, di mana penyalahgunaan suhu yang berbahaya dialami, adalah berbagai antarmuka antara moda transportasi yang berbeda. Ini termasuk misalnya operasi pemuatan, pembongkaran dan pengiriman, bahkan penyimpanan sementara, yang dengan mudah dapat menyebabkan beberapa penundaan. Beban termal dari lingkungan kemasan, produk yang mudah rusak pasti menyebabkan perpindahan panas dari suasana ke produk dan dengan demikian suhu meningkat pada produk. Seberapa serius beban termal mempengaruhi produk yang dikemas terutama ditentukan oleh konfigurasi dan sifat termal dari kemasan dan produk serta kondisi sekitar (suhu udara, kecepatan udara dan bahkan kelembaban). Beberapa penyelidikan telah dilaporkan dalam literatur terbuka pada aspek yang berbeda dari rantai makanan beku yang berfokus pada kenaikan suhu sebagai fungsi dari sifat produk [4] kondisi lingkungan [5], ukuran dan jenis kemasan kehadiran dan ketebalan lapisan udara antara produk dan kemasan [35] dan terakhir, penggunaan penutup palet isolasi [30]. Studi-studi ini mengungkapkan variasi suhu yang besar bahkan setelah paparan singkat terhadap kondisi sekitar. Efek termasuk tikar pendingin beku di dalam kotak ikan segar juga telah dipelajari [19,21].

Eksperimen mengungkapkan bahwa menggunakan alas pendingin dalam kotak ikan adalah cara yang efektif untuk melindungi fillet ikan segar dari penyalahgunaan suhu. Studi yang sama menunjukkan bahwa kinerja isolasi kotak polystyrene (EPS) yang diperluas secara signifikan lebih baik daripada kotak plastik bergelombang (CP), terlepas dari penggunaan alas pendingin. Perbedaan dalam kinerja insulasi antara dua jenis kemasan sebenarnya lebih besar ketika alas pendingin digunakan. Hubungan antara pilihan pengemasan dan penggunaan alas pendingin muncul dalam hasil bahwa penyalahgunaan suhu menyebabkan peningkatan suhu

yang sama pada fillet segar yang disimpan dalam kotak EPS tanpa alas pendingin seperti pada fillet segar yang disimpan dalam kotak CP dengan alas pendingin. Studi yang sama menunjukkan bahwa dalam kondisi suhu dinamis, distribusi suhu di seluruh palet fillet ikan bisa jauh dari homogen. Perbedaan suhu produk dapat dengan mudah melebihi 6-8°C tergantung pada urutan besarnya fluktuasi suhu dan durasinya. Tetapi merencanakan dan melakukan eksperimen, seperti yang disebutkan di atas, memakan waktu dan mahal karena biaya bahan baku, biaya tenaga kerja, dll. Dalam konteks ini, pemodelan numerik telah terbukti menjadi alat yang berguna dan hemat biaya untuk memprediksi produk suhu dalam kondisi suhu dinamis [25,26].

Parameter yang terkait dengan kemasan, yang dapat dipertimbangkan dalam model termal numerik untuk produk kemasan, misalnya. bahan yang digunakan dalam pengemasan, metode pengemasan produk dingin/beku di dalam kemasan konsumen, bagaimana kemasan konsumen dikemas dalam karton induk dan terakhir, bagaimana karton induk dikemas dalam palet. Semua parameter ini dapat sangat mempengaruhi kinerja termal kemasan. Analisis numerik juga dapat membantu menentukan posisi optimal untuk menempatkan termometer serta memiliki gagasan tentang distribusi suhu di palet dari pembacaan suhu di beberapa titik. Sistem pemantauan suhu dalam rantai dingin biasanya ditujukan untuk mengukur dan memantau suhu udara sekitar dalam rantai. Parameter utama untuk menentukan masa simpan produk yang mudah rusak dan didinginkan adalah suhu produk - bukan suhu udara sekitar. Jadi, kebutuhan yang jelas adalah untuk menggabungkan riwayat waktu suhu udara ambien ke suhu produk. Inilah yang dapat diberikan oleh model termal numerik untuk produk kemasan. Model termal dengan demikian dapat memberikan masukan suhu produk ke model pertumbuhan mikroba dari riwayat suhu-waktu sekitar dan dengan demikian digunakan untuk tujuan penilaian risiko dalam rantai dingin. Pengaruh beban panas ambien pada suhu produk yang dikemas bukan satu-satunya bidang di mana model termal numerik berguna untuk membuat keputusan dan mengoptimalkan rantai pendingin. Evolusi yang cepat dalam industri komputer sejak dekade kesembilan abad terakhir telah memungkinkan kode CFD komersial (Computational Fluid Dynamics) digunakan untuk secara efektif meningkatkan kontrol suhu di truk berpendingin [1,27] dan toko dingin [20,28,7,11]. Penyelidikan numerik ini telah membuktikan potensi CFD dalam meningkatkan desain bangunan untuk mendinginkan dan menyimpan bahan makanan.

### **Memilih Bahan Baku yang Tepat**

Masalah memilih bahan baku yang tepat selalu menjadi tugas penting bagi semua produsen makanan. Untuk produsen makanan laut Islandia, situasinya tidak berbeda, memilih lokasi penangkapan yang tepat adalah yang paling penting. Sigvaldason dkk. [31] mungkin yang pertama menggunakan riset operasi (OR) di perikanan Islandia untuk memilih lokasi penangkapan. Contoh lain dari studi OR di perikanan Islandia adalah Jensson [14], yang memperkenalkan model simulasi untuk menganalisis operasi armada. Fokusnya antara lain pada pengaruh operasi armada terhadap total tangkapan, pada pemanfaatan pabrik yang berbeda dan pada kategori ukuran kapal yang berbeda. Jensson [15] juga harus disebutkan, di mana fokusnya adalah pada penjadwalan harian dalam pengolahan ikan. Millar dan Gunn [23] menyajikan model simulasi yang berbeda, dengan tujuan untuk menilai dampak variabilitas tingkat tangkapan pada kinerja biaya armada penangkapan ikan yang terkoordinasi. Mereka

menyimpulkan bahwa model seperti itu berguna untuk pengambilan keputusan di industri. Randhawa dan Bjarnason [29] melihat pendaratan tangkapan sambil memperhitungkan persediaan bahan baku di pabrik pengolahan. Sebuah model terbaru, yang dikembangkan oleh Hasan dan Raffensberger [9] ditujukan untuk mengkoordinasikan penjadwalan kapal pukat, penangkapan ikan, pengolahan dan alokasi tenaga kerja dari perikanan terpadu. Hasil dari model tersebut dapat digunakan untuk membantu pengambil keputusan di mana penangkapan harus dilakukan, berapa banyak yang akan ditangkap, jenis produk apa yang harus diproduksi dan alokasi tenaga kerja juga.

Banyak faktor yang berbeda mempengaruhi profitabilitas rantai nilai makanan laut. Untuk beberapa nama, faktor biaya berikut dianggap perlu untuk membangun model optimasi untuk industri ikan pada tahun 1969 [31].

1. Gaji awak kapal dan karyawan pengolahan berbasis darat.
2. Biaya alat tangkap.
3. Biaya sistem pendingin/biaya es di kapal.
4. Biaya perawatan, kapal dan pengolahan berbasis darat.
5. Biaya asuransi.
6. Biaya pendaratan.
7. Biaya makanan untuk kru.
8. Biaya kantor dan biaya tetap lainnya untuk menjalankan perusahaan.
9. Biaya keuangan.

### **Model Optimasi, Teori dan Hasil Praktis**

Untuk memecahkan masalah pemilihan lokasi yang tepat, waktu dan lebih untuk akuisisi bahan baku, model optimasi linier telah diusulkan dan digunakan [19,8]. Model yang diusulkan adalah kombinasi dari masalah penugasan dan masalah produksi, di mana tujuannya adalah untuk menetapkan kapal ke daerah penangkapan ikan dan untuk menentukan alokasi tangkapan yang diharapkan untuk memaksimalkan keuntungan total perusahaan perikanan. Solusi dari model tersebut sebenarnya adalah rencana terperinci untuk penangkapan ikan dan pemrosesan untuk periode perencanaan tertentu, seringkali satu tahun, di mana kendala peraturan penangkapan ikan, seperti kuota, dan pembatasan personel dipertimbangkan. Rencana ini kemudian dapat digunakan sebagai saran untuk rencana yang sebenarnya atau sebagai sumber inspirasi bagi para perencana. Gambar 2 mengilustrasikan hubungan dan rantai sebab akibat untuk model tersebut. Indeks yang digunakan dalam model adalah sebagai berikut:

Untuk memecahkan masalah pemilihan lokasi yang tepat, waktu dan lebih untuk akuisisi bahan baku, model optimasi linier telah diusulkan dan digunakan [19,8]. Model optimasi yang diusulkan dapat digambarkan sebagai model aliran multi-komoditas, di mana sifat-sifat material yang mengalir melalui jaringan yang diusulkan bergantung pada cara bahan mentah mengalir melaluiinya. Ini karena sifat ikan berubah saat mengalir melalui jaringan, diilustrasikan pada Gambar 2. Indeks yang digunakan dalam model adalah sebagai berikut:

- v : Daerah penangkapan ikan.
- s : Identitas kapal.
- h : Identitas pelabuhan.

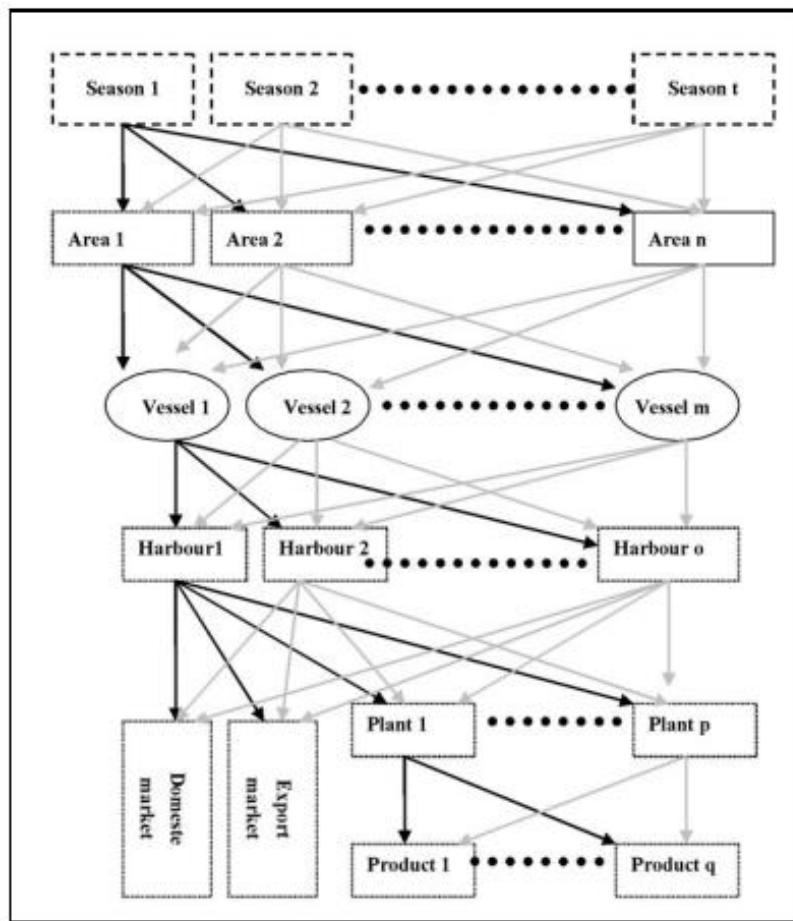
- r : Distribusi bahan baku, mis. pasar domestik, pasar luar negeri atau pabrik sendiri.
- a : Jenis produk.
- t : Musim.
- f : Kategori bahan baku. Setiap spesies dapat dibagi ke dalam kategori yang berbeda, mis. berdasarkan grading.
- g : Jenis ikan. Cod, haddock, redfish, dll.

Variabel keputusan (variabel yang dapat dikontrol model untuk menemukan solusi terbaik) adalah:

- $Y_{vshf}$  : Jumlah jenis ikan f yang ditangkap oleh kapal s di daerah penangkapan v selama musim t dan didaratkan di pelabuhan h.
- $Z_{vshrf}$  : Jumlah jenis ikan f yang ditangkap oleh kapal s di daerah penangkapan v selama musim t, didaratkan di pelabuhan h dan dijual di saluran distribusi r.
- $Q_{vshratf}$  : Jumlah jenis ikan f yang ditangkap oleh kapal s di daerah penangkapan v selama musim t, didaratkan di pelabuhan h, dijual di saluran distribusi r dan diolah menjadi produk a.
- $U_{af}$  : Jumlah produk a dari jenis ikan f .
- $T_{inf}$  : Jumlah kuota yang ditransfer ke spesies ikan f .
- $T_{outf}$  : Jumlah kuota yang ditransfer dari spesies ikan f .
- $W_{inf}$  : Kuantitas kuota yang disewakan kepada perusahaan spesies f .
- $W_{outf}$  : Kuantitas kuota yang disewa dari perusahaan spesies f .
- $D_{vsth}$  : Hari yang digunakan kapal s di daerah penangkapan v pada musim t, berlayar dari pelabuhan h.
- $DT_{rt}$  : Jam siang hari yang digunakan di pabrik pengolahan sendiri (r) pada musim t.
- $OT_{rt}$  : Jam lembur yang digunakan di pabrik pengolahan sendiri (r) pada musim t.

Tujuan dari model yang diusulkan adalah untuk memaksimalkan keuntungan total dari rantai nilai dari penangkapan hingga pemrosesan:

$$\text{Laba} = \text{Pendapatan penangkapan ikan} - \text{Biaya penangkapan ikan} + \text{Pendapatan pemrosesan} - \text{Biaya pemrosesan}$$



**Gambar 12.2** Jaringan untuk satu musim yang menunjukkan arus tangkapan ikan melalui rantai nilai perusahaan perikanan

Pendapatan perikanan berasal dari penjualan hasil tangkapan dan sewa kuota dari perusahaan. Biaya penangkapan adalah biaya penangkapan, pendaratan dan pemasaran, jika dipasarkan sebagai ikan utuh. Pendapatan pemrosesan adalah pendapatan dari pabrik pemrosesan dan biaya pemrosesan adalah biaya pemrosesan. Model ini tunduk pada sejumlah kendala, seperti kuota dan ketersediaan tenaga kerja. Kendala, parameter model dan presentasi matematis dibahas secara rinci dalam Margeirsson et al.[19] dan Gudmundsson dkk. [8].

Model ini membutuhkan empat kategori data yang berbeda:

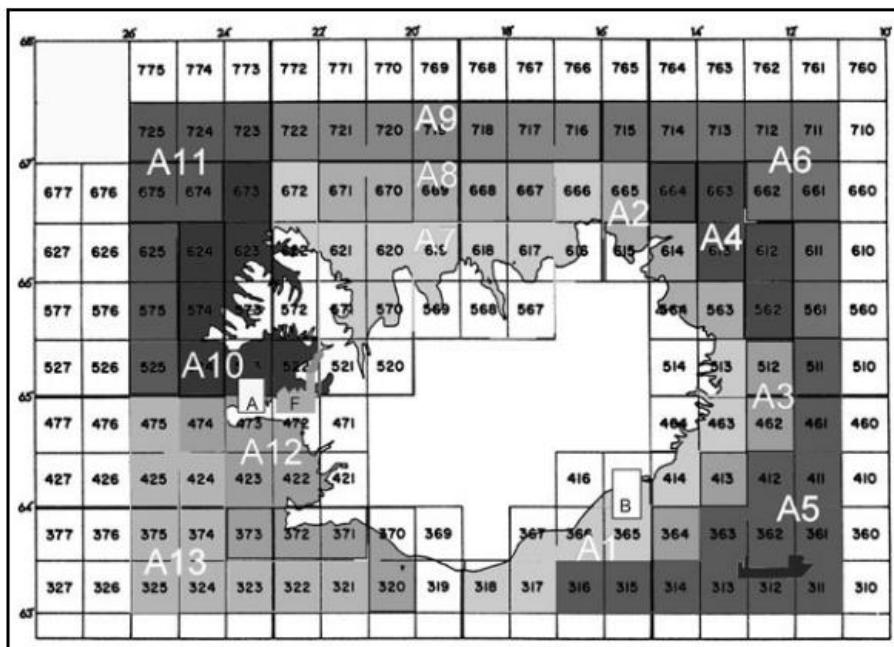
1. Data tentang daerah penangkapan ikan; volume tangkapan, komposisi spesies, jarak berlayar. Tersedia melalui buku log elektronik (lihat misalnya [www.seadata.is](http://www.seadata.is)).
2. Data hasil tangkapan; sifat-sifat tangkapan sehubungan dengan pemrosesan. Tersedia melalui pengukuran dari kontrol kualitas.
3. Data biaya operasional termasuk penangkapan ikan, transportasi dan pengolahan. Tersedia dari sebagian besar sistem informasi yang digunakan di perusahaan (lihat misalnya [www.wisefish.com](http://www.wisefish.com)).
4. Data pasar; permintaan dan harga makanan laut (sebagai bahan baku) dan produk makanan laut.

Untuk memastikan bahwa model dapat dipecahkan, semua kendala dan fungsi tujuan adalah linier. Masalah optimasi linier, seperti masalah yang ditunjukkan pada Tabel 2.3, biasanya diselesaikan dalam waktu yang cukup singkat, mengingat ukurannya tidak terlalu besar. Saat memecahkan model, daerah penangkapan Islandia dibagi menjadi 13 sub-area (A1-A13, lihat Gambar 3) dan tahun dibagi menjadi kuartal. Data volume tangkapan dan komposisi spesies (proporsi relatif dari spesies yang paling penting) di setiap daerah diperkirakan, bekerja sama dengan manajer penangkapan salah satu perusahaan makanan laut yang lebih besar di Islandia (GR: Gudmundur Runo'lfsson hf). Untuk menyederhanakan, hanya dua pelabuhan yang digunakan untuk pendaratan dan modelnya didasarkan pada perusahaan dengan satu lokasi untuk pemrosesan. Jarak berlayar dari dua pelabuhan (lihat Gambar 3) ke 13 daerah diberi peringkat (jarak berlayar dari setiap pelabuhan ke daerah tertentu diperkirakan 1, 1,5 atau 2, tergantung pada jarak antara daerah dan pelabuhan). Akses diberikan ke sistem akuntansi GR, di mana data tentang biaya operasi termasuk penangkapan ikan, transportasi dan pengolahan diperoleh. Data pasar juga diperoleh dari GR.

**Tabel 12.1** Bentuk umum model program linier.  $x_i$  adalah variabel keputusan model,  $c_i$  adalah koefisien biaya sedangkan  $a_{ij}$  dan  $b_j$  adalah parameter data.

Maksimalkan	$c_1x_1 + c_2x_2 + \dots + c_nx_n,$	(fungsi objektif)
Tunduk pada	$a_{11}x_1 + a_{12}x_1 + \dots + a_{1n}x_n \leq b_1$	(kendala 1)
	$a_{21}x_1 + a_{22}x_1 + \dots + a_{2n}x_n \leq b_2,$	(kendala 2)
<hr/>		
$a_{m1}x_1 + a_{m2}x_1 + \dots + a_{mn}x_n \leq b_m, x_1, \dots, x_n \geq 0$ (kendala m)		
<hr/>		

Kami mengacu pada Margeirsson et al.[19] dan Gudmundsson dkk. [8] mengenai hasil dari model. Hasil utama menunjukkan bahwa dengan menggabungkan upaya perusahaan industri di industri perikanan dengan keterampilan ilmiah dan manajemen dari komunitas penelitian dan universitas, pengetahuan tentang sifat-sifat tangkapan dapat ditingkatkan secara substansial dan OR dapat digunakan untuk membantu pengambilan keputusan dalam rantai nilai ikan kod, di mana faktor-faktor seperti tempat penangkapan, musim penangkapan, harga minyak, sewa kuota dan pengelolaan pengolahan berbasis lahan adalah beberapa faktor yang harus dipertimbangkan.



**Gambar 12.3** Pembagian perairan Islandia menjadi 13 wilayah yang berbeda (A1-A13).

Gambar juga menunjukkan lokasi dua pelabuhan, A dan B dan pabrik pengolahan ikan F. Pelabuhan A dan B adalah pelabuhan tempat kapal pukat perusahaan dalam skenario dapat mendarat. Pabrik pengolahan ikan F dimiliki oleh perusahaan.

### 12.3 SISTEM PENDUKUNG KEPUTUSAN DALAM RANTAI PASOKAN DAGING

Dalam industri makanan modern serta sebagian besar industri modern lainnya, ada tekanan umum dan konstan untuk meningkatkan tingkat layanan dan mengeluarkan inventaris dari rantai pasokan sejauh mungkin. Pada saat yang sama ada tekanan untuk mencapai throughput yang lebih tinggi dalam jangka waktu yang lebih pendek dan mengurangi biaya produksi. Selain meningkatnya persaingan, industri makanan menghadapi tantangan yang berkembang dari meningkatnya kompleksitas operasional, peraturan pemerintah yang baru, dan konsolidasi di dalam industri. Sistem pendukung keputusan baru-baru ini membuktikan diri sebagai alat yang membantu dan menjadi penting untuk tetap kompetitif di sebagian besar sektor industri makanan.

Produksi dan pengolahan daging merupakan bagian yang menantang dari industri makanan. Beberapa tantangan terbesar adalah untuk menjaga ketertelusuran, memprediksi permintaan pelanggan dan barang-barang yang mudah rusak dan produk tanggal memerlukan penanganan dan perhatian khusus. Daging pada umumnya merupakan bahan mentah yang mahal dan masa pakai bahan mentah dan produk daging segar seringkali dibatasi hingga 1-2 minggu. Telah diketahui dengan baik dalam industri daging bahwa terdapat pemborosan bahan mentah dan produk yang cukup besar di berbagai lokasi dalam rantai pasokan daging. Tujuan dari proyek yang tercakup dalam studi kasus ini adalah untuk meningkatkan efisiensi dan mengurangi limbah di seluruh rantai pasokan makanan. Studi kasus mencakup dua produsen daging yang relatif besar dan juga pengecer yang relatif besar dengan karena bahan baku yang mahal, ada potensi besar untuk meningkatkan keuntungan dengan mengurangi limbah dan sebagai hasilnya proyek ini sangat penting bagi manufaktur maupun pengecer. .

#### Penyebab Pemborosan = Kebutuhan DSS

Bagian pertama dari proyek ini mencakup analisis rinci rantai pasokan makanan dengan tujuan mengidentifikasi penyebab utama pemborosan bahan mentah dan produk akhir. Kami membagi rantai pasokan menjadi tautan dan setiap tautan dianalisis sehubungan dengan proses yang memengaruhi biaya dan harga serta faktor-faktor yang mendorong pemborosan. Hasil penelitian menunjukkan bahwa sumber utama sampah adalah:

1. Produksi berlebihan dan tingkat persediaan produk yang mudah rusak
2. Penanganan produk dan bahan baku yang tidak tepat
3. Masalah dengan logistik

Masalah dengan logistik terutama disebabkan oleh pendinginan atau pembekuan produk yang tidak memadai selama transportasi. Kami menanggapi masalah tersebut dan penanganan produk dan bahan mentah yang tidak tepat dengan mendefinisikan ulang proses kerja dan meningkatkan pelatihan karyawan. Tingkat produksi dan persediaan yang berlebihan atau salah diidentifikasi sebagai sumber pemborosan terbesar dan fokus proyek sebagai hasilnya adalah meningkatkan kinerja produksi dan manajemen persediaan. Manajemen persediaan dan produksi tentunya juga penting untuk menghindari kekurangan produk di toko yang dapat menurunkan kepuasan pelanggan secara nyata dan mempengaruhi baik pengecer maupun produsen.

Metode perencanaan kolaboratif yang digunakan bersama dengan metode peramalan lanjutan umumnya diketahui dapat membantu dalam mengurangi tingkat persediaan dan meningkatkan efisiensi dalam rantai pasokan [33]. Teori dapat dianggap sebagai mapan dan terdapat berbagai penelitian yang melaporkan implementasi yang berhasil [34]. Secara umum diterima bahwa kolaborasi perusahaan yang berbeda dalam rantai pasokan makanan juga dapat menjadi metode yang efektif untuk mengurangi biaya [22]. Kolaborasi juga merupakan metode yang efektif untuk mengurangi limbah ketika produk yang mudah rusak terlibat seperti dalam rantai pasokan makanan. Analisis kami menunjukkan bahwa perusahaan dalam rantai pasokan, terutama produsen dan pengecer tidak berbagi informasi atau berkolaborasi dengan cara lain dengan tujuan bersama untuk meningkatkan pengelolaan seluruh rantai pasokan. Salah satu alasan utama yang kami temukan adalah kurangnya kepercayaan tetapi juga kurangnya prosedur dan alat sederhana untuk mendukung kolaborasi. Studi lain juga mengidentifikasi kurangnya kepercayaan sebagai penghalang utama untuk meningkatkan kolaborasi dalam rantai pasokan berbagai produk [6,10,12,16].

Studi-studi ini juga melaporkan masalah lain berdasarkan pengalaman dari berbagai proyek eksperimental. Kesimpulan umum adalah bahwa ada keuntungan potensial yang cukup besar tetapi terlalu sering gagal untuk mempertahankan kolaborasi setelah durasi eksperimen dan mempertahankan kolaborasi sebagai bagian dari proses sehari-hari di perusahaan. Kami yakin ini terutama karena kurangnya prosedur sederhana dan alat yang efisien serta sistem pendukung keputusan untuk mendukung kolaborasi. Sm'aros [32] melaporkan beberapa hambatan untuk peningkatan kolaborasi dan antara lain keterbatasan kemampuan pengecer untuk membuat perkiraan penjualan yang akurat, kebutuhan yang berbeda dari pengecer dan pemasok untuk perkiraan penjualan, dan akhirnya kurangnya menggabungkan informasi harian dengan produksi jangka panjang. rencana. Sistem pendukung keputusan yang efektif pasti bisa sangat membantu menghilangkan hambatan ini.

Sebagian besar perusahaan menjalankan sistem sistem perencanaan sumber daya perusahaan (ERP) untuk melacak produksi, inventaris, dan penjualan. Sistem ERP menyimpan database besar yang berisi berbagai data bisnis tetapi data tersebut biasanya tidak digunakan dengan baik untuk meningkatkan pengambilan keputusan. Pengalaman dan pengetahuan yang luas seringkali tersembunyi dalam database dan seringkali memungkinkan untuk meningkatkan keputusan dengan menggunakan data yang dikombinasikan dengan sistem pendukung keputusan yang efektif. Itulah tepatnya yang kami lakukan dalam studi kami tentang rantai pasokan daging untuk mengurangi limbah dan meningkatkan efisiensi. Untuk memulainya, kami berfokus pada tautan individu dari rantai pasokan dan mengembangkan sistem pendukung keputusan untuk produsen (dan pemasok) dan pengecer yang digunakan secara independen tetapi langkah selanjutnya adalah mengembangkan metode untuk perencanaan kolaboratif. Logika sistem untuk produsen/pemasok dan pengecer sangat mirip. Berikut ini kami akan menjelaskan pekerjaan kami pada sistem pendukung keputusan untuk setiap tautan, yaitu produsen dan pengecer, dan akhirnya untuk kolaborasi antara tautan.

### **Pendukung Keputusan untuk Produsen Makanan**

Tahap analisis proyek dengan jelas menunjukkan bahwa produsen produk daging mengalami masalah dalam memperkirakan permintaan produk akhir dan merencanakan produksi dengan baik sesuai dengan permintaan. Akibatnya, para produsen mengalami masalah dengan kelebihan dan kekurangan. Overstocking sangat buruk karena umur simpan yang pendek dari sebagian besar produk daging. Selain itu, para produsen juga mengalami masalah dengan persediaan berbagai bahan dan komponen yang diperlukan untuk produksi mereka yang mengurangi waktu respons mereka sendiri terhadap perubahan permintaan yang tidak terduga. Tingkat teknologi informasi dalam industri pengolahan daging telah meningkat selama setahun terakhir. Semua perusahaan besar telah menerapkan sistem ERP tetapi sistem pendukung keputusan tingkat lanjut masih jarang dan manajer sebagian besar bekerja dengan data dan melakukan perhitungan buatan sendiri dengan perangkat lunak spreadsheet.

Untuk memberikan dukungan keputusan bagi produsen yang terlibat dalam proyek kami, kami telah mengembangkan sistem pendukung keputusan berdasarkan solusi AGR Inventory Optimiser (AIO) yang sudah ada yang awalnya dikembangkan untuk pengecer. AIO adalah sistem pendukung keputusan perencanaan dan pengoptimalan persediaan yang bertujuan untuk meminimalkan biaya dan kekurangan persediaan. Kepala perencanaan produksi di pabrik membuat jadwal produksi untuk setiap minggu dan memperbarui jadwal lebih sering jika diperlukan oleh produk dengan frekuensi produksi yang sangat tinggi atau jika beberapa asumsi berubah. Manajer masing-masing lini produksi kemudian menggunakan rencana produksi sebagai daftar peringkat tugas yang harus mereka selesaikan. Gambar 4 menunjukkan screenshot dari antarmuka pengguna.

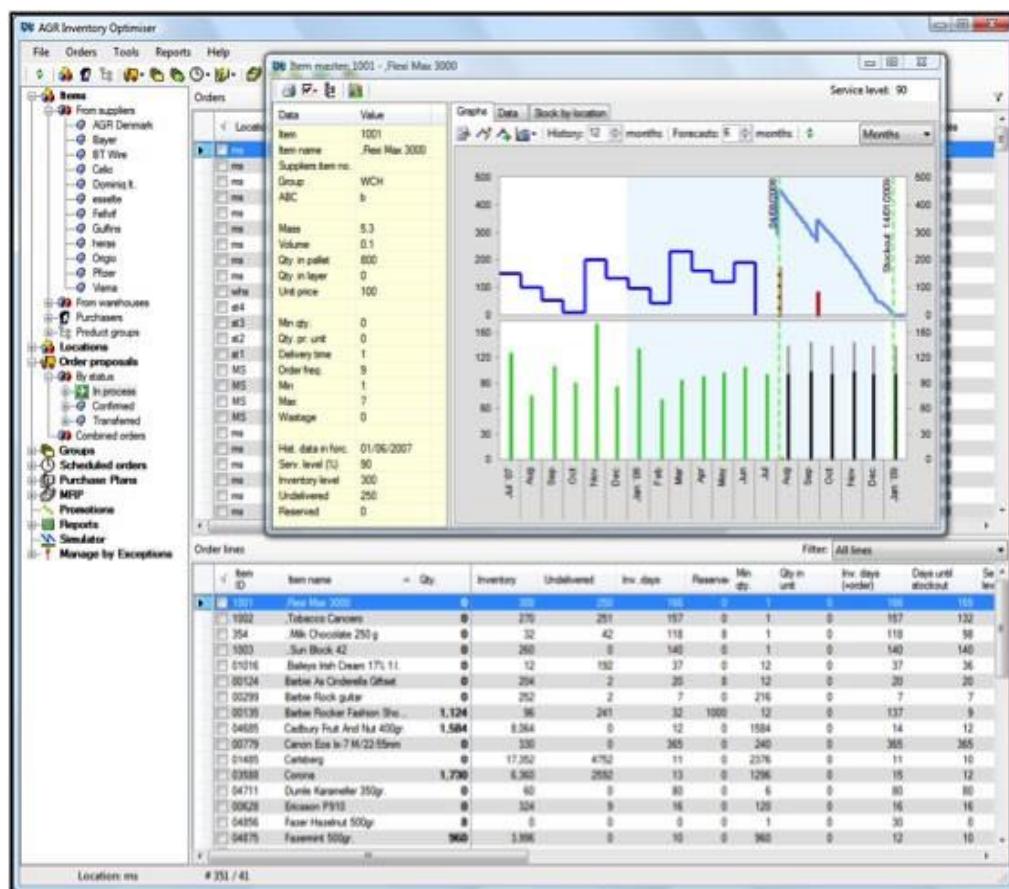
Sebagai masukan untuk peramalan permintaan kami menggunakan informasi penjualan tentang setiap nomor produk. Kami menggunakan data historis dari sistem ERP yang ada dan sistem pakar secara otomatis memilih metode peramalan yang paling sesuai. Ia memilih di antara kelas model peramalan berikut: metode sederhana, pemasangan kurva, model volume rendah, pemulusan eksponensial, dan Box-Jenkins. Sistem memastikan bahwa metode peramalan yang paling relevan dipilih untuk item tergantung pada sifat produk dan

jumlah data historis yang tersedia. Berdasarkan perkiraan dan informasi tentang tingkat persediaan saat ini, sistem menghitung jumlah produksi di mana:

$$\text{Jumlah produksi} = \text{TSL} - \text{stok saat ini} - \text{produksi sedang berlangsung}$$

di mana:

$$\text{TSL (Target stock level)} = (\text{permintaan yang diharapkan pada waktu pengiriman} + \text{frekuensi produksi}) + \text{safety stock}$$



**Gambar 12.4.** Gambar menunjukkan antarmuka pengguna untuk meninjau proposal produksi

Dan

$$\text{safety stock} = Z \times S \times \sqrt{\text{delivery time} + \text{production frequency}}$$

Z = parameter tingkat layanan (misalnya 95% = 1,65).

S = standar deviasi permintaan.

Tujuan dari perhitungan ini adalah untuk meminimalkan tingkat persediaan pada saat yang sama dengan memenuhi tingkat layanan yang telah ditentukan sebelumnya. Jumlah produksi diperbarui secara dinamis secara otomatis ketika tingkat persediaan atau

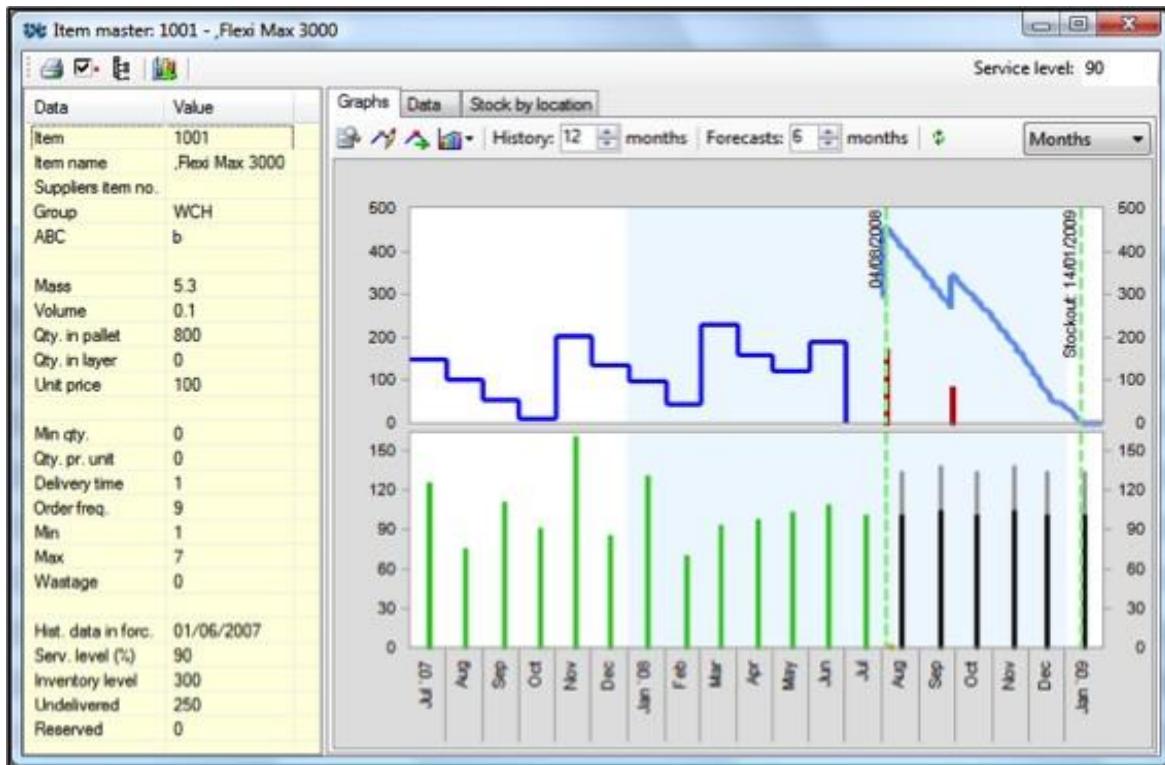
permintaan berubah. Produk dengan penjualan tertinggi dan umur simpan terpendek diproduksi tiga kali per minggu. Frekuensi produksi yang begitu tinggi membutuhkan perkiraan penjualan yang akurat yang memprediksi penjualan harian. Sangat menantang untuk membuat perkiraan yang masuk akal untuk penjualan harian produk konsumen berdasarkan pengiriman dari produsen dan kami memiliki masalah dengan membuatnya cukup akurat. Prakiraan untuk produk dengan frekuensi produksi yang rendah dan sering kali umur simpan yang lama di sisi lain jauh lebih akurat dan lebih mudah dibuat. Ini adalah masalah yang akan sering ditemukan dalam industri makanan untuk produk dengan waktu simpan yang singkat.

Seperti disebutkan sebelumnya, sistem membuat proposal otomatis dari rencana produksi untuk setiap minggu berdasarkan tingkat persediaan saat ini dan perkiraan permintaan. Sistem ini juga memperhitungkan umur simpan produk dan tanggal produksi persediaan yang ada. Sistem ini menyediakan antarmuka yang mudah digunakan bagi manajer produksi untuk meninjau proposal produksi dan menggunakan keahliannya untuk meningkatkan hasil. Sangat penting untuk dicatat bahwa hasil terbaik dapat diperoleh dengan menggabungkan otomatisasi sistem berbasis optimasi dengan keahlian manajer produksi tingkat lanjut.

Produsen juga menggunakan sistem tersebut untuk membuat rencana pembelian bahan atau komponen yang perlu digunakan untuk produksi. Sistem ini menggunakan Bill-of-materials (BOM) untuk menentukan bagaimana item akhir dibangun dari berbagai komponen dan menggunakan perhitungan perencanaan kebutuhan material (MRP) untuk menentukan jumlah yang dibutuhkan setiap komponen untuk item akhir, berdasarkan rencana produksi dan tagihan bahan untuk item akhir. Perhitungan MRP juga memperhitungkan tanggal komponen dibutuhkan berdasarkan rencana produksi untuk produk akhir.

#### **Pendukung Keputusan untuk Pengecer - Manajemen Inventaris dan Pengisian Ulang**

Dengan menganalisis operasi pengecer kami menemukan masalah manajemen persediaan yang sama seperti yang ditemukan di perusahaan produksi. Pengecer jelas mengalami masalah dengan memperkirakan permintaan sebagai akibatnya mereka mengalami masalah dengan kelebihan dan kekurangan. Penimbunan yang berlebihan sangat buruk karena umur simpan yang pendek dari sebagian besar produk daging dan di toko-toko kita dapat melihat terlalu banyak produk yang kadaluwarsa dan rusak. Oleh karena itu, solusi awal kami adalah menerapkan sistem pendukung keputusan yang serupa seperti yang kami terapkan untuk produsen. Perbedaan utama adalah bahwa toko menggunakan sistem pendukung keputusan untuk membuat pesanan dari pemasok sementara produsen menggunakan sistem untuk membuat rencana produksi meskipun logika yang mendasarinya sangat mirip. Seperti sebelumnya, sistem menyediakan estimasi permintaan otomatis dan penghitungan otomatis proposal pembelian yang ditinjau dan dikonfirmasi oleh manajer pembelian.



**Gambar 12.5** Gambar menunjukkan master item dengan detail produk dan presentasi grafis dari data historis dan perkiraan masa depan. Manajer pembelian di toko dapat melihat perkembangan inventaris historis, angka penjualan historis, prakiraan masa depan, pesanan produksi yang tidak terkirim, dan tingkat inventaris yang diproyeksikan.

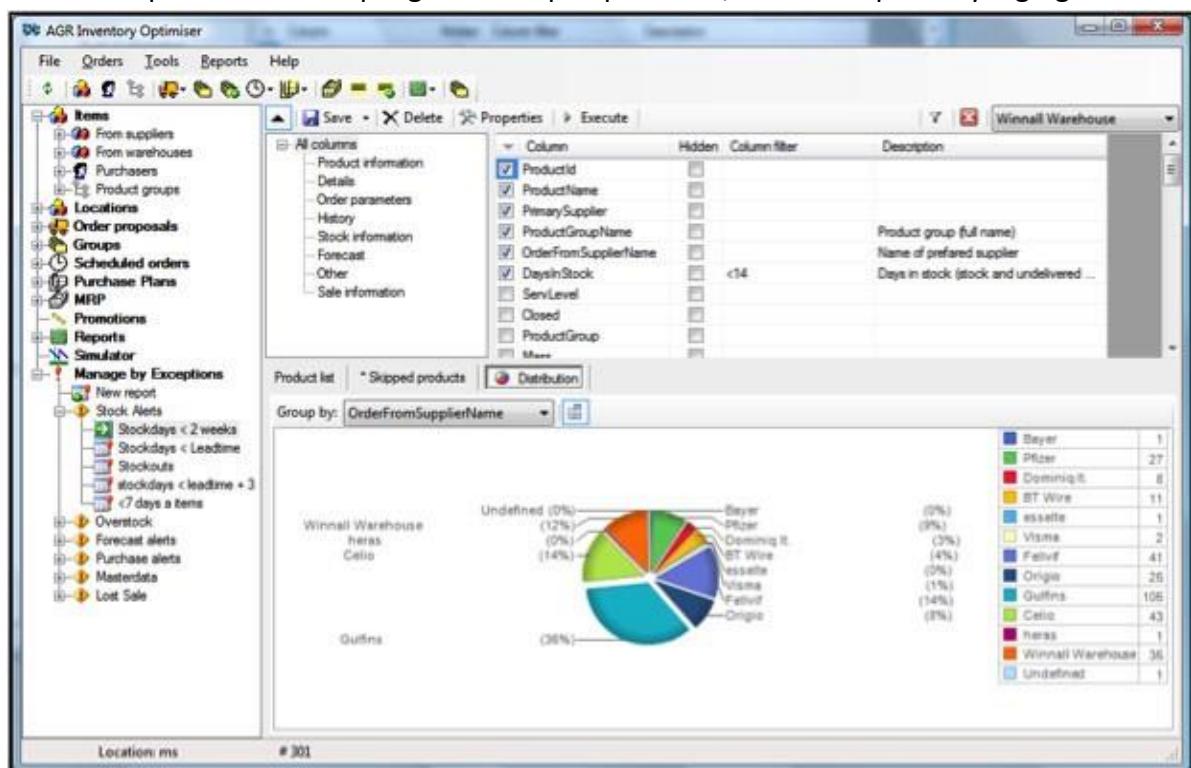
Implementasi sistem harus lebih mudah jika semua data tersedia. Namun kami mengalami masalah besar dalam mengakses data yang diperlukan dari sistem ERP yang dimiliki toko. Di antara data yang diperlukan adalah tingkat persediaan real-time produk di toko-toko. Karena kami bekerja dengan produk yang mudah rusak dengan masa simpan yang sangat singkat, kami juga memerlukan distribusi usia inventaris setiap produk agar dapat memperkirakan sisa masa pakai inventaris. Ini tidak mungkin terjadi dalam kasus kami. Sebagian besar sistem ERP yang saat ini digunakan tidak diatur untuk menyimpan tingkat inventaris waktu nyata dengan atau tanpa distribusi usia stok. Versi yang lebih baru dari sistem ERP yang paling canggih memiliki fungsi ini tetapi implementasinya bisa mahal dan terutama jika perusahaan perlu meningkatkan dari versi lama seperti dalam kasus kami.

Estimasi biaya bagi pengecer untuk menerapkan sistem ERP baru yang dapat menangani persediaan dan distribusi usia stok adalah 5-10 juta Euro. Tentu saja sistem ERP baru dapat melakukan banyak hal lain yang bagus untuk memiliki hal-hal tetapi tidak dengan cara apa pun mungkin untuk membenarkan investasi untuk saat ini. Hal ini membuat implementasi kami sangat sulit dan alih-alih menggunakan data yang tepat, kami harus mengandalkan perkiraan yang lebih kasar. Kami mendapatkan tingkat persediaan di toko dengan menggunakan data yang belum dikonfirmasi dari penerimaan pengiriman ke toko dan menggabungkannya dengan data pengiriman yang dikirim dari produsen ke toko individu. Dengan cara ini kami mendapatkan akurasi yang dapat diterima untuk data tingkat persediaan tetapi kami tidak dapat memperoleh data tentang distribusi usia stok. Sebaliknya kami harus mengandalkan prinsip First In First Out (FIFO). Ketersediaan informasi yang dapat dipercaya

tentang tingkat persediaan termasuk distribusi umur persediaan merupakan faktor penting untuk kemudahan dan keberhasilan implementasi sistem pendukung keputusan untuk pembelian dan manajemen persediaan barang dengan umur simpan yang pendek.

### Berbagi Informasi - Perencanaan Kolaborasi

Seperti disebutkan sebelumnya dapatkah metode perencanaan kolaboratif membantu dalam mengurangi tingkat persediaan dan meningkatkan efisiensi dalam rantai pasokan [33]. Untuk rantai pasokan daging yang sedang dipertimbangkan di sini, akan bermanfaat untuk berbagi informasi tentang penjualan dan persediaan di dalam rantai tersebut. Variabilitas permintaan meningkat ketika seseorang bergerak ke atas rantai pasokan menjauh dari konsumen dan perubahan kecil dalam permintaan konsumen dapat menghasilkan variasi besar dalam pesanan yang ditempatkan di hulu. Akhirnya, jaringan dapat berosilasi dalam ayunan yang sangat besar karena setiap organisasi dalam rantai pasokan berusaha memecahkan masalah dari perspektifnya sendiri [3]. Fenomena ini dikenal sebagai efek bullwhip dan telah diamati di sebagian besar industri [17,18]. Efek bullwhip terlihat jelas dalam rantai pasokan daging yang sedang dipertimbangkan dalam penelitian kami. Sebagai upaya untuk menghilangkan efek bullwhip, kami telah menggunakan sistem pendukung keputusan AIO sebagai platform untuk berbagi informasi dan kami telah mencoba menggunakan informasi tambahan sebagai bagian dari proses perencanaan. Karena sistem telah diterapkan baik untuk pengecer maupun produsen, ini adalah pilihan yang agak mudah.



**Gambar 12.6** Gambar menunjukkan contoh laporan yang dihasilkan dalam sistem. Ini menunjukkan distribusi proporsional antara pemasok barang dalam bahaya kehabisan stok sebelum pengiriman berikutnya.

Idenya adalah untuk berbagi informasi tentang tingkat stok dan penjualan dalam rantai pasokan. Informasi tentang tingkat stok di satu sisi dibagi antara toko individu pengecer dan di sisi lain antara pengecer dan produsen. Jika toko tertentu kelebihan stok beberapa produk

sementara toko lain kekurangan stok produk yang sama, akan bermanfaat untuk mendistribusikan kembali stok secara lebih merata di antara toko-toko dan dengan demikian mencegah stok kadaluarsa dan mengurangi kemungkinan kehabisan stok. Produsen juga dapat mengurangi tingkat persediaannya dan mempersingkat waktu tunggu produknya dengan menggunakan informasi penjualan dan persediaan waktu nyata dari toko pengecer.

Untuk berbagi informasi, kami menggunakan modul pelaporan berbasis pengecualian. Kami menggunakan antarmuka pengguna yang telah ditentukan sebelumnya serta antarmuka pengguna yang fleksibel yang memungkinkan pengguna membuat aturan untuk menangani situasi yang perlu diperingatkan. Daftar dinamis disajikan ketika kriteria tertentu terpenuhi, mis. potensi kehabisan stok, penjualan yang sangat tinggi, penyimpangan besar antara perkiraan dan penjualan aktual, item yang terlalu banyak menimbun, item yang ditebar kurang, dll. Pengguna tingkat lanjut dapat menentukan kriteria mereka sendiri dengan menulis pernyataan SQL dalam filter lanjutan yang disertakan dalam sistem pendukung keputusan.

### **Kesimpulan**

Pelajaran terpenting dari studi kasus ini bukanlah hal baru, yaitu pentingnya memiliki akses ke data yang akurat dan terstruktur dengan baik. Manfaat potensial dari penggunaan sistem pendukung keputusan untuk menerapkan metode perencanaan kolaboratif dan peramalan tingkat lanjut, inventaris, dan metode manajemen produksi sudah jelas. Namun, manfaat potensial ini tidak akan diperoleh dengan benar tanpa akses ke data yang akurat dan terkini tentang tingkat persediaan dan masa pakai persediaan di semua tingkat dalam rantai pasokan.

Informasi yang disimpan dalam sistem ERP bisa sangat berharga jika digunakan dengan benar. Kebanyakan sistem ERP saat ini namun tidak menggunakan informasi dengan benar untuk mendukung pengambilan keputusan dan ada ruang lingkup besar untuk perbaikan yang diperoleh dengan modul pendukung keputusan yang berguna dan efektif, baik sebagai bagian dari sistem ERP atau dikembangkan secara individual.

#### **12.4 KESIMPULAN**

Dapat disimpulkan bahwa DSS telah terbukti berguna dalam industri makanan dan ada kemungkinan besar untuk penggunaan yang lebih lama. Industri makanan berbeda dengan banyak industri lainnya, karena sifat produk dan bahan dapat berubah secara dramatis seiring waktu dan berbeda dalam kondisi yang berbeda. Oleh karena itu, ketertelusuran penting untuk mengetahui sejarah produk dan/atau bahan yang diminati. Suatu hal yang penting ketika makanan dibahas jika misalnya keamanan. Informasi keamanan pangan dapat dilampirkan ke suatu produk dengan memanfaatkan ketertelusuran - memungkinkan pengelolaan yang lebih mudah oleh otoritas pengawasan pangan dan pengelolaan mutu yang lebih baik dalam rantai nilai pangan.

Cakupan potensi DSS sangat luas. Untuk menyebutkan beberapa bidang yang menarik, DSS dapat digunakan untuk meminimalkan dampak lingkungan dari pemrosesan makanan, untuk tujuan manajemen proses, untuk manajemen stok (dengan mempertimbangkan fakta bahwa sebagian besar produk makanan sangat mudah rusak).

Untuk mempercepat penggunaan DSS dalam industri makanan, diperlukan lebih banyak kerjasama antara pelaku bisnis makanan, penyedia perangkat lunak, lembaga penelitian dan universitas. Penggabungan sistem informasi dan riset operasi diperlukan dan pemahaman rinci tentang industri makanan juga, untuk menafsirkan jawaban yang ditemukan dan memastikan penggunaan DSS yang realistik. Salah satu bidang minat yang jelas adalah mempertimbangkan variabilitas alami dalam bahan mentah ketika mengelola rantai nilai makanan.

Sangat jelas bahwa ada banyak peluang dalam menggunakan DSS dalam industri makanan. Otomatisasi dalam beberapa dekade terakhir berarti bahwa banyak data dikumpulkan tetapi tidak banyak digunakan, karena tidak ada yang tahu bagaimana menanganinya atau membuat informasi dari data tersebut. Orang harus selalu ingat bahwa memercayai data Anda secara membabi buta sering kali tidak aman dan frasa lama sampah masuk - sampah keluar sepenuhnya sah dalam bisnis makanan serta tempat lain.

## BAB 13

### MEMBANGUN SISTEM PENDUKUNG KEPUTUSAN DESAIN PERKOTAAN BERBASIS KONSEP KOTA KREATIF

Renaisans kota telah memainkan peran yang semakin penting dalam regenerasi perkotaan sejak pertengahan 1980-an. Konsep Kota Kreatif yang diusulkan oleh Charles Landry mendorong imajinasi para pengembang kota. Perkembangan akhir-akhir ini kurang terfokus pada proyek-proyek modal dan lebih pada kemampuan aktivitas dalam seni untuk mendukung pembaruan yang dipimpin masyarakat. Penting bagi peneliti untuk lebih memperhatikan isu pengembangan Kota Kreatif. Menurut UNESCO, Creative Cities Network menghubungkan kota-kota yang akan berbagi pengalaman, ide, dan praktik terbaik yang bertujuan untuk pengembangan budaya, sosial dan ekonomi. Hal ini dirancang untuk mempromosikan pembangunan sosial, ekonomi dan budaya kota-kota baik di negara maju dan berkembang. Namun, desain Kota Kreatif harus terintegrasi dengan berbagai pengetahuan dan database yang beragam. Penerapan pembangunan perkotaan adalah tugas yang kompleks dan rumit. Ini melibatkan berbagai isu termasuk teknik, ekonomi, ekologi, sosiologi, pembangunan perkotaan, seni, desain dan domain lainnya. Untuk memberdayakan efisiensi dalam pembangunan kota secara bersamaan, alat evaluasi dan keputusan yang tepat perlu disediakan. Membangun sistem pendukung keputusan pengembangan Kota Kreatif dapat membantu para pengambil keputusan untuk memecahkan masalah semi terstruktur dengan menganalisis data secara interaktif.

Sistem pendukung keputusan didasarkan pada pendekatan baru untuk menangani perangkat kasar. Metode ini akan memainkan peran penting dan akan digunakan secara dinamis dalam DSS. Pendekatan tersebut mewujudkan metode pengambilan sampel yang efisien dalam analisis himpunan kasar yang membedakan apakah suatu himpunan bagian dapat diklasifikasikan dalam himpunan fokus atau tidak. Algoritma dari model rough set akan digunakan untuk menganalisis sampel yang diperoleh. Dalam tulisan ini pertama-tama kita akan mengkaji aturan desain pengembangan Kota Kreatif oleh para ahli desain perkotaan. Kedua, kami akan menerapkan teori himpunan kasar untuk memilih aturan keputusan dan mengukur status kota-kota Jepang saat ini. Akhirnya, kami akan memulai prototipe sistem pendukung keputusan untuk desain Kota Kreatif berdasarkan hasil yang diperoleh dari analisis perangkat kasar.

#### **13.1 PENDAHULUAN**

Saat ini, renaisans kota telah memainkan peran yang semakin penting dalam regenerasi kota. Konsep Kota Kreatif yang diusulkan oleh Charles Landry mendorong imajinasi para profesional yang terlibat dalam pembangunan kembali kota [1]. Menurut UNESCO, Creative Cities Network menghubungkan kota-kota yang akan berbagi pengalaman, ide, dan praktik terbaik yang bertujuan untuk pengembangan budaya, sosial dan ekonomi. Hal ini dirancang untuk mempromosikan pembangunan sosial, ekonomi dan budaya kota-kota baik di negara maju dan berkembang [2].

Baru-baru ini, pendekatan berorientasi seni untuk desain perkotaan, yang melibatkan eksperimen budaya dan kegiatan untuk membawa hasil regenerasi sosial, ekonomi dan lingkungan, semakin banyak diterapkan di banyak kota [3]. Bagaimana kita memahami sebuah kota ketika berjalan di sepanjang jalan? Bagaimana kita memaknai furnitur jalanan dan seni publik di ruang perkotaan? Untuk meningkatkan identitas sebuah kota, banyak eksplorasi desain perkotaan telah dikembangkan. Sebuah metode yang secara otomatis dan cepat menggambarkan apakah sebuah kota kreatif akan meningkatkan efisiensi pemecahan masalah dalam perencanaan dan pembangunan kota. Ini adalah titik awal dari makalah ini.

Tujuan dari makalah ini adalah untuk membuat metode klasifikasi sederhana dalam pendekatan rough set yang membedakan apakah suatu subset dapat diklasifikasikan dalam focal set atau tidak. Teori himpunan kasar adalah pendekatan matematika baru untuk pengetahuan yang tidak sempurna. Masalah pengetahuan yang tidak sempurna telah ditangani sejak lama oleh para filsuf, ahli logika, dan matematikawan. Teori ini telah menarik perhatian banyak peneliti dan praktisi di seluruh dunia, yang telah memberikan kontribusi penting untuk pengembangan dan penerapannya [4].

Namun, dalam situasi tertentu, sangat sulit bagi peneliti untuk mendapatkan data yang tepat saat menerapkan teori himpunan kasar. Misalnya, mengidentifikasi apakah sebuah kota adalah Kota Kreatif memerlukan berbagai basis data untuk mengklasifikasikan kota sampel. Oleh karena itu, maksud dari makalah ini adalah untuk mengusulkan suatu cara untuk menentukan secara efisien apakah suatu subset dapat diklasifikasikan dalam set fokus atau tidak.

Saat ini, mereka yang tertarik dengan metode yang ada telah difokuskan pada penggunaan analisis data untuk menemukan pola tersembunyi, menghasilkan seperangkat aturan keputusan, dan sebagainya. Salah satu gagasan penting yang mendasari teori himpunan kasar adalah aproksimasi. Analisis himpunan kasar menggunakan pendekatan atas dan bawah. Keuntungan utama dari survei ini adalah menyediakan metode baru untuk memaksakan diskriminasi antara pendekatan atas dan luar. Dalam makalah ini, menggunakan metode pengambilan sampel yang efisien berdasarkan uji statistik, kami menerapkan algoritme teori himpunan kasar untuk memutuskan apakah sebuah kota harus diklasifikasikan dalam kelompok kota kreatif dengan mengevaluasi kuantitas seni publik. Selain itu, untuk meminimalkan biaya dan memaksimalkan efisiensi, kami memilih alternatif pemanfaatan data buatan dalam makalah ini.

Sisa dari makalah ini disusun sebagai berikut: di Bagian 2, konsep Kota Kreatif, beberapa contoh kota kreatif di Jepang dan definisi seni publik akan dijelaskan secara singkat. Bagian 3 memberikan ikhtisar penelitian dalam teori himpunan kasar dan konsep dasar dan dasar analisis himpunan kasar dan himpunan kasar. Dalam Bagian 4, metode pengambilan sampel yang efisien diilustrasikan berdasarkan uji statistik, yang menghemat dan menyederhanakan evaluasi atribut keputusan dan kondisi, sehingga lebih efisien. Contoh simulasi akan didemonstrasikan untuk menunjukkan mekanisme metode sampling untuk model rough set di Bagian 5. Bagian 6 akan menjelaskan definisi sistem pendukung keputusan. Aplikasi sistem informasi geografis akan diuraikan dalam Bagian 7. Pada Bagian 8, desain dan metodologi penelitian akan dibahas. Akhirnya, prototipe sistem pendukung keputusan akan

dijelaskan pada bagian 9. Bagian 10 akan menyimpulkan makalah ini dengan beberapa catatan.

### **13.2 KOTA KREATIF**

#### **Konsep Kota Kreatif**

Kita mulai menyadari betapa pentingnya kreativitas dan budaya bagi kehidupan masyarakat dan kesejahteraan ekonomi modern. Chris Smith (2005), Mantan Menteri Departemen Kebudayaan, Media dan Olahraga di Inggris menyatakan kreativitas adalah kemampuan yang memungkinkan orang untuk berpikir kembali, untuk memulai ide-ide baru, untuk menemukan kemungkinan baru dalam melakukan sesuatu, untuk menghasilkan imajinasi, dan seterusnya. Ini juga merupakan komponen terpenting dalam rasa identitas kita sendiri, sebagai individu, komunitas lokal, kota atau bangsa [5]. Industri kreatif semakin menjadi penting bagi kemakmuran ekonomi dan kesejahteraan masyarakat kota-kota besar dunia.

Konsep Kota Kreatif awalnya ditujukan oleh Charles Landry untuk memikirkan kota sebagai karya seni yang hidup, di mana warga dapat terlibat dan terlibat dalam penciptaan tempat yang berubah. Hal ini akan membutuhkan kreativitas yang berbeda-beda seperti para insinyur, sosiolog, perencana kota, arsitek, pemerhati lingkungan, antropolog, seniman dan tentunya masyarakat biasa yang menjalani kehidupannya sebagai warga negara [1]. Penekanan pada kreativitas di kota-kota telah berkembang ketika orang-orang menyadari bahwa kota-kota saling bersaing lagi di beberapa tingkatan.

Sebuah bangunan, instalasi seni publik, perabot jalanan, dan ruang perkotaan apa pun di kota, seperti yang ditunjukkan pada Tabel 1, dapat menumbuhkan suasana kreatif dan menginspirasi penghuni. Apa yang membuat sebuah lingkungan menjadi kreatif adalah bahwa lingkungan itu memberi penghuni perasaan bahwa mereka dapat membentuk, menciptakan, dan membuat tempat di mana mereka tinggal. Penduduk adalah peserta aktif daripada konsumen pasif. Ide Kota Kreatif adalah proses yang berkelanjutan. Itu dinamis, bukan statis. Untuk membuat Kota Kreatif membutuhkan infrastruktur di luar perangkat keras. Infrastruktur kreatif adalah kombinasi dari hard dan soft. Ini akan melibatkan infrastruktur mental. Memang, sangat sedikit tempat yang kreatif secara komprehensif, tetapi setiap kota bisa lebih kreatif dari itu [5].

**Tabel 13.1** Contoh Desain Kota Kreatif

Public Art Installation	Naoshima, Kagawa, Japan 	Naoshima, Kagawa, Japan 
Street Furniture	International Forum, Tokyo 	Midtown, Tokyo 
Local Identity	Echigo-Tsumari, Nigatta 	Biei, Hokkaido 

**Bakat, Teknologi, dan Toleransi - Indeks Kreativitas 3T**

Indeks Kreativitas yang dikembangkan oleh Florida pada tahun 2002 [5], memberikan instrumen baru untuk mengukur ekonomi kreatif. Tabel 2 mencantumkan faktor-faktor berbobot yang sama yang diusulkan berdasarkan metodologi Florida: (1) Bakat - bagian angkatan kerja Kelas Kreatif; (2) Inovasi teknologi, diukur sebagai paten per kapita dan industri teknologi tinggi, menggunakan Indeks Kutub Teknologi (Indeks Teknologi Tinggi) dari Milken Institute yang diterima secara luas; (3) Toleransi, diukur dengan Indeks Gay, Indeks Bohemian dan Indeks Melting Pot. Namun, penelitian Florida bukan tanpa kelemahan. Pengembangan Kota Kreatif merupakan proses yang kompleks. Faktor Talent, Technology and Tolerance yang dicatat belum cukup untuk menganalisis konsep kota kreatif. Masih ada berbagai indikator yang perlu diperhatikan untuk mengkaji pembangunan kembali kota. Oleh karena itu, kami akan mengeksplorasi Indeks Kreativitas lainnya setelah dengan cermat meninjau kembali temuan penelitian kami.

**Tabel 13.2** Teknologi, Bakat dan Toleransi- Indeks Kreatif

Bakat	Kelas Kreatif	Persentase populasi profesional kreatif
	Indeks Modal Manusia	Persentase penduduk dengan gelar sarjana atau lebih tinggi
	Bakat Ilmiah	Persentase populasi peneliti ilmiah

Teknologi	Indeks Inovasi	Paten diberikan per kapita
	Indeks Teknologi Tinggi	<ul style="list-style-type: none"> <li>Output industri teknologi tinggi sebagai persentase dari total output industri teknologi tinggi AS</li> <li>Persentase total output ekonomi daerah yang berasal dari industri teknologi tinggi dibandingkan dengan persentase nasional.</li> </ul>
Toleransi	Indeks Gay	Populasi gay di sebuah kota
	Indeks Bohemian	Jumlah artis dan musisi
	Indeks Melting Pot	Persentase penduduk asing di suatu wilayah.

### Peringkat Kreativitas di Kota Besar AS

Tabel 3 dan Tabel 4 menyajikan peringkat indeks kreatif untuk 10 besar dan 10 wilayah metropolitan terbawah di antara 49 wilayah AS dengan populasi lebih dari satu juta [5]. Menurut penelitian Florida, Austin, Texas, kini telah melampaui San Francisco untuk menempati posisi pertama. Seattle, Boston dan Raleigh-Durham berada di daftar lima besar. Namun, kota-kota seperti Buffalo, New Orleans, dan Louisville adalah contoh kota-kota yang gagal menarik Kelas Kreatif. Sekali lagi, peringkat Indeks Kreativitas ini belum banyak diteliti karena keterbatasannya. Karena kurangnya dukungan kuat untuk bukti hubungan antara 3T dan Kota Kreatif yang sukses, penelitian lebih lanjut tentang faktor-faktor yang tepat untuk pengembangan kota kreatif diperlukan.

**Tabel 13.3 Top 10 Kota Kreatif di AS**

Peringkat	Kota dengan Skor Indeks Materi Iklan Tertinggi	Peringkat Teknologi	Peringkat Bakat	Peringkat Toleransi
1	Austin-TX	1	3	7
2	San Francisco-CA	3	5	6
3	Seattle-WA	6	6	1
4	Boston-MA	12	4	3
5	Raleigh-Durham-NC	2	2	20
6	Portland-OR	4	19	2
7	Minneapolis-MN	16	9	4
8	Washington-Baltimore	15	1	16
9	Sacramento-CA	5	11	17
10	Denver-CO	22	8	8

**Tabel 13.4 10 Kota Kreatif Terbawah di AS**

Peringkat	Kota dengan Skor Indeks Materi Iklan Tertinggi	Peringkat Teknologi	Peringkat Bakat	Peringkat Toleransi

39	Detroit-MI	48	22	37
39	Norfolk-VA	37	30	46
41	Cleveland-OH	40	32	43
42	Milwaukee-WI	43	40	41
43	Grand Rapids-MI	33	48	32
44	Memphis-TN	27	43	48
45	Jacksonville-FL	49	39	33
46	Greensboro-NC	41	46	39
47	New Orleans-LA	47	35	39
48	Buffalo-NY	41	37	<b>47</b>

### Eksperimen Kota Kreatif di Jepang

Baru-baru ini, beberapa kota di Jepang, seperti Yokohama, Kanazawa dan Sendai, telah memulai proyek eksperimental yang terinspirasi oleh konsep Kota Kreatif, seperti yang disajikan pada Tabel 5. Hasil kerja mereka dirangkum sebagai berikut:

**Tabel 13.5** Perkembangan Kota Kreatif di Jepang

Tahun	Kota	Isi
1999/3	Kanazawa	Simposium Kota Kreatif Kanazawa
2004/4	Yokohama	Mendirikan Divisi Budaya, Kota Seni, dan Bisnis Kreatif
2005/4	Nagoya	Visi Abad Baru Nagoya 2010
2005/5	Kobe	Visi Kobe 2010
2005/4	Sapporo	Visi Kota Kreatif
2006/3	Fukuoka	Rencana 10 Tahun Fukuoka yang Kreatif
2007/1	Sendai	Visi Kota Sendai
2007/3	Osaka	Strategi Kota Kreatif Osaka
2007/4	Hamamatsu	Nilai Baru Kota Kreatif

### *Kota Kreatif, Yokohama!*

#### *Latar Belakang*

Kota Yokohama telah mewujudkan visi “Kota Kreatif” ini sebagai strategi kunci untuk pengembangan kota. Dalam waktu kurang dari 150 tahun sejak pelabuhan dibuka untuk perdagangan luar negeri, Yokohama telah berubah, menjadi kota terbesar kedua di Jepang, dengan populasi 3,6 juta dan budaya yang berbeda dari tetangga Tokyo, seperti yang ditunjukkan pada Tabel 8. Sejarahnya telah meninggalkannya dengan pemandangan kota yang unik, bangunan bersejarah, dan pemandangan pelabuhan. Ini menarik banyak penduduk dan turis Yokohama, dan juga telah memelihara beragam seni dan budaya. Terinspirasi oleh konsep Kota Kreatif, pemerintah kota Yokohama berusaha menunjukkan kepada dunia bahwa ia menciptakan nilai baru dan menjadikan dirinya lebih menarik sebagai sebuah kota.

Untuk mewujudkan visi Kota Kreatif, pada tahun 2004 dibentuk divisi Kebudayaan, Kota Seni, dan Bisnis Kreatif, departemen baru pemerintah kota Yokohama. Selain itu, peringatan 150 tahun pembukaan Pelabuhan Yokohama pada tahun 2009 memberikan kesempatan yang sangat baik untuk mendorong maju dengan inisiatif pembangunan perkotaan baru yang besar. Visi ini dituangkan dalam slogan, "Yoko-hama-Kota Kreatif Seni dan Budaya."

#### ***Rencana Taman Seni Nasional***

Terkonsentrasi di sekitar enam area di atau dekat tepi laut di pusat kota, dan memanfaatkan sumber daya pemandangan pelabuhan, upaya aktif dilakukan untuk mendorong kegiatan seni dan budaya, seperti disajikan pada Tabel 6.

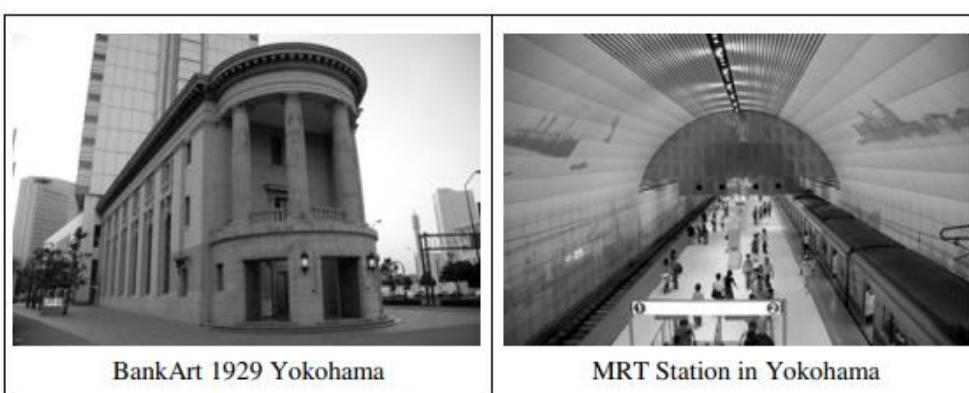
**Tabel 13.6 Rencana Taman Seni Nasional di Kota Yokohama**



#### ***Strategi Pembentukan Daerah Inti Kreatif Budaya***

Bashamichi, Nihon-Odori Ave. dan Sakurakicho Noge telah dipilih sebagai tiga area inti kreatif, untuk sepenuhnya memanfaatkan sumber daya lokal dari bangunan bersejarah, gudang, dan kantor kosong tempat seniman dan pencipta dapat tinggal, bekerja, dan berpameran, menghadirkan vitalitas bagi komunitas, seperti yang ditunjukkan pada Tabel 7.

**Tabel 13.7 Pembentukan Kawasan Inti Kreatif di Kota Yokohama**



Akibatnya, kunjungan wisatawan ke Yokohama telah meningkat menjadi 41 juta pada tahun 2007, dengan tambahan enam juta kunjungan dibandingkan dengan tahun 2004 yang mencapai 35 juta kunjungan. Juga, Yokohama Art Triennial 2008 berhasil menarik 300.000 Sistem Pendukung Keputusan (Dr Joseph Teguh Santoso dan Budi Hartono, M.Kom)

pengunjung ke kota Yokohama, menurut buku panduan statistik Yokohama. Selain itu, perkiraan nilai dampak ekonomi untuk proyek “Kota Kreatif Yokohama” adalah sekitar 12 miliar Yen Jepang antara tahun 2004 dan 2007.

**Tabel 13.8 Profil Kota Yokohama**

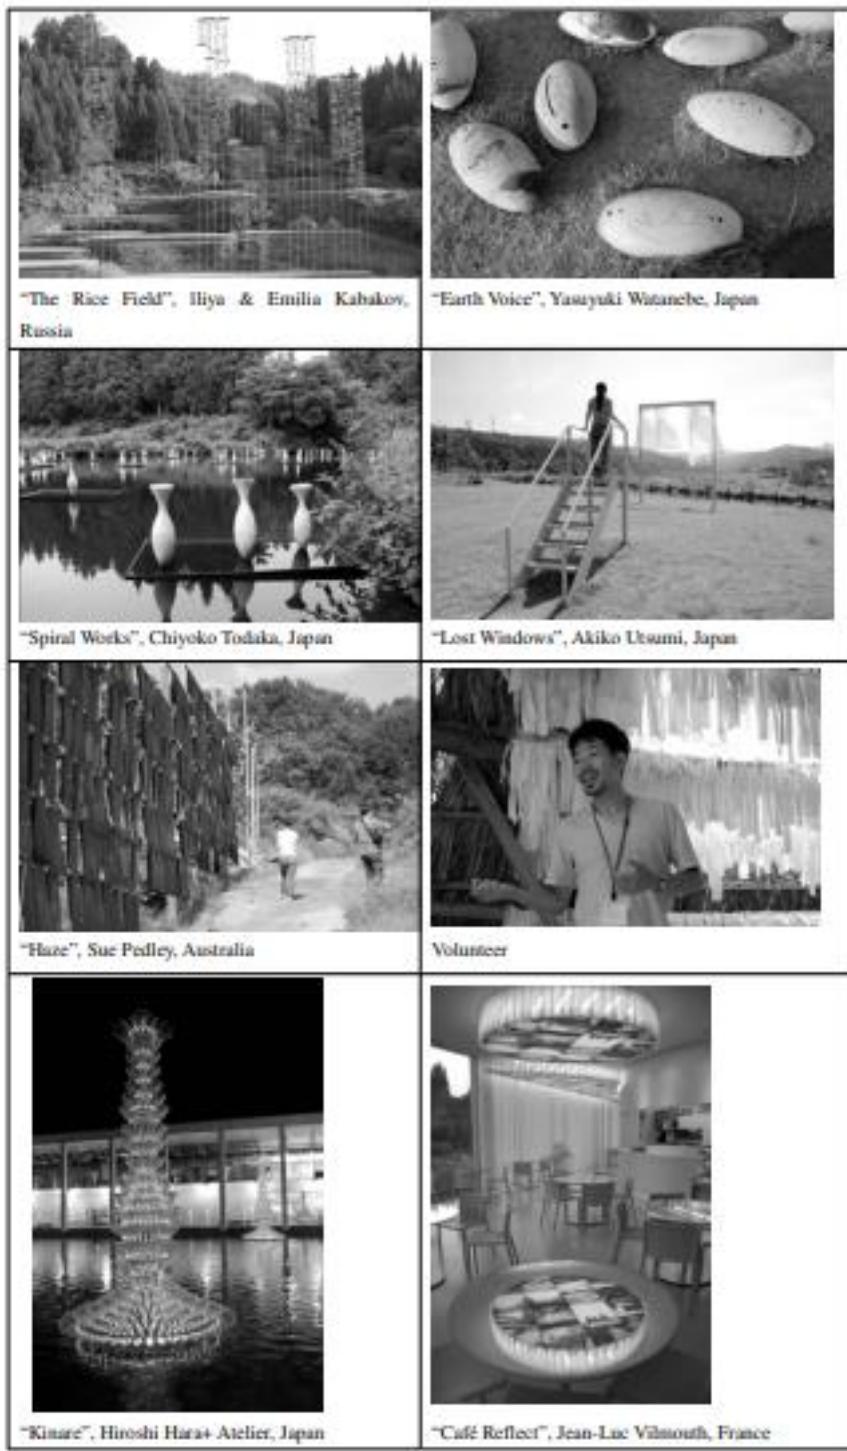
<b>Informasi dasar</b>	Populasi: 3.654.326 Luas:434,98 km2
<b>Indeks Kreatif</b>	Persentase Penduduk yang terdiri dari Profesional Kreatif: 4,7% (55.945/1.185.778) Rata-rata Nasional: 3,1% (1.632.084/52.067.396)
<b>Penglihatan</b>	Kota Kreatif Yokohama!
<b>Tujuan</b>	<ul style="list-style-type: none"> <li>• Menciptakan lingkungan di mana seniman dan pencipta ingin tinggal.</li> <li>• Merangsang perekonomian dengan klaster industri kreatif.</li> <li>• Memanfaatkan dengan baik sumber-sumber sejarah yang ada di masyarakat.</li> <li>• Warga memimpin untuk menghasilkan kota seni dan budaya yang kreatif.</li> </ul>
<b>Proyek Utama</b>	<ul style="list-style-type: none"> <li>• Rencana Taman Seni Nasional</li> <li>• Pembentukan Area Inti Kreatif</li> <li>• Kota Budaya Gambar</li> <li>• Triennial Internasional Seni Kontemporer Yokohama</li> <li>• Memelihara Pencipta Masa Depan</li> </ul>
<b>Organisasi</b>	Seksi Bisnis Kota Kreatif, Panitia Promosi Peringatan 150 Tahun Pembukaan Pelabuhan Kota Yokohama

### ***Echigo-Tsumari Triennial, Nigatta, Jepang***

#### ***Tentang Echigo-Tsumari***

Echigo-Tsumari terletak di ujung selatan Prefektur Niigata, dua jam perjalanan kereta dari Tokyo. Salah satu daerah di Jepang dengan hujan salju terberat, termasuk Kota Tokamachi dan Kota Tsunan. Meskipun luas totalnya, 760 kilometer persegi, lebih besar dari total 23 distrik Tokyo, populasinya kurang dari 75.000 penduduk, 30% di antaranya berusia di atas 65 tahun. Wilayah ini menghadapi masalah serius dari masyarakat yang menua. dan depopulasi yang dramatis. Selanjutnya, wilayah Echigo-Tsumari dilanda gempa bumi hebat pada tahun 2004 dan 2007.

**Tabel 13.9.** Karya seni yang dipamerkan dalam The Echigo-Tsumari Art Triennial



#### **Apa itu Triennial Seni Echigo-Tsumari?**

Echigo-Tsumari Art Triennial adalah festival seni internasional terbesar di dunia, diadakan setiap tiga tahun di wilayah Echigo-Tsumari, meliputi Kota Tokamachi dan Kota Tsunan di Prefektur Niigata. Ini menghadirkan potensi baru bagi pameran seni rupa internasional untuk berekspresi dengan menggunakan pendekatan berbeda seperti yang disebut "Off-Museum", mencoba melepaskan diri dari keterbatasan ruang di dalam museum tradisional. Triennial telah diadakan tiga kali sejauh ini, pada tahun 2000, 2003, dan 2006, sebagai tempat untuk memamerkan hasil proyek jangka panjang yang disebut "Proyek Kalung

"Seni Echigo-Tsumari", yang tujuannya adalah untuk menarik nilai yang dapat ditemukan di daerah, mengangkat nilai itu, menunjukkannya kepada dunia, dan dengan demikian berkontribusi pada revitalisasi daerah melalui media seni. Persiapan sudah dimulai untuk Triennial keempat, yang akan diadakan pada tahun 2009. Lebih dari 330 karya seni yang dibuat oleh 150 seniman dari 45 negara akan dimasukkan, seperti yang ditunjukkan pada Tabel 9.

Bekerja sama dengan penduduk setempat, peserta membuat karya seni khusus lokasi di sawah bertingkat, bukit hutan, tepi sungai, lereng gunung, dan rumah atau sekolah terbengkalai. Dengan cara ini, mereka mengenal spiritualitas dan keramahan orang-orang dan menerapkan jenis desain arsitektur baru. Selain itu, melalui interaksi dengan seniman, warga dibangunkan oleh instalasi seni publik, memahami nilai baru yang dapat dibawa oleh budaya dan tradisi lokal mereka sendiri ke kampung halaman mereka.

### Definisi Seni Publik

Dalam tulisan ini, kami menganalisis kuantitas seni publik di sebuah kota. Istilah "seni publik" mengacu pada karya seni dalam media apa pun yang telah direncanakan dan dilaksanakan dengan tujuan khusus untuk ditempatkan atau dipentaskan dalam domain publik, biasanya di luar dan dapat diakses oleh semua orang, seperti yang ditunjukkan pada Tabel 10.

**Tabel 13.10** Contoh Instalasi Seni Rupa Umum



### 13.3 TEORI HIMPUNAN KASAR

Teori himpunan kasar sangat berguna untuk domain di mana data yang dikumpulkan tidak tepat dan/atau tidak lengkap. Ini menyediakan alat yang kuat untuk analisis data dan penambangan data dari data yang tidak tepat dan ambigu. Reduksi adalah himpunan minimal atribut yang mempertahankan hubungan indispensability, yaitu kekuatan klasifikasi dari dataset asli [6]. Teori himpunan kasar memiliki banyak keuntungan: ia menyediakan algoritma yang efisien untuk menemukan pola tersembunyi dalam data, menemukan kumpulan data minimal (reduksi data), mengevaluasi signifikansi data, dan menghasilkan kumpulan aturan keputusan minimal dari data. Sangat mudah untuk memahami dan menawarkan interpretasi langsung dari hasil [7]. Keunggulan tersebut dapat mempermudah analisis, sehingga banyak aplikasi yang menggunakan pendekatan rough set sebagai metode penelitiannya. Teori himpunan kasar sangat penting dalam kecerdasan buatan dan ilmu kognitif, terutama di bidang pembelajaran mesin, akuisisi pengetahuan, analisis keputusan, penemuan

pengetahuan dari database, sistem pakar, sistem pendukung keputusan, penalaran induktif, dan pengenalan pola [8 , 9, 10].

Teori himpunan kasar telah dikembangkan oleh Pawlak [15] dan telah diterapkan pada pengelolaan banyak masalah, termasuk diagnosis medis, keandalan teknik, sistem pakar, studi empiris data material [11], diagnosis mesin [12], analisis permintaan perjalanan [13], prediksi kegagalan bisnis, penyelesaian program linier, penambangan data [14] dan -RST [15]. Makalah lain membahas urutan preferensi kriteria atribut yang diperlukan untuk memperluas teori himpunan kasar asli, seperti masalah penyortiran, pilihan dan peringkat [16], pasar asuransi [17], dan penyatuan teori himpunan kasar dan teori fuzzy [18] ]. Teori himpunan kasar adalah metode yang berguna untuk menganalisis data dan mereduksi informasi dengan cara yang sederhana.

### **Ikhtisar Konsep Teori Himpunan Kasar**

Dalam perencanaan & pengembangan kota, furnitur jalanan merupakan komponen penting, dan pengetahuan tentang bagaimana merancang seni publik yang berkelanjutan tidak lengkap dan tidak pasti. Alat yang ternyata sangat memadai untuk analisis berbagai jenis data, dan terutama untuk menangani pengetahuan yang tidak pasti, tidak pasti atau kabur, adalah teori himpunan kabur dan himpunan kasar. Baik teori himpunan kabur maupun himpunan kasar berhubungan dengan pengetahuan persepsi dan tak terlukiskan. Perbedaan paling mendasar di antara mereka adalah bahwa teori himpunan kasar tidak perlu memiliki fungsi keanggotaan, sehingga dapat menghindari pra-asumsi dan informasi subjektif pada analisis. Teori himpunan kasar memberikan pendekatan matematis baru yang berbeda untuk menganalisis yang tidak pasti, dan dengan himpunan kasar, kita dapat mengklasifikasikan data atau informasi yang tidak sempurna dengan mudah. Hasilnya disajikan dalam bentuk aturan keputusan. Dalam penelitian ini, kami menggunakan teori himpunan kasar untuk menganalisis masalah desain perkotaan.

### **Sistem Informasi**

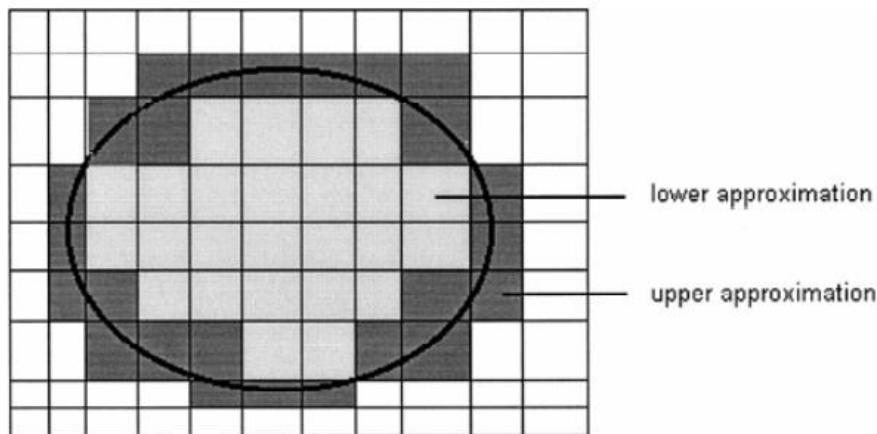
Secara umum, sistem informasi yang dinotasikan IS didefinisikan oleh IS (U,A) , dimana U terdiri dari objek berhingga dan diberi nama alam semesta dan A adalah himpunan berhingga atribut  $\{a_1 , a_2 \dots, a_n \}$  . Setiap atribut a termasuk dalam himpunan A , yaitu  $a \in A$  .  $f_a :U \rightarrow V_a$  .  $f_a$  berarti semua  $V_a$  berada di U , di mana  $V_a$  adalah himpunan nilai atribut. Itu dinamai domain atribut a.

### **Perkiraan Bawah dan Atas**

Sebuah metode untuk menganalisis himpunan kasar didasarkan pada dua konsep dasar, yaitu perkiraan bawah dan atas dari himpunan fokus, seperti yang ditunjukkan pada Gambar 1. Tanpa diragukan lagi, ini mungkin himpunan. Pada Gambar 1, lingkaran dari satu set fokus diwakili oleh beberapa kotak. Kuadrat yang tercakup seluruhnya dalam lingkaran disebut aproksimasi lebih rendah. Kuadrat yang sebagian dan seluruhnya termasuk dalam lingkaran disebut aproksimasi atas. Biarkan X menjadi bagian dari elemen di alam semesta U , yaitu,  $X \subset U$  . Mari kita pertimbangkan subset dalam  $V_a$ ,  $P \subseteq V$ . Pendekatan rendah dari P , dilambangkan sebagai PX , dapat didefinisikan dengan gabungan semua himpunan elementer  $X_i$  yang terdapat dalam X sebagai berikut: PX =  $\{X_i \in U | X_i \text{ ind}(P) \subset X\}$  di mana  $X_i$  adalah elemen himpunan yang terdapat dalam  $X_i$  ,  $i = 1,2,\dots, n$  . Pendekatan atas P , dilambangkan sebagai

$\overline{P}X$ , dapat dilambangkan dengan perpotongan tak kosong dari semua himpunan elementer  $X_i$  yang terdapat dalam X sebagai berikut:  $\overline{P}X = \{X_i \in U | X_i \text{ in } P \cap X \neq \emptyset\}$ .

Batas X di U didefinisikan sebagai berikut:  $PX = \overline{P}X - \underline{P}X$ . Gambar 1 menunjukkan pendekatan rendah dan atas secara konseptual.



**Gambar 13.1** Perkiraan Atas dan Bawah dari Himpunan X

### Inti dan Reduksi Atribut

Melanjutkan diskusi di 3.3, himpunan atribut inti dan reduksi,  $COR(B)$  dan  $RED(P)$ , adalah dua konsep dasar himpunan kasar. Reduksi dapat berupa subset minimal dari atribut yang menyediakan klasifikasi objek yang sama dengan set atribut lengkap. Inti adalah umum untuk semua pereduksi [18]. Reduksi atribut dapat menghilangkan atribut yang berlebihan dan berlebihan dan memberikan informasi yang sederhana dan mudah kepada pembuat keputusan. Mungkin ada lebih dari satu pengurangan atribut. Jika himpunan atribut bergantung, kita tertarik untuk menemukan semua himpunan bagian minimal yang mungkin dari atribut yang memiliki jumlah himpunan dasar yang sama; ini disebut reduksi [18]. Himpunan atribut reduct tidak mempengaruhi proses pengambilan keputusan, dan atribut inti merupakan atribut yang paling penting dalam pengambilan keputusan. Jika himpunan atribut sangat diperlukan, himpunan tersebut disebut inti [18].

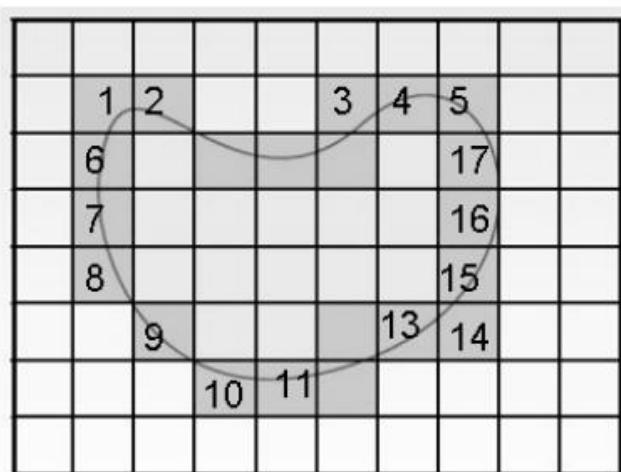
$$RED(P) \subseteq A, COR(B) = \bigcap RED(P)$$

### Aturan Keputusan

Aturan keputusan juga dapat dianggap sebagai seperangkat aturan keputusan (klasifikasi) dari bentuk:  $a_k \Rightarrow d_j$ . Dimana  $a_k$  berarti atribut  $a_k$  bernilai 1,  $d_j$  mewakili atribut keputusan dan simbol ' $\Rightarrow$ ' menunjukkan implikasi proposisional. Dalam aturan keputusan  $\theta \Rightarrow \varphi$ , rumus  $\theta$  dan  $\varphi$  masing-masing disebut kondisi dan keputusan [19]. Dengan aturan keputusan, kita dapat meminimalkan himpunan atribut, mereduksi atribut yang berlebihan dan mengelompokkan elemen ke dalam grup yang berbeda. Dengan cara ini kita dapat memiliki banyak aturan keputusan: setiap aturan memiliki fitur yang berarti. Aturan yang lebih kuat akan mencakup lebih banyak objek dan kekuatan setiap aturan keputusan dapat dihitung untuk menentukan aturan yang sesuai.

### 13.4 PENGAMBILAN SAMPEL YANG EFISIEN BERDASARKAN UJI STATISTIK

Menurut algoritma metode rough set, kami membangun model pengambilan sampel yang efisien berdasarkan uji statistik yang dapat mengklasifikasikan data yang berkaitan dengan setiap atribut secara otomatis. Model meningkatkan efisiensi klasifikasi data. Artinya, jika kita memiliki data dalam jumlah besar atau bermaksud untuk mendapatkan sampel secara acak, kita dapat menghemat waktu dan biaya kita dengan mengelompokkan data ini ke dalam kelompok-kelompok tertentu sesuai dengan atributnya. Model akan membantu kita untuk memecahkan masalah ini. Kami hanya memilih jumlah sampel minimal, katakanlah 25 sampel pada Gambar 2 dan 3, mengklasifikasikannya secara otomatis tergantung pada hasil uji statistik dan membuat perkiraan untuk analisis himpunan kasar. Ketika sampel tersebut tidak cukup untuk mencapai suatu keputusan, maka kita mengambil sampel lain, katakanlah 25 sampel lagi pada Gambar 3. Melalui metode pengambilan sampel yang efisien ini, kita dapat dengan mudah menentukan apakah data termasuk dalam kelompok tertentu atau tidak, melainkan secara otomatis.



Gambar 13.2 Gambar Rough Set

Seperti yang kita ketahui, definisi metode rough set dapat dijelaskan, seperti yang ditunjukkan oleh Gambar 1. Dari Gambar 2 kita dapat mengidentifikasi bahwa bagian dengan kotak berwarna terang adalah wilayah positif dari set fokus dan bagian dengan kotak berwarna gelap, seperti set1-set17, adalah wilayah batas dari set fokus. Jelas wilayah positif disertakan dalam set fokus, tetapi kita juga dapat melihat bahwa beberapa set, seperti set16 dan set17, hampir disertakan dalam set fokus, sementara set lainnya, seperti set1 dan set2, jauh lebih sedikit disertakan dalam set fokus. Set fokus. Lantas, bagaimana cara menentukan apakah wilayah batas, seperti set1 hingga set17, termasuk dalam set fokus? Bisakah kita mengatakan bahwa set1 hingga set17 semuanya termasuk dalam set fokus? Kami telah menetapkan ambang batas untuk setiap set: jika jumlah elemen di dalam set lebih dari ambang batas, maka kami dapat memasukkan set ke dalam set fokus, dan sebaliknya. Ini menyelesaikan dua konsep perkiraan atas dan bawah.

Berdasarkan penjelasan di atas, kami merancang algoritme model pengambilan sampel yang efisien berdasarkan uji statistik. Misalkan ada 30 himpunan bagian yang termasuk dalam satu himpunan utuh dan setiap himpunan bagian memiliki 25 nilai sampel. Ada juga rasio diskriminasi untuk seluruh himpunan, artinya ketika hasil klasifikasi setiap subset lebih

besar dari rasio diskriminasi, kita dapat memasukkan subset ini ke dalam fokal set. Dalam situasi buatan kami, ini berarti bahwa beberapa kota dapat diekstraksi sebagai Kota Kreatif. Jika uji statistik tidak meyakinkan kita bahwa suatu himpunan dianggap diklasifikasikan dalam himpunan fokus atau tidak, maka kita memperoleh sampel lebih lanjut, dalam contoh 25 sampel lebih, untuk mencapai beberapa keputusan klasifikasi. Ketika kita menggunakan model ini, kita dapat memperoleh hasil dari masalah klasifikasi dengan mudah dan cepat.

### **Metode Pengambilan Sampel Statistik**

Setelah menyelesaikan langkah pengambilan sampel, kita harus menerapkan uji-t Student untuk memverifikasi hasil setiap subset karena kita tidak tahu apakah hasil sampel sesuai dengan hasil seluruh subset.

The number of samples	Discrimin City 1	City 2	City 3	City 4	City 5	City 6	City 7	City 8	City 9	City 10	City 11	City 12	City 13	City 14	City 15	City 16	City 17	City 18	City 19	City 20	City 21	City 22	City 23	City 24	City 25	City 26	City 27	City 28	City 29	City 30	
0.5	55																														
Sample 1	87	86	26	36	56	13	90	30	68	0	48	27	57	20	23	65	44	3	11	51	70	5	35	20	35	67	12	13	5	73	
Sample 2	33	92	16	48	81	87	76	15	96	69	25	70	68	61	6	38	58	68	99	66	36	41	68	4	61	31	35	45	51	12	
Sample 3	81	56	12	48	72	32	66	58	54	12	8	45	75	71	90	12	17	8	60	42	81	33	6	16	52	33	67	90	51	86	
Sample 4	38	37	43	63	9	47	87	72	41	69	45	12	93	79	37	84	25	72	18	46	44	19	3	35	41	37	31	61	79	10	
Sample 5	57	60	0	87	53	35	88	17	27	23	83	46	70	38	49	19	44	19	3	35	41	37	31	61	79	10	83	20	49		
Sample 6	52	73	40	46	82	21	79	1	73	4	27	54	70	43	58	39	98	58	79	41	95	25	66	13	30	7	44	44	17		
Sample 7	95	68	31	75	82	36	65	11	80	13	29	68	56	40	38	34	12	56	45	56	1	70	56	97	28	54	74	62	42	34	
Sample 8	71	88	33	39	69	28	87	87	99	62	58	47	44	45	97	87	97	65	24	84	84	64	19	42	22	93	99	31	69	28	
Sample 9	99	79	1	90	46	95	60	85	1	50	20	84	86	24	45	59	13	54	48	28	93	16	22	83	26	13	39	51	38	0	
Sample 10	90	38	23	7	6	72	88	36	38	45	79	18	45	47	29	11	0	0	32	61	31	99	10	66	79	19	43	62	68	68	
Sample 11	86	85	0	73	53	36	98	51	97	83	87	84	66	23	41	9	9	36	42	93	95	64	45	37	57	34	19	47	66	34	
Sample 12	87	22	23	94	65	67	99	9	18	15	71	3	55	67	5	6	76	38	87	48	91	34	98	20	24	57	64	72	9	59	
Sample 13	44	84	25	86	24	38	77	27	87	29	55	53	60	72	66	13	11	83	91	85	15	5	22	8	7	20	6	17	29	8	
Sample 14	85	78	43	62	46	46	89	33	47	14	69	98	80	88	30	52	33	2	56	78	99	51	83	27	52	87	57	26	74	85	
Sample 15	41	48	33	49	88	55	97	56	17	56	87	21	58	70	66	1	55	7	76	53	44	28	50	24	36	61	53	61	83	92	
Sample 16	60	89	74	7	28	83	97	89	4	54	92	20	94	41	46	36	87	78	42	75	86	74	47	59	81	64	63	21	22	60	
Sample 17	31	21	25	73	89	45	79	38	87	87	7	84	70	32	69	50	40	28	81	71	10	29	64	72	76	34	16	22	94	89	
Sample 18	80	65	37	38	65	64	67	99	7	95	28	62	57	19	8	42	70	75	77	95	5	17	48	6	70	24	29	15	99	99	
Sample 19	40	35	40	65	83	42	67	8	5	50	58	53	51	52	79	19	42	96	76	26	8	56	17	96	50	75	41	80	35	1	
Sample 20	38	54	37	13	58	32	75	35	82	88	1	23	57	25	18	57	18	92	63	24	12	0	39	48	48	81	47	75	86	28	
Sample 21	90	26	16	46	53	30	87	77	37	96	8	98	49	60	74	31	99	75	35	22	57	87	0	96	20	90	65	39	19	63	
Sample 22	98	43	72	34	33	22	79	29	77	98	75	67	87	90	10	64	91	62	34	82	35	58	13	47	63	61	44	13	60	30	
Sample 23	45	45	28	11	70	19	69	14	94	84	63	17	80	98	78	81	74	4	54	37	14	99	8	63	55	24	6	5	64	75	
Sample 24	97	90	43	21	48	25	58	43	73	5	55	33	90	49	91	75	72	71	49	63	25	35	6	40	73	17	38	61	30	81	
Sample 25	69	11	22	32	37	2	79	25	10	82	14	50	52	77	44	24	62	91	58	38	31	58	14	70	18	19	66	31	82	52	
Mean	67.4	58.9	29.7	47.1	55.6	43.3	79.9	41.8	51.8	52.1	47.7	49.5	66.8	53.3	47.9	41.1	47.5	51.3	52.8	57.6	46.0	49.0	32.5	51.8	45.8	48.4	43.9	41.2	50.5	50.8	
Standard Deviation	23.4	25.2	18.4	27.4	23.5	23.5	12.5	26.9	34.3	34.0	29.0	27.7	15.3	23.4	28.1	26.4	30.1	33.5	25.1	22.7	32.4	29.5	25.7	28.4	24.9	26.5	25.3	24.0	25.7	30.5	
t-test	2.06	2.6	-6.9	-1.4	0.2	-2.5	10.0	-2.3	-0.3	-0.4	-1.3	-1.0	3.8	-0.4	-1.3	-2.6	-1.2	-0.5	0.4	0.6	-1.4	-1.0	-1.9	-1.2	-2.2	-2.9	-0.9	-0.7	-0.1	-2.2	
X<55%的判定	-2.06	>	no	<	<	no	<	<	<	<	<	<	<	<	<	<	<	<	<	<	<	<	<	<	<	<	<	<	<	<	
Decision	Art	NON	NON	NON	NON	NON	NON	NON	NON	NON	NON	NON	NON	NON	NON	NON	NON	NON	NON	NON	NON	NON									
Focal Set Model																															
The value of goodness	*	16*	14	2*	16*	14	6	25	8*	17*	16*	20*	12	19*	18*	19*	9*	15*	19*	14*	16*	13*	13	5*	13*	16*	12	9	8*	17*	19
The ratio of goodness	*	0.64	0.28	0.08	0.32	0.28	0.24	1	0.32	0.34	0.32	0.4	0.24	0.76	0.36	0.38	0.36	0.3	0.38	0.28	0.32	0.26	0.2	0.26	0.32	0.24	0.36	0.32	0.34	0.38	
Is it included in CC?	Art	NON	NON	NON	NON	NON	Art	NON	NON	NON	NON	NON	Art	NON																	

Gambar 13.3 Contoh simulasi

Dalam pengujian kami, uji-t satu sisi diterapkan. Persamaan yang digunakan ditulis sebagai berikut:

$$T = \frac{\bar{x} - \mu_0}{\frac{S_n^*}{\sqrt{n}}},$$

di mana  $\bar{x}$  adalah rata-rata setiap subset.  $\mu_0$  adalah ambang batas yang telah kita tetapkan untuk setiap subset.  $S_n^*$  adalah varians sampel yang dimodifikasi dari setiap subset, dan  $n$  adalah jumlah sampel yang digunakan. Tingkat signifikansinya adalah % tergantung pada masalahnya. Mari kita ambil 5% di sini. Maka langkah pengujian dapat disimpulkan sebagai berikut:

Pertama, kami menghitung jumlah rata-rata setiap subset. Selanjutnya kita hitung varians sampel yang dimodifikasi dan nilai T. Jumlah  $\lambda$  dapat ditemukan di Fungsi Excel "TINV". Menurut prinsip uji-t, jika nilai  $T \geq \lambda$  atau  $T \leq -\lambda$ , maka kita menerima hasil sampling jika mean masing-masing lebih besar atau lebih kecil dari threshold. Jika tidak, kami menolak hasilnya, yang berarti bahwa kami harus melanjutkan pengambilan sampel sampai hasil uji-t menerima hasil pengambilan sampel.

### 13.5 SIMULASI

Di bagian ini, kami akan menerapkan model set kasar kami ke situasi klasifikasi kota kreatif buatan (Gambar 3). Pertama kami memilih 30 kota dari dunia. Kemudian kami mengambil sampel 25 kota di setiap kota pada awalnya, yang berarti bahwa kami mengumpulkan jumlah buatan nomor seni publik di setiap kota dan menerapkan angka-angka ini ke model set kasar kami. Setelah kami memasukkan data ke dalam model kami, model akan memulai estimasinya pada klasifikasi data, dan kota yang secara signifikan lebih besar dari ambang batas akan dihitung. Di sisi lain, kota yang secara signifikan lebih kecil dari ambang batas akan dihitung. Akhirnya kita dapat menemukan kota mana yang dapat dimasukkan dalam kelompok Kota Kreatif, dan mana yang tidak dapat dimasukkan.

Misalnya, di kota1, kami memiliki nomor seni publik buatan dari 25 kota sampel. Kami menetapkan ambang batas ke 55 instalasi seni publik untuk mengevaluasi sebuah kota sebagai Kota Kreatif, dan kami mengambil rasio kepercayaan dari uji-t sebagai 5%. Jumlah instalasi seni publik di setiap kota atau setiap kelurahan yang lebih besar dari 55 akan dicantumkan. Misalnya, rasio jumlah kota dengan jumlah seni yang besar dari seluruh kota1 juga akan dicantumkan. Kemudian kami menerapkan model kami untuk analisis nilai seni publik: pertama kami memilih nilai yang lebih besar dari 55. Di kota1, ada 16 sampel lebih besar dari 55. Kemudian kami menghitung rasio kebaikan yaitu 0,64 ( $=16/ 25$ ) (Lihat Gambar 3), tetapi kita harus menguji apakah nilai yang diperoleh benar-benar lebih besar dari ambang batas secara statistik. Kemudian kami menerapkan uji-t rasio kepercayaan satu sisi 5% terhadap hipotesis nol bahwa nilai yang diperoleh sama dengan ambang batas. Hasilnya mengatakan kepada kita bahwa uji-t menolak hipotesis nol. Kemudian, mengingat nilai yang diperoleh lebih besar dari threshold, maka secara statistik dapat disimpulkan bahwa rasio kebaikan di kota1 adalah 0,64, yang jumlahnya lebih besar dari threshold. Maka dapat dikatakan bahwa kota1 telah berkembang menjadi Kota Kreatif sesuai dengan hasil sampel tersebut.

Dari city2 ke city30, kita dapat mengulangi algoritme di atas untuk menganalisis data seni publik dan mendapatkan hasil yang sama seperti yang kita lakukan untuk city1. Akhirnya kita dapat menentukan semua hasil untuk 30 kota.

### 13.6 SISTEM PENDUKUNG KEPUTUSAN

#### Definisi

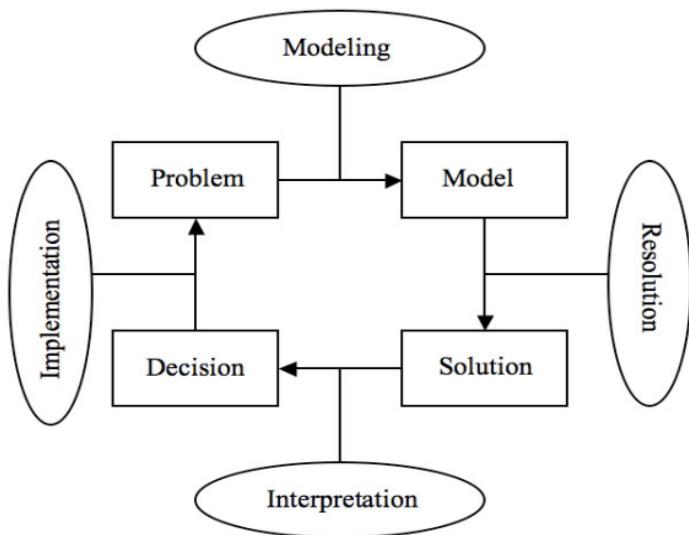
Sistem pendukung keputusan adalah sistem berbasis komputer yang digunakan untuk membantu para pengambil keputusan dalam proses pengambilan keputusan mereka. Berbagai pendekatan untuk definisi sistem pendukung keputusan dibahas dalam [20], [21], dan [22]. Keen dan Scott-Morton (1970) mencatat bahwa sistem pendukung keputusan memainkan peran yang berbeda dan mengusulkan definisi berikut [20], [22], [23], [24]:

*"Sistem pendukung keputusan menggabungkan sumber daya intelektual individu dengan kemampuan komputer untuk meningkatkan kualitas keputusan. Ini adalah dukungan berbasis komputer untuk pengambil keputusan manajemen yang menangani masalah semi-terstruktur."*

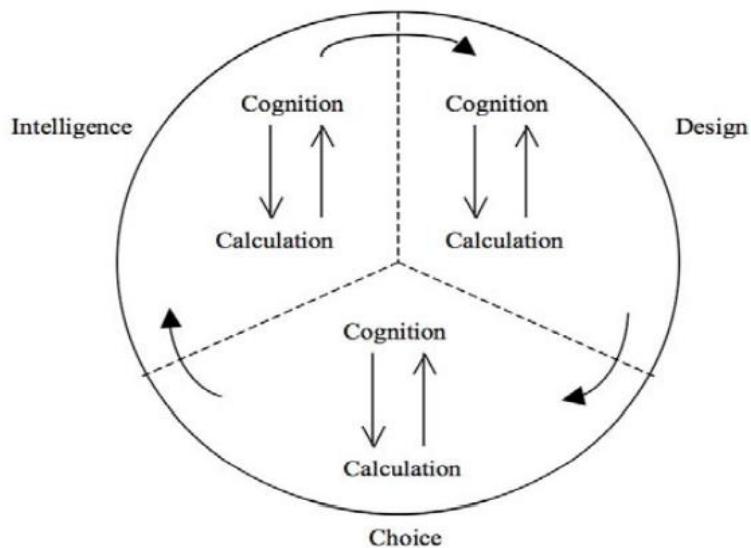
### Model Fase DSS

Sejak awal 1970-an, teknologi dan aplikasi sistem pendukung keputusan telah berkembang secara signifikan. Banyak perkembangan teknologi dan organisasi yang berdampak pada evolusi ini. Awalnya, sistem pendukung keputusan memiliki database dan pemodelan dan fungsionalitas antarmuka pengguna yang terbatas, tetapi inovasi teknologi memungkinkan pengembangan sistem pendukung keputusan yang lebih kuat. Sistem pendukung keputusan, pada kenyataannya, solusi teknologi komputer yang dapat digunakan untuk mendukung pengambilan keputusan yang kompleks dan pemecahan masalah. Pengambilan keputusan adalah studi tentang bagaimana keputusan benar-benar dibuat, dan bagaimana keputusan itu bisa lebih baik, atau lebih berhasil dibuat. Gambar 4 mengilustrasikan proses pengambilan keputusan DSS: begitu masalah dikenali, masalah tersebut didefinisikan dalam istilah yang memfasilitasi pembuatan model. Tahap pemodelan mendefinisikan formalisasi kriteria. Tahap resolusi memaksakan pilihan pendekatan algoritmik yang tepat. Seperangkat proposal keputusan kemudian ditetapkan melalui tahap interpretasi dan disajikan kepada pembuat keputusan yang bersangkutan. Tahap implementasi akhir terdiri dari menerapkan keputusan operasional, mengawasi dampaknya, mengambil tindakan korektif, dan memvalidasi keputusan [25].

Vahidov [26] menyatakan bahwa literatur DSS terutama mengadopsi model tiga fase oleh Simon, yang terdiri dari fase kecerdasan, desain dan pilihan, seperti yang ditunjukkan pada Gambar 5. Secara singkat, fase kecerdasan berkaitan dengan mencari tahu lebih banyak informasi tentang masalah. Fase desain terutama berkaitan dengan menghasilkan keputusan alternatif, dan fase pilihan melibatkan konvergensi pada keputusan akhir. Selama beberapa dekade terakhir, sistem pendukung keputusan, melalui integrasi kecerdasan manusia dan rekayasa perangkat lunak, telah banyak digunakan untuk memecahkan masalah semi-terstruktur atau tidak terstruktur. Pengembangan dan implementasi sistem pendukung keputusan membutuhkan pengetahuan dan pemahaman tentang pengambilan keputusan manajerial, tingkat penalaran, pemecahan masalah dan peran manajer dalam organisasi.



**Gambar 13.4** Proses Pengambilan Keputusan DSS



**Gambar 13.5** Model fase Simon dan tingkat artikulasi

### 13.7 SISTEM INFORMASI GEOGRAFIS

#### Definisi

Sistem informasi geografis adalah kumpulan perangkat keras komputer, perangkat lunak, dan data geografis untuk menangkap, mengelola, menganalisis, dan menampilkan semua bentuk informasi yang bereferensi geografis. Interaksi komponen ini memberikan GIS berbagai aplikasi [27]. Secara khusus, GIS telah diperkenalkan dalam perencanaan kota dengan fungsi memvisualisasikan lanskap masa depan. Sistem ini meningkatkan kualitas proses perencanaan, karena memungkinkan penggunaan penyimpanan data dan output grafik [21].

Sistem informasi geografis berfungsi baik sebagai kotak alat dan database untuk desain dan perencanaan perkotaan. Sebagai kotak alat, GIS memungkinkan perencana untuk melakukan analisis spasial dengan menggunakan fungsi geo-processing atau pemodelan kartografi mereka seperti pengambilan data, overlay peta, konektivitas dan buffer [20].

Peningkatan kecepatan dan penyimpanan data serta penurunan harga workstation dan periferalnya telah membuat GIS terjangkau.

### **Aplikasi GIS dan Pemerintah Daerah**

Kisaran aplikasi GIS di pemerintah daerah cukup besar, termasuk penilaian properti dan persiapan rencana pembangunan. Berbagai implementasi proyek GIS telah menunjukkan bahwa GIS adalah alat penting dalam perencanaan kota. GIS telah menjadi alat dalam pengambilan keputusan bagi otoritas lokal yang harus berurusan dengan serangkaian kriteria yang kompleks untuk konservasi perkotaan. Kemampuan GIS dalam memilih dan mengambil data dalam jumlah besar akan digunakan dalam menganalisis perkembangan tertentu. Dengan menggunakan pendekatan perencanaan terpadu, informasi lain akan ditata ulang ke dalam database, termasuk alokasi penggunaan lahan dan program pembaruan kota, yang dengannya skenario perencanaan masa depan dapat diantisipasi. Ini akan membantu dalam menilai dampak pembangunan kembali berdasarkan pola pertumbuhan yang diprediksi dan diharapkan dari daerah yang bersangkutan [21].

## **13.8 DESAIN PENELITIAN**

### **Metodologi Penelitian**

Penerapan pembangunan perkotaan adalah tugas yang kompleks dan rumit. Desain Kota Kreatif akan terintegrasi dengan berbagai pengetahuan dan database yang beragam. Ini melibatkan berbagai isu termasuk teknik, ekonomi, ekologi, sosiologi, pembangunan perkotaan, seni, desain dan domain lainnya. Selain itu, sulit untuk menetapkan aturan dan kriteria operasional untuk konsep Kota Kreatif, karena memiliki domain yang luas dan batasan yang ambigu. Untuk meningkatkan efisiensi dalam pembangunan kota secara bersamaan, evaluasi dan perangkat keputusan yang tepat perlu disediakan.

Membangun sistem pendukung keputusan untuk pengembangan Kota Kreatif dapat membantu pengambil keputusan untuk memecahkan masalah semi terstruktur dengan menganalisis data secara interaktif. Dalam pekerjaan masa depan, kami berencana untuk mengatasi masalah berikut. Pertama, kita akan mengkaji aturan desain pengembangan Kota Kreatif menurut pakar desain perkotaan. Kedua, kami akan menerapkan teori himpunan kasar untuk memilih aturan keputusan dan mengukur status kota-kota Jepang saat ini. Ketiga, kami akan menginisiasi prototipe sistem pendukung keputusan untuk desain kota kreatif berdasarkan hasil yang diperoleh dari analisis perangkat kasar.

### **Prosedur Penelitian**

Langkah-langkah utama penerapan teori himpunan kasar untuk menemukan aturan keputusan desain kota kreatif tercantum di bawah ini pada Gambar 6:

#### ***Langkah 1. Pengembangan Daftar Atribut***

Kami telah mengembangkan daftar atribut untuk Kota Kreatif. Ini terdiri dari 40 atribut dan dibagi menjadi 8 faktor, seperti yang ditunjukkan pada Tabel 11.

**Tabel 13.11** Daftar Atribut Kota Kreatif

Faktor
Seni
Budaya

Bakat
Teknologi
Efek Ekonomi
Tempat umum
Pengelolaan
Masyarakat sipil

### **Langkah 2. Desain Kuesioner**

Setelah menyelesaikan daftar atribut, kuesioner akan dikembangkan untuk mendapatkan informasi dari masing-masing kota. Ini terdiri dari 10 bagian.

### **Langkah 3. Mencapai Konsensus di antara Para Ahli dengan Metode Delphi**

Pada langkah ini, kami berencana untuk mengumpulkan pendapat dari para ahli perkotaan untuk mencapai konsensus dengan menggunakan metode Delphi.

### **Langkah 4. Menganalisis atribut keputusan Kota Kreatif dengan Proses Hirarki Analitik**

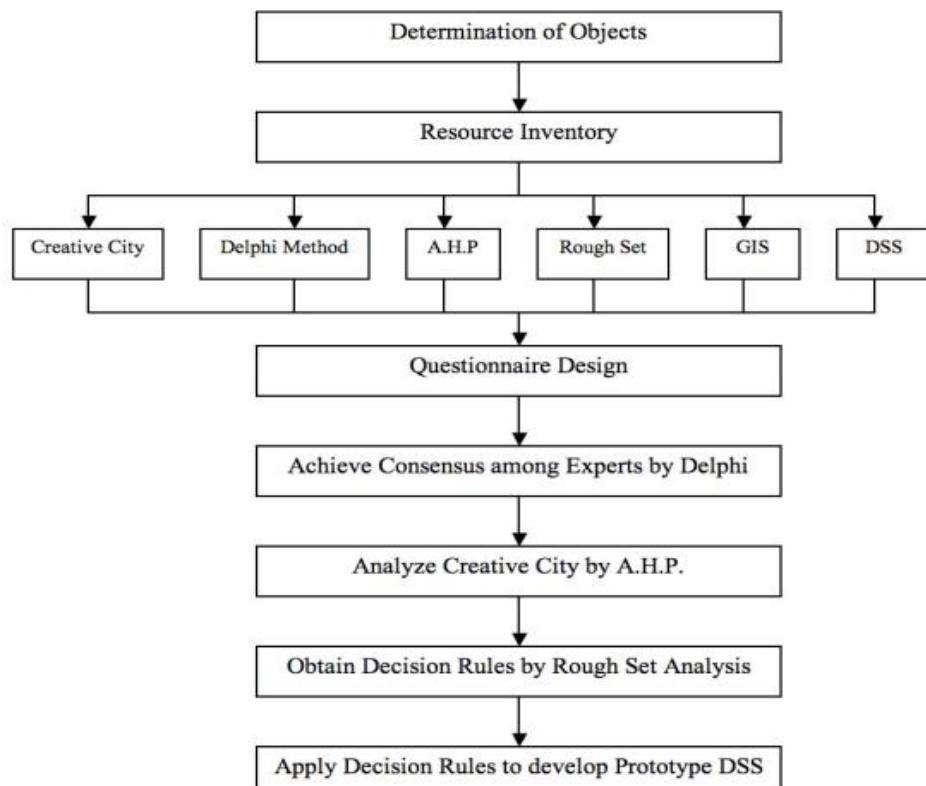
Untuk menganalisis atribut keputusan, kami akan melakukan AHP untuk menguji tingkat kreativitas dari 30 kota sampel. Evaluasi oleh ahli perkotaan akan dikonversi ke nilai numerik.

### **Langkah 5. Menerapkan analisis Rough Set untuk Mendapatkan Aturan Keputusan**

Selanjutnya, kami akan menerapkan analisis himpunan kasar untuk mendapatkan aturan keputusan untuk Kota Kreatif.

### **Langkah 6. Menerapkan Aturan Keputusan untuk Mengembangkan Sistem Pendukung Keputusan Prototipe untuk Desain Kota Kreatif**

Akhirnya, prototipe sistem pendukung keputusan akan dikembangkan berdasarkan aturan keputusan untuk perencanaan kota.

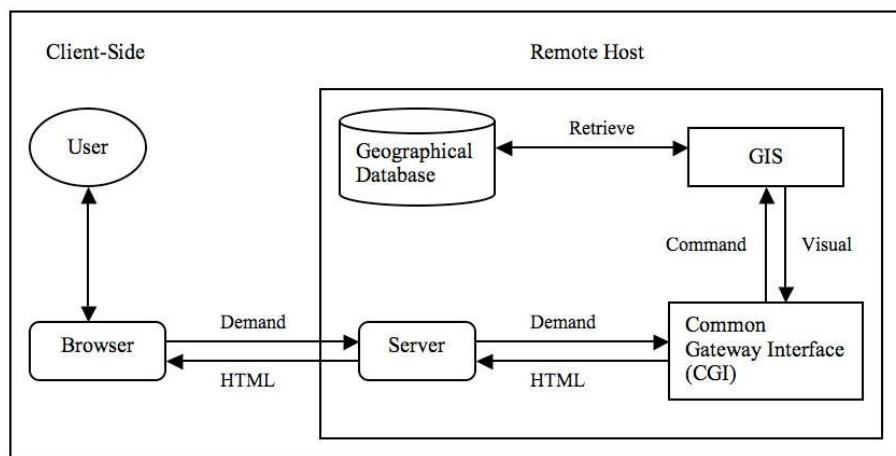


**Gambar 13.6. Prosedur Penelitian**

### 13.9 PROTOTIPE SISTEM PENDUKUNG KEPUTUSAN

#### Arsitektur Umum Sistem Pendukung Keputusan

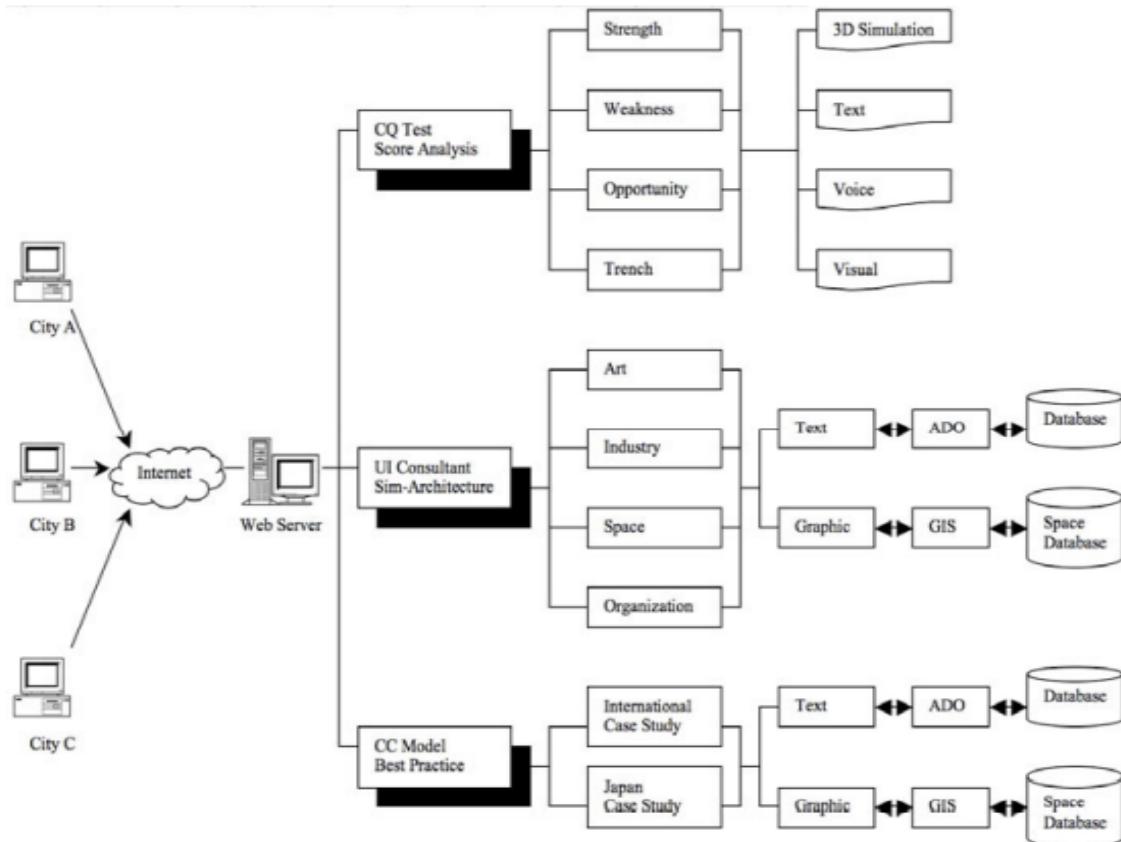
Sistem pendukung keputusan membutuhkan sejumlah besar data untuk melakukan dukungan keputusan yang berkualitas. Dalam metode yang kami usulkan, kami berencana untuk mengembangkan aplikasi GIS untuk desain Kota Kreatif. Misalnya, jika kita memperoleh aturan keputusan dari analisis himpunan kasar yang menunjukkan bahwa atribut revitalisasi bangunan bersejarah penting bagi sebuah kota untuk dianggap sebagai Kota Kreatif, maka penting bagi perencana kota untuk mendesain ulang warisan arsitektur untuk pembangunan kembali kota dengan aplikasi SIG. Masalah lain yang harus ditangani adalah mengembangkan antarmuka pengguna interaktif untuk lebih meningkatkan penggunaan GIS untuk perencanaan kota. Arsitektur umum sistem pendukung keputusan kami disajikan pada Gambar 7.



**Gambar 13.7** Arsitektur Umum Sistem Pendukung Keputusan

#### Membangun Model Sistem Pendukung Keputusan Desain Kota Kreatif

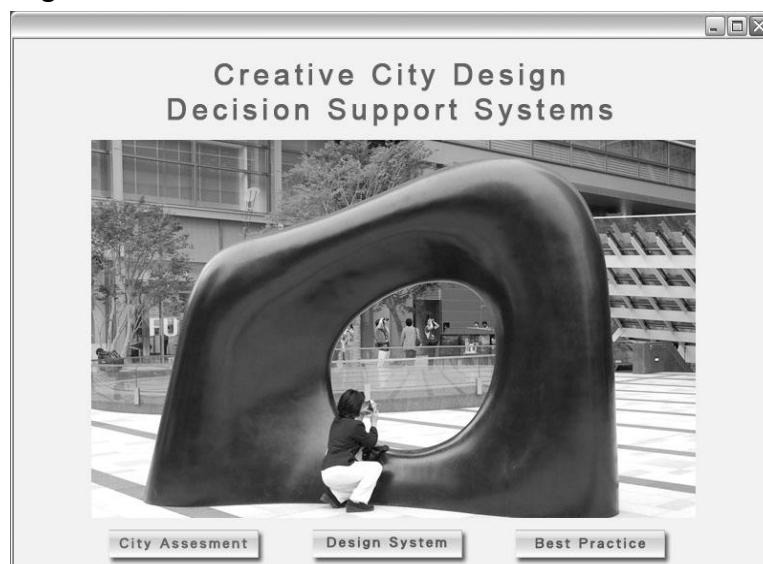
Dalam proyek eksperimental yang kami usulkan, kami berencana untuk mengembangkan sistem pendukung keputusan untuk desain perkotaan. Model prototipe disebut Sistem Inovator Perkotaan, seperti yang ditunjukkan pada Gambar 8. Sistem Inovator Perkotaan akan memberdayakan penerapan pengembangan Kota Kreatif untuk perencana kota. Pada dasarnya, Urban Innovators Systems berperan sebagai konsultan perencanaan kota bagi pemerintah kota. Ini akan terdiri dari tiga fungsi utama dalam Sistem Inovator Perkotaan prototipe kami sebagai berikut:



**Gambar 13.8** Prototype Sistem Pendukung Keputusan Sistem Urban Inovator

#### **Skor Kreativitas Penilaian Kota Kreatif (CQ)**

Dalam Sistem Urban Innovators, kami akan mengembangkan Skor Kecerdasan Kreativitas (CQ) untuk mengukur tingkat kreativitas kota, seperti yang ditunjukkan pada Gambar 9, 10 dan 11. Setelah menyelesaikan tes, kota akan mendapatkan skor untuk Kecerdasan Kreativitasnya.. Selain itu, Sistem Inovator Perkotaan akan memberikan laporan evaluasi untuk kota dengan metode perencanaan strategis SWOT. SWOT adalah singkatan dari Strengths, Weaknesses, Opportunities and Threats. Analisis akan didukung dengan simulasi 3D, teks, suara dan grafik visual.



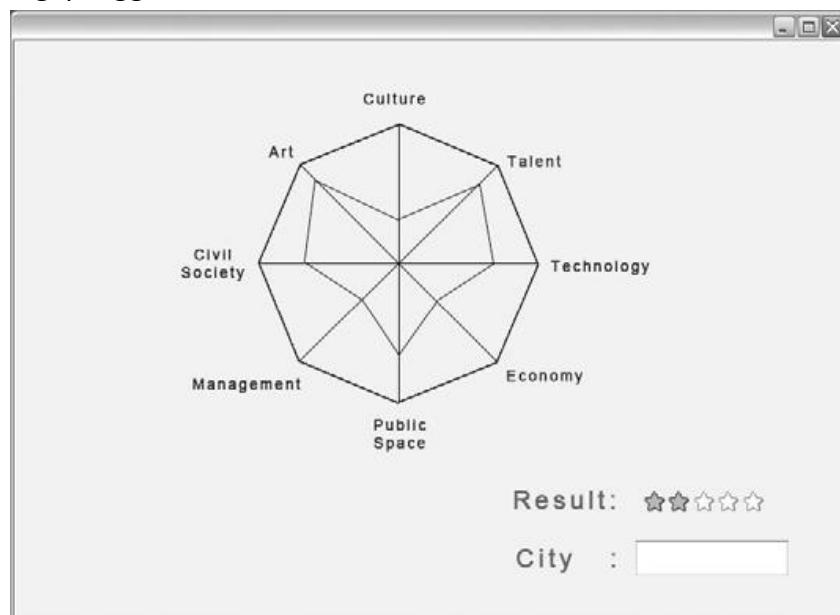
**Gambar 13.9** Contoh Home Page Sistem Desain Kota Kreatif



**Gambar 13.10** Contoh Penilaian Kota Kreatif

#### **Konsultan Inovator Perkotaan**

Fungsi lain dari prototipe Sistem Inovator Perkotaan kami adalah untuk menyediakan kota calon dengan rencana Sim-Arsitektur yang disarankan untuk desain dan perencanaan perkotaan masa depan. Rencananya akan mencakup empat dimensi seni, industri, ruang dan organisasi. Juga, aplikasi GIS akan digunakan dalam sistem untuk menampilkan grafik dan Sim-Arsitektur. Kota dapat memperoleh prinsip desain dari sistem pendukung prototipe seperti yang diilustrasikan pada Gambar 12 dan 13. Contoh menunjukkan saran untuk merancang furnitur jalan bagi pengguna.



**Gambar 13.11** Contoh Hasil Penilaian



**Gambar 13.12** Contoh Toolkit Kota Kreatif

#### **Praktik Kota Kreatif Terbaik**

Selain itu, prototipe Sistem Inovator Perkotaan akan menyediakan database contoh Kota Kreatif yang sukses termasuk aplikasi internasional dan lokal. Perencana kota yang tertarik dengan studi kasus dapat mencari database untuk meninjau praktik terbaik tersebut untuk memiliki pemahaman yang lebih baik tentang pengembangan Kota Kreatif.



**Gambar 13.13** Contoh Toolkit Desain Perabot Jalan

#### **13.10 KESIMPULAN**

Membuat keputusan yang baik membutuhkan pengambil keputusan untuk memahami keadaan dunia saat ini dan masa depan dan cara untuk merumuskan respon yang tepat [28]. Desain Kota Kreatif adalah petualangan yang kompleks dan rumit. Ini akan terintegrasi dengan berbagai pengetahuan dan database yang beragam. Membangun sistem pendukung keputusan untuk desain Kota Kreatif dapat membantu pengambil keputusan untuk memanfaatkan sumber daya dengan teknologi informasi. Penelitian ini mengeksplorasi

kemungkinan baru untuk penerapan sistem pendukung keputusan. Sebuah prototipe Sistem Inovator Perkotaan telah dikembangkan untuk mendukung model partisipasi publik yang kolaboratif ini. Sistem yang baru dimulai ini akan memainkan peran penting dalam merancang Kota Kreatif. Ini menyediakan platform pemecahan masalah interaktif untuk desainer perkotaan dengan menerapkan tiga fungsi utama yang diusulkan: penilaian Kota Kreatif, Sim-Arsitektur dan database praktik terbaik dalam prototipe Sistem Inovator Perkotaan.

Penelitian ini juga bertujuan untuk memberikan metode klasifikasi yang efektif dan akurat berdasarkan uji statistik dengan menerapkan teori himpunan kasar pada berbagai masalah praktis. Salah satu kontribusi dari model yang kami usulkan adalah meningkatkan penerapan analisis himpunan kasar, tetapi ada juga banyak kesulitan dalam menerapkan model yang kami usulkan untuk beberapa masalah praktis. Misalnya, dalam beberapa situasi praktis, pengumpulan data akan menjadi tugas yang sangat besar dan kompleks meskipun metode pengambilan sampel yang diusulkan dapat menyederhanakan prosedur. Jadi, untuk mengatasi kesulitan tersebut, studi lebih lanjut mengenai penerapan analisis himpunan kasar akan diperlukan: kami percaya bahwa algoritma optimal dari model klasifikasi akan dirancang menggunakan teori himpunan kasar dan diterapkan untuk memecahkan beberapa masalah praktis dalam sebuah karya masa depan. Selain itu, prosedur yang disarankan dapat diterapkan tidak hanya untuk atribut keputusan tetapi juga untuk semua atribut kondisi [29].

Sebagai kesimpulan, Kota Kreatif menjelaskan metode baru perencanaan kota strategis dan menunjukkan bagaimana orang dapat berpikir, merencanakan, dan bertindak kreatif di kota. Pembuatan kota yang baik terdiri dari memaksimalkan aset. Dalam membangun Kota Kreatif, kami mengeksplorasi cara membuat kota kami lebih layak huni dan vital dengan menginspirasi imajinasi dan bakat orang. Kreativitas tidak selalu merupakan jawaban atas semua masalah perkotaan kita, tetapi memberikan peluang yang memungkinkan untuk menemukan solusi. Sistem pendukung keputusan yang baik untuk desain Kota Kreatif dapat membantu pengambil keputusan memahami perubahan dinamis dalam asumsi rumit yang diperlukan untuk meningkatkan kualitas keputusan. Keberhasilan sistem pendukung keputusan cerdas sangat tergantung pada kemampuannya untuk memproses data dalam jumlah besar dan mengekstrak pengetahuan yang berguna [30]. Upaya penelitian lebih lanjut diperlukan untuk mengevaluasi efektivitas prototipe Sistem Inovator Perkotaan dan berbagi pengetahuan melalui simulasi.

## BAB 14

### HARGA FUZZY DALAM LELANG KOMBINASI

Lelang kombinatorial mendukung transaksi beberapa item dalam satu penawaran paket. Meskipun demikian, itu tidak mempertimbangkan ketidaktepatan harga. Dalam studi ini, kami mempertimbangkan mekanisme lelang kombinatorial di mana bidder dapat mengajukan beberapa harga per paket, yang mencerminkan nilai pesimis, ideal, dan optimisnya. Selain itu, kami menyediakan operasionalisasi baru pada hubungan pelelang-penawar berdasarkan jenis penawaran atau distribusi kemungkinan segitiga. Dengan memodelkan ketidaktepatan harga dalam 3 model matematika fuzzy yang terpisah, wawasan risiko introspektif dikumpulkan dari masalah pengujian. Secara umum, uji peringkat bertanda Wilcoxon mengungkapkan bahwa penawaran segitiga tidak seimbang kanan lebih menguntungkan bagi juru lelang daripada segitiga tidak seimbang kiri, dengan atau tanpa penawaran penahanan. Pengukuran berulang Generalized Linear Model (GLM) mengkonfirmasi bahwa metode Lai dan Hwang [5] adalah penghindaran risiko, sedangkan metode pusat area adalah pencarian risiko. Metode deterministik yang ideal, di sisi lain, menerima solusi konservatif namun sensitif terhadap tawaran segitiga tidak seimbang kiri. Interval solusi fuzzy memberikan kemampuan negosiasi dan penilaian risiko bagi juru lelang.

#### **14.1 PENDAHULUAN**

Aspek utama dari pengambilan keputusan adalah dalam membuat keputusan pembelian dan penjualan. Semua pihak yang terlibat dalam proses pengambilan keputusan ini akan berusaha memaksimalkan keuntungan masing-masing. Oleh karena itu, pengorbanan harus dipenuhi dengan bantuan sistem formal yang dianggap adil dan adil. Oleh karena itu, beberapa bentuk strategi pengambilan keputusan untuk mendapatkan harga setinggi mungkin untuk suatu barang di pasar dan jangka waktu tertentu dapat dianggap sebagai pengorbanan yang maksimal. Mengalokasikan sumber daya dalam proses pengambilan keputusan seperti itu disebut sebagai lelang. Umumnya lelang terdiri dari juru lelang, penawar dan pasar yang merupakan konteks penjualan barang (misalnya barang mewah, rumah, dll).

Bentuk lelang yang paling sederhana adalah di mana penjual berada di bawah pasar tarikan permintaan. Harga yang ditawarkan oleh pembeli meningkat nilainya secara teoritis maksimum pada akhir lelang. Namun, kondisi pasar jarang menguntungkan penjual atau juru lelang untuk setiap jendela waktu; terutama ketika item mengalami ketidakpastian harga. Fakta ini menjadi lebih rumit ketika seseorang mempertimbangkan satu set barang yang dapat dilelang dalam kombinasi apa pun yang memungkinkan bagi banyak penawar. Oleh karena itu, ketidakpastian setiap item dalam jangka waktu tertentu berkontribusi pada nilai keseluruhan bundel. Untuk alasan ini, tidak mungkin lagi seseorang mengabaikan fakta bahwa barang yang dilelang di bawah lingkungan kabur mungkin memiliki penilaian yang berbeda pada akhir penjualan. Kemudian, hal itu memaksa argumen bahwa harga final memang tidak jelas dan masih harus dinegosiasikan lebih lanjut antara para pihak, penawar dan juru lelang.

Oleh karena itu, tantangannya tidak hanya terletak pada pemodelan masalah lelang kombinatorial tetapi juga memperhitungkan ketidaktepatan harga saat menentukan *Sistem Pendukung Keputusan (Dr Joseph Teguh Santoso dan Budi Hartono, M.Kom)*

pemenang paket yang diterima. Untuk membantu masalah ini, seseorang dapat menggunakan teori himpunan fuzzy, di mana ketidaktepatan dan ketidakpastian dapat diwakili oleh sistem formal. Dalam pemilihan pemenang, sistem lelang fuzzy dapat dikatakan mengamati proses sebagai fenomena negosiasi yang belum didamaikan dan tidak bermaksud menyederhanakan ambiguitas ini di awal. Sebaliknya, ini memberikan tingkat hubungan antara tawaran yang menang (objek) dan konsep harga yang bersangkutan. Konsep subjektif harga seperti harga optimis dan harga ideal atau harga pesimis memiliki tingkat pemahaman yang berbeda bagi penawar yang berbeda. Namun, harga yang diajukan oleh penawar ini memberikan intuisi kepada seluruh kekuatan permintaan dan penawaran pasar untuk juru lelang.

Mungkin tidak tepat; harga fuzzy dipaksa untuk mencapai nilai akhir yang terdiri dari integrasi semua keputusan fuzzy dalam banyak penelitian. Solusi akhir ini dianggap tepat dan merupakan hasil dari apa yang kemudian dikenal sebagai proses defuzzifikasi. Selain beberapa studi signifikan [mis. 6, 8, 9] yang telah menekankan pada proses defuzzifikasi, itu hanya dianggap sebagai sarana untuk mencapai tujuan, mungkin karena prosesnya pada akhirnya membuat pilihan deterministik yang dianggap tidak kabur oleh para puritan. Dalam kasus kami, kami percaya bahwa mencapai harga deterministik melalui upaya komputasi murni tidak memiliki pertimbangan dan fleksibilitas pragmatis terutama di bawah pasar yang bergejolak. Meskipun algoritma penentuan pemenang ada, namun sifatnya yang memunculkan satu harga per penawar menempatkan negosiasi lebih lanjut di bawah tekanan ketika harga pasar bergeser, dan barang saat ini tidak lagi efisien untuk diperdagangkan.

Sejauh pengetahuan kami, kami belum menemukan literatur apa pun yang menyelidiki sifat tawaran dan ketidakpastian harganya dalam pengaturan lelang kombinatorial. Xia dkk. [14] memperkenalkan masalah kompatibilitas insentif dalam harga lelang kombinatorial. Namun, studi terbaru tentang ketidakpastian harga hanya diterapkan pada model pengadaan lelang penawaran sederhana untuk cadangan sistem tenaga [lihat 12]. Meskipun lelang kombinatorial diterapkan pada beberapa konteks: layanan jaringan perdagangan [10] pasar listrik [7], lisensi telekomunikasi [1], dan outsourcing layanan truk [11], tidak ada yang mempertimbangkan ketidaktepatan harga. Upaya terdekat adalah lelang multi-objek yang membawa satu jenis objek di bawah ketidakpastian di setiap lelang berturut-turut [lihat 3].

Ada kekhawatiran lain ketika mempertimbangkan lingkungan fuzzy. Yaitu, bagaimana seseorang dapat mengoperasionalkan sifat penawaran sehingga memperhitungkan risiko dan ketidakpastian pasar? Kedua, bagaimana ketidakpastian ini dapat dimodelkan ke dalam algoritma penentuan pemenang (WDA). Ketiga, mengingat hanya ada sedikit cara untuk memodelkan ketidakpastian, implikasi apa yang akan muncul dari solusi optimalnya? Pada akhirnya, pemilihan penawaran harus memiliki makna yang signifikan dan dalam domain preferensi juru lelang. Seperti dalam kebanyakan penelitian, kinerja metode terbatas pada konteks pengambilan keputusan. Kami menyediakan situasi di mana pengambil keputusan adalah juru lelang yang menerima penawaran paket dari calon penawar dan menjalankan WDA untuk menentukan pemenang tender. Selain itu, juru lelang dapat memperkirakan pendapatannya berdasarkan harga pasar yang tidak tepat yang diajukan untuk bundel item yang berbeda per paket. Makalah ini lebih lanjut menggambarkan bagaimana berbagai model fuzzy WDP mempengaruhi rentang pendapatan (risk spread) untuk jenis tawaran (yaitu berbagai bentuk bilangan fuzzy segitiga).

Sisa makalah ini disusun sebagai berikut: Bagian 2 menguraikan masalah penentuan pemenang (WDP) dan konteks lelang kombinatorial (CA), sementara Bagian 3 memperkenalkan perlakuan dan model fuzzy untuk yang pertama. Bagian 4 merumuskan aspek pemrograman matematika dari bagian 3. Bagian 5 mengoperasionalkan interpretasi harga fuzzy dengan proposisi dan bukti. Prosedur dan hasil tes tercakup dalam Bagian 6. Bagian 7 menyimpulkan makalah.

#### 14.2 LELANG KOMBINASI DAN SOAL PENENTUAN PEMENANG

Ada properti tertentu atau potensi manfaat di CA yang menarik penawar untuk terlibat dalam aktivitasnya. Tersirat dalam paket yang diajukan adalah struktur preferensi penawar. Terutama, penawar dapat mengajukan paket yang terdiri dari beberapa item, di mana paket tersebut bernilai lebih dari item individual yang digabungkan. Situasi ini menunjukkan bahwa barang-barang yang diajukan oleh penawar mungkin memiliki properti pelengkap yang selanjutnya dapat memaksimalkan pendapatan juru lelang.

Dalam hal komplementaritas antar item, penilaian penawaran berlaku:

$$v^j(A) + v^j(B) + \dots + v^j(S) \leq v^j(A \cup B \cup \dots \cup S) \quad \forall j \in N, \quad A, B, \dots, S \in M \quad \text{and} \\ A \cap B \cap \dots \cap S = \emptyset \quad (1)$$

Karena solusinya adalah NP-hard, ada juga tradeoff antara item yang saling melengkapi dan properti pembuangan gratis. Sebuah fungsi penilaian  $v$  memenuhi pembuangan bebas jika  $v(S \cup T) \geq v(s)$  untuk semua kombinasi  $S$  dan  $T$ . Secara khusus, pelepasan item dari kombinasi tidak dapat meningkatkan nilai kombinasi.

Juru lelang memecahkan masalah optimasi kombinatorial untuk memilih penawar yang akan membeli semua barang dengan harga tertinggi. Oleh karena itu, penyelesaian rutin untuk CA disebut sebagai masalah penentuan pemenang (WDP). Ini berusaha untuk menentukan  $v(S) = \max_{j \in N} v^j(S)$ , di mana  $S$  adalah subset atau paket dari  $M$  objek berbeda yang diajukan oleh  $N$  penawar.

Dari perspektif pemrograman matematis, ini dapat diformalkan sebagai Program Integer (IP) dengan variabel keputusan biner yang sama dengan 1 jika dan hanya jika penawar  $j$  menyediakan paket  $S \subseteq M$ . Hal ini tercermin dalam rangkaian batasan pertama yang secara sederhana menunjukkan bahwa tidak ada paket yang dapat diberikan kepada lebih dari 1 penawar. Fungsi tujuan memaksimalkan pendapatan atau nilai tawaran sebagai berikut:

$$\begin{aligned} & \max \sum_{S \subseteq M} v(S) \cdot x_S \\ \text{s.t. } & \sum_{s \ni i} x_s \leq 1 \quad \forall i \in M \\ & x_s \in \{0, 1\} \quad \forall s \subseteq M \end{aligned} \quad (2)$$

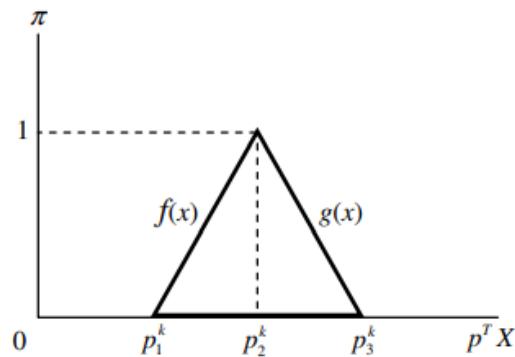
Solusi WDP tetap merupakan alokasi yang efisien dari item lelang yang tidak dapat dibagi. Mengingat dua alokasi yang layak, kita dapat mendefinisikan bahwa alokasi dengan nilai fungsi tujuan yang lebih tinggi memiliki efisiensi yang lebih besar.

### 14.3 KOMBINASI LELANG DAN PENENTUAN PEMENANG DALAM LINGKUNGAN FUZZY

Dalam perspektif yang lebih ketat, keputusan untuk memberikan satu set item kepada pemenang adalah tujuan akhir dari pelelangan. Namun, lelang juga dapat digunakan sebagai metode estimasi pendapatan yang besar bagi juru lelang. Pertimbangkan kasus di mana pelelang yang memiliki reputasi baik memiliki satu set barang yang akan dijual, di mana harga barang berfluktuasi sesuai dengan kondisi pasar. Kami berasumsi bahwa strategi pengisian stoknya didasarkan pada hasil lelang. Karena volatilitas pasar tinggi dan ada jeda waktu antara pelaksanaan lelang dan penentuan pemenang, kemungkinan harga yang diajukan oleh penawar tidak akan berada dalam penilaian awal yang menguntungkan mereka. Hal ini mengakibatkan tidak ada penjualan. Potensi larangan penjualan lainnya yang dapat terjadi adalah ketika harga pasar turun secara signifikan lebih rendah dari harga penawaran. Untuk juru lelang yang tidak memiliki persediaan yang memadai, ini berarti bahwa ia harus membeli dengan harga lebih tinggi dari pemasoknya dan menjual dengan harga lebih rendah kepada penawar jika ia masih berniat untuk menghormati kontrak lelang. Dalam keadaan seperti itu, seseorang harus melihat lelang sebagai sarana dan bukan tujuan itu sendiri. Artinya, ini harus dianggap sebagai perkiraan yang meramalkan pemenuhan pesanan untuk juru lelang, sambil memberikan penawar yang menang untuk memiliki hak untuk menegosiasikan harga lebih lanjut. Ini karena setiap penawar mungkin memiliki beberapa pengetahuan pribadi yang secara total akan memungkinkan juru lelang untuk menentukan penilaian relatif barang, dan dengan demikian secara efektif merencanakan kegiatan pengadaannya sendiri sebelumnya. Untuk mencegah tidak ada penjualan, diusulkan agar seseorang dapat mengizinkan pengajuan beberapa harga per format paket. Harga yang diajukan bisa dalam bentuk  $\tilde{P} = (p_1^k, p_2^k, p_3^k)$ , ,  $p_1$ , dan  $p_3$  adalah harga terendah dan tertinggi untuk paket k yang ingin diterima oleh penawar dalam kondisi pasar terburuk dan terbaik.  $p_2$  adalah harga saat ini yang diajukan di bawah iklim ekonomi saat ini. Oleh karena itu, kami memperkenalkan beberapa konsep fuzzy untuk memodelkan masalah ini.

#### Harga Fuzzy

Kita dapat mendefinisikan harga fuzzy sebagai kombinasi dari dua fungsi:  $f$  dan  $g$  dengan  $p_2^k$  menjadi batas umum interval  $[p_1^k, p_3^k]$  untuk harga fuzzy  $\tilde{P}$  (lihat Gambar 1). Jadi, paket yang dikirimkan akan memiliki bilangan fuzzy dengan fungsi yang sesuai  $N(p_1^k, p_2^k, p_3^k; f, g)$ .



**Gambar 14.1.** Harga fuzzy

Bilangan fuzzy yang didefinisikan dengan pendekatan ini bergantung pada  $L_s, R_s > 0$ , dimana spread kiri dan kanan masing-masing dinotasikan sebagai  $d_s^- = (p_2^k - p_1^k)$  dan  $d_s^+ = (p_3^k - p_2^k)$ . Sisi-sisi bilangan fuzzy adalah linier:

$$f(x) = L\left(\frac{p_2^k - x}{d_s^-}\right) \quad \text{and} \quad g(x) = R\left(\frac{x - p_2^k}{d_s^+}\right) \quad (3)$$

Harga fuzzy segitiga  $\tilde{P} = (p_1^k, p_2^k, p_3^k)$  adalah representasi paling sederhana dari bilangan fuzzy, karena properti linieritasnya, yaitu:

$$f(x) = g(x) = \max\{0, 1-x\}. \quad (4)$$

### WDP Fuzzy (Model 1)

Jelas, fungsi tujuan dari (2) harus diganti dengan (5) untuk memenuhi koefisien harga yang tidak tepat

$$\max \sum_{S \subseteq M} (p_1^k, p_2^k, p_3^k)(S) \cdot x_S \quad (5)$$

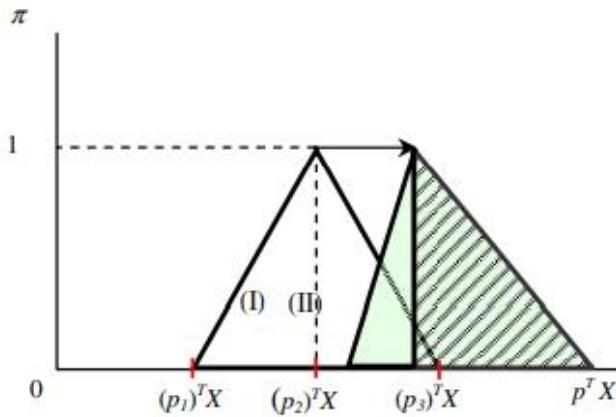
Dari sudut pandang juru lelang,  $p_2$  merupakan nilai yang paling mungkin (kemungkinan=1 jika dinormalisasi),  $p_3$  nilai yang paling pesimis dan  $p_1$  nilai yang paling optimis yang dapat dicapai. Pendekatan menggunakan distribusi segitiga fuzzy untuk memodelkan ketidakakuratan koefisien biaya pertama kali diperkenalkan oleh Lai dan Hwang [5]. Kami menggambarkan bahwa itu dapat diterapkan pada lelang kombinatorial dengan mengubahnya menjadi fungsi tujuan dari masalah bantu yang mirip dengan Lai dan Hwang [5] sebagai berikut:

$$Z_1 = \min (p_2 - p_1)^T x_s, \quad (6)$$

$$Z_2 = \max (p_2)^T x_s, \quad (7)$$

$$Z_3 = \max (p_3 - p_2)^T x_s, \quad (8)$$

Metode untuk menangani keuntungan unit yang tidak tepat yang diusulkan oleh Lai dan Hwang [5] memberikan strategi untuk meminimalkan wilayah I, sekaligus memaksimalkan wilayah II (lihat Gambar 2). Hal ini memungkinkan solusi untuk mencari kemungkinan memperoleh tawaran yang menguntungkan juru lelang tanpa mengabaikan risiko yang melekat pada penyebaran harga yang diajukan.



**Gambar 14.2** Memaksimalkan Laba Tidak Tepat

Dalam fuzzy CA WDP, bidder diperbolehkan untuk mengajukan beberapa harga untuk setiap paket. Oleh karena itu, fuzzy WDP menemukan solusi optimal di antara harga dari beberapa kombinasi item yang menghasilkan perkiraan paling konservatif untuk juru lelang, yang didasarkan pada penyebaran harga. Oleh karena itu, persamaan (7) mencari ruang yang layak dalam distribusi kemungkinan untuk kemungkinan memaksimalkan pendapatan berdasarkan ekspektasi rata-rata. Persamaan (6) meminimalkan daerah yang layak untuk memperoleh pendapatan yang lebih rendah dari rata-rata, sedangkan persamaan (8) memaksimalkan kemungkinan untuk memperoleh pendapatan yang lebih tinggi dari rata-rata. Masalah yang tampaknya multiobjektif ini dapat direduksi menjadi model matematika tunggal dari:

$$\begin{aligned} \max \quad & \alpha \\ \text{s.t. } & \alpha \leq \mu_{zi}, \quad i = 1, 2, 3. \\ & x \in X. \end{aligned} \quad (7)$$

dimana  $\mu_{zi}$  diturunkan dengan menetapkan rentang terbaik dan terburuk ketika masing-masing  $Z_i$  dimaksimalkan dan diminimalkan sambil mempertahankan konstan kendala lain dalam model [lihat 15]. Fungsi keanggotaan pesimis dan optimis adalah sebagai berikut:

$$\mu_{zi} = \begin{cases} 1 & \text{if } Z_i < Z_i^+, \\ \frac{Z_i^- - Z_i}{Z_i^- - Z_i^+} & \text{if } Z_i^+ \leq Z_i \leq Z_i^-, \\ 0 & \text{if } Z_i > Z_i^-. \end{cases} \quad (8)$$

$$\mu_{zi} = \begin{cases} 1 & \text{if } Z_i^+ < Z_i, \\ \frac{Z_i - Z_i^-}{Z_i^+ - Z_i^-} & \text{if } Z_i^+ \leq Z_i \leq Z_i^-, \\ 0 & \text{if } Z_i^- < Z_i. \end{cases} \quad (9)$$

### WDP Fuzzy (Model 2)

Metode pemrograman matematika fuzzy lain yang dapat digunakan untuk menyelesaikan masalah harga fuzzy adalah dengan mendapatkan defuzzifikasi  $\tilde{P} = (p_1^k, p_2^k, p_3^k)$  dan selanjutnya menyelesaiakannya sebagai masalah deterministik yang tajam.

$$\begin{aligned} \max & \sum_{S \subseteq M} \tilde{P}(S) \cdot x_S \\ \text{s.t. } & x \in X \end{aligned} \quad (10)$$

Metode center of area (COA) digunakan untuk proses defuzzifikasi  $\tilde{P}$  menjadi  $P$  sebagai berikut:

$$P^k = \left[ \frac{(p_2 - p_1) + (p_3 - p_1)}{3} \right] + p_1 \quad (11)$$

Prosedur untuk defuzzifikasi di atas juga disebut sebagai mencari nilai kinerja nonfuzzy terbaik (BNP). Ada beberapa metode defuzzifikasi seperti mean of maximal (MOM), center of area (COA) dan -cut. Penelitian ini menggunakan COA karena kelayakan dan popularitasnya yang luas. Metode COA untuk defuzzifikasi telah digunakan dalam beberapa aplikasi: perencanaan dan pemilihan desain tender [4], penerapan strategi pengembangan perikanan [2] dan evaluasi perusahaan manufaktur [13].

### WDP Fuzzy (Model 3)

Kami menyediakan model lain di mana harga ideal  $P_2^k$  diasumsikan BNP. Pada kasus ini,

$$\begin{aligned} \max & \sum_{S \subseteq M} p_2^k(S) \cdot x_S \\ \text{s.t. } & x \in X \end{aligned} \quad (12)$$

## 14.4 FORMULASI MODEL

Kami memformalkan notasi berikut.

### indeks

K : Set paket C : Set penawar

### Parameter

Himpunan bundel tawaran adalah  $B^k$  dapat ditentukan sebagai 2-tupel  $({}_c a^k, {}_c p^k)$  dimana

- ${}_c a^k = ({}_c a_i^k, \dots, {}_c a_n^k)$  dengan  ${}_c a^k \in (\mathbb{R}^+)^{mxn}$ :  ${}_c a^k$  adalah jumlah unit yang diterima dari penawar c yang sedang ditawar sebagai bagian dari paket k .
- ${}_c p^k = ({}_c p_i^k, \dots, {}_c p_n^k)$  dengan  ${}_c p^k \in (\mathbb{R}^+)^{mxn}$ :  ${}_c p_i^k$  adalah harga penawaran dari penawar c sebagai bagian dari penawaran paket k .

### Variabel Keputusan

Variabel keputusan yang sesuai dengan setiap tawaran  ${}_c x^k$  adalah status paket k yang diterima dari penawar c.

*Model 1:* Model Fuzzy (Lai dan Hwang, 1993)

$$\text{Min } Z_1 = \sum_{c=1}^{\text{bidders}} \sum_{k=1}^{\text{package}} \left( {}_c p_1^k - {}_c p_2^k \right) {}_c x^k \quad (13)$$

$$\text{Max } Z_2 = \sum_{c=1}^{\text{bidders}} \sum_{k=1}^{\text{package}} \left( {}_c p_2^k \right) {}_c x^k \quad (14)$$

$$\text{Max } Z_3 = \sum_{c=1}^{\text{bidders}} \sum_{k=1}^{\text{package}} \left( {}_c p_3^k - {}_c p_2^k \right) {}_c x^k \quad (15)$$

$$\text{s.t.} \quad \sum_{c=1}^{\text{bidders}} \sum_{k=1}^{\text{package}} {}_c a_i^k {}_c x^k \geq {}_c a_i^k \quad (16)$$

$${}_c x^k = \{0,1\} \quad (17)$$

*Model 2:* Model Pusat Area

$$\text{Max} \quad \sum_{c=1}^{\text{bidders}} \sum_{k=1}^{\text{package}} \left\{ \left[ \frac{\left( {}_c p_2^k - {}_c p_1^k \right) + \left( {}_c p_3^k - {}_c p_1^k \right)}{3} \right] + {}_c p_1^k \right\} \left( {}_c x^k \right) \quad (18)$$

*Model 3:* Harga Ideal sebagai BNP

$$\text{Max} \quad \sum_{c=1}^{\text{bidders}} \sum_{k=1}^{\text{package}} {}_c p_2^k {}_c x^k \quad (19)$$

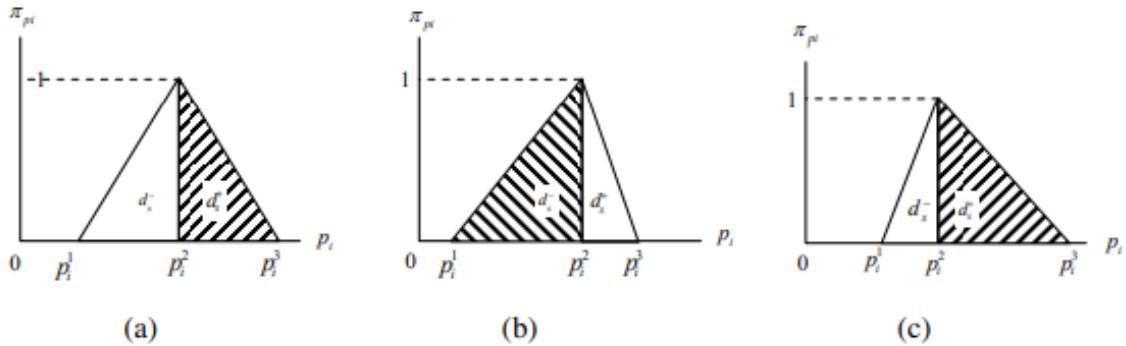
$$\text{s.t.} \quad (16) \text{ and } (17)$$

Dalam Model 2 dan Model 3, persamaan fungsi tujuan (18-19) memaksimalkan keuntungan penjual (atau juru lelang). Persamaan (16) memastikan bahwa semua penawaran yang tersedia dari juru lelang telah diselesaikan. Persamaan (17) memverifikasi apakah penawar diberikan tawaran paket. Dalam Model fuzzy 1, fungsi tujuan (18-19) diganti dengan (13-15), yang sesuai dengan (6-8).

#### 14.5 INTERPRETASI HARGA YANG DIAJUKAN

Untuk mempelajari kinerja model dan memperoleh implikasi darinya, prosedur pembuatan data perlu sampai batas tertentu secara akurat mewakili penawaran dan perilaku pasar. Kami menyajikan definisi kerja untuk data.

**Definisi 1.** Telah ditetapkan bahwa format harga yang diajukan untuk suatu paket oleh himpunan penawar adalah dalam bentuk  $\tilde{P} = (p_1^k, p_2^k, p_3^k)$ . Juga, kesenjangan waktu antara panggilan untuk tender dan pemberian penjualan akan mempengaruhi harga pasar barang. Tiga kemungkinan kondisi pasar dibedakan berdasarkan spread masing-masing  $d_s^- = (p_2^k - p_1^k)$  dan  $d_s^+ = (p_3^k - p_2^k)$ .



**Gambar 14.3** (a) Segitiga sama kaki (Kasus 1). (b) Segitiga kiri tidak seimbang (Kasus 2). (c) Segitiga siku-siku tidak seimbang (Kasus 3).

**Kasus 1.** Dalam hal penawaran bidder dalam bentuk  $d_s^- = d_s^+$ , bidder menyampaikan kepada juru lelang bahwa ia ingin dapat menurunkan harganya pada tingkat yang sama dengan keinginannya untuk menaikkan harganya. Namun, penawar yang rasional akan lebih memilih untuk mencapai nilai yang lebih dekat dengan pk sementara juru lelang ingin bernegosiasi menuju  $p_3^k$ . Tergantung pada apakah permintaan pasar pada waktu tertentu adalah bidder push atau pull, harga akhir yang diberikan dari setiap tawaran yang menang akan berada dalam interval  $[p_1^k, p_3^k]$ .

**Kasus 2.** Ketika  $d_s^- < d_s^+$ , seorang penawar yang rasional mencoba untuk mengkomunikasikan bahwa ia percaya bahwa harga yang ditawarkannya kepada juru lelang relatif lebih rendah daripada harga pasar. Untuk membenarkan hal ini, penawar tidak keberatan merevisi harganya ke atas dan menerima harga yang lebih tinggi jika permintaan pasar meningkat.

**Kasus 3.** Ketika  $d_s^- > d_s^+$ , penawar secara implisit mengomunikasikan bahwa harga pasar paket barang saat ini tinggi tetapi ia yakin dapat menurunkan harganya secara signifikan jika harga pasar turun dalam waktu dekat. Penawar rasional yang mengajukan dengan cara ini ingin memenangkan hak penolakan pertama, mengetahui bahwa juru lelang akan memberikan penawaran dengan harga terendah namun memberikan opsi untuk merevisi harga ke atas.

**Proposisi 1.** Penawar rasional Kasus 3 memiliki efisiensi ekonomi yang lebih rendah dibandingkan dengan penawar rasional Kasus 2 jika kedua kasus memiliki  $p_2^k$  yang kurang lebih sama, dan juru lelang menghindari risiko.

**Bukti 1.** Misalkan  $A = (p_{1a}^k, p_{2a}^k, p_{3a}^k)$  dan  $B = (p_{1b}^k, p_{2b}^k, p_{3b}^k)$  merupakan bagian dari penawaran yang diajukan oleh penawar A dan B dari Kasus 2 dan Kasus 3, masing-masing. Ketika  $p_2^k$  untuk A dan B kira-kira sama,  $p_{1b}^k < p_{1a}^k$  dan  $[p_{2a}^k + (p_{3a}^k - p_{1a}^k)] < p_{3b}^k \leq \infty$ .

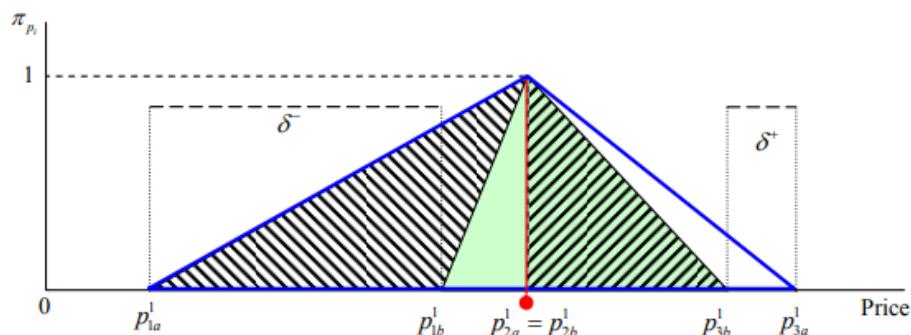
Sangat mudah untuk mengamati itu  $\left[ p_{2a}^k + (p_{2a}^k - p_{1a}^k) \right] = p_{3a}^k$  adalah syarat segitiga simetris. Kemudian, untuk  $p_{3b}^k > p_{3a}^k$ , potensi keuntungan lebih rendah dari potensi kerugian  $|p_{3b}^k - p_{3a}^k| < |p_{1b}^k - p_{1a}^k|$ . Untuk juru lelang yang menghindari risiko, hanya rasional jika Kasus 2 dipilih daripada Kasus 3.

**Proposisi 2.** Dari bukti dan kasus sebelumnya, kita dapat membandingkan solusi dari 3 model dan membuktikan sifat-sifatnya berdasarkan kontinum penghindaran risiko hingga pencarian risiko. Solusi optimal penentuan pemenang dikatakan memberikan penawaran yang menang dalam bentuk  $X = (x_1, \dots, x_3)^T$ , dimana:

$$\tilde{P}X_i = \left( \sum_{n=1}^{\text{winning packages}} (p_1 + \dots + p_{1n}), \sum_{n=1}^{\text{winning packages}} (p_2 + \dots + p_{2n}), \sum_{n=1}^{\text{winning packages}} (p_3 + \dots + p_{3n}), \right)$$

tetap menjadi solusi segitiga kabur dari perkiraan pendapatan juru lelang dalam pelaksanaan lelang. Biarkan  $PXi$  menjadi solusi yang dihasilkan oleh Fuzzy WDP ( $i = 1$ ), COA ( $i = 2$ ) dan model ideal ( $i = 3$ ). Dan, pertimbangkan peristiwa di mana Kasus 2 secara signifikan terkandung dalam Kasus 3, yaitu.  $p_1^{LU} \leq p_1^{RU}$  dan  $p_3^{RU} \geq p_3^{LU}$  tapi  $p_3^{RU} - p_3^{LU} < p_1^{RU} - p_1^{LU}$ . Kemudian, jika solusi  $A(\tilde{P}X_i^{LU} > \tilde{P}X_i^{RU})$ , pendapatan diperkirakan juru lelang dengan model  $i$  lebih tinggi di segitiga tidak seimbang kiri lebih besar dari segitiga tidak seimbang kanan, dan sebaliknya untuk solusi  $B(\tilde{P}X_i^{LU} < \tilde{P}X_i^{RU})$ . Model yang menghasilkan solusi dalam bentuk A adalah dikatakan lebih rasional dan menghindari risiko daripada B. Model 1 dianggap risk averse sedangkan Model 2 dan 3 risk seeker.

**Bukti 2.** Solusi Model 1 memperhitungkan tradeoff antara maks  $\delta^+$  dan min  $\delta^-$  (lihat Gambar 3). Kemungkinan memperoleh keuntungan yang lebih tinggi ditimbang terhadap kemungkinan mencapai pendapatan kurang dari rata-rata (lihat persamaan 13, 15). Sebaliknya, Model 2 dan Model 3 rentan terhadap pengaruh ketidakseimbangan harga yang diajukan. Karena properti rata-rata, Model 3 memberikan nilai defuzzified dari  $*p_2^k$ , sehingga  $*p_2^k < p_2^k$  ketika  $d_s^- > d_s^+$ , dan sebaliknya berlaku. Semakin besar tail-off atau ketidakseimbangan, semakin besar kemiringannya. Dalam hal Kasus 2 secara signifikan terkandung dalam Kasus 3 seperti yang ditunjukkan pada Gambar 4, Model 2 akan menghasilkan pendapatan yang lebih rendah sebagai  $\delta^- < \delta^+$ . Karena Model 3 secara efektif memanfaatkan harga tengah yang diajukan oleh bidder, hal ini sama saja dengan mengabaikan  $\delta^- < \delta^+$ . Oleh karena itu, ini membuktikan bahwa Model 2 dan 3 adalah risk seeker, sedangkan Model 1 adalah risk averse.



Gambar 14.4 Tawaran Penahanan

**Proposisi 3.** Karena spread  $d_s^-$  dan  $d_s^+$  dikaitkan dengan risiko, fungsi tujuan akhir adalah estimasi interval pendapatan juru lelang.

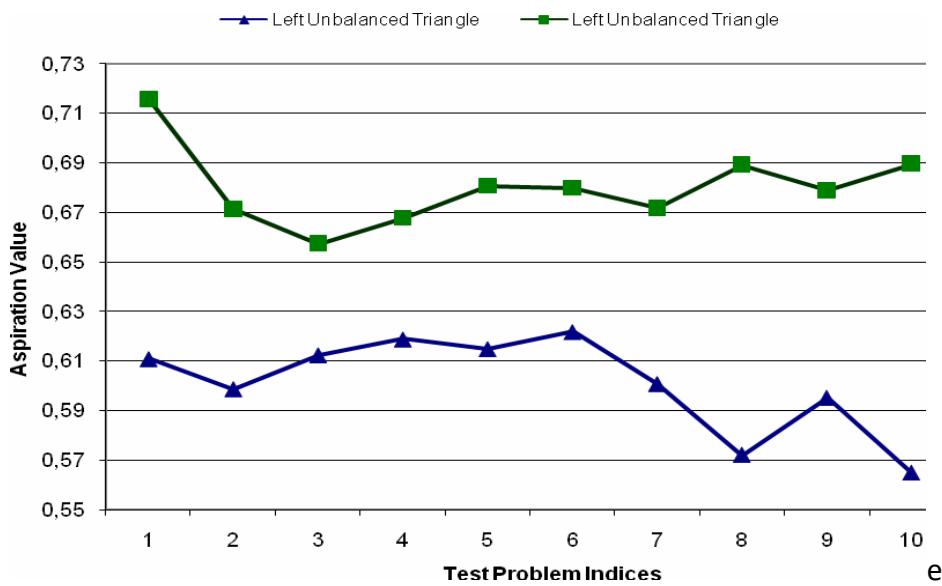
**Bukti 3.** Biarkan  $Y^*=\{x^1 \dots x^n\}$  menjadi solusi optimal dari paket pemenang yang dihasilkan dari program matematika apa pun. Hampir sepele untuk mengamati bahwa fungsi tujuan akhir akan berada dalam kisaran  $Z = [p_1^k Y^*, p_3^k Y^*]$

#### 14.6 TES GENERASI MASALAH

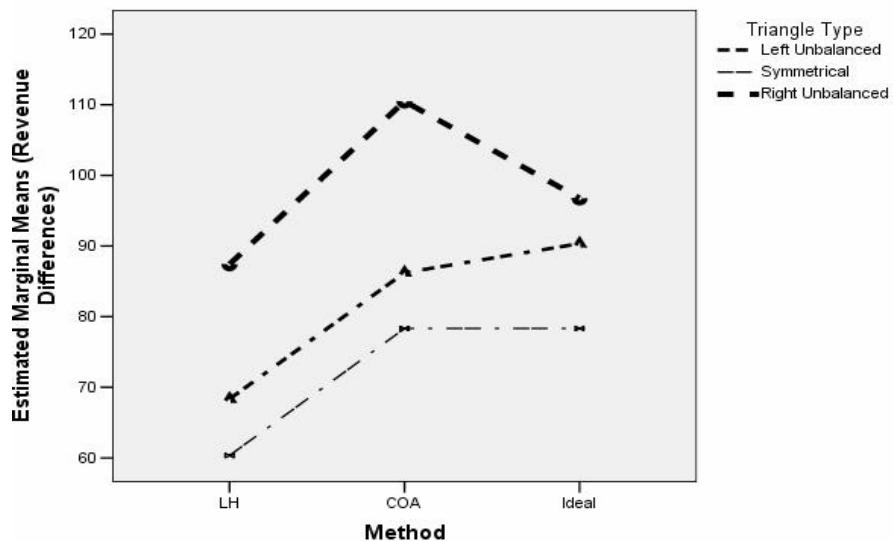
Dalam prosedur pengujian kami, kami menghasilkan data untuk lingkungan lelang fuzzy melalui MATLAB (R2006b). Prosedur umum dapat dibagi menjadi 3 bagian seperti yang ditentukan dalam Tabel 1 untuk 3 kondisi penawaran Kasus 1, Kasus 2 dan Kasus 3 seperti yang diperkenalkan pada Bagian 5. Tabel 2 dan Tabel 3 mengkonfirmasi Bukti 1 dan Bukti 2, di mana mudah untuk mengamati bahwa segitiga tidak seimbang kanan (RUT) mendominasi segitiga tidak seimbang kiri (LUT) untuk semua teknik yang dipertimbangkan di masing-masing 10-tes masalah (lihat juga Gambar 5). Selain itu, kami melakukan dua tes peringkat bertanda Wilcoxon dengan 10 sampel terkait untuk Bukti 1 dan 2, masing-masing. Tes peringkat bertanda Wilcoxon dipilih daripada ekuivalen parametrik dari uji t siswa berpasangan karena yang pertama tidak memerlukan penetapan asumsi distribusi pengukuran. Dalam kedua kasus, dengan dan tanpa tawaran penahanan, RUT memberikan tingkat pencapaian yang jauh lebih besar daripada LUT pada  $Z=-2.803$ ,  $p < .01$ . Karena tingkat pencapaian juru lelang lebih besar hanya ketika pendapatan yang diterimanya lebih tinggi, hal itu kembali menegaskan Bukti 1, di mana penawar rasional Kasus 2 memiliki efisiensi ekonomi yang lebih besar dibandingkan dengan Kasus 3.

**Tabel 14.1** Prosedur Pembuatan Data

Step 1	Step 2	Step 3
<pre> Procedure Volume Bid Generation BEGIN     Initialize No. of Items=10, No. of Buyers=100,     Auctioneer's interested volume for each item     := random generate a = [1,1000]     Bidders units:= random generate r = [1,10]     IF r &lt; 5,         bidders bid exact amount allocated by auctioner,     ELSE         Random generate e = [1,100]         IF e &lt; 80,             Bidders do not accept the item,         ELSE             Random generate w = [1,70]             Calculate bidders interested volume for item as             v = 0.1*w*a         END     END STOP </pre>	<pre> Procedure Bidder Price Generation BEGIN     Initialize price index i for each item in an i+1 increase     Compute standard package s_p = i*a     Mean price :=random generate d = [1,20]     Compute bidders ideal price     s_q = 0.01*[ s_p + (0.01*d*s_p) ]     Pessimistic price :=random generate d' = [1,20]     s'_q = s_q - (0.01*d'*s_q)     Optimistic price :=random generate d'' = [1,20]     s''_q = s_q + (0.01*d''*s_q)     END STOP </pre> <p><i>Note:</i>  For isosceles prices, <math>s_q - s'_q = s''_q - s_q</math>  For left unbalanced, <math>s_q - s'_q &gt; s''_q - s_q</math>  For right unbalanced, <math>s_q - s'_q &lt; s''_q - s_q</math> </p>	<pre> Procedure Price of Package BEGIN     Compute price for package-     Mean = s_p * v     Pessimistic = s_q * v     Optimistic = s''_q * v STOP </pre>



**Gambar 14.5** Nilai Aspirasi: Kiri Vs. Tawaran Segitiga Tidak Seimbang Kanan



**Gambar 14.6** Perbedaan Rentang Pendapatan di Seluruh Metode dan Jenis Penawaran

**Tabel 14.2** Solusi Penentuan Pemenang: Segitiga Seimbang Kiri vs. Kanan

0	Kiri Tidak Seimbang				Kanan Tidak Seimbang			
	I	L&H	COA	Ideal	I	L&H	COA	Ideal
1	0.6109193	(201.7439, 241.2619, 277.5001)	(258.3468, 328.3324, 361.0976)	(266.499, 323.7329, 348.2986)	0.7157933	(276.8351, 292.8978, 366.4534)	(295.5672, 328.3324, 398.318)	(299.1672, 323.7329, 380.9668)
2	0.5987357	(137.4778, 167.2098, 192.8141)	(199.4716, 253.5958, 290.1544)	(192.571, 258.498, 292.754)	0.6713493	(207.537, 220.9594, 272.233)	(223.2093, 255.9842, 318.2502)	(224.242, 258.498, 324.425)
3	0.6125091	(191.2112, 222.43, 263.3621)	(214.4874, 263.7796,	(196.7485, 263.7796, 0.6573657)	0.6573657	(216.6535, 232.0345, 263.7796,	(235.3808, 263.7796, 263.7796,	(235.3808, 263.7796, 263.7796,

		249.9259)	285.6075)	292.1784)		285.6259)	330.8107)	330.8107)
4	0.6188817	(160.9487, 190.5192, 217.3667)	(219.504, 266.5959, 296.7208)	(202.0532, 269.8248, 294.0549)	0.6678163	(214.4305, 228.8277, 283.9942)	(252.0961, 274.9946, 340.9672)	(245.5947, 269.8248, 337.5964)
5	0.6149769	(174.9002, 209.6325, 241.733)	(243.0223, 301.5646, 340.3477)	(239.2299, 302.221, 342.6049)	0.680795	(220.0786, 236.7228, 298.3768)	(281.5663, 298.3046, 340.679)	(261.8371, 302.221, 365.2121)
6	0.6219031	(151.2112, 182.1666, 208.9371)	(226.5559, 274.0654, 307.9014)	(207.4193, 262.0536, 304.6458)	0.6799682	(192.8652, 209.0516, 259.921)	(243.6403, 263.7093, 312.3402)	(219.4614, 262.0536, 316.6879)
7	0.6008268	(123.8312, 152.8225, 177.7539)	(204.2243, 241.4274, 271.4029)	(179.3619, 244.3055, 278.6595)	0.6717981	(198.9651, 212.5151, 261.3879)	(233.5784, 246.3177, 292.2688)	(209.9515, 244.3055, 309.2491)
8	0.5721426	(138.9089, 176.1114, 204.4348)	(255.2181, 306.1853, 329.1356)	(234.368, 302.6572, 329.7981)	0.6892049	(276.5556, 291.7439, 351.9597)	(290.881, 304.6098, 354.9732)	(275.5163, 302.6572, 370.9464)
9	0.5952598	(257.4587, 315.828, 364.5785)	(387.6695, 461.3603, 508.8579)	(387.6695, 461.3603, 508.8579)	0.6789365	(353.0816, 377.5722, 475.7156)	(375.6525, 453.0711, 596.159)	(413.8627, 461.3603, 535.0511)
10	0.5648857	(184.457, 226.2865, 260.8869)	(249.3702, 318.4022, 373.5582)	(248.946, 319.3468, 372.9265)	0.6896677	(292.7954, 311.4253, 377.7261)	(284.6113, 318.2044, 388.6123)	(265.7671, 319.3468, 389.7476)

**Tabel 14.3 Solusi Penentuan Pemenang: Segitiga Seimbang Kiri vs. Kanan (Kasus Penahanan Bukti 5.2)**

Nomor Tes.	Kiri Tidak Seimbang				Kanan Tidak Seimbang			
	I	L&H	COA	Ideal	I	L&H	COA	Ideal
1	0.5602082	(153.9495, 195.7311, 230.4237)	(240.513, 313.4814, 353.5161)	(240.513, 313.4814, 353.5161)	0.6715952	(283.2343, 292.3277, 326.8667)	(297.2566, 314.7082, 350.7668)	(297.4699, 313.4814, 348.7907)
2	0.5711837	(179.9287, 224.2664, 263.5376)	(277.8412, 371.4729, 432.9982)	(277.8412, 371.4729, 432.9982)	0.6627964	(342.6883, 350.1084, 386.0667)	(348.5297, 371.4729, 419.0105)	(348.5297, 371.4729, 419.0105)
3	0.5645395	(164.3035, 202.2729, 234.7761)	(268.9654, 341.9236, 392.833)	(264.107, 337.8935, 384.0519)	0.693984	(288.0151, 297.1841, 332.8137)	(323.0408, 342.6625, 382.4945)	(313.089, 337.8935, 374.0679)

4	0.5586566	(266.0916, 316.5051, 360.9977)	(326.3924, 398.6696, 448.1938)	(313.8231, 399.9962, 452.6661)	0.6969287	(337.3735, 346.9136, 389.6231)	(376.2013, 399.9962, 445.9972)	(376.2013, 399.9962, 445.9972)
5	0.5604279	(156.9779, 194.339, 229.6228)	(278.9423, 342.6066, 391.5783)	(278.9423, 342.6066, 391.5783)	0.7019467	(286.6321, 295.1516, 332.1824)	(321.5231, 342.6066, 381.3376)	(321.5231, 342.6066, 381.3376)
6	0.5420034	(216.7566, 264.9487, 307.1978)	(305.6541, 373.7809, 424.9731)	(293.3828, 373.6738, 430.0128)	0.6345645	(332.3614, 344.2184, 385.5766)	(344.1564, 362.2205, 395.184)	(350.4891, 373.6738, 417.8466)
7	0.557049	(272.1698 318.9274, 358.9925)	(305.2059, 386.7644, 442.504)	(305.2059, 386.7644, 442.504)	0.6552459	(328.2626, 337.21, 376.1936)	(362.3191, 384.1855, 429.0329)	(365.0276, 386.7644, 426.8877)
8	0.570035	(189.4491, 240.0472, 285.4828)	(349.6256, 419.8465, 460.1672)	(346.8757, 421.1095, 455.575)	0.6670071	(334.8326, 346.9792, 391.1598)	(387.4674, 415.9816, 457.53332)	(405.4922, 421.1095, 449.0239)
9	0.5720877	(117.205, 142.7886, 164.7209)	(173.6011, 213.1481, 241.6906)	(173.6011, 213.1481, 241.6906)	0.6644463	(162.0989, 168.4119, 189.5751)	(203.8059, 213.1481, 238.3488)	(203.8059, 213.1481, 238.3488)
10	0.5620291	(133.3908, 164.7031, 192.9064)	(226.8055, 287.0959, 334.8583)	(226.8055, 287.0959, 334.8583)	0.6768237	(253.9262, 261.7461, 289.5906)	(267.0216, 287.0959, 325.874)	(267.0216, 287.0959, 325.874)

**Tabel 14.4** Rentang Pendapatan menurut Jenis dan Metode Penawaran

Nomor Tes.	Kiri Tidak Seimbang			Simetris			Kanan Tidak Seimbang		
	L&H	COA	Ideal	L&H	COA	Ideal	L&H	COA	Ideal
1	73.3958	79.7945	101.3978	73.3024	146.4276	146.4276	105.228	101.255	136.4252
2	80.6886	129.8929	132.0392	51.0624	72.851	72.851	78.9043	115.611	102.3071
3	56.3336	65.8254	70.6094	59.4598	66.0822	66.0822	96.9742	80.7175	90.1459
4	53.6992	90.8291	50.1091	69.1862	62.8638	62.8638	73.4553	117.162	41.283
5	92.7026	107.9062	147.0331	50.8544	82.4682	82.4682	83.0151	125.1794	108.3989
6	58.8563	102.2453	102.2453	75.1978	95.8566	95.8566	78.9186	133.7009	57.2006
7	54.3146	61.7346	61.7346	35.6732	38.573	38.573	91.8932	88.9781	88.9781
8	86.0345	80.4537	90.6627	74.9318	105.7108	105.7108	79.4185	124.2582	124.2582
9	55.1044	48.5006	48.5005	45.0218	22.232	22.232	79.6395	145.8375	112.4338
10	72.3263	95.0896	99.1613	68.7158	90.199	90.199	106.883	72.133	106.2433

**Tabel 14.5.** Perbedaan Rentang Pendapatan menurut Jenis dan Metode Penawaran

Perbedaan Pendapatan	LB-S	LB-RU	S-RU
	9.31†	-16.587*	-25.897*
	LH-COA	LH-I	COA-I
	-19.639*	-16.441†	3.198

Catatan: Left Unbalanced (LB), Symmetry (S), Right Unbalanced (RU), metode Lai dan Hwang (LH), Center of Area (COA), Ideal (I). Rerata tidak berbeda nyata pada \* $p < .05$ ,  $p < .10$ .

**Tabel 14.6** Estimasi Parameter. Hubungan antara Metode dan Jenis Penawaran

Metode	Kiri Tidak Seimbang	Simetris	Kanan Tidak Seimbang
Lai dan Hwang	-22.004†(.124)	-17.986(.004)	-9.334(.03)
COA	-4.122(.005)	-5.41x10 <sup>-14</sup> (0)	13.716(.063)
Ideal	-	-	-

Catatan: Signifikan pada \* $p < .05$ ,  $p < .10$ . Nilai yang ditampilkan berupa beta (partial eta squared). Metode yang ideal digunakan sebagai kelompok referensi.

Kami menggunakan Generalized Linear Model (GLM) dengan pengukuran berulang untuk menganalisis dampak jenis penawaran (Kasus 1, 2, dan 3) dan metode (L&H, COA, Ideal) pada kisaran pendapatan dari solusi optimal. Uji omnibus mengungkapkan bahwa ada rentang pendapatan yang signifikan di antara faktor-mata pelajaran (yaitu metode) pada  $F(df)=3.241(2)$ ,  $p < .10$ . Namun, interpretasi hasil ini mensyaratkan bahwa asumsi normalitas multivariat terpenuhi untuk rentang pendapatan. Hal ini dicapai melalui uji Box M, di mana matriks varians-kovarians sama di seluruh sel yang dibentuk oleh jenis metode (LH, COA, Ideal) jika hipotesis alternatif tidak didukung. Asumsi tersebut didukung dengan  $F(df_1, df_2)=1.337(12.3532.846)$  pada  $p > .10$ . Di sisi lain, uji omnibus juga mengungkapkan bahwa ada rentang pendapatan yang signifikan di seluruh faktor dalam subjek (yaitu jenis penawaran) pada  $F(df)=9.097(1)$ ,  $p < .01$ .

Faktor dalam subjek dari jenis penawaran (atau bentuk segitiga) ditemukan berkontribusi signifikan pada model multivariat dan dikonfirmasi oleh empat statistik (Diasumsikan Bulat, Rumah Kaca-Geisser, Huynh-Feldt dan Batas bawah) di hal. <0,01. Karena uji homogenitas Levene mengungkapkan bahwa persamaan varian kesalahan dapat diasumsikan untuk semua jenis segitiga pada  $p > 0,1$ , statistik perbandingan berganda post hoc dari LSD dilakukan. Tabel 5 menunjukkan bahwa tawaran tidak seimbang kanan memiliki rentang pendapatan yang jauh lebih besar daripada tawaran tidak seimbang kiri atau simetris. Dari segi metode, tidak ada perbedaan yang signifikan antara rentang pendapatan yang dihasilkan dari COA atau metode deterministik ideal. Namun, rentang pendapatan yang dihasilkan oleh metode L&H secara signifikan lebih rendah daripada COA dan deterministik ideal. Menariknya, pengurangan kisaran pendapatan dengan metode Lai dan Hwang memiliki hubungan signifikan yang lebih besar dengan peningkatan kisaran tawaran tidak seimbang yang tersisa dibandingkan dengan metode deterministik yang ideal (lihat Tabel 6). Hasilnya dapat dengan mudah diverifikasi dari plot profil Gambar 6.

Secara keseluruhan, juga penting untuk mengamati dua temuan: Pertama, dalam kasus penawaran simetris, kisaran pendapatan serupa antara COA dan metode deterministik ideal. Kedua, kisaran pendapatan dari penawaran tidak seimbang kanan memiliki perbedaan yang dapat diabaikan antara metode Lai dan Hwang dan deterministik ideal jika dibandingkan dengan segitiga tidak seimbang simetris atau kiri. Dalam kasus ketidakseimbangan kanan tawaran awal, mengambil nilai ideal pusat  $p_2^k$  juga mirip dengan perkiraan konservatif untuk metode deterministik ideal. Karena metode Lai dan Hwang berusaha menjembatani kesenjangan antara sisi pesimistik dan titik ideal  $p_2^k$ , kisaran pendapatan mereka tidak jauh berbeda dibandingkan dengan metode yang berasal dari COA. Dalam kasus segitiga siku-siku tidak seimbang, nilai  $p_2^k$  sebenarnya adalah  $p_2^k + \Delta$  karena  $d_s^- > d_s^+$ .

#### **14.7 DISKUSI**

Temuan penelitian ini menjelaskan sifat tawaran dan menunjukkan efek penyebarannya pada nilai solusi optimal yang diturunkan di ketiga model. Meskipun demikian, kompleksitas komputasi tidak jauh dari implikasi teoretis dan praktis yang dibawanya.

Mengingat bahwa teori lelang terus berputar di sekitar prinsipal (pelelang) yang lebih menghindari risiko daripada penawar, perlu dicatat bahwa pekerjaan kami berbeda dari masalah penjualan klasik (CSP) dalam beberapa aspek. Pertama, CSP hanya mencakup satu objek dengan penilaian pribadi independen, sedangkan paket item dipertimbangkan dalam penelitian ini. Kedua, pekerjaan kami tidak terbatas pada kasus penawar netral risiko dan penjual penghindar risiko. Bahkan, dengan mempertimbangkan harga yang tidak tepat, penawar dan penjual bebas untuk "menawar" harga. Namun, kisaran negosiasi yang diperbolehkan untuk jangka waktu tertentu harus dijabarkan dengan jelas apriori dalam bentuk kontrak sebelum dimulainya aktivitas penawaran. Harga pemberian final akan ditentukan berdasarkan apakah itu dorongan permintaan atau tarikan pasar pada jendela waktu tertentu dan algoritma penentuan pemenang apa yang digunakan. Misalkan, ditunjukkan bahwa model COA memberikan nilai optimis yang lebih tinggi tetapi juga memiliki perbedaan pendapatan (spread) yang lebih tinggi. Ini mencerminkan model pencarian risiko, di mana juru lelang mengharapkan revisi harga ke atas di bawah kondisi ekonomi tertentu yang menguntungkannya juga harus bersedia merevisi harganya ke bawah dengan cara yang sama ketika kondisi yang menguntungkan tidak berlaku. Oleh karena itu, kemungkinan untuk memperoleh pendapatan yang lebih tinggi terkait erat dengan risiko.

Sebaliknya, model Lai dan Hwang memberikan perkiraan konservatif, dan karenanya mengurangi risiko atau penyebaran pendapatan. Model penghindaran risiko ini mempertimbangkan kemungkinan untuk memperoleh pendapatan yang lebih rendah, sekaligus memaksimalkan ruang kemungkinan untuk memperoleh pendapatan di atas rata-rata. Menarik juga untuk dicatat bahwa dalam hal tawaran tidak seimbang kanan yang terkandung dalam tawaran tidak seimbang kiri yang berat, metode Lai dan Hwang dapat mengeksplorasi wilayah optimis tambahan dari yang pertama sambil mengelilkan wilayah negatif dari yang terakhir (lihat Gambar 3). Di sisi lain, model deterministik yang ideal dapat dianggap sebagai model yang kinerjanya paling rendah. Solusi WDP dari model ideal mempertimbangkan nilai tengah terlepas dari sifat dan distribusi tawaran. Solusinya dapat dilihat sebagai perkiraan konservatif tetapi dengan kerugian tambahan dari spread atau risiko yang luas.

#### 14.8 KESIMPULAN

Kami telah menetapkan bahwa juru lelang yang menghindari ambiguitas akhirnya akan menegosiasikan nilai akhir di sisi kehati-hatian, karena ia hanya memiliki pengetahuan yang tidak tepat tentang permintaan pada saat menjalankan masalah penentuan pemenang. Oleh karena itu, tulisan ini tidak menekankan pada harga pasti yang harus diminta oleh juru lelang dari pemenang tender. Ini hanya masuk akal dengan asumsi bahwa harga barang dipengaruhi secara negatif oleh waktu yang berlalu antara menjalankan algoritma penentuan pemenang dan pemberian penjualan, sebuah fakta yang dapat dimanfaatkan oleh juru lelang untuk meminta harga yang lebih rendah dari pemasok hulunya sebelum menyelesaiannya. Untuk harga akhir. Selain itu, kecerdikan dalam memunculkan harga berganda adalah kemampuannya untuk membentuk distribusi kemungkinan untuk memecahkan masalah ketidakpastian harga dalam lelang kombinatorial. Akhirnya, ini juga memberikan metode baru dalam membentuk opini tentang efisiensi ekonomi para penawar.

## **BAB 15**

### **PENERAPAN JARINGAN SYARAF TIRUAN PADA TEKNIK KESELAMATAN KEBAKARAN**

Jaringan saraf tiruan (JST) telah banyak diadopsi sebagai sistem pendukung keputusan dalam aplikasi rekayasa yang berbeda. Baru-baru ini, ANN telah digunakan untuk menentukan terjadinya bencana kebakaran dan untuk memprediksi perkembangan api dan asap. Pendekatan cerdas menjadi cara alternatif untuk mengevaluasi keamanan kebakaran bangunan daripada pendekatan numerik tradisional yang membutuhkan penyimpanan komputer yang luas dan perhitungan yang lama. Karena data kebakaran biasanya bersifat noise corrupted, beberapa model JST dikembangkan secara khusus untuk aplikasi ini.

#### **15.1 PENDAHULUAN**

Kebakaran gedung adalah salah satu ancaman utama bagi kehidupan kita sehari-hari. Meskipun teknologi canggih telah dikembangkan dan diterapkan dalam sistem proteksi dan pemadam kebakaran, kecelakaan kebakaran masih dilaporkan setiap hari. Karena tidak mungkin merancang bangunan dengan risiko kebakaran nol, para insinyur akan memodifikasi desain bangunan dan menyelidiki tingkat keselamatan kebakaran yang sesuai untuk mengurangi kemungkinan terjadinya kebakaran dan tingkat keparahan kebakaran. Dalam proses desain bangunan, merupakan proses pengambilan keputusan untuk menentukan keberterimaan desain sedemikian rupa sehingga, jika terjadi kebakaran, skenario kebakaran masih dapat dipertahankan dalam kondisi yang dapat dipertahankan oleh penghuni bangunan selama evakuasi mereka. Untuk membuat keputusan ini, simulasi model komputasi numerik biasanya diadopsi untuk menentukan tenability. Pendekatan tradisional ini biasanya membutuhkan penyimpanan komputer yang luas dan waktu komputasi yang lama. Sebagai alternatif, JST telah diusulkan dan terbukti menjadi model pengambilan keputusan yang efisien dan efektif dalam aplikasi kebakaran. Misalnya, telah diadopsi secara luas untuk pengambilan keputusan dalam membedakan kebakaran nyata atau alarm palsu berdasarkan data yang diterima dari detektor kebakaran. Baru-baru ini, ini juga telah digunakan sebagai model pengambilan keputusan untuk menentukan kelayakan skenario kebakaran berdasarkan ukuran api dan geometri kompartemen kebakaran. Karya-karya ini mengeksplorasi area aplikasi baru (yaitu teknik keselamatan kebakaran) dari model JST untuk pengambilan keputusan.

Regresi data merupakan salah satu alat dalam sistem pendukung keputusan. Ini juga merupakan topik penelitian utama di bidang pendekatan fungsi. Model Jaringan Syaraf Tiruan (JST) yang berbeda untuk regresi data termasuk Multi-layer Perceptron (MLP) dan Radial Basis Function (RBF) telah dikembangkan. Dalam MLP, permukaan regresi dibangun oleh transformasi non-linier dari kombinasi output neuron. RBF mendekati fungsi yang mendasarinya dengan kombinasi fungsi semi-parametrik non-linear (yaitu fungsi kernel). Namun, jumlah neuron atau kernel tersembunyi dari model JST ini harus ditentukan sebelumnya sebelum pelatihan jaringan.

Model GRNN yang dikembangkan oleh Specht [1] adalah alat regresi yang kuat dengan struktur jaringan yang dinamis. Kecepatan pelatihan jaringan sangat cepat. Karena kesederhanaan struktur jaringan dan kemudahan implementasi, telah diterapkan secara luas ke berbagai bidang termasuk pemrosesan gambar [2], kontrol adaptif non-linier [3], diagnosis kesalahan mesin [4], dan keuangan. prediksi [5]. Selama proses pelatihan, setiap sampel pelatihan direkrut sebagai kernel. Kemudian, permukaan regresi dapat dibuat dengan menggunakan estimator Parzen-window [6] dengan semua lebar kernel diasumsikan identik dan berbentuk bola. Kelemahan utama dari GRNN adalah kebutuhan sumber daya komputer yang luas untuk menyimpan dan memproses semua sampel pelatihan. Spect [1] mengusulkan algoritma pengelompokan untuk GRNN untuk mengurangi jumlah kernel dan karenanya beban komputasi. Alih-alih merekrut semua sampel pelatihan sebagai kernel, prosedur pengelompokan digunakan untuk memampatkan semua sampel pelatihan menjadi lebih sedikit kernel.

FA, di sisi lain, adalah pengklasifikasi tanpa pengawasan yang kuat. Arsitektur FA dikembangkan berdasarkan Adaptive Resonance Theory (ART) [7]. Subset fuzzy [8] digunakan sebagai ukuran kesamaan antara pola input dan prototipe jaringan. FA telah terbukti menjadi jaringan yang stabil yang memecahkan dilema stabilitas-plastisitas. Ini juga telah diterapkan ke berbagai bidang. Brezmes [9] menggunakan FA sebagai alat klasifikasi dalam hidung elektroniknya untuk menentukan kualitas buah. Araujo dan Almeida [10], [11] menggunakan FA untuk membangun peta dengan sinyal sensor untuk navigasi mobile robot. Cinque dkk. [12] menerapkan FA dengan fungsi pilihan yang dimodifikasi untuk segmentasi gambar. FA juga digunakan untuk pengelompokan pelanggan dalam e-commerce oleh Park [13].

Makalah ini menyajikan jaringan hybrid, dilambangkan sebagai GRNNFA [14,15], yang menggunakan FA sebagai pra-prosesor untuk GRNN untuk mengompresi sampel data pelatihan menjadi lebih sedikit kernel. Dibandingkan dengan metode clustering populer lainnya (misalnya Kohonen Self-Organizing Map [16] dan Fuzzy C-Means clustering [17]), FA telah terbukti stabil [18], dan sangat cepat dalam pembelajaran. Selama pembelajaran, batas (yaitu hiper-persegi panjang) dari prototipe akan meningkat secara monoton. Dalam GRNNFA, pusat dan label kernel ditentukan, masing-masing, dengan menghitung centroid dari input dan output dari titik data yang di-cluster ke kernel tersebut setelah proses clustering selesai. Noise yang disematkan pada titik data di dalam setiap hyper-rectangle mungkin dapat membatalkan satu sama lain jika mereka didistribusikan secara simetris di sekitar centroid sampel data. Untuk menentukan lebar kernel, algoritma optimasi telah dikembangkan. Sebelum penggunaan algoritma, lebar kernel diinisialisasi oleh K-nearest- tetangga kernel [19].

Susunan makalah ini adalah sebagai berikut. Bagian 2 menjelaskan arsitektur dasar GRNN dan FA. Bagian 3 mengilustrasikan penggabungan GRNN dan FA ke dalam GRNNFA. Serangkaian percobaan pada empat set data benchmark dan aplikasi baru GRNNFA untuk memprediksi waktu evakuasi selama bencana kebakaran disajikan di Bagian 4. Hasilnya dibandingkan dan dibahas. Bagian 5 menunjukkan penerapan model GRNNFA dalam rekayasa keselamatan kebakaran dan Bagian 6 menyimpulkan bab ini.

## 15.2 ARSITEKTUR MODEL GRNN DAN FA

### Arsitektur GRNN

Dengan asumsi bahwa fungsi skalar yang mendasari yang akan didekati adalah  $y = f(x)$  di mana  $x \in \mathbb{R}^m$  adalah variabel independen multidimensi dan  $y \in \mathbb{R}$  adalah variabel dependen, regresi dalam GRNN dilakukan oleh kondisi yang diharapkan. mean nasional diberikan  $x$  seperti yang ditunjukkan pada (1) di mana  $(x, y)$  adalah penduga kepadatan probabilitas Parzen [6] dengan fungsi Gaussian seperti yang didefinisikan dalam (2).

$$E[y|x] = \frac{\int_{-\infty}^{\infty} yg(x,y)dy}{\int_{-\infty}^{\infty} g(x,y)dy} \quad (1)$$

$$g(x,y) = \frac{1}{n(2\pi)^{\frac{p+1}{2}}} \left\{ \sum_{i=1}^n \frac{1}{\sigma_i^{p+1}} \exp \left[ -\frac{1}{2} \sum_{k=1}^p \left( \frac{x_k - x_{ik}}{\sigma_i} \right)^2 \right] \cdot \exp \left[ -\frac{1}{2} \sum_{k=1}^p \left( \frac{y - y_i}{\sigma_i} \right)^2 \right] \right\} \quad (2)$$

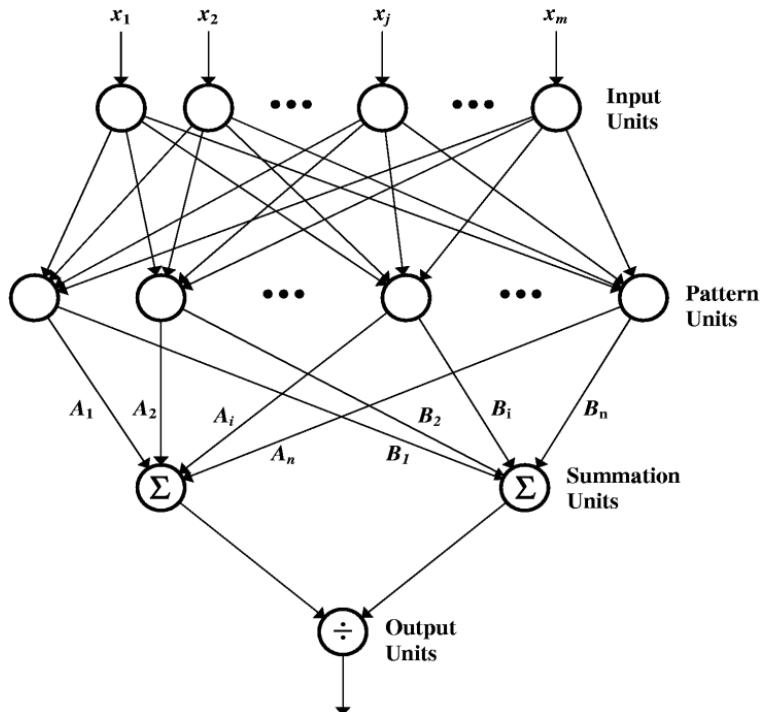
Persamaan (3) menunjukkan hasil prediksi model GRNN. Kernel diasumsikan berbentuk hyper-spherical tetapi dengan jari-jari yang berbeda. Hal yang sama digunakan dalam model GRNN yang dimodifikasi di [20] di mana:

- $x_j$  adalah komponen ke- $j$  dari vektor input
- $x_{ik}$  adalah komponen ke- $k$  dari vektor posisi kernel ke- $i$
- $\sigma_i$  adalah lebar kernel ke- $i$
- $\sigma_{iy}$  adalah lebar dari label kernel ke- $i$

$$\hat{y}(x) = \frac{\sum_{i=1}^n \frac{y_i}{\sigma_i^p} \cdot \exp \left[ -\frac{1}{2\sigma_i} (x - x_i)^T (x - x_i) \right]}{\sum_{i=1}^n \frac{1}{\sigma_i^p} \cdot \exp \left[ -\frac{1}{2\sigma_i} (x - x_i)^T (x - x_i) \right]} \quad (3)$$

Kelemahan utama dari GRNN adalah kebutuhan sejumlah besar sumber daya komputasi untuk menyimpan informasi dari kernel. Ini juga membutuhkan waktu komputasi yang substansial untuk optimasi lebar kernel. Specht [21] membahas konsep dasar inklusi teknik clustering dalam model GRNN.

Gambar 1 menunjukkan arsitektur versi clustering dari model GRNN.



**Gambar 15.1** Arsitektur model General Regression Neural Network (GRNN)

Menurut [1], persamaan (4) dan (5) digunakan di mana  $i(k)$  dan  $i(k)$  diperbarui secara bertahap setiap kali output dari sampel pelatihan untuk cluster  $i$  ditemukan. Versi pengelompokan GRNN ini digunakan di GRNNFA. Pendekatan pengelompokan yang berbeda untuk mengurangi jumlah kernel model GRNN atau Probabilistic Neural Network (PNN) diusulkan, mis. Teknik Learning Vector Quantization Kohonen [22], algoritma k-means [23], dan campuran model densitas Gaussian [24]. Skema clustering ini membutuhkan penentuan jumlah kernel sebelum proses clustering. Dalam [18], kemungkinan ketidakstabilan teknik pengelompokan dengan pengukuran jarak Euclidean dibahas. Di sisi lain, FA [18] dengan jaminan konvergensi dalam pelatihan jaringan telah terbukti stabil. Akibatnya, FA digunakan untuk mengelompokkan sampel pelatihan secara bertahap dan stabil ke dalam jumlah kernel yang lebih sedikit di GRNNFA.

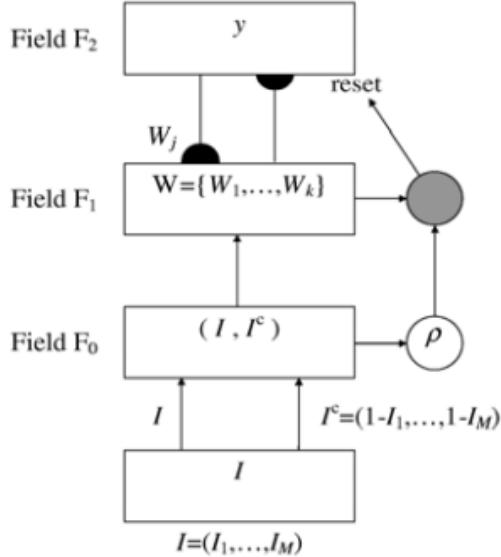
$$\hat{y}(\mathbf{x}) = \frac{\sum_{i=1}^n \frac{A_i}{\sigma_i^p} \cdot \exp \left[ -\frac{1}{2\sigma_i} (\mathbf{x} - \mathbf{x}_i)^T (\mathbf{x} - \mathbf{x}_i) \right]}{\sum_{i=1}^n \frac{B_i}{\sigma_i^p} \cdot \exp \left[ -\frac{1}{2\sigma_i} (\mathbf{x} - \mathbf{x}_i)^T (\mathbf{x} - \mathbf{x}_i) \right]} \quad (4)$$

$$\begin{cases} A_i(k) = A_i(k-1) + y_j \\ B_i(k) = B_i(k-1) + 1 \end{cases} \quad (5)$$

### Arsitektur FA

Gambar 2 menggambarkan arsitektur jaringan FA. Algoritma pembelajaran FA adalah sebagai berikut. Pola input m-dimensi,  $\mathbf{I} = \{I_1, I_2, \dots, I_m\}$  di mana  $I_k \in [0,1]$  dan  $k = 1, 2, \dots, m$  disajikan ke lapisan  $F_1$  dalam format kode pelengkap,  $(\mathbf{I}, \mathbf{I}^c) \in \mathbb{R}^{2m}$  di mana  $\mathbf{I}^c = \{I_1^c, I_2^c, \dots, I_m^c\}$  di antaranya  $I_k^c \equiv 1 - I_k$  untuk  $k = 1, 2, \dots, m$ .

Pola masukan berkode komplemen akan dibandingkan dengan prototipe  $W_j \in \mathbb{R}^{2m}$  pada lapisan  $F_2$  dengan menggunakan fungsi pilihan seperti yang ditunjukkan pada (6).



**Gambar 15.2** Arsitektur model Fuzzy ART

Prototipe yang memiliki derajat fuzzy subsethood tertinggi dipilih oleh (7). Perhatikan bahwa  $|x| \equiv \sum_{i=1}^M x_i$ ,  $x \wedge y \equiv \min(x_i, y_i)$  dan parameter pilihan,  $\alpha$ , adalah bilangan positif kecil.

$$T_j = \frac{|I \wedge W_j|}{|W_j| + \alpha} \quad (6)$$

$$J = \arg \max_j \{T_j\} \quad (7)$$

Resonansi dikatakan terjadi jika prototipe yang dipilih oleh fungsi pilihan (yaitu  $j = J$ ) juga memenuhi (8) di mana parameter kewaspadaan adalah ambang batas yang telah ditentukan sebelumnya oleh pengguna.

$$\frac{|I \wedge W_J|}{|I|} \geq \rho \quad (8)$$

Sebuah prototipe memenuhi baik (7) dan (8) dipilih sebagai prototipe pemenang. Jika prototipe memenuhi (7) tetapi gagal (8), itu akan dihambat. Pencarian prototipe pemenang akan diulang sampai prototipe yang memenuhi (7) dan (8) ditemukan. Jika tidak, prototipe baru akan dibuat untuk mewakili pola input saat ini.

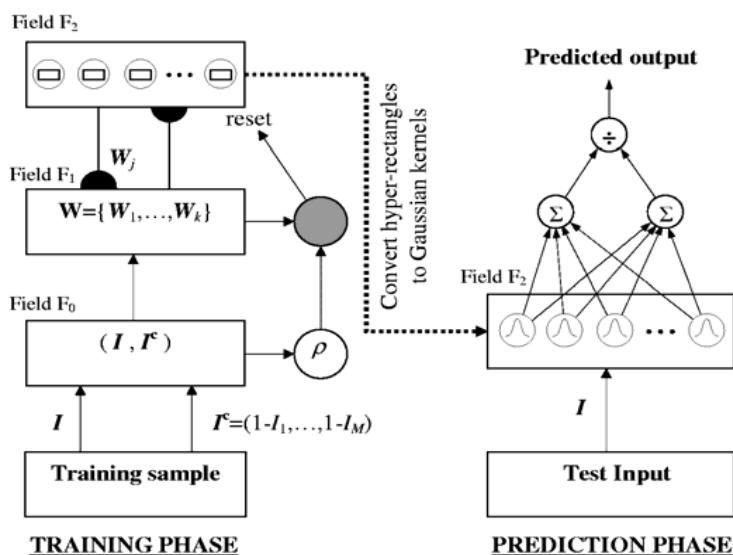
Setelah prototipe pemenang diidentifikasi, itu akan diperbarui sesuai dengan (9) di mana  $\beta$  adalah parameter kecepatan pembelajaran.

$$W_J^{(new)} = \beta(I \wedge W_J^{(old)}) + (1 - \beta)W_J^{(old)} \quad (9)$$

Disebut fast learning jika  $\beta = 1$ . Telah ditunjukkan pada [18] bahwa ukuran maksimum prototipe  $j$  dikendalikan oleh parameter vigilance, dan  $|W_j|$  adalah kuantitas yang meningkat secara monoton untuk menjamin konvergensi prosedur pembelajaran.

### 15.3 PENGGABUNGAN GRNN DAN FA

Arsitektur GRNNFA, seperti yang ditunjukkan pada Gambar 3, terdiri dari dua modul yaitu, FA digunakan untuk pelatihan sedangkan GRNN digunakan untuk prediksi. Pendekatan dasar untuk menggabungkan model GRNN dan FA adalah dengan mengelompokkan semua sampel pelatihan terlebih dahulu ke jumlah prototipe yang lebih sedikit oleh FA. Kemudian, prototipe FA diubah menjadi kernel GRNN. Karena setiap prototipe FA awalnya diwakili oleh dua simpul dari hiper-persegi panjang, skema untuk mendapatkan tiga parameter dari setiap kernel Gaussian (yaitu pusat, lebar, dan label) dari masing-masing hiper-persegi panjang diusulkan sebagai berikut.



Gambar 15.3 Arsitektur model GRNNFA

#### Estimasi Pusat Kernel

FA diterapkan untuk membuat prototipe dalam domain input sesuai dengan distribusi sampel input. Namun, prototipe yang dibuat oleh FA tidak dapat digunakan secara langsung sebagai kernel GRNN karena prototipe ini, sesuai dengan algoritma pembelajaran FA, hanya mewakili simpul dari hiper-persegi panjang. Akibatnya, metode yang diusulkan dalam [19] untuk memperkirakan pusat kernel dari prototipe yang dibuat oleh Fuzzy ARTMAP (FAM) diadopsi di GRNNFA. Pusat kernel  $x_J$  dari cluster  $J$  ditentukan oleh (10) di mana  $i$  ( $i = 1, 2, \dots$ ) terdiri dari semua sampel milik .

$$x_J = \frac{\sum_{i=1}^{N_J} I_i}{N_J} \quad (10)$$

#### Estimasi Label Kernel

Sebuah model regresi statistik dapat dikembangkan dengan mengambil nilai yang diharapkan lebih dari jumlah kernel seperti yang ditunjukkan pada (11) di mana  $\hat{y}_i$ , dan  $(K_i | x)$

masing-masing adalah output yang diprediksi, label kernel i dan probabilitas kernel i diberikan vektor input x.

$$\hat{y}(x) = \sum_{i=1}^N \xi_i P(K_i|x) \quad (11)$$

Dengan menerapkan teori Bayesian pada (11), dapat diperoleh model regresi berikut di mana i adalah jumlah sampel yang termasuk dalam kernel  $K_i$ .

$$\hat{y}(x) = \frac{\sum_{i=1}^c n_i \xi_i p(x|K_i)}{\sum_{i=1}^c n_i p(x|K_i)} \quad (12)$$

Format (12) mirip dengan (4). Dapat diamati bahwa i dalam penyebut (12) (yaitu jumlah sampel kernel  $K_i$ ) persis sama dengan nilai i dalam (5). Diusulkan untuk menyamakan  $n_i \xi_i$  dalam (12) dan i dalam (5), yaitu,

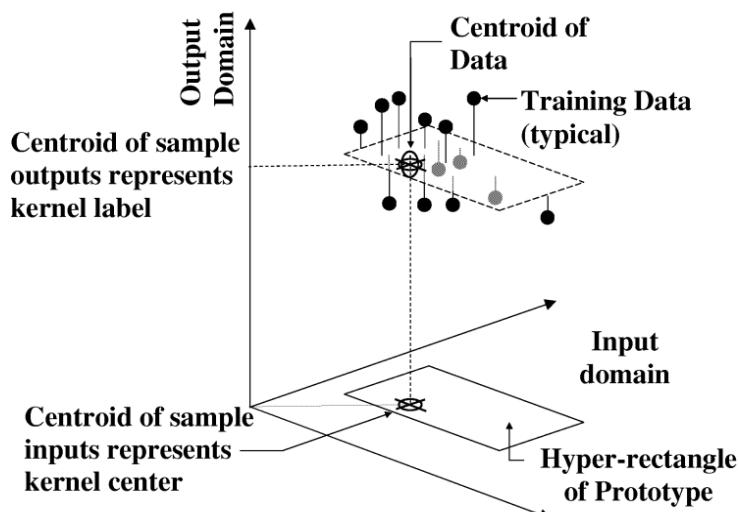
$$\xi_i = \frac{A_i}{n_i} \quad (13)$$

Menurut (13), centroid dari vektor-vektor keluaran dari sampel-sampel masukan berkerumun harus diambil sebagai label kernel i. Skema kompresi yang diusulkan untuk mendapatkan pusat kernel dan label digambarkan pada Gambar 4.

### Estimasi Lebar Kernel

Sebelum menerapkan skema optimasi lebar kernel, setiap lebar kernel diinisialisasi sesuai dengan (14) yang mirip dengan skema yang diusulkan pada [19].

$$\sigma_j = \frac{1}{2K} \sum_{k=1}^K \|x_j - x_k\| \quad j \neq k \quad 1 \leq K \leq N-1 \quad (14)$$



**Gambar 15.4** Skema kompresi data untuk menghilangkan noise. Sampel dikelompokkan dengan menerapkan FA pada input sampel. Centroid dari input dan output sampel masing-masing mewakili pusat kernel dan label.

Lebar kernel j pertama-tama diatur menjadi setengah dari jarak rata-rata di atas jumlah tetangga terdekat ke kernel j. Dengan menggunakan K-nearest-neighbors yang sesuai dan parameter kewaspadaan, struktur jaringan dengan kesalahan validasi minimum dapat diinisialisasi. Akurasi prediksi dapat lebih ditingkatkan dengan menerapkan skema optimasi lebar kernel berbasis gradien. Kesalahan dari sampel pelatihan tertentu didefinisikan sebagai berikut di mana  $\delta_k = \hat{y}(\mathbf{x}_k) - \tilde{y}_k$ ,  $\hat{y}(\mathbf{x}_k)$  adalah prediksi GRNNFA dan  $k$  adalah nilai target dari vektor input yang sesuai  $\mathbf{x}_k$ .

$$e_k \equiv \frac{1}{2} \delta_k^2 \quad (15)$$

- - -

Kesalahan dari semua sampel pelatihan adalah:

$$E \equiv \sum_{k=1}^N e_k \quad (16)$$

Gradien permukaan kesalahan dapat diperoleh dengan membedakan (16) sehubungan dengan lebar kernel, yaitu,

$$\frac{\partial E}{\partial \sigma_j} \equiv \sum_{i=1}^N \delta_i \frac{\partial \hat{y}(\mathbf{x}_i)}{\partial \sigma_j} \quad (17)$$

Persamaan (18) diperoleh dengan mensubstitusikan (4) ke (17), yaitu,

$$\frac{\partial E}{\partial \sigma_j} = \sum_{i=1}^N \delta_i \frac{\partial}{\partial \sigma_j} \left\{ \frac{\sum_{i=1}^n \frac{A_i}{\sigma_i^p} \cdot \exp \left[ -\frac{1}{2\sigma_i} (\mathbf{x} - \mathbf{x}_i)^T (\mathbf{x} - \mathbf{x}_i) \right]}{\sum_{i=1}^n \frac{B_i}{\sigma_i^p} \cdot \exp \left[ -\frac{1}{2\sigma_i} (\mathbf{x} - \mathbf{x}_i)^T (\mathbf{x} - \mathbf{x}_i) \right]} \right\} \quad (18)$$

Dengan menggunakan  $D_{kj}^2 = (\mathbf{x}_k - \mathbf{x}_j)^T (\mathbf{x}_k - \mathbf{x}_j)$ , yaitu kuadrat jarak Euclidean antara  $\mathbf{x}_k$  dan  $\mathbf{x}_j$ , (19) diperoleh dimana dan adalah pembilang dan penyebut (4).

$$\frac{\partial E}{\partial \sigma_j} = \sum_{k=1}^N \frac{\delta_k \hat{y}(\mathbf{x}_k)}{\sigma_j^{p+1}} \left[ \left( \frac{D_{kj}^2}{\sigma_j} \right) - p \right] \cdot \frac{1}{\sqrt{2\pi}} \exp \left[ -\frac{1}{2} \left( \frac{D_{kj}}{\sigma_j} \right)^2 \right] \left[ \frac{A_j}{h(\mathbf{x}_k)} - \frac{B_j}{s(\mathbf{x}_k)} \right] \quad (19)$$

Dengan algoritma penurunan gradien tradisional, lebar kernel,  $j$  diperbarui menurut (20).

$$\sigma_j^{(new)} = \sigma_j^{(old)} - \alpha^2 \frac{\partial E}{\partial \sigma_j} \quad (20)$$

Untuk menghindari masalah over-fitting, sampel data pelatihan dibagi menjadi dua yaitu set pelatihan dan validasi. Proses pelatihan dihentikan ketika kesalahan validasi mencapai ambang batas yang telah ditentukan sebelumnya, yaitu prosedur pelatihan validasi penghentian awal. Salah satu kekurangan dari algoritma gradient descent tradisional adalah tingkat konvergensi yang lambat. Akibatnya, faktor pemutakhiran elastis, seperti yang diperkenalkan pada 25, dikembangkan pada (21) di mana adalah perubahan kesalahan pelatihan dari langkah terakhir.

$$\alpha_{new}^2 = \begin{cases} \rho\alpha_{old}^2, & \Delta E < 0 \\ \sigma\alpha_{old}^2, & \Delta E \geq 0 \end{cases} \quad (21)$$

Nilai dan biasanya diatur ke 1,1 dan 0,5 menurut [25]. Jika kesalahan pelatihan bertambah atau berkurang, faktor pemutakhiran akan berkurang atau bertambah seiring. Skema ini dapat membantu menentukan faktor pemutakhiran yang tepat untuk memaksa kesalahan pelatihan berkurang secara monoton. Algoritma optimasi dihentikan jika kesalahan validasi tidak memiliki perbaikan lebih lanjut selama beberapa jumlah zaman. Dalam penelitian ini, 2.000 epoch digunakan.

#### 15.4 STUDI EKSPERIMENTAL

Kinerja model GRNNFA dievaluasi dengan menggunakan lima dataset, dengan empat yang pertama menjadi masalah benchmark. Masalah bising-dua-terjalin-spiral pertama kali digunakan untuk melihat dan membandingkan hasil yang direkonstruksi oleh GRNNFA. Ini adalah masalah klasifikasi menggunakan data sintetis dengan noise Gaussian diperkenalkan. Masalah kedua dan ketiga, yaitu, Ozon dan Friedman #1, masing-masing terdiri dari data nyata dan sintetis (dengan diperkenalkannya derau Gaussian). Masalah keempat adalah dataset astrofisika nyata, yaitu Santa Fe Series-E, yang berisik, terputus-putus, dan nonlinier.

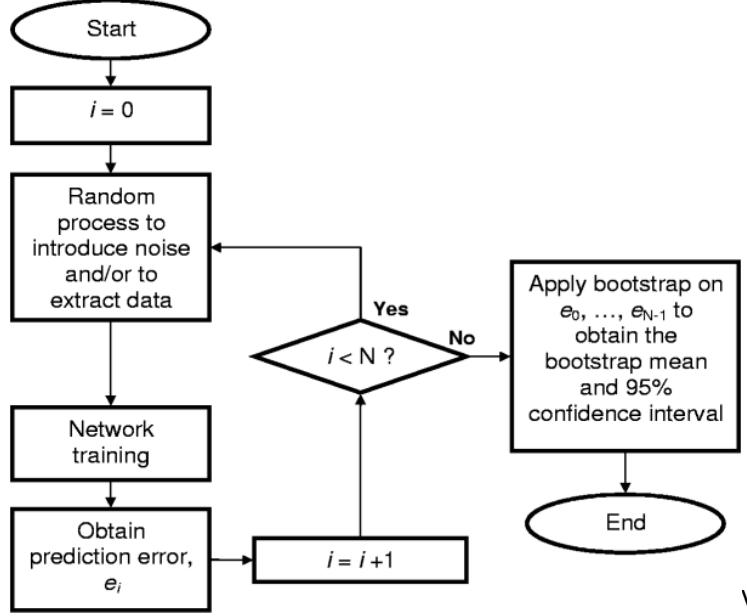
Diharapkan bahwa prosedur pengacakan yang digunakan untuk menghasilkan data yang rusak akibat noise dan pemilihan data untuk pelatihan dan pengujian jaringan dapat mempengaruhi kesalahan prediksi. Untuk membandingkan hasil yang diprediksi oleh model GRNNFA dengan hasil lain yang dipublikasikan oleh model lain terlepas dari efek pengacakan, bootstrap [26], [27] digunakan untuk mengukur indikator kinerja secara statistik. Bootstrap adalah metode untuk memperkirakan variasi statistik dari suatu parameter dalam situasi di mana distribusi sampling yang mendasari parameter tidak diketahui atau sulit untuk diperkirakan. Telah terbukti berguna untuk menghitung parameter populasi secara statistik dalam masalah dengan sampel data kecil. Gambar. 5 menunjukkan prosedur yang digunakan untuk mengurangi efek pengacakan dalam percobaan. Alih-alih menjalankan tunggal, beberapa percobaan dilakukan dan bootstrap diterapkan untuk mendapatkan kesalahan prediksi dalam bentuk rata-rata dan interval kepercayaan 95%.

Prinsip bootstrap untuk rata-rata komputasi dari satu set sampel data tercantum dalam langkah-langkah berikut.

1. Satu set data  $X = x_1, \dots, x_n$  dikumpulkan. Misalkan adalah ukuran sampel yang diamati dari distribusi probabilitas yang sama sekali tidak ditentukan  $F$ ,  $\hat{\mu}$  adalah rata-rata dari semua nilai dalam  $X$ , dan adalah jumlah pengulangan boot-strapping.

2. Gambarlah sampel acak dari titik data secara independen, dengan penggantian, dari X. Kumpulan data baru  $X^*$  adalah sampel bootstrap.
3. Rata-rata sampel bootstrap dari  $X^*$ ,  $\hat{\mu}^*$ , dihitung.

Langkah 2 dan 3 diulang sebanyak N kali untuk mendapatkan estimasi bootstrap  $\hat{\mu}_1^*, \dots, \hat{\mu}_N^*$ .



**Gambar 15.5** Algoritma untuk mengevaluasi kinerja model dengan teknik bootstrap

### Spiral Dua Jalanan Bising

Masalah benchmark sintetis ini dirancang untuk klasifikasi data yang bising. Domain input adalah persegi satuan dua dimensi (yaitu  $[0,1]^2$ ) yang berisi dua spiral yang saling terkait. Setiap spiral terdiri dari 97 distribusi Gaussian isotropik yang berpusat di sepanjang spiral. Standar deviasi masing-masing Gaussian adalah 0,025. Dataset pelatihan dibuat sesuai dengan prosedur di [28]. Perhatikan bahwa klasifikasi adalah sejenis regresi tetapi dengan keluaran diskrit. Masalah ini dipilih karena kemampuan GRNNFA dalam merekonstruksi dua spiral yang saling terkait berdasarkan data noise dapat dilihat dan dibandingkan dengan yang dari Gaussian ARTMAP, yaitu jaringan berbasis ART yang diawasi untuk tugas klasifikasi noise [28].

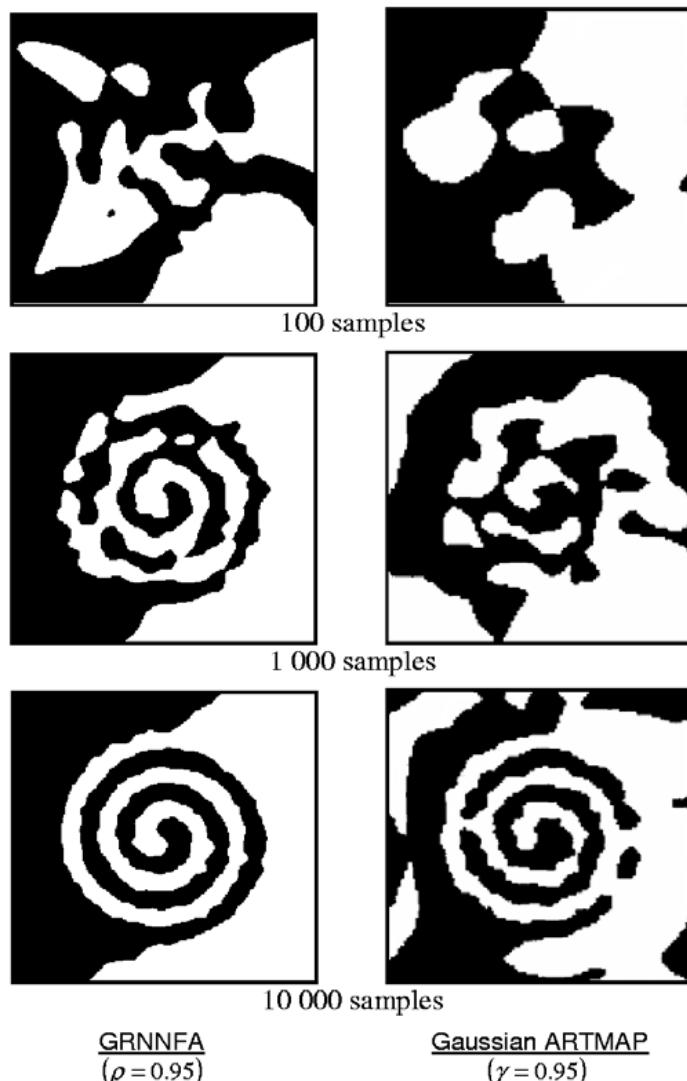
Setelah beberapa kali percobaan, parameter vigilance dan nilai K model GRNNFA ditetapkan masing-masing menjadi 0,95 dan 2. Sebanyak dua puluh percobaan dilakukan dengan sampel data acak yang berbeda. Perhatikan bahwa nilai keluaran setiap piksel gambar diperoleh dari bootstrap dengan 2.000 jumlah re-sampling. Mereka didiskritisasi, dengan menetapkan demarkasi pada nilai 0,5, baik 0 atau 1. Gambar. 6 menunjukkan gambar direkonstruksi dari dua spiral terjalin. Dapat dilihat dengan jelas bahwa gambar yang direkonstruksi dari GRNNFA lebih jernih daripada gambar dari Gaussian ARTMAP (diadaptasi dari [28]) dengan jumlah sampel pelatihan yang berbeda.

### Ozon

Dataset ini diperoleh dari University of California di Berkeley1. Ini memiliki 330 sampel dengan 8 input dan 1 output. Sampel input terdiri dari informasi meteorologi seperti kelembaban dan suhu. Output target adalah ozon harian maksimum di lokasi di cekungan Los Angeles. Sesuai dengan [29], 250 sampel dipilih secara acak dari dataset untuk pelatihan

jaringan dimana 125 sampel digunakan untuk validasi. Sisa 80 sampel digunakan untuk pengujian jaringan.

Setelah beberapa percobaan, nilai terbaik dari K-tetangga terdekat dan parameter kewaspadaan ditetapkan masing-masing ke 3 dan 0,9. Sebanyak dua puluh percobaan dilakukan. Rata-rata Mean-Squared-Error (MSE) dan standar deviasi yang diperoleh dari test set dihitung. Hasil GRNNFA dibandingkan dengan model Neural-BAG (NBAG), Bench, dan Simple. Perhatikan bahwa model Bench [30] menggunakan bagging untuk menghasilkan ansambel submodel jaringan saraf yang dilatih oleh kumpulan data berbeda yang diambil sampelnya kembali dari kumpulan data asli dengan teknik bootstrap. Dibutuhkan rata-rata output prediksi dari sub-model jaringan saraf sebagai output prediksi akhir. Model Simple mirip dengan Bench tetapi dilengkapi dengan algoritma pelatihan fast-stop [29]. Model NBAG mirip dengan Simple tetapi dengan algoritma untuk mengontrol keragaman di antara sub-model jaringan saraf untuk meningkatkan kinerja generalisasi model keseluruhan. Model-model ini diterapkan pada masalah benchmark Ozon dan hasilnya ditunjukkan pada Tabel 1.



**Gambar 15.6** Rekonstruksi bising dua spiral terjalin oleh GRNNFA dan Gaussian ARTMAP  
(diadaptasi dari [28])

**Tabel 15.1** MSE Model Berbeda pada Masalah Ozon. Standar deviasi yang dihitung dari 20 run diberi tanda kurung. (Hasil NBAG, Bench dan Simple diadaptasi dari [29]).

Model	Ozon
NBAG	18.37 (3.59)
Bangku	18.58 (3.40)
Sederhana	19.14 (3.21)
GRNNFA	17.18 (2.57)

MSE GRNNFA adalah 17,18 dengan standar deviasi 2,57. Hasil ini lebih baik daripada model lain seperti yang dilaporkan dalam [29]. Untuk memeriksa lebih lanjut kinerja GRNNFA secara statistik, rata-rata bootstrap dan batas kepercayaan 95% dari MSE dihitung, seperti yang ditunjukkan pada Tabel 2. Karena variasi rata-rata dan batas kepercayaan MSE untuk pengambilan sampel ulang yang lebih besar dari 1600 adalah kecil (yaitu kurang dari 0,2%), hasil yang diperoleh dari 1600 re-sampling yang diambil. Hasil ini membenarkan bahwa kinerja GRNNFA secara signifikan lebih baik daripada model lain dari sudut pandang statistik.

**Tabel 15.2** Rata-rata bootstrap dan batas kepercayaan MSE untuk masalah ozon

Jumlah sampel ulang	Batas Keyakinan Bawah	Batas Keyakinan Atas	Mean
200	16.104	18.280	17.154
400	16.061	18.208	17.201
800	16.203	18.253	17.204
1600	16.058	18.317	17.165
3200	16.033	18.287	17.187
6400	16.074	18.294	17.178

### Friedman #1

Ini adalah dataset benchmark sintetis yang diusulkan di [31]. Setiap sampel terdiri dari 5 input dan 1 output. Rumus untuk pembangkitan data adalah dengan persamaan berikut dimana  $\varepsilon$  derau acak Gaussian (0,1), dan  $x_1, \dots, x_5$  terdistribusi secara seragam pada domain [0,1].

$$t = 10 \sin(\pi x_1 x_2) + 20(x_3 - 0.5)^2 + 10x_4 + 5x_5 + \varepsilon \quad (22)$$

Mirip dengan [29], 1.400 sampel dibuat, 200 sampel dipilih secara acak untuk pelatihan jaringan dan 200 sampel untuk validasi. Sisa 1000 sampel digunakan untuk pengujian jaringan. Setelah beberapa kali uji coba, nilai K-nearest-neighbors dan vigilance terbaik masing-masing adalah 3 dan 0,95. Tabel 3 merangkum hasil yang diprediksi oleh GRNNFA dan model lainnya seperti yang tercantum dalam [29].

**Tabel 15.3** MSE Model Berbeda pada Soal Friedman #1. Standar deviasi yang dihitung dari 20 run diberi tanda kurung. (Hasil NBAG, Bench dan Simple diadaptasi dari [29]).

Model	Friedman #1
NBAG	4,502 (0,268)
Bangku	5.372 (0.646)
Sederhana	4,948 (0,589)
GRNNFA	4,563 (0,195)

MSE yang diperoleh dengan rata-rata hasil 20 run adalah 4,563 dengan standar deviasi 0,195. MSE GRNNFA lebih tinggi dari NBAG, tetapi lebih rendah dari yang lain. Selain itu, GRNNFA menghasilkan standar deviasi terkecil, menunjukkan kinerja yang stabil. Bootstrap kembali diterapkan untuk mengukur hasil GRNNFA secara statistik. Tabel 4 merangkum rata-rata bootstrap dan batas kepercayaan 95% dari MSE.

Rerata MSE yang diperoleh dari 1600 re-sampling (dengan variasi kurang dari 0,04%) adalah 4,5627 dengan batas kepercayaan 95% antara 4,4773 dan 4,6438. Dapat diamati bahwa MSE dari NBAG (yaitu 4,502) berada dalam interval kepercayaan 95% dari distribusi MSE GRNNFA yang diperkirakan oleh bootstrap. Ini menyiratkan bahwa kinerja GRNNFA dapat dibandingkan dengan NBAG dalam tes benchmark ini.

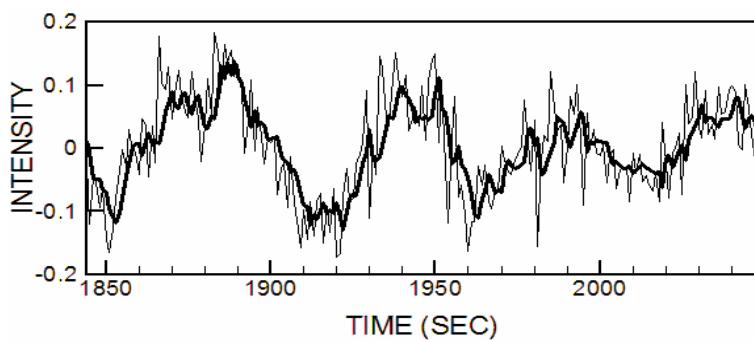
**Tabel 15.4** Bootstrap Mean dan batas kepercayaan MSE untuk masalah Friedman #1

Jumlah sampel ulang	Batas Keyakinan Bawah	Batas Keyakinan Atas	Mean
200	4.4843	4.6461	4.5631
400	4.4760	4.6494	4.5634
800	4.4743	4.6462	4.5613
1600	4.4773	4.6438	4.5627
3200	4.4761	4.6423	4.5619
6400	4.4780	4.6424	4.5635

### Sante Fe Seri E

Ini adalah masalah Seri-E Kompetisi Seri Waktu Sante Fe [32]. Ini adalah rangkaian waktu univariat dari sampel data astrofisika (variasi intensitas cahaya bintang) 2 yang bersifat bising, terputus-putus, dan nonlinier. Sesuai dengan [33], 2048 sampel digunakan, masing-masing dengan lima input dan satu output, yaitu.  $x_t = f(x_{t-1}, x_{t-2}, x_{t-3}, x_{t-4}, x_{t-5})$  di mana adalah intensitas bintang pada waktu . Urutan penyajian datanya sama persis dengan aslinya. 90% pertama dari dataset diekstraksi untuk pelatihan jaringan dan validasi. 10% terakhir diekstraksi untuk pengujian. Setelah beberapa kali percobaan, nilai terbaik dari K-nearest tetangga dan parameter kewaspadaan masing-masing adalah 2 dan 0,8. Dua puluh percobaan dilakukan. Gambar 7 menunjukkan perbandingan antara data uji (garis tipis) dan keluaran yang diprediksi dari GRNNFA (garis tebal).

Rata-rata MSE ditunjukkan pada Tabel 5. Hasil yang dilaporkan pada [33], yaitu Pattern Modeling and Recognition System (PMRS), Exponential Smoothing (ES) dan Neural Network (NN), disertakan untuk perbandingan. Perhatikan bahwa PRMS dirancang untuk prediksi deret waktu yang bising dengan menggunakan peramalan satu langkah, sedangkan ES adalah metode regresi dengan parameter pemulusan eksponensial.



**Gambar 15.7** Deret waktu aktual Seri Sante Fe-E (garis tebal) dan deret waktu yang diprediksi oleh model GRNNFA (garis tipis)

**Tabel 15.5** MSE Model Berbeda pada Soal Sante Fe Seri-E. (Hasil PMRS, ES dan NN diadaptasi dari [33]).

Model	Sante Fe Seri-E
PMRS	0,015
ES	0,033
NN	0,078
GRNNFA	0,00326

Model NN adalah perceptron multi-layer feed-forward dengan satu lapisan tersembunyi dan jumlah node tersembunyi ditentukan dengan menggunakan prosedur di [34] untuk mencapai kesalahan generalisasi minimum atau kinerja generalisasi maksimum. Dapat dilihat bahwa MSE dari GRNNFA jauh lebih rendah daripada model lainnya. Hasil bootstrap ditunjukkan pada Tabel 6.

Karena variasi rata-rata dan batas kepercayaan MSE untuk pengambilan sampel ulang yang lebih besar dari 200 adalah kecil (yaitu kurang dari 0,2%), hasil yang diperoleh dari pengambilan sampel ulang 200 diambil. Dapat diamati bahwa batas atas interval kepercayaan 95% (yaitu 0,003516) lebih rendah daripada MSE model lain seperti yang ditunjukkan pada Tabel V. Sekali lagi, kinerja GRNNFA secara signifikan lebih baik daripada model lain dari statistik sudut pandang.

**Tabel 15.6** Rata-rata Bootstrap dan batas kepercayaan MSE untuk masalah Sante Fe Series-E

Jumlah sampel ulang	Batas Keyakinan Bawah	Batas Keyakinan Atas	Mean
200	0.003349	0.003516	0.003429
400	0.003356	0.003514	0.003434

800	0.003353	0.003517	0.003433
1600	0.003357	0.003519	0.003432
3200	0.003351	0.003516	0.003431
6400	0.003352	0.003513	0.003431

## 15.5 APLIKASI UNTUK REKAYASA KESELAMATAN KEBAKARAN

Kebakaran gedung yang tidak disengaja menyebabkan banyak korban jiwa dan kerugian harta benda bagi masyarakat. Di banyak tempat komersial, sistem pencegahan dan pemadam kebakaran (misalnya sistem sprinkler, sistem hidran kebakaran, sistem deteksi kebakaran, dll.) digunakan secara luas untuk membatasi tingkat kerusakan struktur bangunan jika terjadi kebakaran. Namun demikian, api, yang terdiri dari banyak proses fisik dan kimia yang saling berinteraksi secara dinamis yang sifatnya sangat nonlinier, merupakan ancaman yang signifikan karena banyak keadaan yang tidak terduga; jika tidak dikendalikan, bisa berpotensi mematikan. Selama beberapa dekade terakhir, para ilmuwan dan insinyur telah menginvestasikan banyak upaya dalam pemodelan fenomena kebakaran dengan tujuan meningkatkan sistem pemadam kebakaran dan mengurangi risiko kebakaran. Akibatnya, banyak pendekatan numerik - model zona dan lapangan - telah dikembangkan. Secara khusus, lonjakan penerapan model lapangan [35-38] untuk masalah kebakaran jelas menunjukkan kemampuan untuk lebih memahami dan memprediksi skenario kebakaran yang realistik. Namun, diketahui dengan baik bahwa model ini biasanya memerlukan sumber daya komputasi yang luas (terutama waktu komputasi yang lama) untuk memberikan informasi teknik yang berguna (misalnya, ketinggian lapisan asap panas sementara, distribusi suhu, dll.) untuk desain keselamatan kebakaran.

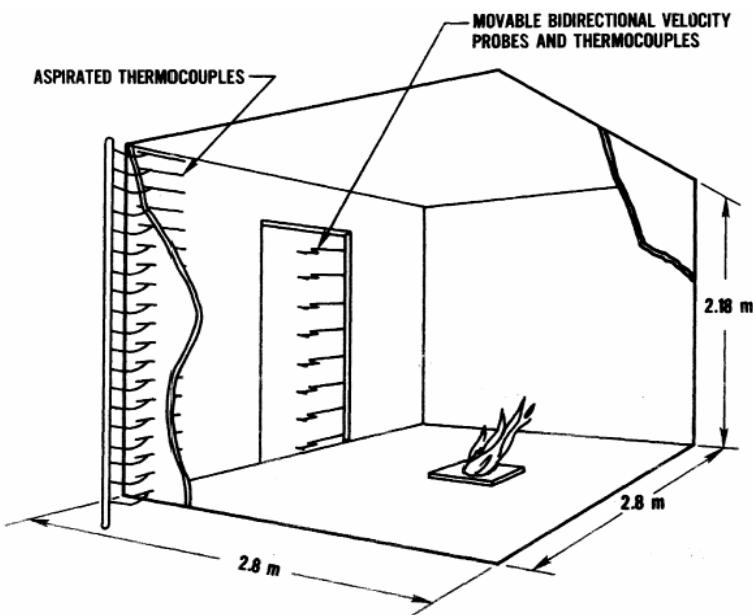
Upaya untuk mempersingkat proses siklus desain untuk mencapai solusi desain bangunan yang optimal untuk keselamatan kebakaran merupakan pertimbangan penting. Makalah ini mengeksplorasi potensi menggunakan teknik cerdas seperti jaringan saraf tiruan (JST) untuk memprediksi fenomena kebakaran. Penerapan JST untuk penelitian kebakaran masih tergolong baru. Pekerjaan perintis [39-51] telah mengkonfirmasi kelayakan penerapan JST untuk masalah kebakaran tertentu. Di antaranya, pemodelan respons detektor kebakaran adalah salah satu contoh pertama yang berhasil [39-43]. Model JST yang diterapkan didasarkan pada prosedur feed-forward multi-layer perceptron (MLP), jaringan berulang untuk prediksi time series dan self-organizing map (SOM). Karena hasil yang menggembirakan yang disajikan melalui studi ini, kami telah melakukan penelitian mendasar dan mengeksplorasi MLP dan Fuzzy ARTMAP (FAM) untuk memprediksi waktu aktuasi sprinkler [44] dan terjadinya flashover [45]. Selanjutnya, model jaringan saraf – PEMAP [46] dikembangkan berdasarkan entropi maksimum untuk memprediksi terjadinya flashover dengan prasangka minimum. Keberhasilan penerapan JST untuk membangun desain api [47-51] secara ringkas ditunjukkan melalui studi penelitian terbaru.

Untuk mengevaluasi kinerja model GRNNFA, kemampuannya untuk menentukan lokasi antarmuka termal dalam kebakaran kompartemen tunggal disajikan. Perbandingan prediksi model terhadap data eksperimen Steckler et al [52] dilakukan. Prediksi model juga diverifikasi lebih lanjut terhadap hasil model lapangan yang dihasilkan dengan menggunakan kode api simulasi eddy besar – simulator dinamika api (FDS) [53]. FDS untuk prediksi model

lapangan untuk api kompartemen tunggal dipilih karena prediksi yang andal dan metodologi yang terbukti untuk studi kebakaran seperti yang ditunjukkan dalam studi terbaru tentang perambatan api PMMA [54].

### Pengantar Eksperimen Steckler

Serangkaian percobaan keadaan tunak skala penuh dari aliran yang diinduksi dalam kebakaran kompartemen tunggal telah dilaporkan di Steckler et al. [52]. Pengaturan pengujian ditunjukkan pada Gambar. 8.



**Gambar 15.8** Pengaturan eksperimental percobaan Steckler. Angka ini diadopsi dari [52].

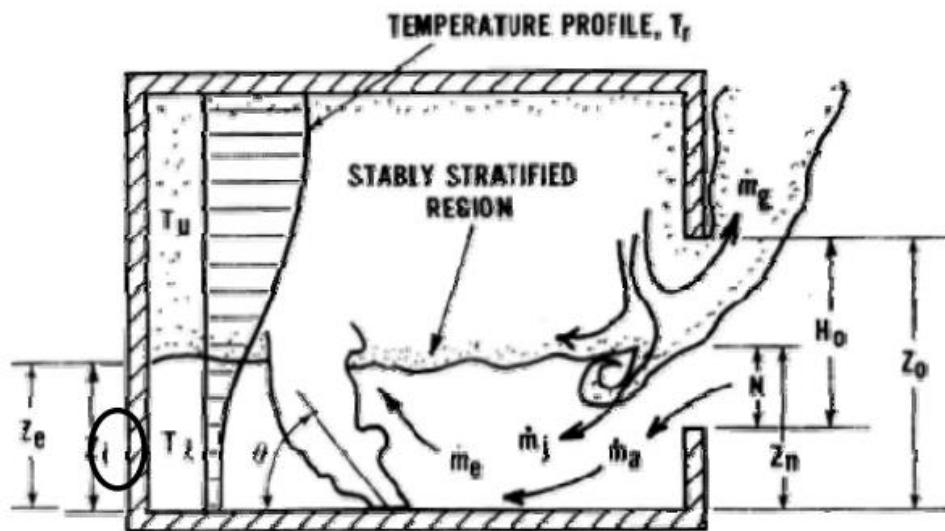
Sebanyak 55 percobaan dilakukan yang mencakup lokasi kebakaran yang berbeda, intensitas kebakaran dan ukuran jendela dan pintu. Ketinggian antarmuka termal seperti yang didefinisikan pada Gambar. 9 diperkirakan dari data profil suhu kamar sebagai posisi perubahan suhu yang cepat antara lapisan dingin bawah dan lapisan panas atas kompartemen. Karena efek difusi dan pencampuran aliran fluida, tinggi antarmuka termal tidak dapat ditentukan secara tepat. Dipastikan bahwa ketinggian antarmuka hanya dapat dicapai dalam kisaran akurasi  $\pm 8\%$  hingga  $\pm 50\%$  [52]. Nilai ketinggian antarmuka yang direkam dalam format mean  $\pm$  error digunakan untuk membandingkan prediksi GRNNFA.

### Performa GRNNFA Dilatih oleh Data Eksperimental Bising

Data eksperimen diperoleh dari Steckler et al. [52] dipekerjakan untuk pelatihan dan evaluasi GRNNFA. Parameter terkontrol dan hasil pengukuran disajikan pada Tabel 7. Dataset mencakup 6 parameter terkontrol: lebar dan tinggi ambang bukaan, jarak sejajar dan tegak lurus dari pusat dasar api ke garis tengah vertikal bukaan, kekuatan api dan suhu sekitar digunakan sebagai sampel data masukan untuk jaringan. Dalam studi ini, nilai rata-rata dari ketinggian yang diukur dari antarmuka termal dipilih untuk menjadi nilai target untuk pelatihan jaringan dan kesalahan hanya digunakan untuk mengevaluasi kinerja GRNNFA.

Pendekatan konvensional yang terkenal – “Leave-One-Out Cross-Validation”, yang sering digunakan untuk evaluasi kinerja model JST, telah diterapkan. Ini berarti bahwa dari jumlah total 55 percobaan, untuk setiap percobaan, 54 percobaan disajikan ke jaringan untuk pelatihan untuk memprediksi data sampel “diambil”. Sebanyak 20 set pelatihan dan prediksi

dilakukan; setiap urutan sampel pelatihan dikocok secara acak. Bootstrap dengan 5000 resampling diterapkan pada 20 set hasil prediksi untuk mendapatkan rata-rata bootstrap dan batas kepercayaan 95% dari percobaan itu. Rata-rata bootstrap dari output yang diprediksi diplot terhadap nilai target pada Gambar. 10.



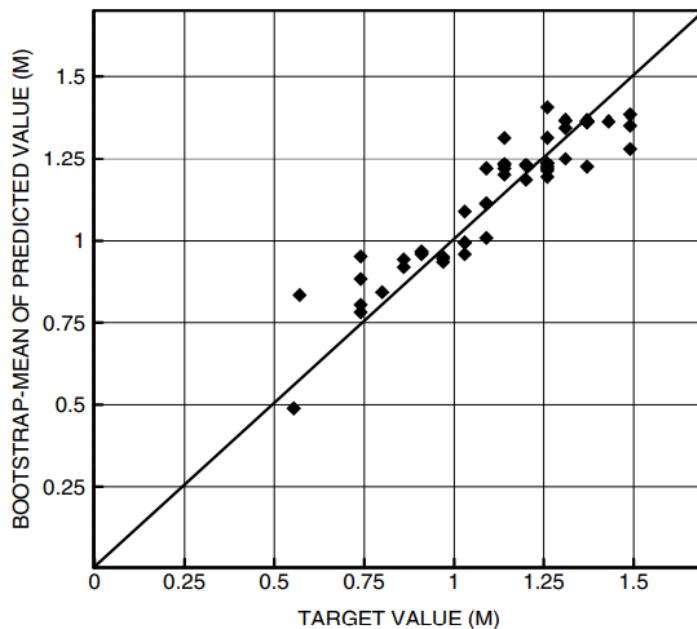
**Gambar 15.9** Tinggi  $z_i$  adalah tinggi rata-rata lapisan asap di atas lantai. Ini didefinisikan sebagai ketinggian antarmuka termal kompartemen api. Angka ini diadopsi dari 52.

**Tabel 15.7** Variabel dalam Percobaan Steckler

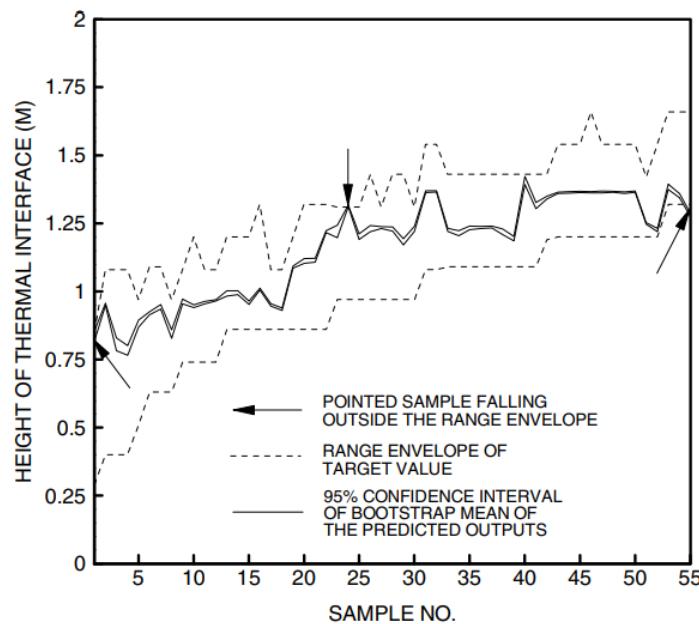
<b>Variabel Terkendali</b>	<ul style="list-style-type: none"> <li>- Lebar bukaan</li> <li>- Ketinggian ambang bukaan</li> <li>- Kekuatan Api</li> <li>- Jarak dari garis tengah vertikal bukaan ke pusat dasar api (sejajar dengan bukaan)</li> <li>- Jarak dari garis tengah vertikal bukaan ke pusat beban api (tegak lurus bukaan)</li> <li>- Suhu sekitar</li> </ul>
<b>Hasil Terukur</b>	<ul style="list-style-type: none"> <li>- Laju aliran massa udara</li> <li>- Lokasi bidang netral</li> <li>- Ketinggian antarmuka termal</li> <li>- Suhu rata-rata lapisan gas atas</li> <li>- Suhu rata-rata lapisan udara bawah</li> <li>- Tingkat pencampuran maksimum</li> <li>- Profil kecepatan udara saat pembukaan</li> <li>- Profil suhu saat pembukaan</li> </ul>

Kesepakatan yang baik dicapai antara keluaran yang diprediksi dan nilai yang ditargetkan. Koefisien korelasi antara hasil eksperimen dan prediksi dengan GRNNFA menghasilkan nilai 0,929. 95% interval kepercayaan bootstrap dan rentang nilai target diilustrasikan pada Gambar. 11 di mana hasil prediksi telah disusun dalam urutan menaik

dengan nilai target. Secara ringkas diamati bahwa, kecuali 3 sampel yang ditunjukkan pada Gambar 11, 52 sampel yang tersisa berada dalam kisaran amplop (yaitu kesalahan rata-rata) dari nilai keluaran target. Kita dapat menyimpulkan bahwa persentase statistik prediksi yang benar terletak pada 94,5%. Mayoritas pengukuran kebakaran, termasuk data eksperimen Steckler et al. [52] secara implisit memiliki berbagai tingkat kebisingan tertanam karena fluktuasi yang ada dalam aliran fluida dan proses perpindahan panas.



**Gambar 15.10** Validasi Leave-one-out dengan teknik bootstrap



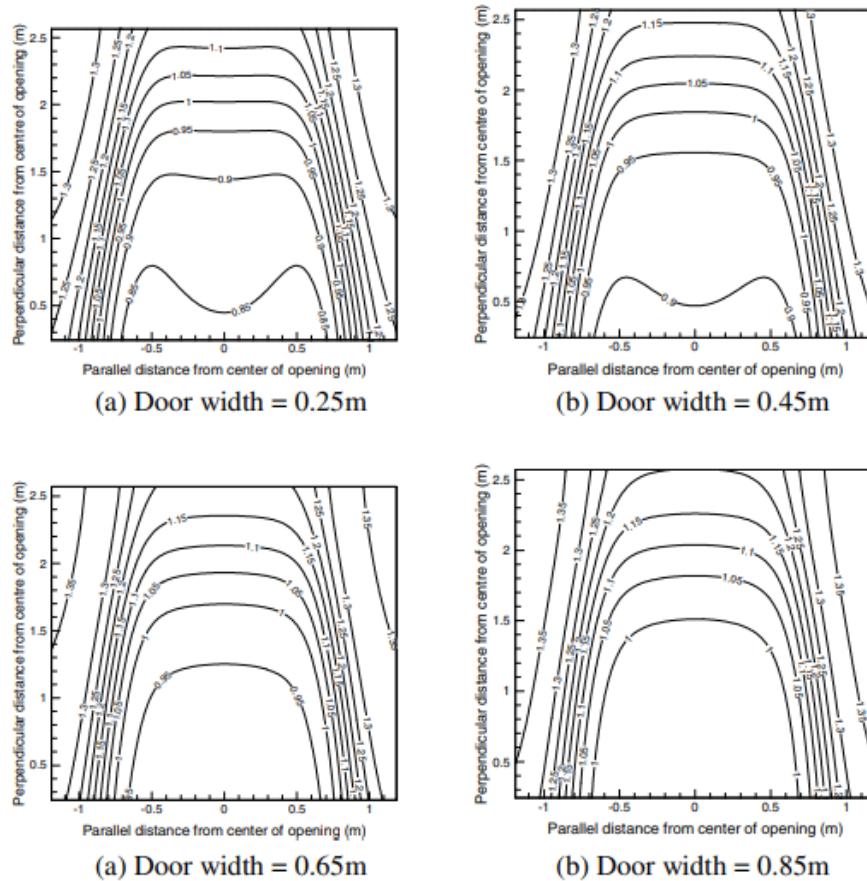
**Gambar 15.11** Tumpang tindih interval kepercayaan 95% prediksi oleh GRNNFA pada rentang lokasi antarmuka termal dari percobaan Steckler

GRNNFA yang diusulkan untuk prediksi kebakaran, ditingkatkan dengan fitur penghilangan kebisingan efektif yang tertanam, merespons secara positif terhadap prediksi akurat dari antarmuka termal. Ini telah dikonfirmasi oleh tingkat kepercayaan tinggi yang

dicapai melalui prediksi GRNNFA meskipun data input sampel terbatas tersedia untuk tujuan pelatihan.

### Ketinggian Antarmuka Termal dalam Berbagai Lebar Pembukaan Pintu

Model api GRNNFA terlatih diterapkan untuk memprediksi lokasi antarmuka termal dengan lebar bukaan pintu yang berbeda mulai dari 0,25 m hingga 0,95 m dengan langkah inkremental 0,05m. Dalam setiap langkah, model api GRNNFA yang terlatih diterapkan untuk menentukan ketinggian antarmuka termal kondisi tunak dengan menempatkan api di setiap kisi ( $0,01\text{m} \times 0,01\text{m}$ ) dari lantai kompartemen. Bagian atas dasar api ditinggikan hingga 0,02 m di atas lantai dengan laju pelepasan panas konstan sebesar 62,9 kW dan suhu sekitar 20°C di seluruh prediksi. Lokasi kontur antarmuka termal disajikan pada Gambar. 12. Prediksi terungkap: (i) lapisan antarmuka termal dinaikkan melalui pelebaran inkremental dari bukaan pintu; dan (ii) lapisan antarmuka termal diturunkan dengan menempatkan dasar api di dekat bukaan pintu. Dugaan ini diverifikasi a posteriori.

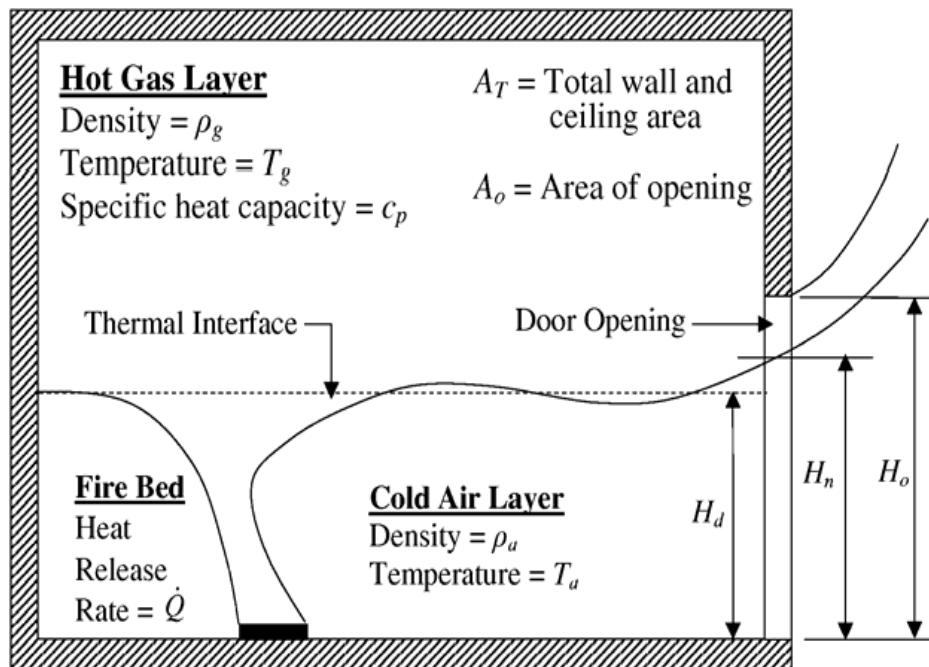


**Gambar 15.12** Kontur ketinggian antarmuka termal dengan berbagai lebar bukaan pintu

Dari sudut pandang teoretis, hubungan empiris yang berlaku untuk kebakaran kompartemen tunggal dapat diterapkan untuk memberikan beberapa tren signifikan setelahnya mengkonfirmasi perilaku antarmuka termal yang diprediksi oleh GRNNFA. Tiga argumen untuk dugaan (i) disajikan. Argumen pertama berfokus pada suhu lapisan atas gas panas, yang dapat ditentukan oleh [55]:

$$\frac{T_g - T_a}{T_a} = 1.63 \left( \frac{\dot{Q}}{\sqrt{g\rho_a c_p T_a A_o \sqrt{H_o}}} \right)^{2/3} \left( \frac{h_k A_T}{\sqrt{g\rho_a c_p A_o \sqrt{H_o}}} \right)^{-1/3} \quad (23)$$

di mana  $g$  dan  $h_k$  adalah percepatan gravitasi dan koefisien perpindahan panas konveksi dari dinding dan langit-langit kompartemen. Variabel lain seperti yang ditunjukkan pada Persamaan. (14) sampai (16) digambarkan pada Gambar 13.



**Gambar 15.13** Nomenklatur variabel ditunjukkan pada persamaan (23) sampai (25)

Jika lebar bukaan (yaitu  $A_o/H_o$ ) diperbesar dalam Persamaan. (14), dengan mempertimbangkan laju pelepasan panas yang konstan dan semua sifat termofisika dan kuantitas ambien diasumsikan diketahui, Persamaan. (14) menghasilkan suhu keadaan tunak yang lebih rendah dari lapisan gas panas,  $T_g$ , yang pada akhirnya akan menaikkan tingkat bidang netral. Selanjutnya, argumen kedua untuk dugaan dapat ditunjukkan bahwa dengan mempertimbangkan hubungan berikut di mana lokasi saraf [56] dinyatakan oleh:

$$\frac{H_n}{H_0} = \frac{1}{1 + [(1 + \phi/r)^2 \cdot \rho_a/\rho_g]^{1/3}} \quad (24)$$

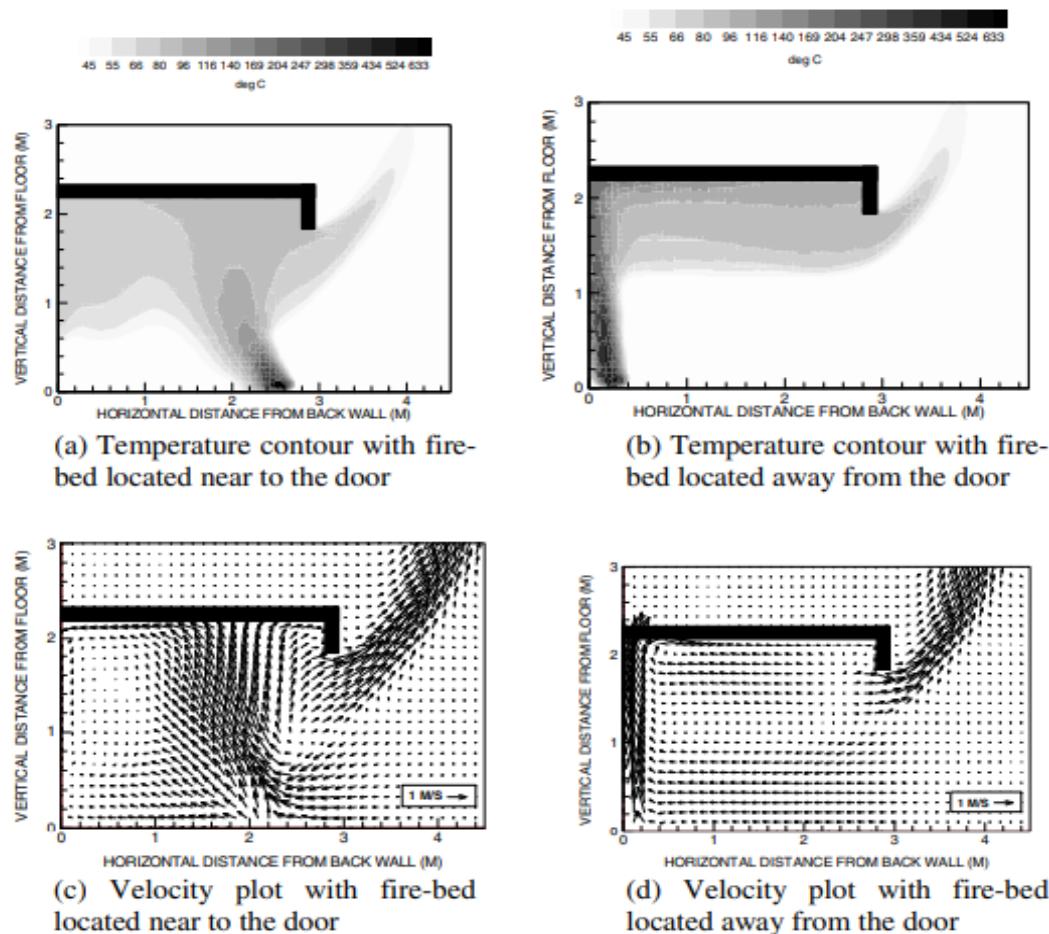
di mana  $r/\phi$  adalah rasio massa bahan bakar/udara stoikiometrik. Hal ini dapat diamati dari Persamaan. (24) bahwa bidang netral akan dinaikkan oleh peningkatan densitas gas panas. Karena nilai  $g$  berbanding terbalik dengan  $T_g$ , maka dapat ditunjukkan dengan menggabungkan Persamaan. (23) dan (24) bahwa bidang saraf akan dinaikkan dengan memperbesar lebar bukaan. Yang ketiga dapat dikatakan bahwa jika hubungan antara bidang netral dan lokasi antarmuka termal yang diberikan oleh Karlsson dan Quintiere [57] digunakan:

$$\sqrt{\rho_a}(H_n - H_d)^{1/2} \left( H_n + \frac{H_d}{2} \right) = \sqrt{\rho_g}(H_o - H_n)^{3/2} \quad (25)$$

Ketinggian antarmuka termal meningkat secara monoton dengan ketinggian bidang netral. Oleh karena itu dapat disimpulkan secara memadai dari tiga argumen pendukung ini bahwa

ketinggian antarmuka termal akan meningkat dengan meningkatkan lebar bukaan pintu untuk kebakaran kompartemen tunggal sehingga memverifikasi prediksi GRNNFA.

Dari sudut pandang numerik, kami menerapkan model lapangan mapan – Fire Dynamics Simulator (FDS) [53] untuk memverifikasi dugaan (ii) selain pertimbangan teoritis yang disebutkan di atas. Dalam simulasi kebakaran oleh FDS, grid didistribusikan secara merata di seluruh domain dengan ukuran (sekitar 0,05m) yang kurang dari skala panjang karakteristik model (yaitu 0,32m). Gambar 14 mewakili kontur suhu yang diprediksi dan plot kecepatan di bagian tengah kompartemen dengan api terletak di dekat bukaan pintu dan di dinding belakang kompartemen masing-masing.



**Gambar 15.14** Profil suhu api kompartemen dengan lokasi kebakaran yang berbeda

Hasilnya dengan jelas menunjukkan bahwa ketinggian antarmuka termal diturunkan ketika api berada di dekat bukaan pintu. Wawasan penting melalui plot vektor yang ditunjukkan pada Gambar. 14 (c) dan (d) adalah aliran ke atas yang kuat dari semburan api membatasi gas lapisan atas yang mengalir keluar dari kompartemen untuk skenario di mana api terletak dekat ke bukaan pintu. Perilaku ini sesuai dengan antarmuka termal yang ditangkap oleh model api GRNNFA.

## 15.6 KESIMPULAN

GRNNFA adalah model jaringan saraf hibrida baru yang dirancang khusus untuk regresi data yang bising. Ia menggunakan FA sebagai praprosesor sebagai GRNN untuk mengompresi

semua sampel pelatihan ke dalam satu set kernel yang representatif. Skema kompresi dikembangkan untuk menyampaikan informasi dari prototipe FA ke kernel GRNN. Skema kompresi ini juga memfasilitasi penghilangan noise. Algoritma heuristik juga dikembangkan untuk menyetel lebar kernel secara dinamis selama pelatihan jaringan.

GRNNFA diterapkan untuk memprediksi lokasi antarmuka termal dalam kebakaran kompartemen tunggal. Hasil prediksi dibandingkan dengan hasil eksperimen. Ditemukan bahwa GRNNFA mampu memprediksi lokasi antarmuka termal dengan baik dalam rentang hasil eksperimen hingga akurasi 94,5% (yaitu hanya 3 dari 55 sampel yang diprediksi di luar rentang amlop). Dapat disimpulkan bahwa GRNNFA mampu menangkap perilaku sistem dinamik kebakaran dari data eksperimen. Selain itu, model api GRNNFA mampu menangkap fenomena kebakaran dari data eksperimen yang tersedia bahwa ketinggian antarmuka termal akan diturunkan jika lebar bukaan dikurangi. Selain itu, ketinggian juga akan diturunkan jika api terletak di dekat bukaan yang ukurannya tetap. Plot kontur seperti yang ditunjukkan pada Gambar. 14 (a) dan (b) sangat berguna untuk memahami perilaku antarmuka termal yang akan membutuhkan waktu komputasi yang lama untuk mengevaluasi model CFD. Juga, model GRNNFA yang terlatih diterapkan pada lima kasus uji yang tidak muncul dalam eksperimen Stecker. Hasilnya dibandingkan dengan yang disimulasikan menggunakan FDS. Ditemukan bahwa perbedaan antara prediksi dan simulasi berada dalam kisaran kesalahan minimum seperti yang ditunjukkan pada [52]. Tes ini menunjukkan kinerja yang sangat baik dari model GRNNFA dalam memprediksi antarmuka termal di lokasi tak terlihat dalam pelatihan jaringan. Hal ini juga mengungkapkan bahwa akurasi prediksi terkait dengan jumlah pengetahuan yang diberikan untuk pelatihan jaringan yang mirip dengan pembelajaran manusia.

Studi ini berhasil menunjukkan bahwa model kebakaran GRNNFA yang unik, baru, dan baru cukup cerdas dan cerdas untuk menghilangkan kebisingan dan ketidakpastian yang tertanam dalam set data pelatihan dan untuk menangkap secara efisien karakteristik asli yang dominan dari fenomena kebakaran dalam hitungan detik dari sampel terbatas.

## BAB 16

### PENGAMBILAN KEPUTUSAN STRATEGI OPTIMAL AGLOMERASI PENDUDUK DALAM PERENCANAAN KOTA DENGAN PATH-CONVERGED DESIGN

Bab ini bertujuan pertama untuk mengidentifikasi aglomerasi populasi yang ada dan efisiensinya, dan kedua untuk mensimulasikan pengambilan keputusan untuk strategi migrasi yang optimal dalam perencanaan kota untuk menghilangkan inefisiensi di antara kota-kota di Cina. Pertama, identifikasi berdasarkan path-converged design mengungkapkan inefisiensi dalam aglomerasi populasi yang ada di China karena populasi sebagian besar mengaglomerasi ke kota-kota dengan tingkat urbanisasi lebih rendah dari 0,35 dan populasi berkumpul ke daerah-daerah dengan tingkat urbanisasi lebih rendah dari tingkat rata-rata di kota besar, menengah dan kecil. kota dari perspektif regional dan perkotaan. Kedua, pengambilan keputusan untuk migrasi penduduk regional berjalan dengan baik dalam menghilangkan inefisiensi. Dengan beremigrasi sekitar 14, 10, dan 14 persen populasi regional dari kota-kota dengan tingkat urbanisasi rendah ke kota-kota dengan tingkat urbanisasi yang lebih tinggi, kekuatan inefisiensi antara benchmark dan distribusi populasi regional menyusut menjadi 0,058, 0,041, dan 0,056 dari 0,1464, 0,0985, 0,1397 untuk masing-masing kota kecil, menengah, dan besar.

#### **16.1 PENDAHULUAN**

Studi sebelumnya tentang urbanisasi telah difokuskan pada migrasi penduduk. Johnson [4] memperkirakan sekitar 39,7 juta imigrasi dan 16,3 juta emigrasi di provinsi-provinsi Tiongkok selama tahun 2000. Yang [11] mempelajari skala dan intensitas migrasi penduduk Tiongkok dan menemukan bahwa sekitar 20 juta orang pedesaan berimigrasi ke kota-kota selama tahun 1955-2000. Yu dan Zhang [12] menggunakan metode terkait arah dan jarak dalam statistik spasial untuk mempelajari imigrasi penduduk daerah metropolitan Beijing, Tianjin dan Tang, daerah metropolis Delta Yangtze dan daerah metropolitan Delta Sungai Pearl dari perspektif arah imigrasi, jarak imigrasi dan faktor imigrasi. Wang dan Huang [13] menemukan bahwa imigrasi provinsi merupakan faktor yang tak tergantikan untuk mendorong pembangunan di Cina Timur selama 1995-2000.

Selain penyelidikan migrasi penduduk, penelitian cenderung mengeksplorasi apakah urbanisasi tertinggal dari pertumbuhan ekonomi. Cai [1] berpendapat bahwa kemajuan urbanisasi cenderung menghasilkan aglomerasi produksi daripada aglomerasi populasi, yaitu, sistem itu sendiri sebagian menyebabkan perkembangan urbanisasi tertinggal dari pertumbuhan ekonomi. Krisis saat ini yang dihadapi pembangunan urbanisasi Cina pada dasarnya adalah krisis pasokan yang sistematis [2]. Menggunakan data panel provinsi selama 1987-2004, Lu dan Chen [8] menunjukkan bahwa kesenjangan pendapatan yang melebar antara daerah perkotaan dan pedesaan terkait dengan kebijakan yang berpihak pada daerah perkotaan dari pemerintah daerah.

Berbeda dengan penelitian sebelumnya yang berfokus pada bagaimana mengontrol migrasi bebas dan apakah urbanisasi tertinggal dari pertumbuhan ekonomi di China, tujuan

dari penelitian ini ada dua. Pertama, penelitian ini bertujuan untuk mengidentifikasi aglomerasi penduduk yang ada untuk kota kecil, menengah, dan besar baik dari perspektif regional maupun perkotaan dan untuk mengevaluasi efisiensi aglomerasi penduduk yang ada dalam perencanaan kota. Kedua, penelitian ini bertujuan untuk mengusulkan pengambilan keputusan untuk strategi optimal aglomerasi penduduk dalam perencanaan kota.

Terinspirasi oleh investigasi Henderson [3] tentang bagaimana penyimpangan yang signifikan dari setiap tingkat optimal konsentrasi perkotaan atau tingkat urbanisasi menyebabkan kerugian ekonomi dalam hal maksimalisasi pertumbuhan produktivitas, studi ini mengembangkan desain jalur-konvergen berdasarkan distribusi kepadatan kernel nonparametrik. pendekatan untuk mengidentifikasi aglomerasi populasi dan mengusulkan pengambilan keputusan untuk aglomerasi populasi dengan tujuan menghilangkan inefisiensi di Cina.

Bagian 2 secara singkat menggambarkan desain jalur-konvergensi berdasarkan pendekatan nonparametrik. Bagian 3 menyajikan sumber data, benchmark, dan identifikasi jalur populasi melalui fungsi kepadatan kernel. Bagian 4 menyajikan pengambilan keputusan untuk migrasi penduduk yang optimal yang bertujuan untuk menghilangkan inefisiensi. Bagian 5 menyimpulkan.

## **16.2 DESAIN KONVERGENSI JALUR**

Identifikasi desain jalur-konvergen berdasarkan ekonometrik nonparametrik dikembangkan dalam penelitian ini daripada regresi linier tipikal, kointegrasi Granger, dan model ARCH. Kebijakan kependudukan China telah menyebabkan perbedaan besar antara penduduk perkotaan yang sebenarnya dan penduduk perkotaan yang terdaftar, menurut sistem daftar rumah tangga. Misalnya, populasi terapung di Beijing adalah 3,573 juta; 23 persen dari orang-orang itu adalah permanen 2005, dan 38,8 persen dari orang-orang itu telah bekerja dan tinggal di Beijing selama lebih dari lima tahun. Mereka pada dasarnya adalah "penduduk Beijing." Apalagi standar statistik telah mengalami beberapa kali perubahan dan penyesuaian, sehingga pengamatan terhadap data kependudukan cenderung bervariasi karena berbagai alasan. Tingkat urbanisasi data yang diamati dari sistem daftar rumah tangga menyimpang secara substansial dari tingkat urbanisasi yang sebenarnya. Bahkan jika data cross-sectional atau deret waktu diterima oleh unit root test, analisis model seperti regresi linier dan ARCH diragukan karena distribusi itu sendiri menyajikan fitur ekor gemuk, dan momen orde yang lebih tinggi tidak ada. Pendekatan identifikasi aglomerasi penduduk berawal dari perubahan struktur urbanisasi dengan tiga proses berikut. Pertama, misalkan alokasi penduduk awal adalah keseimbangan struktur urbanisasi. Kedua, ketika populasi baru berimigrasi ke ekuilibrium awal, struktur awal akan berubah menjadi ketidakseimbangan dinamis alokasi populasi. Akhirnya, struktur disequilibrium akan kembali ke re-ekuilibrium setelah beberapa waktu untuk menyesuaikan ketidakseimbangan menjadi keadaan keseimbangan alokasi sumber daya.

Proses pertama yang bersangkutan adalah bagaimana memodelkan keseimbangan awal alokasi penduduk dari struktur urbanisasi. Studi ini memulai analisis struktur urbanisasi menggunakan estimasi densitas kernel nonparametrik. Keseimbangan awal struktur urbanisasi adalah struktur dasar yang tidak diketahui, yang perlu diestimasi.

Proses kedua yang terlibat adalah bagaimana memodelkan proses perubahan alokasi populasi struktur urbanisasi dari ekuilibrium awal menjadi disekuilibrium, ketika imigrasi populasi baru terjadi dan mengubah efisiensi. Misalkan total imigrasi relatif kecil dibandingkan dengan total penduduk asli. Jika tidak, keseimbangan awal struktur urbanisasi akan rusak daripada berubah menjadi ketidakseimbangan dinamis, yang berada di luar cakupan penelitian ini. Dengan demikian, faktor populasi migrasi baru tidak berada pada posisi yang setara dengan populasi aslinya. Masuknya populasi baru cenderung berkontribusi pada efisiensi melalui promosi kualitas daripada peningkatan kuantitas. Dalam pengertian ini, penelitian ini berusaha mengidentifikasi bagaimana efisiensi alokasi penduduk berubah di bawah struktur kondisional dari faktor populasi baru.

Proses terakhir yang bersangkutan adalah bagaimana memodelkan proses perubahan struktur alokasi penduduk dari disekuilibrium ke ekuilibrium akhir. Seluruh proses perubahan, dari ekuilibrium ke disekuilibrium dan kemudian ke ekuilibrium akhir selama semua periode, disebabkan oleh migrasi imigrasi penduduk baru. Untuk mencapai tujuan tersebut, sebuah desain jalur konvergen dari populasi baru diusulkan untuk mengidentifikasi efisiensi alokasi populasi dengan tiga langkah yang diberikan.

Misalkan struktur yang mendasari menghasilkan tingkat urbanisasi dunia nyata yang diamati. Identifikasi mengacu pada kesimpulan yang diambil dari distribusi probabilitas variabel yang diamati ke struktur yang mendasarinya. Biarkan  $X_i, i = 1, \dots, n$ , menjadi tingkat urbanisasi yang diamati dari kota  $i$ , misalkan struktur yang mendasari tingkat urbanisasi keseluruhan adalah:

$$S_0 : f(x, X) \quad (1)$$

Dimana:

$$X = (X_1, X_2, \dots, X_n).$$

### Model Tolok Ukur

Estimasi struktur dasar urbanisasi diberikan dengan estimasi kepadatan kernel berikut:

$$S_1 \quad f_n(x, X) = \frac{1}{n} \sum_{i=1}^n h^{-1} K\left(\frac{x - X_i}{h}\right) \quad (2)$$

di mana  $K(\bullet)$  adalah singkatan dari fungsi kernel dan  $h$  bandwidth.

Persamaan (2) menyajikan perkiraan kepadatan distribusi tingkat urbanisasi dengan kombinasi informasi di semua kota tingkat prefektur. Ini memberikan bobot yang sama  $1/n$  pada setiap pengamatan  $X_i$ . Artinya, estimasi kepadatan kernel rata-rata tertimbang aritmatika memodelkan keseimbangan alokasi sumber daya pada tingkat urbanisasi secara keseluruhan.

### Model Jalur

Migrasi penduduk mencerminkan variabel kelembagaan dan diambil sebagai strategi yang memungkinkan untuk mengubah tingkat urbanisasi dalam penelitian ini. Untuk

mengidentifikasi alokasi populasi di berbagai wilayah, pendekatan kepadatan kernel bersyarat dilengkapi dengan desain jalur-konvergen untuk mengeksplorasi struktur dasar tingkat urbanisasi.

### a) Struktur bersyarat

Estimasi fungsi kepadatan bersyarat dari struktur bersyarat diberikan oleh:

$$\begin{aligned} s_2 \quad f_n(x, X|p) &= \frac{f_n(x, p)}{f_n(p)} \\ &= \frac{\frac{1}{n} \sum_{l=1}^n h^{-2} K_0\left(\frac{x-X_l}{h}, \frac{p-p_l}{h}\right)}{\frac{1}{n} \sum_{j=1}^n h^{-1} K_1\left(\frac{p-p_j}{h}\right)} \end{aligned} \quad (3)$$

Mengambil

$$K_0\left(\frac{x-X_l}{h}, \frac{p-p_l}{h}\right) = K_1\left(\frac{p-p_l}{h}\right) K\left(\frac{x-X_l}{h}\right)$$

Membuatkan

$$\omega_l = \frac{K_1\left(\frac{p-p_l}{h}\right)}{\sum_{j=1}^n K_1\left(\frac{p-p_j}{h}\right)} \quad (4)$$

Disini  $K_0$ ,  $K_1$  dan  $h$  adalah fungsi kernel dan bandwidth yang sama pada persamaan (2), dan  $\omega_i$  adalah lintasan dari bobot populasi kota  $i$ ,  $i = 1, \dots, n$ .  $p_i = p_i t$  dirancang sesuai dengan rasio penduduk terhadap PDB untuk kota  $i$  pada waktu  $t$ .

Oleh karena itu, fungsi kepadatan bersyarat dari struktur bersyarat diberikan oleh:

$$f_n(x | X | \omega) = f_n(x | X | p) = \sum_{j=1}^n \omega_j h^{-1} K\left(\frac{x-X_j}{h}\right) \quad (5)$$

Misalkan  $\omega_j = 1/n$  mendefinisikan keseimbangan alokasi penduduk dalam hubungan (4) di antara semua kota; maka  $\omega_j$  pada (5) merupakan indikator derajat ketidakseimbangan alokasi penduduk. Nilai  $\omega_j$  mewakili kekuatan ketidakseimbangan. Ini sangat diperlukan untuk desain jalur konvergen karena menggambarkan penurunan efisiensi imigrasi populasi baru dari waktu ke waktu.

**b) Desain jalur-konvergen**

Secara khusus, biarkan

$$K_1\left(\frac{p - p_l}{h}\right) = \frac{I}{2h} I(|p - p_l| \leq h),$$

Kemudian

$$\omega = \frac{K_1\left(\frac{p - p_l}{h}\right)}{\sum_{j=1}^n K_1\left(\frac{p - p_j}{h}\right)} = \frac{1}{n} \quad (6)$$

Dengan fungsi kerapatan seragam  $K_1$ , tanpa mengungkapkan efisiensi populasi, persamaan (6) membuat model (5) kembali ke model (2).

Dengan fungsi kerapatan seragam  $K_1$ , persamaan (6) mengubah model (5) kembali menjadi model (2).

Sekarang biarkan

$$K_1\left(\frac{p - p_l}{h}\right) = \frac{p_l}{2h} I(|p - p_l| \leq h)$$

dalam (5), maka

$$\omega = \frac{K_1\left(\frac{p - p_l}{h}\right)}{\sum_{j=1}^n K_1\left(\frac{p - p_j}{h}\right)} = \frac{p_l}{\sum_{j=1}^n p_l} \quad (7)$$

Selanjutnya, asumsi ekonomi bahwa  $p_l t = P_l t / GDP_t$  akan konvergen menjadi konstan ketika waktu  $t$  mendekati tak terhingga dan probabilitas satu benar,

$$P\left(\lim_{t \rightarrow \infty} p_l t = constant\right) = 1 \quad (8)$$

Bahkan jika waktu  $t$  diberikan, persamaan (8) mungkin masih berlaku karena pengaruh ekonomi terencana terhadap PDB dan pengaruh sistem register rumah tangga terhadap populasi di Cina.

Kemudian:

$$P\left(\lim_{t \rightarrow \infty} \left[ \omega(t) - \frac{1}{n} \right] = 0\right) = 1 \quad (9)$$

Persamaan ini disebut sebagai I path-converged design dalam penelitian ini. Sekarang identifikasi Path dari struktur yang mendasari diberikan sebagai berikut.

**Definisi 1.** Struktur dasar  $S_0$  dikatakan  $\omega$  jalur yang dapat diidentifikasi dengan probabilitas satu jika (9) dan kedua persamaan (10) dan (11) dipenuhi:

$$(a) \quad P\left(\lim_{n \rightarrow \infty} f_n(x, X) = f(x, X)\right) = 1 \quad (10)$$

$$(b) \quad P\left(\lim_{n \rightarrow \infty} [f_n(x, X, \omega) - f_n(x, X)] = 0\right) = 1 \quad (11)$$

Identifikasi jalur populasi mewujudkan identifikasi perubahan efisiensi alokasi jalur populasi dan identifikasi struktur urbanisasi yang mendasari  $S_0$  efisiensi produksi dengan mengamati perubahan efisiensi model jalur  $S_2$  berdasarkan benchmark model  $S_1$  dengan probabilitas satu.

**Definisi 2.** Kota  $x$  dikatakan tidak efisien jika struktur dasarnya  $S_0$  adalah  $\omega$  jalur yang dapat diidentifikasi, dan  $x$  memenuhi  $f_n(x, X, \omega) < f_n(x, X)$ . Selanjutnya,  $\omega$  interval tidak efisien terdiri dari semua titik tidak efisien; yaitu, interval tidak efisien  $D = \{x : x \text{ is inefficiency}\}$ .

**Definisi 3.** Kekuatan inefisiensi jalur ditentukan oleh luas integral antara fungsi kerapatan acuan dan fungsi kerapatan jalur pada interval inefisiensi, yaitu,  $\int_D (f_n(x, X) - f_{on}(x, X, \omega)) dx$ , jika kota  $x$  alokasinya  $\omega$  tidak efisien.

Xu dan Watada [14] membuktikan pada tahun 2008 bahwa jalur yang mendasari  $S_0$  dapat diidentifikasi dengan probabilitas satu, yaitu jalur yang mendasari  $S_0$  diidentifikasi oleh perbedaan antara jalur benchmark  $S_1$  dan jalur faktor  $S_2$  melalui probabilitas. Pilihan fungsi kernel  $K(\bullet)$  dan bandwidth  $h$  sangat penting untuk distribusi benchmark dan jalur populasi. Fungsi kernel dalam penelitian ini adalah fungsi kernel Gauss:  $K_h(u) = (2\pi)^{-1/2} \exp(-u^2/2)$ .

Karena  $h$  terkait dengan bobot yang sesuai dalam penelitian ini, metode pemilihan bandwidth konvensional yang tidak relevan dengan  $\bar{\omega}_j$  dan  $j$  tidak tepat. Penelitian ini mencoba untuk mendapatkan bandwidth melalui langkah-langkah berikut. Pilihan bandwidth  $h$  menentukan jumlah smoothing yang dibutuhkan untuk memperkirakan kepadatan kernel. Terinspirasi oleh penerapan Maria dan Roberto [9], kami mendefinisikan jumlah mode kepadatan tertimbang  $f_\omega(x)$  sebagai:

$$M(f_\omega) = \#\{y \in \mathfrak{R}_+ : f'_\omega(y) = 0 \text{ and } f''_\omega(y) < 0\}$$

Hipotesis nol  $H_0$ : kerapatan dasar  $f_\omega$  memiliki m mode ( $M(f_\omega) \leq m$ );

$H_1$ :  $f_\omega$  memiliki lebih dari m mode ( $M(f_\omega) > m$ )

untuk  $m = 1, \dots, M$ , di mana  $\hat{f}_{\omega h}$  adalah estimasi densitas kernel tertimbang dan  $h$  bandwidth keseluruhan. Tes multimodality bootstrap didasarkan pada gagasan pemulusan kritis dan bandwidth kritis.  $m$ -th Bandwidth kritis  $\hat{h}_{m,crit}$  didefinisikan oleh:

$$\hat{h}_{m,crit} = \inf\{h : M(\hat{f}_{\omega,h}) \leq m\}$$

Ketika  $h = \hat{h}_{m,crit}$ ,  $\hat{f}_{\omega,h}$  akan menampilkan  $m$  mode dengan bahan. Ketika  $h$  semakin berkurang, mode tambahan ( $m + 1$ ) - th akan muncul di tempat bahan. Dengan demikian, penelitian ini mencoba untuk memilih  $h$  melalui proses berikut:

Langkah 1. Terapkan metode Cross Validation ke model benchmark (1) pada aturan IMSE , lalu pilih pilot bandwidth awal  $h_1$  ;

Langkah 2. Untuk  $m = 1, \dots, M$  fungsi densitas tertimbang  $f_{\omega,h}(x)$  dapatkan masing-masing  $\hat{h}_{m,crit}$ .

Langkah 3. Uji bootstrap pada jumlah mode  $m$  , untuk  $m = 1, \dots, M$  .

(a) Seperti yang disarankan oleh Silverman [10], data bootstrap  $x^j$  dihasilkan oleh:

$$x_i^j = \bar{y}^j + (1 + \hat{h}_{m,crit}^2 / \hat{\sigma}^2)^{-1/2} (y_i^j - \bar{y}^j + \hat{h}_{m,crit} \epsilon) \quad (12)$$

di mana  $y_i^j$  diambil secara random (dengan penggantian) dari sampel asli,  $\bar{y}^j$  adalah meanya,  $\hat{\sigma}^2$  adalah variansnya, dan adalah variabel i.i.d N (0, 1) untuk  $j = 1, \dots, b$  ,  $i = 1, \dots, n$  ;

(b) Untuk  $j=1, \dots, b$ , terapkan metode kernel terbobot untuk mendapatkan estimasi bootstrap  $\hat{f}_{\omega,h_{m,crit},crit}^j$  berdasarkan bandwidth kritis  $\hat{h}_{m,crit}$  yang dihitung dari t data asli. Untuk setiap sampel bootstrap, hitung jumlah mode yang sesuai  $M(\hat{f}_{\omega,h_{m,crit}}^j)$  dan bandwidth kritis ke- $m$   $\hat{h}_{m,crit}^j$  .

(c) Hitung perkiraan tingkat signifikansi yang dicapai (ASL) atau nilai-p:

$$\widehat{ASL}_m = p_m = \frac{1}{b} \sum_{j=1}^b \# \{ M(\hat{f}_{h_{m,crit}}^j) > m \} \quad (13)$$

(d) Jangan menolak nol dari  $m$  mode dalam kerapatan dasar jika  $\widehat{ASL}_m$  atau  $p_m$  cukup besar.

Pengujian dilakukan dengan menghitung  $\widehat{ASL}_m$  secara simultan untuk semua  $m = 1, \dots, M$ , di mana  $M$  adalah bilangan yang telah ditentukan. Untuk kerapatan dasar  $f_\omega$ , kami memilih perkiraan  $m^*$  sebagai jumlah kritis mode jika  $\widehat{ASL}_m^*$  menunjukkan nilai terbesar di antara

semua  $\widehat{ASL}_m$  untuk  $m = 1, \dots, M$ . Dengan bandwidth  $h$  dan fungsi kernel  $K(\bullet)$ , diperoleh model benchmark  $f_h(x)$ , distribusi jalur populasi regional  $f_{\omega_1, h}(x)$ , dan jalur populasi perkotaan  $f_{\omega_2, h}(x)$  diperoleh.

$$f_{\omega_n}(x) = \sum_{j=1}^n \omega_j h^{-1} K\left(\frac{x - X_i}{h}\right) \quad (14)$$

di mana  $K(\bullet)$  adalah fungsi kernel, dan  $h$  adalah bandwidth,  $f_{\omega_1, h}(x)$  dan  $f_{\omega_2, h}(x)$  masing-masing adalah jalur faktor populasi regional dan jalur faktor populasi perkotaan dari tingkat urbanisasi  $\omega_{1j} = l_{1j} / \sum_{j=1}^n l_{1j}$ ,  $\omega_{2j} = l_{2j} / \sum_{j=1}^n l_{2j}$ ,  $l_{1j}$ ,  $l_{2j}$  adalah rasio populasi regional, total populasi perkotaan terhadap PDB untuk kota  $j$ , masing-masing.

### 16.3 IDENTIFIKASI AGLOMERASI POPULASI

#### Data

Sumber data untuk penelitian ini adalah Chinese City Statistical Yearbook di [www.bjinfobank.com](http://www.bjinfobank.com). Variabel yang termasuk dalam penelitian ini adalah: (1) jumlah penduduk akhir tahun di perkotaan, (2) penduduk non pertanian akhir tahun di perkotaan, (3) jumlah penduduk akhir tahun di seluruh kota, dan (4) populasi non-pertanian akhir tahun di seluruh kota, (5) PDRB di wilayah perkotaan dan (6) PDRB di seluruh kota setingkat prefektur tahun 2002, 2004, dan 2006. Kota setingkat prefektur dalam penelitian ini mengacu pada semua kota tingkat prefektur, kota di tingkat sub-provinsi, dan kotamadya yang dikelola langsung oleh pemerintah pusat di Tiongkok. Menurut klasifikasi di Cina, seluruh kota dari kota tingkat prefektur adalah wilayah administratif di bawah yurisdiksi kota, termasuk pedesaan atau banyak kabupaten dan kota tingkat kabupaten, dan mengacu pada wilayah regional dalam penelitian ini. Kabupaten kotamadya perkotaan mengacu pada kota perkotaan dan pinggirannya, yang diambil sebagai wilayah perkotaan dalam penelitian ini.

Dua definisi yang banyak digunakan untuk menggambarkan perkembangan tingkat urbanisasi: proporsi penduduk perkotaan dan proporsi penduduk non-pertanian. Definisi pertama biasanya digunakan untuk analisis tingkat perkembangan urbanisasi tunggal di Cina. Dalam studi ini, data populasi non-pertanian untuk kota tingkat prefektur, bukan data populasi perkotaan, tersedia. Selain itu, studi ini berupaya mendapatkan tingkat perkembangan urbanisasi secara keseluruhan dari tingkat perkembangan urbanisasi di hampir 300 kota tingkat prefektur, dengan fokus pada relativitas data daripada kemutlakan. Dalam hal ini, penelitian ini berbeda dengan indeks tunggal tingkat urbanisasi. Oleh karena itu, studi ini mengambil tingkat urbanisasi sebagai proporsi penduduk non-pertanian. Ini mewujudkan pergeseran surplus tenaga kerja pedesaan ke kota dan juga mengungkapkan kemampuan menerima tenaga kerja kota. Data statistik menunjukkan bahwa tingkat urbanisasi menurut definisi kedua pada tahun 2002, 2004, dan 2006 masing-masing adalah 27,89%, 30,81%, dan 36,26%, lebih rendah dari tingkat urbanisasi yang ditentukan oleh proporsi penduduk perkotaan [6].

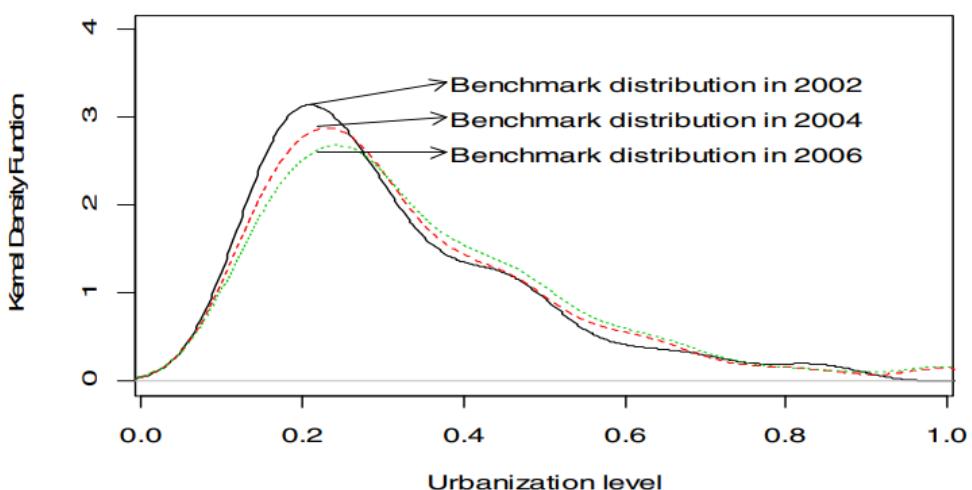
Alasan menggunakan perkembangan urbanisasi di kota-kota tingkat prefektur untuk mewakili tingkat urbanisasi adalah karena pertumbuhan China pada 1990-an ditopang terutama oleh kota-kota ini. Total PDB lebih dari 290 kota tingkat prefektur menyumbang lebih dari 50% PDB pada tahun 2000, dan tingkat pertumbuhan rata-ratanya sebagian besar lebih dari 12%. China mungkin gagal mengatasi deflasi pada 1990-an jika bukan karena pertumbuhan dua digit kota-kota setingkat prefektur. Penelitian saat ini bertujuan untuk mengidentifikasi aglomerasi penduduk yang ada dan efisiensinya dalam perencanaan kota dengan desain jalur konvergen di Cina. Hal ini dikejar dari dua perspektif berikut:

Studi ini berusaha untuk mengidentifikasi aglomerasi populasi dan efisiensinya dalam perencanaan kota di Cina dengan menggunakan desain jalur konvergen dari dua perspektif berikut:

- 1) Perspektif ukuran kota, yang memisahkan hampir 300 kota tingkat prefektur di Cina menjadi kota besar, menengah, dan kecil menurut skala populasi perkotaan, yang berbeda dari tingkat urbanisasi tunggal biasa;
- 2) Perspektif lokasi spasial, yang memisahkan wilayah kota menjadi wilayah perkotaan dan wilayah menurut skala wilayah kota.

### Model Tolok Ukur Tingkat Urbanisasi

Gambar 1 menunjukkan distribusi patokan tingkat urbanisasi di kota-kota tingkat prefektur pada tahun 2002, 2004, dan 2006 dan mencerminkan tingkat aglomerasi. Tabel 1 menampilkan informasi rinci mengenai distribusi di setiap tahun.  $f_h(x)_{max}$  adalah nilai maksimum fungsi  $f_h(x)$ ,  $S_1$ ,  $S_2$ , dan  $S_3$  adalah nilai integral dari setiap distribusi pada interval  $(0, 0.35]$ ,  $(0.35, 0.7]$  dan  $(0.7, 1]$  memuaskan  $S_1 = \int_0^{0.35} f(x)dx$ ,  $S_2 = \int_{0.35}^{0.7} f(x)dx$ ,  $S_3 = \int_{0.7}^1 f(x)dx$ . Interval  $(0, 0.35]$ ,  $(0.35, 0.7]$  dan  $(0.7, 1]$  menggambarkan tingkat urbanisasi rendah, sedang, dan tinggi. EX adalah nilai yang diharapkan dari keseluruhan tingkat perkembangan urbanisasi di Cina dengan setiap distribusi, memuaskan  $EX = \int_0^{\infty} xf_h(x)dx$  x urbanisasi rata-rata keseluruhan tingkat di setiap tahun. Baris terbawah pada Tabel 1 menyajikan rata-rata laju pertumbuhan masing-masing indeks selama 2002-2006 (jika negatif berarti menurun). Tingkat pertumbuhan rata-rata dari nilai yang diharapkan adalah 1,79%, diperoleh dengan menyelesaikan  $0,3145(1+x)^4 = 0,3376$ .



**Gambar 16.1** Distribusi tolok ukur urbanisasi di kota-kota tingkat prefektur pada tahun 2002, 2004 dan 2006

**Tabel 16.1** Informasi Distribusi Benchmark Tahun 2002, 2004 2006

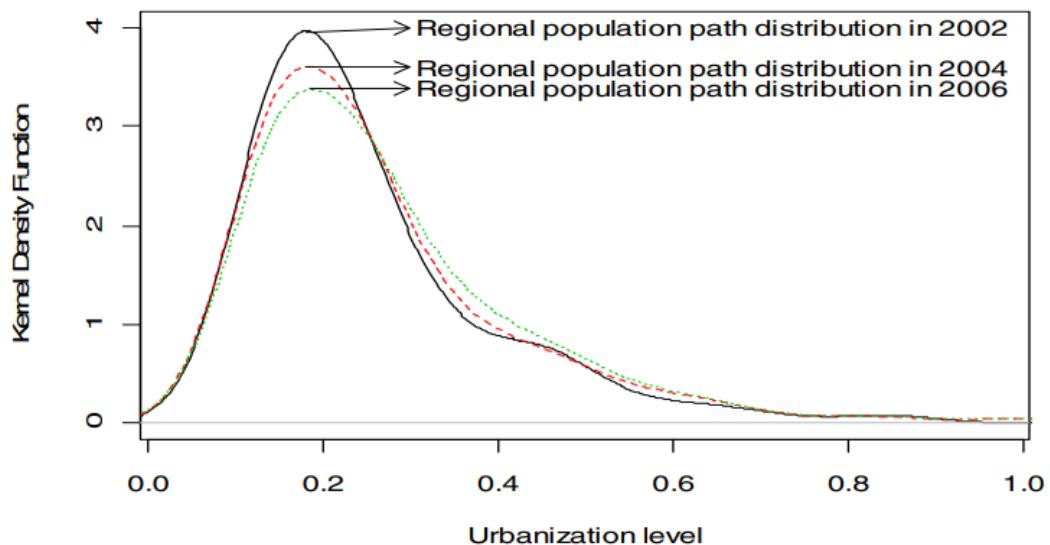
Tahun	$f_h(x)_{\max}$	$EX$	$S_1$	$S_2$	$S_3$
2002	3.15	0.315	0.665	0.292	0.0426
2004	2.88	0.325	0.629	0.319	0.0428
2006	2.68	0.338	0.595	0.346	0.0487
Tingkat Pertumbuhan	-3.88%	1.79%	-2.74%	4.30%	3.41%

Pertama, Tabel 1 dan Gambar 1 menggambarkan bahwa sebagian besar kota berada pada interval tingkat urbanisasi rendah (0, 0,35), karena tingkat urbanisasi rata-rata kurang dari 0,35 dan integral dari distribusi benchmark pada (0, 0,35) mengambil setidaknya 60% untuk semua tahun.

Kedua, tingkat urbanisasi tumbuh secara bertahap dari waktu ke waktu. Di satu sisi, tingkat pertumbuhan urbanisasi rata-rata selama 2002-2006 adalah 1,79% untuk kota-kota setingkat prefektur di Cina. Di sisi lain, area integral pada urbanisasi yang lebih tinggi meningkat secara bertahap; secara khusus, luas integral pada selang (0,7, 1) tumbuh sebesar 3,41% setiap tahun, sedangkan luas integral pada selang (0, 0,35) menurun secara bertahap dengan laju penurunan sebesar 2,74% setiap tahun. Demikian pula, titik tertinggi fungsi tergelincir setiap tahun pada tingkat tahunan 3,88%.

### Model Jalur Aglomerasi Populasi

Untuk mengidentifikasi mode aglomerasi populasi dari perspektif regional dan perkotaan, bagian berikut menyajikan jalur populasi regional dan distribusi jalur populasi perkotaan untuk dianalisis.



**Gambar 16.2** Distribusi jalur urbanisasi penduduk regional di kota-kota setingkat prefektur pada tahun 2002, 2004 dan 2006

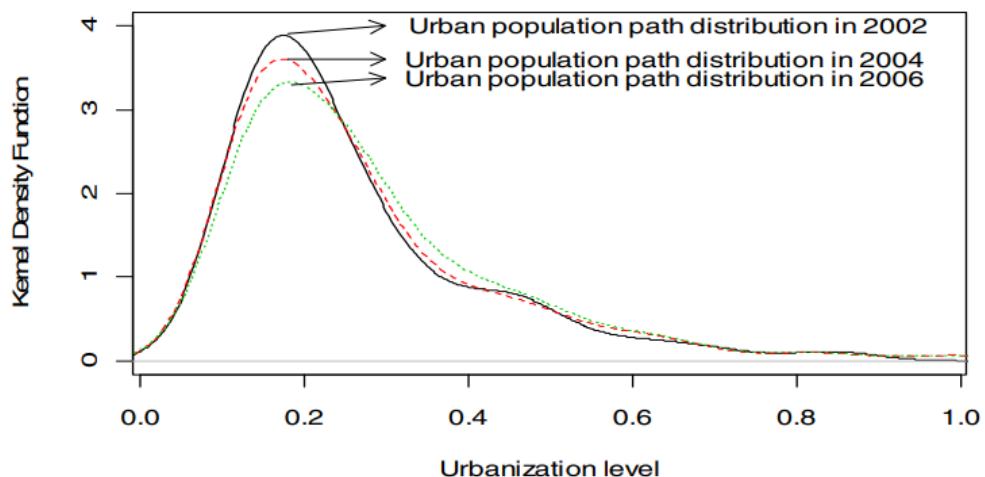
**Tabel 16.2** Distribusi jalur penduduk regional tahun 2002, 2004, 2006

Tahun	$f_h(x)_{\max}$	$EX$	$S_1$	$S_2$	$S_3$
2002	3.97	0.253	0.801	0.180	0.0164
2004	3.60	0.260	0.782	0.196	0.0178

2006	3.37	0.270	0.755	0.221	0.0192
Tingkat Pertumbuhan	-4.01%	1.66%	-1.48%	5.21%	4.02%

Gambar 2 dan Tabel 2 mencantumkan informasi tentang distribusi jalur populasi regional, yang mencerminkan mode aglomerasi populasi regional kota. Tingkat pertumbuhan rata-rata urbanisasi regional rata-rata adalah 1,66% selama 2002-2006. Mirip dengan kasus benchmark, area integral pada tingkat urbanisasi yang lebih tinggi meningkat secara bertahap. Secara khusus, luas integral pada selang (0,7, 1) tumbuh sebesar 4,02% setiap tahun, sedangkan luas integral pada selang (0, 0,35) menurun secara bertahap dengan laju 1,48% setiap tahun. Sekali lagi, nilai maksimum distribusi jalur populasi regional tergelincir setiap tahun pada tingkat tahunan 4,01%.

Gambar 3 dan Tabel 3 menggambarkan rincian distribusi jalur penduduk perkotaan, memberikan informasi rinci tentang mode aglomerasi penduduk perkotaan kota. Rata-rata tingkat pertumbuhan urbanisasi adalah 1,87% selama 2002-2006. Area integral pada urbanisasi yang lebih tinggi meningkat secara bertahap; secara khusus, luas integral pada selang (0,7, 1) tumbuh 2,74% setiap tahun, sedangkan luas integral pada selang (0, 0,35) berkurang secara bertahap dengan laju 1,33% setiap tahun. Sekali lagi, nilai maksimum distribusi jalur populasi perkotaan menurun pada tingkat tahunan 3,84%.



**Gambar 16.3** Distribusi jalur urbanisasi penduduk perkotaan di kota-kota setingkat prefektur pada tahun 2002, 2004 dan 2006

**Tabel 16.3** Distribusi jalur penduduk perkotaan tahun 2002, 2004, 2006

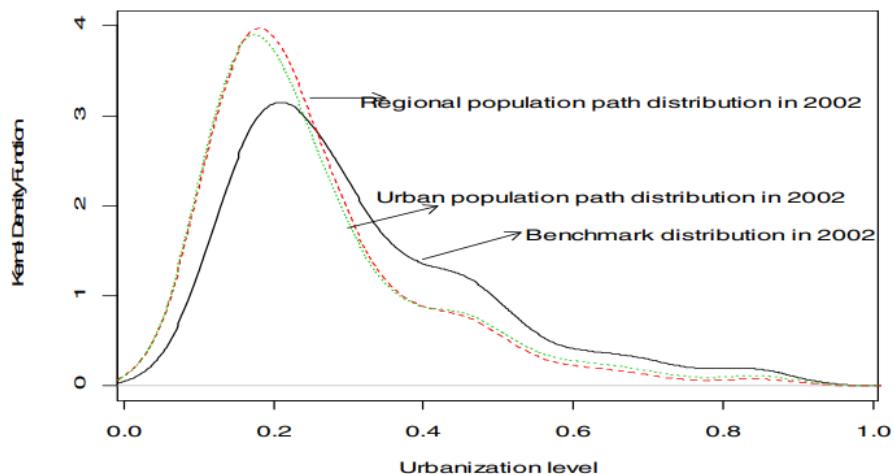
Tahun	$f_h(x)_{\max}$	$EX_2$	$S_1$	$S_2$	$S_3$
2002	3.89	0.260	0.783	0.192	0.0236
2004	3.61	0.265	0.769	0.200	0.0252
2006	3.33	0.276	0.742	0.226	0.0263
Tingkat Pertumbuhan	-3.84%	1.52%	-1.33%	4.16%	2.74%

Singkatnya, dua kesimpulan disajikan mengenai mode aglomerasi populasi dari perspektif regional dan perkotaan.

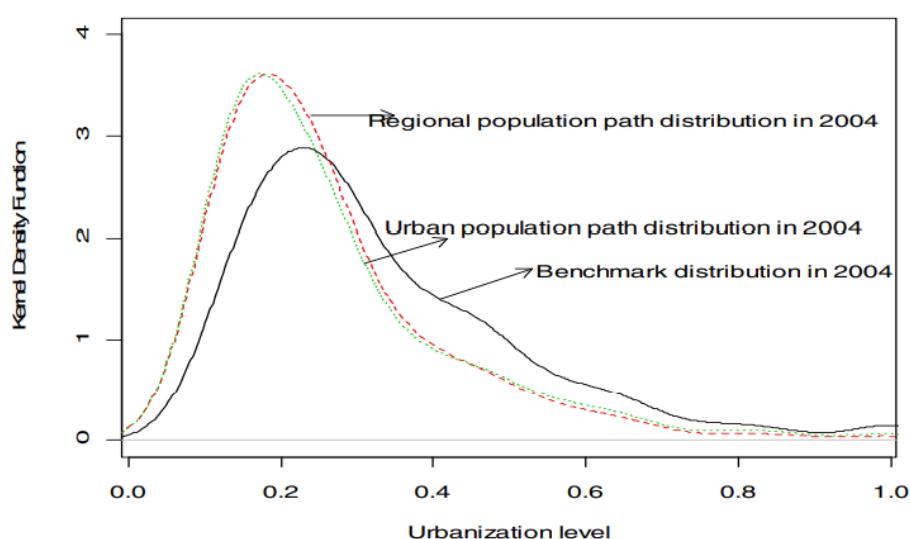
- 1) Pertama, penduduk regional dan perkotaan menggumpal ke kota-kota dengan urbanisasi lebih rendah dari 0,35 karena integral dari jalur populasi regional dan distribusi jalur populasi perkotaan pada  $(0, 0,35)$  mengambil setidaknya 75% untuk semua tahun, yang menyajikan ineffisiensi dari aglomerasi penduduk.
- 2) Kedua, aglomerasi populasi regional dan perkotaan menyusut secara bertahap dari waktu ke waktu karena area integral di  $(0, 0,35)$  menyaksikan tren penurunan untuk kedua distribusi jalur.

### Aglomerasi Penduduk ke Kiri

Bagian ini bertujuan untuk memperjelas apakah penduduk terutama berkumpul ke wilayah atau ke wilayah perkotaan melalui jalur tingkat urbanisasi.

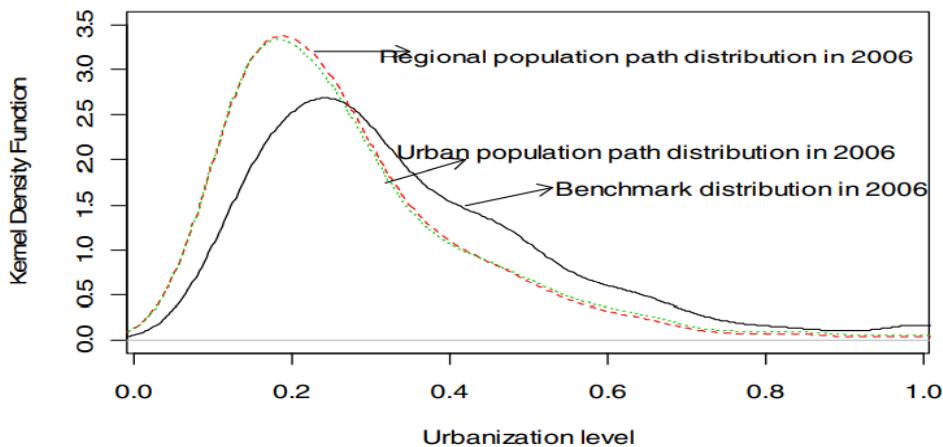


**Gambar 16.4** Perbandingan tahun 2002



**Gambar 16.5** Perbandingan Tahun 2004

Gambar 4 sampai 6 menggambarkan perbandingan distribusi antara benchmark, jalur populasi regional dan distribusi jalur populasi perkotaan pada tahun 2002, 2004 dan 2006. Tabel 4 mencantumkan tingkat urbanisasi rata-rata dari tiga distribusi pada tahun 2002, 2004 dan 2006.



**Gambar 16.6** Perbandingan tahun 2006

**Tabel 16.4** Rata-rata tingkat urbanisasi sebaran benchmark, jumlah penduduk wilayah dan jalur penduduk perkotaan tahun 2002, 2004 dan 2006

Tahun	$EX$	$EX_1$	$EX - EX_1$	$EX_2$	$EX_2 - EX$
2002	0.315	0.253	-0.0617	0.260	-0.0546
2004	0.325	0.260	-0.0650	0.265	-0.0601
2006	0.338	0.270	-0.0676	0.276	-0.0614
Rata-rata	0.326	0.261	-0.0648	0.267	-0.0587

di mana  $EX$ ,  $EX_1$  dan  $EX_2$  masing-masing menunjukkan nilai yang diharapkan dari benchmark, jalur populasi regional, dan distribusi jalur populasi perkotaan.

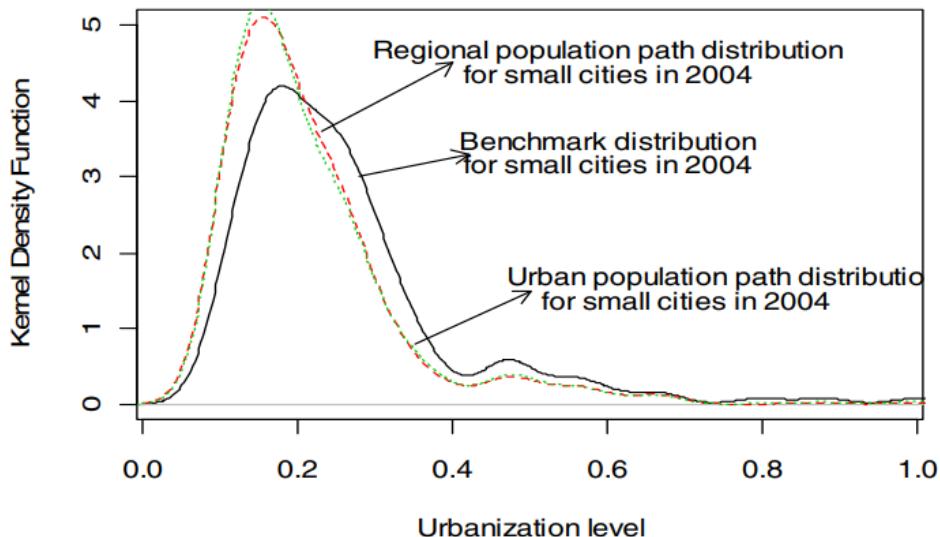
Pada Tabel 4,  $EX$ ,  $EX_1$  dan  $EX_2$  masing-masing mewakili nilai yang diharapkan dari benchmark, jalur populasi regional, dan distribusi jalur populasi perkotaan. Angka-angka tersebut menunjukkan tren yang sama: baik distribusi jalur populasi regional maupun perkotaan bergeser ke kiri berdasarkan distribusi tolok ukur yang sesuai, yang mengisyaratkan inefisiensi aglomerasi populasi. Distribusi jalur penduduk regional mengalami pergeseran yang lebih kuat dibandingkan dengan distribusi jalur penduduk perkotaan. Hal ini menyiratkan bahwa distribusi jalur penduduk baik regional maupun perkotaan mengurangi tingkat urbanisasi secara keseluruhan, yang juga diamati dari gambar pada Tabel 4.

Nilai ekspektasi dari distribusi benchmark adalah yang tertinggi, dan nilai ekspektasi dari distribusi jalur populasi regional adalah yang terendah. Jalur populasi regional dan jalur populasi perkotaan mengurangi nilai benchmark yang diharapkan sebesar 6,96% dan 6,27%, yang masing-masing diperoleh  $EX_1 - EX$  dan  $EX_2 - EX$ . Hasil ini menyiratkan bahwa populasi berkumpul ke daerah dengan tingkat urbanisasi lebih rendah dari tingkat urbanisasi regional dan perkotaan rata-rata. Namun demikian, kekuatan penurunan sebaran jalur penduduk di wilayah tersebut sedikit lebih kuat dibandingkan dengan kekuatan penurunan sebaran jalur penduduk perkotaan.

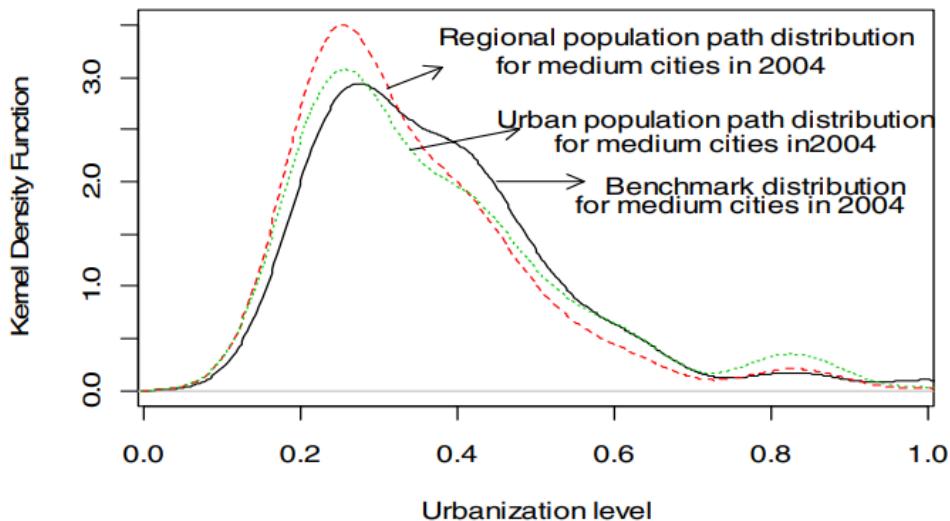
#### Inefisiensi Aglomerasi Penduduk: Ukuran Kota

Studi menunjukkan di bagian sebelumnya bahwa populasi terutama berkumpul di kota-kota dengan tingkat urbanisasi yang lebih rendah dari perspektif regional dan perkotaan.

Untuk memperjelas ada tidaknya inefisiensi aglomerasi penduduk di kota-kota kecil, menengah, dan besar, penelitian dilanjutkan dengan mengeksplorasi aglomerasi dari perspektif ukuran kota.

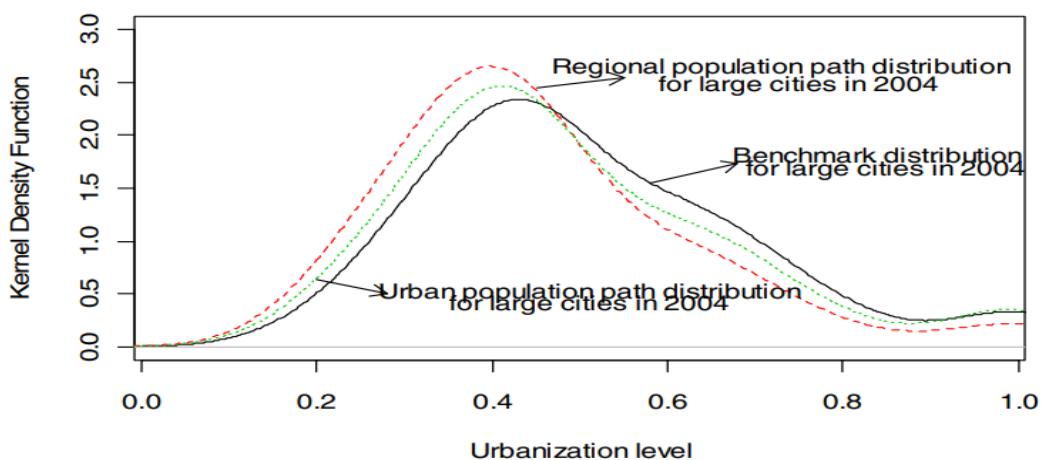


**Gambar 16.7** Distribusi kota-kota kecil pada tahun 2004

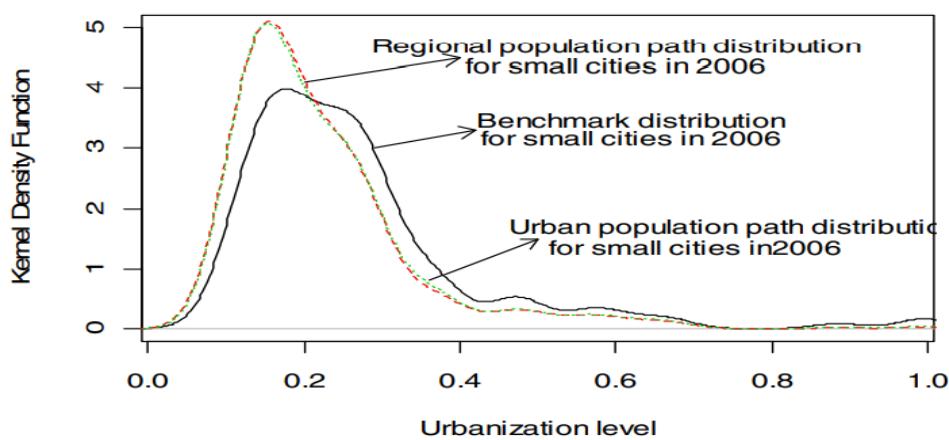


**Gambar 16.8** Distribusi kota menengah tahun 2004

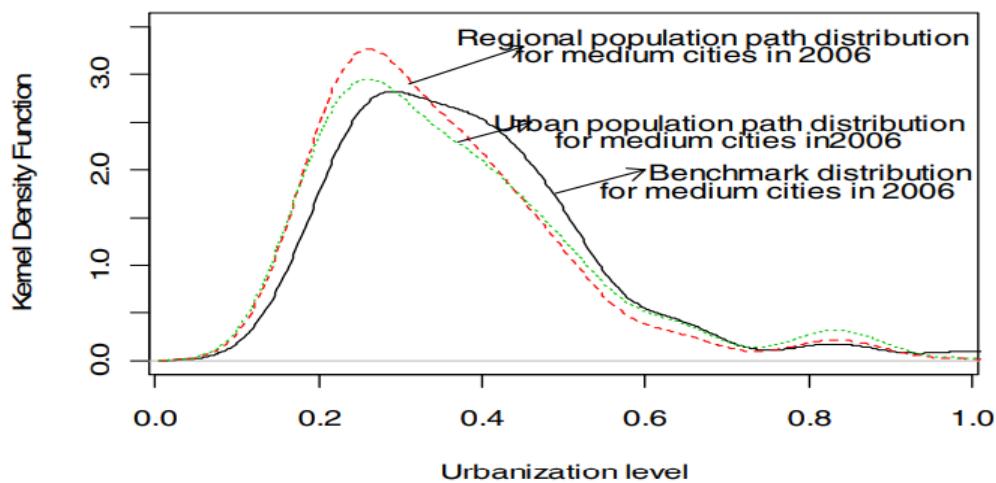
Pada bagian ini, penelitian memisahkan semua kota setingkat prefektur menjadi tiga kelompok: kota kecil (total penduduk perkotaan kurang dari 0,5 juta), kota sedang (total populasi perkotaan berkisar antara 0,5 hingga 1 juta), dan kota besar (total populasi perkotaan mereka). lebih besar dari 1 juta). Penelitian ini memberikan benchmark, jalur populasi regional dan distribusi jalur populasi perkotaan untuk kota kecil, kota menengah dan kota besar masing-masing pada tahun 2000, 2002 dan 2004 untuk mengidentifikasi ciri aglomerasi penduduk. Gambar 7 sampai 12 menyajikan tiga distribusi untuk tiga kelompok kota pada tahun 2004 dan 2006, dan Tabel 5 mencantumkan nilai harapan yang sesuai.



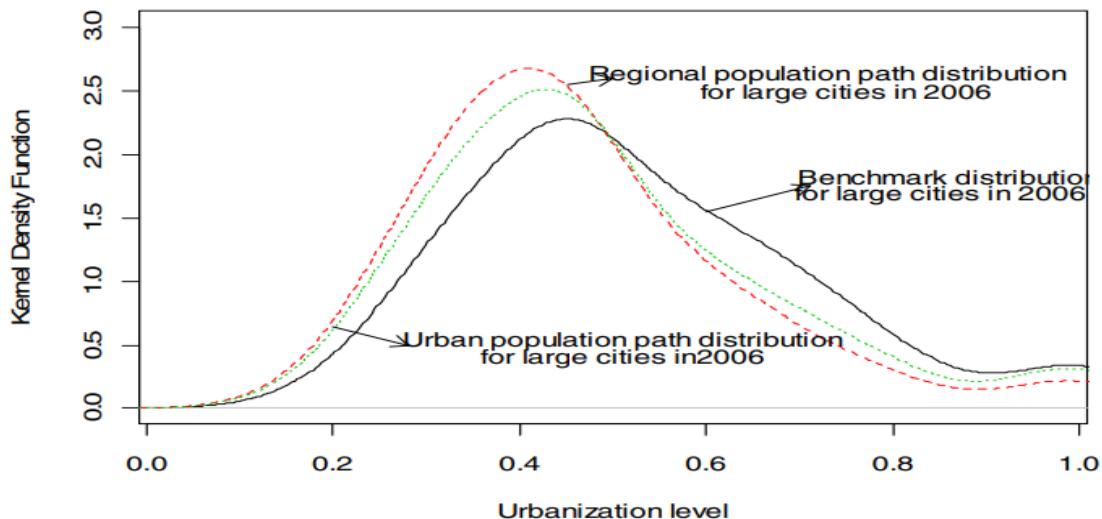
**Gambar 16.9** Distribusi kota-kota besar pada tahun 2004



**Gambar 16.10** Distribusi kota-kota kecil pada tahun 2006



**Gambar 16.11** Distribusi kota menengah tahun 2006



**Gambar 16.12** Distribusi kota-kota besar pada tahun 2006

**Tabel 16.5** Rata-rata tingkat urbanisasi dari benchmark, populasi regional dan distribusi jalur populasi perkotaan untuk kota-kota kecil

Tahun	EX	EX 1	EX 2
2004	0.255	0.215	0.216
2006	0.260	0.219	0.222

**Tingkat urbanisasi rata-rata untuk kota sedang**

Tahun	EX	EX 1	EX 2
2004	0.369	0.342	0.368
2006	0.376	0.348	0.3642

**Tingkat urbanisasi rata-rata untuk kota-kota besar**

Tahun	EX	EX 1	EX 2
2004	0.483	0.439	0.463
2006	0.499	0.447	0.464

di mana EX , EX<sub>1</sub> dan EX<sub>2</sub> menunjukkan nilai yang diharapkan dari benchmark, jalur populasi regional, dan distribusi jalur populasi perkotaan, masing-masing.

Dibandingkan dengan benchmark, distribusi jalur populasi regional dan perkotaan di setiap kelompok kota di semua tahun bergeser ke kiri, yang konsisten dengan kecenderungan semua kota setingkat prefektur. Distribusi jalur penduduk regional dan distribusi jalur penduduk perkotaan cenderung sama untuk kota-kota kecil pada tahun 2004 dan 2006. Namun, sebaran jalur penduduk perkotaan cenderung bergeser ke kanan dibandingkan dengan distribusi jalur penduduk regional untuk kota-kota sedang dan besar pada kedua tahun tersebut.

Inefisiensi aglomerasi penduduk teridentifikasi di kota-kota besar, menengah dan kecil karena semua penduduk berkumpul di kota-kota yang tingkat urbanisasinya lebih rendah dari tingkat rata-rata baik dari perspektif regional maupun perkotaan. Lebih khusus lagi, penduduk

daerah terutama berkumpul di kota-kota yang tingkat urbanisasinya lebih rendah dari 0,2143 untuk kota-kota kecil, lebih rendah dari 0,3341 untuk kota-kota sedang dan lebih rendah dari 0,4919 untuk kota-kota besar pada tahun 2006. Aglomerasi penduduk perkotaan mirip dengan aglomerasi penduduk regional pada tahun 2006. kota-kota kecil dan besar, sedangkan penduduk perkotaan terutama berkumpul di kota-kota yang tingkat urbanisasinya lebih rendah dari 0,2935 untuk kota-kota sedang.

Dengan tujuan untuk mendorong urbanisasi, migrasi penduduk dari kota dengan tingkat urbanisasi rendah ke kota dengan tingkat urbanisasi tinggi diharapkan dapat dilaksanakan berdasarkan mode aglomerasi populasi yang teridentifikasi.

#### 16.4 PENGAMBILAN KEPUTUSAN TENTANG STRATEGI MIGRASI OPTIMAL

Identifikasi menunjukkan bahwa aglomerasi penduduk yang ada tidak efisien. Pengambilan keputusan adalah untuk mendorong migrasi penduduk dari kota-kota dengan tingkat urbanisasi rendah ke kota-kota dengan tingkat urbanisasi tinggi untuk menghilangkan inefisiensi. Optimasi teoritis  $p_j$  populasi migrasi untuk kota  $j$  memenuhi persamaan sebagai berikut:

$$f_{\omega}(x_j) - f_n(x_j) = 0 \quad (4.1)$$

Dimana

$$f_n(x) = \frac{1}{n} \sum_{i=1}^n h^{-1} K\left(\frac{x - X_i}{h}\right),$$

Dan

$$f_{\omega}(x) = \sum_{j=1}^n \omega_j h^{-1} K\left(\frac{x - X_j}{h}\right).$$

Namun, sulit untuk mendapatkan solusi unik dari persamaan (4.1). Untungnya, itu diwakili oleh

$$\int_0^1 (f_{\omega}(x) - f_n(x)) dx = 0 \quad (4.2)$$

karena integral dari kerapatan peluang

$$\int_0^1 f_{\omega}(x) dx = 1 \text{ and } \int_0^1 f_n(x) dx = 1$$

Selanjutnya, penduduk bermigrasi dari kota-kota di tingkat urbanisasi yang lebih rendah ke kota-kota di tingkat yang lebih tinggi. Jadi, ada beberapa nilai  $I$ , sehingga

$$\int_0^l (f_\omega(x) - f_n(x))dx = \int_l^1 (f_n(x) - f_\omega(x))dx \quad (4.3)$$

It dapat ditemukan dengan persamaan(4.3) .

Dengan demikian, strategi migrasi penduduk yang optimal diberikan dalam persamaan (4.2) untuk kota-kota kecil, menengah dan besar pada tahun 2006.

### Keputusan 1: Kota Kecil

I adalah 0,214 dalam pengambilan keputusan migrasi penduduk regional untuk kota-kota kecil. Lebih khusus lagi, pengambilan keputusan migrasi penduduk untuk kota-kota kecil dilaksanakan dengan empat langkah.

1. Kekuatan populasi migrasi adalah 14,64 persen.

$$\int_0^{0.214} (f_{\omega_i}(x) - f_n(x))dx = 0.1464$$

2. Jumlah penduduk migrasi adalah

$$0.1464 \sum_{k=1}^n p_k I(u_k < 0.214)$$

Dimana  $p_k$  adalah populasi regional kota kecil  $k$ , dan  $\sum_{k=1}^n p_k I(u_k < 0.214)$  adalah jumlah penduduk regional kota-kota yang tingkat urbanisasinya lebih rendah dari 0.214.  $I(u_k < 0.214) = 1$ , if  $u_k < 0.214$ , jika tidak,  $I(u_k < 0.214) = 0$ , if  $u_k \geq 0.214$ .

3. Penduduk emigrasi untuk beberapa kota kecil i diberikan oleh

$$p_{iE} = \frac{\left[ f_{\omega_i}(x_i) - f_n(x_i) \right] I(u_i < 0.214)}{\sum_{j=1}^n \left[ f_{\omega_i}(x_j) - f_n(x_j) \right] I(u_j < 0.214)} \times 0.1464 \sum_{k=1}^n p_k I(u_k < 0.214)$$

Populasi imigrasi untuk beberapa kota kecil i diberikan oleh

$$p_{ii} = \frac{\left[ f_n(x_i) - f_{\omega_i}(x_i) \right] I(u_i \geq 0.214)}{\sum_{j=1}^n \left[ f_n(x_j) - f_{\omega_i}(x_j) \right] I(u_j \geq 0.214)} \times 0.1464 \sum_{k=1}^n p_k I(u_k < 0.214)$$

Hal ini menggambarkan bahwa migrasi penduduk untuk setiap kota kecil dilaksanakan sesuai dengan perbedaan benchmark dan distribusi jalur penduduk asli daerah. Semakin besar perbedaannya, semakin besar migrasi penduduk.

4. Jumlah penduduk daerah baru untuk beberapa kota kecil i diperoleh sebagai

$$p_{li} = p_i - p_{iE} + p_{ii}$$

5. Bobot jalur populasi regional baru dihitung ulang dengan jalur baru

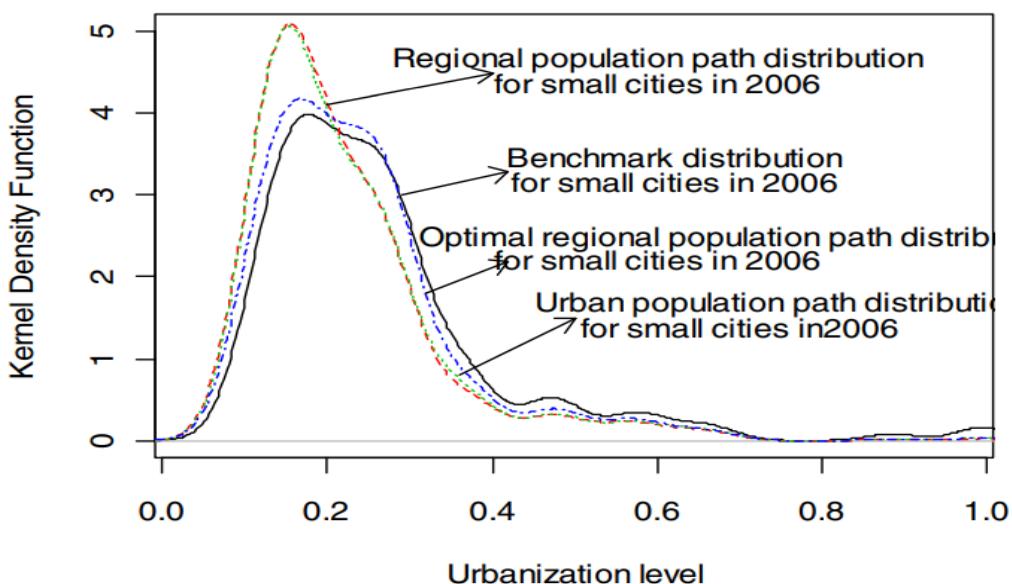
$$\omega_i = l_i / \sum_{j=1}^n l_j,$$

Dimana

$$l_i = p_{li}/GDP_i .$$

Lima langkah menyajikan desain jalur-konvergensi dari jalur populasi regional baru setelah migrasi untuk kota-kota kecil. Migrasi di sini hanya menyangkut migrasi pedalaman di antara kota-kota kecil. Langkah 4 perlu diperbarui untuk simulasi jika migrasi dilaksanakan di antara kota-kota kecil dan besar (menengah).

Dengan implementasi keputusan 1 untuk kota-kota kecil, Gambar 13 dan Tabel 6 menggambarkan keputusan untuk mempromosikan urbanisasi untuk kota-kota kecil pada tahun 2006. Gambar 13 menggambarkan pergeseran ke kanan dari distribusi jalur populasi regional dengan keputusan untuk bermigrasi. Tabel 6 menunjukkan bahwa kekuatan inefisiensi antara benchmark dan distribusi penduduk regional menyusut menjadi 0,0855 dari 0,146 dan tingkat urbanisasi rata-rata mengalami pertumbuhan sebesar 1,84 persen (0,237-0,2186). Kedua temuan menunjukkan fakta bahwa keputusan untuk bermigrasi dari kota-kota kecil efektif.



**Gambar 16.13** Distribusi jalur penduduk regional baru untuk kota-kota kecil pada tahun 2006

**Tabel 16.6** Informasi mengenai keputusan 1

Tahun	EX <sub>1</sub>	Optimal EX <sub>1</sub>	Kekuatan inefisiensi	Kekuatan Inefisiensi Optimal
2006	0.219	0.237	0.146 (0.214)	0.0585 (0.278)

### Keputusan 2: Migrasi Regional untuk Kota Menengah

/ adalah 0,334 dalam keputusan migrasi penduduk regional untuk kota sedang.

1. Kekuatan populasi migrasi adalah 9,85 persen.

$$0.0985 = \int_{0.334}^1 (f_n(x) - f_{\omega_1}(x)) dx$$

2. Jumlah penduduk migrasi adalah

$$0.0985 \sum_{k=1}^n p_k I(u_k < 0.334)$$

di mana  $p_k$  adalah populasi regional kota sedang  $k$ , dan  $\sum_{k=1}^n p_k I(u_k < 0.334)$  adalah jumlah penduduk wilayah kota sedang yang tingkat urbanisasinya lebih rendah dari 0,334.

3. Penduduk emigrasi untuk beberapa kota sedang  $i$  diberikan oleh

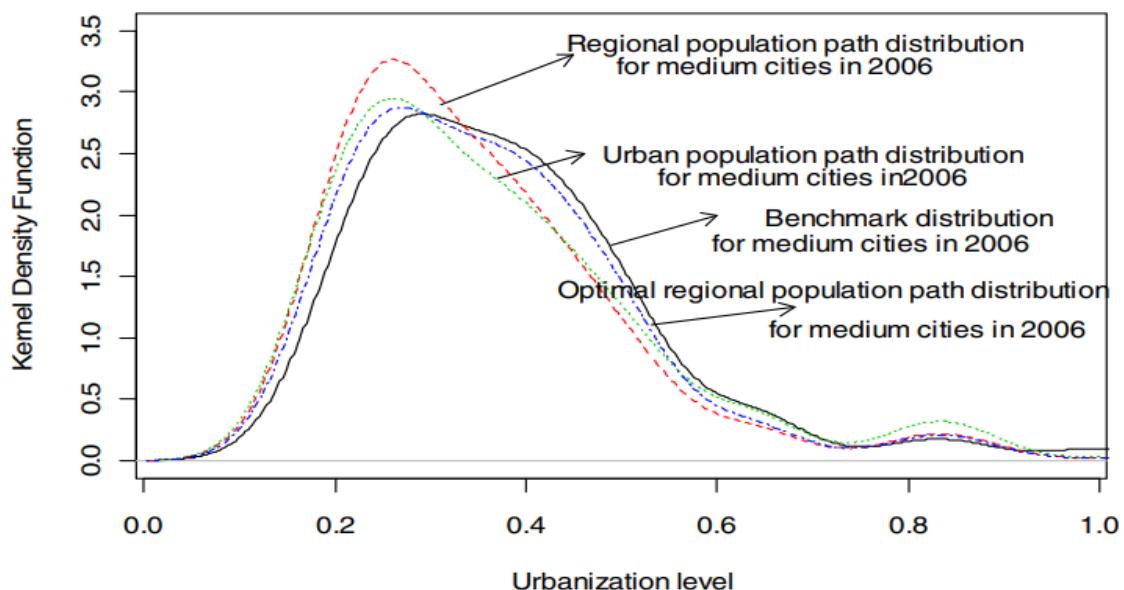
$$p_{iE} = \frac{\left[ f_{\omega_i}(x_i) - f_n(x_i) \right] I(u_i < 0.334)}{\sum_{j=1}^n \left[ f_{\omega_i}(x_j) - f_n(x_j) \right] I(u_j < 0.334)} \times 0.0985 \sum_{k=1}^n p_k I(u_k < 0.334)$$

Populasi imigrasi untuk beberapa kota sedang  $i$  diberikan oleh

$$p_{il} = \frac{\left[ f_n(x_i) - f_{\omega_i}(x_i) \right] I(u_i \geq 0.334)}{\sum_{j=1}^n \left[ f_n(x_j) - f_{\omega_i}(x_j) \right] I(u_j \geq 0.334)} \times 0.0985 \sum_{k=1}^n p_k I(u_k < 0.334)$$

4. Penduduk daerah baru untuk beberapa kota sedang  $i$

$$p_{1i} = p_i - p_{iE} + p_{il}$$



**Gambar 16.14** Distribusi jalur populasi regional baru untuk kota sedang pada tahun 2006

**Tabel 16.7** Informasi Keputusan No.2

Tahun	EX <sub>1</sub>	Optimal EX <sub>1</sub>	Kekuatan inefisiensi	Kekuatan Inefisiensi Optimal
2006	0.348	0.362	0.0985 (0.334)	0.0412 (0.295)

Dengan mengacu pada desain path-converged, implementasi keputusan 2 untuk kota menengah menyertai informasi pada Gambar 14 dan Tabel 7. Gambar 14 menggambarkan pergeseran ke kanan dari distribusi jalur populasi regional dengan keputusan untuk bermigrasi. Tabel 7 menggambarkan kekuatan inefisiensi antara benchmark dan distribusi penduduk regional menyusut menjadi 0,0412 dari 0,0985 dan rata-rata tingkat urbanisasi mengalami pertumbuhan sebesar 1,41 persen.

### **Keputusan 3: Migrasi Perkotaan untuk Kota Menengah**

/ adalah 0,294 dalam pengambilan keputusan migrasi penduduk perkotaan untuk kota sedang.

1. Kekuatan populasi migrasi adalah 7,10 persen.

$$0.071 = \int_{0.294}^1 (f_n(x) - f_{\omega_2}(x)) dx$$

2. Jumlah penduduk migrasi adalah:

$$0.071 \sum_{k=1}^n p_k I(u_k < 0.294)$$

di mana  $p_k$  adalah populasi perkotaan dari kota sedang  $k$ ,  $0.071 = \int_{0.294}^1 (f_n(x) - f_{\omega_2}(x)) dx$ , dan  $\sum_{k=1}^n p_k I(u_k < 0.294)$  adalah jumlah penduduk perkotaan kota sedang yang tingkat urbanisasinya lebih rendah dari 0,294.

3. Penduduk emigrasi perkotaan untuk beberapa kota sedang  $i$  diberikan oleh:

$$p_{iE} = \frac{\left[ f_{\omega_2}(x_i) - f_n(x_i) \right] I(u_i < 0.294)}{\sum_{j=1}^n \left[ f_{\omega_2}(x_j) - f_n(x_j) \right] I(u_j < 0.294)} \times 0.071 \sum_{k=1}^n p_k I(u_k < 0.294)$$

Populasi imigrasi untuk beberapa kota sedang  $i$  diberikan oleh:

$$p_{ii} = \frac{\left[ f_n(x_i) - f_{\omega_2}(x_i) \right] I(u_i \geq 0.294)}{\sum_{j=1}^n \left[ f_n(x_j) - f_{\omega_2}(x_j) \right] I(u_j \geq 0.294)} \times 0.071 \sum_{k=1}^n p_k I(u_k < 0.294)$$

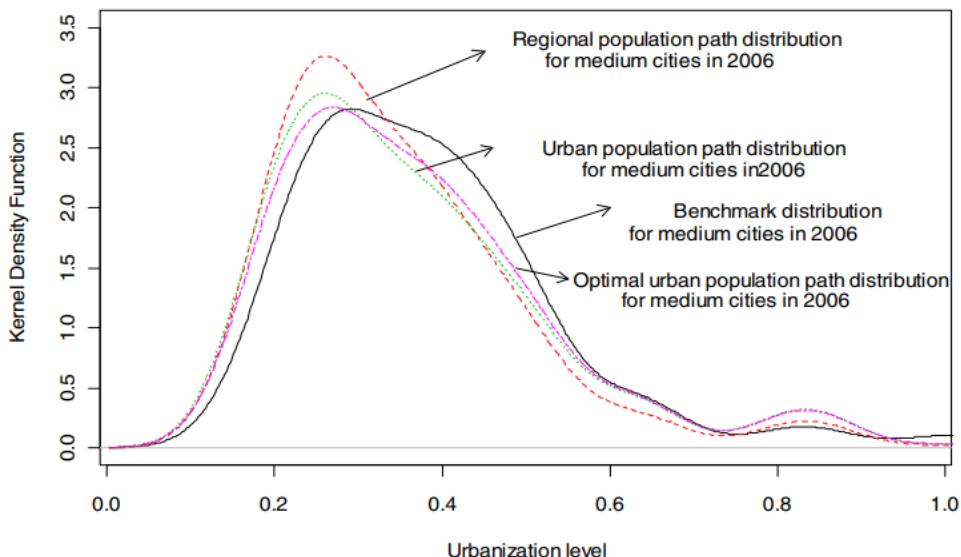
4. Penduduk perkotaan baru untuk beberapa kota sedang  $i$

$$P_{ii} = P_i - P_{iE} + P_{il}$$

Implementasi keputusan 3 untuk kota sedang disajikan pada Gambar 15 dan Tabel 8. Gambar 15 menggambarkan pergeseran ke kanan dari distribusi jalur penduduk perkotaan dengan pengambilan keputusan migrasi penduduk. Tabel 8 menyajikan kekuatan inefisiensi antara benchmark dan distribusi penduduk perkotaan menyusut menjadi 0,0473 dari 0,071 dan tingkat urbanisasi rata-rata tidak mengalami pertumbuhan yang jelas.

**Tabel 16.8** Informasi Keputusan No.3

Tahun	$EX_2$	Optimal $EX_2$	Kekuatan inefisiensi	Kekuatan Inefisiensi Optimal
2006	0.364	0.363	0.0710(0.294)	0.0473(0.284)

**Gambar 16.15** Distribusi jalur penduduk perkotaan baru untuk kota sedang pada tahun 2006**Keputusan 4: Migrasi Penduduk Daerah untuk Kota Besar**

$I$  adalah 0,492 dalam keputusan migrasi penduduk regional untuk kota-kota besar.

1. Kekuatan populasi migrasi adalah 14,0 persen.

$$0.140 = \int_{0.492}^1 (f_n(x) - f_{\omega_i}(x)) dx$$

2. Jumlah penduduk migrasi adalah

$$0.140 \sum_{k=1}^n p_k I(u_k < 0.492)$$

di mana  $p_k$  adalah populasi regional kota besar  $k$ ,  $\sum_{k=1}^n p_k I(u_k < 0.492)$  adalah jumlah penduduk wilayah kota besar yang tingkat urbanisasinya lebih rendah dari 0,492.  $0.140 = \int_{0.492}^1 (f_n(x) - f_{\omega_i}(x)) dx$  dan

3. Penduduk emigrasi untuk beberapa kota besar  $i$  diberikan oleh

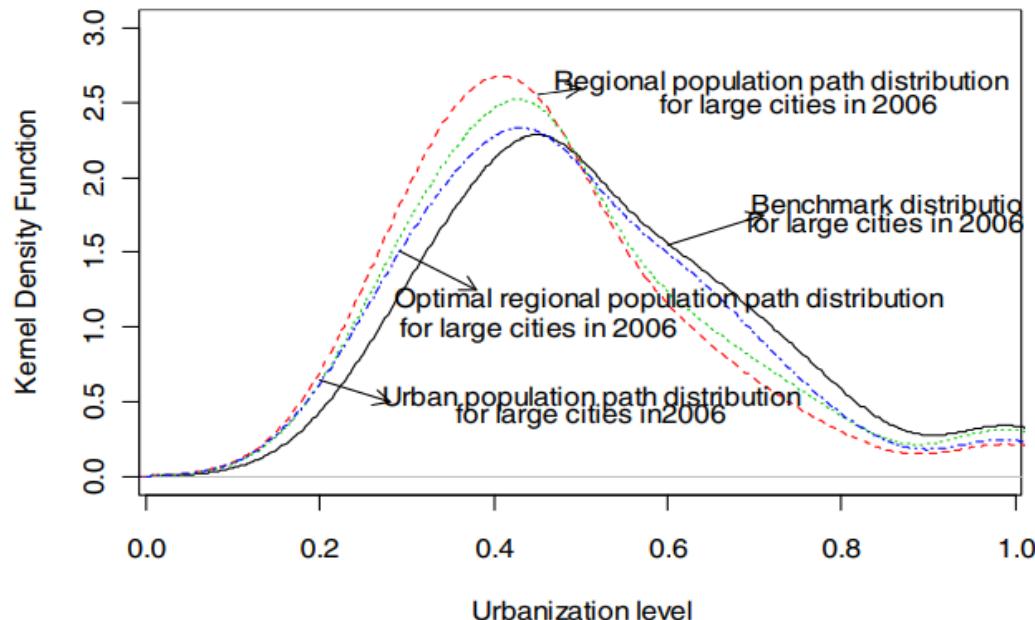
$$p_{iE} = \frac{[f_{\omega_i}(x_i) - f_n(x_i)] I(u_i < 0.492)}{\sum_{j=1}^n [f_{\omega_j}(x_j) - f_n(x_j)] I(u_j < 0.492)} \times 0.140 \sum_{k=1}^n p_k I(u_k < 0.492)$$

Populasi imigrasi untuk beberapa kota besar  $i$  diberikan oleh

$$p_{il} = \frac{[f_n(x_i) - f_{\omega_l}(x_i)] I(u_i \geq 0.492)}{\sum_{j=1}^n [f_n(x_j) - f_{\omega_l}(x_j)] I(u_j \geq 0.492)} \times 0.140 \sum_{k=1}^n p_k I(u_k < 0.492)$$

4. Populasi regional baru untuk beberapa kota besar i

$$p_{il} = \frac{\left[ f_n(x_i) - f_{\omega_l}(x_i) \right] I(u_i \geq 0.492)}{\sum_{j=1}^n \left[ f_n(x_j) - f_{\omega_l}(x_j) \right] I(u_j \geq 0.492)} \times 0.140 \sum_{k=1}^n p_k I(u_k < 0.492)$$



**Gambar 16.16** Distribusi jalur populasi regional baru untuk kota-kota besar pada tahun 2006

**Tabel 16.9** Informasi Keputusan No.4

Tahun	EX <sub>1</sub>	Optimal EX <sub>1</sub>	Kekuatan inefisiensi	Kekuatan Inefisiensi Optimal
2006	0.447	0.474	0.140(0.492)	0.0562(0.462)

Implementasi keputusan 4 untuk kota besar disajikan pada Gambar 16 dan Tabel 9. Gambar 16 mengalami pergeseran ke kanan dari distribusi jalur penduduk regional dengan keputusan migrasi penduduk. Tabel 9 menunjukkan bahwa rata-rata tingkat urbanisasi mengalami pertumbuhan sebesar 2,73% dan bahwa kekuatan inefisiensi antara benchmark dan distribusi penduduk regional menyusut menjadi 0,0562 dari 0,140.

## 16.5 KESIMPULAN

Studi ini mengembangkan identifikasi desain jalur-konvergensi berdasarkan estimasi kepadatan kernel nonparametrik untuk mengidentifikasi aglomerasi populasi dan efisiensinya dari perspektif regional dan perkotaan. Ini juga mengusulkan keputusan migrasi penduduk yang optimal untuk perencanaan kota untuk menghilangkan inefisiensi urbanisasi di Cina.

### Identifikasi Aglomerasi Penduduk

Pertama, identifikasi tingkat urbanisasi dengan model benchmark menggambarkan sebagian besar kota berada pada tingkat urbanisasi lebih rendah dari 0,35. Tingkat urbanisasi tumbuh secara bertahap seiring dengan waktu karena tingkat pertumbuhan rata-rata tingkat urbanisasi selama 2002-2006 adalah 1,79 persen dan wilayah integral pada tingkat urbanisasi

yang lebih tinggi meningkat secara bertahap. Secara khusus, luas integral pada interval (0,7, 1) tumbuh sebesar 3,41 persen setiap tahun.

Kedua, inefisiensi aglomerasi penduduk diidentifikasi untuk semua kota di Cina. Identifikasi aglomerasi penduduk menunjukkan bahwa populasi berkumpul secara asimetris di sekitar tingkat perkembangan urbanisasi rata-rata. Penduduk regional dan perkotaan diaglomerasi ke kota-kota dengan tingkat urbanisasi lebih rendah dari 0,35 selama 2002-2006 karena integral dari jalur populasi regional dan distribusi jalur populasi perkotaan pada (0, 0,35) terdiri dari setidaknya 75 persen untuk semua tahun. Selain itu, aglomerasi penduduk baik wilayah maupun perkotaan menyusut secara bertahap dari waktu ke waktu karena wilayah integral pada (0, 0,35) mengalami tren penurunan untuk kedua distribusi jalur.

Ketiga, inefisiensi aglomerasi penduduk juga teridentifikasi di kota-kota besar, sedang dan kecil. Lebih khusus lagi, penduduk regional berkumpul di kota-kota dengan tingkat urbanisasi lebih rendah dari 0,214 untuk kota-kota kecil, lebih rendah dari 0,334 untuk kota-kota sedang, dan lebih rendah dari 0,4919 untuk kota-kota besar pada tahun 2006. Aglomerasi penduduk perkotaan sangat mirip dengan aglomerasi penduduk regional di kota-kota kecil dan besar. kota; sedangkan penduduk perkotaan di kota-kota sedang berkumpul di kota-kota yang urbanisasinya lebih rendah dari 0,294.

### **Pengambilan Keputusan Migrasi Penduduk yang Optimal**

Berdasarkan identifikasi aglomerasi penduduk dan inefisiensi aglomerasi, disajikan empat keputusan perencanaan mengenai migrasi penduduk untuk menghilangkan inefisiensi alokasi penduduk. Migrasi penduduk dilaksanakan atas dasar ketidakefisienan kekuatan benchmark dan distribusi jalur penduduk. Jumlah migrasi penduduk untuk setiap kota dilaksanakan sesuai dengan perbedaan antara benchmark dan distribusi jalur penduduk asli. Semakin besar perbedaannya, semakin besar migrasi penduduk.

Keputusan 1 untuk migrasi penduduk regional yang optimal di kota-kota kecil adalah untuk memandu 14,64 persen penduduk daerah di kota-kota kecil dengan tingkat urbanisasi lebih rendah dari 0,214 bermigrasi ke kota-kota kecil dengan tingkat urbanisasi yang lebih tinggi. Keputusan 2 untuk migrasi penduduk regional di kota-kota sedang adalah mengarahkan 9,85 persen penduduk regional di kota-kota sedang dengan tingkat urbanisasi lebih rendah dari 0,214 untuk bermigrasi ke kota-kota sedang dengan tingkat urbanisasi yang lebih tinggi. Keputusan 4 untuk migrasi penduduk regional di kota-kota besar adalah mengarahkan 14 persen penduduk regional di kota-kota besar dengan tingkat urbanisasi lebih rendah dari 0,4919 untuk bermigrasi ke kota-kota besar dengan tingkat urbanisasi yang lebih tinggi. Kekuatan inefisiensi antara benchmark dan distribusi penduduk regional menyusut menjadi 0,058, 0,041, dan 0,056 masing-masing dari 0,1464, 0,0985, 0,1397, dan rata-rata tingkat urbanisasi dengan distribusi jalur penduduk regional mengalami pertumbuhan sebesar 1,84, 1,41, dan 2,73 persen untuk kecil, menengah, dan besar. kota masing-masing. Semua temuan menunjukkan bahwa keputusan mengenai migrasi penduduk regional efektif.

Namun, migrasi penduduk yang digunakan dalam penelitian ini adalah migrasi pedalaman masing-masing untuk kota kecil, sedang dan besar. Desain jalur-konvergensi perlu diperbarui untuk simulasi migrasi jika migrasi penduduk diterapkan di antara kelompok kota yang berbeda, yang akan menghasilkan kesimpulan yang berbeda.

## BAB 17

### INTERPRETASI KOGNITIF GAMBAR TERMOGRAFI MENGGUNAKAN MEMORI SEMANTIK PEMBELAJARAN FUZZY NOVEL

Fuzzy neural network (FNN), hibrida dari logika fuzzy dan neural network, secara komputasi kuat, kuat dan mampu memodelkan domain masalah nonlinier yang kompleks melalui ekstraksi dan self-tuning aturan fuzzy IF-THEN. Ini menghasilkan sistem memori pembelajaran semantik yang kuat yang berguna untuk membangun alat pendukung keputusan yang cerdas. Pencitraan termal telah efektif digunakan dalam mendeteksi spektrum inframerah untuk skrining pasien SARS potensial. Bab ini mengusulkan pendekatan kognitif dalam studi korelasi dan interpretasi semantik gambar termal superfisial terhadap suhu tubuh internal yang sebenarnya. Perbandingan antara memori semantik global dan lokal serta model FNN Mamdani dan TSK disajikan. Sistem inframerah yang ada biasanya digunakan di berbagai pos pemeriksaan asrama dan ini memiliki tingkat negatif palsu yang tinggi. Penggunaan FNN sebagai back-end sistem dapat meningkatkan secara signifikan dan karenanya berperan sebagai alat pendukung keputusan medis yang cerdas dengan tingkat akurasi yang tinggi. Eksperimen ekstensif dilakukan pada data kehidupan nyata yang diambil dari Departemen Darurat (A&E), Rumah Sakit Tan Tock Seng (pusat SARS yang ditunjuk di Singapura). Kinerja FNN sebagai sistem pendukung keputusan analisis termal, memberikan interpretasi dan pemahaman semantik yang masuk akal, sangat menggembirakan.

#### 17.1 PENDAHULUAN

Sistem fuzzy telah dikembangkan untuk menangani informasi yang tidak tepat, sangat mirip dengan penalaran manusia, sedangkan jaringan saraf didasarkan pada arsitektur otak dan kemampuan belajar. Fuzzy neural networks (FNNs) menggabungkan kemampuan sistem fuzzy dan jaringan saraf untuk meningkatkan kecerdasan sistem pendukung keputusan yang bekerja di lingkungan yang tidak pasti, tidak tepat, dan bising [1]. FNN adalah feed-forward multi-layered network yang mengintegrasikan elemen dasar dan fungsi dari kontroler logika fuzzy tradisional ke dalam struktur koneksi yang memiliki kemampuan belajar terdistribusi [2]. Sistem logika fuzzy menggunakan nilai fuzzy yang diturunkan dari fungsi keanggotaan berdasarkan input linguistik fuzzy. Ini kemudian dicocokkan dengan aturan IF-THEN linguistik fuzzy melalui proses implikasi fuzzy. Selanjutnya, respons dari setiap aturan dibobot sesuai dengan kepercayaan atau derajat keanggotaan inputnya, dan pusat respons dihitung untuk menghasilkan output.

Ada dua konstruksi berbeda dalam proses pembelajaran FNN, yaitu pembelajaran global dan pembelajaran lokal. Jaringan pembelajaran global umumnya memiliki arsitektur lima lapis, yang terdiri dari simpul linguistik masukan, simpul istilah masukan, simpul aturan, simpul istilah keluaran, dan simpul linguistik keluaran. Pembelajaran dan penyetelan jaringan global akan mempengaruhi lebih banyak aturan, karena aturan berbagi label/node yang sama. Model lokal memiliki aturan yang hanya dipengaruhi oleh data di/dekat lingkup pengaruhnya. Dengan kata lain, jaringan global berkonsultasi dengan seluruh basis aturan fuzzy untuk

menyimpulkan output, sedangkan jaringan lokal hanya bergantung pada aturan fuzzy terdekat.

Pemodelan fuzzy FNN juga dapat dibagi menjadi dua kelas, yaitu: model Mamdani [3] dan model Takagi-Sugeno-Kang (TSK) [4, 5]. Pemodelan fuzzy linguistik, model Mamdani, lihat Persamaan (1), difokuskan pada interpretasi, sedangkan pemodelan fuzzy yang tepat, model TSK, lihat Persamaan (2 dan 3), difokuskan pada akurasi jaringan.

Mamdani:

$$R_i : \text{IF } x_1 \text{ is } A_{i,1} \text{ AND } \dots \text{ AND } x_n \text{ is } A_{i,n} \text{ THEN } y \text{ is } B_i \text{ for } i = 1, 2, \dots, L \quad (1)$$

Takagi, Sugeno dan Kang (TSK):

$$R_i : \text{IF } x_1 \text{ is } A_{i,1} \text{ AND } \dots \text{ AND } x_n \text{ is } A_{i,n} \text{ THEN } y_i = f_i(x_1, x_2, \dots, x_n) \quad (2)$$

for  $i = 1, 2, \dots, L$

$$y = \sum_{i=1}^L w_i(x) y_i \quad (3)$$

dimana  $x$  adalah vektor input,  $x = [x_1, x_2, \dots, x_n]$ ,  $y$  adalah nilai output,  $A_{i,j}$  dan  $B_i$  adalah label linguistik / himpunan fuzzy yang dicirikan oleh fungsi keanggotaan,  $n$  adalah jumlah input pola, dan  $L$  adalah jumlah aturan. Konsekuensi dalam Persamaan (1) hanyalah label linguistik, sedangkan konsekuensi dalam Persamaan (2) adalah fungsi linier dari input. Oleh karena itu, model TSK mengalami penurunan interpretabilitas tetapi meningkatkan daya perwakilan dibandingkan dengan model Mamdani [6].

Termografi, juga dikenal sebagai pencitraan termal inframerah, didasarkan pada analisis yang cermat terhadap suhu permukaan kulit sebagai cerminan dari fisiologi manusia normal atau abnormal [7]. Memanfaatkan pencitraan inframerah non-kontak, makalah ini bertujuan untuk menyelidiki korelasi antara termograf dan suhu tubuh internal yang sebenarnya. Karena sistem IR yang ada belum divalidasi secara ilmiah khususnya yang berkaitan dengan tingkat negatif palsu dan positif palsu [8], FNN diusulkan untuk digunakan untuk mencapai akurasi sistem yang tinggi.

Makalah ini disusun sebagai berikut. Bagian 2 secara singkat membahas prapemrosesan gambar termal yang digunakan sebagai input ke FNN. Bagian 3 menjelaskan metode pemilihan fitur untuk mengambil input ke FNN. Bagian 4 secara singkat menjelaskan jaringan saraf Fuzzy TSK dan Mamadani yang digunakan dalam pekerjaan ini untuk interpretasi kognitif gambar termografi. Bagian 5 menyajikan hasil eksperimen klasifikasi suhu gambar termal dan perbandingan antara jaringan pembelajaran global terhadap lokal serta jaringan model Mamdani terhadap TSK. Dalam Bagian 6, proses menghubungkan termograf dengan kondisi suhu disorot berdasarkan analisis aturan fuzzy. Bagian 7 menyimpulkan makalah ini.

## 17.2 PEMROSESAN GAMBAR

Dalam menganalisis objek dalam gambar, penting untuk membedakan antara objek/wilayah yang menarik, dan yang lainnya. Kelompok yang terakhir ini juga disebut sebagai latar belakang. Teknik yang digunakan untuk menemukan objek/daerah yang diinginkan biasanya disebut sebagai teknik Segmentasi, yaitu memisahkan latar depan dari latar belakang. Segmentasi adalah langkah pertama dalam mencari tahu apa yang ada dalam gambar. Dengan demikian, langkah selanjutnya yang harus dilakukan dengan citra yang telah diproses sebelumnya (“direkonstruksi”) adalah mengelompokkan orang yang diinginkan (dalam hal ini pasien SARS yang potensial). Algoritma metode yang digunakan pada bagian segmentasi citra digambarkan pada 1. Gambar 1 (a) adalah gambar bitmap asli (320x240) dari Gambar 1 (c). Gambar 1 (b) menunjukkan citra biner (Hitam-Putih) setelah melalui proses “deteksi tepi” menggunakan metode Sobel Persamaan (4) sampai (7). Tingkat ambang batas untuk mengubah citra intensitas menjadi citra biner dihitung secara otomatis untuk setiap citra, dengan menggunakan metode Otsu (meminimalkan varians dalam grup) Persamaan (8) – (11). Setelah itu nilai threshold dikalikan dengan 0,01 untuk mendapatkan edge seperti pada Gambar 1 (b).

Operator gradien:

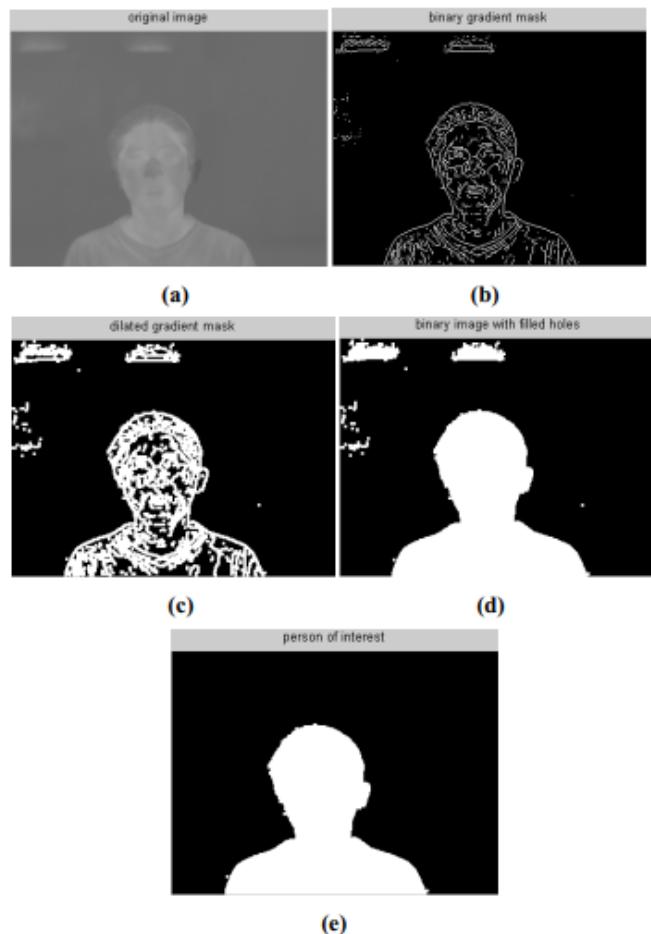
$$\nabla f = \begin{bmatrix} G_x \\ G_y \end{bmatrix} = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{bmatrix} \quad (4)$$

Besaran vektor:

$$|\nabla f| = \sqrt{(G_x^2 + G_y^2)} \approx |G_x| + |G_y| \quad (5)$$

Arah vektor:

$$\alpha(x, y) = \arctan\left(\frac{G_y}{G_x}\right), \text{ with respect to x-axis} \quad (6)$$



**Gambar 17.1** Prosedur Segmentasi Citra (a – e)

Sobel masks:

-1	-2	-1
0	0	0
1	2	1

-1	0	1
-2	0	2
-1	0	1

$z_1$	$z_2$	$z_3$
$z_4$	$z_5$	$z_6$
$z_7$	$z_8$	$z_9$

$$Gx = (z_7 + 2z_8 + z_9) - (z_1 + 2z_2 + z_3) \quad (7)$$

$$Gy = (z_3 + 2z_6 + z_9) - (z_1 + 2z_4 + z_7)$$

Varians Otsu dalam grup:

$$\sigma_w^2 = q_L(t)\sigma_L^2(t) + q_H(t)\sigma_H^2(t) \quad (8)$$

di mana t adalah ambang batas, dan

$$q_L(t) = \sum_{r=0}^t p(r) \text{ and } q_H(t) = \sum_{r=t+1}^{255} p(r) \quad (9)$$

adalah probabilitas kelompok atas dan bawah masing-masing.

$$\mu_L(t) = \frac{1}{q_L(t)} \sum_{r=0}^t (r \cdot p(r)) \text{ and } \mu_H(t) = \frac{1}{q_H(t)} \sum_{r=t+1}^{255} (r \cdot p(r)) \text{ are} \quad (10)$$

masing-masing adalah rata-rata kelompok atas dan bawah, dan

$$\sigma_L^2(t) = \frac{1}{q_L(t)} \sum_{r=0}^t (r - \mu_L(t))^2 \cdot p(r)$$

Dan

$$\sigma_H^2(t) = \frac{1}{q_H(t)} \sum_{r=t+1}^{255} (r - \mu_H(t))^2 \cdot p(r) \quad (11)$$

adalah varians kelompok atas dan bawah masing-masing.

Untuk membuat garis-garis pada Gambar 1 (b) menggambarkan garis luar orang yang diinginkan, citra Sobel didilatasikan menggunakan vertikal diikuti oleh elemen penataan linier datar horizontal dengan panjang 3 (dalam piksel). Hasilnya ditunjukkan pada Gambar 1 (c). Topeng gradien yang melebar menunjukkan garis besar orang tersebut dengan cukup baik, tetapi masih ada lubang di bagian dalam orang tersebut. Untuk mengisi celah interior lubang, MATLAB®'s built-in function imfill digunakan. Gambar 1 (d) menunjukkan hasilnya. Oleh karena itu, orang yang menarik telah ditangkap di sini. Namun, masih ada beberapa kebingungan di sekitarnya. Menghapus piksel yang tidak terkait yang tidak terhubung ke pusat perhatian pada gambar dilakukan menggunakan fungsi imreconstruct bawaan. Proses ini akan merekonstruksi citra berdasarkan titik piksel yang diberikan dan piksel tetangga yang terhubung, sedangkan sisanya akan dibuang. Hasil akhir ditunjukkan pada Gambar 1 (e).

Nilai rata-rata piksel ambient kemudian dapat dihitung dari setiap gambar; dengan menjumlahkan nilai piksel pada citra asli (Gambar 1 (a)) yang terletak pada piksel hitam (0) pada Gambar 1 (e), dan membaginya dengan jumlah total piksel hitam. Kekurangan dari algoritma ini adalah hanya berlaku untuk kasus ideal dari sebuah gambar, di mana tidak ada noise signifikan yang terletak dekat dengan orang yang diinginkan. Algoritma ini tidak dapat menangani kasus di mana suara-suara terhubung (tumpang tindih) dengan orang tersebut (lihat Gambar 2).



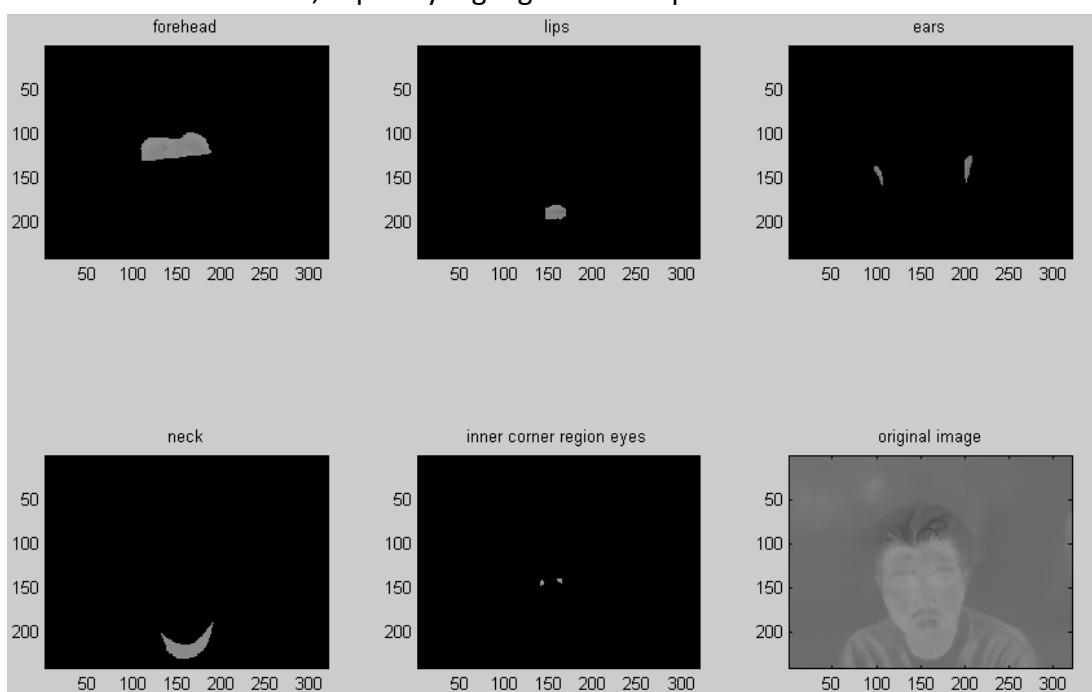
**Gambar 17.2** Hasil Penerapan Algoritma Segmentasi pada Citra Noisy

Noise tanpa filter yang muncul dalam gambar IR sebagian besar berasal dari gambar orang lain yang diambil selama proses fotografi. Oleh karena itu, salah satu cara untuk mengatasi masalah ini adalah dengan menggunakan teknik clustering Fuzzy C-Means untuk memisahkan citra setiap orang menjadi satu kelompok masing-masing. Setelah ini, orang yang tidak diinginkan dalam gambar IR kemudian dapat dihapus. Teknik ini belum diterapkan dalam pekerjaan ini. Hasil yang diharapkan dengan menerapkan algoritma ini ke dalam Gambar 2 ditunjukkan pada Gambar 3. Setelah itu, cluster yang bukan milik orang yang diinginkan (dalam hal ini selalu terletak di tengah gambar) kemudian dapat disaring. Perhitungan teliti dari rata-rata piksel ambient kemudian dapat dilakukan.



**Gambar 17.3** Hasil Segmentasi Penerapan Algoritma Fuzzy C-Means

Prapemrosesan gambar terutama berkaitan dengan pemfilteran gambar (penghilangan noise), normalisasi gambar (standarisasi kisaran suhu), dan konversi rgb-to-grayscale dari gambar termal. Fitur gambar diekstraksi secara manual menggunakan fungsi roipoly() bawaan MATLAB®. Fitur yang diekstraksi adalah dahi, bibir, telinga, leher, dan daerah sudut dalam di sekitar mata; seperti yang digambarkan pada Gambar 4.



**Gambar 17.4** Ekstraksi fitur citra termal skala abu-abu (320x240 piksel)

### 17.3 PILIHAN INPUT: METODE PENILAIAN KORELASI

Input ke FNN  $x = [x_1, x_2, \dots, x_n]$ , dengan jumlah pola input n, dapat diambil dari nilai intensitas/skala abu-abu piksel absolut atau relatif (0-255) dari lima fitur gambar yang diekstraksi daerah, yaitu: dahi, bibir, telinga, leher, dan daerah sudut dalam mata (ICREA). Koefisien korelasi Pearson ( $r_{xy}$ ), seperti yang ditunjukkan pada Persamaan. (12), dapat digunakan untuk mengevaluasi hubungan antara input  $x = [x_1, \dots, x_k]^T$  dan output  $y = [y_1, \dots, y_k]^T$ , yaitu memeriksa apakah input tertentu relevan dengan output yang diinginkan. Dengan demikian, input yang optimal dapat diamati dengan melihat nilai korelasinya. Mengambil momen statistik  $s = [\text{minimum}, \text{maksimum}, \text{median}, \text{mean}, \text{standar-deviasi}, \text{varians}]^T$  dari fitur gambar  $i = [\text{dahi}, \text{bibir}, \text{telinga}, \text{leher}, \text{ICREA}]^T$  dari K termograf (gambar termal) dalam warna abu-abu-skala (nilai piksel dalam format [0,255]), akan menghasilkan 30 fitur  $F = [f_{11}, \dots, f_{1j}, \dots, f_{15}; \dots; f_{61}, \dots, f_{6j}, \dots, f_{65}]$ ; dimana  $f_{ii} = s_i i_i = [f_{ii}^{(1)}, \dots, f_{ii}^{(K)}]^T$  adalah vektor nilai minimum daerah dahi,  $f_{ij} = s_i j_i = [f_{ij}^{(1)}, \dots, f_{ij}^{(K)}]^T$  adalah vektor nilai minimum daerah bibir, dan seterusnya.  $f_{ij} = s_i j_i = [f_{ij}^{(1)}, \dots, f_{ij}^{(K)}]$  di mana  $i, j = 1, \dots, 5$  berkorelasi dengan output yang diinginkan  $y = [y_1, \dots, y_K]^T$  di mana  $y_i$  adalah suhu inti seseorang dalam I termograf K. Hasil dari 30 nilai korelasi, dengan K = 180 citra gray-scale dirangkum pada Tabel 1.

**Tabel 17.1** Koefisien Korelasi,  $r_{xy}$ , antara Fitur Input dan Output yang Diinginkan (ICREA: daerah sudut dalam area mata)

Fitur	dahi	bibir	telinga	leher	ICREA
Minimum	0.549	0.288	0.454	0.570	0.636
Maksimum	<i>0.841</i>	0.702	0.664	0.826	0.668
median	0.764	0.628	0.595	0.767	0.660
Berarti	0.762	0.610	0.631	0.768	0.662
Standar deviasi	0.159	0.391	0.195	0.043	0.014
Perbedaan	0.162	0.433	0.175	0.028	0.059

$$r_{xy} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 * \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2}} \quad (12)$$

di mana  $x_i$  adalah input ke jaringan,  $y_i$  adalah output jaringan yang diinginkan,  $x$  adalah rata-rata input,  $\bar{y}$  adalah rata-rata output yang diinginkan, dan  $n$  adalah jumlah sampel pelatihan. Tabel 1 menunjukkan bahwa nilai maksimum fitur  $s_2$  memiliki nilai korelasi tertinggi di seluruh fitur gambar  $i$  (seperti yang ditunjukkan dalam huruf miring). Oleh karena itu, kelima fitur ini, yaitu  $f_{21}, f_{22}, f_{23}, f_{24}, f_{25}$ , adalah yang paling relevan dengan output dan oleh karena itu dipilih sebagai input ke jaringan  $x = [x_1, \dots, x_5]$  selama eksperimen. Bagian berikut secara singkat menjelaskan arsitektur jaringan saraf fuzzy yang digunakan dalam pembangunan sistem pendukung keputusan cerdas yang memungkinkan interpretasi kognitif dari keputusan yang dilakukan pada gambar termal.

## 17.4 JARINGAN SARAF FUZZY

Jaringan saraf tiruan adalah jaringan neuron buatan yang meniru pensinyalan dan pemrosesan otak manusia. Mereka memiliki kemampuan pengenalan pola yang sangat kuat tetapi menderita masalah yang melekat sebagai kotak hitam, karena mereka tidak mampu menjelaskan hubungan sebab akibat antara input dan hasil (output). Di sisi lain, sistem fuzzy memodelkan kemampuan penalaran manusia dalam lingkungan ketidakpastian. Sistem ini menggunakan aturan fuzzy IF-THEN yang mirip dengan penalaran manusia. Logika fuzzy ini mudah dipahami dan cenderung toleran terhadap data yang tidak tepat. Ada 2 model utama untuk sistem fuzzy; yaitu: Mamdani dan Sugeno. Perbedaan mereka terletak pada cara output mereka ditafsirkan. Model Mamdani menghasilkan sistem logika fuzzy yang memiliki konsekuensi yang sangat dapat diinterpretasikan; sedangkan model Sugeno menghasilkan konsekuensi yang merupakan fungsi tajam dari input. Yang terakhir ini secara komputasi lebih akurat tetapi tidak dapat ditafsirkan seperti yang pertama.

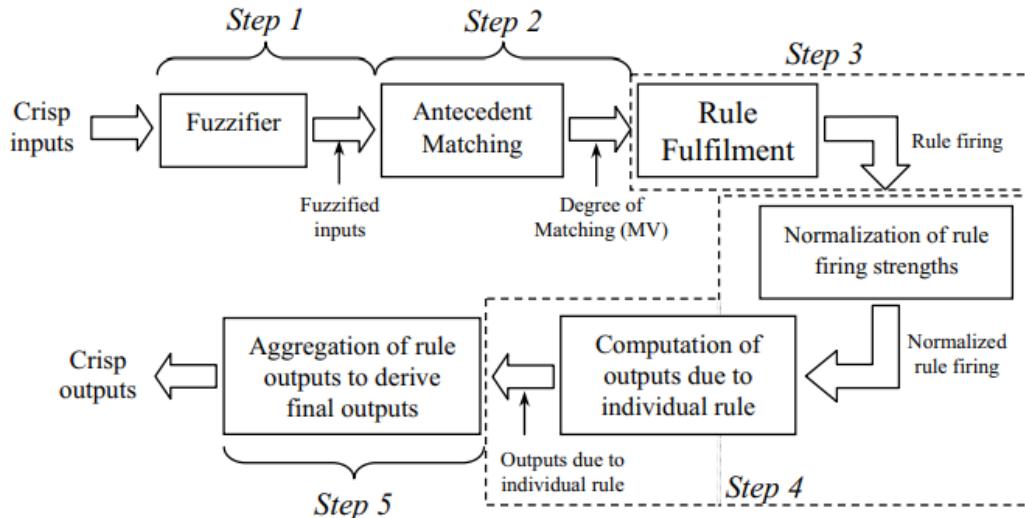
Sistem neuro-fuzzy adalah sistem hybrid, mengintegrasikan jaringan saraf dengan sistem fuzzy. Sistem ini tidak mengalami keterbatasan kotak hitam dan mampu bekerja di lingkungan yang tidak pasti. Sistem neuro-fuzzy seperti Pseudo Outer-Product based Fuzzy Neural Network (POPFNN) [11] – contoh model Mamdani, ANFIS [10], dan FITSK [19] – contoh model Sugeno mendapatkan pengakuan di beberapa area berbeda seperti sebagai keuangan, keamanan dan perawatan kesehatan, karena kinerja dan interpretasinya lebih unggul daripada sistem lain seperti jaringan fungsi basis radial (RBF). Bagian berikut menjelaskan secara singkat dua kelas utama arsitektur fuzzy saraf yang digunakan dalam proses pengambilan keputusan untuk interpretasi kognitif gambar termografi. Yaitu: Sistem fuzzy TSK – jaringan ANFIS [10] dan Sistem Fuzzy Mamdani – POPFNN (jaringan pembelajaran global) [11] dan FCMAC-AARS (jaringan pembelajaran lokal) [13].

### **ANFIS**

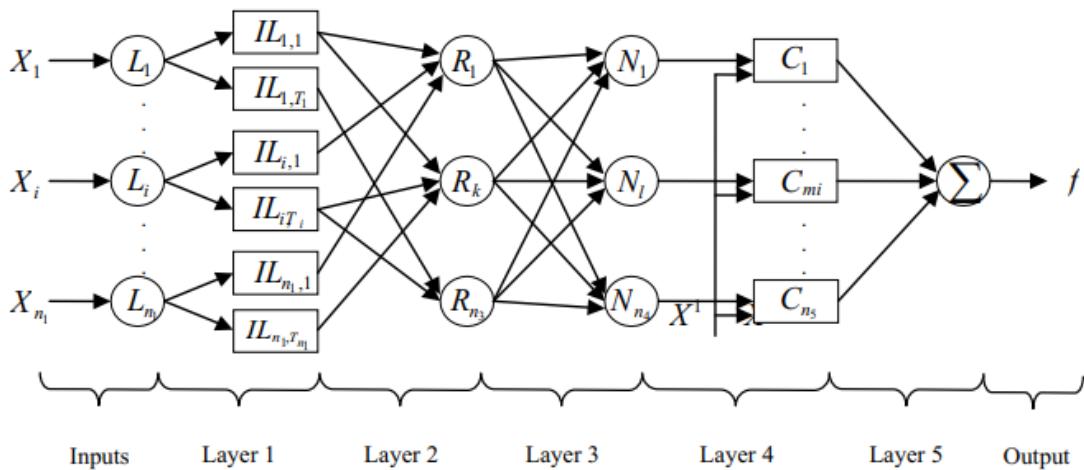
Adaptive Neuro-Fuzzy Inference System (ANFIS) mengimplementasikan model fuzzy TSK. Proses inferensi berdasarkan model fuzzy TSK ditunjukkan pada Gambar 5. Jaringan ANFIS memiliki struktur lima lapis seperti yang diilustrasikan pada Gambar 5. Untuk jaringan ANFIS, input dan output tidak dianggap sebagai bagian dari struktur jaringan. Selain itu, struktur jaringan telah ditentukan sebelumnya oleh pengguna sebelum dimulainya pelatihan. Siklus pelatihan jaringan ANFIS dengan demikian menyetel parameter jaringan (dikenal sebagai pembelajaran parameter) tetapi tidak mengubah struktur koneksi jaringan. Dalam pengantar ini, node input ke jaringan ANFIS dilambangkan sebagai  $L_i$ , di mana  $i \in \{1 \dots n_1\}$ . Label  $n_1$  mengacu pada jumlah input ke jaringan ANFIS. Vektor  $X = [X_1, \dots, X_i, \dots, X_{n_1}]^T$  menunjukkan input numerik yang disajikan ke jaringan ANFIS. Output dilambangkan sebagai  $f$ . Di sini, hanya sistem multiple-input-and-single-output (MISO) yang dipertimbangkan. Ini karena sistem multiple-input-and-multiple-output (MIMO) dapat dengan mudah didekomposisi menjadi beberapa sistem MISO.

Gambar 6 menunjukkan koneksi saraf (ANFIS) yang digunakan untuk mengimplementasikan skema inferensi fuzzy TSK. Layer 1 pada dasarnya terdiri dari istilah linguistik (set fuzzy) dari node input ke jaringan ANFIS. Istilah linguistik ke- $j$  dari input ke- $i$  dilambangkan sebagai  $IL_{i,j}$ . Label  $T_i$  menunjukkan jumlah istilah linguistik yang dimiliki input  $L_i$ . Setiap simpul masukan  $L_i$  mungkin memiliki jumlah suku linguistik  $T$  yang berbeda. Oleh karena

itu, jumlah node pada layer 1 adalah  $\sum_{i=1}^{n1} T_i$ . Lapisan 2 dari jaringan ANFIS adalah basis aturan fuzzy yang memodelkan karakteristik yang mendasari data pelatihan numerik. Node aturan dilambangkan sebagai  $R_k$ , di mana  $k \in \{1 \dots n3\}$ .



Gambar 17.5 Proses Inferensi Model Fuzzy TSK



Gambar 17.6 Struktur jaringan ANFIS

Ada  $n1$  node (istilah fuzzy) dari layer 1 (satu dari setiap variabel input) yang dimasukkan ke dalam node sembarang  $R_k$  di layer 2. Label  $n3$  mengacu pada jumlah aturan fuzzy dalam jaringan ANFIS. Layer 3 adalah lapisan normalisasi jaringan ANFIS. Ada koneksi penuh antara node layer 2 dan layer 3. Jumlah node pada layer 3 (dilambangkan sebagai  $n4$ ) ditentukan oleh jumlah aturan fuzzy dalam jaringan ANFIS. Artinya,  $n4 = n3$ . Fungsionalitas dari masing-masing node layer 3 adalah untuk melakukan normalisasi kekuatan tembak dari aturan fuzzy yang diwakilinya. Selanjutnya, perhitungan konsekuensi aturan dilakukan pada lapisan 4 jaringan ANFIS. Karena jaringan ANFIS mengadopsi model fuzzy TSK, konsekuensi dari aturan adalah fungsi dari input.

Fungsi-fungsi ini dilambangkan sebagai  $C_m$ , di mana  $m \in \{1 \dots n5\}$ . Label  $n5$  mengacu pada jumlah fungsi keluaran pada lapisan 4 dan sekali lagi ditentukan oleh jumlah aturan fuzzy. Jadi,  $n5 = n3$ . Setiap fungsi keluaran  $C_m$  dapat diinterpretasikan sebagai Persamaan 13 :

$$C_m : (X_1, \dots, X_i, \dots, X_n) \rightarrow \mathfrak{R} \quad (13)$$

Dimana  $X_i$  = input numerik ke- $i$  ke jaringan ANFIS; dan

$\mathfrak{R}$  = himpunan bilangan real.

Karena setiap aturan akan menghitung keluaran yang disimpulkan (garis untuk ANFIS) berdasarkan stimulus masukan  $X = [X_1, \dots, X_2, \dots, X_n]^T$ , keluaran jaringan akhir adalah agregasi dari semua keluaran yang disimpulkan yang dihitung. Oleh karena itu, fungsi lapisan ANFIS terakhir (lapisan 5) adalah untuk menggabungkan semua keluaran yang disimpulkan dari aturan melalui penjumlahan dan menyajikan nilai yang dihitung sebagai keluaran jaringan. Output ini dilambangkan sebagai  $f$ . Selama siklus pelatihan jaringan ANFIS, kumpulan data pelatihan numerik  $S$  terdiri dari pasangan input-output yang diinginkan ( $X^{(p)}$ ,  $Y^{(p)}$ ) (di mana  $p \in \{1, \dots, P\}$  dan  $P$  menunjukkan jumlah pelatihan instance) dimasukkan ke dalam jaringan ANFIS dari lapisan input dan output. Parameter jaringan ANFIS selanjutnya dapat disetel baik menggunakan algoritma propagasi balik berbasis gradien negatif [16] atau algoritma pembelajaran hybrid yang diusulkan oleh Jang [10].

Pemetaan Gambar 5 ke Gambar 6 menunjukkan korespondensi antara langkah-langkah proses inferensi TSK dan fungsi jaringan ANFIS.

**Langkah 1** - Inferensi TSK secara implisit dilakukan oleh node input dari jaringan ANFIS. Node input berfungsi sebagai fuzzifier tunggal untuk proses inferensi.

**Langkah 2** - Fungsi node layer 1 dari jaringan ANFIS siap dipetakan ke fase pencocokan antecedent dari proses inferensi. Nilai keanggotaan dari input numerik sehubungan dengan himpunan fuzzy dihitung.

**Langkah 3** - Lapisan 2 dari jaringan ANFIS mengimplementasikan fase pemenuhan aturan dari proses inferensi di mana kekuatan tembak aturan fuzzy ditentukan.

**Langkah 4** – Fase normalisasi dari proses inferensi TSK dilakukan oleh node di layer 3 dan layer 4 dari jaringan ANFIS. Lapisan 3 node menghitung kekuatan aturan fuzzy yang dinormalisasi sementara lapisan 4 menurunkan output yang disimpulkan.

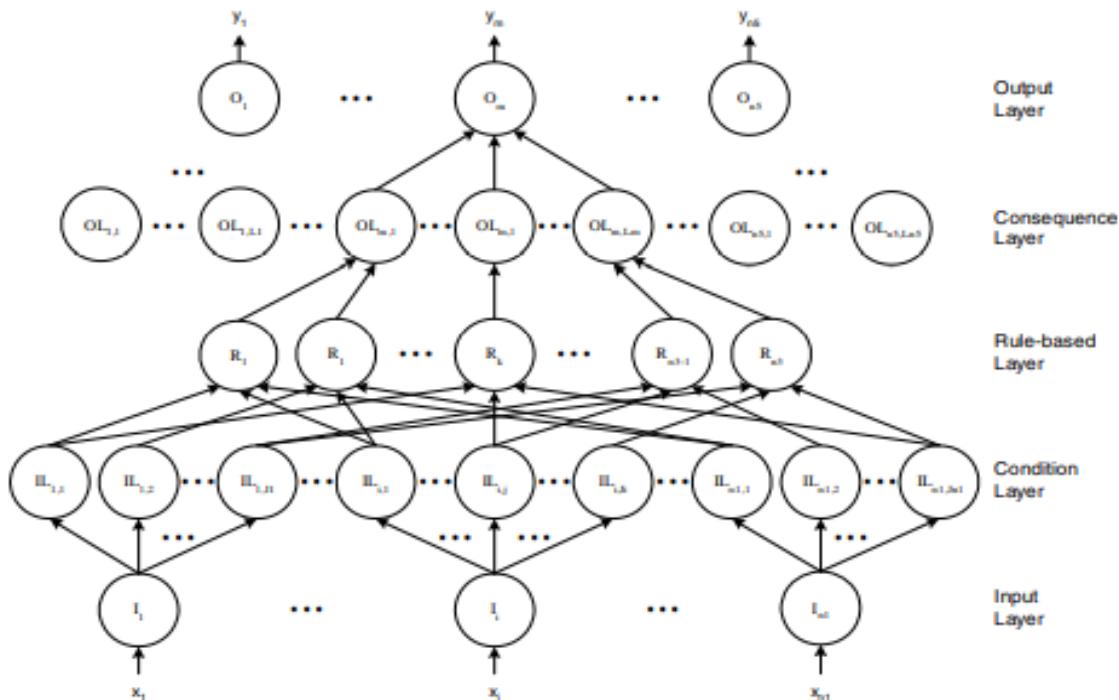
**Langkah 5** - Lapisan 5 dari jaringan ANFIS selanjutnya mengumpulkan output yang disimpulkan untuk mendapatkan output tajam yang diperlukan dalam fase agregasi dari proses inferensi TSK.

ANFIS adalah sistem inferensi fuzzy yang diimplementasikan dalam kerangka jaringan adaptif, di mana parameter keanggotaan disetel secara otomatis. Sistem inferensi fuzzy dapat dibangkitkan dengan 2 cara, baik dengan clustering maupun non-clustering. Clustering merupakan salah satu bentuk unsupervised learning, dimana data yang tidak diketahui dikelompokkan menjadi beberapa cluster yang berasosiasi dengan pola yang berbeda. Menggunakan metode ini untuk menghasilkan sistem inferensi fuzzy mengurangi kutukan dimensi dan dapat dengan mudah menghasilkan sistem inferensi fuzzy tanpa perlu menentukan fungsi keanggotaan. Penyetelan parameter keanggotaan akan dilakukan melalui pembelajaran terawasi dari pasangan input-output yang diberikan ke sistem sebagai data pelatihan. Ini menggunakan algoritma pembelajaran hibrida yang mensinergikan metode

propagasi balik dan estimasi kuadrat terkecil untuk meningkatkan kinerja pembelajaran. Bagian berikut menjelaskan secara singkat kelas jaringan saraf fuzzy kelas Mamdani. Dua kelas perwakilan untuk jaringan saraf fuzzy global dan lokal disajikan untuk diskusi.

### POPFNN

Arsitektur POPFNN-CRI(S) [10] untuk sistem Multi-Input Multi-Output (MIMO) adalah jaringan saraf lima lapis seperti yang ditunjukkan pada Gambar 7. Untuk kesederhanaan, hanya interkoneksi untuk output  $y_m$  yang ditunjukkan pada Gambar. 7.



**Gambar 17.7** Struktur POPFNN-CRI(S)

Setiap lapisan dalam POPFNN-CRI(S) melakukan operasi fuzzy tertentu. Input dan output dari POPFNN-CRI(S) direpresentasikan sebagai vektor non-fuzzy  $X^T = [x_1, x_2, \dots, x_i, \dots, x_{n1}]$  dan vektor non-fuzzy  $Y^T = [y_1, y_2, \dots, y_l, \dots, y_{n5}]$  masing-masing. Fuzzifikasi data masukan dan defuzzifikasi data keluaran masing-masing dilakukan oleh lapisan linguistik kondisi dan keluaran, sedangkan inferensi fuzzy secara kolektif dilakukan oleh lapisan aturan dan lapisan konsekuensi. Jumlah neuron dalam kondisi dan lapisan rule-base didefinisikan masing-masing dalam Persamaan (14) sampai (16). Penjelasan rinci tentang fungsionalitas setiap lapisan diberikan sebagai berikut; lihat Persamaan (14) – (16):

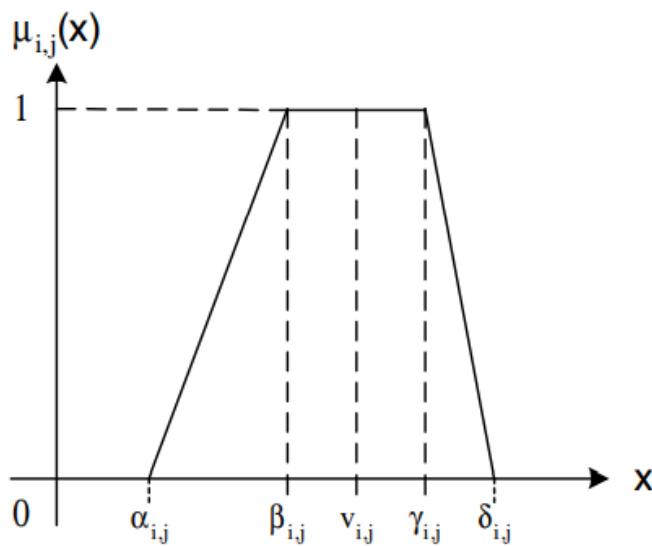
$$n2 = \sum_{i=1}^{n1} J_i \quad (14)$$

$$n4 = \sum_{m=1}^{n5} L_m \quad (15)$$

$$n3 = \left[ \prod_{i=1}^{n1} J_i \right] \times \left[ \prod_{m=1}^{n5} L_m \right] \quad (16)$$

Dimana

- J<sub>i</sub> = jumlah label linguistik untuk input ke-i,
- L<sub>m</sub> = jumlah label linguistik untuk keluaran ke-m,
- n<sub>1</sub> = jumlah input,
- n<sub>2</sub> = jumlah neuron pada lapisan kondisi,
- n<sub>3</sub> = jumlah aturan atau neuron berbasis aturan,
- n<sub>4</sub> = jumlah label linguistik untuk keluaran, dan
- n<sub>5</sub> = jumlah keluaran.



**Gambar 17.8** Fungsi keanggotaan berbentuk trapesium

**Lapisan linguistik input:** Neuron di lapisan linguistik input disebut simpul linguistik input. Setiap simpul linguistik input li mewakili variabel input linguistik dari input non-fuzzy  $x_i$  yang sesuai. Setiap node mentransmisikan input non-fuzzy langsung ke lapisan kondisi.

**Lapisan kondisi:** Neuron di lapisan kondisi disebut simpul label-input. Setiap simpul label masukan  $I_{i,j}$  mewakili label linguistik ke-j dari simpul linguistik ke-i dari lapisan masukan. Node input-label merupakan anteseden dari aturan fuzzy. Setiap simpul diwakili oleh fungsi keanggotaan trapesium  $\mu_{i,j}(x)$  yang dijelaskan oleh interval fuzzy yang dibentuk oleh empat parameter  $(\alpha_{i,j}, \beta_{i,j}, \gamma_{i,j}, \delta_{i,j})$  dan sebuah centroid  $v_{i,j}$  seperti yang ditunjukkan pada Gambar . Interval fuzzy ini dikenal sebagai bilangan fuzzy trapesium [17].

**Lapisan rule-base:** Neuron di lapisan rule-base disebut node aturan. Setiap node aturan  $R_k$  merepresentasikan aturan fuzzy if-then.

**Lapisan konsekuensi:** Neuron di lapisan konsekuensi disebut simpul label keluaran. Node label keluaran  $OL_{m,l}$  mewakili label linguistik ke-l dari keluaran  $y_m$ .

**Lapisan linguistik keluaran:** Neuron di lapisan linguistik keluaran disebut simpul linguistik keluaran. Simpul linguistik keluaran  $O_m$  mewakili nilai linguistik keluaran dari keluaran  $y_m$

### FCMAC-AARS

Cerebellar Model Articulation Control (CMAC) memiliki alternatif dalam jaringan saraf multi-layer yang dilatih dengan backpropagation yang memiliki kelemahan dari banyak iterasi untuk konvergen, sejumlah besar komputasi, perangkat keras khusus yang mahal, permukaan kesalahan dengan relatif minimal dan tidak ada pembelajaran tambahan yang berhasil . Arsitektur Fuzzy Cerebellar Model Articulation Control (FCMAC) menggunakan skema inferensi logika fuzzy. Fitur utamanya, adalah generalisasi lokal, komputasi algoritmik cepat, pelatihan tambahan, representasi fungsional, dan superposisi keluaran. Bagian ini mengulas dasar matematis dari inferensi AARS yang digunakan untuk struktur FCMAC. Seperti yang dijelaskan pada bagian sebelumnya, AARS dapat didefinisikan sebagai Persamaan (17):

$$\begin{array}{ll}
 \text{Rule:} & \text{IF } x \text{ is } A, \text{THEN } y \text{ is } B, \text{ threshold} = \tau \\
 \text{Fact:} & x \text{ is } \tilde{A} \\
 \hline
 \text{Conclusion:} & y \text{ is } \begin{cases} \text{MF}(B, \text{SM}(A, \tilde{A})) & \text{if } \text{SM}(A, \tilde{A}) \geq \tau \\ \text{no conclusion} & \text{otherwise} \end{cases}
 \end{array} \quad (17)$$

Istilah-istilah kunci diadaptasi dan dijelaskan sebagai berikut:

**AARS Threshold ( $\tau$ )** adalah ambang batas untuk SM adalah nilai di bawah aturan yang dianggap terlalu tidak relevan dengan fakta dan harus disaring untuk pengurangan konsekuensi.

**Ukur Kesamaan (SM)** mengevaluasi kesamaan antara anteseden aturan  $\tilde{A}$  dan pengamatan A yang diturunkan dari ukuran jarak (DM), diberikan oleh Persamaan (18)

$$SM = (1 + DM)^{-1} \quad SM \in [0,1] \quad (18)$$

Definisi ukuran jarak bisa sebagai berikut:

Ukuran Ketidakkonsistenan:

$$DM(A, \tilde{A}) = 1 - \sup_{x \in X} \mu_{A \cap \tilde{A}}(x) \quad (19)$$

Pengukuran Hausdorff:

$$DM(A, \tilde{A}) = |c(A) - c(\tilde{A})| \quad (20)$$

Di mana  $c(\cdot)$  menunjukkan centroid dari himpunan fuzzy. Tidak seperti di TVR di mana pencocokan antara  $A$  dan  $\tilde{A}$  direpresentasikan sebagai fungsi, nilai tunggal SM digunakan sebagai gantinya di AARS. Ini dianggap sebagai kelemahan dalam akurasi, tetapi mengurangi kompleksitas komputasi dan membuat seluruh proses lebih sederhana dan lebih mudah untuk diintegrasikan ke dalam struktur seperti jaringan saraf [18, 19].

Dari Persamaan (18) dapat dilihat bahwa itu menerjemahkan setiap ukuran ketidakkonsistenan positif DM ke dalam kisaran  $[0, 1]$ . Namun, jika ini digunakan bersama dengan Persamaan (19), akan menimbulkan masalah bahwa SM bias menjadi kisaran  $[0,5, 1]$ . Ini tidak diinginkan dalam konteks FCMAC-AARS karena, kontribusi konsekuensi dari aturan yang berbeda tergantung pada SM dengan aturan ini dan bias tersebut mengurangi perbedaan di antara SM ini. Salah satu cara untuk menormalkan SM seperti yang diusulkan dalam Persamaan (18) [18] adalah dengan mendefinisikannya sebagai Persamaan (21)

$$SM = 1 - DM \quad (21)$$

Yang mempertahankan efek bahwa semakin besar DM, semakin kecil SM. Ketika Persamaan (21) digunakan bersama dengan Persamaan (19), SM menjadi Persamaan (22)

$$SM(A, \tilde{A}) = \sup_{x \in X} \mu_{A \cap \tilde{A}}(x) \quad (22)$$

Persamaan (22) memiliki keunggulan dibandingkan Persamaan (19) menggunakan Persamaan (20) (Hausdorff Ukur sebagai DM) karena mengambil informasi lengkap dari dua himpunan fuzzy menjadi pertimbangan daripada hanya mempertimbangkan hanya centroid. Implementasi bijaksana itu juga murah. Fungsi Modifikasi (MF) hadir untuk menyimpulkan konsekuensinya. Ini adalah fungsi dari konsekuensi aturan B dan ukuran kesamaan SM, yaitu,  $\tilde{B} = MF(B, SM)$ . Fungsi modifikasi yang diberikan oleh Turksten hadir dalam 2 jenis; yaitu: bentuk ekspansi dan reduksi, dan didefinisikan oleh Persamaan (23) dan (24):

Perluasan dari:

$$\mu_{\tilde{B}}(y) = \min\left(\frac{\mu_B(y)}{SM}, 1\right) \quad (23)$$

Bentuk pengurangan:

$$\mu_{\tilde{B}}(y) = \mu_B(y) \cdot SM \quad (24)$$

Satu dengan MF Turksen, adalah menghasilkan himpunan fuzzy yang tidak dinormalisasi. Oleh karena itu, fungsi Modifikasi yang diusulkan berikut Persamaan (25) dan (26) digunakan:  $MF^x$  (bentuk ekspansi):

$$\forall \alpha \in [0,1] \quad \frac{c(A) - \min(\alpha \tilde{A})}{c(A) - \min(\alpha A)} = \frac{\max(\alpha \tilde{A}) - c(A)}{\max(\alpha A) - c(A)} = \frac{1/SM}{1} \quad (25)$$

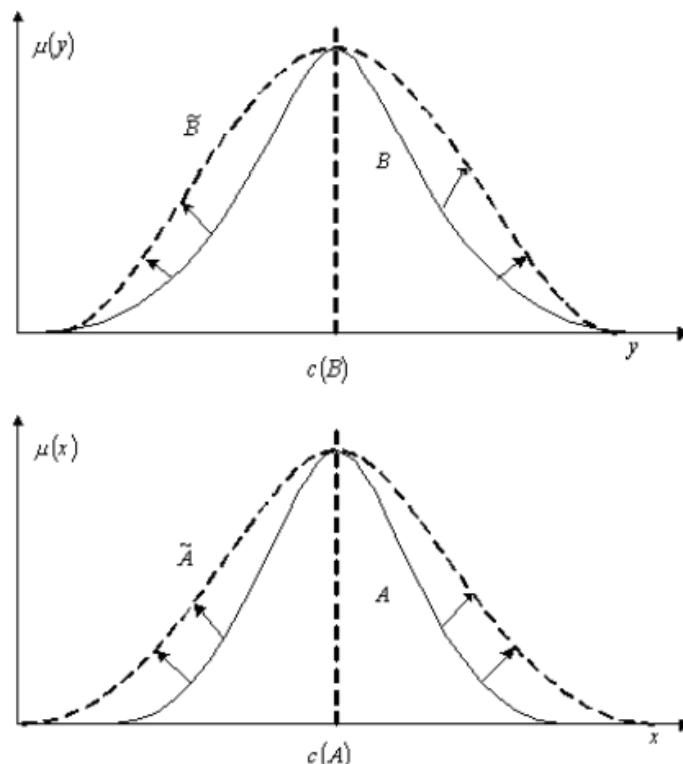
$MF^r$  (bentuk reduksi):

$$\forall \alpha \in [0,1] \quad \frac{c(A) - \min(\alpha \tilde{A})}{c(A) - \min(\alpha A)} = \frac{\max(\alpha \tilde{A}) - c(A)}{\max(\alpha A) - c(A)} = \frac{SM}{1} \quad (26)$$

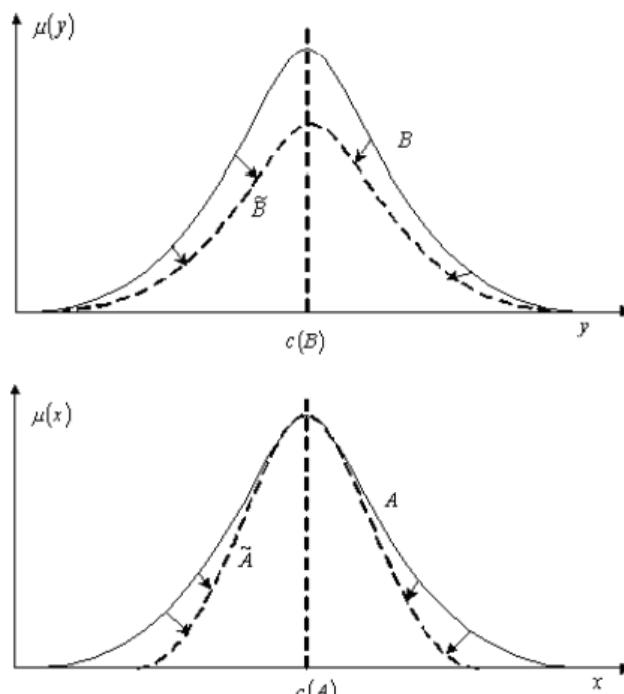
Dimana  $A$  adalah himpunan fuzzy yang akan dimodifikasi

- $\alpha A$  adalah potongan alfa ( $\alpha$ - cut) dari himpunan fuzzy  $A$  yang menyatakan semua elemen yang keanggotaannya di  $A$  lebih besar dari atau sama dengan  $\alpha$
- $\text{Max}(\alpha A)$  menunjukkan elemen terbesar di  $\alpha A$ .
- $c(A)$  adalah pusat massa  $A$ .  $\tilde{A}$  dan  $A$  berbagi pusat massa yang sama.

Di sini, untuk mencapai efek ekspansi atau pengurangan, daripada menskalakan nilai keanggotaan, lebar himpunan fuzzy dapat diskalakan sebagai gantinya dibandingkan pada Gambar 9 dan 10. Dengan bentuk ekspansi, himpunan fuzzy yang disimpulkan diperkenalkan dengan ketidakpastian tambahan ; karenanya sesuai dengan lindung nilai linguistik "kurang lebih", lihat Gambar 9.



**Gambar 17.9** Bentuk MF Ekspansi : Asli dan dimodifikasi



**Gambar 17.10** Bentuk Pengurangan MF: Asli dan dimodifikasi

Bentuk reduksi memiliki efek yang berlawanan dengan bentuk ekspansi, dan dalam beberapa hal merupakan tiruan dari CRI [18]. Ini memiliki efek lindung nilai linguistik "sangat", lihat Gambar 10. Penskalaan yang diusulkan memiliki efek ekspansi atau pengurangan yang serupa, sementara itu juga tidak mengalami masalah himpunan fuzzy subnormal. Himpunan yang dimodifikasi  $\tilde{A}$  yang dihasilkan dari  $A$  oleh MF dapat didefinisikan secara formal dalam Persamaan (27) dan (28):

$$\text{MF}^x \text{ (expansion form): } \mu_{\tilde{A}}(\chi) = \mu_A(c(A) + SM \cdot (\chi - c(A))) \quad (27)$$

$$\text{MF}^r \text{ (reduction form): } \mu_{\tilde{A}}(\chi) = \mu_A \left( c(A) + \frac{\chi - c(A)}{SM} \right) \quad (28)$$

Oleh karena itu, dapat dibuktikan bahwa  $\tilde{A} = \text{MF}(A, SM)$  dengan  $\text{MF}^x$  yang didefinisikan dalam Persamaan (27) berikan  $M(\tilde{A}) = \frac{1}{SM} \cdot M(A)$ , dan  $\text{MF}^r$  dalam Persamaan (28) memberikan  $M(\tilde{A}) = SM \cdot M(A)$ , yaitu Persamaan (29) dan (30) berturut-turut:

$$\tilde{A} = \text{MF}^x(A, SM) \Rightarrow M(\tilde{A}) = \frac{1}{SM} \cdot M(A), \text{ and} \quad (29)$$

$$\tilde{A} = \text{MF}^r(A, SM) \Rightarrow M(\tilde{A}) = SM \cdot M(A) \quad (30)$$

Di mana

$M(A)$  menunjukkan area di bawah himpunan fuzzy, dihitung dengan Persamaan (31) dan (32)

- 1) Integrasi pada rentang nilai:

$$M(A) = \int_{x \in X} (\mu_A(x)) d\chi \quad , \text{ or} \quad (31)$$

- 2) Integrasi pada rentang keanggotaan:

$$M(A) = \int_0^1 (\max(\alpha A) - \min(\alpha A)) d\alpha \quad (32)$$

Aturan fuzzy dalam FCMAC-AARS dapat diekspresikan dengan pola indeks yang unik dan isi sel yang terletak oleh pola indeks. Untuk mengilustrasikan ini, biarkan vektor input dilambangkan dengan

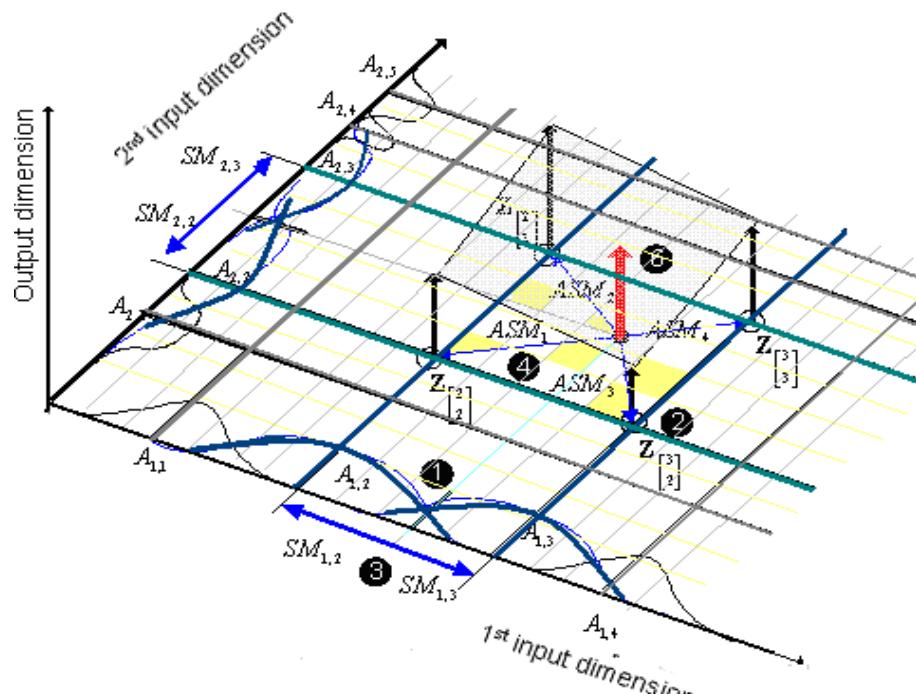
$$\mathbf{x} = [x_1, x_2, \dots, x_i, \dots, x_I]^T$$

Aturan fuzzy dapat dinyatakan sebagai Persamaan (33):

$$\underbrace{\text{IF } x_1 \text{ is } A_{1,j_1}, x_2 \text{ is } A_{2,j_2}, \dots, x_i \text{ is } A_{i,j_i}, \dots, x_I \text{ is } A_{I,j_I}}_{\text{antecedent}} \text{ THEN } o \text{ is } \mathbf{Z}_{[j_1 j_2 \dots j_i \dots j_I]^T} \quad (33)$$

$[j_1 j_2 \dots j_i \dots j_I]^T$  adalah pola indeks dari aturan khusus ini, dan  $\mathbf{Z}_{[j_1 j_2 \dots j_i \dots j_I]^T}$  adalah konten yang disimpan dalam sel memori, yang mewakili konsekuensi dari aturan. Untuk kemudahan penjelasan dan implementasi, pola indeks diganti dengan indeks tunggal  $d$ , Persamaan (34)

$$\mathbf{Z}_d = \mathbf{Z}_{[j_1 j_2 \dots j_i \dots j_I]^T} \quad (34)$$



Gambar 17.11 Jaringan Saraf Fuzzy FCMAC-AARS 2 Dimensi

Konversi antara  $[j_1 \ j_2 \ ... \ j_i \ ... \ j_I]^T$  dan  $d$  dibahas di bagian berikutnya. Sel-sel dalam memori asosiatif dapat dilihat sebagai vektor  $Z$  yang isinya dapat diindeks oleh  $d$ .

## 17.5 HASIL EKSPERIMENT DAN ANALISIS

Eksperimen dilakukan dengan menggunakan 180 termograf sebagai data, dengan root mean square error (RMSE) Persamaan (35) digunakan sebagai istilah evaluasi hasil kinerja. Secara umum, semakin kecil RMSE, semakin baik kinerjanya.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - y_i)^2} \quad (35)$$

di mana  $x_i$  adalah output yang disimpulkan oleh jaringan,  $y_i$  adalah output jaringan yang diinginkan, dan  $n$  adalah jumlah sampel pelatihan.

Ukuran keluaran yang digunakan dalam percobaan adalah sebagai berikut:

- Klasifikasi I (diukur dengan tingkat klasifikasi, CR I). Output diklasifikasikan menjadi tiga kelas, yaitu: L (rendah: <36,2oC), N (normal: 36,2oC-37,7oC), dan H (tinggi:>37,7oC). Suhu inti tubuh digunakan, dengan ambang batas untuk hipertermia/demam mengikuti [8, 9] dan untuk hipotermia mengikuti [9].
- Klasifikasi II (diukur dengan tingkat klasifikasi, CR II). Untuk lebih meningkatkan akurasi klasifikasi, kisaran suhu selanjutnya dipartisi menjadi 8 kelas yang lebih kecil, yaitu: <=34, 34-35, 35-36, 36-37, 37-38, 38-39, 39-40, > 40 (oC).
- Prediksi Suhu (diukur dengan RMSE).

Performa antara jaringan pembelajaran global dan lokal pada data termal dianalisis dan dibandingkan. Menggunakan set data input 5 dimensi  $x = [x_1, \dots, x_5]^T$  yang diperoleh dari metode penilaian korelasi dengan output yang diinginkan  $d$  adalah suhu inti tubuh, percobaan dilakukan pada jaringan saraf (NNs) yang sudah mapan: multilayer perceptron (MLP) feedforward backpropagation (BP) network dan beberapa FNNs, yaitu: ANFIS [10], POPFNN-CRI(S) [11], GenSoFNN-AARS(S) [12], DoFCMAC-AARS (direct output) [13], dan FoFCMAC-AARS (output kabur) [13]. Pengaturan jaringan untuk berbagai arsitektur benchmark baru tersebut ditentukan dalam Tabel A-1 di Lampiran A.

Tabel 2 menunjukkan hasil eksperimen. Terlihat bahwa jaringan global dan lokal memiliki kinerja yang sebanding, meskipun proses pembelajaran jaringan lokal lebih cepat dan menghasilkan struktur yang lebih sederhana dibandingkan dengan jaringan global. Ini karena konstruksi aturan di jaringan lokal hanya didasarkan pada data dalam lingkup pengaruhnya, sedangkan jaringan global memerlukan konsultasi seluruh basis aturan fuzzy untuk menyimpulkan output.

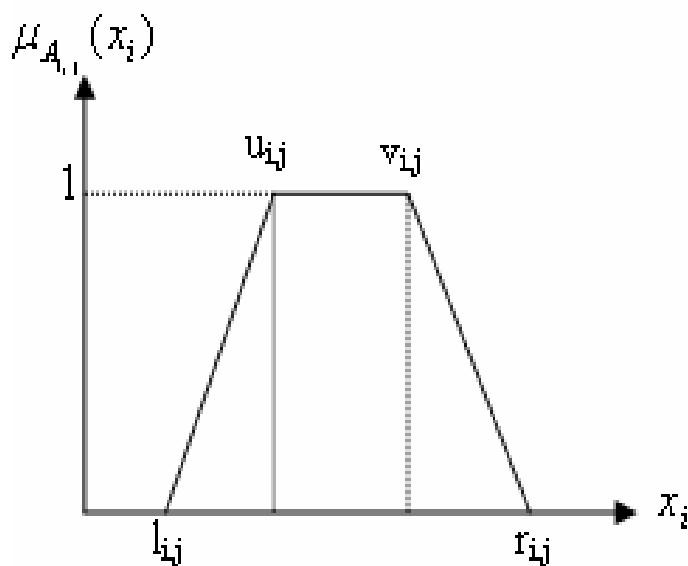
**Tabel 17.2** Hasil Kinerja Jaringan Pembelajaran Global vs. Lokal (Pengingat memori: menggunakan semua 180 instance data untuk pelatihan dan pengujian, Generalisasi: menggunakan 120 instance data yang dipilih secara acak untuk pelatihan dan 60 sisanya untuk pengujian, CR I (%): tingkat klasifikasi I yaitu kelas Rendah/Normal/Tinggi, CR II (%): tingkat klasifikasi II yaitu 8 kelas suhu, RMSE: root mean square error)

Ilmu bangunan	Ingatan memori			Generalisasi		
	CR I	CR II	RMSE	CR I	CR II	RMSE
<b>Jaringan Global</b>						
MLP (5-10-1)	97.67	94.83	0.052	94.50	88.50	0.126
ANFIS	100.00	100.00	0.003	88.33	75.00	0.680
POPFNN-CRI(S)	93.89	79.44	0.268	96.67	83.33	0.277
GenSoFNN-AARS(S)	97.22	88.33	0.081	91.67	83.33	0.171
<b>Jaringan Lokal</b>						
DoFCMAC-AARS	95.00	85.00	0.120	88.33	85.00	0.229
FoFCMAC-AARS	96.11	88.33	0.103	90.00	91.67	0.131

Dapat juga dilihat dari Tabel 2 bahwa ANFIS menghasilkan ingatan yang sempurna dari kumpulan data pengujian yang dipelajari, karena sistem neural-fuzzy ini didasarkan pada model TSK [4, 5] yang digunakan untuk pemodelan fuzzy yang tepat; maka menurunkan interpretabilitas tetapi meningkatkan akurasi [6]. Namun, pengaturan jaringan dengan akurasi kinerja 100% dalam konfigurasi uji pemanggilan kembali memori, yang sebagian besar disebabkan oleh overfitting data pelatihan, dapat menurunkan kinerja dalam konfigurasi uji generalisasi. Itu adalah trade-off. Sebaliknya, POPFNN-CRI(S), GenSoFNN-AARS(S), DoFCMAC-AARS, dan FoFCMAC-AARS didasarkan pada model Mamdani [3] dan sangat cocok untuk pemodelan fuzzy linguistik, yang difokuskan pada interpretabilitas. Oleh karena itu semantik lebih intuitif dan lebih dekat dengan pendekatan kognitif manusia. Selain itu, kinerja mereka dalam tes generalisasi lebih unggul dari ANFIS.

## 17.6 ANALISIS ATURAN FUZZY

Menganalisis kembali hasil dari Tabel 3, dapat diamati bahwa jaringan saraf MLP memiliki kinerja keseluruhan yang lebih unggul daripada FNN lainnya. Namun, sudah menjadi rahasia umum bahwa MLP berfungsi sebagai kotak hitam dan tidak mungkin untuk mengekstrak bentuk aturan fuzzy IF-THEN linguistik dari MLP. Dengan demikian, meninggalkan GenSoFNN-AARS(S) sebagai sistem neural-fuzzy (FNN) yang kinerja keseluruhannya tepat di bawah MLP selama eksperimen. Aturan fuzzy jaringan GenSoFNN menggunakan fungsi himpunan/keanggotaan fuzzy berbentuk trapesium (seperti yang ditunjukkan pada Gambar 12), yang parameternya dihitung dengan teknik pengelompokan DIC [14].



**Gambar 17.12** Fungsi keanggotaan trapesium  $A_{i,j}$  mewakili suku fuzzy ke- $j$  dari input ke- $i$

GenSoFNN-AARS(S) dilatih menggunakan 180 termograf dengan set data input 5 dimensi  $x = [x_1, \dots, x_5]^T$  yang diperoleh dari metode penilaian korelasi dan output yang diinginkan  $d \in [0,1]$  dari kondisi suhu, di mana  $d = 0$  untuk Normal ( $T \leq 37.7^\circ\text{C}$ ) dan  $d = 1$  untuk Demam ( $T > 37.7^\circ\text{C}$ ) [8, 9]. Pengaturan jaringan GenSoFNN-AARS(S) ditentukan pada Tabel A-1 pada Lampiran A. Struktur jaringan setelah pelatihan diamati memiliki 96 aturan fuzzy dengan 32 fungsi keanggotaan trapesium (lapisan 2 node) untuk semua 5 input dan 2 fungsi keanggotaan trapesium (lapisan 4 node) untuk output. Dengan mengacu pada Gambar 12, parameter rinci dari setiap set/label fuzzy input ditunjukkan pada Tabel 3.

**Tabel 17.3.** Himpunan Fuzzy untuk Lima Input yang Dihitung oleh Jaringan GenSoFNN-AARS(S) (menggunakan 180 data pelatihan input 'nilai maks.' yang dipilih oleh metode penilaian korelasi; ICREA: wilayah sudut dalam di sekitar area mata)

<i>i</i> th input	<i>j</i> th fuzzy term	$l_{i,j}$	$u_{i,j}$	$v_{i,j}$	$r_{i,j}$	label semantik
Input 1: Maximum forehead area [0,255]	Label 1=	126.83 7	130.56 5	136.074	139.802	Rendah
	Label 5=	137.27 2	141	142.237	145.966	Marginal Rendah
	Label 2=	142.59 9	146.32 8	148	151.728	Sedang
	Label 3=	149.55 4	153.28 2	154	157.728	Marginal Tinggi
	Label 4=	153.18 7	156.91 5	161.627	165.356	Tinggi
	Label 6=	161.58 9	165.30	169	172.728	Tinggi Luar Biasa
Input 2:	Label 5=	107.58 3	112	121	125.417	Rendah

Maximum lips area [0,255]	Label 4= 3	125.58	130	132.152	136.569	Marginal Rendah
	Label 2= 3	134.58	139	139.717	144.134	Sedang
	Label 1= 3	138.58	143	144.785	149.202	Marginal Tinggi
	Label 3= 8	145.81	150.23	157.785	162.202	Tinggi
	Label 6= 2	160.89	165.30	174	178.417	Tinggi Luar Biasa
Input 3:	Label 6= 7	107.31	113	113.717	119.401	Rendah
Maximum ears area [0,255]	Label 1= 7	116.31	122	124.672	130.356	Marginal Rendah
	Label 3= 9	125.72	131.41	142	147.683	Sedang
	Label 4= 2	153.23	158.91	160.074	165.757	Marginal Tinggi
	Label 2= 7	140.31	146	155.382	161.066	Tinggi
	Label 5= 9	162.90	168.59	170	175.683	Tinggi Luar Biasa
Input 4:	Label 6= 1	121.00	125	133.542	137.542	Rendah
Maximum neck area [0,255]	Label 4= 8	131.45	135.45	139.691	143.69	Marginal Rendah
	Label 2= 1	138.48	142.48	147.785	151.784	Sedang
	Label 1= 6	147.23	151.23	153.085	157.084	Marginal Tinggi
	Label 3= 6	151.56	155.56	160	163.999	Tinggi
	Label 5= 1	161.00	165	166.435	170.434	Tinggi Luar Biasa
Input 5:	Label 6= 3	120.90	125	133.435	137.532	Rendah Luar Biasa
Maximum ICREA [0,255]	Label 8= 3	131.90	136	136.717	140.814	Rendah
	Label 1= 3	134.90	139	139.802	143.899	Marginal Rendah
	Label 2= 3	138.40	142.5	143.435	147.532	Sedang

Label 4=	144.52	148.61	149.542	153.639	Marginal Tinggi
	1	7			
Label 3=	147.36	151.45	152.382	156.479	Tinggi
		7			
Label 5=	150.90	155	159.87	163.967	Tinggi Luar Biasa
		3			
Label 7=	160.44	164.54	169	173.097	Sangat tinggi
	7	4			

Label semantik seperti Rendah, Sedang, dan Tinggi dilampirkan ke himpunan fuzzy masing-masing untuk mengekstrak aturan fuzzy yang diformulasikan dari struktur terlatih jaringan GenSoFNN-AARS(S). Dua puluh (dari 96) aturan yang paling banyak digunakan untuk membedakan kondisi normal dan demam terdaftar dan diurutkan dalam urutan menurun dari kekuatan tembak pada Tabel 4. Aturan fuzzy diekstraksi hanya dengan menelusuri hubungan dan koneksi antara node lapisan 2 (input istilah fuzzy), layer 3 node (rule node), dan layer 4 node (output istilah fuzzy).

**Tabel 17.4** Aturan Fuzzy yang Diekstraksi dari Jaringan GenSoFNN-AARS(S) (dilatih menggunakan 180 input data pelatihan 'nilai maks.' yang dipilih dengan metode penilaian korelasi; F = nilai intensitas piksel maksimum area dahi, L = intensitas piksel maksimum nilai area bibir, E = nilai intensitas piksel maksimum area telinga, N = nilai intensitas piksel maksimum area leher, dan I = intensitas piksel maksimum area sudut dalam di sekitar area mata)

- 
- Rule 1: IF L is *Marginal High* THEN subject is *not Fever*
  - Rule 2: IF L is *Marginal High* AND I is *High* THEN subject is *not Fever*
  - Rule 3: IF F is *Marginal Low* AND L is *Marginal High* THEN subject is *not Fever*
  - Rule 4: IF F is *Medium* AND L is *Medium* AND E is *Medium* AND N is *Medium* AND I is *Marginal High* THEN subject is *not Fever*
  - Rule 5: IF I is *High* THEN subject is *not Fever*
  - Rule 6: IF F is *Medium* AND L is *High* AND E is *Medium* AND N is *Medium* AND I is *Marginal High* THEN subject is *not Fever*
  - Rule 7: IF F is *Marginal High* AND L is *Marginal High* THEN subject is *not Fever*
  - Rule 8: IF L is *Marginal High* AND I is *Medium* THEN subject is *not Fever*
  - Rule 9: IF L is *Marginal High* AND E is *Marginal Low* THEN subject is *not Fever*
  - Rule 10: IF N is *Marginal High* THEN subject is *not Fever*
  - Rule 11: IF F is *Medium* AND L is *Medium* AND E is *High* AND N is *Medium* AND I is *Marginal High* THEN subject is *not Fever*
  - Rule 12: IF F is *Marginal Low* AND I is *High* THEN subject is *not Fever*
  - Rule 13: IF F is *Marginal High* AND L is *Marginal High* AND I is *High* THEN subject is *not Fever*
  - Rule 14: IF F is *Medium* AND L is *High* AND E is *High* AND N is *Medium* AND I is *Marginal High* THEN subject is *not Fever*
  - Rule 15: IF L is *Marginal High* AND N is *Marginal Low* AND I is *High* THEN subject is *not Fever*
  - Rule 16: IF I is *Medium* THEN subject is *not Fever*
  - Rule 17: IF F is *Marginal Low* THEN subject is *not Fever*
  - Rule 18: IF L is *Marginal High* AND E is *Marginal Low* AND I is *High* THEN subject is *not Fever*
  - Rule 19: IF F is *Marginal Low* AND N is *Marginal Low* THEN subject is *not Fever*
  - Rule 20: IF E is *Marginal Low* THEN subject is *not Fever*
- 

Karena 180 data pelatihan tidak seimbang dengan hanya 16 (8,89%) subjek demam dan sisanya (91,1%) berada dalam kondisi suhu normal, sebagian besar aturan fuzzy yang

dibangun dalam jaringan GenSoFNN-AARS(S) adalah aturan negatif, yaitu. aturan yang konsekuennya 'bukan' Demam (Kondisi Normal). Dapat dilihat dari Tabel 4 bahwa dua puluh aturan fuzzy terbaik semuanya negatif, di mana kekuatan tembaknya (frekuensi) jauh lebih besar daripada aturan positif (yaitu di mana kasus Demam ditemukan). Aturan fuzzy yang diekstraksi dalam Tabel diamati cukup dekat dengan pendekatan kognitif manusia untuk menyaring pasien SARS potensial (keputusan subjek normal atau demam). Ambil contoh Aturan 4, yaitu ketika suhu maksimum daerah dahi, bibir, telinga, leher, dan sudut dalam di sekitar area mata (ICREA) normal (Sedang) atau hanya sedikit tinggi (Marginal Tinggi), dapat disimpulkan bahwa subjek masih dalam kondisi Normal (tidak Demam). Selain itu, aturan fuzzy yang diekstraksi juga terbukti telah mempertimbangkan beberapa faktor variasi fisiologis untuk mengkonfirmasi validitas keputusan sistem. Ambil contoh Aturan 14 dari Tabel 4, di mana suhu tinggi pada bibir dan telinga dan suhu ICREA yang sedikit tinggi (Marginal High) tidak akan mengakibatkan subjek Demam terdeteksi. Hal ini mirip dengan situasi praktis untuk kasus luar biasa di mana subjek yang sebelumnya menderita ulkus bibir (suhu tinggi) dan telinga bersuhu tinggi (suhu tinggi) diskriptif pada sistem deteksi SARS.

## 17.7 KESIMPULAN

Sistem neural-fuzzy (FNN) diusulkan dalam bab ini sebagai pendekatan kognitif untuk mempelajari korelasi citra termal superfisial terhadap suhu tubuh internal yang sebenarnya, berdasarkan termografi. Hal ini memungkinkan pendekatan baru untuk pembangunan sistem pendukung keputusan cerdas yang memiliki kemampuan interpretasi kognitif penalaran manusia dan pembelajaran pengetahuan langsung dari data yang mewakili domain masalah. Dengan menjalani beberapa preprocessing citra citra termal dan pemilihan input melalui metode penilaian korelasi, kemudian dilakukan eksperimen pada MLP dan beberapa FNN. Hasil kinerjanya menggembirakan dengan tingkat akurasi yang tinggi. Kinerja jaringan semantik global dan lokal sebanding, meskipun proses pembelajaran jaringan lokal lebih cepat dan menghasilkan struktur yang lebih sederhana dibandingkan dengan jaringan global. ANFIS, sebagai perwakilan dari model TSK, terbukti memberikan hasil yang lebih baik dalam mengingat data yang telah dipelajari ke FNN lain. Namun, overfitting data pelatihan akan menyebabkan trade-off yang menurunkan kinerja dalam tes generalisasi. Model Mamdani, yang berfokus pada kemampuan interpretasi dan oleh karena itu mirip dengan pendekatan kognitif manusia, memiliki kinerja yang lebih baik daripada ANFIS dalam tes generalisasi.

Meskipun telah ditunjukkan bahwa jaringan MLP memiliki kinerja keseluruhan yang unggul, jaringan ini hanya berfungsi sebagai kotak hitam dan oleh karena itu tidak mungkin untuk mengekstrak aturan fuzzy IF-THEN linguistik. Jaringan GenSoFNN-AARS(S) yang kinerja keseluruhannya tepat di bawah jaringan MLP digunakan untuk mengekstrak aturan fuzzy dalam mengkorelasikan termograf dengan kondisi suhu. Hal ini menunjukkan bahwa aturan fuzzy yang diekstraksi cukup dekat dengan pendekatan kognitif manusia dalam mengambil keputusan dalam membedakan kondisi normal dan demam dari pasien SARS potensial. Studi kasus dengan data terkait medis kehidupan nyata ini telah berhasil menunjukkan kemampuan jaringan saraf fuzzy lokal dan global berdasarkan Model Fuzzy Mamdani untuk memberikan aturan yang dapat ditafsirkan secara kognitif untuk menggambarkan proses pendukung keputusan langsung dari data pelatihan.

## Lampiran A

**Tabel A-1.** Pengaturan Standar dari Berbagai Arsitektur FNN (parameter dipilih secara empiris untuk mencapai hasil kinerja terbaik)

	POPFNN-CRI(S)	GenSoFNN-AARS(S)	DoFCMAC-AARS	FoFCMAC-AARS
<b>Parameter</b>				
<b>Pelatihan</b>	-	0.005 [15]	0.3	-
Learning constant				
AARS threshold	-	-	0.8	-
Maximum epochs	-	50	3500	-
<b>DIC [14]</b>				
<b>Configurations</b>	0.3	0.5	0.5	0.5
Input slope				
Output slope	0.3	0.2	-	0.3
Plasticity parameter	0.7	0.7	0.7	0.7
Tendency parameter	0.5	0.5	0.5	0.5
Input threshold	0.5	0.5	0.5	0.8
Output threshold	0.5	0.8	-	0.8

## BAB 18

### SISTEM JARINGAN SARAF INFERENSI FUZZY ADAPTIF UNTUK KLASIFIKASI SINYAL EEG

Karena elektroensefalogram (EEG) adalah salah satu sumber informasi terpenting dalam terapi epilepsi, beberapa peneliti mencoba membahas masalah pendukung keputusan untuk data semacam itu. Studi penelitian ini menjelaskan penerapan sistem logika fuzzy baru yang diimplementasikan dalam kerangka jaringan saraf untuk klasifikasi sinyal EEG. Pengambilan keputusan dilakukan dalam dua tahap: awalnya, skema ekstraksi fitur menggunakan transformasi wavelet (WT) telah diterapkan dan kemudian pengklasifikasi algoritma berbasis pembelajaran melakukan klasifikasi. Jaringan yang diusulkan membangun aturan awalnya dengan pengelompokan sedangkan dasar aturan fuzzy akhir ditentukan oleh pembelajaran kompetitif. Baik backpropagation error dan estimasi kuadrat terkecil rekursif, diterapkan pada skema pembelajaran. Kinerja model dievaluasi dalam hal kinerja pelatihan dan akurasi klasifikasi dan hasilnya menegaskan bahwa skema yang diusulkan memiliki potensi dalam mengklasifikasikan sinyal EEG.

#### **18.1 PENDAHULUAN**

Otak manusia jelas merupakan sistem yang kompleks, dan menunjukkan dinamika spatiotemporal yang kaya. Di antara teknik non-invasif untuk menyelidiki dinamika otak manusia, elektroensefalografi memberikan pengukuran langsung aktivitas kortikal dengan resolusi temporal milidetik. Awalnya, analisis EEG terbatas pada inspeksi visual catatan EEG. Karena tidak ada kriteria pasti yang dievaluasi oleh para ahli, analisis visual sinyal EEG tidak cukup. Misalnya, dalam kasus delta aktivitas alfa dominan dan aktivitas theta tidak diperhatikan. Diagnosis klinis rutin perlu analisis sinyal EEG. Oleh karena itu, beberapa teknik otomatisasi dan komputer telah digunakan untuk tujuan ini [1]. Sejak hari-hari awal pemrosesan EEG otomatis, representasi berdasarkan transformasi Fourier telah paling umum diterapkan. Pendekatan ini didasarkan pada pengamatan sebelumnya bahwa spektrum EEG mengandung beberapa bentuk gelombang karakteristik yang terutama berada dalam empat pita frekuensi-delta (1-4 Hz), theta (4-8 Hz), alfa (8-13 Hz), dan beta ( 13–30Hz). Metode tersebut telah terbukti bermanfaat untuk berbagai karakterisasi EEG, tetapi transformasi Fourier cepat (FFT), menderita sensitivitas kebisingan yang besar.

Metode estimasi spektrum daya parametrik seperti AR, mengurangi masalah kerugian spektral dan memberikan resolusi frekuensi yang lebih baik. Selain itu, metode AR memiliki keunggulan dibandingkan FFT yaitu membutuhkan data record dengan durasi yang lebih pendek dibandingkan dengan FFT [2]. Sebuah metode yang kuat diusulkan pada akhir 1980-an untuk melakukan analisis skala waktu sinyal: transformasi wavelet (WT). Metode ini menyediakan kerangka kerja terpadu untuk berbagai teknik yang telah dikembangkan untuk berbagai aplikasi. Sejak WT sesuai untuk analisis sinyal non-stasioner dan ini merupakan keuntungan utama atas analisis spektral, sangat cocok untuk menemukan peristiwa transien, yang mungkin terjadi selama serangan epilepsi. Ekstraksi fitur dan properti representasi

Wavelet dapat digunakan untuk menganalisis berbagai peristiwa transien dalam sinyal biologis. Adeli dkk. [3] memberikan gambaran tentang transformasi wavelet diskrit (DWT) yang dikembangkan untuk mengenali dan mengukur lonjakan, gelombang tajam, dan gelombang lonjakan. Mereka menggunakan transformasi wavelet untuk menganalisis dan mengkarakterisasi pelepasan epileptiform dalam bentuk kompleks gelombang dan lonjakan 3-Hz pada pasien tanpa kejang. Melalui dekomposisi wavelet dari catatan EEG, fitur transien secara akurat ditangkap dan dilokalisasi dalam konteks waktu dan frekuensi. Kemampuan mikroskop matematis ini untuk menganalisis berbagai skala ritme saraf terbukti menjadi alat yang ampuh untuk menyelidiki osilasi skala kecil dari sinyal otak. Pemahaman yang lebih baik tentang dinamika otak manusia melalui analisis EEG dapat diperoleh melalui analisis lebih lanjut dari catatan EEG tersebut.

Banyak teknik lain dari teori analisis sinyal telah digunakan untuk mendapatkan representasi dan mengekstrak fitur yang menarik untuk tujuan klasifikasi. Jaringan saraf dan metode pengenalan pola statistik telah diterapkan pada analisis EEG. Neural network (NN) sistem deteksi telah diusulkan oleh sejumlah peneliti. Pradan dkk. [4] menggunakan EEG mentah sebagai input ke jaringan saraf sementara Weng dan Khorasani [5] menggunakan fitur yang diusulkan oleh Gotman dengan jaringan saraf struktur adaptif, tetapi hasilnya menunjukkan tingkat deteksi palsu yang buruk. Petrosian dkk. [6] menunjukkan bahwa kemampuan jaringan saraf rekuren (RNN) yang dirancang dan dilatih secara khusus dikombinasikan dengan pra-pemrosesan wavelet, untuk memprediksi timbulnya serangan epilepsi baik pada kulit kepala maupun rekaman intrakranial hanya pada satu saluran elektroensefalogram. Untuk menyediakan algoritma yang lebih cepat dan efisien, Folkers et al. [7] mengusulkan pemrosesan sinyal serbaguna dan kerangka analisis untuk data bioelektrik dan khususnya untuk rekaman saraf dan 128-channel EEG. Dalam kerangka ini sinyal didekomposisi menjadi sub-band menggunakan algoritma transformasi wavelet cepat, dieksekusi secara real-time pada platform perangkat keras prosesor sinyal digital saat ini.

Teori himpunan fuzzy memainkan peran penting dalam menghadapi ketidakpastian ketika membuat keputusan dalam aplikasi medis. Oleh karena itu, himpunan fuzzy telah menarik perhatian dan minat yang semakin besar dalam teknologi informasi modern, teknik produksi, pengambilan keputusan, pengenalan pola, diagnostik, dan analisis data [8]. Sistem neuro-fuzzy adalah sistem fuzzy, yang menggunakan teori NN untuk menentukan propertiannya (set fuzzy dan aturan fuzzy) dengan memproses sampel data.

Sistem neuro-fuzzy memanfaatkan kekuatan dua paradigma: logika fuzzy dan NN, dengan memanfaatkan sifat matematika NN dalam menyetel sistem fuzzy berbasis aturan yang mendekati cara manusia memproses informasi. Pendekatan khusus dalam pengembangan neuro-fuzzy adalah sistem inferensi neuro-fuzzy adaptif (ANFIS), yang telah menunjukkan hasil yang signifikan dalam pemodelan fungsi non-linear. Dalam ANFIS, parameter fungsi keanggotaan diekstraksi dari kumpulan data yang menggambarkan perilaku sistem. ANFIS mempelajari fitur dalam kumpulan data dan menyesuaikan parameter sistem sesuai dengan kriteria kesalahan yang diberikan. Implementasi ANFIS yang berhasil dalam analisis EEG telah dilaporkan [9].

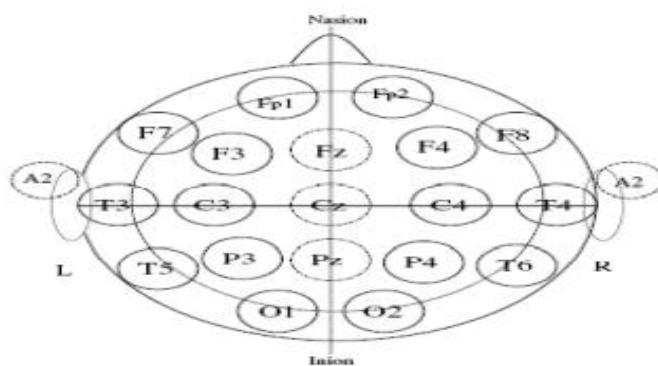
Dibandingkan dengan metode konvensional analisis frekuensi yang menggunakan transformasi Fourier atau transformasi Fourier waktu singkat, wavelet memungkinkan analisis

dengan perspektif sinyal multi-resolusi kasar hingga halus. Dalam karya ini, DWT telah diterapkan untuk analisis waktu-frekuensi sinyal EEG dan skema neuro-fuzzy baru untuk klasifikasi menggunakan koefisien wavelet. Kami akan mempertimbangkan sistem Adaptive Fuzzy Inference Neural Network (AFINN) yang terdiri dari fungsi keanggotaan Gaussian yang terkait dengan sistem linier lokal. Sistem logika fuzzy yang diusulkan didasarkan pada tipe Sugeno yang dimodifikasi dengan pengenalan lapisan tambahan dari partisi keluaran. Berbeda dengan sistem ANFIS, di mana jumlah sistem linier lokal sama dengan jumlah aturan, AFINN menyediakan sarana untuk mengendalikan pertumbuhan jumlah sistem linier lokal ketika orde sistem yang dipertimbangkan meningkat, sehingga estimasi kuadrat terkecil dapat diterapkan tanpa penurunan kinerja. Sebuah algoritma pengelompokan diterapkan untuk data sampel untuk mengatur vektor fitur ke dalam cluster sedemikian rupa sehingga titik-titik dalam sebuah cluster lebih dekat satu sama lain daripada vektor milik cluster yang berbeda. Kemudian basis aturan fuzzy dibuat menggunakan hasil yang diperoleh dari algoritma ini. Tidak seperti metode Sugeno [10], implikasi fuzzy dari sistem fuzzy didasarkan pada partisi fuzzy dari ruang input secara langsung daripada partisi fuzzy dari setiap dimensi ruang input. Dengan demikian fungsi keanggotaan yang dipertimbangkan dalam sistem yang diusulkan adalah fungsi keanggotaan multidimensi. Dalam hal ini, ada kesamaan dengan pembangunan pusat Gaussian di jaringan Radial Basis Function (RBF).

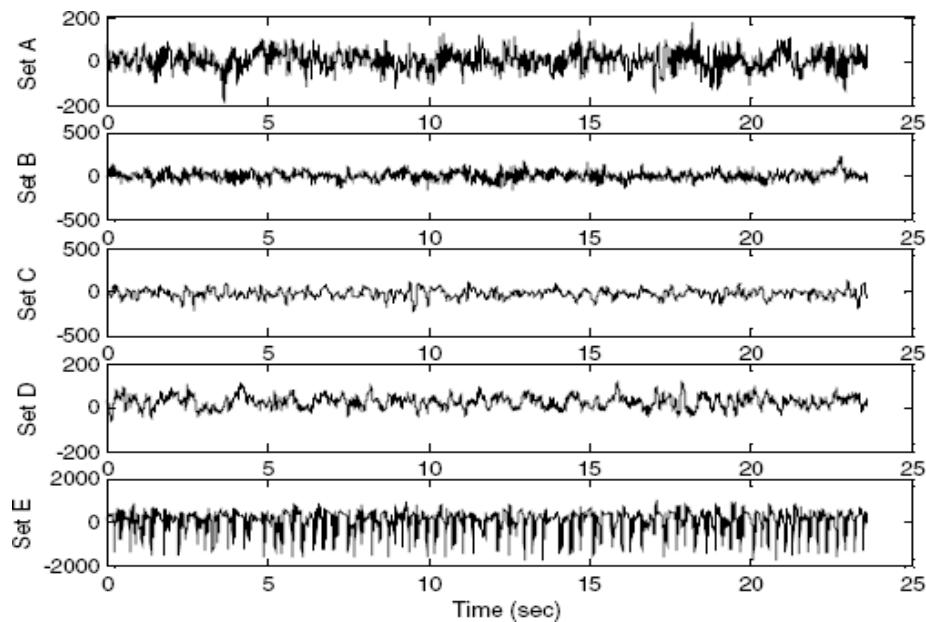
Karena ruang masukan dianggap dipartisi daripada setiap dimensi ruang masukan, jumlah aturan bisa kecil dan oleh karena itu jumlah sistem linier lokal juga kecil. Selain itu, teknik pembelajaran kompetitif diterapkan untuk menemukan partisi ruang sesuai dengan pengelompokan aturan fuzzy di awal pelatihan. Metodologi yang diusulkan diimplementasikan dan kinerjanya dalam mengklasifikasikan sinyal EEG dievaluasi terhadap Multilayer Perceptron (MLP).

## 18.2 PEMILIHAN DAN PEREKAMAN DATA

Kami telah menggunakan data yang tersedia untuk umum yang dijelaskan dalam Andrzejak et al. [11]. Kumpulan data lengkap terdiri dari lima set (dilambangkan A–E) masing-masing berisi 100 segmen EEG saluran tunggal. Segmen ini dipilih dan dipotong dari rekaman EEG multi-saluran terus menerus setelah inspeksi visual untuk artefak, misalnya, karena aktivitas otot atau gerakan mata. Set A dan B terdiri dari segmen yang diambil dari rekaman EEG permukaan yang dilakukan pada lima sukarelawan sehat menggunakan skema penempatan elektroda standar (Gbr. 1).



**Gambar 18.1** Gambar 10-20 sistem internasional penempatan elektroda c dari kasus normal dan abnormal



**Gambar 18.2** Contoh lima set sinyal EEG yang berbeda yang diambil dari subjek yang berbeda

Relawansantai dalam keadaan terjaga dengan mata terbuka (A) dan mata tertutup (B), masing-masing. Set C, D, dan E berasal dari arsip EEG diagnosis pra-bedah. EEG dari lima pasien dipilih, semuanya telah mencapai kontrol kejang lengkap setelah reseksi salah satu formasi hipokampus, yang oleh karena itu didiagnosis dengan benar sebagai zona epileptogenik. Segmen di set D direkam dari dalam zona epileptogenik, dan segmen di set C dari formasi hipokampus dari belahan otak yang berlawanan. Sementara set C dan D hanya berisi aktivitas yang diukur selama interval bebas kejang, set E hanya berisi aktivitas kejang. Di sini segmen dipilih dari semua lokasi perekaman yang menunjukkan aktivitas iktal. Semua sinyal EEG direkam dengan sistem penguat 128 saluran yang sama, menggunakan referensi umum rata-rata.

Data didigitalkan pada 173,61 sampel per detik menggunakan resolusi 12 bit. Pengaturan band-pass filter adalah 0,53–40 Hz (12dB/okt). EEG khas digambarkan pada Gambar 2.

### 18.3 ANALISIS SPEKTRAL MENGGUNAKAN TRANSFORMASI WAVELET DISKRIT

Memprediksi timbulnya serangan epilepsi adalah masalah biomedis yang penting dan sulit, yang telah menarik perhatian besar komunitas komputasi cerdas selama dua dekade terakhir [12]. Metodologi neuro-fuzzy yang diusulkan menggunakan dekomposisi wavelet sinyal diterapkan pada masalah. Transformasi Wavelet (WT) menyediakan teknik yang sangat umum, yang dapat diterapkan pada banyak tugas dalam pemrosesan sinyal. Salah satu aplikasi yang sangat penting adalah kemampuan untuk menghitung dan memanipulasi data dalam parameter terkompresi, yang sering disebut fitur. Dengan demikian, sinyal EEG, yang terdiri dari banyak titik data, dapat dikompresi menjadi beberapa parameter. Parameter ini mencirikan perilaku sinyal EEG. Fitur menggunakan lebih sedikit parameter untuk mewakili sinyal EEG ini sangat penting untuk tujuan pengenalan dan diagnostik.

Transformasi wavelet adalah teknik estimasi spektral di mana setiap fungsi umum dapat dinyatakan sebagai rangkaian wavelet yang tak terbatas. Ide dasar yang mendasari analisis wavelet terdiri dari mengekspresikan sinyal sebagai kombinasi linier dari serangkaian fungsi tertentu, yang diperoleh dengan menggeser dan melebarkan satu fungsi tunggal yang disebut mother wavelet. Dekomposisi sinyal mengarah ke satu set koefisien yang disebut koefisien wavelet. Oleh karena itu sinyal dapat direkonstruksi sebagai kombinasi linier dari fungsi wavelet yang diberi bobot oleh koefisien wavelet. Untuk mendapatkan rekonstruksi sinyal yang tepat, jumlah koefisien yang memadai harus dihitung. Fitur utama dari wavelet adalah lokalisasi waktu-frekuensi. Ini berarti bahwa sebagian besar energi wavelet terbatas pada interval waktu yang terbatas. Lokalisasi frekuensi berarti bahwa transformasi Fourier terbatas pada pita. Jika dibandingkan dengan STFT, keuntungan dari lokalisasi waktu-frekuensi adalah bahwa analisis wavelet memvariasikan aspek rasio waktu-frekuensi, menghasilkan lokalisasi frekuensi yang baik pada frekuensi rendah (long time windows), dan lokalisasi waktu yang baik pada frekuensi tinggi (short time windows). Ini menghasilkan segmentasi, atau penataan bidang frekuensi waktu yang sesuai untuk sebagian besar sinyal fisik, terutama yang bersifat sementara. Teknik wavelet yang diterapkan pada sinyal EEG akan mengungkapkan fitur yang terkait dengan sifat transien dari sinyal yang tidak terlihat jelas oleh transformasi Fourier. Secara umum, harus dikatakan bahwa tidak ada wilayah frekuensi waktu melainkan wilayah skala waktu yang ditentukan [13]. Semua transformasi wavelet dapat ditentukan dalam hal filter lolos rendah  $g$ , yang memenuhi kondisi filter cermin kuadratur standar

$$G(z)G(z^{-1}) + G(-z)G(-z^{-1}) = 1 \quad (1)$$

di mana  $G(z)$  menunjukkan transformasi-z dari filter  $g$ . Filter high-pass pelengkapnya dapat didefinisikan sebagai

$$H(z) = zG(-z^{-1}) \quad (2)$$

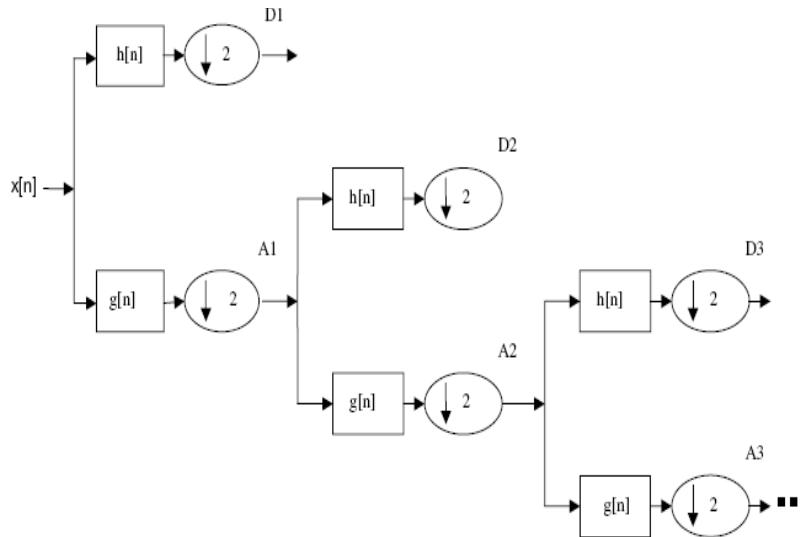
Urutan filter dengan panjang yang bertambah (diindeks oleh  $i$ ) dapat diperoleh

$$\begin{aligned} G_{i+1}(z) &= G(z^{2^i})G_i(z), & \text{for } i = 0, 1, \dots, I-1 \\ H_{i+1}(z) &= H(z^{2^i})G_i(z) \end{aligned} \quad (3)$$

dengan kondisi awal  $G_0(z) = 1$ . Dinyatakan sebagai relasi dua skala dalam domain waktu

$$\begin{aligned} g_{i+1}(k) &= [g]_{\uparrow 2^i} g_i(k), \\ h_{i+1}(k) &= [h]_{\uparrow 2^i} g_i(k) \end{aligned} \quad (4)$$

di mana subscript  $[.]^m$  menunjukkan up-sampling dengan faktor m, dan k adalah waktu diskrit yang sama sampelnya.



**Gambar 18.3** Dekomposisi sub-band dari implementasi DWT

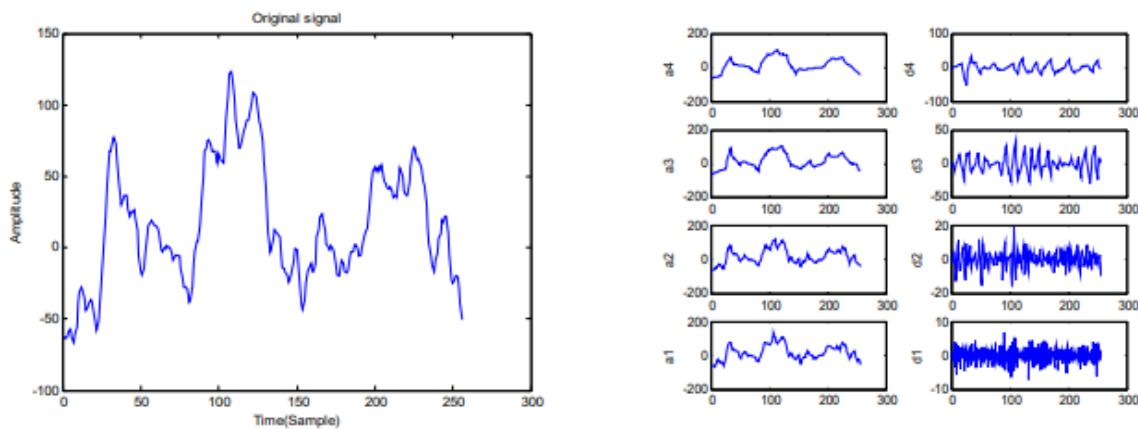
Satu area di mana DWT sangat berhasil adalah epilepsy deteksi kejang karena menangkap fitur sementara dan melokalisasinya dalam konten waktu dan frekuensi secara akurat. DWT menganalisis sinyal pada pita frekuensi yang berbeda, dengan resolusi yang berbeda dengan menguraikan sinyal menjadi perkiraan kasar dan informasi detail. DWT menggunakan dua set fungsi yang disebut fungsi penskalaan dan fungsi wavelet, yang masing-masing terkait dengan filter lolos rendah dan tinggi. Dekomposisi sinyal ke dalam pita frekuensi yang berbeda hanya diperoleh dengan penyaringan high-pass dan low-pass berturut-turut dari sinyal domain waktu.

Prosedur dekomposisi multi-resolusi sinyal  $x[n]$  secara skematis ditunjukkan pada Gambar. 3. Setiap tahap skema ini terdiri dari dua filter digital dan dua down-sampler dengan 2. Filter pertama  $h[.]$  adalah diskrit mother wavelet, high-pass di alam, dan yang kedua,  $g[.]$  adalah versi cerminnya, low-pass di alam. Output down-sampled dari filter high-pass dan low-pass pertama memberikan detail,  $D_1$  dan aproksimasi,  $A_1$ , masing-masing. Pendekatan pertama,  $A_1$  didekomposisi lebih lanjut dan proses ini dilanjutkan seperti yang ditunjukkan pada Gambar.3.

Pemilihan wavelet yang sesuai dan jumlah tingkat dekomposisi sangat penting dalam analisis sinyal menggunakan DWT. Jumlah tingkat dekomposisi dipilih berdasarkan komponen frekuensi dominan dari sinyal. Tingkat dipilih sedemikian rupa sehingga bagian-bagian dari sinyal yang berkorelasi baik dengan frekuensi yang diperlukan untuk klasifikasi sinyal dipertahankan dalam koefisien wavelet. Dalam penelitian ini, karena sinyal EEG tidak memiliki komponen frekuensi yang berguna di atas 30 Hz, jumlah tingkat dekomposisi dipilih menjadi 4. Dengan demikian, sinyal EEG didekomposisi menjadi detail  $D_1$ – $D_4$  dan satu perkiraan akhir,  $A_4$ .

Biasanya, pengujian dilakukan dengan berbagai jenis wavelet dan salah satu yang memberikan efisiensi maksimum dipilih untuk aplikasi tertentu. Fitur smoothing dari wavelet Daubechies orde 2 (db2) membuatnya lebih tepat untuk mendeteksi perubahan sinyal EEG.

Oleh karena itu, koefisien wavelet dihitung menggunakan db4 dalam penelitian ini. Metode yang diusulkan diterapkan pada semua dataset data EEG (Set A, B, C, D dan E). Gambar. 4 menunjukkan perkiraan (A4) dan rincian (D1-D4) dari sinyal EEG epilepsi.



**Gambar 18.4** Koefisien perkiraan dan detail sinyal EEG yang diambil dari subjek tidak sehat (pasien epilepsi)

### Ekstraksi Fitur

Koefisien wavelet yang diekstraksi memberikan representasi kompak yang menunjukkan distribusi energi sinyal EEG dalam waktu dan frekuensi.

**Tabel 18.1** Frekuensi yang sesuai dengan tingkat dekomposisi yang berbeda

Sinyal Terurai	Rentang frekuensi (Hz)
D1	43.4-86.8
D2	21.7 43.4
D3	10.8-21.7
D4	5.4-10.8
A4	2.7-5.4

Tabel 1 menyajikan frekuensi yang sesuai dengan tingkat dekomposisi yang berbeda untuk wavelet orde-2 Daubechies dengan frekuensi sampling 173,6 Hz. Untuk lebih mengurangi dimensi dari vektor fitur yang diekstraksi, statistik di atas himpunan koefisien wavelet digunakan [14].

Pemilihan input pengklasifikasi adalah komponen terpenting dalam merancang jaringan AFINN yang diusulkan berdasarkan klasifikasi pola karena pengklasifikasi terbaik pun akan berkinerja buruk jika input tidak dipilih dengan baik. Pemilihan input memiliki dua arti: (1) komponen mana dari suatu pola, atau (2) set input mana yang paling mewakili suatu pola tertentu. Koefisien wavelet diskrit yang dihitung memberikan representasi kompak yang menunjukkan distribusi energi sinyal dalam waktu dan frekuensi. Oleh karena itu, detail yang dihitung dan koefisien wavelet aproksimasi dari sinyal EEG digunakan sebagai vektor fitur yang mewakili sinyal. Sebuah jendela persegi panjang, yang dibentuk oleh 256 data diskrit, dipilih sehingga berisi segmen EEG tunggal. Untuk setiap segmen EEG, koefisien wavelet detail ( $d^k$ ,  $k = 1, 2, 3, 4$ ) pada level pertama, kedua, ketiga dan keempat (koefisien  $129 + 66 + 34 + 18$ )

dan koefisien aproksimasi wavelet (A4) pada tingkat keempat (18 koefisien) dihitung. Kemudian diperoleh 265 koefisien wavelet untuk setiap segmen EEG. Untuk mengurangi dimensi dari vektor fitur yang diekstraksi, statistik di atas himpunan koefisien wavelet digunakan. Fitur statistik berikut digunakan untuk mewakili distribusi waktu-frekuensi dari sinyal EEG:

- Maksimum koefisien wavelet di setiap sub-band.
- Koefisien wavelet minimum di setiap sub-band.
- Rata-rata koefisien wavelet di setiap sub-band
- Standar deviasi dari koefisien wavelet di setiap sub-band

Fitur yang diekstraksi untuk lima rekaman kelas A dan E yang ditunjukkan pada Tabel 2. Untuk masing-masing sub-pita ini, kami mengekstrak empat ukuran dispersi, menghasilkan total 20 atribut per jendela sampel. Dalam penelitian ini, metode PCA digunakan, untuk mengubah representasi atribut dimensi tinggi asli menjadi representasi dimensi rendah. Transformasi diturunkan dari vektor Eigen yang sesuai dengan nilai Eigen terbesar dari matriks kovarians untuk data kelas A, B, C, D dan E.

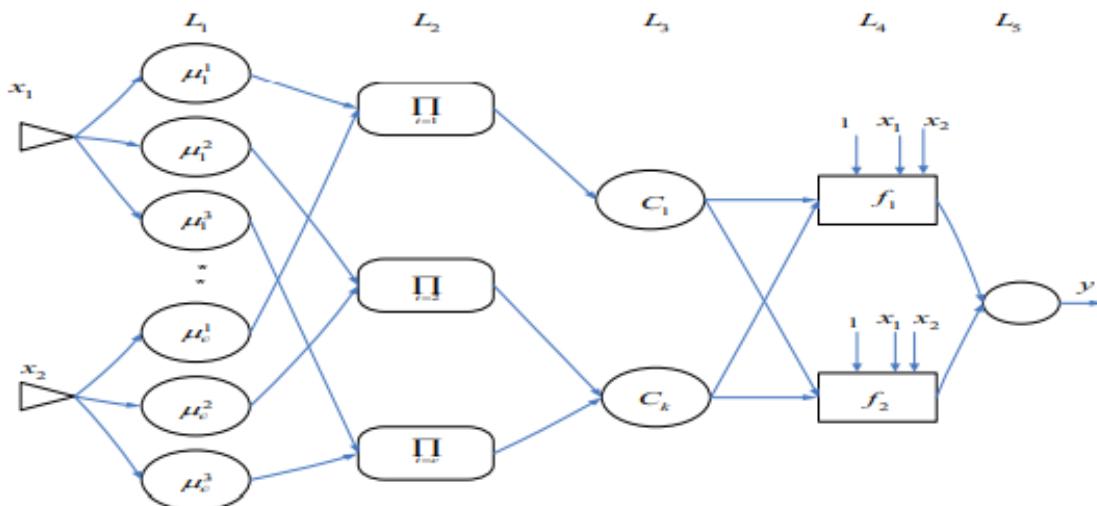
#### 18.4 ARSITEKTUR AFINN

Ada banyak kombinasi yang berbeda dari sistem logika fuzzy dan jaringan saraf. Dalam makalah ini kami mengusulkan model koneksi sistem fuzzy dalam bentuk jaringan multi-layer feed-forward, yang dapat dilatih menggunakan algoritma iteratif. Sistem neuro-fuzzy semacam ini menggunakan struktur seperti perceptron dan prosedur pembelajaran terawasi hibrida dari jaringan saraf untuk sistem inferensi fuzzy dengan basis aturan dan penalaran fuzzy. Masalah terpenting dalam sistem fuzzy adalah menemukan aturan fuzzy. Beberapa metode dapat menghasilkan aturan fuzzy dari pasangan input-output [15]. Dalam studi penelitian ini, basis aturan fuzzy diturunkan menggunakan hasil yang diperoleh dari algoritma clustering.

**Tabel 18.2** Fitur dua jendela yang diekstraksi dari kelas A, B, C, D & E

Dataset	Extracted features	Sub-bands				
		D1	D2	D3	D4	A4
Set A	Maximum	28.1094	101.757	131.0846	124.377	114.138
	Minimum	-28.401	-60.813	-149.072	-158.797	-109.521
	Mean	-0.0022	0.0058	-0.0035	0.0388	3.7950
	Std. dev.	5.1818	13.6442	23.3685	24.7933	35.1465
Set B	Maximum	14.1446	46.9284	102.2603	242.5219	302.9787
	Minimum	-14.757	-51.4840	-139.1860	-157.733	-208.899
	Mean	0.4727	0.0892	-7.3273	-2.7413	24.0453
	Std dev.	6.0482	17.9383	60.0547	88.4955	146.4562
Set C	Maximum	6.4079	17.1955	49.5235	142.3749	231.6009
	Minimum	-7.373	-21.1106	-42.6390	-182.481	-269.463
	Mean	0.0668	-0.1359	2.2645	-12.3407	-39.0668
	Std. dev.	2.8001	9.5142	25.9131	95.0770	153.3921
Set D	Maximum	26.0292	117.9646	32.3480	88.2469	320.4451
	Minimum	-20.682	-82.1600	-61.5424	-89.1512	-175.767
	Mean	-0.1935	0.1121	-2.2112	-2.6360	94.1584
	Std. dev.	4.3874	19.2455	20.1756	43.6354	126.3576
Set E	Maximum	123.392	278.924	429.6621	375.0564	582.3167
	Minimum	-90.705	-238.51	-417.120	-468.064	-361.215
	Mean	0.0131	-0.0281	-0.0359	-0.0071	-5.5526
	Std. dev.	11.848	35.9941	73.7659	78.1432	180.4493

Arsitektur jaringan neuro-fuzzy yang diusulkan ditunjukkan pada Gambar 5 terdiri dari lima lapisan. Dua lapisan pertama L1 dan L2 sesuai dengan IF bagian dari aturan fuzzy sedangkan lapisan L4 dan L5 berisi informasi tentang THEN bagian dari aturan ini dan melakukan tugas defuzzifikasi. Pada lapisan L3 pemetaan antara lapisan aturan dan lapisan keluaran dilakukan oleh proses pembelajaran kompetitif.



**Gambar 18.5** Struktur sistem AFINN

Sistem linier lokal di L4 diasosiasikan dengan setiap istilah lapisan L3 daripada lapisan dasar aturan L2. Jadi ukuran matriks yang dibutuhkan untuk estimasi kuadrat terkecil dianggap jauh lebih kecil.

### Algoritma Pengelompokan

Algoritma clustering yang kami terapkan dalam makalah ini pada layer L<sub>2</sub> terdiri dari dua tahap [16]. Pada tahap pertama, metode yang mirip dengan algoritma Learning Vector Quantisation (LVQ) menghasilkan partisi-c yang tajam dari kumpulan data. Jumlah cluster c dan pusat cluster  $v_i$ ,  $i = 1, \dots, c$ , yang diperoleh dari tahap ini digunakan algoritma FCM (Fuzzy c-means) pada tahap kedua. Algoritma clustering tahap pertama menentukan jumlah cluster dengan membagi data pembelajaran ke dalam crisp clusters tersebut dan menghitung pusat cluster yang merupakan nilai awal dari fuzzy cluster center yang diturunkan dari algoritma tahap kedua.

Misalkan  $X = [x_1, \dots, x_n] \in R^{np}$  menjadi data pembelajaran. Cluster pertama dibuat 1 dimulai dengan vektor data pertama dari X dan nilai awal pusat cluster diambil sebagai nilai vektor data ini. Kemudian vektor data lain dimasukkan ke dalam cluster tetapi hanya yang memenuhi kondisi berikut:

$$\|x_k - v_i\| < D \quad (5)$$

dimana  $x_k \in X$ ,  $k = 1, \dots, n$  dan  $v_i$ ,  $i = 1, \dots, c$  adalah pusat cluster,  $V = [v_1, \dots, v_n] \in R^{cp}$ , nilai konstanta  $k$   $i$   $D$  ditetapkan pada awal algoritma. Pusat cluster  $v_i$  dimodifikasi untuk setiap cluster (yaitu,  $i = 1, \dots, c$ ) menurut persamaan berikut

$$v_i(t+1) = v_i(t) + a_t(x_k - v_i(t)) \quad (6)$$

di mana  $t = 0, 1, 2, \dots$  menunjukkan jumlah iterasi, pada  $a_t \in [0, 1]$  adalah kecepatan pembelajaran dan menurun selama kinerja algoritma (tergantung pada jumlah elemen dalam cluster). Rekursi dari Persamaan. 6, berasal dari algoritma LVQ. Sebagai hasil dari kinerja algoritma ini, kami mendapatkan jumlah cluster  $c$ , kami telah membagi kumpulan data ke dalam cluster, dan kami mengetahui nilai pusat cluster  $v_i$   $i = 1, \dots, c$  yang dapat kami gunakan sebagai nilai awal untuk algoritma clustering tahap kedua.

Pada tahap kedua telah digunakan algoritma fuzzy c-means. FCM adalah prosedur optimasi terbatas yang meminimalkan jumlah tertimbang dalam-kelompok jumlah kesalahan kuadrat fungsi tujuan  $J_m$  sehubungan dengan pusat cluster  $u_{ik}$  keanggotaan fuzzy  $v_i$ , diberikan data pelatihan  $x_k$ ,  $i = 1, \dots, c$ ;  $k = 1, \dots, n$

$$\min_{(U,V)} \{J_m(U,V;X) = \sum_{k=1}^n \sum_{i=1}^c (u_{ik})^m \|x_k - v_i\|^2\} \quad (7)$$

Jumlah cluster  $c$  dan nilai awal cluster center  $v_i$  berasal dari algoritma clustering tahap pertama.

### Analisis Umpan Maju dari AFINN

Algoritma pengelompokan dua tahap memberikan partisi-c fuzzy dari data sampel. Hasil ini membantu kita untuk menghasilkan dasar aturan fuzzy untuk skema AFINN. Jumlah aturan sama dengan jumlah cluster  $c$  yang diperoleh dari algoritma clustering. Biarkan  $X$  dan  $y$  menunjukkan vektor input dan output dari skema AFINN. Misalkan  $\bar{x}_1, \dots, \bar{x}_q$  dan  $\bar{y}$  masing-masing merupakan variabel linguistik yang berasosiasi dengan  $x$  dan  $y$ . Aturan Fuzzy IF-THEN dapat ditulis dalam bentuk berikut:

$$\text{IF } (x_1 \text{ is } U_1^j \text{ AND } \dots \text{ AND } x_a \text{ is } U_a^j) \text{ THEN } (y = w_0^j + w_1^j x_1 + \dots + w_a^j x_a) \quad (8)$$

dimana  $U_j^i$ ,  $i = 1, \dots, c$ ;  $j = 1, \dots, p$  dan  $q = p - 1$ , adalah himpunan fuzzy yang didefinisikan berdasarkan partisi-c data pembelajaran  $X$ . Fungsi keanggotaan himpunan fuzzy  $U_j^i$  dapat dipilih sebagai fungsi keanggotaan Gaussian dalam bentuk berikut:

$$O_{U_j^i}^1 = \mu_{U_j^i} = \exp \left[ - \left( \frac{x_j - v_{ij}}{\sigma_{ij}} \right)^2 \right] \quad (9)$$

untuk  $j = 1, \dots, q$  dan  $i = 1, \dots, c$ . Nilai  $v_{ij}$  dalam Persamaan. 9 menunjukkan pusat fungsi keanggotaan Gaussian dan sama dengan nilai komponen vektor  $v_i$  yang berasal dari algoritma pengelompokan tahap kedua. Nilai  $\sigma_{ij}$  dalam Persamaan. 9 menentukan lebar fungsi keanggotaan Gaussian. Nilai-nilai ini dihitung menurut

$$\sigma_{ij} = \left( \sum_{k=1}^n u_{ik} (x_{kj} - v_{ij})^2 \Big/ \sum_{k=1}^n u_{ik} \right)^{1/2} \quad (10)$$

Ide menghitung nilai  $\sigma_{ij}$  berasal dari [17]. Nilai-nilai ini dihitung berdasarkan matriks U yang elemen-elemennya mewakili keanggotaan fuzzy dari pola  $x_k$  pada cluster ke-i dan memiliki nilai yang diperoleh dari algoritma clustering tahap kedua. Mereka adalah elemen  $c \times q$  di lapisan  $L_1$ . Mereka menyadari fungsi keanggotaan yang didefinisikan oleh Persamaan. 9. Lapisan kedua  $L_2$  memiliki elemen c yang mewujudkan operasi perkalian karena menggunakan aturan Larsen dalam prosedur penalaran fuzzy. Output dari lapisan ini mewakili kekuatan aturan, dinyatakan sebagai:

$$O_i^2 = \prod_{j=1}^q O_{U_j^i}^1 \quad (11)$$

dimana  $i = 1, \dots, c$ . Dalam struktur AFINN, lapisan tambahan ( $L_3$ ), dibandingkan dengan skema TSK klasik, telah diperkenalkan. Ini adalah lapisan tambahan dari partisi keluaran, yang masing-masing dikaitkan dengan sistem linier lokal untuk mengurangi jumlah node aturan. Node pada layer ini mewakili partisi dari variabel output. Tautan pada lapisan ini, terbentuk sebagai konsekuensi dari aturan. Node harus melakukan operasi fuzzy OR untuk mengintegrasikan aturan yang diaktifkan:

$$O_l^3 = \sum_k O_k^2 w_{l,k}^3 \quad (12)$$

dimana,  $k = 1, \dots, c$ . Oleh karena itu, hubungan antara  $L_2$  dan  $L_3$  (yaitu hubungan antara aturan fuzzy dan partisi output) berfungsi sebagai mesin inferensi yang tidak memerlukan proses pencocokan aturan. Awalnya, tautan pada lapisan  $L_2-L_3$  sepenuhnya saling berhubungan, yaitu jumlah atau aturan maksimum yang dipertimbangkan. Namun, tidak semua aturan penting untuk sistem fuzzy. Bobot link yang menghubungkan simpul aturan ke-k dari  $L_2$  dan partisi keluaran ke-l pada  $L_3$  dilambangkan sebagai  $w_{l,k}^3$  dan ditetapkan sebagai 0,5. Sebuah algoritma pembelajaran kompetitif diadopsi. Untuk himpunan pasangan data latih  $(x,y)$  bobotnya disesuaikan sebagai:

$$\Delta w_{l,k}^3 = O_l^3 (-w_{l,k}^3 + O_k^2) \quad (13)$$

dimana  $O_l^3$  dilambangkan sebagai output dari l output term node, sedangkan  $O_k^2$  adalah output dari k fuzzy rule node. Oleh karena itu,  $O_l^3$  berfungsi sebagai indeks menang-kalah persaingan. Setelah pembelajaran kompetitif, bobot  $w_{l,k}^3$  akan mendekati nol l ,k atau beberapa nilai. Tujuan dari fase ini adalah untuk menghapus aturan yang kurang penting dan untuk mempertahankan yang penting berdasarkan hasil pembelajaran kompetitif melalui

seluruh rangkaian pasangan data yang terlatih. Bobot link yang menghubungkan node aturan dan node partisi output menunjukkan kekuatan aturan yang mempengaruhi partisi output. Tautan dengan bobot maksimum dipilih dan ditetapkan ke 1. Yang lain akan ditetapkan ke 0. Oleh karena itu, hanya aturan dengan tautan dengan bobot maksimum yang ditetapkan ke partisi output. Setelah itu bobot link yang menghubungkan simpul keluaran yang sama dibandingkan. Jika bobot tautan ditemukan lebih kecil dibandingkan dengan bobot maksimum, bobot tautan ditetapkan ke nol.

Bobot yang tersisa diberikan ke 1. Oleh karena itu  $w^3_{l,k}$  akan menjadi 0 atau 1, yang menunjukkan keberadaan tautan yang menghubungkan simpul l di  $L_3$  dan simpul k di  $L_2$ .

Pada layer  $L_4$ , setiap node merupakan node adaptif, dengan fungsi node sebagai:

$$O_l^4 = \frac{O_l^3}{\sum_l O_l^3} f_l = \frac{O_l^3}{\sum_l O_l^3} (p_l x_1 + q_l x_2 + r_l) \quad (14)$$

di mana  $\{ p_l, q_l, r_l \}$  adalah set parameter dari simpul ini. Parameter dalam lapisan ini disebut sebagai "parameter konsekuensi". Akhirnya di lapisan terakhir,  $L_5$ , simpul tunggal di lapisan ini menghitung output keseluruhan sebagai penjumlahan dari semua sinyal yang masuk:

$$O^5 = \sum_l O_l^4 \quad (15)$$

### Tuning Premise dan Consequence Parameter AFINN

Pada fase penyetelan, penekanan diberikan pada sifat skema AFINN itu sendiri. Ada dua set parameter yang berbeda dan perlu disetel. Ini termasuk parameter premis nonlinier di bagian fuzzifikasi dan parameter konsekuensi linier di bagian defuzzifikasi. Pendekatan pembelajaran hibrida telah diadopsi untuk skema AFINN. Jaringan dapat dianggap sebagai kaskade sistem nonlinier dan sistem linier. Pada fase ini, error backpropagation diterapkan untuk menyetel parameter premis dari fungsi keanggotaan dan estimasi kuadrat terkecil rekursif diterapkan untuk menemukan parameter konsekuensi dari sistem linier lokal.

Mari kita pertimbangkan propagasi balik kesalahan untuk jaringan umum lapisan R. Untuk setiap pasangan pelatihan  $(x, y)$ , keluaran sistem  $O^5$  diperoleh dalam lintasan maju setelah memasukkan pola masukan ke dalam jaringan. Kemudian tujuan dari fase pembelajaran ini adalah, untuk pasangan data pelatihan pth yang diberikan  $(x, y)$ , parameternya disesuaikan sehingga meminimalkan fungsi kesalahan.

$$E_p = \frac{1}{2} (y_p - O^5)^2 \quad (16)$$

Kita perlu menghitung  $\partial E_p / \partial O_i^j$  untuk semua node tersembunyi di back pass.

$$\frac{\partial E_p}{\partial O^5} = -(y_p - O^5) \quad (17)$$

$$\frac{\partial E_p}{\partial O_l^3} = \frac{\partial E_p}{\partial O^5} \frac{\partial O^5}{\partial O_l^3} = -(y_p - O^5) \frac{f_l \sum_l O_l^3 - \sum_l f_l O_l^3}{(\sum_l O_l^3)^2} \quad (18)$$

$$\frac{\partial E_p}{\partial O_k^2} = \frac{\partial E_p}{\partial O_l^3} \frac{\partial O_l^3}{\partial O_k^2} = \frac{\partial E_p}{\partial O_l^3} \quad (19)$$

Kita harus ingatkan itu  $\partial E_p / \partial O_k^2$  dari simpul ke-k di L2 sama dengan  $\partial E_p / \partial O_l^3$  dari l di L<sub>3</sub> jika dua node terhubung. Karenanya,

$$\frac{\partial E_p}{\partial v_{jk}} = \frac{\partial E_p}{\partial O_k^2} \frac{\partial O_k^2}{\partial v_{jk}} = \frac{\partial E_p}{\partial O_k^2} O_k^2 \left[ \frac{2(x_j - v_{jk})}{(\sigma_{jk})^2} \right] \quad (20)$$

Pembaruan untuk parameter premis didefinisikan sebagai:

$$\Delta v_{jk} = -n \left( \frac{\partial E_p}{\partial v_{jk}} \right) \quad (21)$$

Dengan demikian

$$\Delta v_{jk} = -n \frac{\partial E_p}{\partial O_k^2} O_k^2 \left[ \frac{2(x_j - v_{jk})}{(\sigma_{jk})^2} \right] \quad (22)$$

di mana  $\eta$  adalah kecepatan belajar. Lebar dihitung sebagai

$$\frac{\partial E_p}{\partial \sigma_{jk}} = \frac{\partial E_p}{\partial O_k^2} \frac{\partial O_k^2}{\partial \sigma_{jk}} = \frac{\partial E_p}{\partial O_k^2} O_k^2 \left[ \frac{2(x_j - v_{jk})^2}{(\sigma_{jk})^3} \right] \quad (23)$$

$$\Delta \sigma_{jk} = -n \left( \frac{\partial E_p}{\partial \sigma_{jk}} \right), \text{ thus} \quad (24)$$

$$\Delta \sigma_{jk} = -\eta \frac{\partial E_p}{\partial O_k^2} O_k^2 \left[ \frac{2(x_j - v_{jk})^2}{(\sigma_{jk})^3} \right] \quad (25)$$

Estimasi kuadrat terkecil rekursif digunakan untuk mencari parameter konsekuensi dari sistem linier lokal. Sekarang mari kita definisikan kesalahan estimasi  $e_p$  pada pasangan data pelatihan ke-p:

$$e_p = y_p - O_p^5 = y_p - \varphi_p^T \hat{\theta}_{p-1} \quad (26)$$

Keluaran sistem dirumuskan ulang sebagai:

$$O^5 = \sum_l \left[ \sum_m \left( \left( \frac{O_l^3}{\sum_l O_l^3} z_m \right) w_{lm} \right) \right] \quad (27)$$

di mana l adalah jumlah node di L3, dan m menunjukkan jumlah variabel input ditambah 1 (yaitu,  $m = 1, n_1, \dots, n_q$ ). Parameter konsekuensi  $\{ p, q, r \}$  dalam Persamaan. 14 dilambangkan sebagai w. Mari kita tunjukkan,

$$\varphi_p = \left[ \frac{O_1^3}{\sum_l O_l^3} z_1 \dots \frac{O_1^3}{\sum_l O_l^3} z_{n_1} \frac{O_2^3}{\sum_l O_l^3} z_1 \dots \frac{O_2^3}{\sum_l O_l^3} z_{n_2} \dots \frac{O_q^3}{\sum_l O_l^3} z_1 \dots \frac{O_q^3}{\sum_l O_l^3} z_{n_q} \right] \quad (28)$$

Dan

$$\hat{\theta}_p = [w_{11} \dots w_{1n_q} w_{21} \dots w_{2n_q} w_{l1} \dots w_{ln_q}] \quad (29)$$

Dengan demikian, estimasi kuadrat terkecil rekursif dapat diterapkan untuk menemukan parameter sedemikian rupa sehingga fungsi biaya  $J$  diminimalkan.

$$J = \frac{1}{2} \sum_p e_p^2 \quad (30)$$

Algoritma untuk memperbarui parameter adalah:

$$\hat{\theta}_p = \hat{\theta}_{p-1} + \frac{P_{p-1} \varphi_p}{1 + \varphi_p^T P_{p-1} \varphi_p} e_p \quad (31)$$

$$P_p = P_{p-1} - \frac{P_{p-1} \varphi_p \varphi_p^T P_{p-1}}{\varphi_p^T P_{p-1} \varphi_p} \quad (32)$$

di mana  $\hat{\theta}_0$  diberikan dan  $P_{-1}$  adalah matriks identitas.

## 18.5 DISKUSI HASIL

Sistem diagnostik otomatis bertujuan untuk meningkatkan kemampuan mendeteksi struktur patologis dalam pemeriksaan medis dan untuk mendukung evaluasi temuan patologis selama prosedur diagnostik. Teknik yang dikembangkan untuk deteksi perubahan elektroensefalografik otomatis mengubah sebagian besar kriteria diagnostik kualitatif menjadi masalah klasifikasi fitur sinyal kuantitatif yang lebih objektif. Agar masalah pemrosesan pola dapat diselesaikan, diperlukan konversi pola menjadi fitur, yang merupakan representasi pola yang diringkas, idealnya hanya berisi informasi penting. Oleh karena itu, jaringan AFINN yang diusulkan menggunakan koefisien wavelet diimplementasikan untuk deteksi perubahan elektroensefalografik otomatis.

Set data (set A, B, C, D, dan E) dibagi menjadi dua set data terpisah—set data pelatihan dan set data pengujian. Dalam studi ini tiga kasus telah diperiksa:, (i) klasifikasi antara dua kelas, A dan E masing-masing, (ii) klasifikasi antara tiga kelas (A, C, D) dan (iii) klasifikasi kumpulan data lengkap. Fungsi yang memadai dari pengklasifikasi AFINN tergantung pada ukuran set pelatihan dan set tes. Dalam penelitian ini, 100 deret waktu dari 4096 sampel untuk setiap kelas berjendela oleh jendela persegi panjang yang terdiri dari 256 data diskrit dan kemudian set pelatihan dan uji pengklasifikasi AFINN dibentuk oleh 8000 vektor (1600 vektor dari setiap kelas) dengan dimensi tertentu ( dimensi vektor fitur yang diekstraksi yang ditentukan dari skema PCA).

Teknik pengambilan sampel ulang adalah metode yang terkenal untuk menghindari batas tingkat kesalahan yang tampak, yang bertujuan untuk memberikan perkiraan kesalahan prediksi yang tidak bias. Validasi silang adalah metode memperkirakan kinerja generalisasi berdasarkan re-sampling, dan hasil yang diperoleh sering digunakan untuk perbandingan model. Validasi silang K-fold adalah salah satu cara untuk meningkatkan metode ketidaksepakatan. Kumpulan data dibagi menjadi k himpunan bagian, dan metode holdout diulang sebanyak k kali. Setiap kali, salah satu dari k subset digunakan sebagai test set dan k-1 subset lainnya disatukan untuk membentuk training set. Kemudian kesalahan rata-rata di semua k percobaan dihitung. Keuntungan dari metode ini adalah tidak terlalu penting bagaimana data dibagi. Setiap titik data berada dalam set pengujian tepat satu kali, dan berada dalam set pelatihan k-1 kali. Varians dari estimasi yang dihasilkan berkang dengan bertambahnya k. Kerugian dari metode ini adalah algoritma pelatihan harus dijalankan ulang dari awal sebanyak k kali, yang berarti dibutuhkan k kali komputasi untuk melakukan evaluasi. Dalam semua kasus, 75% data digunakan untuk pelatihan, sedangkan 25% sisanya untuk pengujian.

### Kasus Satu (Masalah Dua Kelas)

Kumpulan data pelatihan digunakan untuk melatih model AFINN, sedangkan kumpulan data pengujian digunakan untuk memverifikasi keakuratan dan efektivitas model AFINN yang dilatih untuk klasifikasi dua kelas sinyal EEG. PCA telah menghasilkan 8 input, dan hasil dari classifier yang diusulkan, menggunakan 5 set pelatihan yang berbeda ditunjukkan pada tabel 3.

**Tabel 18.3** Performa AFINN untuk kelas A dan E

Kumpulan data	No Aturan lapisan pertama	No Aturan lapisan kedua	Kelas A %	Kelas E %
1	10	6	98.3	97.3
2	8	5	98.6	98.4
3	10	6	95.7	95.7
4	9	5	99.1	99.4
5	9	5	98.9	99.0
Rata-rata			98.12	97.96

Skema yang diusulkan memiliki akurasi klasifikasi yang tinggi, sedangkan keunggulan utamanya adalah kecepatan pelatihan, hanya 15 epoch. Skema clustering pada bagian fuzzifikasi, menghasilkan 9 aturan awal, sedangkan setelah lapisan kompetitif, aturan dikurangi menjadi 5. Hal itu menghasilkan lebih sedikit parameter konsekuensi pada lapisan defuzzifikasi, yang merupakan keunggulan skema yang diusulkan dibandingkan neuro-fuzzy klasik lainnya. pendekatan, seperti ANFIS. Parameter D diatur ke 0,60. Hanya untuk tujuan perbandingan, perceptron multilayer dua-tersembunyi menghasilkan kinerja yang lebih rendah, dengan biaya tambahan lebih banyak waktu pelatihan. Ini diilustrasikan pada tabel 4, di mana 24 dan 12 neuron digunakan untuk dua lapisan tersembunyi dan jumlah epoch ditetapkan menjadi 2000.

**Tabel 18.4** Performa MLP untuk kelas A dan E

Kumpulan data	Kelas A (%)	Kelas E (%)
1	95.1	96.3
2	94.3	95.3
3	94.1	96.1
4	96.2	95.5
5	95.2	96.1
Rata-rata	94.98	95.86

### Kasus Dua (Masalah Tiga Kelas)

Kumpulan data pelatihan digunakan untuk melatih model AFINN, sedangkan kumpulan data pengujian digunakan untuk memverifikasi keakuratan dan efektivitas model AFINN yang dilatih untuk klasifikasi tiga kelas sinyal EEG. PCA telah menghasilkan 5 input, dan hasil dari classifier yang diusulkan, menggunakan 5 set pelatihan yang berbeda ditunjukkan pada tabel 5. Jaringan saraf MLP terkait, memiliki kinerja yang memuaskan, seperti yang ditunjukkan pada tabel 6, dibandingkan dengan kasus pertama, dan jumlah zaman ditetapkan ke 2000.

**Tabel 18.5** Performa AFINN untuk kelas A, C dan D

Kumpulan data	No. peraturan	Kelas A (%)	Kelas C (%)	Kelas D (%)
1	9/5	96.88	97.2	98.1
2	9/5	99.4	98.9	98.0
3	6/4	98.75	97.7	99.0
4	9/5	99.4	99.5	98.9
5	7/5	98.44	98.9	98.8
<b>Rata-rata</b>		98.6	98.44	98.6

**Tabel 18.6** Performa MLP untuk kelas A, C dan D

Kumpulan Data	Kelas A	Kelas C	Kelas D
1	96.1	97.1	97.3
2	94.3	95.9	95.2
3	93.1	97.1	98.4
4	97.2	94.5	98.6
5	95.2	98.1	97.0
<b>Rata-rata</b>	95.18	96.54	97.3

### Kasus Tiga (Masalah Lima Kelas)

Kumpulan data pelatihan digunakan untuk melatih model AFINN, sedangkan kumpulan data pengujian digunakan untuk memverifikasi keakuratan dan efektivitas model AFINN yang dilatih untuk klasifikasi lima kelas sinyal EEG asli. PCA telah menghasilkan 7 masukan, dan hasil dari pengklasifikasi yang diusulkan, menggunakan 5 set pelatihan yang berbeda ditunjukkan pada tabel 7. Jaringan saraf MLP kembali mencapai kinerja yang baik; namun jumlah epoch, serta jumlah parameter yang akan dioptimalkan, tidak optimal seperti dalam kasus AFINN. Tabel 8, merangkum hasil tersebut.

**Tabel 18.7** Performa AFINN untuk kelas A, B, C, D, dan E

Kumpulan Data	No. Peraturan	Kelas A (%)	Kelas B (%)	Kelas C (%)	Kelas D (%)	Kelas E (%)
1	9/5	96.88	99.4	98.44	98.44	97.5
2	9/5	99.4	98.4	99.1	99.1	99.4
3	6/4	98.75	99.4	99.4	99.1	98.75
4	9/5	99.4	99.1	96.88	98.75	98.75
5	7/5	98.44	98.44	98.75	99.1	96.88
<b>Rata-rata</b>		98.6	99.1	98.5	98.9	98.26

**Tabel 18.8** Performa MLP Kelas A, B, C, D, dan E

Kumpulan Data	Kelas A	Kelas B	Kelas C	Kelas D	Kelas E
1	94.3	94.3	95.0	94.0	96.6

2	95.6	95.3	94.3	94.0	97.2
3	94.7	94.7	95.5	96.1	96.8
4	94.7	95.3	95.4	96.5	96.0
5	96	96.1	96.0	95.7	95.2
<b>Rata-rata</b>	95.06	95.14	95.24	95.26	96.36

## 18.6 KESIMPULAN

Teori himpunan fuzzy memainkan peran penting dalam menghadapi ketidakpastian ketika membuat keputusan dalam aplikasi medis. Menggunakan logika fuzzy memungkinkan kita untuk menggunakan ketidakpastian dalam desain classifier dan akibatnya untuk meningkatkan kredibilitas output sistem. Studi penelitian ini menyajikan implementasi jaringan saraf tiruan dari sistem fuzzy baru dan penerapannya pada klasifikasi sinyal EEG. Kami telah mempelajari algoritma pengelompokan dua tahap untuk menentukan aturan, jumlah himpunan fuzzy, dan nilai awal dari parameter (pusat dan lebar) dari fungsi keanggotaan fuzzy. Tidak seperti ANFIS di mana jumlah sistem linier lokal sama dengan aturan, sistem yang diusulkan menyediakan sarana untuk mengendalikan pertumbuhan jumlah sistem linier lokal ketika urutan sistem yang dipertimbangkan meningkat sehingga estimasi kuadrat terkecil dapat diterapkan. Jaringan yang diusulkan dilatih dan diuji dengan fitur yang diekstraksi menggunakan transformasi wavelet diskrit dari sinyal EEG. Hasil simulasi mengungkapkan kinerja yang hampir sempurna dibandingkan dengan jaringan saraf MLP klasik. Keuntungan utama dari skema AFINN yang diusulkan adalah bahwa kinerja tersebut dikaitkan dengan proses pelatihan kecepatan tinggi.

## BAB 19

### PENDEKATAN SISTEMATIS UNTUK DESAIN SISTEM PENALARAN BERBASIS KASUS UNTUK GANGGUAN PEMUSATAN PERHATIAN-DEFISIT

Attention-deficit hyperactivity disorder (ADHD) adalah gangguan neuropsikiatri umum pada anak-anak dan orang dewasa, ditandai dengan gejala kurangnya perhatian, hiperaktif, dan impulsif. Diagnosis saat ini dibuat dengan menggunakan serangkaian pemeriksaan, skala penilaian, dan wawancara. Banyak dari sumber-sumber ini subjektif dan tidak selalu berkorelasi. Keandalan yang dipertanyakan dari sumber-sumber ini menyoroti perlunya tes ADHD yang lebih objektif. Dalam bab ini, kami membahas kebutuhan ini dengan desain, pengembangan, dan pengujian sistem komputasi yang efisien untuk diferensiasi berdasarkan kontrol yang diubah dari gerakan mata saccadic pada subjek ADHD dan kelompok kontrol. Hipotesis kami adalah bahwa ada cukup informasi prediktif yang terkandung dalam data gerakan mata yang ada untuk memungkinkan pengembangan sistem berbasis pengetahuan yang dapat digunakan untuk mengidentifikasi kelompok subjek ADHD yang bermakna. Secara khusus, sistem penalaran berbasis kasus (CBR) diterapkan untuk mengambil dan menerapkan kasus diagnostik ADHD sebelumnya ke masalah baru berdasarkan data kinerja saccade. Metodologi perbaikan berulang digunakan untuk meningkatkan sistem CBR secara bertahap, menghasilkan alat yang dapat membedakan ADHD dari subjek kontrol normal dengan akurasi lebih dari 70%. Selain itu, banyak subjek ADHD yang salah diklasifikasikan oleh sistem CBR terbukti mewakili subkelompok yang bermakna dalam basis kasus ADHD. Subjek ADHD yang salah diklasifikasikan menunjukkan penurunan manfaat yang signifikan dari pengobatan, yang diukur dengan peningkatan kinerja saccade, bila dibandingkan dengan subjek yang diklasifikasikan dengan benar. Kemampuan sistem CBR untuk mengidentifikasi subkelompok ADHD yang bermakna mendukung potensi penggunaannya sebagai alat diagnostik dengan berkontribusi pada baterai diagnostik multi-sumber bila digabungkan dengan tes objektif lainnya.

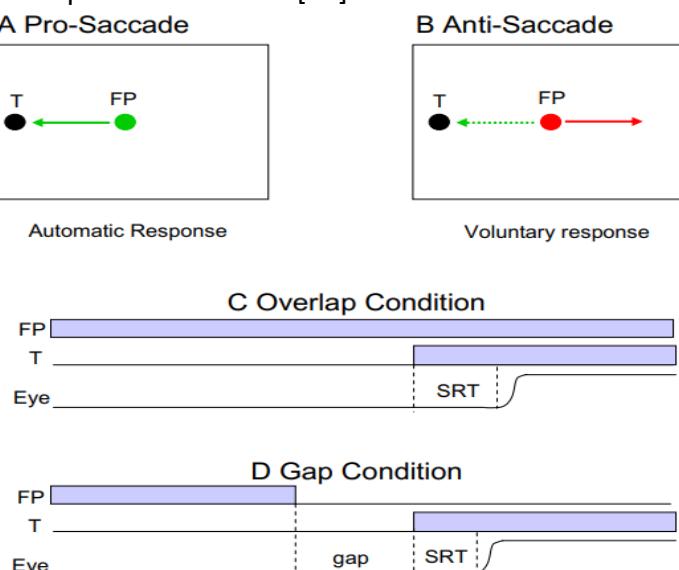
#### 19.1 PENDAHULUAN

Attention-Deficit Hyperactivity Disorder (ADHD) adalah gangguan neuropsikiatri umum pada anak-anak, remaja dan orang dewasa, mempengaruhi sekitar 5% dari anak-anak sekolah di Amerika Utara [4,32]. ADHD saat ini didefinisikan oleh gejala kurangnya perhatian, hiperaktif dan impulsif [3]. Secara khusus, subjek ADHD tidak memiliki kontrol penghambatan; yaitu, mereka mengalami kesulitan menekan refleksif, dan sering tidak sesuai, tanggapan perilaku [31,26]. Diagnosis umumnya dibuat dengan menggunakan kumpulan informasi dari wawancara orang tua dan guru, skala penilaian hiperaktif dan impulsif, riwayat klinis, penilaian kognitif, dan pemeriksaan neurologis dan fisik lengkap [4]. Banyak sumber yang dibutuhkan karena bersifat subjektif dan seringkali tidak berkorelasi secara signifikan [4]. Proses diagnostik lebih rumit oleh komorbiditas (yaitu, adanya gangguan lain selain ADHD) dan fakta bahwa gejala klasik sering tergantung situasi [6]. Ini mempertanyakan keandalan dan konsistensi dari proses diagnostik saat ini, dan menyoroti perlunya tes yang lebih objektif [25].

Tes objektif saat ini, seperti Continuous Performance Test (CPT), telah terbukti berpotensi berguna untuk mengidentifikasi beberapa sub-kelompok gangguan, tetapi kegunaan tes secara keseluruhan telah dipertanyakan [10].

Penelitian tentang etiologi ADHD telah mengungkapkan beberapa tes diagnostik objektif potensial lainnya. Salah satu kemungkinan adalah dengan menggunakan kontrol yang diubah dari gerakan mata saccadic. Saccades adalah gerakan mata cepat yang membawa target visual baru ke fovea retina (wilayah ketajaman visual tertinggi). Mereka dapat dihasilkan secara sukarela atau otomatis sebagai respons terhadap rangsangan sensorik yang muncul secara tiba-tiba. Penelitian telah menunjukkan bahwa subjek dengan ADHD mengalami kesulitan menekan saccade otomatis yang dipicu secara visual [26,29,33]. Tugas telah dikembangkan yang dapat mengukur karakteristik saccades secara tepat [23]. Secara khusus, tugas pro-saccade dan anti-saccade digunakan untuk menyelidiki generasi saccade otomatis dan kehendak, masing-masing (lihat Gambar. 1 A dan B). Kedua tugas dimulai dengan subjek melihat titik fiksasi pusat (FP) pada layar besar di depan mereka. Target visual (T) kemudian muncul di kiri atau kanan FP. Subjek diinstruksikan (melalui warna FP) untuk melihat ke arah T (pro-saccade) atau menjauhi T (anti-saccade).

Pengukuran waktu reaksi saccadic (SRT – waktu dari penampilan target hingga permulaan gerakan mata), variabilitas intra-subjek dalam SRT, dan kesalahan arah digunakan untuk membandingkan kinerja mata pelajaran. Dibandingkan dengan kontrol yang sesuai dengan usia, subjek ADHD membuat lebih banyak kesalahan arah secara signifikan dalam tugas anti-saccade (yaitu, mereka menghasilkan pro-saccade otomatis yang salah) dan umumnya memiliki SRT yang lebih lama dan lebih bervariasi dalam semua tugas [26,29]. Beberapa subjek ADHD mengelompok dengan kelompok kontrol dalam hal kinerja, sementara yang lain berbeda secara signifikan, menunjukkan bahwa subkelompok gangguan juga mungkin ada [29]. Hasil ini menunjukkan bahwa sebagian subjek ADHD mengalami kesulitan menekan pro-saccade otomatis selama tes anti-saccade dan umumnya memiliki kontrol sukarela yang buruk atas produksi saccade [29].



**Gambar 19.1** Paradigma perilaku yang digunakan untuk mengukur kinerja saccade. Mata mewakili jejak gerakan mata dengan waktu. T = Sasaran. FP = Titik Fiksasi. SRT = Waktu reaksi saccadic.

Dalam bab ini kami menjelaskan pengembangan metodologi komputasi baru untuk membuat pengelompokan bermakna subjek ADHD berdasarkan perbedaan dalam kinerja saccade. Kesulitan dalam mengembangkan sistem seperti itu terletak pada kompleksitas yang tinggi, dimensi yang tinggi, dan teori yang kurang dipahami dari domain ini (yaitu, kausalitas dan interaksi tidak terdefinisi dengan baik). Hal ini membuat pendekatan kecerdasan buatan tradisional, yang mengandalkan prinsip pertama dan pemahaman menyeluruh tentang domain untuk membangun model, menjadi tidak praktis. Namun, data saccade yang telah dikumpulkan dapat dilihat sebagai basis kasus pengalaman di mana sistem penalaran berbasis kasus (CBR) dapat diterapkan. Dalam CBR, masalah baru (misalnya, apakah seorang anak menderita ADHD?) diselesaikan dengan mengambil dan mengadaptasi pasangan masalah/solusi yang serupa dalam database kasus [22]. Setiap masalah dan solusi yang sesuai dapat dimasukkan ke dalam database untuk memberikan evolusi dan pembelajaran segera. Menggunakan kembali pengetahuan khusus yang terkandung dalam kasus mengkompensasi pengetahuan domain umum yang tidak lengkap.

CBR menarik dalam domain medis karena basis kasus sering sudah ada (gejala, diagnosis, pengobatan, dan hasil untuk setiap pasien). Lebih jauh lagi, siklus CBR sangat cocok dengan pendekatan yang diambil oleh petugas kesehatan ketika dihadapkan dengan kasus baru, membuat penggabungannya ke dalam pengaturan klinis alami. Dengan demikian, beberapa sistem CBR untuk diagnosis medis dan pendukung keputusan telah diterapkan (misalnya, [2,14,19]. Lihat Bichindaritz dan Marling 2006 [5] untuk review). Sistem ini semakin menggunakan metodologi yang melibatkan teknik rekayasa pengetahuan (KE) [36]. Karena domain yang lebih kompleks ditangani oleh sistem CBR, di mana merepresentasikan kasus dan mengadaptasi solusi dari kasus yang diambil menjadi sulit, pendekatan sistematis untuk pengembangan CBR menggunakan KE diperlukan [1,8]. Hal ini penting dalam domain ini karena menjelaskan pengetahuan yang membantu dalam pembangunan representasi kasus yang bermakna; bermakna, karena memungkinkan kasus yang diambil untuk dicocokkan sedekat mungkin dengan kasus target agar solusi mereka dapat digunakan kembali dengan sedikit adaptasi. CBR masih memiliki manfaat yang jelas dalam domain ini selama upaya KE yang diperlukan untuk membangun representasi kasus seperti itu kurang dari yang dibutuhkan untuk membangun keseluruhan model umum [8]. Bab ini menjelaskan upaya untuk mengatasi kebutuhan ini dengan merinci skema perbaikan berulang yang melibatkan KE dan penerapannya dalam domain teori yang kompleks dan lemah.

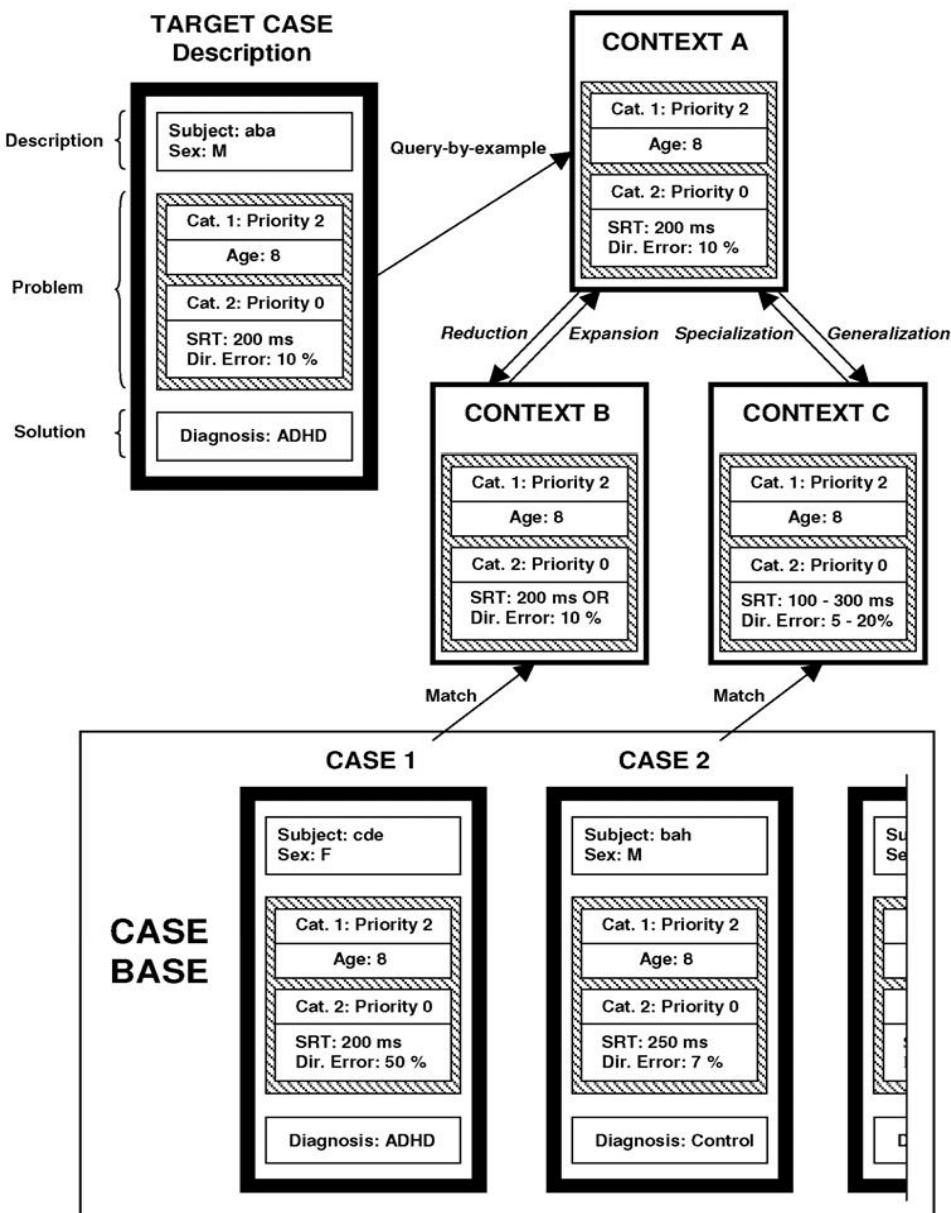
## 19.2 TA3

Jurisica dan rekan telah mengembangkan sistem pendukung keputusan cerdas baru yang menggabungkan CBR dan diarahkan untuk memecahkan masalah dalam biologi dan kedokteran [18,19,20]. Sistem ini, yang dikenal sebagai TA3 (diucapkan tah-tree), memiliki desain yang fleksibel dan catatan yang terbukti dalam domain medis, menjadikannya sistem yang menarik untuk digunakan dengan data kinerja saccade.

Sistem TA3 menggunakan paradigma CBR baru [18]. Penyimpanan case-base tidak rumit, baik menggunakan database relasional atau sistem file sederhana. Kasus direpresentasikan sebagai pasangan atribut/nilai. Pasangan atribut/nilai dan domainnya didefinisikan dalam apa yang disebut deskripsi kasus (lihat kasus target pada Gambar 2). Ada

tiga kelas data yang didefinisikan dalam deskripsi kasus: 1) Deskripsi adalah data non-prediktif, 2) Masalah adalah data prediksi, dan 3) Solusi adalah klasifikasi, diagnosis, atau hasil. Berfokus pada kelas Masalah, atribut dikelompokkan ke dalam kategori. Keuntungan dari pengelompokan atribut adalah memungkinkan penetapan batasan dan prioritas yang berbeda tergantung pada atribut, atau kumpulan atribut, relevansi (yaitu, nilainya dalam mencocokkan kasus serupa). Ini meminimalkan efek yang mungkin dimiliki atribut yang tidak relevan atau kurang relevan saat mencoba mencocokkan kasus serupa. Sebagai contoh, pada Gambar. 2 kelas Masalah diatur ke dalam dua kategori prioritas yang berbeda. Kategori pertama, dengan prioritas lebih tinggi, berisi usia subjek dan kategori kedua berisi SRT subjek dan persentase kesalahan arah. Keanggotaan kategori dapat diberikan oleh seorang ahli dengan pengetahuan domain tentang relevansi atribut yang berbeda atau dengan pendekatan pembelajaran mesin.

Proses pengambilan menggunakan pencocokan tetangga terdekat yang dimodifikasi: atribut prediktif dikelompokkan untuk memungkinkan prioritas/kendala yang berbeda seperti yang dijelaskan, konteks eksplisit digunakan selama penilaian kesamaan, dan algoritma pengambilan dipandu oleh transformasi inkremental dari konteks. Konteks hanyalah subset dari data kelas Masalah dari deskripsi kasus dengan batasan yang diterapkan pada pasangan atribut/nilai. Pada Gambar 2, Konteks A dibuat dari deskripsi kasus dan batasan awalnya adalah bahwa usia harus 8, SRT harus 200 ms, dan kesalahan arah harus 10%. Ini disebut sebagai query-by-example [19]. Pengambilan kasus berlangsung dengan mencoba memenuhi batasan-batasan ini. Dengan demikian, pencarian berdasarkan konteks ini hanya akan mengembalikan kasus target kecuali jika kasus lain sama persis dengan nilai-nilai ini. Kesamaan kasus didefinisikan sebagai kedekatan nilai yang didefinisikan dalam konteks. Suatu kasus dikatakan memenuhi suatu konteks jika setiap nilai atribut dalam kasus tersebut memenuhi batasan-batasan yang dikenakan pada atribut-atribut tersebut dalam konteks tersebut. Dua kasus kemudian dikatakan serupa jika keduanya memenuhi konteks yang sama [19].



**Gambar 19.2** Sistem pengambilan TA3. Dir. Kesalahan = Persentase Kesalahan Arah. SRT = Waktu reaksi saccadic. Kucing. = Kategori. Subjek = Kode yang digunakan untuk mengidentifikasi setiap subjek.

Pengambilan berdasarkan konteks memungkinkan spesialisasi oleh pengguna atau sistem dalam mempertimbangkan apa yang merupakan kecocokan. Untuk mengambil lebih banyak atau lebih sedikit kasus serupa, pengguna atau sistem secara iteratif menerapkan transformasi ke konteks. Dua transformasi dimungkinkan: relaksasi dan pembatasan. Relaksasi dapat dipecah menjadi dua implementasi: reduksi dan generalisasi. Pengurangan, juga disebut pencocokan *m\_of\_n*, mengurangi jumlah atribut dalam kategori yang diperlukan untuk kecocokan. Pada Gambar. 2, Konteks B adalah pengurangan dari Konteks A karena hanya SRT atau kesalahan arah yang harus dipenuhi untuk kecocokan dalam kategori 2 dari Konteks B, sedangkan SRT dan kesalahan arah harus dipenuhi dalam Konteks A.

Setelah relaksasi ini, Kasus 1 dari basis kasus yang ditampilkan akan dianggap cocok meskipun persentase kesalahan arahnya tidak sesuai dengan kasus target. Generalisasi

meningkatkan rentang nilai yang diizinkan yang mungkin diambil oleh suatu atribut. Konteks C adalah generalisasi dari Konteks A karena, dalam kategori 2, latensi 100-200 ms dan kesalahan arah 5-20% sekarang memenuhi konteks ini (Gbr. 2). Setelah relaksasi ini, Kasus 2 dari basis kasus akan dianggap cocok. Demikian pula, pembatasan dapat dipecah menjadi ekspansi dan spesialisasi, yang masing-masing memiliki efek berlawanan dari reduksi dan generalisasi. Perhatikan dalam contoh-contoh ini bahwa prioritas kategori 2 yang lebih rendah dilonggarkan dan bukan kategori 1. Ini adalah bagaimana prioritas kategori mempengaruhi transformasi dan memastikan bahwa relevansi atribut tercermin dalam penilaian kesamaan. Kategori prioritas yang lebih rendah dilonggarkan sebelum kategori prioritas yang lebih tinggi. Relaksasi dan restriksi diterapkan secara iteratif untuk mengontrol jumlah kasus yang diambil. Biasanya, proses pengambilan dipandu pengguna dan TA3 memungkinkan kontrol penuh atas transformasi. Misalnya, pengguna dapat menentukan teknik relaksasi mana yang digunakan terlebih dahulu, berapa kali setiap teknik harus dipanggil, apakah teknik tersebut harus diterapkan secara round-robin, apakah satu transformasi harus lebih disukai daripada yang lain, dan berapa banyak perubahan yang harus dilakukan. - laksasi atau restriksi harus diterapkan pada setiap iterasi.

Sifat TA3 yang fleksibel berarti bahwa tanggung jawabnya berakhir pada proses pengambilan. Terserah pengguna untuk menggunakan kembali set kasus yang dikembalikan dengan tepat berdasarkan masalah yang sedang dipecahkan. Demikian pula, tidak ada modul adaptasi khusus dalam sistem. Ada dukungan untuk penggalian pengetahuan di TA3 melalui fungsi penyempurnaan konteks. Diberikan dua atau lebih set tes yang mewakili kelas kasus yang berbeda, fungsi ini menggunakan Algoritma Genetika untuk memanipulasi konteks.

Fungsi ini memaksimalkan jarak antara kelas yang berbeda dan meminimalkan jarak dalam kelas yang sama. Jarak antara dua kasus didefinisikan sebagai jumlah relaksasi yang diperlukan untuk membuat dua kasus serupa. Fungsi Algoritma Genetika bekerja dengan membuat, mengubah, dan mengevaluasi kecocokan beberapa ratus konteks secara iteratif (di mana kecocokan sebanding dengan jarak seperti yang didefinisikan di atas). Mutasi termasuk mengubah prioritas kategori, reorganisasi kategori, atau mengubah berapa banyak dan jenis transformasi yang dapat diterapkan pada kategori dan atribut. Konteks dengan kebugaran maksimum adalah output di akhir. Informasi yang diperoleh melalui proses ini mungkin tidak hanya menentukan hubungan yang sebelumnya tidak diketahui dalam data, tetapi dapat memberikan konteks baru untuk memandu proses pengambilan dengan akurasi prediksi yang lebih besar.

### **19.3 METODE DAN BAHAN**

Implementasi Java dari browser aplikasi sistem pendukung keputusan TA3 disediakan oleh I. Jurisica dan rekan (Institut Kanker Ontario dan Universitas Toronto, Toronto, Ontario, Kanada). Parsing data dilakukan dengan menggunakan bahasa pemrograman Java (Sun Microsystems). Output statistik dihasilkan menggunakan Perangkat Lunak Statistik Minitab (Minitab Inc., State College, PA, Amerika Serikat) dan Matlab (The Mathworks Inc., Natick, MA, Amerika Serikat).

#### **Data**

Kasus dikompilasi dari tugas pro-saccade dan anti-saccade yang dilakukan pada anak-anak dan orang dewasa oleh Munoz dan rekan [29] serta kasus tambahan yang diuji sejak saat itu. Tugas-tugas ini diuraikan pada Gambar. 1. Perhatikan bahwa selama tugas, FP dapat tetap menyala selama kemunculan target (kondisi tumpang tindih; Gbr. 1 C) atau menghilang 200 ms sebelum kemunculannya (kondisi gap; Gbr. 1 D). Hilangnya FP dalam paradigma kesenjangan menyebabkan SRT lebih cepat [9] dan memfasilitasi generasi saccades ekspres [11,27,30], yang memiliki latensi sekitar 90 hingga 140 ms. Rentang SRT ini mewakili waktu sesingkat mungkin di mana saccade yang dipicu secara visual dapat dimulai di bawah pembatasan kontrol sensorik-motorik [28]. Persentase saccades ekspres dapat mewakili cara lain untuk membedakan ADHD dan subjek kontrol.

Kasus anak terdiri dari 76 anak yang didiagnosis di komunitas dengan ADHD dan 76 anak kontrol normal, usia 6 hingga 16 tahun. Diagnosis dikonfirmasi menggunakan kriteria sumber multipel tradisional yang diuraikan dalam Diagnostic and Statistical Manual of Mental Disorders 4th Edition (DSM- IV) [3]. Subjek ADHD tidak minum obat pada hari percobaan. Setiap subjek melakukan 1 blok uji coba pro-saccade 80-120 diikuti oleh 2 blok uji coba anti-saccade 80-120. Gerakan mata horizontal diukur dan data deskriptif/eksperimental dikumpulkan (lihat [27,29]). Data yang dikumpulkan untuk setiap mata pelajaran dan setiap percobaan ditunjukkan pada Tabel 1.

**Tabel 19.1** Data yang dikumpulkan untuk setiap mata pelajaran dan percobaan tugas kinerja saccade

Atribut	Nilai
Subjek	Kode unik untuk mengidentifikasi setiap subjek
Paradigma	Paradigma tugas saccade – pro atau anti
Kelompok	Diagnosis - ADHD atau kontrol
Obat	Subjek sedang menjalani atau tidak minum obat
Usia	Usia subjek pada saat percobaan
Seks	Laki-laki atau perempuan
kikir	Skor wenangan bilangan bulat di mana -10 adalah tangan kanan ekstrim dan +10 adalah tangan kiri ekstrim.
Hiperaktif	Skor hiperaktivitas bilangan bulat digunakan dalam diagnosis
impulsif	Skor impulsif bilangan bulat yang digunakan dalam diagnosis
Uji coba	Nomor percobaan
Kode	Kode unik yang mengidentifikasi semua karakteristik uji coba (target muncul di kanan/kiri, pro/anti, celah/tumpang tindih)
SRT	Waktu reaksi saccadic yang mewakili waktu dari munculnya target hingga permulaan gerakan mata
Benar	1 atau -1, menunjukkan bahwa subjek menggerakkan matanya ke arah yang benar atau salah

Selain itu, data dikumpulkan untuk banyak subjek anak ADHD pada hari-hari terpisah saat dalam pengobatan. Kumpulan data non-pengobatan sudah lengkap, tanpa nilai yang hilang. Tidak semua subjek untuk data dalam pengobatan memiliki uji coba di luar pengobatan

yang sesuai. Dua dari kasus pengobatan memiliki nilai yang hilang. Secara total, 53 kasus tanpa pengobatan dengan uji coba pengobatan yang cocok tersedia.

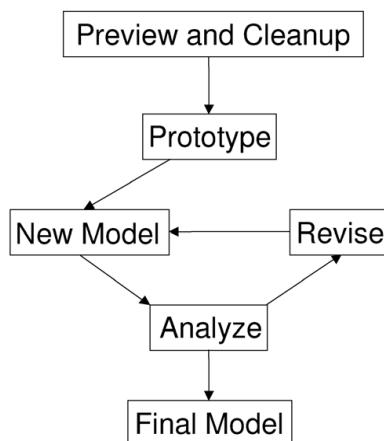
### **Penyempurnaan Iteratif**

Sistem CBR awal sering dikembangkan secara ad-hoc [1]. Satu kesulitan dalam menentukan metodologi yang lebih rinci untuk pengembangan CBR terletak pada ketergantungan yang kuat pada domain dan parameter implementasi. Baru-baru ini, peneliti CBR telah menunjukkan minat dalam mengembangkan metodologi yang fleksibel dan sistematis yang dapat diterapkan terlepas dari domain dan implementasinya [1]. Banyak pekerjaan telah dilakukan di bidang Pemeliharaan Berbasis Kasus untuk mencapai tujuan ini (lihat [17,21,35]). Namun, metode sistematis diperlukan untuk semua aspek pengembangan berbasis kasus, dan sistem yang dijelaskan di sini melanjutkan kebutuhan ini dengan menyediakan metode sistematis untuk mengembangkan pengklasifikasi berbasis kasus berdasarkan TA3. Secara khusus, fokus diberikan untuk mengembangkan representasi kasus yang tepat, indeks, dan skema pengambilan dalam domain kinerja saccadic.

Domain ini dapat disebut sebagai domain teori yang lemah karena hubungan sebab akibat dan interaksinya tidak dipahami dengan baik. Telah ditunjukkan bahwa beberapa karakteristik kinerja saccade subjek ADHD berbeda secara signifikan dari kontrol [29], tetapi tidak diketahui atribut kinerja apa yang paling/paling tidak dapat diprediksi atau apakah data ini dapat digunakan untuk diskriminasi sama sekali. Tentu saja tidak ada pemahaman yang cukup tentang gangguan dan hubungannya dengan gerakan mata saccadic untuk memungkinkan konstruksi model umum untuk diagnosis. Sementara salah satu kekuatan CBR adalah kemampuan untuk menerapkan penalaran dalam domain teori yang lemah, rekayasa pengetahuan menjadi dasar untuk membangun sistem yang tepat karena masalah yang ditangani menjadi lebih kompleks dan kurang dipahami [1,8]. Hal ini sangat penting dalam domain di mana adaptasi sulit atau informasi yang diperlukan untuk mengembangkan strategi adaptasi yang tepat tidak ada. Dalam domain tersebut, representasi kasus yang jelas dan metrik kesamaan perlu dikembangkan agar kasus dicocokkan sedekat mungkin dan solusi dapat digunakan kembali dengan sedikit perubahan [8].

Pekerjaan sebelumnya yang melibatkan pengembangan metodologi sistematis untuk mengelola komponen pengetahuan (representasi kasus, pengambilan, dan adaptasi solusi) telah diringkas oleh Aamodt [1]. Sebuah pandangan konstruksi model untuk CBR dijelaskan, menekankan pemodelan pada tingkat pengetahuan - tingkat di atas tingkat implementasi di mana hanya domain pengetahuan, tugas, dan metode yang ditangani. Komponen pengetahuan ini diperiksa secara terpisah sehingga interaksi di antara mereka lebih jelas dan dengan demikian model yang lebih relevan dapat dibangun. Pandangan tingkat pengetahuan seperti itu mengarah pada metodologi CommonKads untuk Sistem Berbasis Pengetahuan [36], sebuah metodologi yang digunakan dalam domain teori yang lemah di mana persyaratan dan interaksi domain kurang diketahui atau ditentukan dengan buruk. Ini melibatkan mulai dengan model prototipe sederhana yang secara iteratif disempurnakan menggunakan analisis, desain, pengembangan, dan fase pengujian sampai tingkat kinerja yang dapat diterima (yang spesifik aplikasi) tercapai. Dengan cara ini, sistem yang bisa diterapkan dapat dikembangkan tanpa perlu model yang jelas. Cunningham dan Bonzano berhasil menerapkan strategi ini ke Domain Kontrol Lalu Lintas Udara [8]. Pada setiap siklus pengembangan, mereka mengusulkan fitur

kasus baru dan kemudian menilai relevansi fitur ini. Generasi fitur ini (apa yang mereka sebut proses abduktif) didorong oleh analisis kesalahan model sebelumnya oleh pakar domain dan insinyur pengetahuan. Perbaikan berulang yang dijelaskan di sini didasarkan pada pendekatan ini dan memperluasnya ke tugas diagnostik dalam domain medis. Langkah-langkah dalam metodologi ini adalah sebagai berikut (lihat Gambar 3):



**Gambar 19.3** Perbaikan berulang dari sistem berbasis pengetahuan.

1. Pratinjau dan pembersihan - Pengenalan domain harus dilakukan di sini. Pratinjau awal data harus dilakukan serta penilaian integritas data.
2. Pengembangan prototipe awal - Langkah ini berfokus pada kesederhanaan dan berfungsi sebagai patokan untuk pengembangan lebih lanjut. Atribut apa pun yang relevan disertakan dalam deskripsi kasus, meskipun mungkin terlalu dangkal. Masukan ahli berguna pada tahap ini untuk menentukan relevansi fitur dan untuk menentukan batasan. Sebuah pendekatan berbasis daftar periksa untuk representasi kasus dapat digunakan misalnya [22].
3. Analisis - Model sebelumnya dianalisis dan perbaikan disarankan. Pertama, kinerja model harus diukur sebagai perbandingan menggunakan skema evaluasi yang sesuai (misalnya akurasi, sensitivitas/spesifikasi, atau validasi silang). Smith dan rekan [37] baru-baru ini membahas evaluasi menyeluruh dari sistem pendukung keputusan medis. Jika kinerja yang lebih baik diinginkan, analisis risiko model perlu dilakukan. Pertanyaan yang perlu diajukan seperti, apakah semua tugas tercakup dalam basis kasus (kompetensi), apakah waktu pengambilan dapat diterima, mengapa kasus yang berbeda dinilai serupa, dan mengapa kasus relevan yang terlewatkan selama pengambilan? Pakar domain dapat melakukannya dengan mengembangkan set pengujian dan menyarankan atribut baru. Jika atribut baru disarankan, relevansi relatifnya perlu ditentukan. Alat statistik dan teknik penemuan pengetahuan dapat digunakan pada tahap ini juga dan memiliki keuntungan untuk menghindari bias yang mungkin ditimbulkan oleh pendekatan yang dipandu pengguna. Analisis domain yang lebih menyeluruh, dan elaborasi atau abstraksi dari atribut yang ada mungkin diperlukan.
4. Revisi - Pada tahap ini, representasi kasus, fungsi kesamaan, dan kemungkinan strategi adaptasi, direvisi berdasarkan analisis. Ini dapat dicapai dengan menambahkan atribut

baru, menghapus atribut yang berlebihan, menghapus atribut yang tidak relevan, mengubah prioritas atribut, atau mengubah parameter pencarian konteks. Dalam TA3, ini berarti merevisi deskripsi kasus dan konteks untuk pengambilan.

5. Model Baru – Revisi sebelumnya merupakan pembangunan model baru. Model ini kemudian dianalisis seperti pada langkah 3, dan proses yang dijelaskan dalam langkah 3 hingga 5 diulang sampai tingkat kinerja yang berhasil direalisasikan atau kinerja yang stabil. Pada titik ini dokumen desain rinci juga dapat diformalkan.

### Evaluasi

Keakuratan sistem pengambilan TA3 dalam mengklasifikasikan kasus (yaitu, memprediksi diagnosis) ditentukan dengan membagi set data kontrol dan ADHD (di luar pengobatan) secara acak ke dalam set pengujian dan pelatihan yang berukuran sama. Hal ini diperlukan karena representasi kasus dan konteks dibangun secara bertahap berdasarkan eksplorasi basis kasus seperti yang dijelaskan di atas. Sistem case-base dibangun dengan menganalisis set pelatihan dan set pengujian digunakan untuk menilai kinerja sistem menggunakan pengujian tanpa-satu-keluar. Setiap kasus di set tes telah dihapus dari basis kasus pada gilirannya dan konteks dibuat berdasarkan deskripsi kasus saat ini. Sistem kemudian diarahkan untuk mengambil setidaknya satu kasus serupa dari basis kasus menggunakan parameter transformasi yang ditetapkan ke sistem saat ini. Jika lebih dari satu kasus diambil dalam sebuah iterasi, kasus-kasus itu juga dianggap valid. Diagnosis untuk setiap kasus yang diambil diperiksa dan proporsi ADHD dan kontrol ditentukan. Jika proporsi ADHD atau kontrol lebih tinggi dari yang diharapkan secara acak, proporsi itu digunakan sebagai diagnosis akhir.

Tiga statistik digunakan untuk mengukur kinerja sistem:

$$\text{sensitivity} = \frac{\sum \text{true positives}}{\sum \text{true positives} + \sum \text{false negatives}} * 100\%$$

$$\text{specificity} = \frac{\sum \text{true negatives}}{\sum \text{true negatives} + \sum \text{false positives}} * 100\%$$

$$\text{accuracy} = \frac{\sum \text{true positives} + \sum \text{true negatives}}{\sum \text{true positives} + \sum \text{false negatives} + \sum \text{true negatives} + \sum \text{false positives}} * 100\%$$

di mana positif sejati mewakili kasus ADHD yang diklasifikasikan dengan benar, negatif palsu mewakili kasus ADHD yang salah diklasifikasikan sebagai normal, negatif sejati mewakili kasus kontrol yang diklasifikasikan dengan benar sebagai normal, dan positif palsu mewakili kasus kontrol yang salah diklasifikasikan sebagai ADHD.

## 19.4 PERCOBAAN DAN HASIL

### Model 1 – Prototipe Awal

Untuk membangun basis kasus yang tepat dari data dan memutuskan deskripsi kasus, tujuan dan sub-tujuan ditentukan dan data dianalisis. Tujuan utama dari sistem CBR adalah untuk memberikan dukungan keputusan dalam diagnosis ADHD berdasarkan gerakan mata

saccadic yang berubah. Salah satu sub-tujuan adalah untuk memperoleh pola dan hubungan dalam data. Awalnya, daftar periksa/pendekatan berbasis perbedaan [22] digunakan untuk mengidentifikasi, tidak hanya indeks potensial yang akan digunakan untuk pengambilan, tetapi representasi dari kasus individu (yaitu, seperti apa seharusnya kasus itu).

Langkah pertama dalam pendekatan berbasis daftar periksa adalah mengidentifikasi tugas-tugas khusus dari si pemberi alasan. Tugas penalaran ini adalah menggunakan data kinerja saccade sebagai ukuran kesamaan antar kasus sehingga klasifikasi yang disarankan dapat ditetapkan ke kasus target berdasarkan klasifikasi dari kumpulan yang diambil. Langkah selanjutnya adalah menentukan fitur apa yang merupakan prediktor klasifikasi. Hipotesisnya adalah bahwa metrik kinerja saccade adalah prediktor yang baik dalam domain ini. Ini termasuk SRT rata-rata dan kesalahan arah selama tugas tertentu. Prediktor lain yang baik adalah usia, karena kinerja saccade sangat bervariasi dengan usia subjek [12, 27]. Beberapa penelitian [16] menunjukkan bahwa jenis kelamin juga dapat menjadi faktor pembeda karena anak laki-laki menunjukkan gejala yang lebih parah daripada anak perempuan dalam kelompok usia masing-masing. Langkah ketiga adalah membuat generalisasi yang berguna dari prediktor ini. Percobaan individu dapat digunakan sebagai kasus, tetapi itu akan menghasilkan lebih dari 60.000 kasus. Ini kemungkinan akan menghasilkan kinerja yang lambat dan banyak kasus akan diambil selama permintaan. Selain itu, kinerja individu bervariasi dari percobaan ke percobaan [27].

<b>DESCRIPTION</b>							
Subject code: aba		Hyperactivity: 87					
Handedness: 10		Impulsivity: 76					
<b>PROBLEM</b>							
<b>Priority 0</b>							
Age: 8		Sex: Male					
<b>Task Variables</b>							
Task	Mean SRT (ms)	CV	Dir. Error (%)	Exp. (%)			
Anti/Gap/Left	363.00	39.35	93.33	0.00			
Anti/Gap/Right	458.00	50.01	75.76	12.5			
Anti/Over/Left	351.67	42.07	77.78	16.67			
Anti/Over/Right	483.33	44.50	62.50	0.00			
Pro/Gap/Left	338.00	59.82	12.5	7.14			
Pro/Gap/Right	343.06	58.70	5.88	9.38			
Pro/Over/Left	431.50	46.88	3.45	7.14			
Pro/Over/Right	471.24	44.73	9.38	0.00			
<b>SOLUTION</b>							
Diagnosis: ADHD							

**Gambar 19.4** Contoh deskripsi kasus dari Model 1. SRT = Waktu reaksi saccadic. CV = koefisien variasi dalam SRT. Dir. Kesalahan = Persentase Kesalahan Arah. Eks. = Persentase Saccades Ekspres. Anti = Tugas anti-saccade. Pro = Tugas pro-saccade. Over = Kondisi tumpang tindih. Cela = Kondisi celah.

Abstraksi dari percobaan ini di mana setiap kasus mewakili subjek individu dan kinerjanya yang diringkas, memberikan kasus yang lebih bermakna – cukup konkret untuk digunakan untuk menilai kesamaan, tetapi cukup abstrak untuk menjadi bermakna dalam berbagai situasi. Meringkas statistik yang digunakan adalah yang diidentifikasi penting oleh Munoz dan rekan [29]: mean SRT, koefisien variasi dalam SRT untuk uji coba yang benar (yaitu, Standar Deviasi/Mean \* 100), persentase kesalahan arah (yaitu, melihat ke arah T dalam tugas anti-saccade atau jauh dari T selama tes pro-saccade - lihat Gambar. 1) dan persentase saccades ekspres. Oleh karena itu, data diformat ulang untuk menggunakan ringkasan ini dan representasi kasus default dibuat berdasarkan itu. Deskripsi kasus default ini ditunjukkan pada Gambar. 4. Perhatikan bahwa ada 8 tugas ketika mempertimbangkan semua kondisi yang mungkin dan 4 variabel yang diukur dalam setiap tugas dengan total 32 variabel tugas. Tabel 2 menampilkan hasil evaluasi leave-one-out menggunakan deskripsi kasus ini serta untuk model selanjutnya. Seperti yang diharapkan dari model dasar seperti itu, ditemukan sensitivitas dan spesifitas yang relatif rendah. Sistem ini lebih akurat, sekitar 15%, pada pengklasifikasian subjek kontrol dibandingkan subjek ADHD dalam kelompok uji.

### **Model 2 – Kendala Konteks**

Semua atribut yang digunakan dalam Model 1 tidak sama prediktifnya dan parameter konteksnya perlu dimodifikasi untuk mencerminkan hal ini. Salah satu masalah dengan Model 1 adalah terlalu banyak kasus yang diambil selama kueri. Pengambilan itu tidak cukup khusus. Ini menyarankan perlunya membatasi atribut. Kinerja saccade sangat bervariasi dengan usia menunjukkan bahwa itu akan menjadi kendala. Meskipun ada bukti bahwa seks memiliki pengaruh pada tingkat keparahan gangguan [16], belum terbukti mempengaruhi kinerja saccade. Oleh karena itu, jenis kelamin tidak dipertimbangkan dalam model ini, sementara usia diberikan kategori prioritasnya sendiri yang tinggi. Selama pengambilan, sistem diarahkan untuk menggeneralisasi kategori usia sebesar 10% hanya sekali. Misalnya, jika subjek tes berusia 11 tahun, kategori usia akan digeneralisasi menjadi 10-12 tahun. Manipulasi deskripsi kasus ini memungkinkan peningkatan sensitivitas (lebih dari 10%) dan spesifitas (5%) untuk set uji (lihat Tabel 2).

**Tabel 19.2** Perbandingan kinerja model CBR progresif

Model 1 Tolok Ukur	Model 2 Batasan Usia	Model 3 Statistik	Model 4 Clustering/G.A.
<b>Kepekaan (%)</b> 44.21	55.26	61.32	63.16
<b>Kekhususan (%)</b> 60.58	65.79	70.52	81.58
<b>Ketepatan (%)</b> 52.90	60.53	65.92	72.37

Sensitivitas, spesifitas, dan akurasi untuk model CBR yang semakin ditingkatkan. G.A. = Algoritma Genetika.

### **Model 3 – Statistik**

Menerapkan kendala ke Model 1 sehingga lebih sedikit dan lebih banyak kasus yang relevan dapat diambil memiliki manfaat untuk kinerja sistem. Namun, analisis atribut ringkasan yang tersisa tidak semudah usia karena kurang dipahami tentang kekuatan prediksi relatif mereka. Atribut kurang prediktif masih memiliki efek negatif pada kinerja pengambilan Sistem Pendukung Keputusan (Dr Joseph Teguh Santoso dan Budi Hartono, M.Kom)

dengan memungkinkan kasus yang berbeda untuk diambil. Dengan cara yang sama, atribut yang lebih prediktif tidak diberikan prioritas yang cukup tinggi. Untuk membantu dalam mengatur data kinerja ke dalam deskripsi kasus dan konteks yang lebih efektif, analisis statistik berikut dilakukan pada data eksperimen, selain yang dilakukan sebelumnya [29]. Untuk memeriksa variabilitas dan tumpang tindih atribut, histogram dibuat untuk membandingkan masing-masing dari 32 atribut (lihat Gambar. 4 untuk deskripsi kasus awal yang menjelaskan atribut ini) untuk kasus kontrol dan ADHD. Selain itu, dilakukan uji-t pada atribut yang sama.

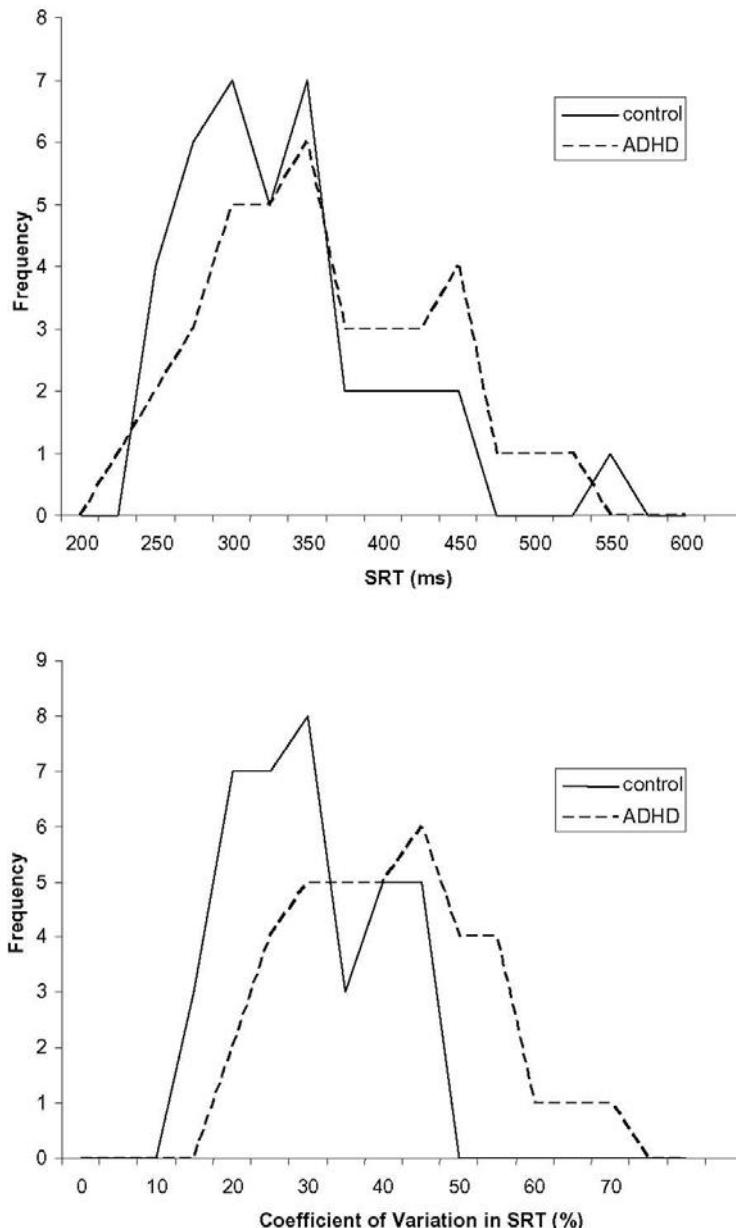
Melalui analisis statistik sederhana ini, terungkap bahwa tidak ada perbedaan yang signifikan antara persentase saccades ekspres untuk ADHD dan kelompok kontrol. Juga tidak ada perbedaan yang signifikan untuk persentase kesalahan arah dalam tugas pro-saccade. Oleh karena itu, atribut ini bukan pembeda yang baik untuk ADHD dan kontrol dan diberi prioritas rendah. Namun, pemisahan terbesar (yaitu, pemisahan terbesar dari distribusi mereka) antara dua kelompok dan variabilitas paling sedikit ditemukan dalam persentase kesalahan arah dalam tugas anti-saccade dan dalam koefisien variasi dalam SRT, menunjukkan mereka prediktor yang kuat. Lebih sedikit pemisahan yang diamati pada latensi rata-rata, tetapi perbedaannya masih signifikan. Gambar 5 menampilkan contoh histogram yang digunakan dalam jenis analisis ini.

Contoh ini, diambil bersama dengan uji-t, menunjukkan bagaimana koefisien variasi dalam SRT (Gbr. 5B) memiliki pemisahan yang lebih baik dan variabilitas yang lebih sedikit daripada SRT (Gbr. 5A) ketika membandingkan ADHD dan kelompok kontrol. Dengan menggunakan analisis ini, deskripsi dan konteks kasus baru dikembangkan. SRT dikelompokkan ke dalam kategori prioritas 0, persentase kesalahan arah dalam tugas anti-saccade dikelompokkan ke dalam kategori prioritas 6, dan koefisien variasi dalam SRT dikelompokkan ke dalam kategori prioritas 8. Prioritas ini relatif dan secara umum mewakili jumlah relaksasi yang diperlukan sebelum kategori tertentu dilonggarkan. Usia juga ditempatkan dalam kategori terpisah seperti pada model sebelumnya. Persentase kesalahan arah dalam tugas pro-saccade dan persentase saccades ekspres tidak termasuk dalam deskripsi kasus ini karena mereka akan ditempatkan dalam kategori prioritas rendah, yang akan sepenuhnya dilonggarkan selama setiap pengambilan.

Keakuratan sistem yang menggunakan deskripsi kasus baru ini (disebut sebagai statistik) sekali lagi ditentukan dengan pengujian tanpa-satu (Tabel 2). Peningkatan lebih lanjut lebih dari 5% dalam sensitivitas dan spesifisitas diwujudkan dengan menggunakan deskripsi kasus baru ini dan set tes.

#### **Model 4 – Algoritma Genetika**

Model sebelumnya menunjukkan bahwa atribut kinerja tidak sama prediktif dan hanya menempatkan mereka dalam kategori mereka sendiri dengan prioritas yang berbeda meningkatkan kinerja sistem. Karena dimensi dan kompleksitas domain yang tinggi, peningkatan kinerja lebih lanjut akan membutuhkan bentuk analisis yang semakin kompleks. Alat penyempurnaan konteks sistem TA3 digunakan untuk membantu penemuan pengetahuan yang lebih kompleks.



**Gambar 19.5** Grafik garis dan uji t berpasangan menunjukkan pemisahan yang lebih baik dan variabilitas nilai atribut yang lebih sedikit dalam koefisien variasi dalam SRT daripada di SRT ketika membandingkan ADHD dan kelompok kontrol. Sementara kedua pemisahan tampak signifikan, dalam contoh ini (Anti-saccade gap-left task) koefisien variasi dalam kondisi SRT menunjukkan pemisahan yang lebih besar dengan variabilitas yang lebih kecil ( $p=0,000$ ) daripada SRT ( $p=0,044$ ) dan dengan demikian ditempatkan pada posisi yang lebih tinggi. kategori prioritas untuk relaksasi konteks. Tren ini diamati untuk semua kondisi.

Menggunakan set pelatihan, alat ini diterapkan pada konteks model sebelumnya (statistik) selama 400 generasi. Konteks yang dihasilkan digunakan untuk membuat deskripsi kasus baru. Namun, tidak ada peningkatan kinerja yang signifikan yang dapat ditemukan dengan menggunakan metode ini, bahkan dengan pengulangan yang berulang. Kegagalan alat ini kemungkinan karena heterogenitas ADHD atau kelompok kontrol. Apakah ada subkelompok alami dalam kelompok ADHD dan Kontrol, yang membuat sulit untuk memisahkan kelompok lebih jauh dengan cara yang berarti? Untuk mendukung hipotesis ini,

ADHD dikenal sebagai gangguan multidimensi, yang mencakup spektrum gejala, di mana faktor-faktor kurangnya perhatian, impulsif, dan hiperaktif mungkin hadir tidak hanya dalam kombinasi yang berbeda, tetapi dengan tingkat keparahan yang berbeda [3]. Selanjutnya, penelitian sebelumnya yang melibatkan tes lain dari gejala ADHD [13, 15, 25] menunjukkan bahwa, sementara mereka tidak dapat digunakan dengan andal dalam diagnosis, mereka berguna untuk mengidentifikasi subkelompok (seperti kasus hiperaktif yang ekstrem).

Salah satu metode untuk menemukan subkelompok yang terjadi secara alami dalam database dikenal sebagai analisis klaster, atau pembelajaran tanpa pengawasan. Dalam jenis analisis ini, komponen (atau kasus) dipisahkan ke dalam cluster yang terjadi secara alami di mana kesamaan intra-grup dimaksimalkan dan kesamaan antar-grup diminimalkan. Ini adalah pendekatan yang diambil di sini. Secara khusus, alat probabilistik (Autoclass C [7]) digunakan untuk memvisualisasikan data dan menentukan jumlah cluster atau outlier yang sesuai yang ada dalam set pelatihan. Autoclass C dipilih karena kemampuannya yang ditunjukkan untuk secara otomatis menentukan jumlah cluster yang sesuai dan ringkasan statistik komprehensif dari cluster tersebut. Ditemukan bahwa kelompok pelatihan ADHD dibagi menjadi tiga kelompok – dua kelompok utama dibedakan pada rata-rata SRT dan persentase kesalahan arah dan satu kelompok outlier.

Kelompok kontrol dibagi menjadi empat kelompok, sekali lagi dibedakan pada rata-rata SRT dan persentase kesalahan arah. Kelompok ADHD dan kontrol dipisahkan menjadi tujuh kelompok ini dan alat penyempurnaan konteks diterapkan di bawah kondisi yang sama seperti sebelumnya. Peningkatan lebih lanjut dalam spesifitas dan sensitivitas diwujudkan, dengan spesifitas sekarang mencapai lebih dari 80% (Tabel 2). Setelah pemeriksaan deskripsi kasus baru, ditemukan bahwa kategori dibiarkan dengan prioritas yang sama, tetapi atribut individu memiliki pengubah rentang yang diterapkan padanya yang mengubah jumlah generalisasi dan pengurangan yang diterapkan. Selain itu, kategori baru dibuat dengan prioritas rendah dan dua variabel SRT ditempatkan di dalamnya (kesenjangan pro-saccade kiri dan pro-saccade tumpang tindih kiri), menunjukkan bahwa mereka tidak dapat diprediksi. Ini adalah jenis perubahan yang kompleks dan atribut khusus dalam transformasi konteks yang akan sulit ditemukan tanpa alat seperti ini. Gambar 6 menampilkan deskripsi kasus akhir yang digunakan oleh sistem.

#### **Penilaian Kesalahan Akhir Menggunakan Data Nyala/Mati**

Setelah tampaknya mencapai puncak kinerja dalam sistem (mengingat alat yang digunakan), penilaian kesalahan akhir dilakukan dengan membandingkan kinerja subjek ADHD yang diklasifikasikan secara salah dan benar saat sedang menjalani pengobatan. Dihipotesiskan bahwa jika beberapa negatif palsu mewakili sub-kelompok nyata dalam data, mereka mungkin menunjukkan manfaat kinerja yang berubah dari pengobatan. Untuk menguji hipotesis ini, uji-t berpasangan dilakukan untuk membandingkan koefisien variasi dalam data SRT untuk setiap subjek yang diklasifikasikan secara salah dan benar dalam kelompok uji (yang diklasifikasikan oleh sistem menggunakan deskripsi kasus yang diturunkan dalam Model 4) sedangkan obat aktif dan tidak aktif (untuk subjek yang memiliki data yang dikumpulkan dalam kedua kondisi). Koefisien variasi dalam data SRT digunakan karena, dengan analisis statistik sebelumnya, itu ditunjukkan sebagai atribut yang paling prediktif

(yaitu, itu adalah variabel yang paling sedikit dan paling terpisah antara ADHD dan kelompok kontrol).

<b>DESCRIPTION</b>	
Subject code: aba	Hyperactivity: 87
Handedness: 10	
Sex: Male	
Impulsivity: 76	
<b>PROBLEM</b>	
<b>Priority 9 – Only generalize once by 10%</b>	
Age: 8	
<b>Priority 8 – Coefficient of Variation</b>	
Anti/Gap/Left:	39.35
Anti/Gap/Right:	50.01
Anti/Over/Left:	42.07
Anti/Over/Right:	44.50
Pro/Gap/Left:	59.82
Pro/Gap/Right:	58.70
Pro/Over/Left:	46.88
Pro/Over/Right:	44.73
<b>Priority 6 – Direction Error (%)</b>	
Anti/Gap/Left:	93.33
Anti/Gap/Right:	75.76
Anti/Over/Left:	77.78
Anti/Over/Right:	62.50
<b>Priority 0 – SRT (ms)</b>	
Anti/Gap/Left:	363.00
Anti/Gap/Right:	458.00
Anti/Over/Left:	351.67
Anti/Over/Right:	483.33
Pro/Gap/Right:	343.06
Pro/Over/Left:	471.24
<b>Priority -13 – SRT (ms)</b>	
Pro/Gap/Left:	338.00
Pro/Over/Left:	431.50
<b>SOLUTION</b>	
Diagnosis: ADHD	

**Gambar 19.6** Deskripsi kasus akhir. SRT = Waktu reaksi saccadic. CV = koefisien variasi dalam SRT. Dir. Kesalahan = Persentase Kesalahan Arah. Anti = Tugas anti-saccade. Pro = Pro-saccade tugas. Over = Kondisi tumpang tindih. Cela = Kondisi celah.

Memang, peningkatan kinerja yang signifikan, seperti yang ditunjukkan oleh penurunan signifikan ( $p<0,05$ ) dalam koefisien variasi dalam SRT (Tabel 3), diamati untuk subjek ADHD yang diklasifikasikan dengan benar saat dalam pengobatan, sementara efek ini tidak ada di antara ADHD yang diklasifikasikan secara salah. mata pelajaran. Subyek yang diklasifikasikan secara tidak benar memiliki perubahan koefisien variasi SRT yang tidak signifikan.

**Tabel 19.3** Perbandingan Subyek ADHD Saat On dan Off Pengobatan  
**Test paradigma**      **Diklasifikasikan dengan benar**    **Salah Diklasifikasikan (N=11)**  
**(N=15)**

	ON (avg.)	OFF (avg.)	p-value	ON (avg.)	OFF (avg.)	p-value
<b>Anti/Gap/Right</b>	34.30	41.07	0.046	29.95	27.25	0.584
<b>Anti/Gap/Left</b>	35.29	40.20	0.200	29.00	33.67	0.293

<b>Anti/Over/Right</b>	35.30	41.29	0.072	31.68	31.24	0.935
<b>Anti/Over/Left</b>	34.47	37.67	0.047	26.67	31.82	0.032
<b>Pro/Gap/Right</b>	40.99	52.04	0.047	43.22	37.47	0.198
<b>Pro/Gap/Left</b>	41.04	50.04	0.025	43.41	36.13	0.203
<b>Pro/Over/Right</b>	42.33	47.69	0.103	41.37	41.54	0.968
<b>Pro/Over/Left</b>	36.87	47.86	0.018	37.83	39.57	0.710

Koefisien rata-rata variasi dalam SRT selama setiap paradigma tes untuk subjek ADHD yang diklasifikasikan dengan benar dan salah saat menjalani dan mematikan pengobatan. Nilai-p dari uji-t berpasangan juga diberikan dan menunjukkan kemungkinan bahwa perbedaan kinerja antara obat aktif dan tidak aktif akan muncul secara kebetulan. Anti = Tugas anti-saccade. Pro = Tugas pro-saccade. Over = Kondisi tumpang tindih. Celah = Kondisi celah.

## 19.5 DISKUSI

Variabel kinerja Saccade mampu membedakan ADHD dari anak-anak kontrol dengan akurasi lebih dari 70% (Tabel 2). Ini adalah langkah menuju penggunaan metrik tersebut dalam pengaturan klinis. Kepentingan relatif dari variabel-variabel ini dinilai dan koefisien variasi dalam SRT ditentukan paling berguna untuk memprediksi ADHD dan membedakan subjek ADHD dari kontrol, sementara SRT dan persentase kesalahan arah dalam tugas anti-saccade memiliki utilitas sedang. Hasil ini sesuai dengan penelitian sebelumnya [29] dan mendukung hipotesis bahwa penghambatan impuls pada subjek ADHD dapat diukur melalui kinerja saccade dan dapat digunakan sebagai cara untuk membedakan mereka dari kontrol. Investigasi negatif palsu mengungkapkan bahwa subjek tersebut tidak menunjukkan peningkatan yang signifikan dalam kinerja saccade saat dalam pengobatan, sedangkan peningkatan yang ditunjukkan oleh hasil positif yang sebenarnya selama pengobatan adalah signifikan.

Sistem CBR berhasil membedakan subkelompok yang bermakna dalam basis kasus dan berpotensi memiliki utilitas klinis. Subkelompok ini dapat berupa kasus yang salah didiagnosis (dengan metode klinis saat ini) atau subkelompok yang terjadi secara alami dalam gangguan yang tidak merespon dengan baik terhadap pengobatan. Fakta bahwa set tes dipisahkan menjadi subkelompok yang bermakna juga mendukung hasil dari metodologi penyempurnaan berulang. Karena kumpulan data harus dipisahkan menjadi dua kelompok untuk menggunakan pendekatan ini (satu untuk pelatihan/eksplorasi dan satu untuk pengujian), ada bahaya efek seleksi. Seiring bertambahnya kumpulan data, ini akan menjadi kurang menjadi perhatian. Jumlah subyek yang sudah besar dan kemampuan sistem untuk mengenali subkelompok yang signifikan dalam kelompok ADHD saat ini menunjukkan bahwa peningkatan kinerja yang dicapai melalui metodologi ini bermakna.

Hasil penelitian ini sebanding dengan penelitian tentang Tes Kinerja Kontinu (CPT) [34], yang kemungkinan merupakan tes laboratorium objektif paling populer yang digunakan untuk menilai perhatian dan kewaspadaan. Kegunaan CPT tetap kontroversial: penelitian telah menunjukkan bahwa subjek ADHD melakukan lebih buruk daripada kontrol normal (misalnya, [24]) sementara yang lain telah menemukan bahwa itu tidak dapat membedakan subjek ADHD dari kontrol yang dirujuk (misalnya, [25]). Namun, beberapa penelitian telah menemukan

bahwa CPT mungkin berguna untuk mengidentifikasi subkelompok yang signifikan dalam gangguan seperti subjek yang terlalu aktif secara signifikan [25] atau subjek yang mencapai skor perilaku yang lebih tinggi [13]. Edwards dkk. [10] juga menemukan bahwa CPT paling berguna dalam mengidentifikasi subtipenya hiperaktif-impulsif dari gangguan tersebut, tetapi secara keseluruhan masih menunjukkan performa terbaik. Kegunaan tes seperti CPT dan sistem CBR yang dikembangkan di sini adalah kemampuannya untuk memberikan informasi yang berguna untuk penilaian neuropsikologis yang komprehensif, bukan penggunaannya secara terpisah.

Konsentrasi metodologi perbaikan berulang adalah pada penggunaan teknik akuisisi pengetahuan untuk mengembangkan deskripsi kasus yang lebih relevan dan penilaian kesamaan. Hal ini memungkinkan sistem TA3 untuk mengambil keuntungan dari hubungan yang lebih kompleks, dalam bentuk konteks, untuk mengimbangi kurangnya strategi adaptasi. Seperti disebutkan, Cunningham dan Bonzano [8] menggunakan pendekatan serupa untuk mengembangkan sistem ISAC (Sistem Intelijen untuk Resolusi Konflik Pesawat) dalam domain kontrol lalu lintas udara. Seperti halnya sistem yang dikembangkan di sini, meskipun pengembangannya tidak lurus ke depan, CBR masih memiliki manfaat dari pendekatan model umum karena fakta bahwa ia menghindari banyak kebutuhan untuk memahami hubungan sebab akibat yang mendasari dalam domain tersebut. Perbedaan utama antara ISAC dan sistem yang dikembangkan di sini adalah ISAC digunakan untuk tugas perencanaan, sedangkan sistem ini digunakan untuk tugas klasifikasi dalam domain medis.

Strategi penyempurnaan berulang untuk pengembangan CBR tampaknya berlaku di seluruh domain dan tugas. Bukti lebih lanjut untuk penerapannya dalam pendukung keputusan medis disediakan oleh sistem yang dikembangkan oleh Frise dan Walker [14] dan Althoff dan rekan [2]. Frise dan Walker menggunakan strategi tersebut dalam pengembangan sistem untuk menentukan status pasien, diagnosis, dan terapi dalam pengaturan perawatan intensif. Althoff dan rekan menggunakan pendekatan Inreca (Induksi dan Penalaran dari Kasus), bersama dengan strategi pengembangan tambahan, untuk mengembangkan sistem yang dapat dengan cepat membantu dalam diagnosis dan pengobatan kasus keracunan. Satu kesulitan tambahan dalam pengembangan sistem ADHD ini adalah kurangnya umpan balik oleh para ahli (misalnya, dokter) pada setiap model. Penggunaan parameter saccade dalam diagnosis ADHD tidak terbukti dan oleh karena itu akan sulit bagi dokter untuk mengomentari kegunaan kasus yang kembali saat ini. Namun, evaluasi sistem masih dimungkinkan melalui penelitian, pendekatan statistik sederhana dan metode penemuan pengetahuan otomatis yang lebih kompleks.

## **19.6 KESIMPULAN**

Dalam bab ini kami menjelaskan metodologi penyempurnaan berulang yang digunakan untuk mengembangkan model CBR yang dapat membedakan ADHD dari subjek kontrol normal, berdasarkan kinerja saccade, dengan akurasi yang meningkat. Itu menunjukkan bahwa banyak negatif palsu mewakili subkelompok yang signifikan dalam kelompok ADHD.

Kinerja sistem ini kemungkinan akan meningkat secara signifikan dengan penambahan kasus baru dan tambahan pengetahuan. Satu masalah yang diidentifikasi ketika bekerja

dengan basis kasus ini adalah kebutuhan akan lebih banyak kasus dalam setiap kelompok usia masing-masing. Dengan basis kasus yang lebih besar, subjek dapat dibatasi untuk usia individu, bukan kelompok, dan mungkin bahkan kategori sub-tahun dalam kasus anak-anak yang lebih muda yang skor kinerjanya berubah sangat dan cepat. Ini juga akan memungkinkan untuk diterapkannya batasan-batasan lain, seperti jenis kelamin. Ketika kasus dan pengetahuan baru tersedia, mereka dapat dimasukkan ke dalam sistem melalui skema pemeliharaan berbasis kasus.

Selain itu, hubungan yang lebih kompleks dalam data dapat ditemukan untuk memungkinkan konteks yang lebih kompleks digunakan untuk pengambilan. Pengetahuan baru ini dapat dijelaskan melalui teknik statistik dan akuisisi data yang lebih canggih. Sebagai pemahaman yang lebih besar dari domain terungkap, penggunaan strategi adaptasi yang lebih maju dan kasus prototipikal dapat menjadi layak. Penggunaan teknik akuisisi pengetahuan yang lebih rumit akan menjadi lebih umum di bidang CBR karena domain yang lebih kompleks ditangani. Penelitian ini memberikan dukungan yang baik untuk gagasan itu. Akhirnya, kinerja dapat ditingkatkan dengan penambahan kategori hasil pada kasus. Hasil ini dapat didasarkan pada diagnosis yang diberikan oleh sistem. Misalnya, kasus yang diklasifikasikan dengan benar akan diberi bobot lebih saat mendiagnosis kasus baru. Dengan cara ini, sistem juga dapat memberikan bobot pada diagnosis akhir, yang akan lebih berguna dalam mendukung keputusan daripada keluaran biner.

Selain melanjutkan strategi penyempurnaan dengan teknik baru dan lebih rumit, sistem ini dapat diterapkan ke bidang terkait lainnya (seperti Parkinson, Sindrom Tourette, dan Huntington) dan dalam hubungannya dengan tes objektif lainnya dari perhatian, impulsivitas dan hiperaktif. Diagnosis multi-sumber yang saat ini digunakan untuk diagnosis ADHD juga merupakan kandidat yang baik untuk CBR. Para ahli dapat memberikan umpan balik dan pemberian yang berharga untuk mengotomatisasi sebagian dan mungkin menghilangkan beberapa subjektivitas dari proses. CBR dapat mengkonsolidasikan berbagai informasi yang saat ini digunakan untuk mendiagnosis ADHD, dengan yang diperoleh dari tes yang lebih objektif seperti kinerja saccade dan CPT, ke dalam database yang dapat digunakan oleh dokter untuk meninjau dan membandingkan kasus. Meskipun tidak ada tes singkat yang mungkin untuk mendiagnosis ADHD secara meyakinkan, dengan kemampuannya yang ditunjukkan untuk mendeteksi kelompok subjek ADHD yang bermakna, sistem ini dapat memberikan kontribusi yang berguna secara klinis untuk diagnosis ADHD multi-sumber.

## BAB 20

### PENDEKATAN NEUROKOGNITIF UNTUK PENGAMBILAN KEPUTUSAN UNTUK REKONSTRUKSI PROFIL INSULIN METABOLIK ORANG SEHAT

Pengambilan keputusan manusia didefinisikan sebagai proses kognitif di mana pilihan yang lebih disukai atau tindakan dipilih dari antara serangkaian alternatif, berdasarkan informasi atau pertimbangan tertentu. Salah satu aspek penting dari pengambilan keputusan adalah untuk memfasilitasi respon yang tepat untuk lingkungan yang dinamis dan tidak pasti. Pengambilan keputusan dinamis secara inheren kompleks, dan dicirikan oleh banyak keputusan, saling bergantung, dan waktu nyata, yang terjadi dalam lingkungan yang dapat berubah secara independen sebagai fungsi dari urutan tindakan. Untuk memperoleh tingkat kemahiran tertentu dalam proses pengambilan keputusan seperti itu, para pembuat keputusan sering kali harus menjalani latihan yang panjang. Ini kemudian menyiratkan bahwa pengambilan keputusan dalam lingkungan yang dinamis didasarkan pada pengalaman, dan selanjutnya memperkuat gagasan pengambilan keputusan dinamis sebagai keterampilan kognitif yang dapat dikembangkan melalui latihan. Seperti perolehan keterampilan kognitif lainnya, pembuat keputusan meningkatkan keterampilan pengambilan keputusan mereka melalui akumulasi, pengakuan dan penyempurnaan episode keputusan yang dihadapi. Penting untuk pengembangan keterampilan kognitif termasuk pengambilan keputusan yang dinamis adalah kemampuan untuk memperoleh pengetahuan baru (belajar) dan untuk mempertahankan pengetahuan tersebut untuk referensi masa depan (memori). Sistem memori prosedural manusia adalah aspek dari struktur komputasi otak yang menunjukkan kapasitas untuk belajar dan memori, dan merupakan susunan yang luas dari basis pengetahuan yang dikalibrasi dengan cermat untuk perilaku dan keterampilan terkoordinasi yang diwujudkan dalam kehidupan sehari-hari. Bab ini menjelaskan penggunaan model memori pembelajaran berbasis otak yang dilihami oleh otak bernama PSECMAC untuk secara fungsional memodelkan proses pengambilan keputusan otonom dalam lingkungan yang dinamis, kompleks, dan tidak pasti. Jaringan PSECMAC terutama dimodelkan setelah mekanisme pembelajaran serebelar di mana pelatihan berulang menginduksi kesetiaan dan ketepatan yang lebih besar dalam pengetahuan yang diperoleh. PSECMAC menggunakan skema kuantisasi adaptif yang digerakkan oleh pengalaman untuk membangun struktur komputasinya dengan mengalokasikan lebih banyak sel memori ke wilayah signifikan dari ruang fitur rangsangan input. Validitas pendekatan neurokognitif untuk pengambilan keputusan ini selanjutnya dievaluasi dengan menggunakan model memori pembelajaran PSECMAC untuk secara dinamis memodelkan proses pengambilan keputusan otonom regulasi insulin dalam kontrol fisiologis proses metabolisme glukosa manusia. Tujuan dari penelitian ini adalah untuk memperkirakan dinamika metabolisme insulin dari subjek yang sehat dalam menanggapi asupan makanan. Dalam hal ini, regulasi fisiologis insulin dapat dianggap sebagai contoh biologis dari proses pengambilan keputusan yang dinamis di mana tubuh manusia secara dinamis menentukan jumlah insulin yang diperlukan untuk mempertahankan

homeostasis tubuh sebagai respons terhadap gangguan makanan. Hasil percobaan awal menggembirakan.

## **20.1 PENDAHULUAN**

Pengambilan keputusan manusia didefinisikan sebagai proses kognitif di mana pilihan yang lebih disukai atau tindakan dipilih dari antara serangkaian alternatif, berdasarkan informasi atau pertimbangan tertentu [1]. Ini membentuk komponen vital dan integral dari kehidupan kita sehari-hari, dan contoh umum berkisar dari keputusan sepele seperti apa yang harus dimakan atau di mana berbelanja, hingga keputusan yang lebih rumit, seperti memutuskan langkah paling menguntungkan berikutnya dalam permainan catur atau memikirkan bagaimana memanfaatkan peluang bisnis baru. Proses pengambilan keputusan manusia melibatkan pengumpulan dan pemrosesan pilihan alternatif yang tersedia saat ini; mengintegrasikannya dengan hasil yang diharapkan berdasarkan ingatan dari pertemuan sebelumnya, serta evaluasi pilihan selanjutnya sehubungan dengan tujuan yang diinginkan [2,3]. Pengambilan keputusan ada di mana-mana dalam kehidupan sehari-hari dan itu tercermin melalui respons perilaku kita. Karena masing-masing dari kita berperilaku berbeda dan bervariasi dalam tanggapan kita terhadap banyak sekali pilihan, oleh karena itu sangat menarik untuk mempelajari mekanisme kognitif dan kemampuan yang mendasari proses pengambilan keputusan manusia, sehingga dapat mengidentifikasi faktor afektif dan pembeda di balik proses pengambilan keputusan. perbedaan kinerja masing-masing pengambil keputusan.

Sebuah aspek penting dari pengambilan keputusan adalah untuk memfasilitasi respon yang tepat untuk lingkungan yang dinamis dan tidak pasti. Pengambilan keputusan yang dinamis dicirikan oleh keputusan yang multipel, saling bergantung, dan waktu nyata, yang terjadi dalam lingkungan yang berubah secara independen sebagai fungsi dari serangkaian tindakan [4, 5]. Proses pengambilan keputusan seperti itu secara dinamis kompleks, karena melibatkan penundaan waktu dan keputusan yang dapat secara positif atau negatif mempengaruhi satu sama lain dengan cara yang rumit. Untuk menetapkan tingkat tertentu dari hubungan kausal dan temporal yang logis dan masuk akal dari keputusan dan hasil dalam keadaan dinamis ini, para pembuat keputusan sering kali harus menjalani praktik yang panjang [6]. Ini kemudian menyiratkan bahwa pengambilan keputusan dalam lingkungan yang dinamis didasarkan pada pengalaman, dan selanjutnya memperkuat gagasan pengambilan keputusan dinamis sebagai keterampilan kognitif yang dapat diperoleh melalui latihan. Memang, penelitian baru-baru ini untuk memahami bagaimana keterampilan pengambilan keputusan dikembangkan dalam situasi dinamis telah mengungkapkan bahwa, dari waktu ke waktu, ada peningkatan penggunaan akumulasi pengetahuan sebelumnya dan pengalaman masa lalu oleh pembuat keputusan untuk memfasilitasi pemikiran mereka. proses [7].

Keterampilan kognitif, di sisi lain, didefinisikan sebagai kemampuan untuk menggunakan pengetahuan seseorang secara efektif dan siap dalam pelaksanaan proses kognitif [8]. Dengan mengacu pada perolehan keterampilan kognitif, belajar dari contoh telah ditetapkan sebagai penyebab utama yang mendorong transisi bertahap dari kinerja pemula yang lambat dan melelahkan ke pelaksanaan perilaku terampil yang cepat dan akurat oleh seorang ahli [9]. Dipercaya secara luas bahwa setiap proses pengembangan keterampilan

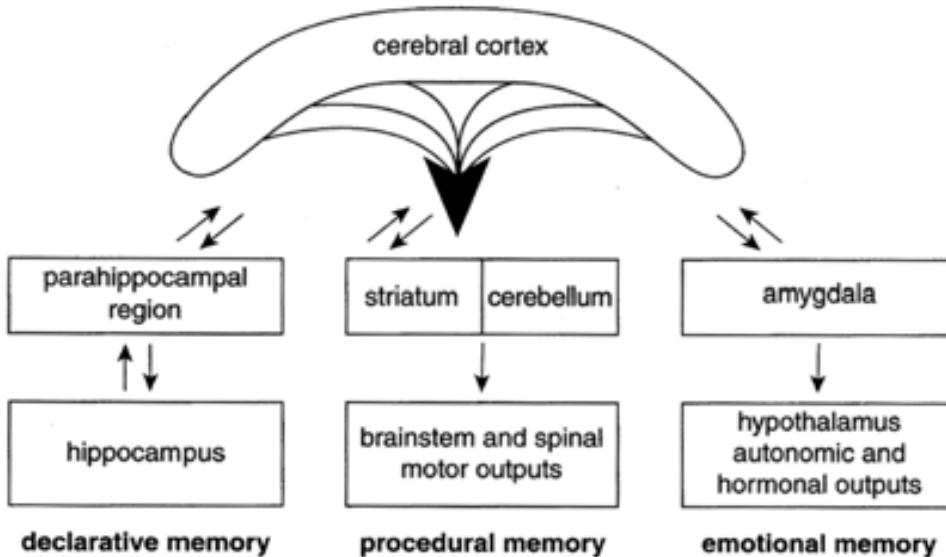
membutuhkan individu untuk maju melalui serangkaian tahap pembelajaran dan melibatkan beberapa bentuk memori untuk retensi pengetahuan yang diperoleh [8-10]. Berdasarkan model tiga tahap akuisisi keterampilan Fitts dan Posner yang mapan [11, 12], pembelajaran dihipotesiskan untuk melanjutkan melalui tiga fase perkembangan berturut-turut: fase kognitif, fase asosiatif, dan fase otonom. Dalam model ini, dianggap bahwa komponen penting dari pembelajaran keterampilan terletak pada kemampuan individu untuk membedakan dan menyaring subset rangsangan yang penting untuk kinerja perilaku terampil.

Pembelajaran dimulai dengan fase kognitif, di mana pelajar secara sadar mencoba untuk membentuk pemahaman umum tentang tugas yang dilakukan, dan satu set informasi yang berkaitan dengan tugas tersebut diakumulasikan dan disimpan dalam memori. Informasi yang tersimpan ini membentuk blok bangunan dasar dari basis pengetahuan yang akan diperoleh dari proses pembelajaran. Pada fase ini, pemrosesan informasi secara mental lambat dan membosankan, dan membutuhkan banyak sumber daya kognitif. Dalam fase asosiatif, individu belajar untuk merespon lebih efisien dengan mempertahankan tindakan yang efektif dan menghilangkan yang tidak efektif. Pengalaman dan paparan berulang pada episode pembelajaran berfungsi untuk memperkuat fitur yang menonjol dari keterampilan, dan ketika kinerja diulang, subjek mempelajari pola baru untuk merespons dengan mengenali isyarat dan rangsangan yang lebih signifikan daripada yang lain, sehingga mengarahkan perhatian ke arah itu. isyarat. Pola-pola asosiasi ini membentuk basis pengetahuan untuk perhatian-arah pelajar.

Sebagai pelajar menjadi kompeten dalam tugas, diskriminasi rangsangan eksogen dan isyarat dilakukan lebih cepat dan melibatkan tingkat kesadaran yang lebih rendah. Fase otonom mengacu pada tahap di mana proses diskriminasi ini dilakukan secara tidak sadar, memungkinkan seorang ahli tugas untuk membedakan dengan sangat cepat banyak rangsangan dan untuk fokus pada isyarat yang sangat spesifik. Pengetahuan mendalam seorang ahli, yang terakumulasi melalui praktik berulang, memungkinkan pengakuan keterkaitan antara elemen masalah yang tidak tersedia untuk pemula [9].

Seperti perolehan keterampilan kognitif lainnya, pembuat keputusan meningkatkan keterampilan pengambilan keputusan mereka melalui akumulasi, pengakuan dan penyempurnaan episode keputusan yang dihadapi [7, 8]. Keterampilan tersebut dikembangkan terutama melalui pengenalan fitur yang menonjol dan peningkatan keakraban untuk setiap episode masa lalu. Pengetahuan tentang episode keputusan sebelumnya menjadi faktor pembeda utama antara pemula dan pembuat keputusan ahli. Pengambil keputusan pemula mengikuti heuristik keputusan lebih dekat, menghasilkan efisiensi yang lebih rendah karena pencarian lengkap untuk fitur akrab dalam ingatan mereka. Pembuat keputusan yang terampil, di sisi lain, memanfaatkan akumulasi pengetahuan sebelumnya untuk melakukan pencarian terpandu yang sangat selektif, perhatian dan dipicu episodik untuk mencapai efisiensi komputasi yang besar. Pengambilan keputusan dinamis adalah keterampilan yang berkembang melalui pembelajaran dan perolehan pengetahuan spesifik domain, dan bahwa mekanisme yang mendasari proses akuisisi pengetahuan ini melibatkan akumulasi dan pengambilan contoh keputusan [7, 13-15]. Oleh karena itu, perkembangan proses pengambilan keputusan manusia membutuhkan kemampuan untuk memperoleh pengetahuan baru (pembelajaran) dan menyimpan informasi tersebut untuk penggunaan

masa depan (memori). Belajar dan memori adalah kemampuan kognitif yang dilayani oleh koneksi masif dari sirkuit otak.



**Gambar 20.1** Kerangka kerja yang terinspirasi secara anatomis dari sistem memori utama manusia. Diadaptasi dari [16].

Otot manusia tidak diragukan lagi masih merupakan mesin komputasi paling kuat yang tersedia saat ini, di mana jaringan kompleks neuron berkolaborasi dengan cara yang sangat non-linear untuk menciptakan struktur komputasi informasi yang masif. Sebagai bagian dari upaya untuk memahami proses pengambilan keputusan manusia, ilmu neurokognitif digunakan untuk mempelajari mekanisme yang mendasari perolehan keterampilan kognitif. Yaitu, belajar dan memori. Tujuan utamanya adalah untuk mempelajari dan mengembangkan model fungsional dari sistem otak yang menunjukkan kemampuan untuk belajar dan memperoleh pengetahuan dari input eksogen dan kapasitas untuk menyimpan pengetahuan yang diperoleh untuk penggunaan selanjutnya. Hal ini kemudian mengarah pada konstruksi model komputasi sistem memori pembelajaran, yang bertujuan untuk memberikan deskripsi fungsional mekanisme dan proses yang terlibat dalam pembelajaran dan pembentukan memori. Model fungsional seperti itu, bagaimanapun, tidak berusaha untuk menggambarkan setiap detail fisiologis dari sistem memori yang sesuai di otak. Sebaliknya, mereka berusaha untuk meniru fakultas kognitif tingkat yang lebih tinggi yang bertanggung jawab untuk belajar dan memori. Meskipun akan menarik untuk membangun model yang lebih realistik secara fisiologis, ini jelas tidak mungkin mengingat terbatasnya pengetahuan yang dimiliki seseorang tentang cara kerja bagian dalam otak manusia saat ini.

Studi neurofisiologis pada memori manusia dan hewan telah menetapkan adanya beberapa sistem otak yang bertanggung jawab untuk pembentukan memori, yaitu memori deklaratif (eksplisit), prosedural (implisit) dan emosional [16]. Secara anatomic, masing-masing jalur pemrosesan memori ini berbeda, dan dimediasi oleh sistem fungsional yang berbeda di otak (lihat Gambar 1). Masing-masing jalur informasi ini bertanggung jawab untuk pemrosesan persepsi, motorik, atau kognitif masing-masing, dan melayani ingatan dari domain yang sama. Yang menarik untuk studi pengambilan keputusan di tingkat otonom adalah sistem memori prosedural, yang terdiri dari striatum dan otak kecil [16]. Keterlibatan

diduga jalur pemrosesan informasi ini dalam perolehan respons perilaku tertentu telah menyebabkan banyak peneliti mempertimbangkan sistem ini sebagai khusus untuk kebiasaan atau memori keterampilan [17]. Jalur memori prosedural merupakan susunan tak berujung dari basis pengetahuan yang dikalibrasi dengan cermat untuk perilaku terkoordinasi dari kebiasaan dan keterampilan yang dimanifestasikan dalam kehidupan sehari-hari. Ada dua karakteristik utama dari sistem memori prosedural. Pertama, pengambilan pengetahuan dari memori prosedural dilakukan secara tidak sadar. Kedua, sistem memori prosedural terus diperbarui oleh pengalaman dan disesuaikan dengan paparan berulang terhadap episode pembelajaran. Karakteristik ini mendasari kemampuan sistem memori prosedural untuk memperoleh repertoar kebiasaan dan keterampilan yang luas, menghasilkan kapasitas individu selanjutnya untuk menampilkan berbagai manifestasi perilaku stereotipik dan tidak sadar.

Bab ini mengusulkan penggunaan model memori pembelajaran berbasis otak yang diilhami otak bernama Pseudo Self-Evolving Cerebellar Model Articulation Controller (PSECMAC) untuk secara fungsional memodelkan proses pengambilan keputusan dinamis otonom. Menarik inspirasi dari pemahaman neurofisiologis dari otak kecil manusia, PSECMAC tampil sebagai model komputasi dari rekan biologisnya dan berguna untuk pembelajaran dan perolehan pengetahuan dalam lingkungan yang dinamis, kompleks dan tidak jelas. Dalam bab ini, jaringan PSECMAC digunakan untuk memodelkan profil insulin dari proses metabolisme glukosa manusia ketika terganggu oleh asupan makanan. Tubuh manusia memiliki kapasitas yang diatur dengan baik untuk secara mandiri mempertahankan homeostasis dari berbagai proses biologis dan fisiologis tanpa pengawasan sukarela dan sadar.

Pengaturan proses metabolisme glukosa melalui kontrol insulin yang cermat adalah salah satu dari proses tersebut. Artinya, mekanisme pengaturan insulin-glukosa alami tubuh manusia mewakili proses pengambilan keputusan otonom yang dikalibrasi dengan cermat dan halus untuk lingkungan yang dinamis yaitu siklus metabolisme glukosa. Ini memberikan dukungan yang memperkuat gagasan bahwa PSECMAC dapat digunakan untuk memodelkan pengetahuan yang melekat yang mendorong keputusan otonom mekanisme alami tubuh dalam mengeluarkan jumlah insulin yang tepat secara efisien untuk mengatur kadar glukosa darah dalam batas fisiologis yang ketat. Ini merupakan komponen kunci utama dalam keberhasilan pengelolaan diabetes Tipe I, di mana PSECMAC dapat digunakan untuk mereplikasi profil insulin yang bertanggung jawab untuk mempertahankan keadaan dekat-normoglikemia jangka panjang dari pasien diabetes. Artinya, dalam upaya mengembangkan rezim pengobatan yang ideal untuk pasien diabetes tipe I, kemampuan untuk menghitung keputusan yang tepat tentang jumlah insulin yang dikeluarkan sebagai respons terhadap gangguan proses metabolisme glukosa oleh gangguan eksogen akibat konsumsi makanan adalah langkah awal tapi signifikan.

Sisa bab ini disusun sebagai berikut. Bagian 2 secara singkat menjelaskan aspek neurofisiologis memori dan pembelajaran di otak kecil yang mengilhami pengembangan model memori pembelajaran PSECMAC. Bagian 3 menguraikan arsitektur jaringan PSECMAC yang diusulkan dan menyoroti pembentukan memori yang diilhami serebelum dan mekanisme pembelajaran yang digerakkan oleh pengalaman jaringan. Bagian 4 menyajikan gambaran umum tentang diabetes dan protokol pengobatan saat ini yang tersedia, serta

memotivasi regulasi fisiologis insulin dalam proses metabolisme glukosa manusia sebagai contoh biologis pengambilan keputusan otonom. Bagian 5 menunjukkan kemampuan pemodelan dinamis dari jaringan PSECMAC yang diusulkan dengan menggunakannya untuk memodelkan profil insulin darah dari subjek yang sehat. Bagian 6 menyimpulkan bab ini.

## **20.2 CEREBELLUM DAN SISTEM MEMORI PROSEDURAL MANUSIA**

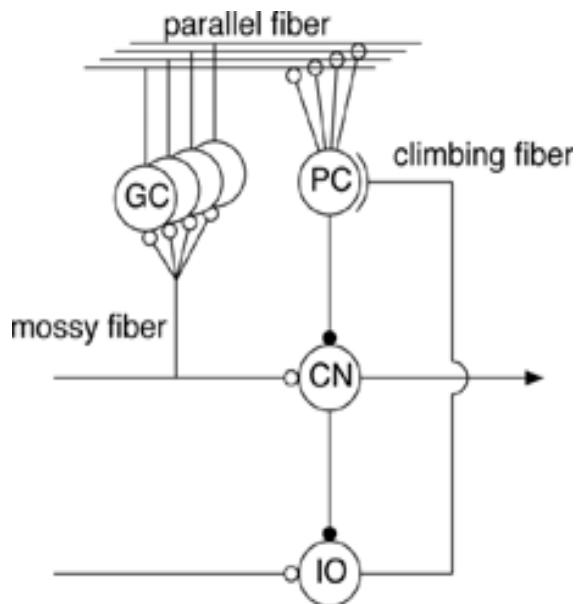
Aspek yang paling mendalam dan menarik dari kecerdasan manusia adalah kapasitas untuk belajar dan mengingat. Belajar didefinisikan sebagai proses yang menghasilkan perubahan yang konsisten dalam respons perilaku (karena pengetahuan yang dipelajari) melalui paparan berulang terhadap rangsangan lingkungan [9] dan memori adalah penyimpanan pengetahuan yang diperoleh ini [18]. Sistem memori prosedural manusia adalah aspek dari kapasitas komputasi informasi otak, yang mewakili sistem memori pembelajaran untuk keterampilan dan prosedur. Karena sifat ingat bawah sadar dari jalur memori tertentu, sistem memori prosedural juga sering disebut sebagai memori "pengetahuan implisit" [19].

Sistem memori prosedural manusia terdiri dari otak kecil dan striatum [16]. Karena organisasi saraf struktural dan kesederhanaan anatomi, otak kecil mungkin salah satu dari sedikit konstruksi di sistem saraf pusat di mana pola koneksi intrinsik diketahui secara cukup rinci [20]. Fakta bahwa korteks serebelar memiliki anatomi yang paling teratur dari setiap wilayah otak telah memungkinkan peneliti ilmu saraf untuk memperoleh sejumlah hubungan neurofisiologis penting pada mekanisme kerja otak kecil manusia. Ini pada gilirannya menawarkan banyak informasi tentang aspek fungsional dan fisiologis otak kecil. Cerebellum, yang dalam bahasa Latin berarti otak kecil, merupakan wilayah otak yang penting untuk sejumlah fungsi motorik dan kognitif, termasuk pembelajaran dan memori [21, 22].

Meskipun fungsi otak kecil terutama sebagai pengatur gerakan [23], ada pengamatan yang menunjukkan bahwa otak kecil juga memainkan peran aktif dalam tugas-tugas kognitif murni [24]. Studi neuroimaging fungsional yang dilakukan oleh Desmond dan rekan-rekannya [25] telah mengungkapkan jejak bukti keterlibatan otak kecil dalam aktivasi memori kerja, pembelajaran dan memori implisit dan eksplisit, serta pemrosesan bahasa. Dukungan lebih lanjut untuk keberadaan fungsi kognitif yang terkait dengan otak kecil berasal dari studi lesi, di mana diamati bahwa pasien dengan arteri serebelar inferior posterior yang tersumbat mengalami kesulitan dalam mempelajari tugas asosiasi kata [17]. Pada bagian ini, sifat anatomi dan fisiologis yang mendasari yang memfasilitasi dan melayani akuisisi pengetahuan dan kemampuan retensi informasi dari otak kecil disajikan.

### **Mekanisme Retensi Informasi di Otak Kecil**

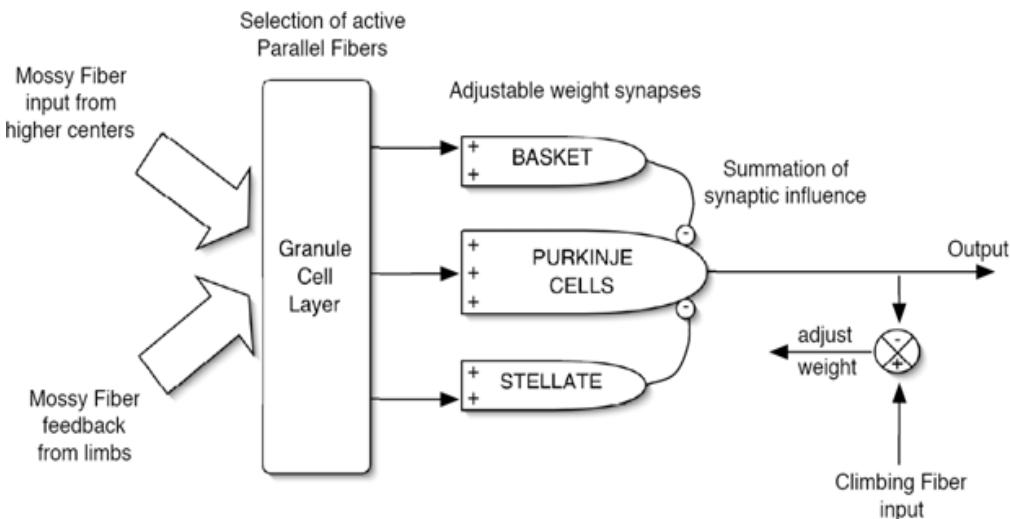
Cerebellum terletak di bagian belakang bawah kepala (otak belakang) tepat di atas batang otak dan sangat dikenal karena keteraturan strukturalnya dan struktur anatominya yang hampir kristal. Namun, meskipun struktur anatominya sangat seragam, serebelum dibagi menjadi beberapa daerah yang berbeda, yang masing-masing menerima proyeksi dari bagian yang berbeda dari otak dan sumsum tulang belakang dan memproyeksikan ke sistem motorik yang berbeda. Fitur ini menunjukkan bahwa daerah yang berbeda dari otak kecil melakukan operasi komputasi yang sama tetapi pada input yang berbeda [17].



**Gambar 20.2** Diagram sirkuit serebelar. GC - Sel Granul; PC - Sel Purkinje; CN - Inti Cerebellar Dalam; IO - Zaitun Rendah. Diadaptasi dari [28].

Untuk melakukan fungsi regulasi motoriknya secara efektif, otak kecil dilengkapi dengan informasi ekstensif tentang tujuan (niat), tindakan (perintah motorik) dan hasil (sinyal umpan balik) yang terkait dengan gerakan [26]. Ada tiga set aferen ekstra serebelar: serat berlumut dan serat panjat, keduanya membawa informasi sensorik dari perifer serta set informasi terkait perintah dari korteks serebral; dan satu set aferen mono-armigenik dan kolinergik, yang diperkirakan memberi sinyal penghargaan [27]. Serabut berlumut membawa informasi yang berasal dari medula spinalis dan batang otak, sedangkan serabut panjat berasal dari olivarius inferior di medula oblongata.

Masukan aferen ke serebelum mengalir ke lapisan sel granula, yang merupakan lapisan masukan korteks serebelum. Masukan serat berlumut, yang membawa sinyal aferen sensorik dan eferen serebral, disampaikan oleh sejumlah besar sel granula. Sel-sel granula ini bekerja sebagai encoder ekspansi dari sinyal input serat berlumut, menggabungkan input serat berlumut yang berbeda. Masing-masing memanjang akson asenden yang naik ke lapisan molekuler korteks serebelar sebagai serat paralel, yang selanjutnya berfungsi sebagai input ke sel Purkinje di korteks serebelum. Sel Purkinje adalah unit komputasi utama dari korteks serebral, di mana masing-masing sel menarik input dari serat paralel, serat panjat, serta sel bintang dan keranjang penghambat. Serat paralel berjalan tegak lurus ke arborisasi dendritik seperti kipas datar dari sel Purkinje, memungkinkan jumlah terbesar serat paralel dan kontak sel Purkinje per unit volume. Sel Purkinje melakukan kombinasi linier dari input sinaptik, dan aksonnya membawa output dari korteks serebelar ke bawah ke materi putih yang mendasari ke inti serebelar dalam. Keluaran dari nukleus serebelum profunda membentuk keluaran keseluruhan dari serebelum. Gambar 2 menggambarkan diagram sirkuit serebelum.



**Gambar 20.3** Diagram Skema dari Cerebellum. Diadaptasi dari [29].

Pembentukan memori di otak kecil difasilitasi oleh ingatan informasi jangka panjang yang tertanam di setiap koneksi sinaptiknya. Otak kecil dapat divisualisasikan sebagai sistem memori asosiatif, yang melakukan pemetaan nonlinier antara input serat berlumut dan output sel Purkinje. Pemetaan ini digambarkan pada Gambar 3. Lapisan sel granul pada dasarnya adalah lapisan asosiasi yang menghasilkan representasi input serat berlumut yang jarang dan diperluas. Hubungan sinaptik antara serat paralel dan dendrit sel Purkinje membentuk susunan bobot sinaptik yang dapat dimodifikasi dari sistem komputasi. Susunan sel Purkinje kemudian membentuk basis pengetahuan otak kecil, dan menghasilkan keluaran dari sistem memori dengan mengintegrasikan koneksi sinaptik masukannya.

#### Mekanisme Pembelajaran di Otak Kecil

Serebelum berfungsi terutama sebagai pengatur gerakan, dan meskipun tidak penting untuk kontrol motorik, sangat penting untuk koordinasi gerakan yang tepat, cepat dan halus. Ini mencapai perannya dalam mempengaruhi koordinasi sistem motorik dengan mengevaluasi perbedaan antara niat dan tindakan dan kemudian menyesuaikan operasi pusat motorik untuk mempengaruhi dan mengatur gerakan tertentu yang sedang berlangsung. Neuroscience telah menetapkan bahwa otak kecil menjalankan fungsinya dengan melakukan pemetaan asosiatif dari input sensorik aferen dan sinyal eferen serebral ke output dari otak kecil, yang kemudian ditransmisikan kembali ke korteks serebral dan sumsum tulang belakang melalui talamus [29-33]. Proses fisiologis membangun peta pola asosiatif ini merupakan mekanisme pembelajaran neuronal yang mendasari di otak kecil. Fakta bahwa otak kecil diberikan informasi yang luas tentang tujuan, perintah, dan sinyal umpan balik yang terkait dengan gerakan tertentu, menandakan bahwa otak kecil mengadopsi paradigma pembelajaran terawasi yang digerakkan oleh koreksi kesalahan. Ini juga menyiratkan bahwa pembelajaran di otak kecil memerlukan percobaan yang diperpanjang dengan paparan berulang terhadap urutan gerakan yang serupa untuk mencapai pemetaan yang dikalibrasi dengan baik dengan ketepatan yang tinggi terhadap koreksi kesalahan antara pelaksanaan gerakan motorik yang dimaksudkan dan yang sebenarnya.

Cerebellum merupakan bagian dari sistem memori prosedural manusia untuk kebiasaan dan keterampilan, yang mengalami adaptasi terus menerus sepanjang rentang

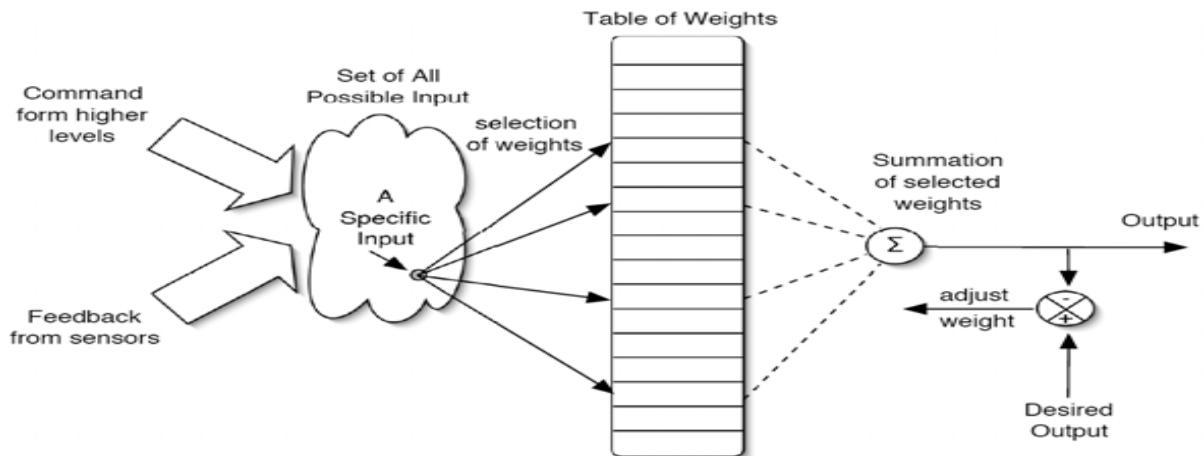
hidup individu. Di otak kecil, mekanisme pembelajaran otak kecil difasilitasi oleh transmisi sinaptik yang dapat dimodifikasi (plastisitas sinaptik serebelum) dan reorganisasi sinaptik (plastisitas struktural otak kecil) dari koneksi sarafnya.

Penelitian fisiologi otak kecil telah cukup menunjukkan bahwa Depresi Jangka Panjang (LTD) dari kemungkinan potensial aksi penembakan sel Purkinje dalam menanggapi input sinaptik dari serat paralel dengan mengubah sifat kimia dari reseptor saraf, adalah mekanisme seluler yang mendasari bertanggung jawab untuk pembelajaran serebelum [17,27,30,33-35]. Input serat paralel ke sel Purkinje menyediakan vektor besar informasi sensorik, mentransmisikan beragam sinyal. Serat panjang, sementara itu, berfungsi sebagai sinyal pelatihan, yang mengajarkan sel Purkinje untuk merespons pola tertentu, dengan menyesuaikan bobot sinaptik dari sinapsis serat paralelnya. Serat panjang mengubah output serebelar dengan secara selektif memodulasi efek sinaptik dari input serat paralel ke sel Purkinje melalui mekanisme LTD. Efek dari LTD dapat bervariasi dari menit ke jam, tergantung pada derajat depolarisasi dan jumlah kalsium yang dihasilkan oleh serat panjang di dendrit sel Purkinje [17].

Namun, bukti klinis menunjukkan bahwa depresi sinaptik mungkin bukan satu-satunya mekanisme yang mendasari pembelajaran di otak kecil [33]. Secara khusus, mekanisme seluler LTD mungkin tidak memadai untuk membentuk memori permanen jangka panjang dari program motorik. Beberapa penelitian memberikan bukti Potensiasi Jangka Panjang (LTP) selain LTD dari sinapsis serebelum [36-38]. Namun penelitian lain menunjukkan bahwa pembelajaran serebelar juga melibatkan perubahan morfologi korteks serebelum. Studi plastisitas struktural serebelum yang dilakukan oleh Greenough dan rekan-rekannya telah menunjukkan bahwa pembelajaran keterampilan motorik yang kompleks sebenarnya mengarah pada peningkatan jumlah sinapsis dalam korteks serebelum [39-42].

Dalam studi tersebut, tikus diberi pelatihan akrobatik dengan menantang mereka untuk memperoleh keterampilan motorik kompleks yang diperlukan untuk melintasi serangkaian rintangan. Ditemukan bahwa tikus dengan pelatihan tersebut mengembangkan peningkatan kepadatan serat paralel ke sinapsis sel Purkinje per satuan volume. Peningkatan kepadatan sinaptik dicapai dengan peningkatan aborsi dendritik dan peningkatan kepadatan tulang belakang dendritik di sepanjang cabang berduri sel Purkinje [40]. Beberapa kesimpulan dapat diambil dari pengamatan tersebut: (1) bahwa pembelajaran serebelar mengarah pada adaptasi fungsional dan struktural yang bertahan lama dari korteks serebelum; dan (2) memperoleh pengalaman dapat mengubah struktur koneksi saraf otak kecil. Plastisitas yang didorong oleh pengalaman seperti itu mungkin merupakan bagian dari substrat neurobiologis yang mendasari pembentukan memori prosedural jangka panjang di otak kecil.

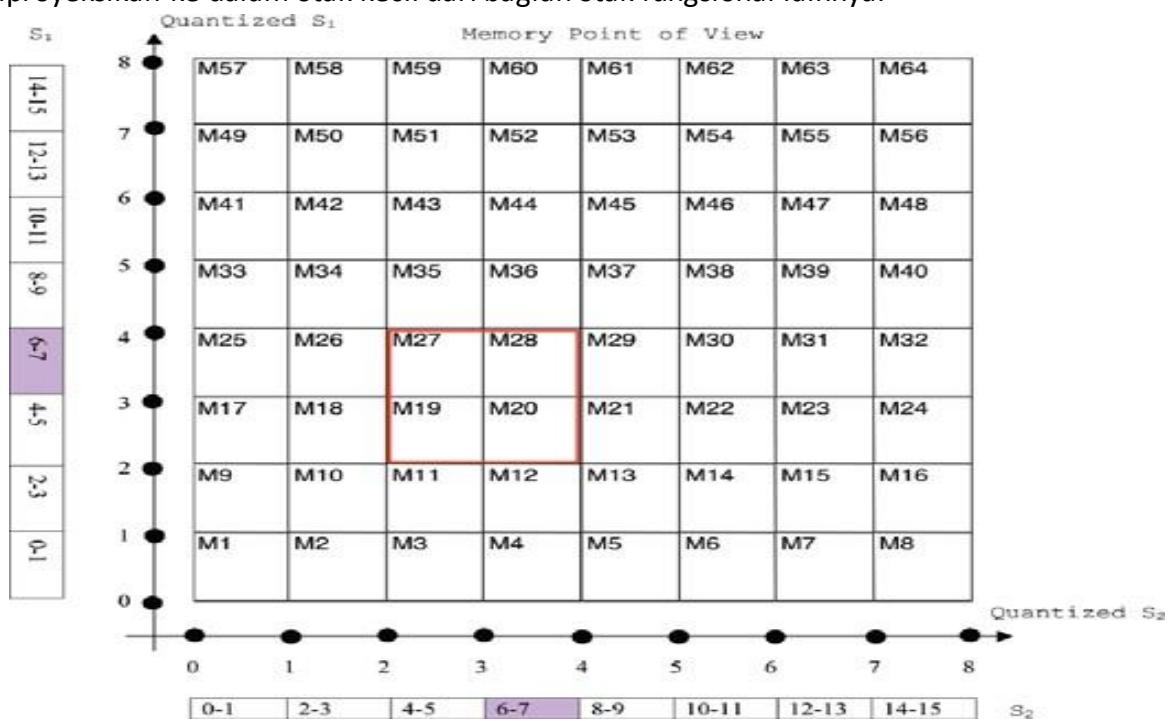
Fenomena plastisitas struktural serebelar yang digerakkan oleh pengalaman menunjukkan bahwa serebelum mengatur pengetahuan yang dipelajarinya dengan cara yang adaptif, di mana pelatihan berulang (paparan pada tupel asosiasi pemetaan input-output tertentu) menghasilkan peningkatan koneksi sinaptik serta kalibrasi yang lebih baik. dalam sirkuit saraf sel Purkinje. Ini menghasilkan pembentukan biologis skema representasi pengetahuan yang lebih tepat.



**Gambar 20.4** Diagram Skema Jaringan Syaraf Tiruan CMAC. Diadaptasi dari [29].

### 20.3 PSECMAC: MODEL MEMORI PEMBELAJARAN CEREBELLAR MULTI-RESOLUSI

Jaringan saraf Cerebellar Model Arithmetic (atau Articulation) Controller (CMAC) adalah model komputasi yang mapan dari otak kecil manusia [43, 44]. Skema mekanisme kerja jaringan CMAC digambarkan pada Gambar 4. Dari perspektif neurofisiologis, struktur CMAC adalah model sintetis dari otak kecil dan menggunakan sinyal koreksi kesalahan untuk mendorong pembelajaran dan akuisisi pengetahuan untuk meniru mekanisme dan fungsi pembelajaran. CMAC mendekati kemampuan rekan biologisnya. Intinya, CMAC berfungsi sebagai memori asosiatif statis yang memfasilitasi generalisasi lokal dan melambangkan pemetaan nonlinier antara input serat berlumut dan output sel Purkinje. Sel komputasi (memori) model CMAC analog dengan sel Purkinje di otak kecil manusia dan organisasi seperti grid dari sel komputasi ini terinspirasi oleh anatomi interkoneksi biologis sel Purkinje dan serat paralel, yang berasal dari lapisan sel granula dan merupakan jalur sinyal untuk informasi yang diproyeksikan ke dalam otak kecil dari bagian otak fungsional lainnya.



**Gambar 20.5** Contoh sel memori CMAC 2D

Dari sudut pandang teknik, CMAC adalah jaringan saraf berbasis memori asosiatif yang melakukan pemetaan tupel data input-output multi-dimensi. Memori CMAC dapat divisualisasikan sebagai array hypercube sel penyimpanan. Sel-sel ini digunakan untuk menyimpan set nilai bobot, yang merupakan basis pengetahuan jaringan CMAC. Elemen-elemen dalam vektor input ke jaringan CMAC digunakan sebagai indeks untuk mengaktifkan satu set sel penyimpanan tertentu, dan agregasi dari nilai yang disimpan dalam sel yang diaktifkan ini membentuk output yang dihitung dari model CMAC. Dalam jaringan CMAC, sel-sel komputasi diatur sebagai array memori multi-dimensi, dan resolusi (bidang reseptif) dari sel-sel ini ditentukan melalui kuantisasi yang merata dari ruang input di sepanjang masing-masing dimensi input. Masing-masing sel komputasi dengan demikian mencakup wilayah dengan ukuran yang sama di permukaan input.

Gambar 5 mengilustrasikan jaringan input CMAC dua dimensi dengan 64 sel memori terkuantisasi, yang digunakan untuk menyimpan pemetaan asosiatif untuk 256 (16 S1 dengan 16 S2) pola pelatihan input. Dalam contoh ini, kedua dimensi input dikuantisasi menjadi 8 segmen, dan setiap vektor input dua dimensi ke jaringan CMAC mengaktifkan wilayah empat sel memori yang berdekatan. Ada dua konsekuensi langsung yang mengikuti skema alokasi memori CMAC yang kaku ini. Pertama, resolusi keluaran jaringan CMAC hanya bergantung pada ukuran jaringan; yaitu, semakin besar ukuran jaringan, semakin halus resolusi keluarannya. Kedua, resolusi output CMAC tetap konstan di seluruh permukaan memori jaringan CMAC, terlepas dari variabilitas dalam kompleksitas dan konten informasi dari data pelatihan yang digunakan untuk membangun respons output.

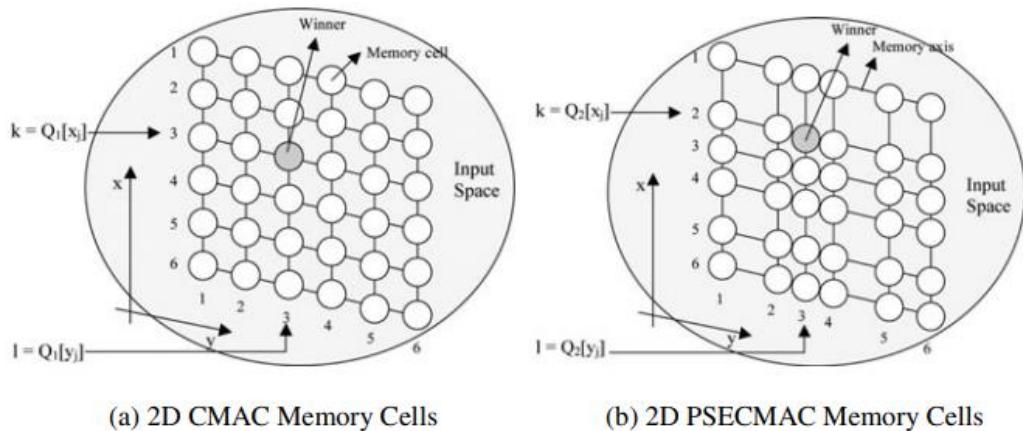
Namun, dalam banyak episode perolehan keterampilan kehidupan nyata, kemahiran perilaku didorong oleh kepekaan pelajar terhadap sekelompok rangsangan yang menonjol, yang hanya merupakan sebagian kecil dari keseluruhan rangkaian isyarat sensori input. Bergantung pada dinamika dan karakteristik yang mendasari keterampilan yang akan dipelajari, beberapa wilayah ruang fitur rangsangan akan berisi lebih banyak informasi terkait keterampilan daripada yang lain. Lebih jauh lagi, dengan paparan berulang terhadap fenomena pembelajaran, mekanisme perolehan keterampilan yang efektif diharapkan dapat mengembangkan ketepatan yang lebih tinggi terhadap urutan yang sering ditemui. Dengan demikian, dengan menarik inspirasi dari gagasan tentang plastisitas struktural serebelum yang digerakkan oleh pengalaman, serta efek mengasah dari pelatihan berulang untuk pengembangan keterampilan kognitif, model komputasi yang diilhami oleh otak kecil diusulkan untuk mensintesis pengambilan keputusan dinamis di kompleks, dan masalah yang tidak jelas. Arsitektur yang diusulkan, bernama Pseudo Self-Evolving CMAC (PSECMAC), menggunakan skema resolusi adaptif untuk representasi pengetahuan melalui kuantisasi variabel dari vektor pelatihan input. Jaringan PSECMAC yang diusulkan meningkatkan kemampuan akuisisi pengetahuan dari CMAC dasar dengan memanfaatkan skema manajemen memori yang digerakkan oleh pengalaman, yang kemudian menghasilkan resolusi keluaran yang lebih baik di wilayah signifikan dari ruang fitur rangsangan.

### **Arsitektur Jaringan PSECMAC**

Studi neurofisiologis telah menetapkan bahwa kabel yang tepat dari otak manusia dewasa tidak sepenuhnya berkembang saat lahir [17]. Sebaliknya, ada dua tahap yang tumpang tindih dalam perkembangan sistem saraf pusat manusia. Tahap pertama dari proses

ini meliputi pembentukan arsitektur dasar sistem saraf, di mana pola koneksi kasar muncul sebagai hasil dari genesis sel-sel otak selama perkembangan prenatal. Selanjutnya, pada tahap kedua, arsitektur awal disempurnakan dan koneksi sinaptik asing dipangkas sepanjang rentang hidup individu dengan paparan berulang ke berbagai pengalaman yang bergantung pada aktivitas. Plastisitas yang digerakkan oleh pengalaman seperti itu juga diamati di otak kecil (lihat Bagian 2), menunjukkan bahwa itu mungkin merupakan salah satu substrat neurobiologis yang mendasari pembentukan sistem memori prosedural manusia. Otak kecil mengatur pengetahuan yang dipelajari melalui mekanisme adaptif dan non-sepele, di mana pelatihan berulang (paparan pada tupel asosiasi input-output tertentu) menghasilkan kesetiaan yang lebih tinggi dalam pemetaan asosiatif antara rangsangan input dan aktuasi output, sehingga menghasilkan respon perilaku yang lebih tepat. Prinsip-prinsip pembelajaran serebelar yang diamati ini dengan patuh dimasukkan ke dalam jaringan PSECMAC yang diusulkan untuk membangun model memori pembelajaran berbasis serebelar.

Gambar 6 mengilustrasikan perbedaan arsitektur mendasar dalam organisasi struktur memori model PSECMAC yang diusulkan dibandingkan dengan model CMAC dasar. Sementara struktur sel memori CMAC dasar didistribusikan secara merata di seluruh ruang pemetaan asosiatif, sel-sel komputasi dalam jaringan PSECMAC secara selektif dialokasikan untuk mencapai representasi ruang fitur keseluruhan yang efisien. Skema alokasi selektif ini difasilitasi melalui identifikasi fitur rangsangan yang menonjol yang signifikan untuk kinerja dari tupel pelatihan input, menghasilkan fungsi pemetaan asosiatif granular adaptif dari jaringan PSECMAC.

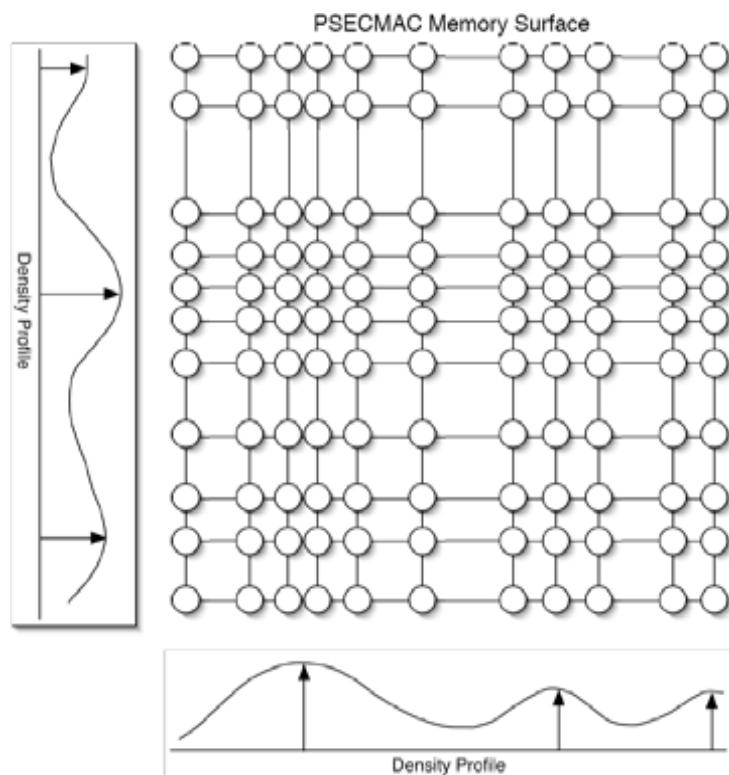


**Gambar 20.6** Perbandingan Permukaan Memori CMAC dan PSECMAC untuk masalah 2-input

Langkah awal menuju pembuatan pemetaan asosiatif resolusi adaptif dari jaringan PSECMAC adalah untuk mengidentifikasi area utama dari ruang fitur rangsangan yang berisi lebih banyak informasi yang berkaitan dengan tugas dibandingkan dengan yang lain, dan kemudian menetapkan granularitas yang lebih baik (yaitu lebih banyak sel memori) ke wilayah signifikan dari ruang fitur ini. Analogi dengan paparan berulang dari episode pembelajaran dan pelatihan keterampilan, area utama ini sesuai dengan wilayah informasi padat penduduk di mana sejumlah besar titik data ada dalam jarak dekat. Gambar 7 menggambarkan ilustrasi

2D prinsip granularity komputasi adaptif berbasis kepadatan ini dalam jaringan PSECMAC yang diusulkan.

Dalam PSECMAC, penetapan memori dan kuantisasi adaptif dilakukan pada basis per-dimensi dan terdiri dari beberapa langkah: (1) menghitung klaster kepadatan; (2) melakukan alokasi sel memori berdasarkan profil kepadatan yang dihitung; dan (3) menentukan titik kuantisasi dalam setiap sel memori yang dialokasikan. Algoritma pengelompokan Pseudo Self Evolving Cerebellar (PSEC) [45] digunakan untuk menghitung pusat cluster kepadatan di ruang pelatihan input. Algoritma PSEC adalah algoritma pengelompokan berbasis kepadatan yang mensinergikan manfaat dari prosedur pembelajaran tambahan dari teknik Learning Vector Quantization (LVQ) [46] dengan efektivitas metode partisi berbasis kepadatan dari algoritma DBSCAN [47]. PSEC terinspirasi oleh perkembangan biologis sistem saraf pusat manusia, di mana kematian sel saraf memainkan bagian integral dalam proses penyempurnaan organisasi saraf otak [45].



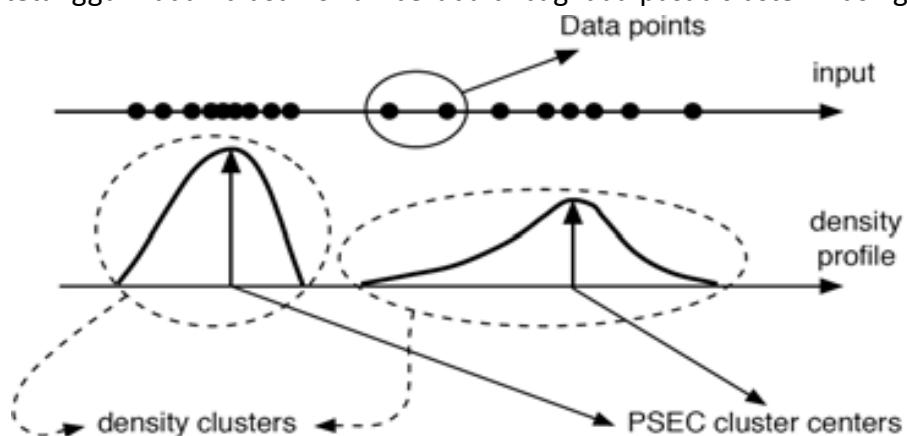
**Gambar 20.7** Contoh Permukaan Memori PSECMAC 2D

Operasi algoritma PSEC dilakukan secara individual untuk setiap dimensi komponen dari kumpulan data pelatihan yang diberikan. Cluster data yang signifikan mendukung organisasi yang melekat dari kumpulan data diidentifikasi oleh algoritma PSEC melalui analisis distribusi kepadatan titik data sepanjang masing-masing dimensi komponen. Algoritma PSEC secara singkat diuraikan sebagai berikut:

- Langkah 1      Inisialisasi ambang densitas sebelum mencari klaster (struktur) data yang signifikan di sepanjang dimensi arbitrer  $d$  dari kumpulan data.
- Langkah 2      Bangun struktur serebelar linier dengan  $m$  neuron dengan karakteristik yang menjangkau ruang input dimensi  $d$ . Langkah ini memodelkan proses pengembangan tahap pertama dari sistem saraf pusat manusia.

- Langkah 3 PSEC melakukan pembelajaran struktural dengan melakukan proses pembelajaran bobot semu satu lintasan untuk mendapatkan distribusi densitas data latih sepanjang dimensi d.
- Langkah 4 Struktur serebelar linier dikembangkan dengan mengidentifikasi neuron yang bertahan hidup dengan faktor tropik tinggi (menggunakan ambang densitas) yang bobot semu (kepadatan agregat) membentuk puncak densitas cembung yang menonjol dalam distribusi densitas yang dihitung dari Langkah 3. neuron yang tersisa dipangkas. Ini analog dengan proses penyempurnaan yang bergantung pada aktivitas dari organisasi saraf otak manusia dan koneksi sinaptik.
- Langkah 5 Neuron yang masih hidup selanjutnya memberikan bobot awal untuk penyempurnaan lebih lanjut oleh algoritma LVQ untuk mengidentifikasi posisi akhir dari pusat klaster data yang diinduksi kepadatan di sepanjang dimensi d.

Gambar 8 mengilustrasikan hasil akhir dari operasi algoritma pengelompokan PSEC. Intinya, PSEC menghitung satu set cluster yang diinduksi kepadatan, yang pusatnya menunjukkan titik kepadatan tertinggi di masing-masing cluster yang sesuai. Algoritme pengelompokan PSEC secara otonom menetapkan pusat cluster ke titik kepadatan kesetimbangan sedemikian rupa sehingga kepadatan wilayah sisi kiri dari pusat cluster setara dengan rekanan sisi kanannya. Cluster data yang dihitung berbentuk arbitrer, dan batas antara dua cluster tetangga mudah diasumsikan berada di bagi dua pusat cluster masing-masing.



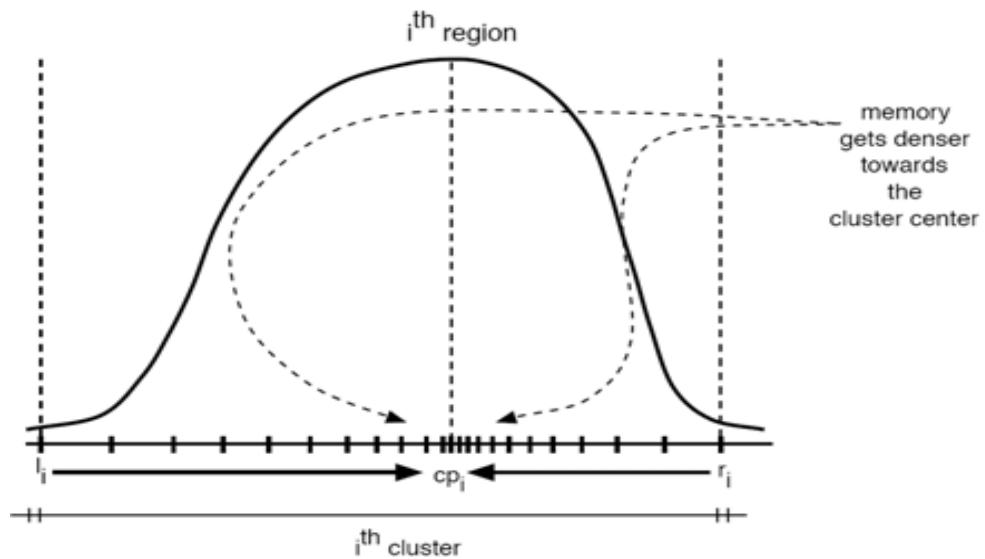
**Gambar 20.8** Contoh output clustering dari teknik clustering PSEC

Dalam model PSECMAC, jumlah sel memori yang dialokasikan untuk masing-masing cluster sebanding dengan kepadatan yang dinormalisasi dari pusat cluster yang sesuai dalam kaitannya dengan kepadatan cluster secara keseluruhan. Biarkan jumlah total sel memori per dimensi input menjadi  $M$ , dan proses alokasi memori PSECMAC dirumuskan sebagai:

$$M_i = \left\lfloor \frac{P_i}{\sum_{j \in S} P_j} \right\rfloor \times M \quad (1)$$

di mana  $M_i$  adalah jumlah total sel memori yang dialokasikan untuk cluster ke- $i$ ,  $M$  adalah jumlah total sel memori yang tersedia per dimensi input,  $P_i$  menunjukkan kepadatan pusat cluster dari cluster ke- $i$ , dan  $S$  mengacu pada himpunan cluster di seluruh ruang fitur input.

Untuk mendapatkan perincian yang disempurnakan secara bertahap untuk area ruang input dengan kepadatan tinggi, skema penugasan non-linier diperkenalkan ke proses alokasi sel memori dari jaringan PSECMAC dengan memvariasikan ukuran langkah kuantisasi sel memori di dalam cluster.. Dalam PSECMAC, sel-sel memori yang dialokasikan ke cluster yang berubah-ubah didistribusikan secara merata ke sisi kiri (subregion kiri) dan kanan (subregion kanan) dari pusat cluster yang sesuai. Di masing-masing subwilayah, titik kuantisasi dari masing-masing sel memori ditetapkan secara logaritmik sehubungan dengan pusat cluster. Hasil dari perhitungan ini diilustrasikan pada Gambar 9, yang menggambarkan sel memori terkuantisasi variabel di dalam wilayah cluster arbitrer. Pusat setiap cluster yang diinduksi kepadatan merupakan granularitas terbaik dalam wilayah cluster. Akibatnya, semakin jauh sel memori yang dialokasikan dari pusat clusternya, semakin kasar granularitas ukuran langkah kuantisasinya. Derajat progresi non-linier dalam perincian ukuran langkah kuantisasi sel memori dalam sebuah cluster diatur oleh parameter . Sebuah kuantisasi logaritmik (biasanya disebut sebagai teknik kuantisasi -hukum [48]) kemudian digunakan untuk memvariasikan distribusi sel memori dalam cluster.



**Gambar 20.9** Distribusi sel memori variabel dalam sebuah cluster

Dengan asumsi bahwa klaster arbitrer yang digambarkan pada Gambar 9 diberikan  $M$  jumlah sel memori oleh proses alokasi memori PSECMAC, titik kuantisasi sel  $j$  memori (dilambangkan sebagai  $Q_j$ ) di kluster dihitung sebagai:

- Jika

$$j \leq \left\lfloor \frac{M}{2} \right\rfloor :$$

$$\text{stepsize} = \frac{cp_i - l_i}{\left\lfloor \frac{M}{2} \right\rfloor} \quad (2)$$

$$pt_j = l_i + (j - 0.5) \cdot stepsize \quad (3)$$

$$Q_j = cp_i - \left[ \frac{(cp_i - l_i) \cdot \log \left( 1 + \frac{\mu \cdot |cp_i - x|}{(cp_i - l_i)} \right)}{\log(1 + \mu)} \right] \quad (4)$$

- Lain jika M ganjil dan

$$\left\lfloor \frac{M_i}{2} \right\rfloor < j < \left\lceil \frac{M_i}{2} \right\rceil + 1 :$$

$$Q_j = cp_i \quad (5)$$

- Lain jika

$$j > \left\lceil \frac{M_i}{2} \right\rceil :$$

$$stepsize = \frac{r_i - cp_i}{\left\lceil \frac{M_i}{2} \right\rceil} \quad (6)$$

$$pt_j = cp_i + (j - \left\lceil \frac{M_i}{2} \right\rceil - 0.5) \cdot stepsize \quad (7)$$

$$Q_j = r_i - \left[ \frac{(r_i - cp_i) \cdot \log \left( 1 + \frac{\mu \cdot |x - r_i|}{(r_i - cp_i)} \right)}{\log(1 + \mu)} \right] \quad (8)$$

di mana  $j$  adalah indeks sel memori yang dialokasikan dalam kluster  $i$ ,  $cpi$  adalah pusat kluster  $i$ ,  $l_i$  dan  $r_i$  menunjukkan batas kiri dan kanan kluster  $i$  masing-masing,  $M_i$  adalah jumlah sel memori yang dialokasikan untuk kluster  $i$ , menunjukkan derajat progresi nonlinier,  $ptj$  adalah titik kuantisasi semu dari sel memori  $j$  di kluster  $i$ , dan  $Q_j$  adalah titik kuantisasi PSECMAC berbasis hukum yang dihasilkan dari sel memori ke- $j$  di kluster  $i$ .

Poin keputusan kuantisasi yang dihitung dari setiap dimensi input dari kumpulan data pelatihan selanjutnya membentuk sumbu memori jaringan PSECMAC untuk menentukan struktur komputasi keseluruhannya. Perpotongan sumbu memori ini pada ruang input menunjukkan sel komputasi dari jaringan PSECMAC yang diusulkan (lihat Gambar 7). Organisasi sel memori yang dihitung secara adaptif ini mewakili struktur model PSECMAC yang digunakan untuk mempelajari karakteristik kumpulan data pelatihan. Subbagian berikut menjelaskan bagaimana struktur komputasi jaringan PSECMAC ini digunakan sebagai penyimpanan memori untuk akuisisi pengetahuan.

## Prinsip Kerja PSECMAC

Model PSECMAC yang diusulkan menggunakan proses komputasi Weighted Gaussian Neighborhood Output (WGNO), di mana satu set sel komputasi yang dibatasi lingkungan diaktifkan secara bersamaan, untuk memperoleh respons output ke setiap set stimulus input. Dalam proses komputasi ini, masing-masing sel tetangga memiliki tingkat aktivasi yang bervariasi yang berbanding terbalik dengan jarak dari rangsangan input. Tujuan penerapan skema pencarian lingkungan ini dalam model PSECMAC adalah untuk meminimalkan efek kesalahan kuantisasi pada keluaran jaringan yang dihitung. Selain itu, proses WGNO juga memperkenalkan kemampuan generalisasi topologi ke dalam model PSECMAC yang diusulkan. Diberikan stimulus input  $X = [x_1, x_2, \dots, x_d]$  ke jaringan PSECMAC, output yang dihitung dari jaringan diturunkan sebagai berikut:

### **Langkah 1: Tentukan Wilayah Aktivasi**

Jaringan PSECMAC menggunakan proses pengambilan keluaran berbasis lingkungan di mana keluaran yang dihitung dari jaringan yang sesuai dengan stimulus input berasal dari kombinasi bobot nilai memori sel tetangga di sekitar rangsangan input seperti yang diamati di multi -dimensi fitur ruang. Ukuran lingkungan ini ditentukan oleh konstanta lingkungan  $N$ , yang menentukan ukuran relatif dari lingkungan sehubungan dengan ruang fitur keseluruhan. Untuk menyederhanakan perhitungan jaringan, batas lingkungan didefinisikan pada basis per dimensi. Untuk stimulus input  $X$ , lingkungan aktivasinya didefinisikan sebagai:

$$l_i = x_i - 0.5 \cdot N \cdot range_i \quad (9)$$

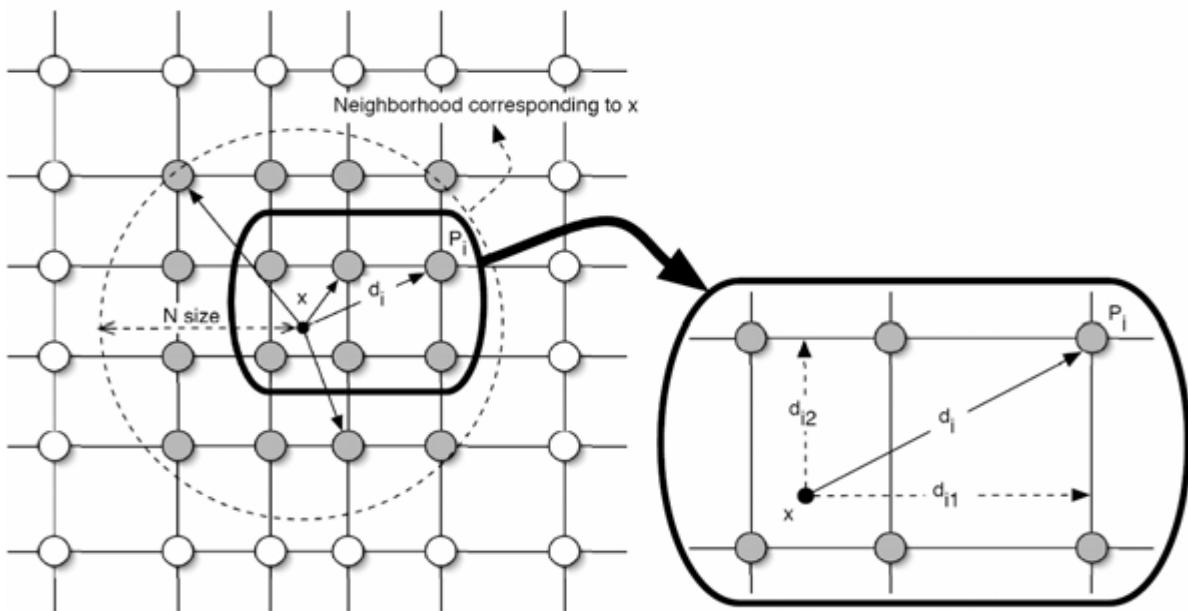
$$r_i = x_i + 0.5 \cdot N \cdot range_i \quad (10)$$

$$i \in \{1, 2, \dots, d\} \quad (11)$$

di mana  $i$  adalah indeks dimensi,  $d$  adalah jumlah dimensi input,  $N$  menunjukkan konstanta lingkungan,  $range_i$  adalah rentang input untuk dimensi ke- $i$ , dan  $l_i$  dan  $r_i$  adalah batas kiri dan kanan dari lingkungan dalam dimensi ke- $i$  yang sesuai dengan stimulus  $X$ . Akibatnya, sumbu memori yang dienkapsulasi di dalam batas yang ditentukan diaktifkan, dan sel memori yang dilambangkan dengan persimpangannya berkontribusi pada himpunan sel komputasi PSECMAC yang diaktifkan untuk rangsangan input  $X$ .

### **Langkah 2: Hitung fungsi pembobotan Gaussian**

Proses pengambilan WGNO dari model PSECMAC yang diusulkan diilustrasikan sebagai Gambar 10. Tingkat kontribusi masing-masing sel yang diaktifkan ke output dari jaringan PSECMAC yang sesuai dengan rangsangan input  $X$  berbanding terbalik dengan jarak antara titik kuantisasi dari sel memori dan  $X$ . Faktor pembobotan Gaussian ( $g_k$ ) digunakan untuk melemahkan bobot sinaptik yang disumbangkan oleh masing-masing sel di lingkungan yang diaktifkan sehubungan dengan jarak Euclidean dari sel komputasi ke titik aktual aktivasi  $X$  dalam Ruang memori PSECMAC. Fungsi pembobotan Gaussian didefinisikan sebagai:



**Gambar 20.10** Contoh 2D PSECMAC Neighborhood

$$g_k = (1 - d_k) e^{-d_k^2 / 2\gamma^2} \quad (12)$$

di mana  $k$  menunjukkan indeks sel yang diaktifkan sewenang-wenang,  $d_k$  adalah jarak Euclidean antara titik kuantisasi sel dan stimulus input  $X$ ,  $g_k$  adalah faktor pembobotan Gaussian untuk sel teraktivasi ke- $k$ , dan mengacu pada lebar Gaussian konstan.

### **Langkah 3: Ambil output PSECMAC**

Output dari model PSECMAC yang diusulkan dihitung sebagai kombinasi linier tertimbang dari isi memori sel yang diaktifkan:

$$Z_X = \frac{\sum_{k \in K} (g_k \cdot W_k)}{\sum_{k \in K} g_k} \quad (13)$$

di mana  $K$  menunjukkan himpunan sel tetangga yang diaktifkan,  $W_k$  menunjukkan nilai bobot sel yang diaktifkan ke- $k$ ,  $g_k$  adalah faktor pembobotan Gaussian untuk sel yang diaktifkan ke- $k$ , dan  $Z_X$  adalah output dari PSECMAC yang sesuai dengan stimulus input  $X$ .

### **Paradigma Pembelajaran PSECMAC**

Jaringan PSECMAC yang diusulkan menggunakan algoritma pelatihan dua fase, yaitu: pembelajaran struktural dan pembelajaran memori. Tujuan dari fase pertama (pembelajaran struktural) adalah untuk membangun struktur memori yang mendasari jaringan PSECMAC menggunakan skema alokasi memori adaptif seperti yang dijelaskan dalam Bagian 3.1. Fase kedua (pembelajaran memori) adalah fase pelatihan jaringan di mana pola hubungan antara input dan output dari tupel data pelatihan secara bertahap dipetakan ke dalam struktur jaringan. Tujuan dari fase pembelajaran memori adalah untuk menyesuaikan jaringan PSECMAC secara adaptif untuk merespon secara asosiatif terhadap rangsangan input yang

disajikan dengan akurasi yang meningkat. Untuk meniru fenomena pembelajaran lingkungan yang diamati di otak kecil manusia [17, 28, 49], jaringan PSECMAC yang diusulkan mengadopsi bentuk modifikasi dari aturan pembelajaran Widrow-Hoff [50] untuk mengimplementasikan Weighted Gaussian Neighborhood Update (WGNU) proses.

Di bawah skema pembelajaran ini, PSECMAC tidak hanya memperbarui neuron pemenang menjadi pola asosiasi input-output dari stimulus input. Sebaliknya, lingkungan sel yang berpusat pada stimulus input diaktifkan, dan tingkat pembelajaran atau adaptasi untuk masing-masing sel yang diaktifkan bervariasi sehubungan dengan jarak antara sel itu dan stimulus input. Pada dasarnya, WGNU menggabungkan algoritma pelatihan Widrow-Hoff dengan fungsi pembobotan Gaussian, yang didefinisikan seperti pada Persamaan (12). Tujuan dari skema pembaruan lingkungan ini adalah untuk mendistribusikan efek pembelajaran sehingga meningkatkan kesetiaan dan kemampuan generalisasi jaringan PSECMAC, serta meningkatkan waktu pelatihan jaringan. WGNU juga sebagian melambangkan perilaku belajar manusia, di mana diamati bahwa pembelajaran tugas terkait akan meningkatkan proses pembelajaran selanjutnya dari tugas terkait.

Proses pembelajaran memori PSECMAC secara matematis dijelaskan dengan persamaan berikut:

$$Z_{X_j}^i = \frac{\sum_{k \in K_{X_j}} (g_k \cdot W_k)}{\sum_{k \in K_{X_j}} g_k} \quad (14)$$

$$W_{k \in K_{X_j}}^{i+1} = W_{k \in K_{X_j}}^i + \Delta W_{k \in K_{X_j}}^{i+1} \quad (15)$$

$$\Delta W_{k \in K_{X_j}}^{i+1} = \alpha \frac{g_{k \in K_{X_j}} (Z_{X_j}^{i+1} - D_{X_j})}{\sum_{k \in K_{X_j}} g_k} \quad (16)$$

di mana I adalah nomor iterasi pelatihan,  $X_j$  menunjukkan vektor input (stimulus) ke-j ke jaringan,  $K_{X_j}$  adalah himpunan sel komputasi yang diaktifkan sesuai dengan input  $X_j$ ,  $g_k$  adalah faktor pembobotan Gaussian dari memori yang diaktifkan ke-k (komputasi) sel,  $Z_{X_j}$  adalah output jaringan ke input  $X_j$ ,  $D_{X_j}$  adalah output yang diharapkan dari jaringan sebagai respons terhadap input  $X_j$ ,  $W_k$  menunjukkan konten sel memori yang diaktifkan ke-k, dan adalah konstanta pembelajaran.

Fase pembelajaran memori PSECMAC dimulai dengan penghitungan keluaran jaringan yang sesuai dengan rangsangan masukan  $X_j$ . Kesalahan pembelajaran dihitung berdasarkan keluaran PSECMAC yang diturunkan dan respons yang diinginkan untuk  $X_j$ . Kesalahan ini selanjutnya didistribusikan ke semua sel komputasi (memori) yang diaktifkan berdasarkan fungsi pembobotan Gaussian yang dihitung dari sel-sel ini. Kesalahan lokal masing-masing, disesuaikan dengan konstanta pembelajaran, kemudian digunakan untuk memperbarui isi memori dari setiap sel yang diaktifkan. Selain itu, bukti teoritis konvergensi pembaruan WGNU telah dilakukan dan dilaporkan dalam [51].

## 20.4 DIABETES SEBAGAI PENYAKIT

Diabetes Mellitus, umumnya dikenal sebagai diabetes, adalah penyakit kronis di mana tubuh tidak dapat mengatur konsentrasi glukosa dalam darah dengan benar, mengakibatkan peningkatan glukosa darah (hiperglikemia), pengeluaran urin yang terkonsentrasi glukosa berlebihan (diuresis osmotik) dan haus. Sejalan dengan itu, pengobatan diabetes difokuskan pada terapi penurunan glukosa menggunakan agen hipoglikemik oral dan insulin. Terapi sub-optimal menghasilkan hiperglikemia persisten sementara pengobatan yang berlebihan dapat menyebabkan hipoglikemia (penurunan glukosa darah).

Hiperglikemia kronis menyebabkan kerusakan pada mata, ginjal, saraf, jantung dan pembuluh darah [52]; dan ada bukti tegas bahwa kontrol glukosa intensif lebih lanjut mengurangi risiko kerusakan organ akhir dibandingkan dengan terapi konvensional [53, 54] serta memberikan efek warisan [55]. Namun terapi penurunan glukosa intensif dapat mengakibatkan hipoglikemia berat yang menghilangkan energi tubuh dan menyebabkan kebingungan yang mengakibatkan hilangnya kesadaran atau kematian [56].

Profesi medis telah mengklasifikasikan diabetes menjadi dua subtipe utama berdasarkan patogenesisnya – (1) Diabetes tipe-1, juga dikenal sebagai diabetes mellitus remaja atau insulin-dependent (IDDM) terjadi sebagai akibat dari kematian atau penghancuran sel beta pankreas [ 57], sedangkan (2) Diabetes tipe 2, juga dikenal sebagai diabetes mellitus onset dewasa atau non-insulin-dependent diabetes (NIDDM), terjadi sebagai akibat dari penurunan sensitivitas insulin seluler yang menyebabkan peningkatan kadar insulin awal (untuk mengkompensasi penurunan sensitivitas insulin. ) diikuti oleh insufisiensi sel beta progresif dan akhirnya defisiensi insulin relatif [58].

Dalam beberapa tahun terakhir, ada urgensi untuk mengatasi efisiensi pengobatan diabetes, terutama didorong oleh kekhawatiran tentang meningkatnya biaya sosial dan ekonomi dari penyakit ini. Karena sifatnya yang kronis, serta beratnya komplikasi yang terkait dengan penyakitnya, diabetes adalah penyakit mahal yang menimbulkan beban keuangan yang berat baik bagi pasien maupun masyarakat. Karena jumlah pasien diabetes meningkat di seluruh dunia [59, 60], proporsi anggaran perawatan kesehatan nasional yang dialokasikan untuk pengobatan diabetes selanjutnya diperkirakan akan membengkak. Sebuah laporan dari American Diabetes Association [60] mendaftarkan diabetes sebagai penyebab kematian kelima di AS dengan pengeluaran medis tahunan langsung dan tidak langsung sekitar \$ 132 miliar. Jumlah ini diproyeksikan meningkat menjadi \$ 156 miliar pada tahun 2010 dan menjadi \$ 192 miliar pada tahun 2020 untuk AS saja.

Penatalaksanaan diabetes yang berhasil memerlukan pemeliharaan kadar glukosa mendekati normal dalam jangka panjang. Untuk mencapai hal ini, semua penderita diabetes diharuskan untuk mempertahankan rencana diet yang disiplin di samping obat diabetes yang diresepkan. Jenis obat diabetes yang dibutuhkan tergantung pada sifat kondisi diabetes dan kemampuan sel beta untuk memproduksi insulin – semua penderita diabetes tipe 1 akan membutuhkan penggantian insulin; kebanyakan penderita diabetes tipe 2 di awal perjalanan penyakit hanya akan membutuhkan obat oral sementara penderita diabetes tipe 2 dengan durasi yang lama akan semakin menghadapi kebutuhan akan terapi insulin.

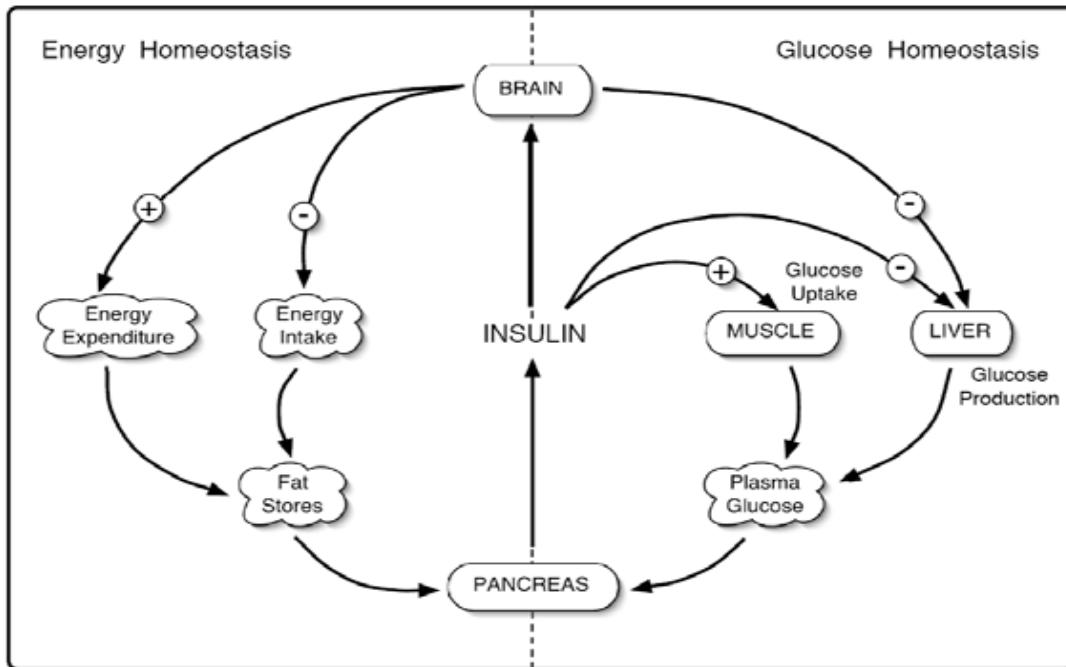
Terapi penggantian insulin memainkan peran penting dalam pengelolaan diabetes tipe 1 dan tipe 2. Regimen insulin yang ideal adalah tiruan fisiologis dan rekreasi respons insulin

non-diabetes terhadap glukosa pada pasien diabetes; untuk mengatur kadar glukosa darah dalam batas fisiologis yang ketat (biasanya 60-110 mg/dl atau 4-7 mmol/l) [61]. Insulin dapat diberikan secara subkutan, intravena atau melalui rute trans-peritoneal, dan dapat berupa suntikan insulin terpisah atau pengiriman insulin terus menerus melalui pompa insulin. Studi ekstensif pada keuntungan, kerugian dan masalah perifer mengenai pendekatan pengiriman insulin ini telah dilakukan dan dilaporkan dalam literatur [62, 63].

Karena sifatnya yang loop terbuka, efek terapeutik dari injeksi insulin diskrit tidak ideal untuk pengobatan diabetes. Infus insulin terus menerus melalui pompa insulin, di sisi lain, menawarkan pendekatan yang lebih layak karena laju infus yang terkendali [64]. Cara kerja pompa insulin tersebut secara algoritmik didorong, dengan sejumlah teknik yang diusulkan, diselidiki dan dilaporkan dalam literatur [65,66]. Metode kontrol klasik dan algoritma canggih menggunakan pengetahuan implisit atau model eksplisit (empiris, fundamental, atau kotak abu-abu) dari pasien diabetes telah dipelajari dan diperiksa di [67-69]. Metode yang diusulkan ini semuanya memerlukan beberapa bentuk pemodelan proses metabolisme glukosa pasien diabetes sebelum rezim kontrol yang sesuai dapat dirancang. Namun, penggunaan teknik pemodelan klasik (pencocokan data, persamaan diferensial / perbedaan terkotak, pendekatan statistik atau pembelajaran mesin dll) [70, 71] untuk menggambarkan dinamika proses metabolisme diabetes yang terganggu umumnya menghasilkan sistem regulasi yang kaku. Ini tidak dapat berkembang secara dinamis dan menanggapi variabilitas glukosa antar dan intra-hari [72, 73] dan merupakan batasan kritis dari algoritma kontrol klasik.

Dari perspektif biologis, insulin berfungsi sebagai hormon pengatur utama yang memastikan homeostasis tingkat glukosa darah manusia [74]. Banyak kemajuan telah dibuat dalam tiga dekade terakhir untuk mengkarakterisasi jalur metabolisme yang terlibat dalam proses fisiologis sekresi insulin. Dari semua jalur yang diidentifikasi sejauh ini, mekanisme metabolisme glukosa dalam memicu sekresi insulin dari sel pankreas telah dipelajari secara ekstensif [75]. Glukosa darah adalah stimulus nutrisi fisiologis yang paling efektif dari sekresi insulin [76]. Fungsi homeostatis ini tergantung pada pengambilan glukosa di sel pankreas dan jalur sinyal berikutnya yang mempengaruhi kecepatan sekresi insulin [77]. Sel pankreas secara fisiologis dirancang untuk mengukur kadar glukosa dalam darah dari waktu ke waktu, untuk mensekresikan insulin pada tingkat yang tepat untuk memastikan tingkat optimal glukosa yang bersirkulasi dalam darah [75] . Ketika kadar glukosa darah meningkat, sekresi insulin ditingkatkan dengan ketergantungan yang khas. Oleh karena itu, tubuh manusia secara alami diberkahi dengan mediasi regulasi yang kuat dan kuat untuk sekresi insulin.

Sistem saraf pusat berpartisipasi dalam menjaga keseimbangan energi dan fungsi penting dari SSP adalah untuk memastikan pasokan substrat energi yang stabil. Untuk menyelesaikan tugas ini, sinyal aferen yang sangat berbeda diintegrasikan di dalam otak dan ditransduksi menjadi sinyal yang memfasilitasi penyesuaian homeostatik asupan makanan dan pengeluaran energi. Berbagai masukan aferen yang digunakan otak untuk secara dinamis menyesuaikan asupan makanan dan metabolisme energi dapat secara luas dikategorikan menjadi dua subkelompok: yang mengkomunikasikan informasi yang berkaitan dengan simpanan energi tubuh dan sinyal yang dihasilkan sebagai respons terhadap konsumsi nutrisi.



**Gambar 20.11** Model homeostasis energi dan glukosa pada manusia. Diadaptasi dari [79].

Bukti yang muncul menunjukkan bahwa metabolisme glukosa di seluruh tubuh dikoordinasikan oleh otak dan dimediasi oleh insulin [78]. Hal ini didukung oleh penemuan reseptor glukokinase, sensor glukosa dari sel pankreas, di sistem saraf pusat (SSP) [79]. Ada konsensus umum bahwa hati memainkan peran sentral dalam proses metabolisme glukosa manusia dengan bertindak sebagai buffer glukosa; yaitu, mengekstraksi glukosa dari aliran darah pada saat banyak dan mensintesis glukosa saat dibutuhkan dengan mengenali keadaan energi tubuh yang berbeda melalui deteksi perubahan konsentrasi insulin darah [80]. Sampai sekarang, insulin diketahui menargetkan hati secara langsung. Namun, eksperimen yang tepat kemudian menunjukkan bahwa insulin, melalui aksinya pada hipotalamus (struktur otak sub-kortikal pusat kontrol otonom dari sistem endokrin manusia), memberikan tingkat yang lebih tinggi dari kontrol pengawasan pada produksi glukosa oleh hati [81]. Pengamatan ini menunjukkan bahwa insulin sebenarnya dapat memodulasi produksi glukosa hati melalui jalur sinyal yang tidak diketahui melalui SSP [82, 83]. Selain itu, studi bio-fisiologis telah menetapkan adanya respon fisiologis penghambatan asupan makanan ketika hormon insulin secara langsung diberikan ke SSP, khususnya di wilayah hipotalamus [84, 85]. Oleh karena itu, insulin tampaknya dibutuhkan oleh SSP untuk mengatur asupan makanan, berat badan dan homeostasis proses fisiologis [86]. Hubungan yang saling terkait dan kompleks ini digambarkan pada Gambar 11.

Sementara banyak mekanisme dan hubungan saling ketergantungan antara insulin, sistem saraf pusat dan proses metabolisme secara keseluruhan masih dalam penelitian ekstensif dan belum ditetapkan secara ilmiah, fakta-fakta yang disajikan di atas telah cukup menunjukkan bahwa mekanisme pengaturan insulin manusia. nism adalah proses keputusan dinamis yang kompleks dalam lingkungan yang berubah dengan cepat dan tidak pasti, di mana masing-masing peserta saling mempengaruhi dengan cara yang sangat kompleks dan nonlinier. Oleh karena itu, tujuan bab ini adalah untuk mendukung penggunaan jaringan PSECMAC, yang merupakan model memori pembelajaran adaptif yang diilhami serebelar,

untuk secara dinamis memodelkan profil insulin dari proses metabolisme glukosa orang yang sehat, sehingga dapat menentukan dinamika insulin yang diperlukan untuk mencapai homeostasis dari proses metabolisme glukosa ketika terganggu oleh asupan makanan. Tujuannya adalah untuk selanjutnya menggunakan model insulin berbasis PSECMAC ini sebagai referensi untuk mengatur infus insulin melalui pompa insulin untuk mencapai normoglikemia dekat jangka panjang pada pasien dengan diabetes tipe I dan mereka dengan diabetes tipe 2 dan sel beta. defisiensi, sambil menghindari hipoglikemia setiap saat.

## 20.5 METABOLISME GLUKOSA: STUDI DINAMIKA INSULIN UNTUK NORMOGLIKEMIA

Langkah pertama dalam membangun model proses metabolisme glukosa manusia adalah menentukan profil pasien yang akan dimodelkan. Karena kurangnya data pasien kehidupan nyata dan kesulitan logistik dan masalah etika yang melibatkan pengumpulan data tersebut, simulator berbasis web terkenal yang dikenal sebagai GlucoSim [87] digunakan untuk mensimulasikan subjek seseorang untuk menghasilkan data glukosa darah yang diperlukan untuk pembuatan model pasien. Tujuan dari penelitian ini adalah untuk menerapkan PSECMAC, model komputasi otak kecil manusia yang terinspirasi oleh neurofisiologis, untuk pemodelan metabolisme glukosa dari subjek yang sehat. Untuk tujuan ini, profil manusia (Subjek A) untuk subjek sehat yang disimulasikan dibuat dan diuraikan dalam Tabel 1.

**Tabel 20.1** Profil Subjek A sehat yang disimulasikan

Nama Atribut	Nilai Atribut
Seks	Pria
Usia	40 tahun
Balapan	Asia
Bobot	67 kg (147,71 pon)
Tinggi	1,70 m (5 kaki 7 inci)
BMI 23	23 (Direkomendasikan untuk orang Asia)
Gaya hidup	Tipikal pekerja kantoran dengan aktivitas fisik sedang seperti berjalan cepat, bersepeda santai dan berenang.

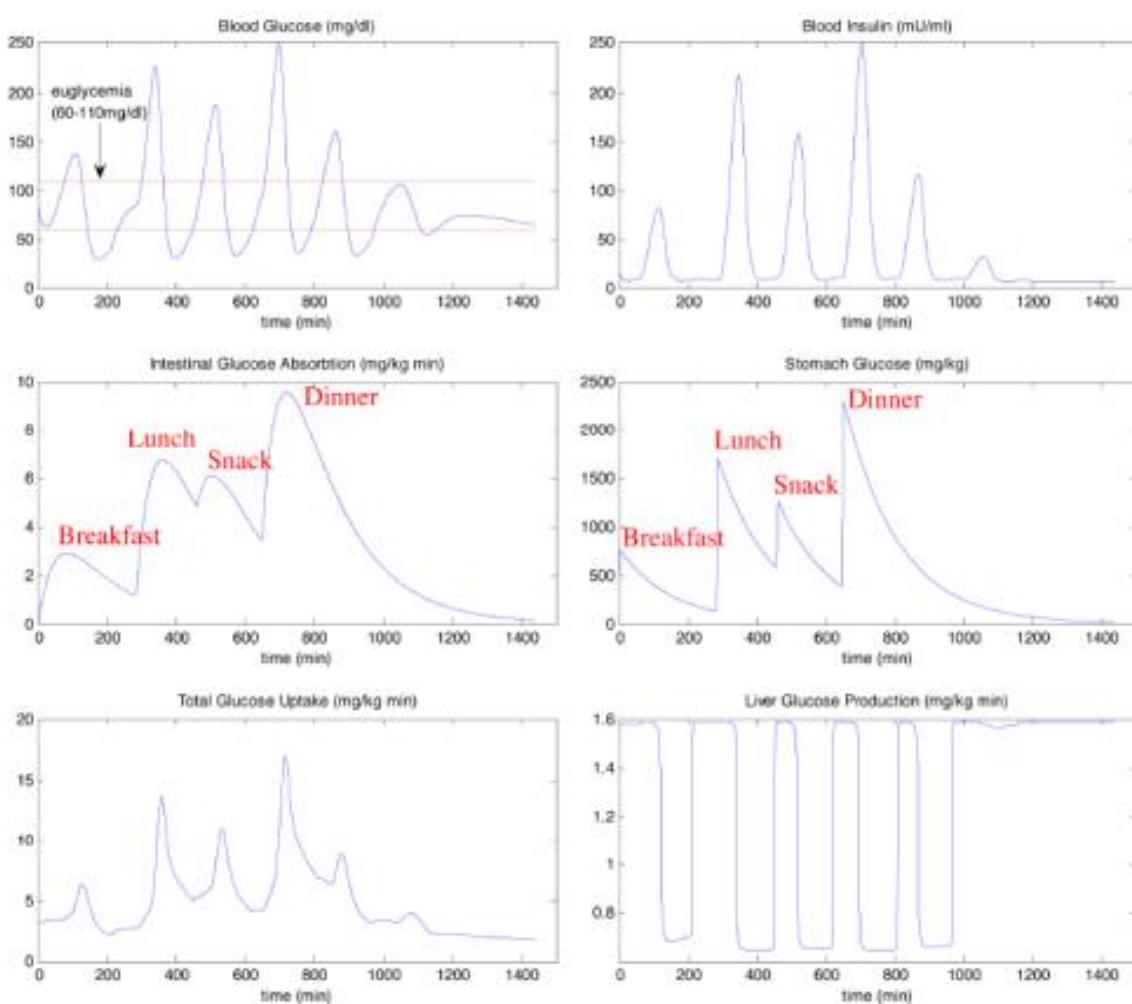
Orang sehat yang disimulasikan, Subjek A, adalah tipikal pria Asia setengah baya. Indeks massa tubuhnya (BMI) berada di 23,0, dalam kisaran yang direkomendasikan untuk orang Asia. Berdasarkan profil orang Subjek A, tunjangan harian yang direkomendasikan (RDA) asupan karbohidrat dari makanan dihitung menggunakan applet dari situs web Health Promotion Board of Singapore [88]. Menurut jenis kelamin, usia, berat badan dan gaya hidup, asupan karbohidrat harian yang direkomendasikan untuk subjek A adalah sekitar 346,9 gram per hari. Untuk tujuan penelitian, total 100 hari data metabolisme glukosa untuk Subjek A harus dikumpulkan.

GlucoSim membutuhkan 10 input berbeda untuk dihasilkan, yang terdiri dari berat badan, periode simulasi, serta waktu dan kandungan karbohidrat dari masing-masing empat kali makan harian yang diasumsikan, yaitu: sarapan, makan siang, camilan sore, dan makan malam. Dengan profil orang Subjek A dan kandungan karbohidrat dari makanan khasnya

sesuai dengan RDA yang dihitungnya, data glukosa 100 hari akan dihasilkan dari simulator. Isi karbohidrat dan waktu makan sehari-hari bervariasi dari hari ke hari selama fase pengumpulan data. Untuk memperhitungkan variabilitas antar dan intra-hari dari kebiasaan makannya dan isi makanan yang dia makan, serta kemungkinan fluktuasi berat badannya dalam periode simulasi 100 hari, perhitungan yang tercantum dalam Tabel 2 dilakukan untuk menghasilkan 100 set input yang berbeda, satu untuk setiap hari dari periode simulasi, untuk digunakan dengan simulator untuk menghasilkan data glukosa. Ini memastikan bahwa PSECMAC yang diusulkan tidak dilatih pada kumpulan data siklus, tetapi digunakan untuk menemukan hubungan yang melekat antara asupan makanan dan proses metabolisme glukosa orang sehat.

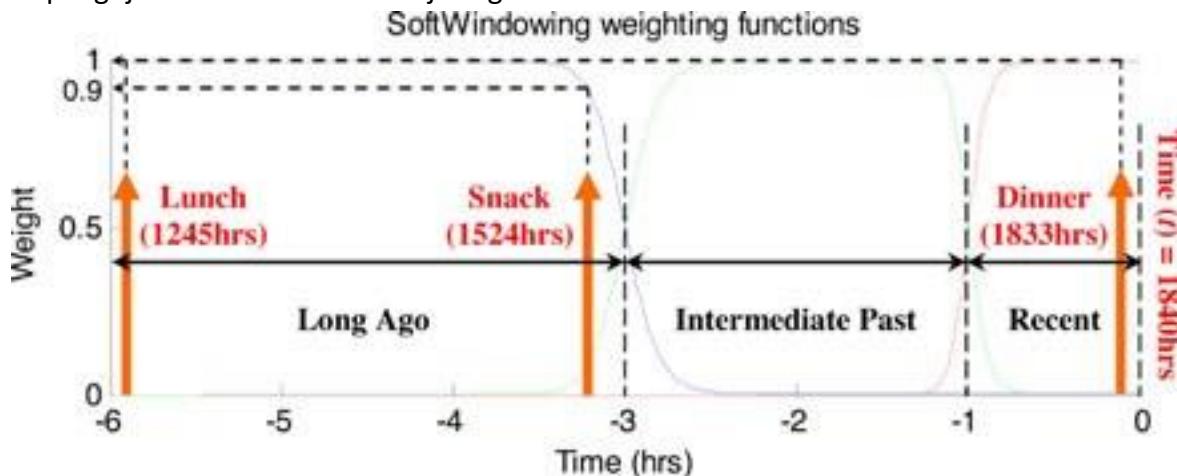
Gambar 12 mengilustrasikan output sampel dari GlucoSim untuk Subjek A. Output ini terdiri dari enam elemen: glukosa darah, insulin darah, laju penyerapan glukosa usus, glukosa lambung, laju penyerapan glukosa total, dan laju produksi glukosa hati Subjek A masing-masing selama a periode waktu simulasi 24 jam. Puncak dalam subplot glukosa lambung pada Gambar 12 bertepatan dengan pengaturan waktu dari asumsi empat kali makan setiap hari (yaitu sarapan, makan siang, camilan sore dan makan malam) sedangkan puncak pada subplot tingkat penyerapan glukosa usus mencerminkan efek penundaan (respon). asupan makanan terhadap kadar glukosa darah Subjek A. Subplot glukosa darah dan insulin darah menggambarkan mekanisme pengaturan insulin-glukosa pada orang sehat seperti Subjek A dan menggambarkan dinamika proses metabolisme ketika mengalami gangguan seperti asupan makanan.

Karena proses metabolisme glukosa bergantung pada keadaan saat ini (dan internal) serta input eksogen (atau gangguan) seperti asupan makanan, dihipotesiskan bahwa tingkat konsentrasi insulin darah pada waktu tertentu adalah fungsi non-linier. asupan makanan sebelumnya dan jejak sejarah insulin dan kadar glukosa darah. Untuk menjelaskan dengan tepat efek dari konsumsi makanan sebelumnya terhadap tingkat insulin darah, jendela historis enam jam diadopsi. Untuk mengatasi masalah variabilitas dalam jumlah makanan (dan karenanya jumlah input) yang diambil dalam 6 jam sebelumnya, strategi soft-windowing diadopsi untuk membagi fungsi histori windowing dan pembobotan enam jam menjadi tiga segmen konseptual, yaitu: Jendela Terakhir (yaitu 1 jam sebelumnya), Jendela Menengah Sebelumnya (yaitu 1 hingga 3 jam sebelumnya) dan Jendela Lama (yaitu 3 hingga 6 jam sebelumnya), menghasilkan hanya tiga input riwayat makanan. Nama-nama segmen dipilih untuk secara intuitif mewakili pemahaman konseptual manusia dan persepsi waktu berdasarkan jendela ini, tiga fungsi pembobotan diperkenalkan untuk menghitung kandungan karbohidrat dari makanan yang diambil dalam periode baru-baru ini, pertengahan masa lalu atau masa lalu. Gambar 13 menggambarkan fungsi pembobotan untuk masing-masing jendela tersegmentasi.



Gambar 20.12 Contoh keluaran data metabolisme glukosa dari simulator GlucoSim.

Tiga jaringan komputasi dibangun untuk memodelkan profil insulin darah dinamis: jaringan PSECMAC ukuran 8 per dimensi dan dua jaringan CMAC ukuran 8 dan 12 per dimensi. Data metabolisme yang dikumpulkan selama 100 hari kemudian digunakan dalam pelatihan dan pengujian PSECMAC dan dua jaringan CMAC.



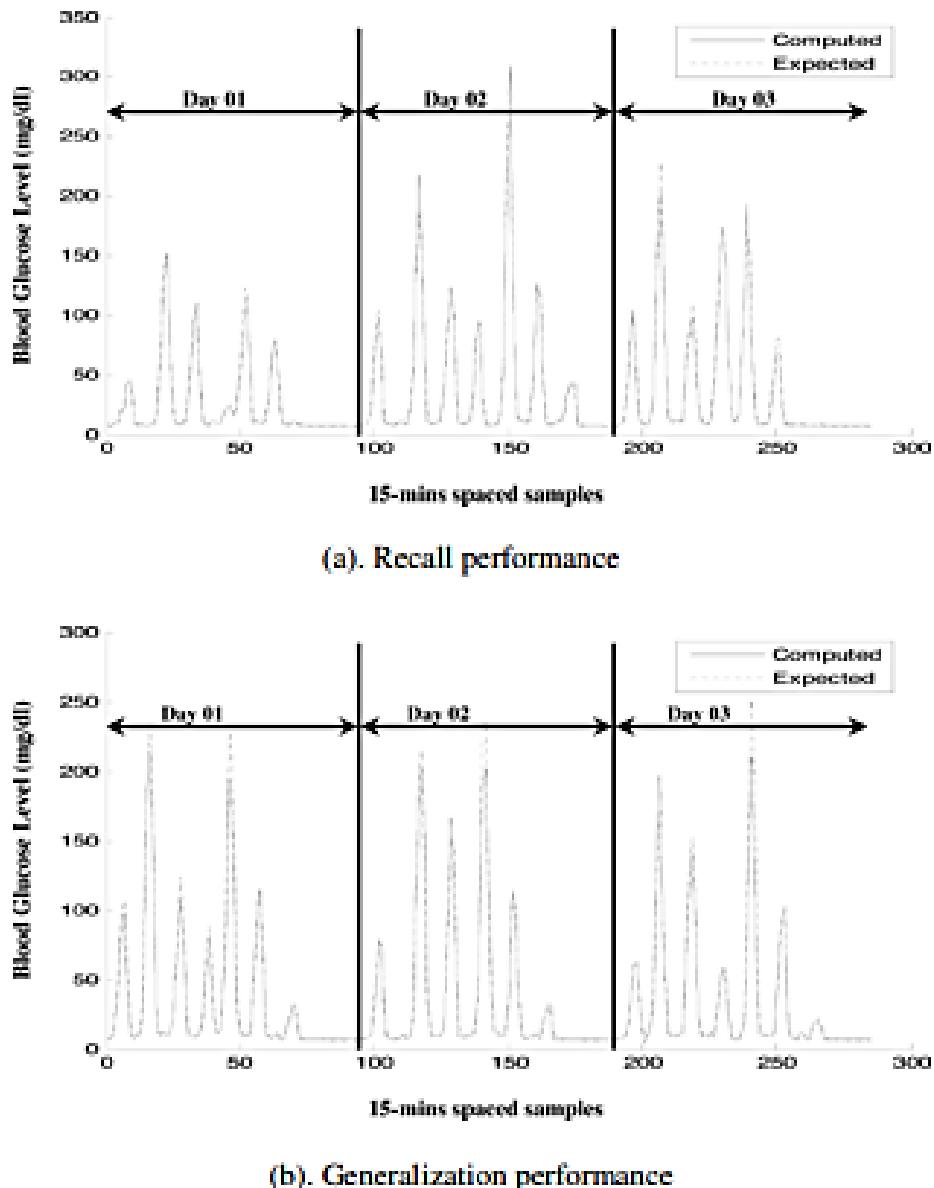
Gambar 13. Pembobotan soft-windowing berfungsi untuk menghitung kandungan karbohidrat makanan di jendela tersegmentasi dari riwayat makanan 6 jam

**Tabel 20.2** Perhitungan untuk menghasilkan parameter input GlucoSim. (Catatan: 100 set parameter input dihasilkan.  $U(x,y)$ : bilangan acak terdistribusi seragam antara  $x$  dan  $y$  secara inklusif; dan  $N(\mu,\sigma)$ : bilangan acak terdistribusi normal dengan rata-rata dan simpangan baku.

No	Glucosim Input	Notation	Value	Remarks
<b>Meal Timings</b>				
1.	Breakfast Time	BkTime	$U(0700\text{hrs},0900\text{hrs})$	
2.	Lunch Time	LunTime	$U(1130\text{hrs},1200\text{hrs})$	
3.	Afternoon Snack Time	ASTime	$U(1500\text{hrs},1600\text{hrs})$	
4.	Dinner Time	DinTime	$U(1830\text{hrs},2030\text{hrs})$	
<b>Total Carbohydrate Intake Per Day</b>				
5.	Breakfast Carbohydrate	BkCarb	$U(12\%,18\%) \times \text{Total Carb}$	
6.	Lunch Carbohydrate	LunCarb	$U(25\%,35\%) \times \text{Total Carb}$	
7.	Afternoon Snack Carbohydrate	ASCarb	$U(13\%,19\%) \times \text{Total Carb}$	
8.	Dinner Carbohydrate	DinCarb	$U(35\%,45\%) \times \text{Total Carb}$	
<b>Other Inputs</b>				
9.	Body Weight	BW	$67\text{kg} + N(\mu=0\text{kg},\sigma=0.5\text{kg})$	Weight is normally randomized
10.	Duration of Simulation	DSimu	24 hours	Constant

**Tabel 20.3** Pengaturan Parameter untuk Jaringan yang dilatih

Nama Parameter	Notasi	Nilai Parameter
Konstanta lingkungan	N	0.1
Lebar fungsi pembobotan Gaussian		0.5
Belajar konstan	?	0.1
Jumlah periode pelatihan	Epmax	1000



**Gambar 20.14** Performa pemodelan 3 hari jaringan PSECMAC dalam pemodelan profil insulin orang sehat

Untuk mendapatkan perbandingan obyektif pada kinerja ketiga model, semua jaringan dilatih dan diuji menggunakan pengaturan parameter yang sama dan pembaruan Gaussian tertimbang dan mekanisme pengambilan (yaitu WGNO dan WGNU masing-masing). Parameter jaringan diuraikan pada Tabel 3.

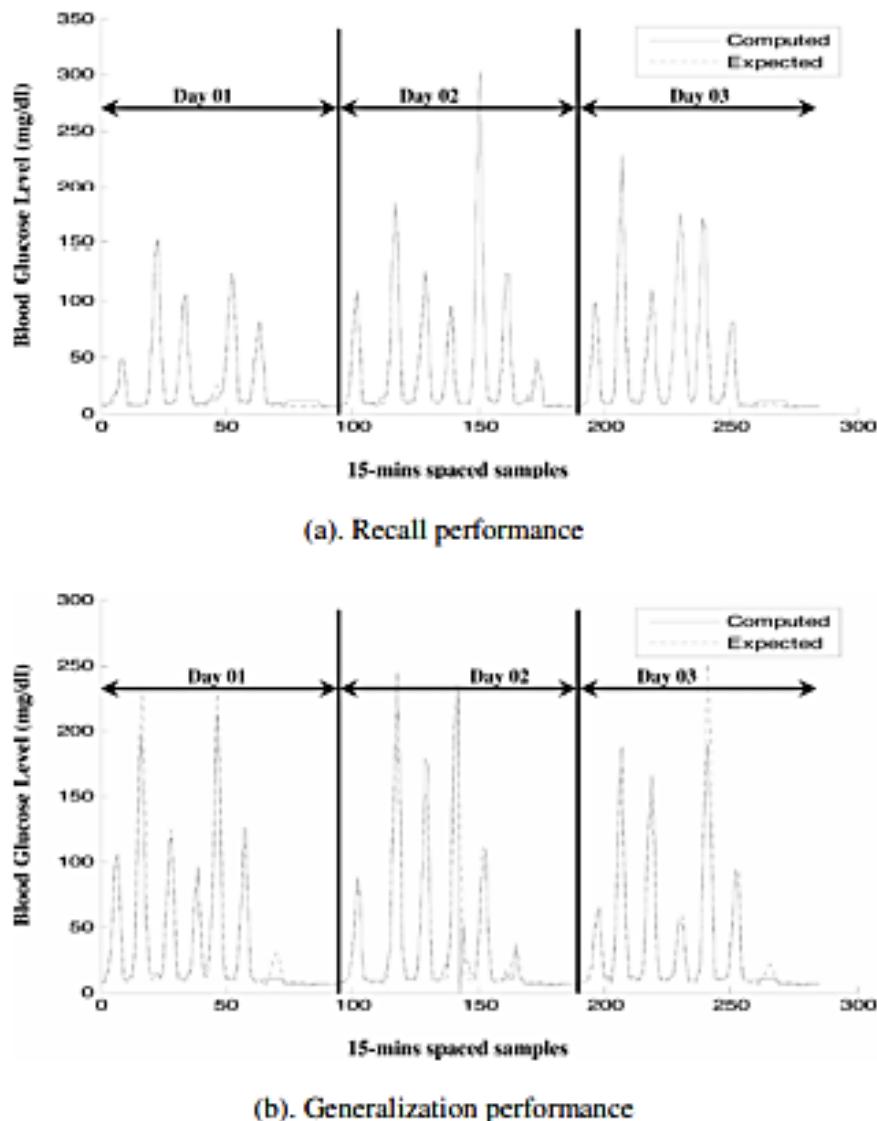
Gambar 14 menggambarkan snapshot 3-hari dari penarikan dan akurasi generalisasi dari jaringan PSECMAC yang diusulkan dibandingkan dengan rekan CMAC-nya (Gambar 15) pada pemodelan profil insulin metabolik. Masing-masing jaringan memiliki 8 sel memori per dimensi. Untuk mengukur kualitas kinerja jaringan, dua indikator kinerja digunakan: root mean-squared error (RMSE) dan koefisien korelasi Pearson antara profil insulin metabolik yang diinginkan dan dihitung. Keakuratan pemodelan jaringan PSECMAC dievaluasi terhadap jaringan CMAC dasar dan hasilnya ditabulasikan pada Tabel 4.

Dari plot Gambar 14 dan Gambar 15, serta hasil yang ditabulasikan pada Tabel 4, dapat diamati bahwa ada sedikit penurunan kinerja karena penekanan evaluasi bergeser dari

penarikan kembali ke generalisasi dalam kinerja pemodelan PSECMAC dan jaringan CMAC. Ini adalah fenomena umum karena umumnya; model komputasi cenderung memiliki pemodelan dan kinerja prediksi yang lebih buruk terhadap sampel data yang belum pernah ditemui sebelumnya dalam fase pelatihan. Namun, jelas ditunjukkan bahwa kemampuan generalisasi jaringan PSECMAC melampaui jaringan CMAC dasar baik dalam RMSE maupun koefisien korelasi Pearson. Faktanya, jaringan PSECMAC berhasil mendapatkan kesesuaian yang cukup baik dengan tingkat konsentrasi insulin darah aktual yang dibutuhkan, seperti yang ditunjukkan oleh korelasi tinggi sebesar 97,69% dan RMSE yang relatif rendah sebesar 10,3349 mU/ml konsentrasi insulin darah. Selain itu, diamati bahwa ada penurunan kinerja jaringan CMAC dasar karena ukuran jaringan bertambah dari 8 menjadi 12. Hal ini disebabkan fakta bahwa dalam jaringan CMAC dasar, partisi memori dilakukan tanpa mempertimbangkan struktur yang melekat dan karakteristik dari domain masalah. Hasil ini telah cukup menunjukkan kemampuan jaringan PSECMAC untuk secara efisien menangkap dinamika proses metabolisme glukosa orang sehat dan selanjutnya dapat secara akurat memutuskan tingkat konsentrasi insulin yang tepat berdasarkan pengetahuan yang diperoleh. Secara khusus, berbeda dengan CMAC dasar, jaringan PSECMAC yang diusulkan menyediakan metode yang lebih bermakna dan efisien untuk mengelola sumber daya memori yang terbatas untuk memodelkan dan menangkap karakteristik domain masalah yang diberikan.

**Tabel 20.4** Hasil simulasi pemodelan respon insulin proses metabolisme glukosa sehat

Arsitektur	Modus Evaluasi (per dimension)	Memory Size	RMSE (mU/ml)	Korelasi Pearson
PSECMAC	Mengingat	8	4.8039	0.9942
	Generalisasi	8	10.3349	0.9769
CMAC	Mengingat	8	3.7044	0.9965
	Generalisasi	8	16.4373	0.9405
	Mengingat	12	2.5443	0.9983
	Generalisasi	12	16.9316	0.9383



**Gambar 20.15** Performa pemodelan 3 hari jaringan PSECMAC dalam memodelkan profil insulin orang sehat

## 20.6 KESIMPULAN

Bab ini mengusulkan model komputasi berbasis otak yang terinspirasi otak baru bernama PSECMAC untuk secara fungsional memodelkan proses pengambilan keputusan otonom dalam lingkungan yang kompleks, dinamis, dan tidak pasti. Proses pengambilan keputusan dinamis dicirikan oleh banyak keputusan, saling bergantung dan waktunya nyata, yang terjadi dalam lingkungan yang berubah secara independen sebagai fungsi dari urutan tindakan. Penelitian telah menetapkan bahwa proses pengambilan keputusan seperti itu tampaknya merupakan keterampilan kognitif yang dapat dikembangkan melalui pelatihan dan paparan berulang pada serangkaian episode keputusan.

Sistem memori prosedural manusia adalah aspek dari struktur komputasi informasi otak, dan menunjukkan kapasitas untuk akuisisi pengetahuan dan retensi informasi. Komponen penting dari sistem memori prosedural manusia adalah otak kecil, yang mewakili sistem memori pembelajaran untuk kebiasaan, keterampilan, dan prosedur. Ini memiliki karakteristik ingatan yang cepat dan tidak disadari, dan bertanggung jawab atas banyak

respons perilaku bawah sadar manusia. Ini memberikan motivasi untuk menggunakan PSECMAC, model memori pembelajaran berbasis otak kecil, sebagai alat komputasi untuk pengambilan keputusan otonom untuk masalah yang dinamis, kompleks, dan tidak jelas.

Terinspirasi oleh mekanisme pembelajaran serebelum yang dibentuk melalui studi neurofisiologis, model memori pembelajaran PSECMAC yang diusulkan menggunakan skema manajemen memori yang digerakkan oleh pengalaman, yang telah terbukti lebih efisien dalam menangkap karakteristik bawaan dari domain masalah untuk keputusan yang efektif. membuat. Jaringan PSECMAC menggunakan prosedur alokasi sel memori berbasis kepadatan, yang kemudian diterjemahkan ke representasi yang lebih baik dan lebih tepat dari fitur yang sering ditemui dari masalah yang dimodelkan. Prosedur alokasi seperti itu pada gilirannya menghasilkan representasi yang lebih akurat dari pengetahuan penting yang terkait dengan domain masalah. Kinerja jaringan PSECMAC yang diusulkan selanjutnya dievaluasi dengan menggunakan untuk memodelkan dinamika mekanisme regulasi insulin metabolisme orang sehat ketika terganggu oleh asupan makanan. Pengaturan proses metabolisme glukosa manusia melalui kontrol insulin dapat dianggap sebagai proses pengambilan keputusan otonom, di mana tubuh secara dinamis memutuskan jumlah insulin yang tepat untuk disekresikan sebagai respons terhadap asupan makanan. Hasil simulasi telah cukup menunjukkan efektivitas model PSECMAC yang diusulkan dalam menangkap hubungan interaksi yang kompleks antara tingkat glukosa darah, asupan makanan dan konsentrasi insulin darah yang dibutuhkan untuk homeostasis metabolismik. Kemampuan pemodelan jaringan PSECMAC selanjutnya dibandingkan dengan CMAC dasar dan peningkatan signifikan dicatat.

Sebagai bagian dari pekerjaan masa depan, model insulin berbasis PSECMAC akan digunakan sebagai model referensi untuk mengembangkan rezim kontrol cerdas untuk pompa insulin yang digerakkan oleh algoritme untuk pengobatan diabetes tipe I. Berbagai upaya penelitian ini saat ini sedang aktif dilakukan di Center of Computational Intelligence (C2i) [89] yang terletak di School of Computer Engineering di Nanyang Technological University, Singapura. Laboratorium C2i melakukan penelitian intensif dalam studi dan pengembangan arsitektur memori pembelajaran yang diilhami otak canggih [90-92] untuk pemodelan sistem yang kompleks, dinamis dan non-linear. Teknik ini telah berhasil diterapkan pada berbagai aplikasi baru seperti mengemudi otomatis [93], deteksi pemalsuan tanda tangan [94], kontrol gigi untuk sistem transmisi variabel kontinu (CVT) dalam mobil [95], klasifikasi kegagalan bank dan peringatan dini sistem (EWS) [96], serta dalam domain rekayasa biomedis [97-98].

# Sistem Pendukung Keputusan



Dr. Joseph T.S. M.Kom  
Rektor Universitas  
STEKOM

## PROFILE PENULIS 1

Dr. Joseph Teguh Santoso, S.Kom., M.Kom. adalah Rektor dari Univeristas Sains & Teknologi Komputer (Universitas STEKOM) Semarang yang memiliki banyak pengalaman praktis dalam bidang *E-Commerce* sejak tahun 2002. Beliau mempunyai 3 (tiga) toko *Official Online Store* di China untuk merek sepeda Raleigh, dengan omzet tahunan pada tahun 2019 mencapai lebih dari Rp. 35 Miliar Rupiah dan terus meningkat.

Dr. Joseph T.S memiliki lisensi tunggal sepeda merek "Raleigh" untuk penjualanOnline di seluruh China. di samping itu beliau juga memiliki pabrik

sepeda dan sepeda listrik merek "Fengjiu", yaitu Pabrik Sepeda listrik yang masih tergolong kecil di China. Pengalaman beliau malang melintang di dunia *online store* di China seperti Alibaba, Tmall, Taobao, JD, Aliexpress sangat membantu mahasiswa untuk memiliki pengalaman teknis dan praktis untuk membuka toko *online* bersama beliau.



## PROFILE PENULIS 2

Budi Hartono, S.Kom, M.Kom Lahir di Sleman pada Tanggal 19 September 1968, dan sekarang menetap di Semarang. Menyelesaikan Pendidikan Dasar hingga SLTA di Sleman, Yogyakarta. Menempuh pendidikan Sarjana dari Program Studi S1-Sistem Komputer Universitas Sains dan Teknologi Komputer ( Universitas STEKOM) Lulus Tahun 2004, Program Magister diselesaikan pada Tahun 2006 pada Program Magister Teknik Informatika Universitas Dian Nuswantoro. Saat ini penulis tercatat aktif sebagai Dosen Tetap di Universitas Sains dan Teknologi Komputer ( Universitas STEKOM )

pada Program Studi S1 Teknik Informatika. Untuk matakuliah yang di ampu antara laian adalah Logika dan Algoritma Pemrograman, Pemrograman Visual, Pemrograman Berorientasi Objek, Pengantar Bahasa Query, Sistem Pendukung Keputusan, Sistem Basis Data, Struktur Data, Analisa dan Perancangan Sistem Informasi.

Buku Pemrograman Berorientasi Objek ini adalah hasil karyanya pada tahun 2022. Adapun buku buku karya penulis yang sudah terbit antara lain Pemrograman WAP, Pemrograman Visual dengan Delphi, Sistem Pendukung Keputusan dan Cara Mudah dan Cepat Belajar Pengembangan Sistem Informasi.



YAYASAN PRIMA AGUS TEKNIK

### PENERBIT :

YAYASAN PRIMA AGUS TEKNIK  
Jl. Majapahit No. 605 Semarang  
Telp. (024) 6723456. Fax. 024-6710144  
Email : [penerbit\\_ypat@stekom.ac.id](mailto:penerbit_ypat@stekom.ac.id)

**Penulis :**  
**Dr. Joseph Teguh Santoso, S.Kom, M.Kom**  
**Budi Hartono. M.Kom**

# DSS | Decision Support Systems

# Sistem Pendukung Keputusan



YAYASAN PRIMA AGUS TEKNIK

**PENERBIT :**  
YAYASAN PRIMA AGUS TEKNIK  
Jl. Majapahit No. 605 Semarang  
Telp. (024) 6723456. Fax. 024-6710144  
Email : [penerbit\\_ypat@stekom.ac.id](mailto:penerbit_ypat@stekom.ac.id)